

Mémoire présenté le :

**pour l'obtention du Diplôme Universitaire d'actuariat de l'ISFA
et l'admission à l'Institut des Actuaires**

Par : Eliot NEHME

Titre : Détection de fraude en assurance non-vie grâce à l'intelligence artificielle

Confidentialité : ☐ NON ☒ (Durée : ☐ 1 an ☒ 2 ans)

Les signataires s'engagent à respecter la confidentialité indiquée ci-dessus

*Membres présents du jury de Signature
l'Institut des Actuaires*

Entreprise :

Nom :

Signature :

*Directeur de mémoire en entre-
prise :*

Nom :

Signature :

*Membres présents du jury de
l'ISFA*

Invité :

Nom :

Signature :

***Autorisation de publication et
de mise en ligne sur un site de
diffusion de documents actua-
riels (après expiration de l'éventuel
délai de confidentialité)***

Signature du responsable entreprise

Signature du candidat

Table des matières

Résumé	iv
Abstract	v
Remerciements	vi
Synthèse	vii
Synthesis	viii
Introduction	1
1 Introduction	2
1.1 Définition de la fraude à l'assurance	3
1.2 Les stades d'occurrence de la fraude dans le cycle assurantiel en assurance non-vie	4
1.2.1 La fraude à la souscription	5
1.2.2 La fraude à la déclaration de sinistre	5
1.2.3 La fraude liée aux Conditions Générales	6
1.3 Cadre réglementaire des sanctions en cas de fraude avérée	6
1.3.1 Souscription	9
1.3.2 Sinistre	9
1.3.3 Preuve de la fraude et sanctions pénales	10
1.4 Enjeux économiques et actuariels de la fraude	11
1.4.1 L'ampleur du marché de la fraude	12
1.4.2 Impact de la fraude sur la tarification	14
2 La détection de la fraude en assurance : de l'approche manuelle à l'automatisation par l'IA	18
2.1 L'approche traditionnelle : une détection manuelle et ciblée	19
2.1.1 Le rôle des équipes dédiées	19
2.1.2 Une détection fondée sur l'expertise humaine	19
2.1.3 Les limites de cette approche	20
2.2 L'apport de l'intelligence artificielle : de nouvelles solutions de détection	20
2.2.1 Le contexte d'émergence	21

2.2.2	Les nouvelles approches	21
2.2.3	Les bénéfices attendus	22
2.2.4	Les points de vigilance à l'utilisation de l'intelligence artificielle	22
2.3	Comparaison du processus manuel et du processus automatisé	23
2.3.1	Les critères de comparaison	24
2.3.2	Mise en regard des deux processus	24
2.3.3	Vers un modèle hybride	25
3	Cadre théorique : les algorithmes de détection de fraude utilisés en assurance non-vie	26
3.1	La régression logistique (modèle de référence)	27
3.2	La forêt aléatoire	29
3.3	Le gradient boosting	31
3.4	Les modèles de scoring à points	33
3.5	Apprentissage non supervisé : détection d'anomalies et comportements atypiques	35
3.5.1	Les algorithmes d'isolation (exemple : Isolation Forest)	36
3.5.2	Le partitionnement de données (Clustering)	37
3.6	Analyse de réseaux (Graph Mining) pour la détection de la fraude organisée	37
3.6.1	Modélisation mathématique du réseau de fraude	38
3.6.2	Détection de communautés et de clusters suspects	39
3.6.3	Application opérationnelle	39
3.7	Critères de qualité des modèles mis en place	40
4	Mise en œuvre technique et détection par l'IA	44
4.1	Détection de la fraude opportuniste (Auto et MRH)	45
4.1.1	L'IA au service de l'expertise visuelle (YOLO)	45
4.1.2	Analyse de la falsification documentaire	45
4.2	Détection de la fraude en bande organisée	45
4.2.1	Identification de patterns de coûts identiques	46
4.2.2	Analyse spatiale et comportementale	46
4.3	Évaluation de la performance des modèles	46
4.3.1	Métriques de précision et de rappel	47
4.3.2	Interprétabilité des résultats (XAI)	47
5	Impacts Actuariels, Rentabilité et Perspectives	48
5.1	Analyse de la rentabilité économique (Business Case)	49
5.1.1	Le dilemme du coût de l'investigation	49
5.1.2	Réduction des frais de gestion	49
5.2	Conséquences sur la tarification et le provisionnement	49
5.2.1	Biais statistiques induits par la fraude	50
5.2.2	Impact sur la prime pure et l'équité	50
5.3	Conclusion et ouverture	50
5.3.1	Synthèse des travaux	51
5.3.2	Limites éthiques et réglementaires (RGPD)	51
5.3.3	Perspectives sur l'évolution de la fraude (Deepfakes)	51

6 Conclusion	52
6.1 Résumé des résultats	53
6.1.1 Synthèse des principaux résultats obtenus	53
6.2 ffhfhf	53
Annexes	55
Bibliographie	57

Résumé

La fraude en assurance non-vie représente un enjeu financier majeur, estimé à environ 2,5 milliards d'euros par an en France, dont une large part échappe encore aux dispositifs de détection traditionnels. Fondés sur l'expertise humaine, ces dispositifs ne contrôlent qu'une fraction des dossiers et peinent à traiter la fraude de masse de faible montant, dont le coût de vérification manuelle excède souvent le gain espéré.

Ce mémoire propose de concevoir et déployer, à l'aide d'un agent d'intelligence artificielle, un processus de détection automatisé de la fraude automobile, de l'ingestion des données jusqu'au pilotage du dispositif. À partir d'une base de sinistres enrichie de variables reproduisant l'information disponible chez un assureur, trois modèles sont construits et comparés selon un arbitrage entre interprétabilité et pouvoir prédictif : un scoring en points, un arbre de décision et un modèle de Gradient Boosting. Ce dernier obtient les meilleures performances (AUC de 0,942, lift de $\times 6,66$ au premier décile) tout en concentrant efficacement les fraudes dans un volume restreint de dossiers à investiguer.

L'outil se décline en deux modules destinés à deux équipes distinctes : la construction du modèle par les actuaires, et son exploitation opérationnelle par les gestionnaires, complétée d'une boucle d'enrichissement continu et d'un rapport de pilotage mesurant le retour sur investissement. L'ensemble s'inscrit dans un cadre de gouvernance conforme au RGPD et à l'AI Act, préservant une supervision humaine à chaque étape.

Les schémas et illustrations de ce mémoire ont été réalisés avec l'aide d'outils d'intelligence artificielle générative. De même, une partie des données d'enrichissement de la base a été simulée à l'aide de tels outils, comme précisé en section 4.2.2.

Abstract

Fraud in non-life insurance is a major financial concern, estimated at around 2.5 billion of euros per year in France, a large share of which still evades traditional detection systems. Relying on human expertise, these systems examine only a fraction of claims and struggle to address low-value mass fraud, where the cost of manual verification often exceeds the expected gain.

This dissertation sets out to design and deploy, using an artificial-intelligence agent, an automated motor-insurance fraud detection process spanning data ingestion through to steering the system. Starting from a claims database enriched with variables reproducing the information available to an insurer, three models are built and compared along an interpretability-versus-predictive-power trade-off : a points-based scorecard, a decision tree and a Gradient Boosting model. The latter achieves the best performance (AUC of 0.942, top-decile lift of $\times 6.66$) while effectively concentrating fraud within a limited volume of claims to investigate.

The tool is organised into two modules aimed at two distinct teams : model construction by actuaries, and operational use by claims handlers, complemented by a continuous-enrichment feedback loop and a monitoring report measuring the return on investment. The whole framework complies with the GDPR and the AI Act, preserving human oversight at every stage.

Keywords : insurance fraud, non-life insurance, automated detection, artificial intelligence, machine learning, scoring, Gradient Boosting, actuarial science.

Remerciements

Je tiens à remercier toute l'équipe Actuariat d'Accenture qui m'a permis de réaliser ce mémoire, et plus particulièrement ma tutrice Rachel Atia pour son implication ainsi que sa capacité à enseigner, qui ont été essentielles tout au long de ce projet.

Synthèse

Reposant sur le principe de mutualisation des risques, l'assurance suppose un climat de confiance entre assureur et assuré que la fraude vient détourner. En assurance non-vie, ce phénomène représente une charge estimée à environ 2,5 milliards d'euros par an en France, dont une partie importante demeure non détectée. La lutte traditionnelle, fondée sur le jugement des gestionnaires et des cellules spécialisées, se heurte à une couverture partielle des dossiers, à une forte dépendance à l'expertise individuelle et à un coût de contrôle rendant non rentable l'investigation de la fraude de faible montant.

Face à ce constat, ce mémoire conçoit un processus de détection automatisé de la fraude automobile s'appuyant sur un agent d'intelligence artificielle. La démarche est volontairement circonscrite à la fraude circonstancielle, décelable à partir de données structurées (caractéristiques du sinistre, antécédents, cohérence déclarative), et s'appuie sur une base publique de 30 000 sinistres enrichie de variables reproduisant l'information réellement disponible chez un assureur.

Trois modèles sont construits et comparés selon un arbitrage entre interprétabilité et performance : un scoring en points, transparent et proche des pratiques actuarielles ; un arbre de décision, capable de capter interactions et effets de seuil ; et un modèle de Gradient Boosting, qui obtient les meilleures performances discriminantes (AUC de 0,942, lift de $\times 6,66$ au premier décile). L'évaluation mobilise une batterie d'indicateurs adaptés au fort déséquilibre des classes (Gini, KS, précision, rappel, PR-AUC, PSI), le choix du seuil de décision relevant d'un arbitrage économique entre coût des faux positifs et coût des fraudes non détectées.

L'outil se structure en deux modules indépendants correspondant à deux profils d'utilisateurs : un premier module de construction et de calibration du modèle, destiné aux actuaires ; un second module opérationnel d'aide à la décision, destiné aux gestionnaires, qui attribue à chaque sinistre une probabilité de fraude et l'oriente vers une zone de risque. Ce dispositif est complété par une boucle d'enrichissement continu, alimentée par les issues réelles des dossiers investigués, et par un rapport de pilotage mesurant la fraude évitée, l'impact sur le ratio Sinistres/Primes et le retour sur investissement.

L'ensemble s'inscrit dans un cadre de gouvernance conforme au RGPD et à l'AI Act, garantissant explicabilité, traçabilité et maintien d'une supervision humaine : l'agent hiérarchise les dossiers sans se substituer à la décision de l'enquêteur. Le mémoire se conclut sur les limites du dispositif et ses perspectives d'extension : couplage à la base portefeuille, intégration de données externes, mutualisation inter-assureurs et approche multi-produits.

Synthesis

Built on the principle of risk pooling, insurance presupposes a relationship of trust between insurer and policyholder that fraud diverts to illegitimate ends. In non-life insurance, this phenomenon represents an estimated burden of around 2.5 billion of euros per year in France, a significant part of which remains undetected. Traditional efforts, based on the judgement of claims handlers and specialised units, face partial coverage of claims, heavy reliance on individual expertise, and a control cost that makes investigating low-value fraud economically unviable.

In response, this dissertation designs an automated motor-insurance fraud detection process based on an artificial-intelligence agent. The approach is deliberately confined to circumstantial fraud, detectable from structured data (claim characteristics, past history, declarative consistency), and draws on a public database of 30 000 claims enriched with variables reproducing the information actually available to an insurer.

Three models are built and compared along an interpretability-versus-performance trade-off : a points-based scorecard, transparent and close to actuarial practice ; a decision tree, able to capture interactions and threshold effects ; and a Gradient Boosting model, which achieves the best discriminating performance (AUC of 0.942, top-decile lift of $\times 6.66$). Evaluation relies on a set of indicators suited to strong class imbalance (Gini, KS, precision, recall, PR-AUC, PSI), the choice of decision threshold being an economic trade-off between the cost of false positives and that of undetected fraud.

The tool is organised into two independent modules matching two user profiles : a first module for model construction and calibration, intended for actuaries ; and a second, operational decision-support module for claims handlers, which assigns each claim a fraud probability and routes it to a risk zone. This is complemented by a continuous-enrichment feedback loop, fed by the actual outcomes of investigated claims, and by a monitoring report measuring avoided fraud, the impact on the loss ratio and the return on investment.

The entire framework complies with the GDPR and the AI Act, ensuring explainability, traceability and the preservation of human oversight : the agent prioritises claims without replacing the investigator's decision. The dissertation concludes on the system's limitations and its avenues for extension : coupling with the policy database, integration of external data, cross-insurer data pooling and a multi-product approach.

Introduction

Ce mémoire est vraiment trop bien

Chapitre 1

Introduction

1.1 Définition de la fraude à l'assurance

Le secteur de l'assurance repose sur un principe fondamental : la mutualisation des risques. En échange du paiement d'une prime, l'assuré bénéficie d'une protection financière en cas de réalisation d'un sinistre prévu au contrat. Ce mécanisme de solidarité économique suppose toutefois un climat de confiance entre l'assureur et l'assuré. Lorsque cette confiance est détournée à des fins illégitimes, on parle alors de fraude en assurance.

La fraude en assurance peut être définie comme **tout acte intentionnel visant à tromper un assureur dans le but d'obtenir un avantage indu, qu'il s'agisse d'une indemnisation injustifiée, majorée ou de la souscription d'un contrat dans des conditions mensongères.**

Elle se distingue de l'erreur ou de l'omission involontaire de par son caractère délibéré et frauduleux.

Cette pratique constitue un enjeu majeur pour les compagnies d'assurance, car elle entraîne des pertes financières importantes, impacte l'équilibre technique des portefeuilles et, indirectement, pèse sur l'ensemble des assurés au travers de l'augmentation des primes afin de compenser ces pertes.

L'objectif de la fraude en assurance est principalement financier : il s'agit d'obtenir un enrichissement personnel ou collectif illégitime. Toutefois, au-delà de la recherche d'un gain immédiat, certaines fraudes répondent à des logiques plus complexes, telles que le blanchiment de capitaux, le financement d'activités criminelles ou la structuration d'organisations délictueuses. Ainsi, la fraude peut prendre des formes variées, allant de la simple exagération d'un dommage à la mise en place de réseaux organisés exploitant systématiquement les failles du système assurantiel.

Il convient, à cet égard, de distinguer deux grandes catégories de fraude, la fraude opportuniste et la fraude organisée :

- **La fraude opportuniste** correspond à un comportement isolé, souvent ponctuel, commis par un assuré qui profite d'une situation donnée (par exemple, majorer le montant d'un sinistre ou déclarer un dommage antérieur comme récent). Elle s'inscrit généralement dans une logique individuelle et circonstancielle.
- À l'inverse, **la fraude organisée** repose sur une démarche structurée et planifiée, impliquant parfois plusieurs acteurs (intermédiaires, professionnels de santé, réparateurs, réseaux criminels). Elle est caractérisée par sa répétition, sa préméditation et son ampleur financière plus importante.

Cette distinction est essentielle, car elle implique des modes de détection, de prévention et de répression différents. Là où la fraude opportuniste peut être combattue par des contrôles renforcés et une sensibilisation accrue, la fraude organisée nécessite des dispositifs d'investigation spécialisés, des outils d'analyse de données avancés et une coopération étroite entre assureurs, autorités judiciaires et organismes de régulation.

À noter que la fraude est contraire à un principe important en assurance : **le principe indemnitaire et la règle de non-enrichissement en assurance non-vie.**

Ce principe est expressément consacré par l'article L.121-1 du Code des assurances, selon lequel :

« L'assurance relative aux biens est un contrat d'indemnité ; l'indemnité due par l'assureur à l'assuré ne peut dépasser le montant de la valeur de la chose assurée au moment du sinistre. »

Ce texte pose clairement la règle de non-enrichissement : l'assurance a pour finalité exclusive la réparation du préjudice subi, et non l'octroi d'un profit à l'assuré. L'indemnité ne peut excéder ni le montant du dommage, ni la somme assurée prévue au contrat.

Ainsi, l'indemnisation vise à replacer l'assuré dans la situation patrimoniale qui aurait été la sienne en l'absence de sinistre (principe de réparation intégrale, sans perte ni profit).

Le principe de non-enrichissement joue également un rôle central dans la lutte contre la fraude en assurance non-vie. En effet, toute déclaration intentionnellement inexacte ayant pour effet d'obtenir une indemnité supérieure au préjudice réel constitue une atteinte directe à ce principe.

Plusieurs dispositions viennent renforcer cette protection :

- **Article L.113-2** : obligation pour l'assuré de répondre exactement aux questions posées lors de la souscription et de déclarer sincèrement le sinistre ;
- **Article L.113-8** : nullité du contrat en cas de réticence ou fausse déclaration intentionnelle ;
- **Article L.113-9** : réduction proportionnelle de l'indemnité en cas de déclaration inexacte non intentionnelle.

Dans le cadre de la fraude opportuniste (exagération du montant des dommages, ajout d'objets inexistants, fausse date du sinistre), la violation du principe indemnitaire se traduit par une tentative d'enrichissement indu.

Dans le cas de la fraude organisée (réseaux de sinistres fictifs, collusion avec des réparateurs ou professionnels de santé, sinistres provoqués), la remise en cause est plus systémique : l'objectif n'est plus seulement d'obtenir une indemnité excessive, mais de détourner de manière structurée le mécanisme même de mutualisation.

1.2 Les stades d'occurrence de la fraude dans le cycle assurantiel en assurance non-vie

En assurance non-vie, la fraude peut intervenir à plusieurs étapes de la relation contractuelle. Deux moments apparaissent particulièrement sensibles :

1. La fraude à la souscription du contrat ;
2. La fraude à la déclaration du sinistre.

Ces deux temporalités répondent à des logiques différentes mais poursuivent un objectif commun : obtenir un avantage économique indu en détournant le mécanisme indemnitaire.

1.2.1 La fraude à la souscription

La fraude à la souscription a lieu lors de la conclusion du contrat, avant tout sinistre. Elle consiste à fournir intentionnellement des informations inexactes ou incomplètes afin d'obtenir des conditions tarifaires plus favorables ou de rendre assurable un risque qui ne le serait pas.

Elle constitue une violation directe de l'obligation de déclaration exacte du risque prévue par l'article L.113-2 du Code des assurances.

L'objectif est ici principalement tarifaire : réduire le montant de la prime ou contourner un refus d'assurance.

La fraude à la souscription peut ainsi priver totalement l'assuré de garantie au moment du sinistre.

1.2.2 La fraude à la déclaration de sinistre

La fraude la plus courante en assurance non-vie se produit lors de la déclaration d'un sinistre. Cela peut inclure la surestimation des dommages, la déclaration de sinistres fictifs, la falsification de preuves (comme des photos ou des rapports de police). Ces fraudes visent à obtenir des indemnités plus élevées que celles auxquelles l'assuré aurait pu prétendre, ou bien d'engendrer une indemnité qui n'aurait tout simplement pas dû exister.

À noter que la falsification de documents est de plus en plus accessible et difficile à détecter à l'œil nu suite à l'essor de la *generative IA*.

En assurance non-vie, la fraude peut ainsi être appréhendée selon différents stades d'occurrence dans le cycle assurantiel. Elle peut naître lors de la souscription du contrat, se révéler au moment de la déclaration du sinistre, mais également prendre la forme d'un détournement des stipulations contractuelles, notamment des conditions générales, afin d'obtenir une prise en charge induue.

	Assurance automobile	Assurance habitation
Fraude à la souscription	— Fausse déclaration du conducteur principal : un parent déclare être le conducteur principal alors que le véhicule est utilisé principalement par un jeune conducteur afin d'éviter une surprime. — Fausse adresse de garage : déclaration d'un stationnement en zone rurale alors que le véhicule est stationné en zone urbaine à forte sinistralité. — Dissimulation d'un usage professionnel : déclarer un usage « privé » alors que le véhicule est utilisé pour des livraisons ou VTC. — Fraude documentaire : faux papiers d'identité.	— Sous-évaluation du capital mobilier pour réduire la prime. — Omission de circonstances aggravantes : logement inoccupé plusieurs mois par an, absence de système de sécurité, activité professionnelle à domicile. — Fausse déclaration de la qualité d'occupant (se déclarer propriétaire occupant plutôt que bailleur).

TABLE 1.1 – Exemples de fraude à la souscription en assurance non-vie

1.2.3 La fraude liée aux Conditions Générales

La fraude liée aux conditions générales ne constitue pas, à strictement parler, un moment autonome de la fraude. Elle renvoie plutôt à une logique contractuelle particulière, consistant à manipuler les circonstances du sinistre ou l'interprétation du contrat afin de faire entrer le dommage dans le champ de la garantie. Si cette fraude peut trouver son origine dès la souscription, elle se manifeste le plus souvent lors de la déclaration ou de l'instruction du sinistre.

La fraude aux Conditions Générales en assurance non-vie renvoie à la recherche volontaire d'une indemnisation en contradiction avec les clauses contractuelles (définitions, exclusions, franchises, plafonds, obligations de prévention), sans nécessairement qu'il y ait eu fraude à la souscription.

Elle se matérialise par une manipulation des circonstances du sinistre afin de le faire entrer dans le périmètre de garantie : déclaration d'un vol simple en vol avec effraction, transformation d'un défaut d'entretien en événement accidentel, antériorité dissimulée d'un dommage, ou requalification d'un usage non couvert.

Par exemple, en assurance automobile, dans le cadre d'un sinistre survenu lors d'un usage professionnel alors que le véhicule est déclaré en usage privé, la modification du contexte pour entrer dans le champ contractuel est qualifiée de fraude.

	Assurance automobile	Assurance habitation
Fraude à la déclaration d'un sinistre	— Exagération des dommages : ajout de dégâts antérieurs sur le constat amiable. — Fausse date de sinistre : déclarer un accident survenu avant la souscription comme postérieur à celle-ci. — Sinistre fictif : déclaration d'un vol de véhicule inexistant ou maquillage d'un incendie volontaire. — Accident provoqué intentionnellement (fraude organisée dans certains cas). — Constats de complaisance entre complices pour imputer la responsabilité à un tiers assuré. — Fraude documentaire : faux devis, fausses factures de réparation, gonflement des temps de main-d'œuvre, faux certificats de cession ou documents d'identité, manipulation de photos (dommages antérieurs).	— Ajout d'objets inexistants lors d'un vol déclaré. — Surestimation de la valeur des biens (factures falsifiées ou modifiées). — Déclaration d'un dégât des eaux ancien comme récent pour le rendre indemnisable. — Incendie volontaire destiné à obtenir une indemnité. — Fraude documentaire : fausses factures d'ameublement après vol, devis travaux surévalués après dégât des eaux, falsification de preuves d'effraction, antidatation de justificatifs.

TABLE 1.2 – Exemples de fraude à la déclaration d'un sinistre en assurance non-vie

	Assurance automobile	Assurance habitation
Fraude liée aux conditions générales	— Requalification d'un usage exclu : déclarer un sinistre survenu dans un cadre privé alors que le véhicule était utilisé à titre professionnel, afin de bénéficier de la garantie. — Déclaration inexacte des circonstances du vol : affirmer que les clés n'étaient pas laissées dans le véhicule ou à proximité, afin d'éviter l'application d'une exclusion. — Manipulation des circonstances du sinistre : faire passer une panne mécanique ou un défaut d'entretien pour un dommage accidentel couvert par le contrat. — Fausse qualité du conducteur au moment du sinistre : déclarer que le véhicule était conduit par un conducteur autorisé alors qu'il était utilisé par une personne exclue ou non déclarée. — Contournement d'une franchise ou d'un plafond : fractionner artificiellement un dommage ou modifier sa nature pour obtenir une meilleure prise en charge contractuelle.	— Fausse déclaration d'effraction : présenter un vol simple comme un vol avec effraction pour satisfaire à la condition contractuelle de garantie. — Transformation d'un défaut d'entretien en événement accidentel : présenter une infiltration progressive ou un défaut d'étanchéité comme un dégât des eaux soudain et garanti. — Dissimulation de l'inoccupation du logement : omettre que le logement était vacant au-delà de la durée prévue par le contrat au moment du sinistre. — Requalification d'un bien exclu en bien garanti : déclarer comme mobilier assuré un objet relevant d'une exclusion ou nécessitant une garantie spécifique. — Mise en scène d'un dommage garanti : présenter un dommage esthétique, ancien ou non garanti comme consécutif à un événement couvert (incendie, dégât des eaux, vol).

TABLE 1.3 – Exemples de fraude liée aux conditions générales en assurance non-vie

1.3 Cadre réglementaire des sanctions en cas de fraude avérée

La fraude en assurance ne se limite pas à une simple irrégularité contractuelle : elle peut emporter des conséquences à plusieurs niveaux. Selon le moment où elle intervient et sa nature, elle peut produire des effets civils et contractuels, tels que la nullité du contrat, la déchéance de garantie, le refus d'indemnisation ou la restitution des indemnités indûment versées.

Elle peut également, lorsque les manœuvres frauduleuses sont suffisamment caractérisées, relever du droit pénal. Le régime applicable diffère toutefois selon que la fraude intervient au moment de la souscription du contrat ou lors de la déclaration du sinistre, ce qui justifie de distinguer ces deux hypothèses avant d'aborder les questions probatoires et les qualifications pénales susceptibles d'être retenues.

1.3.1 Souscription

En matière de souscription, le régime des sanctions repose principalement sur les articles L.113-8 et L.113-9 du Code des assurances. Il convient toutefois de distinguer selon que l'inexactitude déclarative procède d'une intention frauduleuse ou d'une simple erreur.

L'article L.113-8 prévoit que la réticence ou la fausse déclaration intentionnelle de l'assuré entraîne la nullité du contrat. Cette sanction suppose que l'assureur démontre non seulement l'inexactitude ou l'omission, mais également le caractère intentionnel de cette déclaration, c'est-à-dire la volonté de tromper l'assureur sur l'appréciation du risque. En pratique, cette intention frauduleuse doit porter sur un élément que l'assureur considérerait comme déterminant dans sa décision de contracter ou dans la fixation de la prime.

La nullité du contrat produit un effet rétroactif : le contrat est réputé n'avoir jamais existé, de sorte que l'assureur n'est pas tenu de garantir le sinistre. En outre, les primes déjà versées demeurent acquises à l'assureur, à titre de dommages et intérêts. Cette sanction est particulièrement sévère et reflète l'exigence de bonne foi qui gouverne la formation du contrat d'assurance.

À l'inverse, l'article L.113-9 vise l'hypothèse d'une déclaration inexacte non intentionnelle. Dans ce cas, il n'y a pas fraude à proprement parler, mais le contrat n'est pas pour autant maintenu sans conséquence. Si l'erreur est constatée avant tout sinistre, l'assureur peut soit maintenir le contrat moyennant une augmentation de prime, soit le résilier. Si elle est découverte après sinistre, l'indemnité peut être réduite proportionnellement au rapport entre la prime payée et celle qui aurait été due si le risque avait été exactement déclaré. Cette distinction entre mauvaise foi et simple erreur est essentielle, car toute anomalie déclarative n'a pas vocation à recevoir la qualification de fraude.

1.3.2 Sinistre

Lorsque la fraude intervient au moment du sinistre, les conséquences juridiques diffèrent de celles applicables à la souscription. Il ne s'agit plus de remettre en cause la formation du contrat, mais de sanctionner

une demande de garantie ou d'indemnisation obtenue ou tentée au moyen de déclarations mensongères, d'une dissimulation de circonstances essentielles ou de la production de pièces falsifiées.

La première conséquence est le refus d'indemnisation lorsque la fraude est détectée avant tout paiement. En pratique, l'assureur peut opposer à l'assuré l'absence de droit à garantie dès lors que le sinistre déclaré ne correspond pas à la réalité ou que son montant a été artificiellement majoré. Cette sanction peut également prendre la forme d'une déchéance de garantie lorsque le contrat prévoit qu'une fausse déclaration intentionnelle relative au sinistre prive l'assuré du bénéfice de la garantie. La déchéance se distingue de la nullité en ce qu'elle n'affecte pas l'existence même du contrat, mais uniquement le droit à indemnisation au titre du sinistre concerné.

Si l'indemnité a déjà été versée au moment de la découverte de la fraude, l'assureur peut engager une action en restitution des sommes indûment perçues. Cette répétition de l'indu permet de récupérer le montant versé en l'absence de droit légitime à indemnisation. Dans les cas les plus graves, l'assureur pourra en outre solliciter des dommages et intérêts en réparation du préjudice subi, notamment lorsque la fraude a entraîné des coûts d'expertise, d'enquête ou de gestion supplémentaires.

En pratique, la mise en œuvre de ces sanctions suppose toutefois que la fraude soit effectivement démontrée. Or, la fraude au sinistre ne se présume pas : l'assureur doit être en mesure d'établir le caractère intentionnel des manœuvres invoquées, ce qui renvoie directement à la question de la preuve, mais également, dans certaines hypothèses, à d'éventuelles poursuites pénales.

1.3.3 Preuve de la fraude et sanctions pénales

La mise en œuvre des sanctions contractuelles suppose, en premier lieu, que la fraude soit prouvée. En droit des assurances comme en droit commun, la fraude ne se présume pas. Il appartient donc à l'assureur d'établir l'existence de manœuvres intentionnelles destinées à obtenir un avantage indu. Cette exigence probatoire est particulièrement importante, car une simple incohérence ou une approximation dans les déclarations de l'assuré ne suffit pas, à elle seule, à caractériser une fraude.

La preuve peut être rapportée par tout moyen et résulte souvent, en pratique, d'un faisceau d'indices graves, précis et concordants. Il peut s'agir, par exemple, d'incohérences entre les déclarations successives, d'anomalies documentaires, de contradictions entre les circonstances déclarées et les constatations matérielles, ou encore de rapprochements opérés à partir d'historiques de sinistres et de données comportementales.

Cette dimension probatoire explique le recours croissant, chez les assureurs, à des dispositifs spécialisés d'investigation, à l'analyse de données et à des modèles de scoring destinés à hiérarchiser les dossiers les plus suspects, sans pour autant se substituer à l'appréciation humaine.

Au-delà des conséquences contractuelles, certaines fraudes à l'assurance peuvent également recevoir une qualification pénale. Lorsque l'assuré use de manœuvres frauduleuses afin de tromper l'assureur pour obtenir la remise de fonds, les faits peuvent relever de l'escroquerie au sens de l'article 313-1 du Code pénal.

De même, la production de justificatifs falsifiés, de fausses factures, de faux constats ou de documents

d'identité altérés est susceptible de constituer un faux ou un usage de faux. Le droit pénal vient ainsi compléter le droit des assurances : là où ce dernier organise les conséquences contractuelles de la fraude, le premier sanctionne la manœuvre frauduleuse elle-même lorsqu'elle porte atteinte à l'ordre public économique.

1.4 Enjeux économiques et actuariels de la fraude

1.4.1 L'ampleur du marché de la fraude

Le marché de l'assurance non-vie représente 80,3 Md€ de primes pour 56,3 Md€ de prestations versées en 2025.

Le volume de sinistres étant très important, il n'est pas envisageable de vérifier manuellement la véracité de chaque déclaration sans rogner de manière trop importante sur la marge de l'assureur.

	Cotisations	Prestations
Assurance de biens et de responsabilité	80,3 Md€	56,3 Md€
Dont assurance automobile	30,2 Md€	24,7 Md€
Dont assurance habitation	14,9 Md€	9,9 Md€

TABLE 1.4 – Cotisations et prestations d'assurance de biens et de responsabilité en 2025 (Source : France Assureurs).

Ainsi, la profession s'est structurée autour de l'ALFA (Agence de Lutte contre la Fraude à l'Assurance).

Créée en février 1989, cette association professionnelle a pour mission d'accompagner les assureurs français dans la prévention et la détection des fraudes. Elle agit comme un véritable carrefour d'informations, centralisant les données, formant les gestionnaires et collaborant avec les pouvoirs publics (notamment le ministère de l'Intérieur) pour endiguer ce phénomène.

La fraude à l'assurance est un phénomène complexe à quantifier avec précision, car par nature, une grande partie reste non détectée. Au niveau européen, la fédération Insurance Europe estime que la fraude représente jusqu'à 10 % du coût total des sinistres¹. En France, selon les estimations de la Fédération Française de l'Assurance et de l'ALFA, le coût global de la fraude s'élèverait à environ 2,5 milliards d'euros par an, soit environ 5 % du niveau d'encaissement des primes².

Les montants identifiés sont ainsi passés de 695 millions d'euros en 2023 à 902 millions d'euros en 2024 (+30 %) et 947 millions d'euros en 2025 (+5 %).

Finalement, les acteurs du marché soulignent et rappellent que c'est la collectivité entière qui est pénalisée, la fraude alourdissant la prime annuelle de chaque assuré honnête d'environ 50 euros sur chaque contrat d'assurance automobile³.

Si ce fléau touche toutes les branches de l'assurance, l'IARD (Incendie, Accidents et Risques Divers) en représente de loin la part la plus importante.

0. https://www.franceassureurs.fr/wp-content/uploads/20260325_presentation-conference-de-presse-2.pdf

1. <https://www.insuranceeurope.eu/mediaitem/0bf0af82-e7ef-4439-a763-d7862859d421/The+impact+of+insurance+fraud.pdf>

2. <https://www.argusdelassurance.com/institutions/fraude-a-l-assurance-une-facture-de-2-5-md-en-dommages-en-2014-alfa.96060>

3. <https://www.argusdelassurance.com/acteurs/fraude-a-l-assurance-un-cout-de-50-pour-les-assures.60931>

3. Sources : <https://www.alfa.asso.fr/alfa-news-48-septembre-2024/>; <https://www.alfa.asso.fr/alfa-news-39-juin-2023-2/> et <https://www.franceassureurs.fr/wp-content/uploads/donnees-cles-2024.pdf>




FIGURE 1.1 – Évolution de la fraude automobile entre 2020 et 2025 (Source : ALFA Association).

À titre d'exemple, sur les 947 millions d'euros de fraudes détectées en 2025, 627 millions concernent exclusivement l'IARD (notamment l'assurance Automobile et l'assurance Multirisque Habitation), soit près de 66 % du total⁴.

Les assurances de biens, par leur forte fréquence de sinistralité, demeurent le secteur le plus exposé aux déclarations de sinistres fictifs ou à la surestimation des dommages.

Ces segments cumulent plusieurs facteurs d'exposition : une fréquence de sinistres élevée, une forte volumétrie de dossiers de montant unitaire parfois modéré, ainsi qu'une documentation déclarative susceptible d'être manipulée.

En assurance automobile, la multiplicité des intervenants (assuré, tiers, réparateur, expert, dépanneur) accroît les opportunités de fraude. En habitation, la difficulté de vérifier a posteriori la réalité, l'antériorité ou la valeur des biens déclarés favorise également les comportements opportunistes.

Ce phénomène et ses proportions ne sont pas une spécificité française. À l'échelle européenne, la fédération Insurance Europe estime que la fraude représente en moyenne jusqu'à 10 % du coût total des sinistres dans les pays voisins (comme au Royaume-Uni ou en Allemagne). La France se situe donc dans cette moyenne continentale. Toutefois, l'écart observé au niveau européen entre la fraude détectée (environ 2,5 milliards d'euros) et la fraude réelle non détectée (estimée à plus de 13 milliards d'euros) souligne qu'une immense partie des préjudices passe encore « à travers les mailles du filet ». Cette « fraude invisible » représente un défi majeur pour la rentabilité des compagnies d'assurance.

4. <https://www.argusdelassurance.com/assurance-de-personnes/des-filieres-de-larnaque-utilisent-lintelligence-artificielle/VRVQHSDANZGGZL5GXH7FHW3JU4.html>

1.4.2 Impact de la fraude sur la tarification

L'enjeu de la fraude ne se résume pas à une perte ponctuelle pour les assureurs : il affecte plus largement l'équilibre technique du marché, la qualité des données historiques et, en définitive, la construction même des primes. C'est ce lien direct entre fraude, sinistralité observée et tarification qu'il convient désormais d'examiner.

1.4.2.1 Modèle tarifaire usuel en assurance non-vie et biais statistiques

En assurance non-vie, la tarification repose usuellement sur des Modèles Linéaires Généralisés (GLM).

La Prime Pure (PP) est modélisée par le produit de l'espérance de la fréquence des sinistres (N) et de l'espérance de leur coût moyen (C) :

$$PP = \mathbb{E}[N] \times \mathbb{E}[C] \quad (1.1)$$

L'absence de détection de la fraude introduit un biais systématique dans les bases de données utilisées pour calibrer ces modèles tarifaires (que ce soit via des GLM traditionnels ou des algorithmes de Machine Learning comme XGBoost) :

- **Impact sur la fréquence (N)** : la fraude opportuniste ou préméditée (déclaration de sinistres imaginaires) augmente artificiellement le nombre de sinistres dans le portefeuille.
- **Impact sur le coût moyen (C)** : la majoration de dommages (ajout d'éléments fictifs sur une facture réelle) gonfle la sévérité moyenne des sinistres.

Si l'actuaire calibre ses modèles sur ces données polluées, il surestime le risque réel du portefeuille sain. La prime demandée aux assurés honnêtes augmente, ce qui dégrade la compétitivité de l'assureur sur le marché.

1.4.2.2 Conséquence de la fraude sur la prime pure

Dans l'équation de la prime pure, une surestimation de la fréquence ou du coût moyen conduit mécaniquement à une prime plus élevée pour l'ensemble du portefeuille.

Dans le cas de la fraude par majoration (sinistre réel mais montant surévalué), l'impact est directement porté sur l'espérance du coût moyen $\mathbb{E}[C]$:

$$\mathbb{E}[C]_{\text{fraude}} = \mathbb{E}[C]_{\text{réel}} + \mathbb{E}[C]_{\text{majoration}} \quad (1.2)$$

Dans le cas de la fraude par invention (sinistre totalement fictif), l'impact est porté sur la fréquence $\mathbb{E}[N]$:

$$\mathbb{E}[N]_{\text{fraude}} = \mathbb{E}[N]_{\text{réel}} + \mathbb{E}[N]_{\text{fictif}} \quad (1.3)$$

Ainsi, si l'on note α la part de la charge sinistre imputable à la fraude, la prime d'équilibre technique observée ($\Pi_{\text{chargée}}$) se déduit de la prime pure théorique (Π_{pure}) par la relation :

$$\Pi_{\text{chargée}} = \frac{\Pi_{\text{pure}}}{1 - \alpha} \quad (1.4)$$

où α est estimé entre 5 % et 10 % du volume des prestations selon les branches (Source : ALFA).

Part de la fraude dans la charge (α)	Surcoût sur la prime pure (%)
5,0 %	+ 5,26 %
7,5 %	+ 8,11 %
10,0 %	+ 11,11 %

TABLE 1.5 – Impact du levier de la fraude sur la prime des assurés honnêtes

Il faut souligner que l'effet de la fraude sur la tarification ne se limite pas à une hausse mécanique de la prime pure. Il se propage également aux chargements de gestion, dans la mesure où la lutte contre la fraude mobilise des ressources d'expertise, de contrôle et de contentieux.

En outre, une répercussion trop importante de ces coûts dans les primes commerciales peut nuire à la compétitivité de l'assureur et accentuer les phénomènes d'anti-sélection, en éloignant les assurés les moins risqués du portefeuille.

De plus, un enjeu central réside dans le fait que la fraude peut fausser la segmentation elle-même.

En effet, certaines variables explicatives peuvent apparaître comme fortement corrélées à la sinistralité observée non pas en raison d'un risque assurantiel intrinsèque plus élevé, mais parce qu'elles sont associées à une fréquence accrue de comportements frauduleux ou à des modalités de détection différenciées. L'actuaire court alors le risque d'intégrer dans la tarification des effets qui relèvent moins du risque pur que de distorsions comportementales ou informationnelles.

Inversement, l'amélioration des dispositifs de détection permet d'assainir les bases historiques servant à la modélisation actuarielle. À terme, une meilleure identification des dossiers frauduleux contribue à restaurer une mesure plus fidèle du risque technique, à améliorer la segmentation tarifaire et à limiter le transfert de charge vers les assurés honnêtes. La lutte contre la fraude devient ainsi non seulement un levier de réduction des pertes, mais également un instrument de qualité tarifaire.

1.4.2.3 L'analyse coût-bénéfice : le seuil de rentabilité du contrôle

Pour corriger ce biais tarifaire, l'assureur doit identifier et rejeter les sinistres frauduleux. Cependant, le processus de détection n'est pas gratuit : il engage des frais de gestion supplémentaires (expertise contradictoire, enquête administrative, recours à un détective privé).

L'assureur fait donc face à un problème d'optimisation économique simple : l'espérance d'économie (le non-paiement du sinistre) doit être supérieure au coût du contrôle.

Soit C_{invest} le coût moyen d'une investigation et M_{sinistre} le montant du sinistre réclamé. Le contrôle n'est rationnel que si :

$$M_{\text{sinistre}} \times P(\text{Fraude} \mid \text{Alerte}) > C_{\text{invest}} \quad (1.5)$$

où $P(\text{Fraude} \mid \text{Alerte})$ représente la précision du modèle de détection (la probabilité que l'alerte soit réellement fondée).

Sur le marché IARD français, une expertise automobile classique coûte entre 70 € et 400 € par dossier⁵, tandis qu'une investigation spécialisée (enquêteur certifié ALFA) peut rapidement dépasser les 1 000 €, les honoraires étant libres et dépendant fortement du type de sinistre.

Ainsi, pour un sinistre matériel de 1 200 €, engager une expertise à 250 € est rentable. En revanche, pour de « petits sinistres » (par exemple un bris de glace à 400 €), le coût administratif et d'expertise rend la détection humaine irrationnelle d'un point de vue économique.

1.4.2.4 L'automatisation de la détection de la fraude comme levier de rentabilité

C'est sur cette « fraude de masse » — de faible montant — que le modèle traditionnel atteint ses limites, et que l'implémentation de nouvelles technologies devient indispensable.

En effet, à date, avec la digitalisation, on observe une hausse des tentatives de fraude, notamment au travers de falsifications numériques et de retouches d'image⁶.

En parallèle, l'amélioration des outils tels que la Data analytics, la détection d'anomalies, l'analyse d'image ou le Cross-checking de bases externes permet d'améliorer le taux de détection des fraudes.

Néanmoins, malgré l'amélioration des méthodes de détection de fraude, la fraude documentaire reste un poste matériel dans le coût technique global. En mettant en place des méthodes de détection de fraude automatiques (algorithmes de scoring, IA etc.), l'assureur réduit drastiquement le coût de traitement et de ciblage des fraudes.

Le coût marginal de vérification s'approchant de zéro, il devient alors rentable d'investiguer des sinistres de plus faible montant, assainissant ainsi la base de sinistralité et protégeant l'équilibre de la prime.

C'est précisément dans la réponse à ce défi opérationnel et financier que s'inscrit l'objectif central de ce mémoire. En effet, les ambitions des travaux de ce mémoire sont de concevoir et déployer un processus de détection automatisé des fraudes de bout en bout.

Il convient toutefois de circonscrire d'emblée le périmètre de cette détection. Notre démarche ne porte pas sur la fraude documentaire (falsification de factures, de devis ou d'attestations) ni sur la fraude

5. Source : Service public.

6. La fraude documentaire (faux certificats, fausses factures, photos retouchées) est en explosion et représente désormais 39 % des cas de fraude détectés en IARD (source : <https://www.itesoft.com/fr/blog/fraude-assurance-chiffres-cles-alfa/>).

relevant de l'analyse d'images (clichés retouchés ou détournés), faute de disposer des bases de données documentaires et photographiques nécessaires à l'entraînement de tels modèles.

L'approche retenue se concentre au contraire sur la fraude circonstancielle, c'est-à-dire celle qui se révèle à travers les caractéristiques mêmes du sinistre et de l'assuré : nature et chronologie de la déclaration, antécédents et historique du contrat, profil du déclarant, cohérence entre les circonstances rapportées et les paramètres du sinistre, ou encore récurrence de signaux faibles susceptibles de trahir une intention frauduleuse.

Cette orientation présente l'avantage de s'appuyer exclusivement sur des données structurées déjà disponibles dans les systèmes de gestion de l'assureur, ce qui en fait un levier à la fois exploitable, reproductible et directement intégrable au processus d'instruction des sinistres.

Pour y parvenir, l'étude s'appuie sur une base de données publique de sinistres automobiles issue de Kaggle, contenant des dossiers étiquetés comme frauduleux ou non. À défaut de données réelles d'assureur — difficilement accessibles pour des raisons de confidentialité — cette base offre un support représentatif et reproductible pour développer et tester la démarche, même si sa transposition à un portefeuille réel nécessiterait une phase de recalibrage.

Pour pallier en partie à ce recalibrage inexistant, cette base a été enrichie avec des données qui auraient été disponibles chez un assureur de manière à enrichir le modèle de détection de fraude créé.

Les chapitres suivants détailleront cette démarche : après un état des lieux des processus de détection existants et de l'apport de l'intelligence artificielle (Chapitre 2), en opposition à ce qui se fait déjà en matière de détection de fraude (Chapitre 3), nous présenterons la construction et la comparaison des trois modèles de détection retenus (scoring en points, arbre de décision et Gradient Boosting) ainsi que l'évaluation de leurs performances respectives (Chapitre 4). Le Chapitre 5 décrira l'outil opérationnel développé à destination des services de gestion des sinistres, suivi du Chapitre 6 qui expliquera la logique d'enrichissement continu du modèle. Enfin, le Chapitre 7 ouvrira sur les limites de l'outil et les perspectives d'évolution, notamment autour de la qualité des données, de la mutualisation inter-assureurs et de l'extension à une approche multi-produits.

Chapitre 2

La détection de la fraude en assurance :
de l'approche manuelle à l'automatisa-
tion par l'IA

2.1 L'approche traditionnelle : une détection manuelle et ciblée

2.1.1 Le rôle des équipes dédiées

Historiquement, la lutte contre la fraude en assurance non-vie repose sur une organisation humaine structurée, intégrée à la chaîne de gestion des sinistres.

Le premier maillon en est le gestionnaire de sinistres : chargé d'instruire les déclarations et de procéder à l'indemnisation, il constitue le point de contact initial avec le dossier et, à ce titre, la première ligne de détection.

Lorsqu'un dossier éveille un doute, il peut être orienté vers une instance spécialisée (service ou cellule anti-fraude) composée d'enquêteurs et d'analystes dont c'est le métier exclusif. Ces cellules regroupent souvent des enquêteurs spécialisés, des data analystes (pour la détection algorithmique), des juristes et parfois d'anciens policiers ou gendarmes.

Ces enquêteurs disposent de prérogatives et de moyens d'investigation plus poussés : demande de pièces complémentaires, vérification des déclarations, recoupement avec des bases sectorielles, recours éventuel à des expertises ou à des enquêtes de terrain.

Cette organisation s'insère à un point précis de la chaîne d'indemnisation : entre la déclaration du sinistre et le versement de l'indemnité. La détection intervient ainsi comme un filtre, destiné à suspendre ou approfondir l'instruction des dossiers suspects avant que l'indemnisation ne soit prononcée.

Sa position est donc stratégique, puisqu'une fraude non détectée à ce stade se traduit directement par un versement indu, tandis qu'un contrôle trop systématique alourdit les délais de gestion et dégrade la qualité de service pour les assurés de bonne foi. L'équilibre entre maîtrise du risque de fraude et fluidité du règlement constitue l'arbitrage permanent de ces équipes.

2.1.2 Une détection fondée sur l'expertise humaine

Dans ce dispositif traditionnel, la détection repose essentiellement sur le jugement et l'expérience des intervenants. Elle s'opère largement « au fil de l'eau » : c'est au moment de l'instruction d'un dossier que le gestionnaire, par sa connaissance des cas habituels, perçoit une anomalie ou une incohérence. Cette vigilance s'appuie sur un ensemble de signaux d'alerte ou *red flags* issus de l'expérience accumulée : délai anormalement court entre la souscription et le sinistre, déclaration tardive, circonstances peu cohérentes, antécédents répétés, montant de dommages disproportionnés, ou encore concordances suspectes entre plusieurs dossiers.

Une fois le soupçon né, la confirmation passe par un travail de recoupement manuel : rapprochement des informations déclarées, comparaison avec l'historique du contrat et de l'assuré, vérification de la cohérence d'ensemble. Ce processus mobilise fortement l'intuition métier, c'est-à-dire la capacité, forgée par la pratique, à identifier des configurations atypiques que ne traduit aucune règle écrite. Cette

expertise humaine constitue une force réelle : elle est fine, contextuelle et capable d'appréhender des situations inédites. Mais elle est aussi, par nature, difficilement formalisable et transmissible, ce qui en fait simultanément la principale limite de l'approche.

2.1.3 Les limites de cette approche

Si l'expertise humaine demeure précieuse, l'organisation traditionnelle se heurte à plusieurs limites structurelles. La première tient à sa couverture partielle : le contrôle manuel étant coûteux en temps, seule une fraction des dossiers peut être examinée en profondeur, la grande majorité étant traitée sans analyse anti-fraude approfondie. Il en résulte un risque non négligeable de non-détection : de nombreuses fraudes échappent au dispositif, non parce qu'elles seraient indétectables, mais faute de ressources pour les examiner, passant inaperçues sous la forme de faux négatifs lorsque les indices ne sont pas suffisamment manifestes.

S'y ajoute une forte dépendance à l'expertise individuelle. La qualité de la détection varie selon l'expérience, la charge de travail et la vigilance de chaque gestionnaire, chacun appliquant ses propres critères et son propre niveau de rigueur. Il en découle une hétérogénéité des décisions (un même dossier pourra être contrôlé par l'un et laissé passer par l'autre) qui nuit à la reproductibilité du processus et à son auditabilité. Le caractère manuel des vérifications induit par ailleurs une lenteur de traitement et un coût humain élevé, puisque chaque dossier suspect doit être examiné de façon approfondie et que l'augmentation du nombre de contrôles suppose un accroissement proportionnel des effectifs, ce qui ralentit le règlement global des sinistres.

L'approche montre enfin ses limites dans l'exploitation des données disponibles. Les volumes d'informations accumulés au fil du temps sont difficiles à analyser de manière exhaustive sans outils automatisés, ce qui empêche d'identifier les schémas récurrents ou les comportements suspects à grande échelle. Cette difficulté favorise en outre des biais d'attention : à force de concentrer les contrôles sur certains profils ou types de sinistres réputés à risque, on délaisse les schémas de fraude moins familiers et l'on reproduit des a priori non fondés.

L'ensemble de ces limites converge vers un même enjeu de rentabilité. Le volume de fraudes effectivement détecté reste faible au regard du coût que représente le dispositif humain, et surtout au regard de la fraude réellement présente dans le portefeuille. Le rapport entre les montants recouvrés et les ressources mobilisées plafonne, sans qu'il soit possible de l'améliorer significativement par les seuls moyens manuels. C'est précisément cette inefficience (un coût élevé pour une couverture limitée) qui motive le recours à une détection automatisée fondée sur l'intelligence artificielle, capable d'analyser l'intégralité des dossiers à un coût marginal réduit et de dépasser ainsi un grand nombre des limites associées aux méthodes manuelles.

2.2 L'apport de l'intelligence artificielle : de nouvelles solutions de détection

2.2.1 Le contexte d'émergence

L'essor des solutions de détection automatisée n'est pas le fruit d'une rupture isolée, mais la convergence de plusieurs évolutions.

La première est l'explosion du volume de données structurées disponibles : la dématérialisation de la gestion des sinistres, la standardisation des systèmes d'information, la conservation systématique de l'historique des contrats et des déclarations ont constitué des bases de données riches, exploitables et homogènes, là où l'information était auparavant éparse et largement non numérisée.

La deuxième tient à la maturité des méthodes d'apprentissage : les algorithmes de machine learning, et en particulier les méthodes d'ensemble sur données tabulaires présentées précédemment, sont désormais éprouvés, accessibles via des bibliothèques robustes et applicables à coût raisonnable.

La troisième relève du contexte économique : la pression croissante sur les coûts et sur les délais de gestion pousse les assureurs à rechercher des gains d'efficacité, tandis que la fraude, par son impact direct sur la sinistralité et donc sur la prime, demeure un enjeu financier majeur. La conjonction de ces facteurs (données disponibles, outils matures et nécessité économique) a rendu possible et souhaitable le passage à des dispositifs automatisés.

2.2.2 Les nouvelles approches

Ce passage s'est opéré par étapes. Les premiers dispositifs automatisés reposaient sur des moteurs de règles : des conditions explicites, traduisant les signaux d'alerte connus des experts (un délai inférieur à tel seuil, un cumul de sinistres supérieur à tel nombre), déclenchaient une alerte. Reproduisant la connaissance métier, ces systèmes en héritaient aussi les limites : rigides, ils ne détectaient que la fraude déjà identifiée et se révélaient incapables d'appréhender des schémas nouveaux ou la conjonction subtile de plusieurs facteurs.

Les modèles prédictifs ont marqué l'évolution suivante. Plutôt que d'appliquer des règles figées, ils apprennent à partir de l'historique des dossiers à attribuer à chaque sinistre un score de risque de fraude, c'est-à-dire une probabilité estimée à partir de l'ensemble de ses caractéristiques. Cette approche autorise une détection circonstancielle, fondée sur les caractéristiques du sinistre et de l'assuré (chronologie, antécédents, cohérence des circonstances déclarées, profil du dossier) et capable de capter automatiquement des interactions que nul ne formaliserait sous forme de règle. Surtout, elle modifie en profondeur la logique de couverture : alors que le contrôle manuel ne portait que sur un échantillon de dossiers, le modèle procède à un traitement systématique de l'ensemble des dossiers, chacun se voyant attribuer un score, sans tri préalable.

2.2.3 Les bénéfices attendus

Il découle de ces approches plusieurs bénéfices :

- **Une augmentation du volume de fraudes détectées** : en analysant l'intégralité du portefeuille plutôt qu'une fraction, le dispositif fait remonter des dossiers suspects qui auraient échappé à un contrôle manuel nécessairement sélectif. Cette couverture exhaustive s'accompagne d'une capacité analytique accrue : en exploitant aussi bien les données courantes que les historiques, le modèle détecte des schémas complexes et des corrélations difficilement identifiables par l'humain, améliorant ainsi la détection des fraudes les plus élaborées, souvent caractérisées par des signaux faibles ou dispersés.
- **Une réduction du coût unitaire de détection** : une fois le modèle développé, le scoring d'un dossier supplémentaire présente un coût marginal quasi nul, ce qui améliore directement le rapport entre les fraudes détectées et les ressources mobilisées.
- **Une réduction des délais de traitement** : grâce au tri automatique, de grands volumes de sinistres peuvent être analysés quasi instantanément, accélérant ainsi le règlement des dossiers sains tout en orientant sans délai les cas suspects vers l'investigation.
- **Une priorisation objective, homogène et reproductible** : le score fournit un critère unique de hiérarchisation des dossiers, appliqué de manière identique à tous. En substituant des règles et des algorithmes standardisés à l'appréciation individuelle, cette homogénéisation des pratiques garantit une cohérence d'évaluation indépendante des intervenants et réduit le risque de biais subjectifs ou discriminatoires.
- **Une forte capacité de passage à l'échelle** : ces dispositifs absorbent des volumes croissants de données sans accroissement proportionnel des effectifs ni dégradation des performances. L'intervention humaine est ainsi recentrée sur les seuls dossiers présentant le niveau de risque le plus élevé, un atout précieux dans un contexte de croissance et de diversification des flux.

Cette logique constitue le fondement de l'outil développé dans ce mémoire. À chaque nouveau sinistre, l'agent attribue une probabilité de fraude permettant de hiérarchiser les dossiers selon leur niveau de risque. Les équipes d'investigation peuvent ainsi concentrer leurs efforts sur les cas les plus suspects, sans mobiliser inutilement des ressources sur les dossiers présentant une faible probabilité de fraude. Le score ne se substitue pas à la décision humaine : il l'éclaire en transformant un ensemble de déclarations en une file de traitement priorisée.

2.2.4 Les points de vigilance à l'utilisation de l'intelligence artificielle

Ces bénéfices ne sont toutefois pas acquis sans contrepartie, et l'automatisation appelle plusieurs précautions, déjà évoquées dans le cadre de la gouvernance :

- **La qualité des données** : un modèle n'a de valeur que celle des données sur lesquelles il est entraîné. Des données incomplètes, erronées ou biaisées se traduisent mécaniquement par des prédictions de moindre qualité.
- **L'explicabilité des résultats** : un score de fraude ne saurait être opposé à un assuré sans que les facteurs ayant conduit à son attribution puissent être compris et justifiés. Cette exigence répond à des impératifs à la fois opérationnels, réglementaires et éthiques.
- **Le maintien d'une supervision humaine** : l'agent identifie les dossiers susceptibles de présenter un risque de fraude, mais ne prend pas la décision finale. L'investigation et la décision demeurent du ressort des équipes, ce qui permet d'éviter toute décision défavorable fondée exclusivement sur un traitement automatisé.
- **La surveillance de la performance du modèle** : les comportements frauduleux et les caractéristiques du portefeuille évoluant au fil du temps, les performances d'un modèle peuvent se dégrader en l'absence d'un suivi continu et d'un réentraînement périodique.

Loin de constituer une solution autosuffisante, l'intelligence artificielle apparaît ainsi comme un outil puissant dont l'efficacité demeure étroitement conditionnée à la qualité des données, à la robustesse de sa gouvernance et au maintien d'un cadre de contrôle rigoureux.

2.3 Comparaison du processus manuel et du processus automatisé

2.3.1 Les critères de comparaison

Comparer l'approche traditionnelle et l'approche automatisée suppose de fixer au préalable les dimensions sur lesquelles porte l'évaluation, afin d'éviter un jugement global et impressionniste. Sept critères apparaissent particulièrement structurants :

1. Le volume de dossiers analysés mesure la part du portefeuille effectivement soumise à un examen anti-fraude.
2. Le taux de détection rapporte les fraudes identifiées à la fraude réellement présente, et traduit l'efficacité du dispositif.
3. Le coût par dossier rend compte des ressources consommées pour analyser une déclaration.
4. Le délai de traitement conditionne la fluidité du règlement et la qualité de service.
5. L'homogénéité et la traçabilité des décisions renvoient à la reproductibilité du processus et à sa capacité à être audité.
6. La scalabilité désigne l'aptitude du dispositif à absorber une hausse du volume sans dégradation.
7. Enfin, la dépendance à l'expertise caractérise la vulnérabilité du processus à la disponibilité et au niveau de compétence des intervenants.

Ces critères couvrent ainsi les trois enjeux essentiels : l'efficacité de la détection, son coût, et sa robustesse.

2.3.2 Mise en regard des deux processus

La confrontation des deux approches selon ces critères peut être synthétisée comme suit :

Cette mise en regard fait clairement ressortir l'avantage de l'automatisation sur les dimensions de volume, de coût, de délai et d'homogénéité. Elle ne doit cependant pas être lue comme la disqualification de l'intervention humaine.

D'une part, l'expertise reste indispensable en amont, pour concevoir, entraîner et valider le modèle, et en aval, pour instruire les dossiers signalés. D'autre part, le modèle ne produit qu'une probabilité de fraude, c'est-à-dire un soupçon hiérarchisé, et non une preuve : seule l'investigation humaine permet d'établir la réalité de la fraude et d'en tirer les conséquences.

L'automatisation ne supprime donc pas le travail humain, elle le réoriente : libérée du tri d'une masse indifférenciée de dossiers, l'expertise se concentre sur les cas à plus forte valeur ajoutée, ceux que le modèle a identifiés comme les plus à risque.

Critère	Processus manuel	Processus automatisé (IA)
Volume de dossiers analysés	Partiel : seule une fraction des dossiers est examinée	Exhaustif : l'ensemble des dossiers est scoré
Taux de détection	Limité par la capacité humaine de contrôle	Plus élevé, y compris sur des schémas peu visibles
Coût par dossier	Élevé et croissant avec le volume	Faible coût marginal après développement du modèle
Délai de traitement	Long, tributaire de la charge des équipes	Quasi instantané (scoring automatique)
Homogénéité et traçabilité	Variable, subjective, peu reproductible	Critère unique, appliqué identiquement et traçable
Scalabilité	Faible : suppose d'accroître les effectifs	Élevée : montée en charge à coût quasi constant
Dépendance à l'expertise	Forte : qualité tributaire de chaque intervenant	Réduite à l'usage, déportée vers la conception du modèle

TABLE 2.1 – Comparaison du processus manuel et du processus automatisé de détection de la fraude

2.3.3 Vers un modèle hybride

De cette comparaison se dégage non pas une opposition, mais une complémentarité. Les forces de chaque approche répondent précisément aux faiblesses de l'autre : l'IA excelle dans le traitement exhaustif, rapide et homogène de gros volumes, là où l'humain excelle dans l'analyse fine, contextuelle et le jugement sur les cas complexes.

La configuration la plus efficace est dès lors un modèle hybride, dans lequel chaque acteur intervient là où il est le plus pertinent. L'IA assure le filtrage et la priorisation : elle analyse l'ensemble des dossiers et les classe par niveau de risque. L'humain assure l'investigation et la décision finale : il examine les dossiers prioritaires, confirme ou écarte la suspicion, et prononce les suites à donner. Cette articulation préserve la maîtrise humaine du processus tout en démultipliant sa portée.

C'est exactement cette logique hybride que met en œuvre l'Agent développé dans ce mémoire, dont nous présenterons la conception et le fonctionnement après un rapide rappel du cadre théorique sur les algorithmes de détection de fraude utilisés en assurance non-vie.

Chapitre 3

Cadre théorique : les algorithmes de détection de fraude utilisés en assurance non-vie

La détection de la fraude circonstancielle se formule naturellement comme un problème d'apprentissage supervisé binaire. Cette formulation suppose de disposer d'un historique de sinistres dont l'issue (frauduleuse ou licite) a été établie, par exemple à l'issue d'enquêtes passées. On note l'échantillon d'apprentissage :

$$\mathcal{D}_n = \{(x_i, y_i)\}, \quad i = 1, \dots, n, \quad (3.1)$$

où le vecteur $x_i \in \mathbb{R}^p$ rassemble les p caractéristiques décrivant le sinistre et l'assuré (montant déclaré, ancienneté du contrat, délai entre la souscription et la survenance, antécédents, nature de la garantie, canal de déclaration, etc.), et où la variable cible $y_i \in \{0, 1\}$ vaut 1 lorsque le sinistre est frauduleux. Cette classe d'intérêt est par nature minoritaire, ce qui constitue l'une des principales difficultés statistiques du problème et conditionne tant le choix des modèles que celui des métriques d'évaluation. L'objectif commun à toutes les méthodes présentées ci-dessous est d'estimer une fonction de score exprimant la probabilité de fraude conditionnelle aux caractéristiques observées :

$$\hat{p}(x) = \hat{P}(Y = 1 \mid X = x) \in [0, 1]. \quad (3.2)$$

Le recours à une sortie continue plutôt qu'à une décision binaire immédiate est un choix structurant. Il permet de hiérarchiser les dossiers selon leur niveau de risque et de ne déclencher une investigation (coûteuse) que sur les cas les plus suspects, le seuil de décision étant calibré séparément selon une logique économique (rapport entre le coût d'une enquête et le gain espéré d'une fraude évitée). Cette logique de score partagée explique également pourquoi l'évaluation des modèles ne peut reposer sur le simple taux de bonnes classifications, trompeur en présence de classes déséquilibrées, mais s'appuie sur des indicateurs tels que la précision, le rappel et l'aire sous la courbe précision-rappel.

Les quatre familles de modèles retenues dans ce mémoire sont présentées selon un fil conducteur unique : l'arbitrage entre interprétabilité et pouvoir prédictif.

On progresse ainsi de la régression logistique, modèle paramétrique parfaitement transparent, vers la forêt aléatoire puis le gradient boosting, dont la capacité à capturer des relations complexes se paie d'une opacité croissante, avant de revenir avec les modèles de scoring à points à une représentation directement lisible par les équipes métier.

À noter que dans un secteur soumis à de fortes exigences d'explicabilité et de gouvernance (notamment de la part de l'ACPR¹), cet arbitrage n'est pas un simple détail technique mais un critère de sélection à part entière.

1. ACPR : Autorité de Contrôle Prudentiel et de Résolution.

3.1 La régression logistique (modèle de référence)

La régression logistique constitue la référence historique de la modélisation du risque en actuariat. Il s'agit d'un modèle linéaire généralisé (GLM) appartenant à la famille binomiale et doté de la fonction de lien logit. Plutôt que de modéliser directement la probabilité, dont le domaine est borné à l'intervalle $[0, 1]$, le modèle agit sur le logarithme de la cote de fraude (le « log-odds »), dont le domaine couvre l'ensemble des réels, et le relie linéairement aux variables explicatives. Ainsi, la probabilité de fraude $p(x)$ s'écrit :

$$\ln \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \sum_{j=1}^p \beta_j x_j \quad (3.3)$$

En inversant cette relation, on retrouve la fonction logistique (ou sigmoïde) qui garantit une probabilité comprise entre 0 et 1. En notant $\eta = \beta_0 + \beta^\top x$ le prédicteur linéaire, la probabilité de fraude s'écrit :

$$p(x) = \frac{1}{1 + e^{-\eta}} \quad (3.4)$$

La forme sigmoïdale a une conséquence importante pour l'interprétation : la relation est linéaire sur l'échelle du logit, mais l'effet d'une variable sur la probabilité n'est pas constant : il est maximal autour de $p = 0,5$ et s'atténue aux extrêmes. Les coefficients β sont estimés par maximum de vraisemblance. Contrairement à la régression linéaire, il n'existe pas de solution analytique : la log-vraisemblance, dont l'expression est donnée ci-dessous, est concave et maximisée numériquement par des algorithmes itératifs de type Newton-Raphson (moindres carrés repondérés itérativement) :

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln p(x_i) + (1 - y_i) \ln(1 - p(x_i))] \quad (3.5)$$

L'atout déterminant du modèle réside dans son interprétabilité directe. L'exponentielle d'un coefficient fournit un odds-ratio, c'est-à-dire le facteur par lequel la cote de fraude est multipliée lorsque la variable correspondante augmente d'une unité, toutes choses égales par ailleurs :

$$OR_j = e^{\beta_j} \quad (3.6)$$

Un odds-ratio supérieur à 1 traduit une variable aggravante, un odds-ratio inférieur à 1 une variable atténuante ; cette lecture immédiate facilite la justification des décisions et le dialogue avec les équipes de gestion et les autorités de contrôle.

Lorsque le nombre de variables est élevé ou que celles-ci sont fortement corrélées, on recourt à la régularisation, qui ajoute à l'objectif une pénalité sur la norme des coefficients afin de stabiliser l'estimation et de limiter le surapprentissage.

Ainsi on cherche à minimiser :

$$J(\beta) = -\ell(\beta) + \lambda \cdot \text{Pénalité}(\beta) \quad (3.7)$$

avec $\text{Pénalité}(\beta)$ qui admet différentes variantes :

- La pénalité L1 ² (Lasso) définie par $\text{Pénalité}(\beta) = \lambda \sum_{j=1}^p |\beta_j|$, qui a la propriété d'annuler certains coefficients, réalisant ainsi une sélection automatique de variables. En effet, si $\beta_j = 0$, la variable j est complètement exclue du modèle ;
- La pénalité L2 ³ (Ridge) définie par $\text{Pénalité}(\beta) = \lambda \sum_{j=1}^p \beta_j^2$, qui rétrécit les coefficients sans les annuler. Ainsi, toutes les variables restent dans le modèle mais leurs coefficients sont tassés. Ceci est particulièrement utile lorsque les variables sont fortement corrélées entre elles.
- L'elastic net, définie par $\text{Pénalité}(\beta) = \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right]$, avec $\alpha \in [0, 1]$, qui combine les deux termes avec un paramètre qui dose le mélange, pour bénéficier à la fois de la sélection et de la stabilité.

La principale limite du modèle tient à son hypothèse d'additivité et de linéarité sur l'échelle du logit : les interactions entre variables et les effets non linéaires ne sont pas captés automatiquement et doivent être spécifiés à la main (termes croisés, discrétisations, transformations). Face à des schémas de fraude où la suspicion naît précisément de la conjonction de plusieurs facteurs, cette contrainte motive le recours à des méthodes plus flexibles.

2. La pénalité L1 ajoute la somme des valeurs absolues des coefficients à l'objectif à minimiser.

3. La pénalité L2 ajoute la somme des carrés des coefficients.

3.2 La forêt aléatoire

La forêt aléatoire (random forest, Breiman, 2001) appartient à la famille des méthodes d'agrégation (ou méthodes ensemblistes), dont le principe est de combiner de nombreux modèles élémentaires pour obtenir un prédicteur plus performant et plus stable qu'aucun d'entre eux pris isolément. L'unité de base est l'arbre de décision (CART), qui partitionne récursivement l'espace des variables en régions de plus en plus homogènes au regard de la cible. À chaque nœud, l'algorithme évalue toutes les coupures possibles (une variable et un seuil) et retient celle qui maximise la décroissance d'une mesure d'impureté. Les deux mesures les plus courantes en classification sont l'indice de Gini $G(t)$ et l'entropie de Shannon $H(t)$, calculés sur un nœud t comportant une proportion $\hat{p}_{t,1}$ de sinistres frauduleux :

$$G(t) = 2\hat{p}_{t,1}(1 - \hat{p}_{t,1}) \quad (3.8)$$

$$H(t) = - \sum_k \hat{p}_{t,k} \log_2 \hat{p}_{t,k} \quad (3.9)$$

La construction se poursuit jusqu'à un critère d'arrêt (profondeur maximale, effectif minimal par feuille), et la prédiction associée à une feuille est la fréquence empirique de fraude qu'elle contient. Pris isolément, un arbre profond présente un biais faible mais une variance élevée : il s'adapte finement aux données mais une légère perturbation de l'échantillon peut bouleverser sa structure et donc ses prédictions. C'est cette instabilité que la forêt aléatoire vient corriger, au moyen de deux mécanismes complémentaires.

Le premier est le bagging (bootstrap aggregating) : on construit B arbres sur autant d'échantillons obtenus par tirage avec remise dans les données d'origine, puis on moyenne leurs prédictions. La moyenne de prédicteurs de même loi réduit la variance sans augmenter le biais, d'autant plus efficacement que ces prédicteurs sont peu corrélés (la décomposition formelle de cette réduction est reportée en annexe).

Le second mécanisme vise précisément à décorréliser les arbres : à chaque nœud, l'algorithme ne considère qu'un sous-ensemble aléatoire de $m \leq p$ variables candidates (typiquement $m = \sqrt{p}$ en classification), renouvelé à chaque division. Cette restriction empêche les quelques variables les plus prédictives de structurer tous les arbres de façon identique, ce qui diversifie l'ensemble et amplifie la réduction de variance. Le score final est la moyenne des B arbres T_b :

$$\hat{p}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_{T_b}(x) \quad (3.10)$$

avec $\hat{p}_{T_b}(x)$ la prédiction de l'arbre numéro b pour un individu x .

Le tirage bootstrap offre en outre un mécanisme d'évaluation interne quasiment gratuit : chaque observation étant en moyenne absente d'environ 37 % des échantillons, elle peut être prédite par les seuls arbres qui ne l'ont pas vue, fournissant une estimation peu biaisée de l'erreur de généralisation (erreur out-of-bag). Cet avantage est précieux en détection de fraude, où les cas étiquetés sont rares et où l'on souhaite préserver un maximum d'observations pour l'apprentissage. Bien que moins transparente que

la régression logistique, la forêt n'est pas une pure boîte noire : elle fournit des mesures d'importance des variables (décroissance moyenne d'impureté, importance par permutation) qui restituent une part d'interprétabilité utile à la gouvernance du dispositif.

Les propriétés de la forêt aléatoire en font un candidat particulièrement adapté à notre problème : elle capture automatiquement non-linéarités et interactions, tolère des variables hétérogènes, corrélées ou aberrantes, ne requiert qu'un prétraitement limité, et gère le déséquilibre des classes via une pondération ou un rééquilibrage des tirages (balanced random forest). Elle se règle au moyen de quelques hyperparamètres principaux, notamment le nombre d'arbres, le nombre de variables candidates par nœud et la complexité des arbres, et échange une part de l'interprétabilité paramétrique du GLM contre un gain substantiel de pouvoir prédictif.

3.3 Le gradient boosting

Le gradient boosting est, comme la forêt aléatoire, une méthode ensembliste fondée sur des arbres, mais il en diffère radicalement par sa logique de construction. Là où le bagging assemble des arbres en parallèle pour réduire la variance, le boosting les construit séquentiellement, chaque nouvel arbre s'attachant à corriger les erreurs résiduelles de l'ensemble déjà constitué ; il vise donc avant tout à réduire le biais. Le modèle final est une somme pondérée de M arbres h_m :

$$F_M(x) = \sum_{m=1}^M \nu h_m(x) \quad (3.11)$$

Cette somme se construit de façon récursive : partant d'un modèle initial constant, on enrichit à chaque étape le modèle courant d'un nouvel arbre pondéré par le taux d'apprentissage $\nu \in (0, 1]$:

$$F_m(x) = F_{m-1}(x) + \nu h_m(x) \quad (3.12)$$

La clé de la méthode est l'interprétation de cette correction comme une descente de gradient dans l'espace des fonctions. À chaque étape, on calcule les pseudo-résidus r_{im} , définis comme l'opposé du gradient de la fonction de perte L évalué aux prédictions courantes, puis on ajuste un arbre pour les approcher :

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}} \quad (3.13)$$

Le taux d'apprentissage ν joue un rôle de régularisation essentiel : une valeur faible ralentit l'apprentissage et améliore la généralisation, au prix d'un plus grand nombre d'arbres. On combine fréquemment ce « shrinkage » avec un sous-échantillonnage aléatoire des observations et des variables à chaque étape (stochastic gradient boosting), ce qui réduit encore le surapprentissage. Les implémentations modernes ajoutent par ailleurs à la fonction de perte un terme de régularisation Ω pénalisant explicitement la complexité des arbres (nombre de feuilles, norme des poids), de sorte que l'objectif minimisé s'écrit :

$$L(F) = \sum_{i=1}^n L(y_i, F(x_i)) + \sum_{m=1}^M \Omega(h_m) \quad (3.14)$$

Les bibliothèques de référence (XGBoost, LightGBM, CatBoost ⁴) mettent en œuvre ces principes avec des optimisations algorithmiques (construction par histogrammes, croissance des arbres par feuille, traitement natif des variables catégorielles) qui les rendent rapides et très performantes.

Le gradient boosting atteint généralement le meilleur pouvoir prédictif parmi les modèles considérés sur des données tabulaires telles que celles de la détection de fraude. En contrepartie, il est plus sensible au réglage des hyperparamètres et au surapprentissage : le nombre d'arbres doit être contrôlé par un arrêt précoce sur un jeu de validation, et son interprétabilité est moindre que celle de la forêt, ce qui conduit

4. XGBoost, LightGBM et CatBoost sont des bibliothèques open source d'implémentation du gradient boosting, principalement utilisées en Python.

à s'appuyer sur des outils d'explication post-hoc (importance des variables, valeurs de Shapley⁵) pour en restituer la logique.

5. La valeur de Shapley de la variable j pour un individu x mesure sa contribution marginale moyenne à la prédiction en moyennant sur toutes les coalitions possibles de variables.

3.4 Les modèles de scoring à points

Hérités de la pratique du credit scoring, les modèles de scoring à points (ou scorecards) ne constituent pas tant une nouvelle famille d'algorithmes qu'une méthode de mise en forme d'un modèle statistique (le plus souvent une régression logistique) en une grille de points additive, lisible et directement exploitable par un gestionnaire, sans recours à un outil informatique. Leur intérêt est avant tout opérationnel et réglementaire : dans un contexte assurantiel soumis à un devoir d'explication, pouvoir justifier un score par la simple addition de points attachés aux caractéristiques d'un dossier constitue un atout majeur.

La construction débute par une discrétisation de chaque variable en classes, définies de manière à être suffisamment peuplées et, idéalement, à présenter un risque monotone. Cette étape capture les non-linéarités propres à chaque variable et réduit la sensibilité aux valeurs extrêmes. Chaque classe se voit ensuite attribuer un poids de la preuve (Weight of Evidence, WOE), qui mesure son pouvoir discriminant en comparant la répartition des dossiers licites et frauduleux :

$$WOE_i = \ln \left(\frac{\% \text{ non-fraude}_i}{\% \text{ fraude}_i} \right) \quad (3.15)$$

Le pouvoir prédictif global d'une variable peut alors être quantifié par sa valeur informative (Information Value, IV), qui agrège les WOE de ses classes pondérés par l'écart de répartition, et sert à sélectionner et hiérarchiser les variables :

$$IV = \sum_i (\% \text{ non-fraude}_i - \% \text{ fraude}_i) \times WOE_i \quad (3.16)$$

Une régression logistique est ensuite ajustée sur les variables transformées en WOE. Ses coefficients sont enfin convertis en points entiers au moyen d'une transformation affine, calée par deux paramètres : le facteur et l'offset, déterminés à partir d'un score de référence, d'une cote de référence et du nombre de points doublant la cote (PDO, Points to Double the Odds) :

$$\text{facteur} = \frac{PDO}{\ln 2}, \quad \text{offset} = \text{Score}_0 - \text{facteur} \times \ln(\text{Odds}_0) \quad (3.17)$$

Les points attribués à une classe de la variable j combinent le coefficient estimé, le WOE de la classe, l'ordonnée à l'origine α répartie sur les p variables, et les paramètres de calage :

$$\text{Points}_j = \left(\beta_j \times WOE_j + \frac{\alpha}{p} \right) \times \text{facteur} + \frac{\text{offset}}{p} \quad (3.18)$$

Le score d'un dossier est alors la simple somme des points de chacune de ses caractéristiques :

$$\text{Score} = \sum_{j=1}^p \text{Points}_j \quad (3.19)$$

Ce dispositif présente une transparence et une auditabilité maximales : chaque point du score est traçable

jusqu'à une caractéristique précise du dossier, ce qui satisfait directement les exigences d'explicabilité et facilite le suivi de la stabilité du modèle dans le temps (via des indicateurs de dérive des populations).

En contrepartie, la discrétisation et la dépendance à une structure logistique entraînent une perte de finesse prédictive par rapport au gradient boosting, et la définition des classes demande un travail manuel non négligeable. Le scoring à points occupe ainsi une position singulière dans notre panorama : il referme la boucle ouverte par la régression logistique en réconciliant la performance statistique avec une lisibilité opérationnelle.

On peut d'ailleurs envisager une articulation des deux logiques : un modèle puissant de type gradient boosting pour la détection, doublé d'une grille de points pour l'explication et la communication des décisions aux gestionnaires et aux assurés.

3.5 Apprentissage non supervisé : détection d'anomalies et comportements atypiques

Si l'apprentissage supervisé excelle dans l'identification de schémas de fraude historiquement connus, il présente une limite structurelle majeure : il est vulnérable aux techniques de fraude émergentes (zero-day frauds). En effet, un algorithme supervisé ne peut prédire que ce qu'il a déjà vu.

Pour pallier cette faille, les assureurs déploient en complément des algorithmes d'apprentissage non supervisé (Unsupervised Learning). Dans ce paradigme, la variable cible Y (le label « fraude » ou « non-fraude ») est ignorée ou indisponible. L'algorithme explore uniquement l'espace des variables explicatives X pour identifier des structures sous-jacentes ou des déviations statistiques. La fraude est alors assimilée à une anomalie, c'est-à-dire une observation qui dévie si significativement des autres qu'elle éveille le soupçon d'avoir été générée par un mécanisme différent.

Deux grandes familles de méthodes se distinguent pour ce type d'analyse : les algorithmes d'isolation et le partitionnement des données.

3.5.1 Les algorithmes d'isolation (exemple : Isolation Forest)

Contrairement aux approches statistiques classiques qui cherchent d'abord à modéliser le comportement « normal » pour ensuite en déduire les anomalies, l'Isolation Forest cherche directement à isoler les anomalies. Ce modèle repose sur un postulat simple : les anomalies sont des données « peu nombreuses et différentes » (few and different).

L'algorithme construit une forêt d'arbres (les Isolation Trees). Pour chaque arbre, il sélectionne aléatoirement une variable et un seuil de coupure aléatoire (compris entre le minimum et le maximum de cette variable) pour partitionner l'espace récursivement.

Mathématiquement, la métrique clé est la longueur du chemin $h(x)$, c'est-à-dire le nombre d'arêtes qu'une observation x doit parcourir depuis la racine de l'arbre jusqu'à atteindre une feuille terminale où elle est isolée. Parce qu'elles sont situées dans des zones clairsemées de l'espace vectoriel, les anomalies nécessitent beaucoup moins de coupures pour être isolées que les observations normales.

Le score d'anomalie $s(x, n)$ pour un jeu de n données est défini par :

$$s(x, n) = 2^{-\frac{\mathbb{E}(h(x))}{c(n)}} \quad (3.20)$$

où $\mathbb{E}(h(x))$ est l'espérance de la longueur du chemin sur l'ensemble des arbres, et $c(n)$ est une constante de normalisation représentant la longueur moyenne non réussie d'une recherche dans un arbre binaire.

Si $s(x, n)$ tend vers 1, le sinistre est fortement suspect et justifie une levée de doute par un expert. Si le score tend vers 0,5, le sinistre est considéré comme non frauduleux.

3.5.2 Le partitionnement de données (Clustering)

Les algorithmes de Clustering (tels que les K-Means) visent à regrouper les sinistres en sous-ensembles (les clusters) de telle sorte que les dossiers d'un même groupe soient les plus similaires possibles, tout en étant distincts des autres groupes.

Dans le cas de l'algorithme K-Means, l'objectif est de minimiser la variance intra-classe (la distance au carré entre chaque sinistre x_i et le centre de gravité μ_j de son cluster de rattachement) :

$$\arg \min_S \sum_{j=1}^k \sum_{x_i \in S_j} \|x_i - \mu_j\|^2 \quad (3.21)$$

Appliqué à la lutte anti-fraude, le clustering permet d'identifier des sinistres qui ne s'intègrent dans aucun des clusters principaux (les dossiers de masse), ou qui forment de très petits groupes (micro-clusters) très éloignés des autres. Ces poches de données marginales signalent souvent des comportements atypiques, comme des réseaux organisés déclarant des sinistres aux caractéristiques étrangement similaires.

3.6 Analyse de réseaux (Graph Mining) pour la détection de la fraude organisée

Contrairement à la fraude opportuniste (un assuré isolé qui majore ponctuellement un devis), la fraude en bande organisée implique une complicité entre plusieurs acteurs coordonnés dans le but de soutirer des capitaux importants à la compagnie d'assurance de manière répétée.

Ce type de criminalité financière s'appuie sur des réseaux structurés incluant de faux assurés, des prête-noms, et bien souvent des professionnels complices (garagistes, sociétés de dépannage, professionnels de santé ou experts automobiles marrons). Leurs modes opératoires sont quasi industriels : accidents de la circulation mis en scène, carambolages fictifs en chaîne, ou recyclage de véhicules gravement endommagés.

La dangerosité extrême de ces réseaux réside dans leur capacité à « lisser » le risque : pris isolément, chaque sinistre déclaré par le réseau est conçu pour paraître parfaitement vraisemblable et passer sous les radars des règles de gestion classiques. Les algorithmes de Machine Learning vus précédemment montrent ici leurs limites, car ils analysent chaque dossier de manière individuelle. C'est précisément pour contourner ce camouflage qu'il devient impératif de ne plus regarder les sinistres, mais les liens cachés qui les unissent, grâce à la théorie des graphes (Graph Mining).

3.6.1 Modélisation mathématique du réseau de fraude

Dans cette approche, le portefeuille de sinistres n'est plus vu comme un simple tableau (lignes/colonnes), mais est modélisé sous la forme d'un graphe mathématique $G = (V, E)$.

- **Les Nœuds (Vertices — V)** : ils représentent les entités du système. Il peut s'agir d'un dossier de sinistre, d'un assuré, d'un numéro de téléphone, d'une adresse IP ou d'un professionnel de l'automobile.
- **Les arêtes (Edges — E)** : elles matérialisent une relation entre deux nœuds. Une arête est créée si deux sinistres partagent un attribut commun (ex : même garagiste, même compte bancaire pour l'indemnisation) ou s'ils présentent une similarité vectorielle anormalement élevée (ce qui trahit souvent la réutilisation d'un même scénario de fraude).

On peut mesurer la similarité entre deux dossiers A et B dans l'espace des variables via la similarité cosinus :

$$\text{sim}(A, B) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^p A_i B_i}{\sqrt{\sum_{i=1}^p A_i^2} \sqrt{\sum_{i=1}^p B_i^2}} \quad (3.22)$$

Si cette similarité dépasse un seuil critique défini par l'actuaire, une arête est tracée entre les deux dossiers.

3.6.2 Détection de communautés et de clusters suspects

Une fois le graphe construit, l'objectif n'est plus d'évaluer la probabilité de fraude d'un nœud individuel, mais d'identifier des sous-graphes anormalement denses. En théorie des graphes, on appelle cela la détection de communautés ou de composantes connexes.

Des algorithmes comme la méthode de Louvain ou la propagation de labels (Label Propagation) sont utilisés pour partitionner le graphe. Ils cherchent à maximiser la modularité Q , c'est-à-dire la densité des liens à l'intérieur d'un cluster par rapport à la densité des liens à l'extérieur :

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j) \quad (3.23)$$

où A_{ij} est la matrice d'adjacence, k_i est le degré du nœud i , m le nombre total d'arêtes, et $\delta(c_i, c_j)$ indique si les nœuds appartiennent à la même communauté c .

3.6.3 Application opérationnelle

Sur le plan opérationnel, lorsqu'un algorithme de Graph Mining isole un cluster suspect, il fournit une alerte d'une valeur ajoutée qualitativement différente de celle produite par les modèles de scoring individuels classiques. L'investigation ne porte plus sur un sinistre isolé de 2 000 €, mais sur un réseau organisé dont le préjudice global potentiel se chiffre en plusieurs dizaines, voire centaines de milliers d'euros. Cette bascule d'échelle transforme profondément la logique d'allocation des ressources au sein des cellules anti-fraude.

Concrètement, le cluster fourni par l'algorithme se matérialise sous la forme d'un graphe annoté restituant l'ensemble des entités impliquées (assurés, prestataires, intermédiaires) ainsi que la nature et la fréquence de leurs interactions. L'enquêteur dispose ainsi d'une cartographie complète du réseau présumé, lui permettant d'identifier le nœud central (souvent le coordinateur du schéma frauduleux) et de hiérarchiser ses investigations en remontant des ramifications périphériques vers le cœur du dispositif. Cette approche contraste avec l'instruction traditionnelle dossier par dossier, où les connexions entre sinistres restent invisibles faute d'une vision transversale.

Du point de vue du pilotage, le démantèlement d'un tel réseau offre un retour sur investissement massif pour la compagnie d'assurance. Là où l'instruction d'un dossier individuel mobilise plusieurs heures d'analyse pour un enjeu financier limité, une seule investigation réseau peut aboutir à la neutralisation simultanée de plusieurs dizaines de dossiers frauduleux, à des résiliations en cascade et, le cas échéant, à des dépôts de plainte groupés susceptibles d'aboutir à des condamnations pénales. Ces dernières constituent un signal dissuasif fort, dont l'effet préventif sur les comportements frauduleux dépasse largement le périmètre du réseau démantelé.

Enfin, les sorties du Graph Mining s'intègrent naturellement aux processus de reporting réglementaire. Les clusters détectés, documentés et tracés, alimentent les déclarations de soupçon transmises à Tracfin ⁶

6. Tracfin (Traitement du renseignement et action contre les circuits financiers clandestins) est une cellule de renseignement financier placée sous la tutelle du ministère de l'Économie et des Finances. Créée en 1990, elle est chargée de recueillir,

et renforcent la robustesse du dispositif LCB-FT ⁷ de la compagnie, démontrant aux autorités de contrôle, notamment à l'ACPR, que la lutte contre la fraude organisée repose sur des méthodes quantitatives structurées et auditable.

analyser et transmettre aux autorités judiciaires les déclarations de soupçon émises par les professionnels assujettis (dont les organismes d'assurance).

7. La LCB-FT (Lutte contre le blanchiment de capitaux et le financement du terrorisme) désigne l'ensemble du dispositif réglementaire et opérationnel imposé aux acteurs du secteur financier et assurantiel pour prévenir, détecter et signaler ces infractions. En France, ce dispositif est principalement encadré par le Code monétaire et financier (articles L. 561-1 et suivants), transposant les directives européennes.

3.7 Critères de qualité des modèles mis en place

La première mesure naturelle de la qualité d'un modèle de détection de fraude est le taux de bien classés (ou accuracy), défini comme la proportion d'individus correctement classés parmi l'ensemble de la population soumise au modèle. Il se calcule directement à partir de la matrice de confusion, qui croise les prédictions du modèle avec les statuts réels observés selon quatre configurations possibles.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.24)$$

Un dossier est dit :

- vrai positif (TP) lorsque le modèle prédit une fraude et que le dossier est effectivement frauduleux ;
- vrai négatif (TN) lorsque le modèle prédit un dossier sain et que celui-ci l'est bien ;
- faux positif (FP) lorsqu'un dossier sain est incorrectement signalé comme frauduleux (génération d'un coût opérationnel inutile et une dégradation de l'expérience client) ;
- faux négatif (FN) lorsqu'un dossier frauduleux n'est pas détecté, constituant la perte financière directe pour la compagnie.

		Statut réel	
		Fraude réelle	Non-fraude réelle
Prédiction du modèle	Fraude prédite	Vrai Positif (TP) Fraude détectée ✓	Faux Positif (FP) Fausse alerte ✗
	Non-fraude prédite	Faux Négatif (FN) Fraude non détectée ✗	Vrai Négatif (TN) Sain classé sain ✓

FIGURE 3.1 – Matrice de confusion

Toutefois, si le taux de bien classés présente l'avantage d'une lecture immédiate, il s'avère trompeur dans le contexte de la détection de fraude, où les classes sont structurellement déséquilibrées : la fraude ne représente généralement que 1 à 3 % des dossiers.

Un modèle naïf prédisant systématiquement « non-fraude » atteindrait mécaniquement un taux de bien

classés supérieur à 97 %, sans détecter la moindre fraude.

Cette limite justifie le recours à des critères complémentaires mieux adaptés aux distributions asymétriques, notamment des indicateurs capables de mesurer la capacité du modèle à ordonner les dossiers par risque (indépendamment de tout seuil), et d'autres la qualité d'une décision prise à un seuil déterminé.

Ainsi, on distingue les indicateurs suivants, présentés dans le tableau ci-dessous :

Indicateur	Description
Coefficient de Gini et courbe ROC ⁸	Mesure le pouvoir discriminant global du score, c'est-à-dire son aptitude à classer les sinistres frauduleux devant les sinistres licites, sur l'ensemble de la plage de seuils, en s'appuyant sur la courbe ROC (Receiver Operating Characteristic). Le coefficient de Gini est relié à l'AUC par la relation $Gini = 2 \times AUC - 1$ et varie de 0 (discrimination nulle) à 1 (discrimination parfaite).
Statistique de Kolmogorov-Smirnov (KS) ⁹	Mesure l'écart maximal entre les fonctions de répartition cumulées des scores des deux populations (frauduleux et licites). De façon équivalente, elle correspond au plus grand écart entre le taux de vrais positifs et le taux de faux positifs le long de la courbe ROC : $KS = \max_s (TVP(s) - TFP(s))$. Comprise entre 0 et 1, elle indique en outre le seuil de score où la séparation entre les deux classes est la plus nette.
Aire sous la courbe précision-rappel (PR-AUC)	Particulièrement adaptée aux classes déséquilibrées, car elle se concentre sur la classe d'intérêt (la fraude) sans être flattée par l'abondance des vrais négatifs, contrairement à l'AUC-ROC qui peut donner une image trop optimiste. Son interprétation est relative : la valeur de référence (modèle aléatoire) n'est pas 0,5 mais la prévalence de la fraude π , de sorte qu'une PR-AUC doit toujours être appréciée au regard de ce taux de base.
F1-score ¹⁰	Évalue une décision à un seuil fixé. Il s'agit de la moyenne harmonique de la précision $P = \frac{VP}{VP + FP}$ et du rappel $R = \frac{VP}{VP + FN}$, soit $F_1 = \frac{2PR}{P + R}$. Il offre un compromis entre les faux positifs (investigations menées à tort) et les faux négatifs (fraudes manquées).
Lift au décile supérieur (lift@10 %)	Indicateur opérationnel directement aligné sur la logique de priorisation de l'outil. Après avoir classé tous les dossiers par score décroissant, il rapporte le taux de fraude observé dans les 10 % les plus suspects au taux de fraude global : $lift@10\% = \frac{\text{taux de fraude dans le décile supérieur}}{\text{taux de fraude global}}$. Un lift de 5 signifie que le décile ciblé concentre cinq fois plus de fraudes qu'une sélection aléatoire.

TABLE 3.1 – Principaux critères d'évaluation d'un modèle de détection de fraude

De plus, on s'intéressera également à l'indice de stabilité des populations (PSI, Population Stability Index). Ce dernier ne mesure pas le pouvoir prédictif du modèle mais la stabilité de la population dans le temps. Il quantifie l'écart entre la distribution des scores observée sur une population de référence (typiquement l'échantillon d'apprentissage) et celle observée sur une population récente, afin de détecter une dérive susceptible de dégrader la pertinence du modèle. Après avoir réparti les scores en classes (souvent les déciles de la population de référence), il se calcule comme la somme sur les classes des écarts

de proportions pondérés par le logarithme de leur rapport :

$$\text{PSI} = \sum_i (a_i - r_i) \ln \left(\frac{a_i}{r_i} \right), \quad (3.25)$$

où r_i et a_i désignent respectivement la proportion d'observations de la classe i dans la population de référence et dans la population actuelle. Par convention, un PSI inférieur à 0,1 traduit une population stable, une valeur comprise entre 0,1 et 0,25 signale une dérive modérée appelant une surveillance, et une valeur supérieure à 0,25 indique une dérive importante justifiant une investigation, voire un réentraînement du modèle. Le PSI peut s'appliquer à la distribution du score global comme à celle de chaque variable explicative, ce qui permet d'identifier l'origine d'une dérive. Il constitue ainsi un outil clé du suivi opérationnel de l'agent une fois déployé.

En synthèse, l'évaluation d'un modèle actuariel de détection de fraude articule six dimensions complémentaires : le pouvoir discriminant (Gini, KS, PR-AUC), la qualité d'une décision seuillée (F1, matrice de confusion), la valeur économique (coût espéré, ROI, lift financier), la calibration probabiliste (Brier, ECE), la stabilité temporelle (PSI) et l'équité entre segments. Aucun de ces indicateurs pris isolément n'épuise le jugement à porter sur l'agent ; c'est leur lecture conjointe, adossée à une matrice de coûts explicite et à un cadre de gouvernance clair, qui fonde la légitimité actuarielle du dispositif.

ANCRAGE RÉGLEMENTAIRE

Le dispositif d'évaluation retenu s'inscrit dans les attentes de la recommandation ACPR 2020-R-01 sur la gouvernance des algorithmes en assurance, laquelle exige l'existence d'un cadre de suivi de performance, de stabilité et d'explicabilité tout au long du cycle de vie du modèle. Le règlement européen sur l'intelligence artificielle classe par ailleurs les dispositifs de détection de fraude en assurance vie et santé comme systèmes à haut risque, imposant une documentation technique détaillée, une surveillance humaine et une évaluation continue, exigences que la batterie d'indicateurs présentée ci-dessus contribue à satisfaire (cf. §4.1 pour plus de détails).

Chapitre 4

Mise en œuvre technique et détection par l'IA

4.1 Détection de la fraude opportuniste (Auto et MRH)

4.1.1 L'IA au service de l'expertise visuelle (YOLO)

Remplacer l'œil de l'expert pour détecter les incohérences : identifier si une griffure latérale est compatible avec un choc frontal sur un poteau.

4.1.2 Analyse de la falsification documentaire

Détection de retouches sur les photos d'accidents ou sur les documents d'identité.

4.2 Détection de la fraude en bande organisée

4.2.1 Identification de patterns de coûts identiques

Repérer les sinistres ayant exactement le même coût moyen, signe potentiel d'une fraude industrielle.

4.2.2 Analyse spatiale et comportementale

Détection de sinistres similaires sur des habitations éloignées (MRH) n'ayant aucun lien logique, mais présentant des caractéristiques techniques identiques.

4.3 Évaluation de la performance des modèles

4.3.1 Métriques de précision et de rappel

Mesurer la capacité du modèle à ne pas oublier de fraudeurs tout en évitant de suspecter des clients honnêtes.

4.3.2 Interprétabilité des résultats (XAI)

Expliquer pourquoi l'IA a flagué un dossier pour que l'enquêteur humain puisse prendre le relais.

Chapitre 5

Impacts Actuariels, Rentabilité et Perspectives

5.1 Analyse de la rentabilité économique (Business Case)

5.1.1 Le dilemme du coût de l'investigation

Est-il rentable d'engager des frais d'avocats et d'experts pour un sinistre à 1 200 €? Définition du ROI de l'IA.

5.1.2 Réduction des frais de gestion

Automatisation du tri pour concentrer les ressources humaines sur les dossiers à fort enjeu.

5.2 Conséquences sur la tarification et le provisionnement

5.2.1 Biais statistiques induits par la fraude

Analyse de la manière dont la fraude non détectée fausse la fréquence et le coût moyen des sinistres.

5.2.2 Impact sur la prime pure et l'équité

Modélisation de la baisse potentielle des primes pour les assurés honnêtes grâce à la réduction de la charge sinistre globale.

5.3 Conclusion et ouverture

5.3.1 Synthèse des travaux

5.3.2 Limites éthiques et réglementaires (RGPD)

5.3.3 Perspectives sur l'évolution de la fraude (Deepfakes)

Chapitre 6

Conclusion

6.1 Résumé des résultats

6.1.1 Synthèse des principaux résultats obtenus



6.2 ffhfhf



Annexes



Chapitre 3

Bibliographie

- [1] FRANCE ASSUREURS. *L'assurance vie en 2024*. (23 septembre 2025). Consulté le 28 Octobre 2025, sur <https://www.franceassureurs.fr/nos-chiffres-cles/assurance-vie/lassurance-vie-en-2024/>
- [2] DORNAIKA Fadi, HAMAD Denis, CONSTANTIN Joseph, TRONG HOANG Vinh. *Advances in Data Clustering*. Lieu d'édition : Springer, 2024.
- [3] GOFFARD Pierre-Olivier, GUERRAULT Xavier. « Is it optimal to group policyholders by age, gender, and seniority for BEL computations based on model points? ». *European Actuariel Journal*, volume 5, 17 Avril 2015, p. 165-180.
- [4] BEN FADHEL Amine. « Accélération de l'évaluation de la solvabilité prospective d'un assureur épargne ». *Mémoire pour l'Institut des Actuaire*s , 2022.
- [5] INSEE. *Taux de détention des produits de patrimoine selon l'âge de la personne de référence du ménage en 2021*. (2021). Consulté le 18 Septembre 2025, sur https://www.insee.fr/fr/outil-interactif/5367857/details/30_RPC/34_PAT/34A_Figure1
- [6] INSEE. *Pyramide des âges de la population française en 2024*. (2024). Consulté le 1er Septembre 2025, sur <https://www.insee.fr/fr/outil-interactif/5014911/pyramide.htm>
- [7] INSEE. *Enquête Histoire de vie et Patrimoine 2020-2021*. 2021.
- [8] IFOP. *Enquête sur les 60 ans de l'indépendance financière des femmes : chiffres clés sur la répartition hommes-femmes en assurance vie*. (16 Juillet 2025). Consulté le 16 Novembre 2025, sur <https://www.ifop.com/article/enquete-sur-les-60-ans-de-lindependance-financiere-des-femmes/>
- [9] IFOP. *Baromètre - les femmes et l'argent : chiffres clés sur la répartition hommes-femmes sur les fonds EURO et UC en assurance vie*. (Janvier 2024). Consulté le 16 Novembre 2025, sur <https://www.ifop.com/wp-content/uploads/2024/03/barometre-vives-2024ok-1.pdf>