

Mémoire présenté le :

**pour l'obtention du Diplôme Universitaire d'actuariat de l'ISFA
et l'admission à l'Institut des Actuaire**

Par : Eliot NEHME

Titre : Détection de fraude en assurance non-vie à l'aide de l'intelligence artificielle

Confidentialité : ☐ NON ☒ OUI (Durée : ☐ 1 an ☒ 2 ans)

Les signataires s'engagent à respecter la confidentialité indiquée ci-dessus

*Membres présents du jury de Signature
l'Institut des Actuaire*

*Entreprise : Accenture
Nom : Makram Ben Dbabis*

Signature :

*Directeur de mémoire en entre-
prise :
Nom : Rachel Atia*

Signature :

*Membres présents du jury de
l'ISFA*

*Invité :
Nom :*

Signature :

***Autorisation de publication et
de mise en ligne sur un site de
diffusion de documents actua-
riels (après expiration de l'éventuel
délai de confidentialité)***

Signature du responsable entreprise

Signature du candidat

Table des matières

Remerciements	iv
Résumé	v
Abstract	vi
Synthèse	vii
Synthesis	xi
1 Introduction et contexte	1
1.1 Définition de la fraude à l'assurance	1
1.2 Les stades d'occurrence de la fraude dans le cycle assurantiel en assurance non-vie	2
1.2.1 La fraude à la souscription	3
1.2.2 La fraude à la déclaration d'un sinistre	3
1.2.3 La fraude liée aux Conditions Générales	4
1.3 Cadre réglementaire des sanctions en cas de fraude avérée	5
1.3.1 Souscription	5
1.3.2 Sinistre	6
1.3.3 Preuve de la fraude et sanctions pénales	6
1.4 Enjeux économiques et actuariels de la fraude	7
1.4.1 L'ampleur du marché de la fraude	7
1.4.2 Impact de la fraude sur la tarification	9
2 La détection de la fraude en assurance : de l'approche manuelle à l'automatisation par l'IA	13
2.1 L'approche traditionnelle : une détection manuelle et ciblée	13
2.1.1 Le rôle des équipes dédiées	13
2.1.2 Une détection fondée sur l'expertise humaine	13
2.1.3 Les limites de cette approche	14
2.2 L'apport de l'intelligence artificielle : de nouvelles solutions de détection	15
2.2.1 Le contexte d'émergence	15
2.2.2 Les nouvelles approches	15
2.2.3 Les bénéfices attendus	15
2.2.4 Les points de vigilance à l'utilisation de l'intelligence artificielle	16
2.3 Comparaison du processus manuel et du processus automatisé	17
2.3.1 Les critères de comparaison	17
2.3.2 Mise en regard des deux processus	17
2.3.3 Vers un modèle hybride	18
3 Cadre théorique : les algorithmes de détection de fraude utilisés en assurance non-vie	19
3.1 La régression logistique (modèle de référence)	20
3.2 La forêt aléatoire	21

3.3	Le Gradient Boosting	22
3.4	Les modèles de scoring à points	23
3.5	Apprentissage non supervisé : détection d'anomalies et comportements atypiques	25
3.5.1	Les algorithmes d'isolation (Exemple : Isolation Forest)	25
3.5.2	Le partitionnement de données (Clustering)	25
3.6	Analyse de réseaux (Graph Mining) pour la détection de la fraude organisée	26
3.6.1	Modélisation mathématique du réseau de fraude	26
3.6.2	Détection de communautés et de clusters suspects	27
3.6.3	Application opérationnelle	27
3.7	Critères de qualité des modèles mis en place	28
4	Mise en place d'un processus de détection de fraude automobile automatisé à l'aide d'un Agent IA	31
4.1	Gouvernance autour de la mise en place de l'Agent IA	31
4.2	Présentation de la base de données	33
4.2.1	Base de données source	33
4.2.2	Enrichissement de la base de données	35
4.3	Descriptif macro de la création du processus de détection de fraude et de sa déclinaison opérationnelle	37
4.3.1	Le prompt : la décomposition du besoin en étapes	38
4.3.2	Présentation macro des différentes étapes	39
4.4	Étapes 1 & 2 : Ingestion de la base de données et Audit de contrôles de cohérence	42
4.4.1	Étape 1 : Ingestion de la base de données	42
4.4.2	Étape 2 : Audit et contrôles de cohérence	43
4.5	Étape 3 : Analyse statistique des données	45
4.5.1	Analyse de la composition du portefeuille	45
4.5.2	Analyse de la fréquence de la fraude	46
4.5.3	Création de classes de variables	48
4.5.4	Analyse des corrélations entre les variables	53
4.5.5	Analyse du coût moyen de la fraude	58
5	Création du modèle de détection de fraude : Étapes 4 et 5	60
5.1	Scoring en points	61
5.1.1	Résultats du modèle	62
5.1.2	Qualité du modèle obtenu	68
5.1.3	Limites et précautions d'interprétation	70
5.2	Arbre de décision	71
5.2.1	Résultats du modèle	71
5.2.2	Qualité du modèle obtenu	76
5.2.3	Limites et précautions d'interprétation	79
5.3	Un modèle de Machine Learning : le Gradient Boosting	80
5.3.1	Résultats du modèle	80
5.3.2	Qualité du modèle obtenu	83
5.3.3	Limites et précautions d'interprétation	86
5.4	Comparaison des modèles	87
6	Outil mis à disposition du service de détection des fraudes	90
6.1	Utilisation pratique de l'outil	90

6.2	Un outil permettant l'enrichissement du modèle en continu	94
6.3	Rapport annuel de détection de fraude	96
6.4	Dynamisme de l'outil mis en place	98
7	Réflexions autour de l'IA et limites de l'outil créé	100
7.1	Un outil d'aide à la décision complémentaire avec l'humain	100
7.2	Nature de l'IA utilisée : de l'IA générative à l'IA agentique	102
7.3	Limites liées à la qualité et à la richesse des données	102
7.3.1	Le couplage à la base portefeuille	102
7.3.2	Ajout de données externes	104
7.4	Mutualisation inter-assureurs et extension à une approche multiproduit	106
	Conclusion	107
	Annexes	109
	Méthodes de classification	109
	Analyse détaillée des variables	115
	Composition du portefeuille	117
	Matrices de corrélations	119
	Glossaire	121
	Bibliographie	126

Remerciements

Je tiens tout d'abord à remercier l'ensemble de l'équipe Actuariat d'Accenture pour son accueil, sa disponibilité et la confiance qui m'a été accordée tout au long de mon stage et alternance. Les échanges avec les différents membres de l'équipe, ainsi que leur expertise et leurs conseils, ont largement contribué à enrichir ma réflexion et à mener à bien ce mémoire.

Je souhaite remercier tout particulièrement ma tutrice, Rachel Atia, pour son implication et son accompagnement tout au long de ce projet. Sa disponibilité, la qualité de ses conseils et sa capacité à transmettre ses connaissances avec pédagogie ont été essentielles à l'avancement de mes travaux. Son regard, à la fois exigeant et bienveillant, m'a permis d'approfondir ma réflexion et de progresser tant sur le plan technique que professionnel.

Je remercie également Denis Clot, mon tuteur académique à l'ISFA, pour son suivi, ses conseils et les orientations apportées dans le cadre de la réalisation de ce mémoire.

Enfin, je remercie mon co-alternant, camarade de classe et ami, Gabou Gabou, qui m'a accompagné et soutenu tout au long de cette année.

Résumé

La fraude en assurance non-vie représente un enjeu financier majeur, estimé à environ 2,5 milliards d'euros par an en France, dont une large part échappe encore aux dispositifs de détection traditionnels. Fondés sur l'expertise humaine, ces dispositifs ne contrôlent qu'une fraction des dossiers et peinent à traiter la fraude de masse de faible montant, dont le coût de vérification manuelle excède souvent le gain espéré.

Ce mémoire propose de concevoir et déployer, à l'aide d'un agent d'intelligence artificielle, un processus de détection automatisé de la fraude automobile, de l'ingestion des données jusqu'au pilotage du dispositif. À partir d'une base de sinistres automobiles enrichie de variables reproduisant l'information disponible pour un assureur, trois modèles d'estimation de probabilité de fraude seront construits et comparés selon un arbitrage entre interprétabilité et pouvoir prédictif : un *scoring* en points, un arbre de décision et un modèle de Gradient *Boosting*.

In fine, c'est ce dernier qui obtiendra les meilleures performances (AUC de 0,933, *lift* de $\times 6,37$ au premier décile) tout en concentrant efficacement les fraudes dans un volume restreint de dossiers à investiguer.

L'outil se décline en deux modules destinés à deux équipes distinctes : d'une part la construction du modèle par les actuaires, et d'autre part son exploitation opérationnelle par les gestionnaires, complétée d'une boucle d'enrichissement continu et d'un rapport de pilotage mesurant le retour sur investissement de l'outil. L'ensemble de ces développements s'inscrit dans un cadre de gouvernance conforme au Règlement Général sur la Protection des Données (RGPD) et à l'AI Act, préservant une supervision humaine à chaque étape du processus de détection de fraude.

Note : Les schémas et illustrations de ce mémoire ont été réalisés avec l'aide d'outils d'intelligence artificielle générative. De même, une partie des données d'enrichissement de la base a été simulée à l'aide de tels outils, comme précisé en section 4.2.2

Mots-clés : fraude à l'assurance, assurance non-vie, détection automatisée, intelligence artificielle, *machine learning*, *scoring* à points, Gradient *Boosting*, arbre de décision, processus, actuariat.

Abstract

Fraud in non-life insurance represents a major financial challenge in France, with annual losses estimated at approximately € 2.5 billion, a substantial share of which remains undetected by traditional detection systems. As these systems rely primarily on human expertise, they examine only a fraction of claims and struggle to address high-volume, low-value fraud, for which the cost of manual verification often exceeds the expected financial benefit.

This thesis proposes the design and deployment of an AI-agent-supported process for the automated detection of motor insurance fraud, covering the entire workflow from data ingestion to system monitoring. Using an automotive claims dataset enriched with variables designed to replicate the information available for an insurer, three fraud-probability estimation models are developed and compared in terms of the trade-off between interpretability and predictive performance : a points-based scorecard, a decision tree, and a Gradient Boosting model.

Ultimately, the Gradient Boosting model achieves the strongest performance, with an AUC of 0.933 and a lift of $\times 6.37$ in the first decile, while effectively concentrating fraudulent claims within a limited volume of cases requiring investigation.

The tool comprises two modules designed for two distinct teams : a model-development module for actuaries and an operational-use module for claims handlers, complemented by a continuous data-enrichment loop and a monitoring report that assesses the tool's return on investment. The overall framework is governed in accordance with the General Data Protection Regulation (GDPR) and the AI Act and maintains human oversight at every stage of the fraud-detection process.

Note : The diagrams and illustrations included in this thesis were produced with the assistance of generative artificial intelligence tools. Likewise, part of the data used to enrich the dataset was simulated using such tools, as specified in Section 4.2.2

Keywords : insurance fraud, non-life insurance, automated detection, artificial intelligence, machine learning, points-based scoring, Gradient Boosting, decision tree, process, actuarial science.

Synthèse

Le principe de mutualisation des risques est un principe pilier de l'assurance qui suppose un climat de confiance entre assureur et assuré que la fraude vient détourner.

En assurance non-vie, ce phénomène représente une charge estimée à environ 2,5 milliards d'euros par an en France, soit environ 3 % des cotisations en assurance de biens et de responsabilité, dont une partie importante (de l'ordre de 60 %) demeure non détectée. Au-delà de son coût direct, la fraude alourdit la prime de chaque assuré honnête d'une cinquantaine d'euros par contrat automobile et fragilise à terme la solidarité même de la mutualité.

La lutte traditionnelle contre ce phénomène, fondée sur le jugement des gestionnaires de sinistres et l'intervention de cellules spécialisées, atteint aujourd'hui ses limites. Elle ne permet de contrôler qu'une fraction des dossiers, dépend fortement de l'expertise individuelle des enquêteurs, et se heurte à une contrainte économique difficilement surmontable : le coût d'une investigation manuelle rend non rentable le contrôle de la fraude de faible montant, pourtant la plus répandue. C'est de ce constat qu'est né le présent mémoire, dont l'objet est de présenter la conception et la mise en œuvre pas à pas d'un processus de détection automatisé de la fraude automobile, reposant sur un agent d'intelligence artificielle et couvrant l'intégralité de la chaîne, de l'ingestion des données jusqu'au pilotage du dispositif, des outils similaires ayant déjà fait leur émergence sur le marché ces dernières années.

Enjeux et positionnement : Le mémoire s'ouvre sur une caractérisation de la fraude à l'assurance, de ses typologies (opportuniste ou organisée, à la souscription ou au sinistre) et de son cadre juridique, avant d'en établir l'enjeu économique. La valeur d'un dispositif de détection ne se mesure pas à sa seule performance statistique, mais à la charge de sinistres qu'il permet d'éviter : cet ancrage économique, formalisé par la notion de gain unitaire espéré, constitue le fil conducteur du travail et justifie que le choix des paramètres du modèle relève in fine d'un arbitrage coût-bénéfice. Le mémoire dresse ensuite un panorama des méthodes de détection, opposant les approches manuelles traditionnelles aux apports de l'intelligence artificielle, pour aboutir à une conviction qui oriente toute la suite : loin de remplacer l'expertise humaine, l'IA doit s'articuler avec elle selon une logique de complémentarité, où l'algorithme filtre et hiérarchise tandis que l'humain investigate et décide.

Cadre théorique : La partie méthodologique présente les modèles supervisés retenus (du *scoring* en points à la régression logistique, en passant par les arbres de décision et les méthodes d'ensemble comme le Gradient *Boosting*), ainsi que les approches non supervisées mobilisables pour la fraude organisée (détection d'anomalies, *clustering*, analyse de graphes). Une attention particulière est portée aux critères d'évaluation adaptés au fort déséquilibre des classes : dans une population où la fraude est rare, les indicateurs usuels comme le taux de bonne classification deviennent trompeurs, et l'on doit leur préférer l'AUC-ROC, le coefficient de Gini, la statistique de Kolmogorov-Smirnov, la précision, le rappel ou la PR-AUC. Cette partie insiste enfin sur les exigences de gouvernance, d'interprétabilité et de conformité réglementaire (RGPD, AI Act) encadrant le déploiement de tels modèles.

Conception de l'outil : Le cœur du mémoire est consacré à la mise en œuvre concrète l'outil d'aide à la détection de fraude en assurance automobile. La démarche est volontairement circonscrite à la fraude circonstancielle, décelable à partir de données structurées : caractéristiques du sinistre, antécédents de l'assuré et des

intervenants, cohérence de la déclaration. Elle s'appuie sur une base publique de 30 000 sinistres automobiles et vingt-quatre variables, présentant un taux de fraude de 11,5 %. La base est ensuite enrichie de vingt-neuf variables supplémentaires, simulées par l'intelligence artificielle, de manière à reproduire l'information réellement disponible chez un assureur (notamment l'historique du réparateur, du tiers et du véhicule, comportement déclaratif, dimension géographique et temporelle).

L'outil se structure en deux modules, correspondant à deux profils d'utilisateurs bien distincts ainsi qu'à deux temporalités d'utilisation. Le premier outil, destiné aux actuaires, prend en charge la construction du modèle : ingestion standardisée des données, audit automatisé de la qualité de ces dernières, analyses statistiques descriptives, construction des modèles de prédiction de fraude et sélection du modèle le plus performant au regard des critères de qualité définis. Le second outil, cette fois-ci destiné aux gestionnaires de sinistres, exploite le modèle précédemment calibré sans en exposer la complexité, ni même le fonctionnement : pour chaque nouveau dossier de sinistre renseigné, il restitue une probabilité de fraude et oriente le gestionnaire vers une zone de risque conditionnant le niveau d'investigation.

La logique de construction de l'agent est pilotée par un *prompt* décomposé en étapes successives, qui reproduit la démarche actuarielle et garantit la traçabilité de chaque maillon de la chaîne.

Résultats : L'analyse descriptive fait ressortir les déterminants majeurs de la fraude : le rôle central de l'environnement du réparateur, les antécédents de fraude de l'assuré, la cohérence de la déclaration et le ratio entre la facture de réparation et le prix de marché. Un constat contre-intuitif s'en dégage : la fraude ne concerne pas les sinistres les plus coûteux, ce qui justifie pleinement le recours à une approche multivariée. Trois modèles sont alors construits et comparés selon un arbitrage entre interprétabilité et performance, dont les résultats sont synthétisés ci-dessous.

Indicateur	<i>Scoring</i> en point	Arbre de décision	Gradient <i>Boosting</i>
AUC-ROC	0,917	0,845	0,933
Gini	0,835	0,690	0,867
KS	0,666	0,564	0,724
Lift @10 %	—	×4,83	× 6,37
PSI	0,0026	0,0026	0,0023
Écart <i>Backtesting</i>	0,003	0,039	0,016

TABLEAU 1 – Synthèse des résultats des indicateurs de qualité des différents modèles

Le Gradient *Boosting* s'impose comme le modèle le plus discriminant (AUC de 0,933, Gini de 0,867, *lift* de ×6,37 au premier décile) et est retenu à ce titre. Le modèle de *scoring* en points demeure toutefois une alternative pleinement crédible : avec une AUC de 0,917, il se situe très près du Gradient *Boosting* tout en offrant une transparence que les méthodes d'ensemble ne permettent pas, ce qui en fait le choix privilégié lorsque l'explicabilité prime. L'arbre de décision, dominé sur l'ensemble des critères, est écarté. Les trois modèles présentent par ailleurs une excellente stabilité (PSI très inférieur au seuil d'alerte de 0,10) et une bonne capacité de généralisation.

Un enseignement transversal mérite d'être souligné : les trois modèles, pourtant construits sur des principes différents, font converger leur pouvoir explicatif vers les mêmes variables clés. Aux premiers rangs, on retrouve le ratio facture/marché du réparateur, l'historique des montants réclamés et les antécédents de fraude de l'assuré. Le profil du Gradient *Boosting* (modèle retenu) présenté ci-dessous en offre une illustration représentative.




FIGURE 1 – Importance relative des variables dans le modèle retenu (Gradient *Boosting*)

Exploitation et gouvernance : Une fois le modèle retenu et intégré, l'outil est mis à la disposition du service de détection des fraudes. Au quotidien, le gestionnaire y soumet un ou plusieurs sinistre(s), et l'outil lui restitue pour chacun des sinistres soumis une probabilité de fraude assortie d'une orientation sur l'effort d'investigation à engager. Cette probabilité est produite par le modèle retenu, entraîné sur les sinistres dont l'issue est connue : pour le Gradient *Boosting*, elle résulte de la somme des prédictions de 200 arbres successifs, transformée en probabilité par une fonction logistique. Elle est ensuite comparée au seuil optimal (45 %) pour orienter le dossier vers une zone de risque. Les dossiers sont ainsi répartis en trois zones de risque : une zone verte (probabilité faible, aucune investigation), une zone orange (probabilité intermédiaire, investigation légère) et une zone rouge (probabilité élevée, investigation approfondie). Le gestionnaire concentre dès lors ses efforts sur les dossiers les plus à risque, sans perdre de temps sur les dossiers à faible probabilité de fraude.

Résultats de l'évaluation

500 sinistres scorés depuis car_insurance_fraud_dataset_500_fraude_inconnue.csv

0-39% 40-59% 60-100%

Ne pas investiguer 474 ↓ CSV			Investiguer un peu 21 ↓ CSV			Investiguer beaucoup 5 ↓ CSV		
Police	Montant	Fraude	Police	Montant	Fraude	Police	Montant	Fraude
POL129644	612	38%	POL129928	24 045	57%	POL129555	22 739	78%
POL129505	22 546	36%	POL129798	22 890	56%	POL129890	784	72%
POL129809	724	35%	POL129586	24 341	55%	POL129600	2 554	64%
POL129872	21 264	35%	POL129712	24 454	54%	POL129607	24 309	63%
POL129962	24 350	34%	POL129542	2 311	49%	POL129742	12 038	60%
POL129923	24 085	34%	POL129725	1 079	49%			
POL129618	9 377	33%	POL129507	6 596	48%			
POL129965	7 093	33%	POL129636	24 645	47%			
POL129548	4 836	33%	POL129511	20 666	46%			
POL129717	15 870	32%	POL129659	15 552	46%			
POL129765	752	32%	POL129973	557	46%			
POL129540	6 441	31%	POL129940	17 042	45%			

FIGURE 2 – Résultats de l'évaluation restitués au gestionnaire : répartition des sinistres scorés en trois zones d'investigation (vert / orange / rouge)

Le dispositif est ensuite complété par une boucle d'enrichissement continu : une fois l'investigation d'un dossier close, son issue réelle (fraude avérée ou non) est renseignée sous forme binaire, et seuls les dossiers ainsi qualifiés viennent s'ajouter à la base d'apprentissage, permettant au modèle de se recalibrer sur des cas avérés et de suivre l'évolution des comportements frauduleux. Un rapport de pilotage restitue en continu la valeur ajoutée de l'outil avec la mise en avant de KPI clés : le montant de fraude évitée grâce à l'outil, l'impact sur le ratio Sinistres/Primes et le retour sur investissement (ROI). L'ensemble demeure placé sous supervision humaine : l'agent hiérarchise et oriente les dossiers, mais ne prononce aucune décision défavorable de façon automatique, l'investigation et la décision finale relevant toujours de l'enquêteur, conformément à l'article 22 du RGPD et à l'AI Act.

Limites et perspectives : Le mémoire se conclut sur une réflexion critique. Parmi les limites figurent le caractère partiellement simulé des données d'enrichissement, la sur-représentation probable de la fraude dans la base retenue (11,5 % contre environ 5 % en réalité), et la nécessité de recalibrer le modèle sur une sinistralité représentative avant tout déploiement. L'outil ouvre néanmoins de nombreuses voies d'amélioration : le couplage à une base portefeuille offrant une profondeur historique et relationnelle inaccessible au seul niveau du sinistre, l'intégration de données externes, la mutualisation inter-assureurs pour détecter les fraudeurs « nomades », ou encore l'extension à d'autres branches de l'assurance non-vie. À mesure que les capacités de l'intelligence artificielle progressent, la question n'est sans doute plus de savoir si ces outils transformeront la lutte anti-fraude, mais comment les assureurs sauront en faire un usage à la fois performant, maîtrisé et respectueux des droits des assurés.

Synthesis

Risk pooling is a cornerstone of insurance and presupposes a relationship of trust between insurer and policyholder, which fraud subverts. In non-life insurance, this phenomenon is estimated to generate annual losses of approximately € 2.5 billion in France, equivalent to approximately 3% of property and casualty premium income, a substantial share of which (around 60%) remains undetected. Beyond its direct cost, fraud adds approximately € 50 to the premium paid by every honest policyholder for each motor insurance contract and, in the long term, undermines the solidarity underpinning risk pooling.

Traditional approaches to combating fraud, based on the judgement of claims handlers and the intervention of specialised units, have now reached their limits. They allow only a fraction of claims to be reviewed, depend heavily on investigators' individual expertise, and face a difficult economic constraint : the cost of a manual investigation makes the review of low-value fraud (although the most widespread form) economically unviable. This observation gave rise to the present thesis, which sets out the step-by-step design and implementation of an automated motor insurance fraud-detection process supported by an artificial intelligence agent and covering the entire workflow, from data ingestion to system monitoring, against a backdrop in which similar tools have emerged on the market in recent years.

Key issues and positioning : The thesis begins by characterising insurance fraud, its typologies (opportunistic or organised, at policy inception or at the claims stage) and its legal framework, before assessing its economic significance. The value of a detection system cannot be measured solely by its statistical performance, but also by the claims costs it helps avoid. This economic grounding, formalised through the concept of expected unit gain, provides the guiding thread of the analysis and explains why the choice of model parameters ultimately requires a cost-benefit trade-off. The thesis then surveys fraud-detection methods, contrasting traditional manual approaches with the contributions of artificial intelligence, and reaches a conclusion that shapes the remainder of the study : rather than replacing human expertise, AI should complement it, with the algorithm filtering and prioritising cases while humans investigate and decide.

Theoretical framework : The methodological section presents the selected supervised models ranging from points-based scorecards and logistic regression to decision trees and ensemble methods such as Gradient Boosting, as well as unsupervised approaches applicable to organised fraud, including anomaly detection, clustering, and graph analysis. Particular attention is paid to evaluation metrics suited to severe class imbalance : in a population where fraud is rare, conventional indicators such as accuracy become misleading and should be replaced by AUC-ROC, the Gini coefficient, the Kolmogorov-Smirnov statistic, precision, recall, or PR-AUC. This section also emphasises the governance, interpretability, and regulatory-compliance requirements governing the deployment of such models, notably under the GDPR and the AI Act.

Tool design : The core of the thesis is devoted to the practical implementation of a decision-support tool for detecting motor insurance fraud. The scope is deliberately limited to circumstantial fraud that can be identified from structured data, including claim characteristics, the history of the policyholder and other parties involved, and the consistency of the claim declaration. The analysis relies on a public dataset comprising 30,000 motor claims and twenty-four variables, with a fraud rate of 11.5%. The dataset is subsequently enriched with twenty-nine additional variables simulated using artificial intelligence to reproduce the genuine information available

to an insurer, notably the history of the repairer, third party, and vehicle, as well as reporting behaviour and geographical and temporal dimensions.

The tool is structured around two modules corresponding to two clearly distinct user profiles and usage timeframes. The first module, designed for actuaries, supports model development through standardised data ingestion, automated data-quality audits, descriptive statistical analyses, the construction of fraud-prediction models, and selection of the best-performing model against predefined quality criteria.

The second module, designed for claims handlers, applies the previously calibrated model without exposing either its complexity or its internal mechanics. For each newly submitted claim, it returns an estimated probability of fraud and assigns the case to a risk category that determines the appropriate level of investigation.

The agent's construction logic is governed by a prompt broken down into successive stages, replicating the actuarial approach and ensuring the traceability of every link in the chain.

Results : The descriptive analysis identifies the principal determinants of fraud : the central role of the repairer environment, the policyholder's history of fraud, the consistency of the claim declaration, and the ratio of the repair invoice to the market price.

A counter-intuitive finding emerges : fraud is not concentrated among the most costly claims, which fully justifies the use of a multivariate approach. Three models are therefore developed and compared according to the trade-off between interpretability and performance ; their results are summarised below.

Indicator	Points-based scorecard	Decision tree	Gradient Boosting
AUC-ROC	0.917	0.845	0.933
Gini	0.835	0.690	0.867
KS	0.666	0.564	0.724
Lift @10 %	—	×4.83	× 6.37
PSI	0.0026	0.0026	0.0023
Backtesting gap	0.003	0.039	0.016

TABLEAU 2 – Synthesis of the quality indicator results for the different models

The Gradient Boosting model proves to be the most discriminating and is therefore selected, achieving an AUC of 0.933, a Gini coefficient of 0.867, and a lift of ×6.37 in the first decile. The points-based scorecard nevertheless remains a fully credible alternative : with an AUC of 0.917, it performs only slightly below Gradient Boosting while providing a level of transparency unavailable with ensemble methods, making it the preferred option when explainability takes precedence. The decision tree, which is outperformed across all criteria, is rejected. All three models also exhibit excellent stability, with PSI values well below the 0.10 alert threshold, and strong generalisation capacity.

One cross-cutting insight deserves emphasis : although the three models are based on different principles, their explanatory power converges on the same key variables. Foremost among these are the repairer invoice-to-market ratio, the policyholder's historical claimed amounts, and prior instances of fraud. The profile of the selected Gradient Boosting model, presented below, provides a representative illustration.




FIGURE 3 – Relative importance of variables in the retained model (Gradient Boosting)

Operational use and governance : Once selected and integrated, the model is made available to the fraud-detection department. In day-to-day operations, claims handlers submit one or more claims, and the tool returns for each claim an estimated probability of fraud together with guidance on the appropriate level of investigative effort. This probability is produced by the selected model, trained on claims whose outcome is known : for the Gradient Boosting model, it is the sum of the predictions of 200 successive trees, converted into a probability through a logistic function. It is then compared with the optimal threshold (45 %) to assign the claim to a risk category.

Cases are accordingly divided into three risk categories : a green category for low-probability cases requiring no investigation, an amber category for intermediate-probability cases requiring a limited investigation, and a red category for high-probability cases requiring an in-depth investigation. Claims handlers can therefore focus their efforts on the highest-risk cases without spending time on claims with a low probability of fraud.

Résultats de l'évaluation

500 sinistres scorés depuis car_insurance_fraud_dataset_500_fraude_inconnue.csv

● 0-39% ● 40-59% ● 60-100%

✓ Ne pas investiguer 474 ↓ CSV			🔍 Investiguer un peu 21 ↓ CSV			🔥 Investiguer beaucoup 5 ↓ CSV		
Police	Montant	Fraude	Police	Montant	Fraude	Police	Montant	Fraude
POL129644	612	38%	POL129928	24 045	57%	POL129555	22 739	78%
POL129505	22 546	36%	POL129798	22 890	56%	POL129890	784	72%
POL129809	724	35%	POL129586	24 341	55%	POL129600	2 554	64%
POL129872	21 264	35%	POL129712	24 454	54%	POL129607	24 309	63%
POL129962	24 350	34%	POL129542	2 311	49%	POL129742	12 038	60%
POL129923	24 085	34%	POL129725	1 079	49%			
POL129618	9 377	33%	POL129507	6 596	48%			
POL129965	7 093	33%	POL129636	24 645	47%			
POL129548	4 836	33%	POL129511	20 666	46%			
POL129717	15 870	32%	POL129659	15 552	46%			
POL129765	752	32%	POL129973	557	46%			
POL129540	6 441	31%	POL129940	17 042	45%			

FIGURE 4 – Assessment results provided to claims handlers : allocation of scored claims across three investigation categories (green / amber / red)

The system is further complemented by a continuous enrichment loop. Once a case investigation has been completed, its actual outcome (confirmed fraud or no fraud) is recorded as a binary value. Only claims whose outcomes have thus been established are added to the training dataset, enabling the model to be recalibrated on confirmed cases and to track changes in fraudulent behaviour. A monitoring report continuously presents the tool's added value through key performance indicators, including the amount of fraud avoided through the tool, the effect on the claims-to-premiums ratio, and the return on investment (ROI).

Although the fraud-detection process is largely automated using artificial intelligence, every stage remains subject to human oversight. The agent prioritises and routes cases but does not issue any adverse decision automatically ; investigation and the final decision always remain the responsibility of the investigator, in accordance with Article 22 of the GDPR and the AI Act.

Limitations and future directions : The thesis concludes with a critical reflection. The main limitations include the partially simulated nature of the enrichment data, the likely overrepresentation of fraud in the selected dataset (11.5% compared with approximately 5% in practice) and the need to recalibrate the model using representative claims experience before any deployment. Nevertheless, the tool opens up numerous avenues for improvement : linking it to a portfolio database that provides historical depth and relational information unavailable at claim level alone ; integrating external data ; pooling information across insurers to detect mobile fraudsters who move between companies ; and extending the approach to other lines of non-life insurance.

As artificial intelligence capabilities continue to advance, the question is arguably no longer whether these tools will transform the fight against fraud, but how insurers can use them in a manner that is effective, controlled, and respectful of policyholders' rights.

Chapitre 1

Introduction et contexte

1.1 Définition de la fraude à l'assurance

Le secteur de l'assurance repose sur un principe fondamental : la mutualisation des risques. En échange du paiement d'une prime, l'assuré bénéficie d'une protection financière en cas de réalisation d'un sinistre prévu au contrat. Ce mécanisme de solidarité économique suppose toutefois un climat de confiance entre l'assureur et l'assuré. Lorsque cette confiance est détournée à des fins illégitimes, on parle alors de fraude en assurance.

La fraude en assurance peut être définie comme **tout acte intentionnel visant à tromper un assureur dans le but d'obtenir un avantage indu, qu'il s'agisse d'une indemnisation injustifiée, majorée ou de la souscription d'un contrat dans des conditions mensongères.**

Elle se distingue de l'erreur ou de l'omission involontaire de par son caractère délibéré et frauduleux.

Cette pratique constitue un enjeu majeur pour les compagnies d'assurance, car elle entraîne des pertes financières importantes, impacte l'équilibre technique des portefeuilles et, indirectement, pèse sur l'ensemble des assurés au travers de l'augmentation des primes afin de compenser ces pertes.

L'objectif de la fraude en assurance est principalement financier : il s'agit d'obtenir un enrichissement personnel ou collectif illégitime. Toutefois, au-delà de la recherche d'un gain immédiat, certaines fraudes répondent à des logiques plus complexes, telles que le blanchiment de capitaux, le financement d'activités criminelles ou la structuration d'organisations délictueuses. Ainsi, la fraude peut prendre des formes variées, allant de la simple exagération d'un dommage à la mise en place de réseaux organisés exploitant systématiquement les failles du système assurantiel.

Il convient, à cet égard, de distinguer deux grandes catégories de fraude :

- **La fraude opportuniste**, qui correspond à un comportement isolé, souvent ponctuel, commis par un assuré qui profite d'une situation donnée (par exemple, majorer le montant d'un sinistre ou déclarer un dommage antérieur comme récent). Elle s'inscrit généralement dans une logique individuelle et circonstancielle.
- **La fraude organisée**, qui elle repose sur une démarche structurée et planifiée, impliquant parfois plusieurs acteurs (intermédiaires, professionnels de santé, réparateurs, réseaux criminels). Elle est caractérisée par son caractère itératif, sa préméditation et son ampleur financière plus importante.

Cette distinction est essentielle, car elle implique des modes de détection, de prévention et de répression différents. Là où la fraude opportuniste peut être combattue par des contrôles renforcés et une sensibilisation accrue, la fraude organisée nécessite des dispositifs d'investigation spécialisés, des outils d'analyse de données avancés et une coopération étroite entre assureurs, autorités judiciaires et organismes de régulation.

À noter que la fraude est contraire à un principe important en assurance : **le principe indemnitaire et la règle de non-enrichissement en assurance non-vie.**

Ce principe est expressément consacré par l'article L.121-1 du Code des assurances, selon lequel :

« L'assurance relative aux biens est un contrat d'indemnité ; l'indemnité due par l'assureur à l'assuré ne peut dépasser le montant de la valeur de la chose assurée au moment du sinistre. »

Ce texte pose clairement la règle de non-enrichissement : l'assurance a pour finalité exclusive la réparation du préjudice subi, et non l'octroi d'un profit à l'assuré. L'indemnité ne peut excéder ni le montant du dommage, ni la somme assurée prévue au contrat.

Ainsi, l'indemnisation vise à replacer l'assuré dans la situation patrimoniale qui aurait été la sienne en l'absence de sinistre (principe de réparation intégrale, sans perte ni profit).

Le principe de non-enrichissement joue également un rôle central dans la lutte contre la fraude en assurance non-vie. En effet, toute déclaration intentionnellement inexacte ayant pour effet d'obtenir une indemnité supérieure au préjudice réel constitue une atteinte directe à ce principe.

Plusieurs dispositions viennent renforcer cette protection :

- **Article L.113-2** : obligation pour l'assuré de répondre exactement aux questions posées lors de la souscription et de déclarer sincèrement le sinistre ;
- **Article L.113-8** : nullité du contrat en cas de réticence ou fausse déclaration intentionnelle ;
- **Article L.113-9** : réduction proportionnelle de l'indemnité en cas de déclaration inexacte non intentionnelle.

Dans le cadre de la fraude opportuniste (exagération du montant des dommages, ajout d'objets inexistants, fausse date du sinistre), la violation du principe indemnitaire se traduit par une tentative d'enrichissement indu.

Dans le cas de la fraude organisée (réseaux de sinistres fictifs, collusion avec des réparateurs ou professionnels de santé, sinistres provoqués), la remise en cause est plus systémique : l'objectif n'est plus seulement d'obtenir une indemnité excessive, mais de détourner de manière structurée le mécanisme même de mutualisation.

1.2 Les stades d'occurrence de la fraude dans le cycle assurantiel en assurance non-vie

En assurance non-vie, la fraude peut intervenir à plusieurs étapes de la relation contractuelle. Deux moments apparaissent particulièrement sensibles :

1. La fraude à la souscription du contrat ;
2. La fraude à la déclaration d'un sinistre.

Ces deux temporalités répondent à des logiques différentes mais poursuivent un objectif commun : obtenir un avantage économique indu en détournant le mécanisme indemnitaire.

1.2.1 La fraude à la souscription

La fraude à la souscription a lieu lors de la conclusion du contrat, avant tout sinistre. Elle consiste à fournir intentionnellement des informations inexactes ou incomplètes afin d'obtenir des conditions tarifaires plus favorables ou de rendre assurable un risque qui ne le serait pas.

Elle constitue une violation directe de l'obligation de déclaration exacte du risque prévue par l'article L.113-2 du Code des assurances.

L'objectif est ici principalement tarifaire : réduire le montant de la prime ou contourner un refus d'assurance.

La fraude à la souscription peut ainsi priver totalement l'assuré de garantie au moment du sinistre.

	Assurance automobile	Assurance habitation
Fraude à la souscription	• Fausse déclaration du conducteur principal : un parent déclare être le conducteur principal alors que le véhicule est utilisé principalement par un jeune conducteur afin d'éviter une surprime. • Fausse adresse de garage : déclaration d'un stationnement en zone rurale alors que le véhicule est stationné en zone urbaine à forte sinistralité. • Dissimulation d'un usage professionnel : déclarer un usage « privé » alors que le véhicule est utilisé pour des livraisons ou VTC. • Fraude documentaire : faux papiers d'identité.	• Sous-évaluation du capital mobilier pour réduire la prime. • Omission de circonstances aggravantes : logement inoccupé plusieurs mois par an, absence de système de sécurité, activité professionnelle à domicile. • Fausse déclaration de la qualité d'occupant (se déclarer propriétaire occupant plutôt que bailleur).

TABLEAU 1.1 – Exemples de fraude à la souscription en assurance non-vie

1.2.2 La fraude à la déclaration d'un sinistre

La fraude la plus courante en assurance non-vie se produit lors de la déclaration d'un sinistre. Cela peut inclure la surestimation des dommages, la déclaration de sinistres fictifs, la falsification de preuves (comme des photos ou des rapports de police). Ces fraudes visent à obtenir des indemnités plus élevées que celles auxquelles l'assuré aurait pu prétendre, ou bien d'engendrer une indemnité qui n'aurait tout simplement pas dû exister.

À noter que la falsification de documents est de plus en plus accessible et difficile à détecter à l'œil nu suite à l'essor de l'IA générative.

	Assurance automobile	Assurance habitation
Fraude à la déclaration d'un sinistre	• Exagération des dommages : ajout de dégâts antérieurs sur le constat amiable. • Fausse date de sinistre : déclarer un accident survenu avant la souscription comme postérieur à celle-ci. • Sinistre fictif : déclaration d'un vol de véhicule inexistant ou maquillage d'un incendie volontaire. • Accident provoqué intentionnellement (fraude organisée dans certains cas). • Constats de complaisance entre complices pour imputer la responsabilité à un tiers assuré. • Fraude documentaire : faux devis, fausses factures de réparation, gonflement des temps de main-d'œuvre, faux certificats de cession ou documents d'identité, manipulation de photos (dommages antérieurs).	• Ajout d'objets inexistants lors d'un vol déclaré. • Surestimation de la valeur des biens (factures falsifiées ou modifiées). • Déclaration d'un dégât des eaux ancien comme récent pour le rendre indemnisable. • Incendie volontaire destiné à obtenir une indemnité. • Fraude documentaire : fausses factures d'ameublement après vol, devis travaux surévalués après dégât des eaux, falsification de preuves d'effraction, antidatation de justificatifs.

TABLEAU 1.2 – Exemples de fraude à la déclaration d'un sinistre en assurance non-vie

En assurance non-vie, la fraude peut ainsi être appréhendée selon différents stades d'occurrence dans le cycle assurantiel. Elle peut naître lors de la souscription du contrat, se révéler au moment de la déclaration du sinistre, mais également prendre la forme d'un détournement des stipulations contractuelles, notamment des conditions générales, afin d'obtenir une prise en charge indue, comme nous l'évoquerons dans le paragraphe suivant.

1.2.3 La fraude liée aux Conditions Générales

La fraude liée aux conditions générales ne constitue pas, à strictement parler, un moment autonome de la fraude. Elle renvoie plutôt à une logique contractuelle particulière, consistant à manipuler les circonstances du sinistre ou l'interprétation du contrat afin de faire entrer le dommage dans le champ de la garantie. Si cette fraude peut trouver son origine dès la souscription, elle se manifeste le plus souvent lors de la déclaration ou de l'instruction du sinistre.

La fraude aux Conditions Générales en assurance non-vie renvoie à la recherche volontaire d'une indemnisation en contradiction avec les clauses contractuelles (définitions, exclusions, franchises, plafonds, obligations de prévention), sans nécessairement qu'il y ait eu fraude à la souscription.

Elle se matérialise par une manipulation des circonstances du sinistre afin de le faire entrer dans le périmètre de garantie : déclaration d'un vol simple en vol avec effraction, transformation d'un défaut d'entretien en événement accidentel, antériorité dissimulée d'un dommage, ou requalification d'un usage non couvert.

Par exemple, en assurance automobile, dans le cadre d'un sinistre survenu lors d'un usage professionnel alors que le véhicule est déclaré en usage privé, la modification du contexte pour entrer dans le champ contractuel est qualifiée de fraude.

	Assurance automobile	Assurance habitation
Fraude liée aux conditions générales	• Requalification d'un usage exclu : déclarer un sinistre survenu dans un cadre privé alors que le véhicule était utilisé à titre professionnel, afin de bénéficier de la garantie. • Déclaration inexacte des circonstances du vol : affirmer que les clés n'étaient pas laissées dans le véhicule ou à proximité, afin d'éviter l'application d'une exclusion. • Manipulation des circonstances du sinistre : faire passer une panne mécanique ou un défaut d'entretien pour un dommage accidentel couvert par le contrat. • Fausse qualité du conducteur au moment du sinistre : déclarer que le véhicule était conduit par un conducteur autorisé alors qu'il était utilisé par une personne exclue ou non déclarée. • Contournement d'une franchise ou d'un plafond : fractionner artificiellement un dommage ou modifier sa nature pour obtenir une meilleure prise en charge contractuelle.	• Fausse déclaration d'effraction : présenter un vol simple comme un vol avec effraction pour satisfaire à la condition contractuelle de garantie. • Transformation d'un défaut d'entretien en événement accidentel : présenter une infiltration progressive ou un défaut d'étanchéité comme un dégât des eaux soudain et garanti. • Dissimulation de l'occupation du logement : omettre que le logement était vacant au-delà de la durée prévue par le contrat au moment du sinistre. • Requalification d'un bien exclu en bien garanti : déclarer comme mobilier assuré un objet relevant d'une exclusion ou nécessitant une garantie spécifique. • Mise en scène d'un dommage garanti : présenter un dommage esthétique, ancien ou non garanti comme consécutif à un événement couvert (incendie, dégât des eaux, vol).

TABLEAU 1.3 – Exemples de fraude liée aux conditions générales en assurance non-vie

1.3 Cadre réglementaire des sanctions en cas de fraude avérée

La fraude en assurance ne se limite pas à une simple irrégularité contractuelle : elle peut emporter des conséquences à plusieurs niveaux. Selon le moment où elle intervient et sa nature, elle peut produire des effets civils et contractuels, tels que la nullité du contrat, la déchéance de garantie, le refus d'indemnisation ou la restitution des indemnités indûment versées.

Elle peut également, lorsque les manœuvres frauduleuses sont suffisamment caractérisées, relever du droit pénal. Le régime applicable diffère toutefois selon que la fraude intervient au moment de la souscription du contrat ou lors de la déclaration du sinistre, ce qui justifie de distinguer ces deux situations avant d'aborder les questions probatoires et les qualifications pénales susceptibles d'être retenues.

1.3.1 Souscription

En matière de souscription, le régime des sanctions repose principalement sur les articles L.113-8 et L.113-9 du Code des assurances. Il convient toutefois de distinguer si l'inexactitude déclarative procède d'une intention frauduleuse ou d'une simple erreur.

L'article L.113-8 prévoit que la réticence ou la fausse déclaration intentionnelle de l'assuré entraîne la nullité du contrat. Cette sanction suppose que l'assureur démontre non seulement l'inexactitude ou l'omission, mais

également le caractère intentionnel de cette déclaration, c'est-à-dire la volonté de tromper l'assureur sur l'appréciation du risque. En pratique, cette intention frauduleuse doit porter sur un élément que l'assureur considérerait comme déterminant dans sa décision de contracter ou dans la fixation de la prime.

La nullité du contrat produit un effet rétroactif : le contrat est réputé n'avoir jamais existé, de sorte que l'assureur n'est pas tenu de garantir le sinistre. En outre, les primes déjà versées demeurent acquises à l'assureur, à titre de dommages et intérêts. Cette sanction est particulièrement sévère et reflète l'exigence de bonne foi qui gouverne la formation du contrat d'assurance.

À l'inverse, l'article L.113-9 vise l'hypothèse d'une déclaration inexacte non intentionnelle. Dans ce cas, il n'y a pas fraude à proprement parler, mais le contrat n'est pas pour autant maintenu sans conséquence. Si l'erreur est constatée avant tout sinistre, l'assureur peut soit maintenir le contrat moyennant une augmentation de prime, soit le résilier. Si elle est découverte après sinistre, l'indemnité peut être réduite proportionnellement au rapport entre la prime payée et celle qui aurait été due si le risque avait été exactement déclaré. Cette distinction entre mauvaise foi et simple erreur est essentielle, car toute anomalie déclarative n'a pas vocation à recevoir la qualification de fraude.

1.3.2 Sinistre

Lorsque la fraude intervient au moment du sinistre, les conséquences juridiques diffèrent de celles applicables à la souscription. Il ne s'agit plus de remettre en cause la formation du contrat, mais de sanctionner une demande de garantie ou d'indemnisation obtenue ou tentée au moyen de déclarations mensongères, d'une dissimulation de circonstances essentielles ou de la production de pièces falsifiées.

La première conséquence est le refus d'indemnisation lorsque la fraude est détectée avant tout paiement. En pratique, l'assureur peut opposer à l'assuré l'absence de droit à garantie dès lors que le sinistre déclaré ne correspond pas à la réalité ou que son montant a été artificiellement majoré. Cette sanction peut également prendre la forme d'une déchéance de garantie lorsque le contrat prévoit qu'une fausse déclaration intentionnelle relative au sinistre prive l'assuré du bénéfice de la garantie. La déchéance se distingue de la nullité en ce qu'elle n'affecte pas l'existence même du contrat, mais uniquement le droit à indemnisation au titre du sinistre concerné.

Si l'indemnité a déjà été versée au moment de la découverte de la fraude, l'assureur peut engager une action en restitution des sommes indûment perçues. Cette répétition de l'indu permet de récupérer le montant versé en l'absence de droit légitime à indemnisation. Dans les cas les plus graves, l'assureur pourra en outre solliciter des dommages et intérêts en réparation du préjudice subi, notamment lorsque la fraude a entraîné des coûts d'expertise, d'enquête ou de gestion supplémentaires.

En pratique, la mise en œuvre de ces sanctions suppose toutefois que la fraude soit effectivement démontrée. Or, la fraude au sinistre ne se présume pas : l'assureur doit être en mesure d'établir le caractère intentionnel des manœuvres invoquées, ce qui renvoie directement à la question de la preuve, mais également, dans certaines hypothèses, à d'éventuelles poursuites pénales.

1.3.3 Preuve de la fraude et sanctions pénales

La mise en œuvre des sanctions contractuelles suppose, en premier lieu, que la fraude soit prouvée. En droit des assurances comme en droit commun, la fraude ne se présume pas. **Il appartient donc à l'assureur d'établir l'existence de manœuvres intentionnelles destinées à obtenir un avantage indu.** Cette exigence probatoire est particulièrement importante, car une simple incohérence ou une approximation dans les déclarations de l'assuré ne suffit pas, à elle seule, à caractériser une fraude.

La preuve peut être rapportée par tout moyen et résulte souvent, en pratique, d'un faisceau d'indices graves,

précis et concordants. Il peut s'agir, par exemple, d'incohérences entre les déclarations successives, d'anomalies documentaires, de contradictions entre les circonstances déclarées et les constatations matérielles, ou encore de rapprochements opérés à partir d'historiques de sinistres et de données comportementales.

Cette dimension probatoire explique le recours croissant, chez les assureurs, à des dispositifs spécialisés d'investigation, à l'analyse de données et à des modèles de *scoring* destinés à hiérarchiser les dossiers les plus suspects, sans pour autant se substituer à l'appréciation humaine.

Au-delà des conséquences contractuelles, certaines fraudes à l'assurance peuvent également recevoir une qualification pénale. Lorsque l'assuré use de manœuvres frauduleuses afin de tromper l'assureur pour obtenir la remise de fonds, les faits peuvent relever de l'escroquerie au sens de l'article 313-1 du Code pénal.

De même, la production de justificatifs falsifiés, de fausses factures, de faux constats ou de documents d'identité altérés est susceptible de constituer un faux ou un usage de faux. Le droit pénal vient ainsi compléter le droit des assurances : là où ce dernier organise les conséquences contractuelles de la fraude, le premier sanctionne la manœuvre frauduleuse elle-même lorsqu'elle porte atteinte à l'ordre économique public.

1.4 Enjeux économiques et actuariels de la fraude

1.4.1 L'ampleur du marché de la fraude

Le marché de l'assurance non-vie représente 80,3 Md€ de primes pour 56,3 Md€ de prestations versées en 2025.

Le volume de sinistres étant très important, il n'est pas envisageable de vérifier manuellement la véracité de chaque déclaration sans rogner de manière trop importante sur la marge de l'assureur.

	Cotisations	Prestations
Assurance de biens et de responsabilité	80,3 Md€	56,3 Md€
<i>Dont assurance automobile</i>	30,2 Md€	24,7 Md€
<i>Dont assurance habitation</i>	14,9 Md€	9,9 Md€

TABLEAU 1.4 – Cotisations et prestations d'assurance de biens et de responsabilité en 2025 (Source : France Assureurs)¹.

Ainsi, la profession s'est structurée autour de l'**ALFA** (Agence de Lutte contre la Fraude à l'Assurance).

Créée en février 1989, cette association professionnelle a pour mission d'accompagner les assureurs français dans la prévention et la détection des fraudes. Elle agit comme un véritable carrefour d'informations, centralisant les données, formant les gestionnaires et collaborant avec les pouvoirs publics (notamment le ministère de l'Intérieur) pour endiguer ce phénomène [4].

La fraude à l'assurance est un phénomène complexe à quantifier avec précision, car par nature, une grande partie reste non détectée. Au niveau européen, la fédération *Insurance Europe* estime que la fraude représente jusqu'à 10 % du coût total des sinistres². En France, selon les estimations de la Fédération Française de l'Assurance et de l'ALFA, le coût global de la fraude (détectée et non détectée) s'élèverait à environ 2,5 milliards d'euros par an. Cette estimation, établie en 2014, représentait alors environ 5 % des cotisations en assurance de biens

1. https://www.franceassureurs.fr/wp-content/uploads/20260325_presentation-conference-de-presse-2.pdf

2. <https://www.insuranceurope.eu/mediaitem/0bf0af82-e7ef-4439-a763-d7862859d421/The+impact+of+insurance+fraud.pdf>

et de responsabilité ; rapportée aux 80,3 Md€ de cotisations de 2025, elle en représenterait environ 3 %, ce qui en fait vraisemblablement une borne basse ³.

Les montants identifiés sont ainsi passés de 695 millions d'euros en 2023 à 902 millions d'euros en 2024 (+30 %) et 947 millions d'euros en 2025 (+5 %).

Finalement, les acteurs du marché soulignent et rappellent que c'est la collectivité entière qui est pénalisée, la fraude alourdissant la prime annuelle de chaque assuré honnête d'environ 50 euros par contrat d'assurance automobile ⁴.




FIGURE 1.1 – Évolution de la fraude automobile entre 2020 et 2025 (Source : ALFA Association) ⁵.

Si ce fléau touche toutes les branches de l'assurance, l'IARD (Incendie, Accidents et Risques Divers) en représente de loin la part la plus importante.

À titre d'exemple, sur les 947 millions d'euros de fraudes détectées en 2025, 627 millions concernent exclusivement l'IARD (notamment l'assurance Automobile et l'assurance Multirisque Habitation), soit près de 66 % du total ⁶.

Les assurances de biens, par leur forte fréquence de sinistralité, demeurent le secteur le plus exposé aux déclarations de sinistres fictifs ou à la surestimation des dommages.

Ces segments cumulent plusieurs facteurs d'exposition : une fréquence de sinistres élevée, une forte volumétrie de dossiers de montant unitaire parfois modéré, ainsi qu'une documentation déclarative susceptible d'être manipulée.

En assurance automobile, la multiplicité des intervenants (assuré, tiers, réparateur, expert, dépanneur) accroît les opportunités de fraude. En assurance habitation, la difficulté de vérifier a posteriori la réalité, l'antériorité ou la valeur des biens déclarés favorise également les comportements opportunistes.

Ce phénomène et ses proportions ne sont pas une spécificité française. À l'échelle européenne, la fédération

3. <https://www.argusdelassurance.com/institutions/fraude-a-l-assurance-une-facture-de-2-5-md-en-dommages-en-2014-alfa.96060>

4. <https://www.argusdelassurance.com/acteurs/fraude-a-l-assurance-un-cout-de-50-pour-les-assures.60931>

5. Sources : <https://www.alfa.asso.fr/alfa-news-48-septembre-2024/>; <https://www.alfa.asso.fr/alfa-news-39-juin-2023-2/> et <https://www.franceassureurs.fr/wp-content/uploads/donnees-cles-2024.pdf>

6. <https://www.argusdelassurance.com/assurance-de-personnes/des-filieres-de-larnaue-utilisent-lintelligence-artificielle-pres-dun-milliard-deuros-de-fraudes-a-l-assurance-detecte-en-2025.VRVQHSDANZGGZL5GXH7FHW3JU4.html>

Insurance Europe estime que la fraude représente en moyenne jusqu'à 10 % du coût total des sinistres dans les pays voisins (comme au Royaume-Uni ou en Allemagne). La France se situe donc dans cette moyenne continentale. Toutefois, l'écart observé en France entre la fraude effectivement détectée (947 millions d'euros en 2025) et le coût global estimé de la fraude (environ 2,5 milliards d'euros par an) souligne qu'une part importante des préjudices, de l'ordre de 60 %, passe encore « à travers les mailles du filet ». Cette « fraude invisible » représente un défi majeur pour la rentabilité des compagnies d'assurance.

1.4.2 Impact de la fraude sur la tarification

L'enjeu de la fraude ne se résume pas à une perte ponctuelle pour les assureurs : il affecte plus largement l'équilibre technique du marché, la qualité des données historiques et, en définitive, la construction même des primes. C'est ce lien direct entre fraude, sinistralité observée et tarification qu'il convient désormais d'examiner.

1.4.2.1 Modèle tarifaire usuel en assurance non-vie et biais statistiques

En assurance non-vie, la tarification repose usuellement sur des Modèles Linéaires Généralisés (GLM).

La Prime Pure (PP) est modélisée par le produit de l'espérance de la fréquence des sinistres (N) et de l'espérance de leur coût moyen (C) :

$$PP = \mathbb{E}[N] \times \mathbb{E}[C] \quad (1.1)$$

L'absence de détection de la fraude introduit un biais systématique dans les bases de données utilisées pour calibrer ces modèles tarifaires (que ce soit via des GLM traditionnels ou des algorithmes de *machine learning* comme XGBoost) :

- **Impact sur la fréquence (N)** : La fraude opportuniste ou préméditée (déclaration de sinistres imaginaires) augmente artificiellement le nombre de sinistres dans le portefeuille.
- **Impact sur le coût moyen (C)** : La majoration de dommages (ajout d'éléments fictifs sur une facture réelle) gonfle la sévérité moyenne des sinistres.

Si l'actuaire calibre ses modèles sur ces données polluées, il surestime le risque réel du portefeuille sain. La prime demandée aux assurés honnêtes augmente, ce qui dégrade la compétitivité de l'assureur sur le marché.

1.4.2.2 Conséquence de la fraude sur la prime pure

Dans l'équation de la prime pure, une surestimation de la fréquence ou du coût moyen conduit mécaniquement à une prime plus élevée pour l'ensemble du portefeuille.

Dans le cas de la fraude par majoration (sinistre réel mais montant surévalué), l'impact est directement porté sur l'espérance du coût moyen $\mathbb{E}[C]$:

$$\mathbb{E}[C] = \mathbb{E}[C]_{\text{réel}} + \mathbb{E}[C]_{\text{majoration}} \quad (1.2)$$

Dans le cas de la fraude par invention (sinistre totalement fictif), l'impact est porté sur la fréquence $\mathbb{E}[N]$:

$$\mathbb{E}[N] = \mathbb{E}[N]_{\text{réel}} + \mathbb{E}[N]_{\text{fictif}} \quad (1.3)$$

Ainsi, si l'on note α la part de la charge sinistre imputable à la fraude, la prime d'équilibre technique observée

($\Pi_{\text{chargée}}$) se déduit de la prime pure théorique (Π_{pure}) par la relation :

$$\Pi_{\text{chargée}} = \frac{\Pi_{\text{pure}}}{1 - \alpha} \quad (1.4)$$

où α est estimé entre 5 % et 10 % du volume des prestations selon les branches (Source : ALFA).

Part de la fraude dans la charge (α)	Surcoût sur la prime pure (%)
5,0 %	+ 5,26 %
7,5 %	+ 8,11 %
10,0 %	+ 11,11 %

TABLEAU 1.5 – Impact de la fraude sur la prime des assurés honnêtes

Il faut souligner que l'effet de la fraude sur la tarification ne se limite pas à une hausse mécanique de la prime pure. Il se propage également aux **chargements de gestion**, dans la mesure où la lutte contre la fraude mobilise des ressources d'expertise, de contrôle et de contentieux.

En outre, une répercussion trop importante de ces coûts dans les primes commerciales peut nuire à la compétitivité de l'assureur et accentuer les phénomènes d'anti-sélection, en éloignant les assurés les moins risqués du portefeuille.

De plus, un enjeu central réside dans le fait que la fraude peut fausser la segmentation elle-même.

En effet, certaines variables explicatives peuvent apparaître comme fortement corrélées à la sinistralité observée non pas en raison d'un risque assurantiel intrinsèque plus élevé, mais parce qu'elles sont associées à une fréquence accrue de comportements frauduleux ou à des modalités de détection différenciées. L'actuaire court alors le risque d'intégrer dans la tarification des effets qui relèvent moins du risque pur que de distorsions comportementales ou informationnelles.

Inversement, l'amélioration des dispositifs de détection permet d'assainir les bases historiques servant à la modélisation actuarielle. À terme, une meilleure identification des dossiers frauduleux contribue à restaurer une mesure plus fidèle du risque technique, à améliorer la segmentation tarifaire et à limiter le transfert de charge vers les assurés honnêtes. **La lutte contre la fraude devient ainsi non seulement un levier de réduction des pertes, mais également un instrument de qualité tarifaire.**

1.4.2.3 L'analyse coût-bénéfice : le seuil de rentabilité du contrôle

Pour corriger ce biais tarifaire, l'assureur doit identifier et rejeter les sinistres frauduleux. Cependant, le processus de détection n'est pas gratuit : il engage des frais de gestion supplémentaires (expertise contradictoire, enquête administrative, recours à un détective privé).

L'assureur fait donc face à un problème d'optimisation économique simple : l'espérance d'économie (le non-paiement du sinistre) doit être supérieure au coût du contrôle.

Ainsi si C_{invest} représente le coût moyen d'une investigation et M_{sinistre} le montant du sinistre réclamé, le contrôle n'est rationnel que si :

$$M_{\text{sinistre}} \times P(\text{Fraude} \mid \text{Alerte}) > C_{\text{invest}} \quad (1.5)$$

Où $P(\text{Fraude} \mid \text{Alerte})$ représente la précision du modèle de détection (la probabilité que l'alerte soit réellement

fondée).

Sur le marché français, une expertise automobile classique coûte entre 70 € et 400 € par dossier ⁷, tandis qu'une investigation spécialisée (enquêteur certifié ALFA) peut rapidement dépasser les 1 000 €, les honoraires étant libres et dépendant fortement du type de sinistre.

Ainsi, pour un sinistre matériel de 1 200 €, engager une expertise à 250 € est rentable. En revanche, pour de « petits sinistres » (par exemple un bris de glace à 400 €), le coût administratif et d'expertise rend la détection humaine irrationnelle d'un point de vue économique.

1.4.2.4 L'automatisation de la détection de la fraude comme levier de rentabilité

C'est sur cette « fraude de masse », de faible montant, que le modèle traditionnel atteint ses limites, et que l'implémentation de nouvelles technologies devient indispensable.

En effet, à date, avec la digitalisation, on observe une hausse des tentatives de fraude, notamment au travers de falsifications numériques et de retouches d'image ⁸.

En parallèle, l'amélioration des outils tels que la *Data analytics*, la détection d'anomalies, l'analyse d'image ou le *Cross-checking* de bases externes permet d'améliorer le taux de détection des fraudes.

Néanmoins, malgré l'amélioration des méthodes de détection de fraude, la fraude documentaire reste un poste matériel dans le coût technique global. En mettant en place des méthodes de détection de fraude automatiques (algorithmes de *scoring*, IA etc.), l'assureur réduit drastiquement le coût de traitement et de ciblage des fraudes.

Le coût marginal de vérification s'approchant de zéro, il devient alors rentable d'investiguer des sinistres de plus faible montant, assainissant ainsi la base de sinistralité et protégeant l'équilibre de la prime.

C'est précisément dans la réponse à ce défi opérationnel et financier que s'inscrit l'objectif central de ce mémoire. En effet, les ambitions des travaux de ce mémoire sont de concevoir et déployer un processus de détection automatisé des fraudes de bout en bout.

Il convient toutefois de circonscrire d'emblée le périmètre de cette détection. Notre démarche ne porte pas sur la fraude documentaire (falsification de factures, de devis ou d'attestations) ni sur la fraude relevant de l'analyse d'images (clichés retouchés ou détournés), faute de disposer des bases de données documentaires et photographiques nécessaires à l'entraînement de tels modèles.

L'approche retenue se concentre au contraire sur la **fraude circonstancielle**, c'est-à-dire celle qui se révèle à travers les caractéristiques mêmes du sinistre et de l'assuré : nature et chronologie de la déclaration, antécédents et historique du contrat, profil du déclarant, cohérence entre les circonstances rapportées et les paramètres du sinistre, ou encore récurrence de signaux faibles susceptibles de trahir une intention frauduleuse.

Cette orientation présente l'avantage de s'appuyer exclusivement sur des données structurées déjà disponibles dans les systèmes de gestion de l'assureur, ce qui en fait un levier à la fois exploitable, reproductible et directement intégrable au processus d'instruction des sinistres.

Pour y parvenir, l'étude s'appuie sur une base de données publique de sinistres automobiles issue de Kaggle, contenant des dossiers étiquetés comme frauduleux ou non. À défaut de données réelles d'assureur, difficilement accessibles pour des raisons de confidentialité, cette base offre un support représentatif et reproductible pour développer et tester la démarche, même si sa transposition à un portefeuille réel nécessiterait une phase de recalibrage.

7. Source : Service-Public.fr, <https://www.service-public.fr/particuliers/vosdroits/F31268>

8. La fraude documentaire (faux certificats, fausses factures, photos retouchées) est en explosion et représente désormais 39 % des cas de fraude détectés en IARD (source : <https://www.itesoft.com/fr/blog/fraude-assurance-chiffres-cles-alfa/>).

Pour pallier en partie à ce recalibrage inexistant, cette base a été enrichie avec des données qui auraient été disponibles pour un assureur de manière à enrichir le modèle de détection de fraude créé.

Les chapitres suivants détailleront la démarche de mise en œuvre d'un tel outil pas à pas : après un état des lieux des processus de détection existants et de l'apport de l'intelligence artificielle (Chapitre 2), puis un rappel du cadre théorique des algorithmes de détection de fraude et de leurs critères d'évaluation (Chapitre 3), le Chapitre 4 présentera la gouvernance de l'outil, la base de données et les premières étapes de l'agent (ingestion, audit et analyse descriptive). Le Chapitre 5 détaillera la construction et la comparaison des trois modèles de détection retenus (*scoring* en points, arbre de décision et Gradient *Boosting*), et le Chapitre 6 l'outil opérationnel mis à disposition des services de gestion des sinistres, son utilisation pratique et sa logique d'enrichissement continu. Enfin, le Chapitre 7 ouvrira sur les limites de l'outil et les perspectives d'évolution, notamment autour de la qualité des données, de la mutualisation inter-assureurs et de l'extension de l'outil à une approche multi-produits.

Chapitre 2

La détection de la fraude en assurance : de l'approche manuelle à l'automatisation par l'IA

2.1 L'approche traditionnelle : une détection manuelle et ciblée

2.1.1 Le rôle des équipes dédiées

Historiquement, la lutte contre la fraude en assurance non-vie repose sur une organisation humaine structurée, intégrée à la chaîne de gestion des sinistres.

Le premier maillon en est le gestionnaire de sinistres : chargé d'instruire les déclarations et de procéder à l'indemnisation, il constitue le point de contact initial avec le dossier et, à ce titre, la première ligne de détection.

Lorsqu'un dossier éveille un doute, il peut être orienté vers une instance spécialisée (service ou cellule anti-fraude) composée d'enquêteurs et d'analystes dont c'est le métier exclusif. Ces cellules regroupent souvent des enquêteurs spécialisés, des *data analysts* (pour la détection algorithmique), des juristes et parfois d'anciens policiers ou gendarmes.

Ces enquêteurs disposent de prérogatives et de moyens d'investigation plus poussés : demande de pièces complémentaires, vérification des déclarations, recoupement avec des bases sectorielles, recours éventuel à des expertises ou à des enquêtes de terrain.

Cette organisation s'insère à un point précis de la chaîne d'indemnisation : entre la déclaration du sinistre et le versement de l'indemnité. La détection intervient ainsi comme un filtre, destiné à suspendre ou approfondir l'instruction des dossiers suspects avant que l'indemnisation ne soit prononcée.

Sa position est donc stratégique, puisqu'une fraude non détectée à ce stade se traduit directement par un versement indu, tandis qu'un contrôle trop systématique alourdit les délais de gestion et dégrade la qualité de service pour les assurés de bonne foi. L'équilibre entre maîtrise du risque de fraude et fluidité du règlement constitue l'arbitrage permanent de ces équipes.

2.1.2 Une détection fondée sur l'expertise humaine

Dans ce **dispositif traditionnel**, la détection repose essentiellement sur le **jugement et l'expérience des intervenants**. Elle s'opère largement « au fil de l'eau » : c'est au moment de l'instruction d'un dossier que le gestionnaire, par sa connaissance des cas habituels, perçoit une anomalie ou une incohérence. Cette vigilance

s'appuie sur un ensemble de signaux d'alerte ou *red flags* issus de l'expérience accumulée : délai anormalement court entre la souscription et le sinistre, déclaration tardive, circonstances peu cohérentes, antécédents répétés, montant de dommages disproportionnés, ou encore concordances suspectes entre plusieurs dossiers.

Une fois le soupçon né, la confirmation passe par un travail de recoupement manuel : rapprochement des informations déclarées, comparaison avec l'historique du contrat et de l'assuré, vérification de la cohérence d'ensemble. Ce processus mobilise fortement l'intuition métier, c'est-à-dire la capacité, forgée par la pratique, à identifier des configurations atypiques que ne traduit aucune règle écrite. Cette expertise humaine constitue une force réelle : elle est fine, contextuelle et capable d'appréhender des situations inédites. Mais elle est aussi, par nature, **difficilement formalisable et transmissible**, ce qui en fait simultanément la principale limite de l'approche.

2.1.3 Les limites de cette approche

Si l'expertise humaine demeure précieuse, l'organisation traditionnelle se heurte à plusieurs limites structurelles. La première tient à sa couverture partielle : **le contrôle manuel étant coûteux** en temps, seule une fraction des dossiers peut être examinée en profondeur, la grande majorité étant traitée sans analyse anti-fraude approfondie. Il en résulte un risque non négligeable de non-détection : de nombreuses fraudes échappent au dispositif, non parce qu'elles seraient indétectables, mais faute de ressources pour les examiner, passant inaperçues sous la forme de faux négatifs lorsque les indices ne sont pas suffisamment manifestes.

S'y ajoute une **forte dépendance à l'expertise individuelle**. La qualité de la détection varie selon l'expérience, la charge de travail et la vigilance de chaque gestionnaire, chacun appliquant ses propres critères et son propre niveau de rigueur. Il en découle une **hétérogénéité des décisions** (un même dossier pourra être contrôlé par l'un et laissé passer par l'autre) qui nuit à la reproductibilité du processus et à son auditabilité. Le caractère manuel des vérifications induit par ailleurs une lenteur de traitement et un coût humain élevé, puisque chaque dossier suspect doit être examiné de façon approfondie et que l'augmentation du nombre de contrôles suppose un accroissement proportionnel des effectifs, ce qui ralentit le règlement global des sinistres.

L'approche montre enfin ses limites dans l'**exploitation des données disponibles**. Les volumes d'informations accumulés au fil du temps sont difficiles à analyser de manière exhaustive sans outils automatisés, ce qui empêche d'identifier les schémas récurrents ou les comportements suspects à grande échelle. Cette difficulté favorise en outre des **biais d'attention** : à force de concentrer les contrôles sur certains profils ou types de sinistres réputés à risque, on délaisse les schémas de fraude moins familiers et l'on reproduit des a priori non fondés.

L'ensemble de ces limites converge vers un même **enjeu de rentabilité**. Le volume de fraudes effectivement détecté reste faible au regard du coût que représente le dispositif humain, et surtout au regard de la fraude réellement présente dans le portefeuille. Le rapport entre les montants recouverts et les ressources mobilisées plafonne, sans qu'il ne soit possible de l'améliorer significativement par les seuls moyens manuels. C'est précisément cette inefficience (un coût élevé pour une couverture limitée) qui motive le recours à une détection automatisée fondée sur l'intelligence artificielle, capable d'analyser l'intégralité des dossiers à un coût marginal réduit et de dépasser ainsi un grand nombre des limites associées aux méthodes manuelles.

2.2 L'apport de l'intelligence artificielle : de nouvelles solutions de détection

2.2.1 Le contexte d'émergence

L'essor des solutions de détection automatisée n'est pas le fruit d'une rupture isolée, mais la convergence de plusieurs évolutions.

La première est l'**explosion du volume de données structurées** disponibles : la dématérialisation de la gestion des sinistres, la standardisation des systèmes d'information, la conservation systématique de l'historique des contrats et des déclarations ont constitué des bases de données riches, exploitables et homogènes, là où l'information était auparavant éparse et largement non numérisée.

La deuxième tient à la **maturité des méthodes d'apprentissage** : les algorithmes de *machine learning*, et en particulier les méthodes d'ensemble sur données tabulaires présentées au chapitre 3, sont désormais éprouvés, accessibles via des bibliothèques robustes et applicables à coût raisonnable.

La troisième relève du contexte économique : la **pression croissante sur les coûts et sur les délais de gestion** pousse les assureurs à rechercher des gains d'efficacité, tandis que la fraude, par son impact direct sur la sinistralité et donc sur la prime, demeure un enjeu financier majeur. La conjonction de ces facteurs (données disponibles, outils matures et nécessité économique) a rendu possible et souhaitable le passage à des dispositifs automatisés.

2.2.2 Les nouvelles approches

Ce passage s'est opéré par étapes. Les premiers dispositifs automatisés reposaient sur des **moteurs de règles** : des conditions explicites, traduisant les signaux d'alerte connus des experts (un sinistre survenant moins d'un an après la souscription, un cumul de sinistres supérieur à tel nombre), déclenchaient une alerte. Reproduisant la connaissance métier, ces systèmes en héritaient aussi les limites : rigides, ils ne détectaient que la fraude déjà identifiée et se révélaient incapables d'appréhender des schémas nouveaux ou la conjonction subtile de plusieurs facteurs.

Les **modèles prédictifs** ont marqué l'évolution suivante : plutôt que d'appliquer des règles figées, ils apprennent à partir de l'historique des dossiers à attribuer à chaque sinistre un **score de risque de fraude**, c'est-à-dire une probabilité estimée à partir de l'ensemble de ses caractéristiques. Cette approche autorise une **détection circonstancielle**, fondée sur les caractéristiques du sinistre et de l'assuré (chronologie, antécédents, cohérence des circonstances déclarées, profil du dossier) et capable de capter automatiquement des interactions que nul ne formaliserait sous forme de règle. Surtout, elle modifie en profondeur la logique de couverture : alors que le contrôle manuel ne portait que sur un échantillon de dossiers, le modèle procède à un **traitement systématique de l'ensemble des dossiers**, chacun se voyant attribuer un score, sans tri préalable.

La modélisation de la fraude automobile par apprentissage statistique a déjà fait l'objet de mémoires d'actuariat (Decourtieux, 2016 [22] ; Barhoumi, 2020 [21]), dont le présent travail se distingue par la conception d'un processus automatisé de bout en bout.

2.2.3 Les bénéfices attendus

Il découle de ces approches plusieurs bénéfices :

- **Une augmentation du volume de fraudes détectées** : en analysant l'intégralité du portefeuille plutôt

qu'une fraction, le dispositif fait remonter des dossiers suspects qui auraient échappé à un contrôle manuel nécessairement sélectif. Cette couverture exhaustive s'accompagne d'une capacité analytique accrue : en exploitant aussi bien les données courantes que les historiques, le modèle détecte des schémas complexes et des corrélations difficilement identifiables par l'humain, améliorant ainsi la détection des fraudes les plus élaborées, souvent caractérisées par des signaux faibles ou dispersés.

- **Une réduction du coût unitaire de détection** : une fois le modèle développé, le *scoring* d'un dossier supplémentaire présente un coût marginal quasi nul, ce qui améliore directement le rapport entre les fraudes détectées et les ressources mobilisées.
- **Une réduction des délais de traitement** : grâce au tri automatique, de grands volumes de sinistres peuvent être analysés quasi instantanément, accélérant ainsi le règlement des dossiers sains tout en orientant sans délai les cas suspects vers l'investigation.
- **Une priorisation objective, homogène et reproductible** : le score fournit un critère unique de hiérarchisation des dossiers, appliqué de manière identique à tous. En substituant des règles et des algorithmes standardisés à l'appréciation individuelle, cette homogénéisation des pratiques garantit une cohérence d'évaluation indépendante des intervenants et réduit le risque de biais subjectifs ou discriminatoires.
- **Une forte capacité de passage à l'échelle** : ces dispositifs absorbent des volumes croissants de données sans accroissement proportionnel des effectifs ni dégradation des performances. L'intervention humaine est ainsi recentrée sur les seuls dossiers présentant le niveau de risque le plus élevé, un atout précieux dans un contexte de croissance et de diversification des flux.

Cette logique constitue le fondement de l'outil développé dans ce mémoire. À chaque nouveau sinistre, l'agent attribue une probabilité de fraude permettant de hiérarchiser les dossiers selon leur niveau de risque. Les équipes d'investigation peuvent ainsi concentrer leurs efforts sur les cas les plus suspects, sans mobiliser inutilement des ressources sur les dossiers présentant une faible probabilité de fraude. Le score ne se substitue pas à la décision humaine : il l'éclaire en transformant un ensemble de déclarations en une file de traitement priorisée.

2.2.4 Les points de vigilance à l'utilisation de l'intelligence artificielle

Ces bénéfices ne sont toutefois pas acquis sans contrepartie, et l'automatisation appelle plusieurs précautions, qui seront approfondies dans le cadre de la gouvernance de l'outil (cf. section 4.1) :

- **La qualité des données** : un modèle n'a de valeur que celle des données sur lesquelles il est entraîné. Des données incomplètes, erronées ou biaisées se traduisent mécaniquement par des prédictions de moindre qualité.
- **L'explicabilité des résultats** : un score de fraude ne saurait être opposé à un assuré sans que les facteurs ayant conduit à son attribution puissent être compris et justifiés. Cette exigence répond à des impératifs à la fois opérationnels, réglementaires et éthiques.
- **Le maintien d'une supervision humaine** : l'agent identifie les dossiers susceptibles de présenter un risque de fraude, mais ne prend pas la décision finale. L'investigation et la décision demeurent du ressort des équipes, ce qui permet d'éviter toute décision défavorable fondée exclusivement sur un traitement automatisé.
- **La surveillance de la performance du modèle** : les comportements frauduleux et les caractéristiques du portefeuille évoluant au fil du temps, les performances d'un modèle peuvent se dégrader en l'absence

d'un suivi continu et d'un réentraînement périodique.

Loin de constituer une solution autosuffisante, l'intelligence artificielle apparaît ainsi comme un outil puissant dont l'efficacité demeure étroitement conditionnée à la qualité des données, à la robustesse de sa gouvernance et au maintien d'un cadre de contrôle rigoureux.

2.3 Comparaison du processus manuel et du processus automatisé

2.3.1 Les critères de comparaison

Comparer l'approche traditionnelle et l'approche automatisée suppose de fixer au préalable les dimensions sur lesquelles porte l'évaluation, afin d'éviter un jugement global et subjectif. Sept critères apparaissent particulièrement structurants :

1. Le **volume de dossiers analysés** mesure la part du portefeuille effectivement soumise à un examen anti-fraude.
2. Le **taux de détection** rapporte les fraudes identifiées à la fraude réellement présente, et traduit l'efficacité du dispositif.
3. Le **coût par dossier** rend compte des ressources consommées pour analyser une déclaration.
4. Le **délai de traitement** conditionne la fluidité du règlement et la qualité de service.
5. L'**homogénéité et la traçabilité des décisions** renvoient à la reproductibilité du processus et à sa capacité à être audité.
6. La **scalabilité** désigne l'aptitude du dispositif à absorber une hausse du volume sans dégradation.
7. Enfin, la **dépendance à l'expertise** caractérise la vulnérabilité du processus à la disponibilité et au niveau de compétence des intervenants.

Ces critères couvrent ainsi les trois enjeux essentiels : l'efficacité de la détection, son coût, et sa robustesse.

2.3.2 Mise en regard des deux processus

La confrontation des deux approches selon ces critères peut être synthétisée comme suit :

Critère	Processus manuel	Processus automatisé (IA)
Volume de dossiers analysés	Partiel : seule une fraction des dossiers est examinée	Exhaustif : l'ensemble des dossiers est scoré
Taux de détection	Limité par la capacité humaine de contrôle	Plus élevé, y compris sur des schémas peu visibles
Coût par dossier	Élevé et croissant avec le volume	Faible coût marginal après développement du modèle
Délai de traitement	Long, tributaire de la charge des équipes	Quasi instantané (<i>scoring</i> automatique)
Homogénéité et traçabilité	Variable, subjective, peu reproductible	Critère unique, appliqué identiquement et traçable
Scalabilité	Faible : suppose d'accroître les effectifs	Élevée : montée en charge à coût quasi constant
Dépendance à l'expertise	Forte : qualité tributaire de chaque intervenant	Réduite à l'usage, déportée vers la conception du modèle

TABLEAU 2.1 – Comparaison du processus manuel et du processus automatisé de détection de la fraude

Cette mise en regard fait clairement ressortir l'avantage de l'automatisation sur les dimensions de volume, de coût, de délai et d'homogénéité. Elle ne doit cependant pas être lue comme la disqualification de l'intervention humaine.

D'une part, l'expertise reste indispensable en amont, pour concevoir, entraîner et valider le modèle, et en aval, pour instruire les dossiers signalés. D'autre part, **le modèle ne produit qu'une probabilité de fraude, c'est-à-dire un soupçon hiérarchisé, et non une preuve : seule l'investigation humaine permet d'établir la réalité de la fraude et d'en tirer les conséquences.**

L'automatisation ne supprime donc pas le travail humain, elle le **réoriente** : libérée du tri d'une masse indifférenciée de dossiers, l'expertise se concentre sur les cas à plus forte valeur ajoutée, ceux que le modèle a identifiés comme les plus à risque.

2.3.3 Vers un modèle hybride

De cette comparaison se dégage non pas une opposition, mais une complémentarité. Les forces de chaque approche répondent précisément aux faiblesses de l'autre : l'IA excelle dans le traitement exhaustif, rapide et homogène de gros volumes, là où l'humain excelle dans l'analyse fine, contextuelle et le jugement sur les cas complexes.

La configuration la plus efficace est dès lors un **modèle hybride**, dans lequel chaque acteur intervient là où il est le plus pertinent. L'IA assure le **filtrage et la priorisation** : elle analyse l'ensemble des dossiers et les classe par niveau de risque. L'humain assure l'**investigation et la décision finale** : il examine les dossiers prioritaires, confirme ou écarte la suspicion, et prononce les suites à donner. Cette articulation préserve la maîtrise humaine du processus tout en démultipliant sa portée.

C'est exactement cette logique hybride que met en œuvre l'Agent développé dans ce mémoire, dont nous présenterons la conception et le fonctionnement après un rapide rappel du cadre théorique sur les algorithmes de détection de fraude utilisés en assurance non-vie.

Chapitre 3

Cadre théorique : les algorithmes de détection de fraude utilisés en assurance non-vie

La détection de la fraude circonstancielle se formule naturellement comme un problème d'apprentissage supervisé binaire. Cette formulation suppose de disposer d'un historique de sinistres dont l'issue (frauduleuse ou licite) a été établie, par exemple à l'issue d'enquêtes passées. On note l'échantillon d'apprentissage :

$$\mathcal{D}_n = \{(x_i, y_i)\}, \quad i = 1, \dots, n, \quad (3.1)$$

Où le vecteur $x_i \in \mathbb{R}^p$ rassemble les p caractéristiques décrivant le sinistre et l'assuré (montant déclaré, ancienneté du contrat, délai entre la souscription et la survenance, antécédents, nature de la garantie, canal de déclaration, etc.), et où la variable cible $y_i \in \{0, 1\}$ vaut 1 lorsque le sinistre est frauduleux. Cette classe d'intérêt est par nature **minoritaire**, ce qui constitue l'une des principales difficultés statistiques du problème et conditionne tant le choix des modèles que celui des métriques d'évaluation. L'objectif commun à toutes les méthodes présentées ci-dessous est d'estimer une **fonction de score** exprimant la probabilité de fraude conditionnelle aux caractéristiques observées :

$$\hat{p}(x) = \hat{P}(Y = 1 \mid X = x) \in [0, 1]. \quad (3.2)$$

Le recours à une sortie continue plutôt qu'à une décision binaire immédiate est un choix structurant. Il permet de hiérarchiser les dossiers selon leur niveau de risque et de ne déclencher une investigation (coûteuse) que sur les cas les plus suspects, le seuil de décision étant calibré séparément selon une logique économique (rapport entre le coût d'une enquête et le gain espéré d'une fraude évitée). Cette logique de score partagée explique également pourquoi l'évaluation des modèles ne peut reposer sur le simple taux de bonnes classifications, trompeur en présence de classes déséquilibrées, mais s'appuie sur des indicateurs tels que la précision, le rappel et l'aire sous la courbe précision-rappel.

Les familles de modèles supervisés présentées dans ce chapitre suivent un fil conducteur unique : l'arbitrage entre **interprétabilité** et **pouvoir prédictif**.

On progresse ainsi de la régression logistique, **modèle paramétrique** parfaitement transparent, vers les méthodes fondées sur les **arbres de décision** (l'arbre CART, puis la **forêt aléatoire** et le **gradient boosting**), dont la capacité à capturer des relations complexes se paie d'une opacité croissante, avant de revenir avec les **modèles de scoring à points** à une représentation directement lisible par les équipes métier. Parmi ces modèles, trois sont mis en œuvre dans l'outil (chapitre 5) : la *scoring* en points, l'arbre de décision et le Gradient *Boosting* ; la régression logistique intervient comme brique du *scoring* en points, et la forêt aléatoire est présentée à titre de comparaison.

À noter que dans un secteur soumis à de fortes exigences d'explicabilité et de gouvernance (notamment de la part de l'ACPR¹), cet arbitrage n'est pas un simple détail technique mais un critère de sélection à part entière.

3.1 La régression logistique (modèle de référence)

La régression logistique constitue la référence historique de la modélisation du risque en actuariat. Il s'agit d'un **modèle linéaire généralisé** (GLM) appartenant à la famille binomiale et doté de la fonction de lien logit. Plutôt que de modéliser directement la probabilité, dont le domaine est borné à l'intervalle $[0, 1]$, le modèle agit sur le logarithme de la cote de fraude (le « *log-odds* »), dont le domaine couvre l'ensemble des réels, et le relie linéairement aux variables explicatives. Ainsi, la probabilité de fraude $p(x)$ s'écrit :

$$\ln \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \sum_{j=1}^p \beta_j x_j \quad (3.3)$$

En inversant cette relation, on retrouve la fonction logistique (ou sigmoïde) qui garantit une probabilité comprise entre 0 et 1. En notant $\eta = \beta_0 + \beta^\top x$ le prédicteur linéaire, la probabilité de fraude s'écrit :

$$p(x) = \frac{1}{1 + e^{-\eta}} \quad (3.4)$$

La forme sigmoïdale a une conséquence importante pour l'interprétation : la relation est linéaire sur l'échelle du logit, mais l'effet d'une variable sur la probabilité n'est pas constant : il est maximal autour de $p = 0,5$ et s'atténue aux extrêmes. Les coefficients β sont estimés par **maximum de vraisemblance**. Contrairement à la régression linéaire, il n'existe pas de solution analytique : la log-vraisemblance, dont l'expression est donnée ci-dessous, est concave et maximisée numériquement par des algorithmes itératifs de type Newton-Raphson (moindres carrés repondérés itérativement) :

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln p(x_i) + (1 - y_i) \ln(1 - p(x_i))] \quad (3.5)$$

L'atout déterminant du modèle réside dans son interprétabilité directe. L'exponentielle d'un coefficient fournit un odds-ratio, c'est-à-dire le facteur par lequel la cote de fraude est multipliée lorsque la variable correspondante augmente d'une unité, toutes choses égales par ailleurs :

$$OR_j = e^{\beta_j} \quad (3.6)$$

Un odds-ratio supérieur à 1 traduit une variable aggravante, un odds-ratio inférieur à 1 une variable atténuante ; cette lecture immédiate facilite la justification des décisions et le dialogue avec les équipes de gestion et les autorités de contrôle.

Lorsque le nombre de variables est élevé ou que celles-ci sont fortement corrélées, on recourt à la **régularisation**, qui ajoute à l'objectif une pénalité sur la norme des coefficients afin de stabiliser l'estimation et de limiter le surapprentissage.

Ainsi on cherche à minimiser :

1. ACPR : Autorité de Contrôle Prudentiel et de Résolution.

$$J(\beta) = -\ell(\beta) + \lambda \cdot \text{Pénalité}(\beta) \quad (3.7)$$

avec $\text{Pénalité}(\beta)$ qui admet différentes variantes :

- La pénalité L1² (Lasso) définie par $\text{Pénalité}(\beta) = \lambda \sum_{j=1}^p |\beta_j|$, qui a la propriété d'annuler certains coefficients, réalisant ainsi une sélection automatique de variables. En effet, si $\beta_j = 0$, la variable j est complètement exclue du modèle ;
- La pénalité L2³ (Ridge) définie par $\text{Pénalité}(\beta) = \lambda \sum_{j=1}^p \beta_j^2$, qui rétrécit les coefficients sans les annuler. Ainsi, toutes les variables restent dans le modèle mais leurs coefficients sont tassés. Ceci est particulièrement utile lorsque les variables sont fortement corrélées entre elles.
- L'elastic net, définie par $\text{Pénalité}(\beta) = \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right]$, avec $\alpha \in [0, 1]$, qui combine les deux termes avec un paramètre qui dose le mélange, pour bénéficier à la fois de la sélection et de la stabilité.

La principale limite du modèle tient à son hypothèse d'**additivité et de linéarité** sur l'échelle du logit : les interactions entre variables et les effets non linéaires ne sont pas captés automatiquement et doivent être spécifiés à la main (termes croisés, discrétisations, transformations). Face à des schémas de fraude où la suspicion naît précisément de la conjonction de plusieurs facteurs, cette contrainte motive le recours à des méthodes plus flexibles.

3.2 La forêt aléatoire

La forêt aléatoire (*random forest*, Breiman, 2001 [25]) appartient à la famille des méthodes d'**agrégation** (ou méthodes ensemblistes), dont le principe est de combiner de nombreux modèles élémentaires pour obtenir un prédicteur plus performant et plus stable qu'aucun d'entre eux pris isolément. L'unité de base est l'**arbre de décision** (CART), qui partitionne récursivement l'espace des variables en régions de plus en plus homogènes au regard de la cible. À chaque nœud, l'algorithme évalue toutes les coupures possibles (une variable et un seuil) et retient celle qui maximise la décroissance d'une mesure d'impureté. Les deux mesures les plus courantes en classification sont l'indice de Gini $G(t)$ et l'entropie de Shannon $H(t)$, calculés sur un nœud t comportant une proportion $\hat{p}_{t,1}$ de sinistres frauduleux :

$$G(t) = 2\hat{p}_{t,1}(1 - \hat{p}_{t,1}) \quad (3.8)$$

$$H(t) = - \sum_k \hat{p}_{t,k} \log_2 \hat{p}_{t,k} \quad (3.9)$$

La construction se poursuit jusqu'à un critère d'arrêt (profondeur maximale, effectif minimal par feuille), et la prédiction associée à une feuille est la fréquence empirique de fraude qu'elle contient. Pris isolément, un arbre profond présente un **biais faible mais une variance élevée** : il s'adapte finement aux données mais une légère perturbation de l'échantillon peut bouleverser sa structure et donc ses prédictions. C'est cette instabilité que la forêt aléatoire vient corriger, au moyen de deux mécanismes complémentaires.

2. La pénalité L1 ajoute la somme des valeurs absolues des coefficients à l'objectif à minimiser.
3. La pénalité L2 ajoute la somme des carrés des coefficients.

Le premier est le **bagging** (*bootstrap aggregating*) : on construit B arbres sur autant d'échantillons obtenus par tirage avec remise dans les données d'origine, puis on moyenne leurs prédictions. La moyenne de prédicteurs de même loi réduit la variance sans augmenter le biais, d'autant plus efficacement que ces prédicteurs sont peu corrélés : pour B prédicteurs de variance σ^2 et de corrélation deux à deux ρ , la variance de leur moyenne vaut $\rho \sigma^2 + \frac{1-\rho}{B} \sigma^2$.

Le second mécanisme vise précisément à **décorrél**er les arbres : à chaque nœud, l'algorithme ne considère qu'un sous-ensemble aléatoire de $m \leq p$ variables candidates (typiquement $m = \sqrt{p}$ en classification), renouvelé à chaque division. Cette restriction empêche les quelques variables les plus prédictives de structurer tous les arbres de façon identique, ce qui diversifie l'ensemble et amplifie la réduction de variance. Le score final est la moyenne des B arbres T_b :

$$\hat{p}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_{T_b}(x) \quad (3.10)$$

Avec $\hat{p}_{T_b}(x)$ la prédiction de l'arbre numéro b pour un individu x .

Le tirage *bootstrap* offre en outre un mécanisme d'évaluation interne quasiment gratuit : chaque observation étant en moyenne absente d'environ 37 % des échantillons, elle peut être prédite par les seuls arbres qui ne l'ont pas vue, fournissant une estimation peu biaisée de l'erreur de généralisation (erreur *out-of-bag*). Cet avantage est précieux en détection de fraude, où les cas étiquetés sont rares et où l'on souhaite préserver un maximum d'observations pour l'apprentissage. Bien que moins transparente que la régression logistique, la forêt n'est pas une pure boîte noire : elle fournit des **mesures d'importance des variables** (décroissance moyenne d'impureté, importance par permutation) qui restituent une part d'interprétabilité utile à la gouvernance du dispositif.

Les propriétés de la forêt aléatoire en font un candidat particulièrement adapté à notre problème : elle capture automatiquement non-linéarités et interactions, tolère des variables hétérogènes, corrélées ou aberrantes, ne requiert qu'un prétraitement limité, et gère le déséquilibre des classes via une pondération ou un rééquilibrage des tirages (*balanced random forest*). Elle se règle au moyen de quelques hyperparamètres principaux, notamment le nombre d'arbres, le nombre de variables candidates par nœud et la complexité des arbres, et échange une part de l'interprétabilité paramétrique du GLM contre un gain substantiel de pouvoir prédictif.

3.3 Le Gradient Boosting

Le **Gradient Boosting** [26] est, comme la forêt aléatoire, une méthode ensembliste fondée sur des arbres, mais il en diffère radicalement par sa logique de construction. Là où le *bagging* assemble des arbres **en parallèle** pour réduire la variance, le Gradient *Boosting* les construit **séquentiellement**, chaque nouvel arbre s'attachant à corriger les erreurs résiduelles de l'ensemble déjà constitué ; il vise donc avant tout à réduire le biais. Le modèle final est une somme pondérée de M arbres h_m :

$$F_M(x) = \sum_{m=1}^M \nu h_m(x) \quad (3.11)$$

Cette somme se construit de façon récursive : partant d'un modèle initial constant, on enrichit à chaque étape le modèle courant d'un nouvel arbre pondéré par le taux d'apprentissage $\nu \in (0, 1]$:

$$F_m(x) = F_{m-1}(x) + \nu h_m(x) \quad (3.12)$$

La clé de la méthode est l'interprétation de cette correction comme une **descente de gradient dans l'espace des fonctions**. À chaque étape, on calcule les **pseudo-résidus** r_{im} , définis comme l'opposé du gradient de la fonction de perte L évalué aux prédictions courantes, puis on ajuste un arbre pour les approcher :

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}} \quad (3.13)$$

Le taux d'apprentissage ν joue un rôle de régularisation essentiel : une valeur faible ralentit l'apprentissage et améliore la généralisation, au prix d'un plus grand nombre d'arbres. On combine fréquemment ce « *shrinkage* » avec un sous-échantillonnage aléatoire des observations et des variables à chaque étape (*stochastic gradient boosting*), ce qui réduit encore le surapprentissage. Les implémentations modernes ajoutent par ailleurs à la fonction de perte un terme de régularisation Ω pénalisant explicitement la complexité des arbres (nombre de feuilles, norme des poids), de sorte que l'objectif minimisé s'écrit :

$$L(F) = \sum_{i=1}^n L(y_i, F(x_i)) + \sum_{m=1}^M \Omega(h_m) \quad (3.14)$$

Les bibliothèques de référence (XGBoost [27], LightGBM, CatBoost ⁴) mettent en œuvre ces principes avec des optimisations algorithmiques (construction par histogrammes, croissance des arbres par feuille, traitement natif des variables catégorielles) qui les rendent rapides et très performantes.

Le Gradient *Boosting* atteint généralement le meilleur pouvoir prédictif parmi les modèles considérés sur des données tabulaires telles que celles de la détection de fraude. En contrepartie, il est plus sensible au réglage des hyperparamètres et au surapprentissage : le nombre d'arbres doit être contrôlé par un arrêt précoce sur un jeu de validation, et son interprétabilité est moindre que celle de la forêt, ce qui conduit à s'appuyer sur des outils d'explication post-hoc (importance des variables, valeurs de Shapley [29] ⁵) pour en restituer la logique.

3.4 Les modèles de scoring à points

Hérités de la pratique du *credit scoring*, les modèles de *scoring* à points (ou *scorecards*) ne constituent pas tant une nouvelle famille d'algorithmes qu'une méthode de mise en forme d'un modèle statistique (le plus souvent une régression logistique) en une grille de points additive, lisible et directement exploitable par un gestionnaire, sans recours à un outil informatique. Leur intérêt est avant tout opérationnel et réglementaire : dans un contexte assurantiel soumis à un devoir d'explication, pouvoir justifier un score par la simple addition de points attachés aux caractéristiques d'un dossier constitue un atout majeur.

La construction débute par une discrétisation de chaque variable en classes, définies de manière à être suffisamment peuplées et, idéalement, à présenter un risque monotone. Cette étape capture les non-linéarités propres à chaque variable et réduit la sensibilité aux valeurs extrêmes. Chaque classe se voit ensuite attribuer un poids de la preuve (*Weight of Evidence*, WOE), qui mesure son pouvoir discriminant en comparant la répartition des dossiers licites et frauduleux :

4. XGBoost, LightGBM et CatBoost sont des bibliothèques *open source* d'implémentation du gradient *boosting*, principalement utilisées en Python.

5. La valeur de Shapley de la variable j pour un individu x mesure sa contribution marginale moyenne à la prédiction en moyennant sur toutes les coalitions possibles de variables.

$$\text{WOE}_i = \ln \left(\frac{\% \text{ fraude}_i}{\% \text{ non-fraude}_i} \right) \quad (3.15)$$

Le pouvoir prédictif global d'une variable peut alors être quantifié par sa valeur informative (*Information Value*, *IV*), qui agrège les WOE de ses classes pondérées par l'écart de répartition, et sert à sélectionner et hiérarchiser les variables :

$$IV = \sum_i (\% \text{ fraude}_i - \% \text{ non-fraude}_i) \times \text{WOE}_i \quad (3.16)$$

Une régression logistique est ensuite ajustée sur les variables transformées en WOE. Ses coefficients sont enfin convertis en points entiers au moyen d'une transformation affine, calée par deux paramètres : le facteur et l'offset, déterminés à partir d'un score de référence, d'une cote de référence et du nombre de points doublant la cote (*PDO*, *Points to Double the Odds*) :

$$\text{facteur} = \frac{PDO}{\ln 2} \quad (3.17)$$

$$\text{offset} = \text{Score}_0 - \text{facteur} \times \ln(\text{Odds}_0) \quad (3.18)$$

Les points attribués à une classe de la variable j combinent le coefficient estimé, le WOE de la classe, l'ordonnée à l'origine α répartie sur les p variables, et les paramètres de calage :

$$\text{Points}_j = \left(\beta_j \times \text{WOE}_j + \frac{\alpha}{p} \right) \times \text{facteur} + \frac{\text{offset}}{p} \quad (3.19)$$

Le score d'un dossier est alors la simple somme des points de chacune de ses caractéristiques :

$$\text{Score} = \sum_{j=1}^p \text{Points}_j \quad (3.20)$$

Ce dispositif présente une transparence et une auditabilité maximales : chaque point du score est traçable jusqu'à une caractéristique précise du dossier, ce qui satisfait directement les exigences d'explicabilité et facilite le suivi de la stabilité du modèle dans le temps (via des indicateurs de dérive des populations).

En contrepartie, la discrétisation et la dépendance à une structure logistique entraînent une **perte de finesse prédictive** par rapport au Gradient *Boosting*, et la définition des classes demande un travail manuel non négligeable. Le *scoring* à points occupe ainsi une position singulière dans notre panorama : il referme la boucle ouverte par la régression logistique en réconciliant la performance statistique avec une lisibilité opérationnelle.

On peut d'ailleurs envisager une articulation des deux logiques : un modèle puissant de type Gradient *Boosting* pour la détection, doublé d'une grille de points pour l'explication et la communication des décisions aux gestionnaires et aux assurés.

3.5 Apprentissage non supervisé : détection d'anomalies et comportements atypiques

Si l'apprentissage supervisé excelle dans l'identification de schémas de fraude historiquement connus, il présente une limite structurelle majeure : **il est vulnérable aux techniques de fraude émergentes** (*zero-day frauds*). En effet, un algorithme supervisé ne peut prédire que ce qu'il a déjà vu.

Pour pallier cette faille, les assureurs déploient en complément des algorithmes d'apprentissage non supervisé (*Unsupervised Learning*). Dans ce paradigme, la variable cible Y (le label « fraude » ou « non-fraude ») est ignorée ou indisponible. L'algorithme explore uniquement l'espace des variables explicatives X pour identifier des structures sous-jacentes ou des déviations statistiques. La fraude est alors assimilée à une anomalie, c'est-à-dire une observation qui dévie si significativement des autres qu'elle éveille le soupçon d'avoir été générée par un mécanisme différent.

Deux grandes familles de méthodes se distinguent pour ce type d'analyse : les algorithmes d'isolation et le partitionnement des données.

3.5.1 Les algorithmes d'isolation (Exemple : Isolation Forest)

Contrairement aux approches statistiques classiques qui cherchent d'abord à modéliser le comportement « normal » pour ensuite en déduire les anomalies, l'*Isolation Forest* [28] cherche directement à isoler les anomalies. Ce modèle repose sur un postulat simple : les anomalies sont des données « peu nombreuses et différentes » (*few and different*).

L'algorithme construit une forêt d'arbres (les *Isolation Trees*). Pour chaque arbre, il sélectionne aléatoirement une variable et un seuil de coupure aléatoire (compris entre le minimum et le maximum de cette variable) pour partitionner l'espace récursivement.

Mathématiquement, la métrique clé est la longueur du chemin $h(x)$, c'est-à-dire le nombre d'arêtes qu'une observation x doit parcourir depuis la racine de l'arbre jusqu'à atteindre une feuille terminale où elle est isolée. Parce qu'elles sont situées dans des zones clairsemées de l'espace vectoriel, les anomalies nécessitent beaucoup moins de coupures pour être isolées que les observations normales.

Le score d'anomalie $s(x, n)$ pour un jeu de n données est défini par :

$$s(x, n) = 2^{-\frac{\mathbb{E}(h(x))}{c(n)}} \quad (3.21)$$

Où $\mathbb{E}(h(x))$ est l'espérance de la longueur du chemin sur l'ensemble des arbres, et $c(n)$ est une constante de normalisation représentant la longueur moyenne non réussie d'une recherche dans un arbre binaire.

Si $s(x, n)$ tend vers 1, le sinistre est fortement suspect et justifie une levée de doute par un expert. Si le score tend vers 0,5, le sinistre est considéré comme non frauduleux.

3.5.2 Le partitionnement de données (Clustering)

Les algorithmes de *Clustering* (tels que les K-Means) visent à regrouper les sinistres en sous-ensembles (les *clusters*) de telle sorte que les dossiers d'un même groupe soient les plus similaires possibles, tout en étant distincts des autres groupes.

Dans le cas de l'algorithme K-Means, l'objectif est de minimiser la variance intra-classe (la distance au carré entre chaque sinistre x_i et le centre de gravité μ_j de son *cluster* de rattachement) :

$$J = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - \mu_j\|^2 \quad (3.22)$$

Appliqué à la lutte anti-fraude, le *clustering* permet d'identifier des sinistres qui ne s'intègrent dans aucun des *clusters* principaux (les dossiers de masse), ou qui forment de très petits groupes (*micro-clusters*) très éloignés des autres. Ces poches de données marginales signalent souvent des comportements atypiques, comme des réseaux organisés déclarant des sinistres aux caractéristiques étrangement similaires.

3.6 Analyse de réseaux (Graph Mining) pour la détection de la fraude organisée

Contrairement à la fraude opportuniste (un assuré isolé qui majore ponctuellement un devis), la fraude en bande organisée implique une complicité entre plusieurs acteurs coordonnés dans le but de soutirer des capitaux importants à la compagnie d'assurance de manière répétée.

Ce type de criminalité financière s'appuie sur des réseaux structurés incluant de faux assurés, des prête-noms, et bien souvent des professionnels complices (garagistes, sociétés de dépannage, professionnels de santé ou experts automobiles marrons). Leurs modes opératoires sont quasi industriels : accidents de la circulation mis en scène, carambolages fictifs en chaîne, ou recyclage de véhicules gravement endommagés.

La dangerosité extrême de ces réseaux réside dans leur capacité à « lisser » le risque : pris isolément, chaque sinistre déclaré par le réseau est conçu pour paraître parfaitement vraisemblable et passer sous les radars des règles de gestion classiques. Les algorithmes de *machine learning* vus précédemment montrent ici leurs limites, car ils analysent chaque dossier de manière individuelle. C'est précisément pour contourner ce camouflage qu'il devient impératif de ne plus regarder les sinistres, mais les liens cachés qui les unissent, grâce à la théorie des graphes (*Graph Mining*).

3.6.1 Modélisation mathématique du réseau de fraude

Dans cette approche, le portefeuille de sinistres n'est plus vu comme un simple tableau (lignes/colonnes), mais est modélisé sous la forme d'un graphe mathématique $G = (V, E)$.

- **Les Nœuds (Vertices : V)** : ils représentent les entités du système. Il peut s'agir d'un dossier de sinistre, d'un assuré, d'un numéro de téléphone, d'une adresse IP ou d'un professionnel de l'automobile.
- **Les arêtes (Edges : E)** : elles matérialisent une relation entre deux nœuds. Une arête est créée si deux sinistres partagent un attribut commun (ex : même garagiste, même compte bancaire pour l'indemnisation) ou s'ils présentent une similarité vectorielle anormalement élevée (ce qui trahit souvent la réutilisation d'un même scénario de fraude).

On peut mesurer la similarité entre deux dossiers A et B dans l'espace des variables via la similarité cosinus :

$$\text{Similarité}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} \quad (3.23)$$

Si cette similarité dépasse un seuil critique défini par l'actuaire, une arête est tracée entre les deux dossiers.

3.6.2 Détection de communautés et de clusters suspects

Une fois le graphe construit, l'objectif n'est plus d'évaluer la probabilité de fraude d'un nœud individuel, mais d'identifier des sous-graphes anormalement denses. En théorie des graphes, on appelle cela la détection de communautés ou de composantes connexes.

Des algorithmes comme la méthode de Louvain [30] ou la propagation de labels (*Label Propagation*)⁶ sont utilisés pour partitionner le graphe. Ils cherchent à maximiser la modularité Q , c'est-à-dire la densité des liens à l'intérieur d'un *cluster* par rapport à la densité des liens à l'extérieur :

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j) \quad (3.24)$$

Où A_{ij} est la matrice d'adjacence, k_i est le degré du nœud i , m le nombre total d'arêtes, et $\delta(c_i, c_j)$ indique si les nœuds appartiennent à la même communauté c .

3.6.3 Application opérationnelle

Sur le plan opérationnel, lorsqu'un algorithme de *Graph Mining* isole un *cluster* suspect, il fournit une alerte d'une valeur ajoutée qualitativement différente de celle produite par les modèles de *scoring* individuels classiques. L'investigation ne porte plus sur un sinistre isolé de 2 000 €, mais sur un réseau organisé dont le préjudice global potentiel se chiffre en plusieurs dizaines, voire centaines de milliers d'euros. Cette bascule d'échelle transforme profondément la logique d'allocation des ressources au sein des cellules anti-fraude.

Concrètement, le *cluster* fourni par l'algorithme se matérialise sous la forme d'un graphe annoté restituant l'ensemble des entités impliquées (assurés, prestataires, intermédiaires) ainsi que la nature et la fréquence de leurs interactions. L'enquêteur dispose ainsi d'une cartographie complète du réseau présumé, lui permettant d'identifier le nœud central (souvent le coordinateur du schéma frauduleux) et de hiérarchiser ses investigations en remontant des ramifications périphériques vers le cœur du dispositif. Cette approche contraste avec l'instruction traditionnelle dossier par dossier, où les connexions entre sinistres restent invisibles faute d'une vision transversale.

Du point de vue du pilotage, le démantèlement d'un tel réseau offre un retour sur investissement massif pour la compagnie d'assurance. Là où l'instruction d'un dossier individuel mobilise plusieurs heures d'analyse pour un enjeu financier limité, une seule investigation réseau peut aboutir à la neutralisation simultanée de plusieurs dizaines de dossiers frauduleux, à des résiliations en cascade et, le cas échéant, à des dépôts de plainte groupés susceptibles d'aboutir à des condamnations pénales. Ces dernières constituent un signal dissuasif fort, dont l'effet préventif sur les comportements frauduleux dépasse largement le périmètre du réseau démantelé.

Enfin, les sorties du *Graph Mining* s'intègrent naturellement aux processus de *reporting* réglementaire. Les *clusters* détectés, documentés et tracés, alimentent les déclarations de soupçon transmises à Tracfin⁷ et renforcent la robustesse du dispositif LCB-FT⁸ de la compagnie, démontrant aux autorités de contrôle, notamment à

6. Ces algorithmes ne sont volontairement pas détaillés ici car ils ne seront pas utilisés dans le mémoire. Ils sont présentés de manière informative.

7. Tracfin (Traitement du renseignement et action contre les circuits financiers clandestins) est une cellule de renseignement financier placée sous la tutelle du ministère de l'Économie et des Finances. Créée en 1990, elle est chargée de recueillir, analyser et transmettre aux autorités judiciaires les déclarations de soupçon émises par les professionnels assujettis (dont les organismes d'assurance) lorsque ceux-ci détectent des opérations susceptibles de relever du blanchiment de capitaux ou du financement du terrorisme.

8. La LCB-FT (Lutte contre le blanchiment de capitaux et le financement du terrorisme) désigne l'ensemble du dispositif réglementaire et opérationnel imposé aux acteurs du secteur financier et assurantiel pour prévenir, détecter et signaler ces infractions. En France, ce dispositif est principalement encadré par le Code monétaire et financier (articles L. 561-1 et suivants), transposant les directives européennes anti-blanchiment successives (la cinquième directive AML datant de 2018, la sixième de 2020). Les compagnies d'assurance y sont assujetties en tant qu'entités déclarantes et sont placées à ce titre sous le contrôle de l'Autorité de

l'ACPR, que la lutte contre la fraude organisée repose sur des méthodes quantitatives structurées et auditables.

3.7 Critères de qualité des modèles mis en place

La première mesure naturelle de la qualité d'un modèle de détection de fraude est le **taux de bien classés** (ou *accuracy*), défini comme la proportion d'individus correctement classés parmi l'ensemble de la population soumise au modèle. Il se calcule directement à partir de la matrice de confusion, qui croise les prédictions du modèle avec les statuts réels observés selon quatre configurations possibles.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.25)$$

Un dossier est dit :

- **Vrai positif (TP)** lorsque le modèle prédit une fraude et que le dossier est effectivement frauduleux ;
- **Vrai négatif (TN)** lorsque le modèle prédit un dossier sain et que celui-ci l'est bien ;
- **Faux positif (FP)** lorsqu'un dossier sain est incorrectement signalé comme frauduleux (génération d'un coût opérationnel inutile et une dégradation de l'expérience client) ;
- **Faux négatif (FN)** lorsqu'un dossier frauduleux n'est pas détecté, constituant la perte financière directe pour la compagnie.

		Statut réel	
		Fraude réelle	Non-fraude réelle
Prédiction du modèle	Fraude prédite	Vrai Positif (TP) Fraude détectée ✓	Faux Positif (FP) Fausse alerte ✗
	Non-fraude prédite	Faux Négatif (FN) Fraude non détectée ✗	Vrai Négatif (TN) Sain classé sain ✓

FIGURE 3.1 – Matrice de confusion

Toutefois, si le taux de bien classés présente l'avantage d'une lecture immédiate, il s'avère trompeur dans le contexte de la détection de fraude, où les classes sont structurellement déséquilibrées : la fraude ne représente qu'une faible part des dossiers (de l'ordre de 5 % des sinistres automobiles en France, 11,5 % dans la base étudiée).

Un modèle naïf prédisant systématiquement « non-fraude » atteindrait mécaniquement un taux de bien classés de l'ordre de 95 % (88,5 % sur notre base), sans détecter la moindre fraude.

Cette limite justifie le recours à des critères complémentaires mieux adaptés aux distributions asymétriques, notamment des indicateurs capables de mesurer la capacité du modèle à ordonner les dossiers par risque (indépendamment de tout seuil), et d'autres la qualité d'une décision prise à un seuil déterminé.

Ainsi, on distingue :

- **Le coefficient de Gini et la courbe ROC** : ce coefficient mesure le pouvoir discriminant global du score, c'est-à-dire son aptitude à classer les sinistres frauduleux devant les sinistres licites. Cette capacité est mesurée sur l'ensemble de la plage de seuil possible, en s'appuyant sur la courbe ROC (*Receiver Operating Characteristic*). Cette courbe est construite en faisant varier le seuil de décision de 0 à 1 en reportant pour chaque valeur, le taux de vrais positifs (TVP, ou rappel) en ordonnée contre le taux de faux positifs (TFP) en abscisse :

$$\text{TVP} = \frac{TP}{TP + FN}, \quad \text{TFP} = \frac{FP}{FP + TN} \quad (3.26)$$

Un modèle parfait atteint le point (0,1) (aucun faux positif, tous les fraudeurs détectés) tandis qu'un modèle aléatoire suit la diagonale principale. L'aire sous la courbe ROC, notée AUC (*Area Under the Curve*), synthétise cette performance en un scalaire entre 0,5 (aléatoire) et 1 (parfait). Le coefficient de Gini est directement relié à l'AUC par la relation : $Gini = 2 \times AUC - 1$ et varie de 0 (discrimination nulle, équivalente au hasard) à 1 (discrimination parfaite).

À titre indicatif, un Gini inférieur à 0,3 traduit un pouvoir discriminant faible, une valeur de 0,3 à 0,5 est acceptable, au-delà de 0,5 le modèle est jugé bon et au-delà de 0,6 très performant : ces bornes restant des conventions de *scoring* à adapter au contexte. Dans notre exemple d'application, un Gini supérieur à 0,5 est généralement considéré comme satisfaisant, compte tenu du fort déséquilibre des classes et de la rareté du signal frauduleux.

- **La statistique de Kolmogorov-Smirnov (KS)** : elle mesure l'écart maximal entre les fonctions de répartition cumulées des scores des deux populations (frauduleux et licites). De façon équivalente, elle correspond au plus grand écart entre le taux de vrais positifs et le taux de faux positifs le long de la courbe ROC : $KS = \max_s (TVP(s) - TFP(s))$. Comprise entre 0 et 1, elle indique en outre le seuil de score où la séparation entre les deux classes est la plus nette. En pratique, une valeur supérieure à 0,3 est généralement considérée comme acceptable et au-delà de 0,4 comme satisfaisante.
- **L'aire sous la courbe précision-rappel (PR-AUC)** : elle est particulièrement adaptée aux classes déséquilibrées, car elle se concentre sur la classe d'intérêt (la fraude) sans être flattée par l'abondance des vrais négatifs, contrairement à l'AUC-ROC qui peut donner une image trop optimiste. Son interprétation est relative : la valeur de référence (modèle aléatoire) n'est pas 0,5 mais la prévalence de la fraude π , de sorte qu'une PR-AUC doit toujours être appréciée au regard de ce taux de base.
- **Le $F1$ -score** : il évalue une décision à un seuil fixé. Il s'agit de la moyenne harmonique de la précision $P = \frac{VP}{VP + FP}$ et du rappel $R = \frac{VP}{VP + FN}$, soit $F1 = \frac{2PR}{P + R}$. Il offre un compromis entre les faux positifs (investigations menées à tort) et les faux négatifs (fraudes manquées). Comme il dépend du seuil retenu, on peut lui préférer une variante F_β pondérant davantage le rappel lorsque le coût d'une fraude non détectée est jugé supérieur à celui d'une enquête inutile.
- **Le *lift* au décile supérieur (*lift@10 %*)** : il s'agit d'un indicateur opérationnel directement aligné sur la logique de priorisation de l'outil. Après avoir classé tous les dossiers par score décroissant, il rapporte le taux de fraude observé dans les 10 % les plus suspects au taux de fraude global :

$$lift@10\% = \frac{\text{taux de fraude dans le décile supérieur}}{\text{taux de fraude global}} \quad (3.27)$$

Un *lift* de 5 signifie que le décile ciblé concentre cinq fois plus de fraudes qu'une sélection aléatoire. Cet indicateur traduit concrètement le gain d'efficacité offert aux équipes d'investigation et se relie naturellement à l'arbitrage coût-bénéfice du dispositif.

De plus, on s'intéressera également à l'**indice de stabilité des populations** (PSI, *Population Stability Index*). Ce dernier ne mesure pas le pouvoir prédictif du modèle mais la stabilité de la population dans le temps. Il quantifie l'écart entre la distribution des scores observée sur une population de référence (typiquement l'échantillon d'apprentissage) et celle observée sur une population récente, afin de détecter une dérive susceptible de dégrader la pertinence du modèle. Après avoir réparti les scores en classes (souvent les déciles de la population de référence), il se calcule comme la somme sur les classes des écarts de proportions pondérés par le logarithme de leur rapport :

$$PSI = \sum_i (a_i - r_i) \ln \left(\frac{a_i}{r_i} \right), \quad (3.28)$$

Où r_i et a_i désignent respectivement la proportion d'observations de la classe i dans la population de référence et dans la population actuelle. Par convention, un PSI inférieur à 0,1 traduit une population stable, une valeur comprise entre 0,1 et 0,25 signale une dérive modérée appelant une surveillance, et une valeur supérieure à 0,25 indique une dérive importante justifiant une investigation, voire un réentraînement du modèle. Le PSI peut s'appliquer à la distribution du score global comme à celle de chaque variable explicative, ce qui permet d'identifier l'origine d'une dérive. Il constitue ainsi un outil clé du suivi opérationnel de l'agent une fois déployé.

En synthèse, l'évaluation d'un modèle actuariel de détection de fraude articule cinq dimensions complémentaires : le **pouvoir discriminant** (Gini, KS, PR-AUC), la **qualité d'une décision seuillée** (F1, matrice de confusion), la **valeur économique** (coût espéré, ROI, *lift* financier), la **stabilité temporelle** (PSI) et l'**équité entre segments**. Aucun de ces indicateurs pris isolément n'épuise le jugement à porter sur l'agent ; c'est leur lecture conjointe, adossée à une matrice de coûts explicite et à un cadre de gouvernance clair, qui fonde la légitimité actuarielle du dispositif.

ANCRAGE RÉGLEMENTAIRE

Le dispositif d'évaluation retenu s'inscrit dans les orientations du document de réflexion publié par l'ACPR en juin 2020 sur la gouvernance des algorithmes d'intelligence artificielle dans le secteur financier⁹, qui insiste sur la nécessité d'un cadre de suivi de la performance, de la stabilité et de l'explicabilité tout au long du cycle de vie du modèle. Le règlement européen sur l'intelligence artificielle classe par ailleurs parmi les systèmes à haut risque ceux destinés à l'évaluation des risques et à la tarification en assurance vie et santé, soumis à une documentation technique détaillée, à une surveillance humaine et à une évaluation continue ; sans relever nécessairement de cette catégorie, un outil de détection de fraude automobile gagne à anticiper ces exigences, que la batterie d'indicateurs présentée ci-dessus contribue à satisfaire (cf. section 4.1).

9. https://acpr.banque-france.fr/system/files/2025-02/20200612_gouvernance_evaluation_ia.pdf

Chapitre 4

Mise en place d'un processus de détection de fraude automobile automatisé à l'aide d'un Agent IA

4.1 Gouvernance autour de la mise en place de l'Agent IA

Avant même d'aborder la conception technique de l'outil, la mise en place d'un agent de détection de fraude doit être encadrée par une gouvernance explicite. Un tel dispositif traite en effet des données personnelles d'assurés, alimente des décisions susceptibles d'affecter individuellement ces derniers (orientation d'un dossier vers une enquête, suspicion portée sur une déclaration), et s'inscrit dans un secteur étroitement supervisé.

La gouvernance n'est donc pas un complément formel postérieur au modèle, mais un préalable structurant qui en définit le cahier des charges. On peut l'articuler autour de trois niveaux complémentaires :

- Un cadre réglementaire et de conformité,
- Une organisation interne et une répartition des responsabilités,
- Et enfin une maîtrise opérationnelle du cycle de vie du modèle assortie d'une supervision humaine.

Sur le plan réglementaire, le dispositif s'inscrit d'abord dans le cadre du Règlement Général sur la Protection des Données (RGPD).

Les principes de finalité, de minimisation et de légalité du traitement encadrent la collecte et l'usage des données du sinistre et de l'assuré, tandis que **l'article 22**¹, relatif aux décisions individuelles fondées exclusivement sur un traitement automatisé, impose une vigilance particulière : un assuré ne saurait voir sa déclaration rejetée sur la seule base d'un score algorithmique, sans intervention humaine ni possibilité de contestation.

À ce socle s'ajoute désormais le **règlement européen sur l'intelligence artificielle (« AI Act »)**. Le règlement (UE) 2024/1689 est entré en vigueur le 1^{er} août 2024 selon une application échelonnée, les pratiques interdites étant effectives depuis le 2 février 2025. Son annexe III classe parmi les **systèmes à haut risque** ceux relevant de l'accès aux services essentiels, dont l'assurance. Avec le règlement « Omnibus IA », proposé le 19 novembre 2025 dans le cadre du paquet « Omnibus numérique » et entré en vigueur le 27 juillet 2026, l'application des obligations relatives aux systèmes à haut risque de l'annexe III a toutefois été reportée au 2 décembre 2027².

1. « La personne concernée a le droit de ne pas faire l'objet d'une décision fondée exclusivement sur un traitement automatisé, y compris le profilage, produisant des effets juridiques la concernant ou l'affectant de manière significative de façon similaire. » (§1, <https://gdpr-text.com/fr/read/article-22/>).

2. Commission européenne, « L'Omnibus de l'IA entre en vigueur », 27 juillet 2026, <https://digital-strategy.ec.europa.eu/fr/news/ai-omnibus-enters-force>.

La qualification précise d'un agent de détection de fraude automobile reste à apprécier au cas par cas : la catégorie à haut risque vise surtout l'évaluation du risque et la tarification, de sorte qu'un outil qui se borne à signaler des dossiers à des enquêteurs humains se situe vraisemblablement à un niveau de risque inférieur.

La prudence conduit néanmoins à anticiper les exigences applicables aux systèmes sensibles : un système de gestion des risques documenté, une gouvernance des données garantissant leur qualité et l'absence de biais discriminatoires, une documentation technique complète, la journalisation des activités assurant la traçabilité, des obligations de transparence, une supervision humaine et un niveau adéquat de précision, de robustesse et de cybersécurité.

Pour certains déployeurs de services essentiels privés, une analyse d'impact sur les droits fondamentaux (FRIA ³, *Fundamental Rights Impact Assessment*) peut par ailleurs être requise, distincte de l'analyse d'impact relative à la protection des données. Enfin, l'agent évolue dans l'environnement particulier de la lutte contre la fraude à l'assurance, qui mobilise des dispositifs sectoriels propres (échanges de place, conventions professionnelles) et impose le respect du secret et des droits de la personne concernée.

Au-delà du cadre légal, la gouvernance doit intégrer les attentes du superviseur national.

Dès juin 2020, l'ACPR a publié un document de réflexion sur la gouvernance des algorithmes d'intelligence artificielle dans le secteur financier, fruit de travaux exploratoires menés depuis 2018 avec des acteurs du secteur, et portant notamment sur l'explicabilité et la gouvernance du *machine learning*.

Ces travaux ont dégagé quatre critères interdépendants d'évaluation des algorithmes : la gestion appropriée des données, la performance, la stabilité et l'explicabilité. Un arbitrage est nécessaire entre ces quatre critères, ainsi qu'un principe de validation continue. L'explicabilité y est érigée en pilier et déclinée selon plusieurs niveaux, selon que l'on s'adresse à la clientèle, à des experts métier ou à des auditeurs.

Ces orientations fixent un horizon clair : **l'agent devra être non seulement performant, mais aussi auditable et explicable à différents publics, ce qui justifie a posteriori l'attention portée à l'interprétabilité des modèles dans la partie théorique** ⁴.

Ce cadre externe se traduit en interne par une organisation et une répartition des rôles formalisées. La conduite du projet gagne à être pilotée par une instance de gouvernance réunissant les parties prenantes : les équipes métier de la gestion des sinistres et de la lutte anti-fraude, qui portent le besoin et la connaissance du terrain ; les *data scientists* et actuaires, responsables de la conception et de la validation statistique ; la fonction conformité et juridique ainsi que le délégué à la protection des données, garants du respect du cadre réglementaire ; et le contrôle interne ou l'audit, chargés d'une revue indépendante.

Cette organisation s'inscrit naturellement dans une politique de gestion du risque de modèle, qui définit les responsabilités, les exigences de documentation et les seuils de validation tout au long de la vie de l'agent.

La maîtrise opérationnelle porte enfin sur l'ensemble du cycle de vie du modèle : chaque étape (cadrage des données, entraînement, validation indépendante, recette, déploiement puis surveillance) doit être documentée et tracée, de manière à pouvoir reconstituer a posteriori les choix effectués. Une attention spécifique est accordée à la détection et à la remédiation des biais, afin que le modèle ne reproduise pas de discriminations, directes ou indirectes via des variables corrélées à des caractéristiques protégées.

Mais surtout, le principe de supervision humaine structure l'ensemble du dispositif : l'agent produit un score ou une alerte, mais ne prononce aucune décision défavorable de façon automatique ; l'investigation et la décision finale demeurent du ressort d'un gestionnaire ou d'un enquêteur.

³. Évaluation structurée, réalisée avant le déploiement, imposée par l'article 27 de l'AI Act à certains déployeurs de systèmes d'IA à haut risque.

⁴. https://acpr.banque-france.fr/system/files/2025-02/20200612_gouvernance_evaluation_ia.pdf

Ce maintien d'un « humain dans la boucle » répond à l'exigence de l'article 22 du RGPD, préserve les droits de l'assuré et circonscrit le risque réglementaire, tout en organisant une boucle de rétroaction : les retours des enquêteurs alimentant le suivi de la performance, la détection de la dérive du modèle dans le temps et son réentraînement encadré.

Posée en amont, cette gouvernance conditionne la confiance, la conformité et la pérennité du dispositif. Elle constitue le cadre dans lequel s'inscrit la conception de l'outil, présentée dans les sections suivantes.




FIGURE 4.1 – Les trois niveaux de gouvernance encadrant la mise en place de l'agent IA de détection de fraude

4.2 Présentation de la base de données

4.2.1 Base de données source

L'illustration de la mise en place du processus de détection de fraude automobile réalisée dans ce mémoire se fera à l'aide d'une base de données récupérée en *open source* sous :

<https://www.kaggle.com/datasets/ahluwaliasaksham/car-insurance-fraud-detection-dataset> [23]

Cette base de données concerne des sinistres automobiles, et contient le flag « frauduleux » sur lequel repose notre modélisation.

Elle contient 30 000 sinistres, dont 11,5 % sont des sinistres frauduleux. Ce pourcentage est sensiblement supérieur aux estimations communément admises en France, qui situent la fraude réelle autour de 5 % des sinistres automobile. Cet écart s'explique vraisemblablement par le mode de constitution de la base : les dossiers qui la composent ont en grande partie fait l'objet d'une instruction approfondie ou d'une suspicion préalable, ce qui tend mécaniquement à sur-représenter les cas frauduleux par rapport à un portefeuille de sinistres bruts. Conscient de ce biais, nous avons néanmoins choisi de travailler sur cette base, dans la mesure où elle offre un volume suffisant de cas labellisés pour entraîner et évaluer les modèles de détection. Les résultats obtenus devront donc être interprétés avec cette réserve méthodologique à l'esprit, et toute généralisation à l'ensemble du portefeuille automobile français nécessiterait une recalibration du modèle sur des données plus représentatives de la sinistralité réelle.

Usuellement dans les mémoires, une présentation de la base de données est réalisée en amont de la mise en place d'un modèle sur les données. **On se propose ici de revisiter cette présentation, qui sera introduite dans les résultats de l'agent IA afin de mettre en avant le fait que ces travaux ont été automatisés via l'agent et non réalisés manuellement ou via un Code R, Python ou encore SAS, comme c'est le cas usuellement.**

Néanmoins, les variables présentes dans la base de données sinistre sont listées ci-dessous :

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
policy_id	Identifiant contrat	Identifiant	Texte	Identifiant unique du contrat d'assurance	POL100000 ... POL129999
policy_state	État de souscription	Contrat	Catégoriel	État américain de souscription du contrat	GA, PA, MI, CA, OH, NC, SC, WA, TX, NY...
policy_deductible	Franchise	Contrat	Numérique	Montant de la franchise (USD)	300 / 400 / 600 / 1000
policy_annual_premium	Prime annuelle	Contrat	Numérique	Prime annuelle payée par l'assuré (USD)	Float > 0
insured_age	Âge de l'assuré	Assuré	Entier	Âge de l'assuré en années	18 - 75
insured_sex	Sexe de l'assuré	Assuré	Catégoriel (3)	Sexe déclaré de l'assuré	MALE, FEMALE, OTHER
insured_education_level	Niveau d'études	Assuré	Catégoriel (4)	Niveau d'études de l'assuré	High School, College, Master, PhD
insured_occupation	Profession	Assuré	Catégoriel (8)	Profession de l'assuré	Manager, Lawyer, Doctor, Teacher, Sales, Clerk, Technician, Engineer
insured_hobbies	Loisirs	Assuré	Catégoriel (7)	Loisirs déclarés de l'assuré	reading, chess, yachting, hiking, camping, movies, paintball
incident_date	Date du sinistre	Sinistre	Date	Date du sinistre déclaré	YYYY-MM-DD
incident_type	Type de sinistre	Sinistre	Catégoriel (4)	Nature du sinistre	Parked Car, Vehicle Theft, Single Vehicle Collision, Multi-vehicle Collision
collision_type	Zone d'impact	Sinistre	Catégoriel (4)	Zone d'impact lors de la collision	Front, Rear, Side, Unknown
incident_severity	Gravité du sinistre	Sinistre	Catégoriel (3)	Gravité des dégâts matériels	Minor Damage, Major Damage, Total Loss
authorities_contacted	Autorités contactées	Sinistre	Catégoriel (4)	Autorités contactées suite au sinistre	Police, Fire, Ambulance, None (NaN)
incident_state	État du sinistre	Sinistre	Catégoriel (10)	État américain où le sinistre a eu lieu	GA, PA, MI, CA, OH, NC...
incident_city	Ville du sinistre	Sinistre	Texte	Ville où le sinistre a eu lieu	Texte libre
incident_hour_of_the_day	Heure du sinistre	Sinistre	Entier	Heure du sinistre (format 24h)	0 - 23
number_of_vehicles_involved	Nb véhicules impliqués	Sinistre	Entier	Nombre de véhicules impliqués dans le sinistre	1 - 4
bodily_injuries	Nb blessés déclarés	Sinistre	Entier	Nombre de blessés corporels déclarés	0 - 4
witnesses	Nb témoins	Sinistre	Entier	Nombre de témoins déclarés	0 - 5
police_report_available	Rapport police disponible	Sinistre	Booléen	Rapport de police disponible	Yes, No

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
claim_amount	<i>Montant réclamé</i>	Réclamation	Numérique	Montant réclamé par l'assuré pour ce sinistre (USD)	Float > 0
total_claim_amount	<i>Indemnisation totale</i>	Réclamation	Numérique	Montant total de l'indemnisation versée (USD)	Float > 0
fraud_reported	<i>Fraude confirmée (cible)</i>	Cible ML	Catégoriel	Variable cible : fraude confirmée ou non. Variable à prédire par le modèle. 11,5 % de Y dans la base.	Y (fraude) / N (légitime)

TABLEAU 4.1 – Variables de la base de données source

Au total 24 variables, avec la variable « fraud_reported » correspondant au flag dossier frauduleux ou non et « total_claim_amount » le montant du sinistre.

4.2.2 Enrichissement de la base de données

Afin de rendre ce mémoire proche de la réalité des assureurs, le choix d'enrichir la base de données disponible a été réalisé.

En effet, certaines informations incluses dans la base telles que le niveau d'éducation (*insured_education_level*) ou encore les passions de l'assuré (*insured_hobbies*) ne font pas partie des questionnaires usuels de souscription en assurance automobile sur le marché français.

De plus, l'assureur, lors de la déclaration d'un sinistre, a accès à bien plus d'informations que celles reportées dans cette base : ces dernières ont été recréées par simulation à l'aide de Claude [24]⁵ avec pour consigne d'être explicatives dans notre recherche d'identification de fraude **sans pour autant être en lien direct avec la variable à expliquer** (*fraud_reported*).

Ainsi, la base a été enrichie avec 6 types de données, toutes les données pouvant être rendues disponibles en pratique chez un assureur lors de la survenance d'un sinistre automobile :

1. **L'historique de l'assuré**, notamment ses sinistres passés, l'historique du contrat etc. ;
2. **Des informations sur le réseau de garagistes et les prestataires** impliqués dans la réparation du sinistre ;
3. **Des informations sur le tiers et les témoins**, de manière à identifier d'éventuels témoins récurrents ou des liens entre le tiers et l'assuré/les témoins ;
4. **Des informations sur le véhicule**, notamment son âge et sa valeur ;
5. **Des informations sur le comportement déclaratif**, notamment le délai entre la date de sinistre et de déclaration, le nombre de fois où l'assuré a modifié sa déclaration, le canal de déclaration etc. ;
6. **Des informations géographiques et temporelles**, notamment le jour de l'accident (férié/week-end) ou son lieu de survenance.

Au total, vingt-neuf variables ont été générées et sont décrites ci-dessous :

5. Assistant conversationnel développé par Anthropic, société américaine spécialisée en intelligence artificielle.

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
insured_id	Identifiant assuré	Historique assuré	Texte	Identifiant stable de l'assuré, indépendant du numéro de contrat. Permet de relier les dossiers d'un même assuré.	INS000001 ... INSXXXXXX
insured_nb_past_claims	Nb sinistres passés	Historique assuré	Entier	Nombre total de sinistres déclarés par cet assuré sur les 5 dernières années. Distributions chevauchantes, signal modéré.	0 - 5
insured_nb_past_fraud	Nb fraudes passées confirmées	Historique assuré	Entier	Nombre de fraudes confirmées antérieures pour cet assuré.	0 - 3
insured_days_since_last_claim	Jours depuis dernier sinistre	Historique assuré	Entier	Jours depuis le dernier sinistre de cet assuré.	60 - 2800
insured_claim_amount_history	Montant réclamé cumulé (3 ans)	Historique assuré	Numérique	Montant cumulé (USD) de toutes les réclamations de cet assuré sur 3 ans.	0 - 55 000
policy_age_at_incident_days	Ancienneté contrat (jours)	Contrat enrichi	Entier	Ancienneté du contrat en jours au moment du sinistre.	30 - 3600
insured_nb_policies_active	Nb contrats actifs	Contrat enrichi	Entier	Nombre de contrats d'assurance actifs simultanément (multi-assurance).	1 - 4
insured_address_changes_12m	Changements d'adresse (12 mois)	Historique assuré	Entier	Nombre de changements d'adresse dans les 12 derniers mois.	0 - 3
repairer_id	Identifiant réparateur	Réseau garagiste	Texte	Identifiant unique du réparateur mandaté. NONE = pas de réparateur.	GAR0001... GAR0899,NONE
repairer_nb_claims_total	Nb dossiers traités (réparateur)	Réseau garagiste	Entier	Nombre total de dossiers sinistres traités par ce réparateur dans la base.	0 - 200
repairer_nb_fraud_confirmed	Nb fraudes (réparateur)	Réseau garagiste	Entier	Nombre de fois où ce réparateur apparaît dans un dossier clôturé fraude.	0 - ~100
repairer_fraud_rate	Taux de fraude (réparateur)	Réseau garagiste	Numérique	Taux de fraudes du réparateur mandaté calculé comme $\text{repairer_nb_fraud_confirmed} / \text{repairer_nb_claims_total}$.	0 - 0,48
repairer_avg_invoice_vs_market	Ratio facture / marché	Réseau garagiste	Numérique	Ratio facture réparateur / prix marché. >1 = surfacturation.	0,85 - 1,55
repairer_is_flagged	Réparateur signalé	Réseau garagiste	Booléen 0/1	Réparateur inscrit en liste de vigilance.	0 = non-signalé 1 = signalé
third_party_id	Identifiant tiers	Réseau tiers	Texte	Identifiant du tiers impliqué. NONE si sinistre sans tiers.	TRS00001... TRS09999,NONE
third_party_nb_past_incidents	Nb incidents passés (tiers)	Réseau tiers	Entier	Nombre de fois où ce tiers est apparu dans des dossiers passés.	0 - 5
witness_id	Identifiant témoin	Réseau tiers	Texte	Identifiant du témoin principal. NONE si pas de témoin.	WIT00001... WIT11999,NONE
insured_third_party_known	Tiers connu de l'assuré	Réseau tiers	Booléen 0/1	Assuré et tiers se connaissent (même adresse, téléphone ou lien familial).	0 = inconnus / 1 = connus
vehicle_id	Identifiant véhicule	Véhicule	Texte	Immatriculation anonymisée.	VEH000001... VEH027999
vehicle_age_years	Âge du véhicule (années)	Véhicule	Entier	Âge du véhicule en années.	0 - 20
vehicle_market_value	Valeur marché du véhicule	Véhicule	Numérique	Valeur argus estimée du véhicule (USD). Distributions très chevauchantes.	2 000 - 40 000
vehicle_overvalue_ratio	Ratio surévaluation réclamation	Véhicule	Numérique	$\text{claim_amount} / \text{vehicle_market_value}$. >1 = réclamation dépasse la valeur du véhicule.	0,10 - 5,00
vehicle_nb_past_claims	Nb sinistres passés (véhicule)	Véhicule	Entier	Sinistres antérieurs sur ce véhicule, tous propriétaires confondus.	0 - 4

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
nb_ amendments_ declaration	Nb modifications déclaration	Comportement déclaratif	Entier	Nombre de modifications de la déclaration initiale.	0 - 4
declaration_ channel	Canal de déclaration	Comportement déclaratif	Catégoriel (4)	Canal utilisé pour déclarer le sinistre.	web, telephone, agence, courtier
injury_claimed_ without_medical	Blessure sans justificatif	Comportement déclaratif	Booléen 0/1	Blessures corporelles déclarées sans justificatif médical.	0 = justificatif présent / 1 = absent
incident_zip_ fraud_rate	Taux fraude de la zone	Géographique	Numérique	Taux historique de fraude dans l'État du sinistre, calculé sur la base.	0,00 - 0,30
incident_is_ weekend	Sinistre en weekend	Temporel	Booléen 0/1	Sinistre un vendredi soir, samedi ou dimanche.	0 = semaine / 1 = weekend
incident_is_ holiday	Sinistre jour férié	Temporel	Booléen 0/1	Sinistre un jour férié américain (1er jan, 4 juillet, Thanksgiving, Noël).	0 = jour normal / 1 = jour férié

TABLEAU 4.2 – Variables d'enrichissement de la base de données

La base de données finale rassemble ainsi 24 variables issues de la base source et 29 variables d'enrichissement, soit 53 variables au total, dont la variable cible binaire fraud_reported (Y/N) et six identifiants. C'est sur cet ensemble que reposera l'apprentissage des modèles de détection.

4.3 Descriptif macro de la création du processus de détection de fraude et de sa déclinaison opérationnelle

Afin de répondre aux enjeux de rentabilité évoqués précédemment, un processus de détection automatisé à l'aide d'un Agent IA a été construit. L'objectif est de fournir aux équipes d'investigation un outil d'aide à la décision opérationnelle « clé en main ».

Cet outil repose sur une **logique en deux temps**, articulée autour de **deux profils d'utilisateurs distincts** :

- Dans un premier temps, une équipe d'actuaire se charge de modéliser, construire et entraîner le modèle de détection. À partir d'une base de données sinistres au format standardisé, l'outil réalise automatiquement des contrôles qualité sur les données, produit une étude statistique descriptive mettant en avant les indicateurs clés (fréquence de fraude, coût moyen, segmentation par critères prédéfinis), puis entraîne un modèle de détection de fraude. Le résultat est un modèle calibré, sauvegardé et prêt à être déployé.
- Dans un second temps, une équipe opérationnelle (gestionnaires sinistres ou service de détection des fraudes) utilise ce modèle au quotidien sans avoir à en comprendre la construction. Pour chaque nouveau sinistre soumis, l'outil restitue une probabilité de fraude associée, permettant d'identifier les dossiers suspects et de les prioriser. Ainsi, les équipes d'investigation peuvent concentrer leurs efforts sur les cas les plus à risque, sans perdre de temps sur les dossiers à faible probabilité de fraude.




FIGURE 4.2 – Vision macro du fonctionnement de l'outil

Le modèle est entraîné puis sauvegardé à l'issue du temps 1, avant d'être chargé dans le module opérationnel (temps 2). Une fois l'investigation close, son issue est renseignée et vient enrichir la base de données sinistres, ce qui permet de réentraîner le modèle (boucle en pointillés).

L'architecture complète de ce processus est détaillée dans les chapitres suivants, de l'alimentation de la base de données à la boucle d'enrichissement continu, en passant par la modélisation de la probabilité de fraude.

Enfin, l'outil produit automatiquement un **rapport annuel de détection de fraude**, enrichi à chaque fois qu'un sinistre testé est renseigné comme frauduleux par un expert. Ce rapport est accessible à tout moment et fournit une **synthèse consolidée des performances** : nombre de sinistres analysés, taux d'alertes générées, fraudes confirmées et montant de fraude évitée. Il calcule notamment l'impact direct sur le ratio Sinistres/Primes (S/P), indicateur clé de rentabilité en assurance, en rapportant le montant de fraude évitée à la masse de primes du portefeuille. Cette restitution permet au management de suivre en continu le retour sur investissement de l'outil (ROI) et d'objectiver la valeur ajoutée de la détection automatisée année après année.

4.3.1 Le prompt : la décomposition du besoin en étapes

Dans le contexte de l'intelligence artificielle, et plus particulièrement des modèles de langage, un *prompt* désigne l'ensemble des instructions, du contexte et des données fournis au modèle afin de guider son comportement et d'orienter la nature des réponses ou des actions qu'il produit. Il constitue le point d'entrée de l'interaction entre l'utilisateur (ou un système) et l'agent. Un *prompt* ne se réduit pas à une simple question : il peut comporter des consignes précises, des contraintes, des exemples et une structuration attendue du résultat. De façon générale, plus il est clair, détaillé et contextualisé, plus le modèle est en mesure de produire une réponse pertinente et alignée sur l'objectif visé.

D'un point de vue méthodologique, le *prompt* peut être assimilé à la **spécification fonctionnelle** de la tâche confiée à l'agent : il joue, vis-à-vis du modèle, un rôle comparable à celui d'un cahier des charges vis-à-vis

d'un modèle actuariel. Sa qualité conditionne directement celle du résultat, au même titre que la rigueur d'une note technique conditionne la fiabilité d'un calcul. Cette exigence rejoint les principes de gouvernance évoqués précédemment : un *prompt* explicite, documenté et reproductible contribue à la traçabilité et à l'auditabilité du dispositif, en rendant intelligibles les consignes sur lesquelles repose le comportement de l'agent.

Concrètement, un *prompt* bien construit remplit trois fonctions :

- Il **définit la cible** : il ne s'agit pas ici d'affirmer qu'un dossier est frauduleux (l'agent ne se substitue pas à l'enquêteur) mais d'identifier, à partir des données disponibles, les dossiers présentant un risque de fraude élevé.
- Il **précise le cadre d'intervention** : le rôle de l'agent, le contexte métier, les critères à prendre en compte et les limites de son action.
- Il **encadre enfin la forme de la réponse** attendue, par exemple un score, un tableau ou une synthèse exploitable par les équipes opérationnelles.

Pour obtenir un résultat précis, contrôlable et reproductible, il ne suffit toutefois pas de formuler une consigne unique et globale, qui laisserait à l'agent une marge d'interprétation trop large et nuirait à la stabilité des réponses. Nous avons donc adopté une approche de **construction du *prompt* par étapes** : plutôt que de soumettre l'intégralité de la tâche en un seul bloc, le raisonnement attendu de l'agent a été décomposé en une séquence d'étapes successives, chacune assortie d'un objectif clair et d'un résultat intermédiaire vérifiable.

Cette décomposition présente un double intérêt. Elle reproduit la logique même de la démarche actuarielle (du contrôle de la qualité des données à la production d'un score, en passant par l'analyse descriptive et la modélisation) et elle permet de valider chaque maillon de la chaîne indépendamment, limitant ainsi le risque d'erreur ou de dérive et renforçant l'explicabilité de l'ensemble.

Ainsi, le *prompt* constitue un élément central du système : il transforme une demande générale en une tâche claire, structurée et exploitable, et montre que l'efficacité de l'outil ne repose pas uniquement sur les données ou sur le modèle, mais aussi sur la qualité des instructions fournies à l'agent. Le raisonnement confié à ce dernier a en conséquence été structuré selon les étapes successives présentées ci-après.

4.3.2 Présentation macro des différentes étapes

Les **étapes** menant à la création du modèle sont ainsi décomposées :

1. Ingestion standardisée des données
2. Audit et contrôles de cohérence
3. Analyse statistique descriptive
4. Construction des modèles de prédiction de fraude
5. Critères de qualité du modèle et choix du modèle parmi les modèles construits




FIGURE 4.3 – Création et calibration du modèle de détection de fraude

Une fois le modèle de détection mis en place, il est intégré dans un outil d'aide à la décision destiné aux gestionnaires et au service fraude. Contrairement au premier module, ce second module ne fonctionne pas selon une séquence figée : il se comporte comme un véritable logiciel au sein duquel l'utilisateur navigue librement. S'il existe un enchaînement logique naturel, l'utilisateur peut à tout moment revenir en arrière, répéter une opération ou accéder directement à une fonctionnalité selon ses besoins.

L'outil met à disposition les fonctionnalités suivantes :

- **La saisie d'un sinistre** : l'utilisateur renseigne les informations d'un dossier à évaluer.

- **L'obtention d'un score de fraude** : le modèle restitue une probabilité de fraude associée au sinistre soumis.
- **Le renseignement du statut du dossier** : lorsque l'issue de l'investigation est connue, l'utilisateur peut indiquer si le sinistre s'est avéré frauduleux ou non.
- **La restitution d'un rapport de fraude** : basé sur les sinistres testés dans l'outil durant une période donnée.

De plus, l'outil reste lié de manière cyclique au modèle puisque le renseignement du statut du dossier permet :

- l'alimentation de la base de données sinistre ayant servi à faire tourner le modèle ;
- l'affinage du modèle créé à l'aide des nouveaux sinistres renseignés.




FIGURE 4.4 – Représentation des différents blocs de l'agent d'aide à la détection de fraude

À noter que la logique de création des deux agents respecte l'objectif d'utilisation de ces derniers : **deux équipes distinctes seront en charge de leur utilisation, d'où le besoin de rendre totalement indépendants les deux agents créés.**

Dans les paragraphes suivants, nous présenterons la restitution concrète produite par notre outil sur le portefeuille de sinistres simulé (construit à partir des données *Kaggle* enrichies).

Cette phase de conception du modèle constitue une étape amont essentielle, mais elle **n'a pas vocation à être maîtrisée par les équipes opérationnelles en charge de la détection de la fraude**. En effet, l'outil final qui leur est destiné repose sur un modèle déjà entraîné et optimisé, qu'ils pourront exploiter sans avoir à intervenir sur ses mécanismes internes. Ainsi, la complexité technique est volontairement « encapsulée » afin de **proposer une solution simple d'utilisation, centrée sur l'aide à la décision** aux gestionnaires.

Dans la pratique, la responsabilité de la construction, de l'ajustement et de l'amélioration continue du modèle incombe généralement à des profils spécialisés, tels que les actuaires ou les *data scientists*. Ces experts interviennent pour affiner les performances du modèle, intégrer de nouvelles données, ajuster les paramètres et

garantir la robustesse des résultats dans le temps. Cette séparation des rôles permet d'assurer à la fois un haut niveau de performance analytique et une appropriation efficace de l'outil par les équipes métiers.

4.4 Étapes 1 & 2 : Ingestion de la base de données et Audit de contrôles de cohérence

4.4.1 Étape 1 : Ingestion de la base de données

La première étape correspond au chargement des données.

Sur la page d'accueil de l'outil, intitulée « Aide à la détection de fraude », nous invitons l'utilisateur à déposer son fichier de sinistres, qui constitue la donnée d'entrée de l'ensemble du processus.

Le dépôt peut se faire de deux manières :

- Soit par glisser-déposer directement dans la zone prévue à cet effet,
- Soit en cliquant sur le bouton « Parcourir vos fichiers » afin de sélectionner le document depuis l'explorateur.

Les formats acceptés sont les plus courants pour ce type de données, à savoir CSV, Excel (.xlsx et .xls) et ODS, de manière à s'adapter aux différents systèmes de gestion des professionnels de l'assurance.




FIGURE 4.5 – Extrait du *prompt* pour la création de l'étape 1

À ce stade, aucun choix de modèle n'est demandé : celui-ci n'interviendra qu'ultérieurement, une fois les analyses descriptives consultées, ce qui permet à l'utilisateur de sélectionner en connaissance de cause le modèle de détection le plus adapté à la structure de son portefeuille.

Enfin, nous signalons à l'utilisateur que les données importées sont traitées de manière sécurisée et confidentielle, l'outil étant réservé aux professionnels de l'assurance.

L'utilisateur clique ensuite sur le bouton « *submit* » pour passer à l'étape suivante.



FIGURE 4.6 – Page d'accueil de l'outil d'aide à la détection de fraude

4.4.2 Étape 2 : Audit et contrôles de cohérence

Dès l'importation du fichier brut de sinistres, l'outil procède à un audit automatisé, étape fondamentale de *Data Profiling*. L'objectif de cette interface n'est pas de réaliser un simple inventaire, mais de garantir l'intégrité et la qualité des données avant qu'elles ne soient intégrées dans un modèle de prédiction de la fraude.

Concrètement, comme illustré dans le tableau de restitution ci-dessous, le moteur cartographie le portefeuille en réalisant plusieurs contrôles croisés pour chaque variable :

- **La vérification du typage** : l'outil confronte le type de donnée attendu par le système au type réellement détecté. Cela permet de bloquer instantanément les erreurs de formatage.
- **L'analyse des plages et modalités** : le système extrait automatiquement les bornes pour les variables numériques, et liste les différentes catégories pour les variables textuelles, facilitant la détection immédiate de valeurs aberrantes (*outliers*).
- **Le contrôle de complétude** : il calcule le taux de remplissage exact pour mettre en évidence les données manquantes. En cas de donnée(s) manquante(s), l'Agent demande à l'utilisateur de les remplacer par une valeur par défaut à renseigner. À noter qu'il aurait également été possible de proposer des options de remplissage par défaut, par exemple, pour une variable quantitative, la moyenne ou encore la médiane ou la valeur la plus représentée.

Dans notre outil, un contrôle bloquant a été mis en place sur la complétude des données : l'agent ne permet pas la poursuite des tâches si la base de données n'est pas complète.

À titre illustratif, voici une sortie de l'outil lorsque la base admet une valeur manquante :




FIGURE 4.7 – Sortie de l'outil « Analyse de la qualité des données de la base » avec une valeur manquante

Ici, la variable « `policy_deductible` » qui correspond à la franchise du contrat admet une valeur manquante. L'utilisateur est invité à choisir une des valeurs qui s'affiche pour compléter la ligne manquante (les valeurs affichées correspondent aux modalités observées dans la base d'entrée), ou à entrer manuellement une valeur dans un champ dédié.

Une fois l'information complétée, l'affichage se met à jour automatiquement⁶ :




FIGURE 4.8 – Sortie de l'outil « Analyse de la qualité des données de la base » sans valeur manquante

L'examen du tableau de contrôle permet de formuler deux observations métier majeures sur notre jeu de données :

6. L'affichage intégral de la sortie de l'agent à cette étape est disponible en Annexe B.

- D'une part, le contrôle des bornes (colonne « Modalités / Plage ») valide la cohérence globale de notre portefeuille. À titre d'exemple, l'outil confirme immédiatement que la variable *insured_age* est strictement comprise entre 18 et 75 ans. L'absence de valeurs irréalistes confirme que les règles de gestion ont été respectées lors de la saisie.
- De plus, la variable cible de notre étude, *fraud_reported*, est correctement identifiée et renseignée à 100 %, condition sine qua non pour l'entraînement d'un modèle supervisé.

De plus, l'agent a la capacité de détecter les variables susceptibles d'être utilisées dans le modèle et celles qui ne le sont pas (cf. dernière colonne « Inclure ») : la variable « *policy_id* » correspondant à l'identifiant du contrat a été reconnue comme une variable d'incrément et est exclue de la modélisation. L'utilisateur peut également en exclure d'autres, pour des raisons réglementaires ou techniques à ce niveau.

Enfin, en bas de page, l'utilisateur doit préciser à l'agent quelle variable désigne la variable à expliquer.

Pour cela il suffit de sélectionner la variable cible dans la liste déroulante proposée :

Ici, c'est la variable *fraud_reported* qui est la variable à modéliser, et elle sera appelée « fraude » dans la suite des analyses.

4.5 Étape 3 : Analyse statistique des données

Une fois la qualité des données validée, l'agent bascule dans une phase d'analyse exploratoire :

- Univariée : il s'agit d'analyser la composition de notre portefeuille par variable ;
- Bivariée : il s'agit ici d'analyser la fréquence et le coût moyen de la fraude, au même titre que les analyses qui seraient réalisées dans le cadre d'une tarification produit.

4.5.1 Analyse de la composition du portefeuille

Avant d'engager toute modélisation ou détection de comportements atypiques, il est essentiel de dresser un portrait détaillé de la base de données sinistres automobiles étudiée.

Cette analyse préliminaire vise à caractériser la structure des sinistres déclarés selon plusieurs axes : la nature des sinistres (accidents corporels, dommages, etc.), ainsi que les caractéristiques des conducteurs impliqués (âge, sexe, profession, adresse, etc.) et les paramètres du contrat (franchise, prime annuelle, etc.).

Elle permet également d'examiner la distribution temporelle et géographique des déclarations, deux dimensions particulièrement révélatrices en matière de fraude automobile. Une telle exploration permet d'identifier d'éventuels déséquilibres ou concentrations atypiques dans les données (comme une surreprésentation de sinistres déclarés en fin de contrat ou dans certaines zones géographiques) et d'en tenir compte dans les étapes ultérieures de l'analyse. La connaissance fine de la structure de cette base constitue un prérequis indispensable à toute démarche actuarielle rigoureuse, en posant les fondements empiriques sur lesquels reposera l'ensemble de la modélisation de la fraude développée dans ce mémoire.

Le *prompt* adressé à l'agent concernant l'analyse de composition de portefeuille renvoie la sortie suivante :




FIGURE 4.9 – Composition du portefeuille

La base de données étudiée comprend 30 000 sinistres automobiles, offrant ainsi un volume suffisant pour mener une analyse statistique robuste et entraîner des modèles de détection de la fraude performants.

Les classifications de certaines variables proposées ici en sortie (comme *insured_age* et *incident_hour_of_the_day*) ont été définies par l'agent. Ces dernières seront modifiées par la suite et recréées via les méthodes classiques de création de classes telles que le découpage en quantiles, l'algorithme K-means ou encore la méthode de classification hiérarchique ascendante (cf. paragraphe 4.5.2).

Cette analyse descriptive de la base sinistres permet d'établir une vision globale de la structure des données, sans distinction entre sinistres frauduleux et non frauduleux. La section suivante propose d'affiner cette exploration en adoptant une lecture bivariable, c'est-à-dire en comparant systématiquement la distribution de chaque variable selon le statut de fraude, afin d'identifier les premières variables discriminantes qui pourront guider la construction des modèles prédictifs.

À noter que, de manière autonome, l'agent détecte automatiquement la représentation la plus adaptée à la variable à étudier, notamment des camemberts pour les variables qui admettent un faible nombre de modalités et des diagrammes en barres pour les variables admettant un nombre plus important de modalités.

Enfin, l'agent permet l'export de la sortie graphique de composition du portefeuille, à des fins de traçabilité ou d'études intermédiaires par exemple.

4.5.2 Analyse de la fréquence de la fraude

Suite à l'analyse de composition du portefeuille, une analyse de la fréquence de fraude selon les variables explicatives potentielles va être réalisée. Cette analyse permet d'avoir un premier aperçu des variables ayant un impact significatif sur le niveau de fraude observé et de valider par la suite la cohérence des modèles obtenus. Cette analyse permet également d'alimenter le choix de création de classes au sein d'une variables admettant

des modalités ayant un comportement similaire en termes de taux de fraude.

L'agent va ensuite réaliser deux actions de manière autonome :

- Afficher le top3 des variables jugées comme les plus discriminantes au vu de la variable cible (affichage *on Top*)
- Choisir la représentation la plus adaptée à la variable à étudier, notamment des camemberts pour les variables qui admettent un faible nombre de modalités et des diagrammes en barre pour les variables admettant un nombre plus important de modalités.




FIGURE 4.10 – Analyse de la fréquence de la fraude

L'affichage a volontairement été limité à quatre variables à la fois pour offrir une meilleure clarté à l'utilisateur. Un choix d'affichage reste disponible à droite sur simple clic afin de permettre à l'utilisateur de choisir la/les variable(s) qu'il souhaite visualiser.

À noter que l'agent comprend également seul qu'il est inutile de réaliser l'analyse de la fraude par « policy_id » par exemple, dans la mesure où cet indicateur sert de compteur (ou incrément) et n'a pas d'apport dans la modélisation. Pour rappel cette variable avait été décochée dès le début.

L'analyse de ces graphiques et diagrammes permet de dégager des enseignements métiers déterminants pour l'identification des sinistres frauduleux :

- **Le statut de réparateur signalé** est la variable la plus discriminante (dispersion de 0,065). Lorsque le réparateur figure sur une liste de vigilance, le taux de fraude bondit à 56,1 %, contre 10,0 % dans le cas contraire, soit près de cinq fois le taux moyen du portefeuille (11,5 %).

- **Le nombre de fraudes passées de l'assuré** confirme le poids des antécédents (dispersion de 0,063) : le taux de fraude croît de façon strictement monotone avec le nombre de fraudes déjà commises, passant de 8,5 % pour un assuré sans antécédent à 30,6 %, 34,3 % puis 39,8 % pour une, deux et trois fraudes passées.
- **Le nombre d'incidents passés du tiers** suit la même logique (dispersion de 0,042) : de 10,3 % sans antécédent, le taux de fraude grimpe à 32,1 % pour deux incidents et atteint 100 % au-delà de trois, bien qu'il repose sur de faibles effectifs (87 et 36 dossiers), à interpréter donc avec prudence.
- **Le nombre d'amendements à la déclaration** apparaît également discriminant (dispersion de 0,034) : les modifications successives d'une déclaration traduisent une hésitation ou un ajustement suspect, le taux de fraude passant de 7,5 % sans amendement à 26,7 % pour quatre modifications ou plus.

4.5.3 Création de classes de variables

La création de classes constitue une étape préalable importante à la mise en œuvre de certains modèles prédictifs, notamment lorsque les variables explicatives sont continues ou présentent un grand nombre de modalités.

Cette discrétisation permet de regrouper des observations présentant des caractéristiques similaires, afin de réduire la complexité des données, de limiter la sensibilité du modèle aux fluctuations locales et de faciliter l'interprétation des effets associés aux différentes variables.

En actuariat, elle contribue également à obtenir des groupes suffisamment homogènes et robustes d'un point de vue statistique.

Plusieurs approches peuvent être utilisées pour construire ces classes, parmi lesquelles les méthodes fondées sur des quantiles ou des intervalles de largeur constante, les méthodes de classification via l'algorithme des K-means ou encore une classification hiérarchique ascendante.

Une présentation plus détaillée des principes théoriques et des principales méthodes de discrétisation est proposée en Annexe A.

Pour la suite des traitements, les variables suivantes ont été classifiées selon le découpage suivant :

Variable	Nombre de classes créées	Méthode de classification	Descriptif des classes
policy_annual_premium (prime annuelle)	5	Découpage de l'intervalle de valeur [600; 1 500] en amplitudes égales. Contrôle de l'effectif par classe créée (≥ 5 %)	[600; 780]]780; 960]]960; 1 140]]1 140; 1 320]]1 320; 1 500]
insured_age (âge de l'assuré)	2	Arbre de décision CART univarié	18 - 24 ans 25 - 75 ans
incident_hour_of_the_day (heure du sinistre)	3	Découpage métier (créneaux horaires)	Nuit : 22h - 6h Matin : 6h - 12h Après-midi / soir : 12h - 22h
total_claim_amount (montant total du sinistre)	5	Quantiles arrondis à des bornes métier de 5 000 USD	$\leq 5\,000$]5 000; 10 000]]10 000; 15 000]]15 000; 20 000] > 20 000
insured_days_since_last_claim (jours depuis le dernier sinistre)	3	Arbre CART univarié	≤ 800 jours (≈ 2 ans)]800; 2 500] jours > 2 500 jours (≈ 7 ans)

Variable	Nombre de classes créées	Méthode de classification	Descriptif des classes
insured_claim_amount_history (historique des montants indemnisés)	2	Arbre CART univarié	$\leq 30\,000$ $> 30\,000$
policy_age_at_incident_days (ancienneté du contrat)	3	Découpage métier	Moins de 1 an (< 365 jours) Entre 1 an et 3 ans Plus de 3 ans
repairer_fraud_rate (taux de fraude du réparateur)	4	Découpage métier + arbre CART univarié	Pas de réparateur identifié 0 % (réparateur avec historique, aucune fraude)]0 %; 5 %] > 5 %
repairer_avg_invoice_vs_market (facture moyenne / prix du marché)	2	Arbre CART univarié	<i>On market</i> : $\leq 1,15$ <i>Off market</i> (surfacturation) : $> 1,15$
vehicle_age_years (âge du véhicule)	2	Arbre CART univarié	0 - 8 ans 9 ans et plus
vehicle_market_value (valeur de marché du véhicule)	3	Arbre CART univarié	$\leq 5\,500$]5 500; 28 000] $> 28\,000$
vehicle_overvalue_ratio (ratio de survalorisation)	4	Quantiles + validation par CART	$\leq 0,50$]0,50; 0,95]]0,95; 2,20] $> 2,20$
incident_zip_fraud_rate (taux de fraude du code postal)	3	Terciles des 10 modalités observées	Faible : $\leq 11,05$ % Moyen :]11,05 %; 11,71 %] Élevé : $> 11,71$ %

TABLEAU 4.3 – Méthodes de discrétisation retenues pour chaque variable

Le détail du découpage de chaque variable est présenté ci-dessous.

- La variable « **policy_annual_premium** » est quantitative et admet des valeurs comprises entre 600 et 1 500 USD. Le choix de découpage pour la création de classes a été de créer cinq classes de valeur d'amplitudes égales, tout en s'assurant que chacune des classes créées admettait assez de volume (à minima 5 % de la base de sinistres testée).

policy_annual_premium	Nombre de sinistres associés	% de la base sinistre
[600; 780]	5 970	19,90 %
]780; 960]	6 031	20,10 %
]960; 1 140]	5 933	19,78 %
]1 140; 1 320]	5 992	19,97 %
]1 320; 1 500]	6 074	20,25 %
Total	30 000	100 %

- La variable « **insured_age** », correspondant à l'âge de l'assuré, prend ses valeurs entre 18 et 75 ans. Usuellement, ce sont des classes d'âge d'amplitude 5 ou 10 ans qui sont créées en tarification automobile ou en suivi du risque en portefeuille. Pour ce mémoire, l'objectif étant de créer un modèle prédictif de fraude automobile, c'est avant tout l'impact de l'âge sur le taux de fraude qui a été utilisé pour orienter le choix de création de classes sur cette variable. Ce découpage a été établi à l'aide d'un arbre de décision

CART univarié, avec en paramétrage un minimum de 5 % des lignes de la base sinistre par feuille. Ainsi, un seuil unique à 24,5 ans a été établi, suivi d'une fusion des classes à taux homogènes. Seules 2 classes ont donc été créées : les moins de 24 ans et les plus de 24 ans.

insured_age	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
18 - 24 ans	3 539	11,80 %	18,71 %
25 - 75 ans	26 461	88,20 %	10,50 %
Total	30 000	100 %	11,5 %

- La variable « **incident_hour_of_the_day** », correspondant à l'heure du sinistre, a été découpée selon une logique métier, afin de représenter les différents moments de la journée. Ainsi, 3 classes ont été créées : Nuit (22h - 6h), Matin (6h - 12h) et Après-midi - soir (12h - 22h).

incident_hour_of_the_day	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
Nuit : 22h - 6h	9 932	33,11 %	11,38 %
Matin : 6h - 12h	7 535	25,12 %	11,12 %
Après-midi - soir : 12h - 22h	12 533	41,78 %	11,74 %
Total	30 000	100 %	11,5 %

- La variable « **total_claim_amount** », correspondant au montant total du sinistre, a été découpée en quintiles (5 classes) avec un arrondi par tranche de 5 000 USD.

total_claim_amount	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
≤ 5 000	5 410	18,03 %	12,13 %
]5 000; 10 000]	6 168	20,56 %	10,96 %
]10 000; 15 000]	6 199	20,66 %	11,60 %
]15 000; 20 000]	6 151	20,50 %	11,46 %
> 20 000	6 072	20,24 %	11,26 %
Total	30 000	100 %	11,5 %

- La variable « **insured_days_since_last_claim** », correspondant au nombre de jours depuis le dernier sinistre, a été découpée en 3 classes. Ce découpage a été établi à l'aide d'un arbre de décision CART univarié, avec en paramétrage un minimum de 5 % des lignes de la base sinistre par feuille. Ainsi, deux seuils ont été établis, 798,5 et 2 504,5 jours, arrondis respectivement à 800 et 2 500 jours.

insured_days_since_last_claim	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
≤ 800 jours (≈ 2 ans)	9 910	33,03 %	17,28 %
]800; 2 500] jours	17 415	58,05 %	9,21 %
$> 2 500$ jours (≈ 7 ans)	2 675	8,92 %	4,64 %
Total	30 000	100 %	11,5 %

- La variable « **insured_claim_amount_history** », correspondant à l'historique des montants indemnisés, a été découpée en 2 classes. Ce découpage a été établi à l'aide d'un arbre de décision CART univarié, avec en paramétrage un minimum de 5 % des lignes de la base sinistre par feuille. Ainsi, le seuil de 29 997 USD a été établi, arrondi à 30 000 USD.

insured_claim_amount_history	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
$\leq 30\,000$	27 206	90,69 %	8,63 %
$> 30\,000$	2 794	9,31 %	39,08 %
Total	30 000	100 %	11,5 %

- La variable « **policy_age_at_incident_days** », correspondant à l'ancienneté du contrat, a été découpée selon une logique métier de manière à isoler les polices récentes des polices plus anciennes, tout en assurant un volume suffisant d'information par classe créée. Ainsi 3 classes ont été créées : moins de 1 an, 1-3 ans et plus de 3 ans.

policy_age_at_incident_days	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
< 1 an	4 439	14,80 %	16,63 %
1-3 ans	8 502	28,34 %	13,46 %
> 3 ans	17 059	56,86 %	9,13 %
Total	30 000	100 %	11,5 %

- La variable « **repairer_fraud_rate** », correspondant au taux de fraude du réparateur, a été découpée selon un découpage métier de manière à isoler la modalité structurelle « pas de réparateur ». Ce découpage a été réalisé à l'aide d'un arbre CART donnant un intervalle de $[0; 10 \text{ \%}]$, ramené à $[0; 5 \text{ \%}]$ pour respecter la contrainte d'effectif par classe créée ($> 5 \text{ \%}$).

reparer_fraud_rate	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
Pas de réparateur identifié	6 074	20,25 %	11,31 %
0 % (réparateur avec historique, aucune fraude)	11 680	38,93 %	7,31 %
]0 %; 5 %]	9 696	32,32 %	7,52 %
> 5 %	2 550	8,50 %	45,88 %
Total	30 000	100 %	11,5 %

- La variable « **reparer_avg_invoice_vs_market** », correspondant au ratio facture moyenne / prix du marché, a été découpée en 2 classes à l'aide d'un arbre CART. Le seuil obtenu est de 1,15.

reparer_avg_invoice_vs_market	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
<i>On market</i> : $\leq 1,15$	27 589	91,96 %	8,26 %
<i>Off market</i> (surfacturation) : $> 1,15$	2 411	8,04 %	48,15 %
Total	30 000	100 %	11,5 %

- La variable « **vehicle_age_years** », correspondant à l'âge du véhicule, a été découpée en 2 classes de manière à mettre en évidence les écarts relatifs au taux de fraude observé. Un arbre de décision CART univarié a été utilisé, le seuil de 8,5 ans a été mis en évidence.

vehicle_age_years	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
0 - 8 ans	22 480	74,93 %	8,50 %
9 ans et plus	7 520	25,07 %	20,33 %
Total	30 000	100 %	11,5 %

- La variable « **vehicle_market_value** », correspondant à la valeur de marché du véhicule, a été découpée à l'aide d'un arbre de décision CART univarié, avec en paramétrage un minimum de 5 % des lignes de la base sinistre par feuille. Ainsi, deux seuils de 5 140 et 27 970 ont été établis, arrondis à 5 500 et 28 000 USD respectivement pour garantir un volume ≥ 5 % par classe.

vehicle_market_value	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
$\leq 5 500$	1 825	6,08 %	22,19 %
]5 500; 28 000]	20 204	67,35 %	13,47 %
$> 28 000$	7 971	26,57 %	3,94 %
Total	30 000	100 %	11,5 %

- La variable « **vehicle_overvalue_ratio** », correspondant au ratio de survalorisation, a été découpée à l'aide de la méthode des quantiles, associée à une validation par CART.

vehicle_overvalue_ratio	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
$\leq 0,50$	14 829	49,43 %	8,54 %
$]0,50; 0,95]$	7 721	25,74 %	12,47 %
$]0,95; 2,20]$	5 553	18,51 %	14,96 %
$> 2,20$	1 897	6,32 %	20,03 %
Total	30 000	100 %	11,5 %

- La variable « **incident_zip_fraud_rate** », correspondant au taux de fraude du code postal, a été regroupée en 3 classes selon les terciles des valeurs (10 valeurs uniquement).

incident_zip_fraud_rate	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
Faible : $\leq 11,05$ %	9 011	30,04 %	10,86 %
Moyen : $]11,05 \text{ %}; 11,71 \text{ %}]$	8 995	29,98 %	11,46 %
Élevé : $> 11,71$ %	11 994	39,98 %	11,92 %
Total	30 000	100 %	11,5 %

4.5.4 Analyse des corrélations entre les variables

L'agent renvoie également une table de corrélation entre variables après l'analyse de composition du portefeuille, qui faisait partie de notre demande dans le *prompt* adressé.

En effet, avant d'engager la phase de modélisation, il est important d'examiner les relations existantes entre les différentes variables explicatives de la base sinistres. Cette analyse permet de détecter d'éventuelles redondances entre variables, susceptibles d'introduire des problèmes de multicollinéarité dans les modèles ultérieurs, et de mieux comprendre la structure sous-jacente des données.

La nature mixte des variables retenues (à la fois quantitatives et qualitatives) nécessite de recourir à plusieurs mesures d'association adaptées à chaque configuration.

a) Corrélation entre deux variables quantitatives

Les corrélations entre variables quantitatives sont mesurées via le coefficient de Pearson. Pour deux variables X et Y , il est défini par :

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y} = \frac{\mathbb{E}[(X - \mu_X)(Y - \mu_Y)]}{\sqrt{\mathbb{E}[(X - \mu_X)^2] \mathbb{E}[(Y - \mu_Y)^2]}} \quad (4.1)$$

Son estimateur empirique sur un échantillon de taille n s'écrit :

$$\hat{\rho}_{X,Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (4.2)$$

Ce coefficient, borné dans $[-1, 1]$, mesure exclusivement l'intensité et le sens d'une relation *linéaire*. Une valeur proche de 1 traduit une relation positive forte (les deux variables évoluent dans le même sens), une valeur proche de -1 une relation négative forte (l'une croît lorsque l'autre décroît), et une valeur proche de 0 l'absence de relation linéaire.

Attention, une valeur nulle n'exclut pas l'existence d'une dépendance non linéaire, ce qui justifie de compléter l'analyse par une inspection graphique lorsque cela est pertinent.

b) Association entre deux variables qualitatives

Les associations entre variables qualitatives sont quant à elles évaluées à l'aide du V de Cramér (dérivé de la statistique du χ^2 de Pearson). Pour deux variables qualitatives comportant respectivement k et l modalités, croisées dans un tableau de contingence de n observations, il est défini par :

$$V = \sqrt{\frac{\chi^2}{n * \min(k - 1, l - 1)}} \quad (4.3)$$

où la statistique du χ^2 est donnée par :

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*}, \quad \text{avec} \quad n_{ij}^* = \frac{n_{i.} n_{.j}}{n} \quad (4.4)$$

Les termes n_{ij} désignent les effectifs observés dans la cellule (i, j) et n_{ij}^* les effectifs théoriques sous l'hypothèse d'indépendance des deux variables. Le V de Cramér prend ses valeurs dans $[0, 1]$, une valeur nulle traduisant l'indépendance et une valeur unitaire une association parfaite.

Sa normalisation par $\min(k - 1, l - 1)$ le rend comparable entre tableaux de dimensions différentes, ce qui constitue un avantage déterminant dans un contexte où les variables catégorielles présentent des cardinalités hétérogènes.

Contrairement au coefficient de Pearson, le V de Cramér ne renseigne pas sur le sens de la relation, mais uniquement sur son intensité, puisqu'il s'applique à des variables non ordonnées.

c) Association entre une variable quantitative et une variable qualitative

Les relations entre une variable quantitative et une variable qualitative sont appréhendées par le **rapport de corrélation** (η^2).

Soit Y une variable quantitative et X une variable qualitative à k modalités partitionnant l'échantillon en k classes d'effectifs $n_1, \dots, n_k$. En notant $\bar{y}_j$ la moyenne de Y dans la classe j et $\bar{y}$ la moyenne globale, la décomposition de la variance totale s'écrit :

$$\underbrace{\sum_{j=1}^k \sum_{i=1}^{n_j} (y_{ij} - \bar{y})^2}_{SC_{\text{totale}}} = \underbrace{\sum_{j=1}^k n_j (\bar{y}_j - \bar{y})^2}_{SC_{\text{inter}}} + \underbrace{\sum_{j=1}^k \sum_{i=1}^{n_j} (y_{ij} - \bar{y}_j)^2}_{SC_{\text{intra}}} \quad (4.5)$$

Avec SC la somme des carrés. Le rapport de corrélation est alors défini par :

$$\eta^2 = \frac{SC_{\text{inter}}}{SC_{\text{totale}}} \in [0, 1] \quad (4.6)$$

Il s'interprète comme la part de la variance de Y expliquée par l'appartenance aux modalités de X . Une valeur proche de zéro indique une absence de discrimination des modalités de X sur les niveaux moyens de Y , tandis qu'une valeur proche de 1 traduit une segmentation forte.

Par convention, un coefficient supérieur à **0,7** est généralement considéré comme révélateur d'une association forte, pouvant justifier l'exclusion ou la transformation de l'une des variables concernées.

d) Corrélation entre les variables de la base étudiée

Les tableaux ci-dessous synthétisent l'ensemble de ces mesures et constituent ainsi un prérequis méthodologique essentiel à la construction de modèles robustes et interprétables, en garantissant la qualité et l'indépendance de l'information apportée par chaque variable retenue dans l'analyse.

Pour chaque paire de variables par type, le coefficient de corrélation est calculé. La variable de fraude avérée (fraud_reported), qui est notre variable à expliquer, ne fait pas partie des corrélations testées. L'objet ici est uniquement de relever les corrélations entre les variables explicatives.

	repairer_nb_claims_total	repairer_nb_fraud_confirmed
repairer_nb_claims_total	1	0,72
repairer_nb_fraud_confirmed	0,72	1

TABLEAU 4.4 – Coefficient de corrélation de Pearson ou coefficient de rang de Spearman : Extrait de la matrice quantitative $\times$ quantitative

	incident_zip_fraud_rate	repairer_fraud_rate	repairer_is_flagged
incident_state	1	0,02	0,02
repairer_avg_invoice_vs_market	0,01	0,97	0,62

TABLEAU 4.5 – V de Cramér : Extrait de la matrice qualitative $\times$ qualitative

	repairer_fraud_rate	repairer_avg_invoice_vs_market	repairer_is_flagged	total_claim_amount
repairer_nb_claims_total	0,67	0,6	0,45	0
repairer_nb_fraud_confirmed	0,7	0,85	0,78	0
claim_amount	0	0,01	0	0,77

TABLEAU 4.6 – Intensité d'association entre variables quantitatives $\times$ qualitatives ⁷

Chaque matrice d'association mobilise une mesure selon la nature des variables croisées : le coefficient de Pearson pour les couples de variables quantitatives, le V de Cramér pour les couples de variables qualitatives, et le rapport

⁷ La variable « $\text{total_claim_amount}$ » est ici traitée comme une variable qualitative après avoir subi un regroupement en classes (cf. section 4.5.3).

À noter que les matrices 4.4, 4.5 et 4.6 sont des extraits des matrices totales qui sont disponibles en annexe D.

de corrélation η^2 pour les couples de variables mixtes.

Parmi les variables quantitatives, mesurées par le coefficient de Pearson, les corrélations les plus fortes s'observent pour :

- « *repairer_nb_claims_total* » et « *repairer_nb_fraud_confirmed* » (0,72).

Les autres variables quantitatives présentent des corrélations nettement plus faibles entre elles.

Parmi les variables qualitatives, les corrélations les plus fortes mesurées par le V de Cramér sont :

- « *incident_state* » et « *incident_zip_fraud_rate* » (1), sans surprise puisque à chaque état est associé un taux de fraude ;
- « *repairer_avg_invoice_vs_market* » et « *repairer_fraud_rate* » (0,97), qui témoigne de la corrélation importante entre la fraude et la surestimation du prix des réparations lors d'un sinistre.

Enfin, pour les couples de variables **quantitatives** × **qualitatives**, les corrélations les plus fortes sont :

- « *repairer_nb_claims_total* » et « *repairer_fraud_rate* » (0,67) ;
- « *repairer_nb_fraud_confirmed* » et « *repairer_fraud_rate* » (0,70) ;
- « *repairer_nb_fraud_confirmed* » et « *repairer_avg_invoice_vs_market* » (0,85) ;
- « *repairer_nb_fraud_confirmed* » et « *repairer_is_flagged* » (0,78) ;
- « *claim_amount* » et « *total_claim_amount* » (0,77).

Ces redondances signalent un risque de multicolinéarité qu'il conviendra de traiter en amont de la modélisation, par exemple en ne conservant qu'une seule de ces variables ou en construisant un indicateur synthétique, afin de préserver la stabilité et l'interprétabilité des modèles.

Le retrait des variables fortement corrélées répond à un enjeu méthodologique important. Lorsque deux variables explicatives sont redondantes, elles introduisent un phénomène de multicolinéarité qui peut fragiliser le modèle de plusieurs manières.

Sur les modèles de type régression ou *scoring*, la multicolinéarité rend l'estimation des coefficients instable : de faibles variations dans les données peuvent entraîner des changements importants dans les pondérations attribuées à chaque variable, rendant leur interprétation peu fiable, voire trompeuse. Sur l'ensemble des modèles, elle nuit également à la parcimonie et à la lisibilité du dispositif, sans améliorer le pouvoir prédictif puisque l'information est déjà présente. Éliminer ces redondances en amont permet donc de gagner en robustesse, en stabilité et en interprétabilité, sans perte d'information significative.

4.5.4.1 Élimination des variables corrélées

À l'issue de l'analyse des matrices d'association, l'outil offre à l'utilisateur la possibilité d'écarter les variables jugées redondantes. Cette étape de sélection vise à ne conserver, parmi les variables candidates, que celles qui apportent une information « propre » et non déjà captée par d'autres variables par ailleurs, afin de ne pas dégrader la qualité des modèles construits par la suite.

Sur les 53 variables initialement disponibles (24 issues de la base source et 29 issues de l'enrichissement), 39 ont finalement été retenues pour la modélisation.

En effet, 9 variables ont été écartées **automatiquement**⁸ par l'outil, qui les a identifiées comme non pertinentes pour la prédiction.

Il s'agit :

- Des 6 variables d'identifiants uniques (id), dépourvus de tout pouvoir prédictif généralisable (*policy_id*, *insured_id*, *repairer_id*, *third_party_id*, *witness_id*, *vehicle_id*).
- De la variable « *incident_date* », étant donné qu'elle présentait un nombre trop important de modalités distinctes et qu'elle est de plus exploitée autrement au travers de deux autres variables. En effet, les variables « *incident_is_weekend* » et « *incident_is_holiday* » permettent de déduire deux informations intéressantes à partir de la date de survenance du sinistre, à savoir si ce dernier a eu lieu un *week-end* ou un jour de congés. Ces deux variables sont totalement corrélées à la variable date du sinistre puisqu'elles en découlent. Il est donc justifié de la supprimer.
- De la variable « *incident_city* », car très fortement corrélée avec la variable « *incident_state* » (État du sinistre) qui est de plus une variable à champ texte libre (admettant donc un très grand nombre de modalités).
- De la variable « *fraud_reported* », qui constitue la grandeur à prédire et ne peut donc servir de variable explicative.

En plus de ces 9 variables supprimées par l'Agent, l'utilisateur peut ensuite décider d'une part s'il est d'accord ou non avec le choix réalisé par l'agent mais également de choisir d'en supprimer éventuellement d'autres en les sélectionnant manuellement.

Nous décidons, suite aux résultats des analyses de corrélation, de supprimer les variables suivantes :

- « *repairer_nb_fraud_confirmed* » car corrélée à « *repairer_fraud_rate* » ;
- « *repairer_nb_claims_total* » car corrélée à « *repairer_fraud_rate* » ;
- « *claim_amount* » car corrélée à « *total_claim_amount* » ;
- « *incident_state* » car corrélée à « *incident_zip_fraud_rate* » ;
- « *repairer_fraud_rate* » car corrélée à « *repairer_avg_invoice_vs_market* ».

8. Ce choix automatique de l'outil met en avant la puissance des outils d'IA qui appliquent les « bons réflexes » et permettent à l'utilisateur d'éviter certains oublis.

Cochez les variables à retirer de la modélisation

5 variables sélectionnées · 39 variables conservées sur 44.

☐ authorities_contacted Qualitative	☐ bodily_injuries Quantitative
☒ claim_amount Quantitative	☐ collision_type Qualitative
☐ declaration_channel Qualitative	☐ incident_hour_of_the_day Qualitative
☐ incident_is_holiday Qualitative	☐ incident_is_weekend Qualitative
☐ incident_severity Qualitative	☒ incident_state Qualitative
☐ incident_type Qualitative	☐ incident_zip_fraud_rate Qualitative

Récapitulatif avant confirmation

Cette confirmation est définitive pour ce run : les variables retirées ne seront plus utilisées dans les étapes suivantes et aucun retour ne sera possible.

VARIABLES RETIRÉES (5)

claim_amount
incident_state
repairer_fraud_rate
repairer_nb_claims_total
repairer_nb_fraud_confirmed

VARIABLES CONSERVÉES (39)

authorities_contacted · bodily_injuries · collision_type · declaration_channel · incident_hour_of_the_day · incident_is_holiday · incident_is_weekend · incident_severity · incident_type · incident_zip_fraud_rate · injury_claimed_without_medical · insured_address_changes_12m · insured_age · insured_claim_amount_history · insured_days_since_last_claim · insured_education_level · insured_hobbies · insured_nb_past_claims · insured_nb_past_fraud · insured_nb_policies_active · insured_occupation · insured_sex · insured_third_party_known · nb_amendments_declaration · number_of_vehicles_involved · police_report_available · policy_age_at_incident_days · policy_annual_premium · policy_deductible · policy_state · repairer_avg_invoice_vs_market · repairer_is_flagged · third_party_nb_past_incidents · total_claim_amount · vehicle_age_years · vehicle_market_value · vehicle_nb_past_claims · vehicle_overvalue_ratio · witnesses

FIGURE 4.11 – Extrait de la sélection de la suppression de variables corrélées

Cette sélection, réalisée en amont de la modélisation, garantit que seules les variables réellement porteuses d'information alimentent les modèles.

4.5.5 Analyse du coût moyen de la fraude

Après avoir analysé la fréquence de fraude, une étude est réalisée sur le coût moyen des dossiers frauduleux (représenté par la variable « *total_claim_amount* »).

Analyse du coût moyen




FIGURE 4.12 – Coût moyen des sinistres selon le statut de fraude

Ces indicateurs nous permettent de faire un constat contre-intuitif : la fraude ne concerne pas les sinistres les plus coûteux. Le coût moyen des 3 440 dossiers frauduleux s'élève à 12 675,09 USD, soit un montant quasiment identique, et même légèrement inférieur, au coût moyen global (12 757,74 USD). **Autrement dit, les dossiers frauduleux ne se distinguent pas par des montants réclamés plus élevés que les dossiers sains.**

Ce résultat, à première vue surprenant, a une implication importante : **le montant du sinistre n'est pas, à lui seul, un signal permettant d'orienter la détection vers les fraudeurs.** Une stratégie de contrôle qui se concentrerait uniquement sur les sinistres les plus coûteux passerait donc à côté d'une large part de la fraude.

C'est précisément ce qui justifie le recours à une approche multivariée : la fraude se révèle non pas par le montant réclamé, mais par la combinaison de signaux comportementaux et déclaratifs identifiés précédemment (antécédents, cohérence de la déclaration, environnement du sinistre). L'objectif du mémoire étant de modéliser une **probabilité de fraude** (variable cible binaire), l'étude du coût moyen n'entre à priori pas directement dans la spécification du modèle. Néanmoins, elle conserve une justification importante dans un mémoire actuariel : **la justification de l'enjeu économique du modèle.** En effet, modéliser une probabilité de fraude n'a de valeur opérationnelle que si la fraude représente un enjeu financier significatif.

Le gain unitaire espéré d'une fraude détectée correspond au coût moyen d'un sinistre frauduleux, c'est-à-dire au montant que l'assureur évite de verser indûment en écartant le dossier. On fait ici l'hypothèse qu'un sinistre identifié comme frauduleux est intégralement rejeté ; dans le cas d'une simple exagération, seul le surcoût frauduleux serait récupéré. Cela pose le cadre économique qui légitime la démarche de modélisation.

Chapitre 5

Création du modèle de détection de fraude : Étapes 4 et 5

Dans la suite de l'analyse, l'étude se concentre sur trois approches de modélisation couramment utilisées en détection de fraude :

- Un **modèle de *scoring* en points** (interprétable et proche des pratiques actuarielles traditionnelles) ;
- Un **arbre de décision** (permettant de capturer des effets non linéaires et des interactions) ;
- Un **modèle de type Gradient *Boosting*** (plus performant en général grâce aux méthodes d'ensemble).

L'objectif est d'évaluer et de comparer leur **qualité de prédiction** à partir de métriques adaptées, tout en tenant compte des enjeux d'interprétabilité et d'implémentation opérationnelle.

Dans ce cadre, l'outil développé propose dans un premier temps de sélectionner un partitionnement de la base globale de manière à définir deux jeux de données :

- Un jeu qui servira de base d'apprentissage ;
- Un jeu qui servira de base de test du modèle créé.

Le choix du partitionnement est laissé à l'utilisateur, avec une valeur par défaut de départ à 80/20 (ratio base d'apprentissage/base de test) correspondant aux proportions généralement utilisées lors de la mise en place de modèles sur ce type de volumétrie de données.

Répartition entraînement / test

Le fichier contient **30000 lignes** — taux de fraude observé : **11.5%**. Comment voulez-vous répartir le jeu d'entraînement et le jeu de test ?

Méthode de répartition

Le split est stratifié sur la variable cible : le taux de fraude est préservé dans les deux jeux.

80%

20%

Glissez la barre, ou modifiez directement le nombre de lignes ci-dessous.

● Entraînement

24000

lignes

→

● Test

6000

lignes

FIGURE 5.1 – Choix du partitionnement de la base

Pour notre exemple, une partition **80 / 20** est retenue : 80 % des observations (24 000 lignes) constituent le jeu d'apprentissage-validation, et les 20 % restants (6 000 lignes) forment le jeu de test final, mis de côté dès le départ et non utilisé pendant la phase de construction.

Ce partitionnement est **stratifié sur la variable cible**, ce qui signifie que le taux de fraude observé (11,5 %) est préservé à l'identique dans les deux jeux. Cette précaution est essentielle sur des données déséquilibrées : un tirage purement aléatoire pourrait sur- ou sous-représenter les cas de fraude dans l'un des jeux, faussant l'apprentissage comme l'évaluation.

Sur la portion d'apprentissage-validation (80 %), une **validation croisée à 5 plis** est appliquée pour la sélection des hyperparamètres. Le principe consiste à diviser ces données en cinq sous-ensembles : le modèle est entraîné à cinq reprises, chaque fois sur quatre plis et évalué sur le cinquième, de sorte que chaque observation serve tour à tour à l'entraînement et à la validation. Cette approche fournit une estimation plus robuste de la performance et limite le risque de sur-ajustement (*overfitting*) au moment du choix des paramètres.

Enfin, le jeu de test (20 %), resté totalement isolé, permet une **évaluation finale en conditions réelles** : les métriques de performance (AUC, Gini, KS, rappel, précision etc.) sont calculées sur des données que le modèle n'a jamais vues, garantissant une mesure honnête de sa capacité de généralisation.

Une fois le partitionnement entraînement/test choisi, les trois modélisations sont lancées et le résultat de chacune d'elles s'affiche sur simple clic, permettant ainsi une comparaison entre modèles.

Résultats des 3 modèles

Les trois modèles ont été entraînés sur vos données. Consultez leurs résultats avant de retenir une configuration.

CHOISISSEZ LE MODÈLE À VISUALISER

 Scoring en points 

 Arbre de décision

 Gradient Boosting

FIGURE 5.2 – Affichage de l'Agent IA pour le choix de modélisation (à renseigner par l'utilisateur)

Une présentation et analyse des résultats de chaque modèle est proposée ci-dessous.

5.1 Scoring en points

Sur la base de sinistre transmise, l'Agent IA va à présent appliquer un *modèle de scoring en points*.

 Scoring en points 

À noter que pour faciliter l'interprétation des scores obtenus et leur passage en probabilité de fraude, nous avons demandé à l'agent de normaliser le barème de score de manière à ce que l'ensemble des combinaisons possibles soient comprises entre 0 et 1000 points.

5.1.1 Résultats du modèle

La construction d'un modèle de *scoring* performant repose en amont sur une sélection rigoureuse des variables explicatives. Cette étape poursuit un double objectif : d'une part, retenir uniquement les variables porteuses d'un pouvoir discriminant réel vis-à-vis de la variable cible (l'occurrence de fraude), afin de maximiser la performance prédictive du modèle ; d'autre part, garantir la parcimonie du barème, condition essentielle à sa lisibilité, à son appropriation par les gestionnaires sinistres et à sa maintenabilité dans le temps.

Un barème surchargé de critères, même statistiquement significatifs, perd en effet en opérationnalité et devient difficilement auditable.

Une fois la phase de sélection des variables terminée, un nombre de points est affecté à chaque modalité ou situation à risque. Plus une modalité est associée historiquement à un niveau élevé de fraude, plus le nombre de points attribué est important. À l'inverse, les situations jugées peu suspectes reçoivent peu de points, voire aucun.

Le *scoring* en points repose donc sur une logique additive : chaque dossier cumule des points selon les caractéristiques qu'il présente. Le barème reflète ainsi la contribution relative de chaque critère au risque de fraude.

En sortie du modèle, on obtient les indicateurs suivants :

- Le nombre de variables retenues dans le modèle de *scoring* (20) ;
- Pour chaque variable, le nombre de points associé à chaque modalité ;
- « Effectif train » correspondant au nombre de lignes de chaque modalité au sein de la base d'apprentissage ;
- « Taux de fraude train », le taux de fraude observé sur la base d'apprentissage ;
- Le WOE (*Weight of Evidence*), qui correspond au *log-odds* de la modalité, recentré sur le *log-odds* global :

$$\text{WOE} = \ln(\text{odds}_{\text{modalité}}) - \ln(\text{odds}_{\text{global}}) \quad (5.1)$$

Par exemple, pour la variable « *repairer_avg_invoice_vs_market* », sur la modalité « *Off market* », le taux global de fraude est de $2\,752/24\,000 \approx 11,5\%$, donc $\ln(0,48/0,52) - \ln(0,115/0,885) = 1,96$. Un WOE positif signifie donc « plus risqué que la moyenne du portefeuille », négatif « moins risqué », et 0 correspond exactement au risque moyen. C'est la variable explicative réellement injectée dans la régression : chaque modalité est remplacée par son WOE.

- L'*Information Value* (IV) : c'est une mesure de pouvoir discriminant univarié, indépendante du modèle final, donnée par :

$$\text{IV} = \sum_{\text{modalités}} (\% \text{ fraudes} - \% \text{ non-fraudes}) \times \text{WOE} \quad (5.2)$$

Par exemple, sur la variable « *repairer_avg_invoice_vs_market* » : $(0,661 - 0,953) \times (-0,366) + (0,339 - 0,048) \times 1,965 = 0,680$.

Valeur de l'IV	Interprétation
< 0,02	Inutile
0,02 – 0,1	Faible
0,1 – 0,3	Moyen
0,3 – 0,5	Fort
> 0,5	À examiner

TABLEAU 5.1 – Grille d'interprétation de l'IV

- Le coefficient logistique : c'est le coefficient de la variable WOE-isée dans la régression multivariée. Sa référence naturelle est 1 : si une variable était seule dans le modèle, son coefficient vaudrait mécaniquement 1 puisque le WOE est déjà exprimé en *log-odds*. Les valeurs retournées par le modèle (ici 0,997 / 0,980 / 0,980 / 0,904) sont donc à lire comme un facteur d'atténuation. S'il est proche de 1, cela signifie que la variable apporte une information peu redondante avec les autres. À noter que le 0,904 de « *vehicle_market_value* » indique un léger recouvrement avec d'autres variables du modèle. Les signaux d'alerte seraient un coefficient très inférieur à 1 (redondance forte), supérieur à 1,3–1,5, ou négatif, ce dernier cas traduisant une inversion de sens due à de la colinéarité.
- La stabilité de la variable : elle représente la fréquence de sélection de la variable sur des rééchantillonnages (*bootstrap* ou validation croisée). La valeur 1 indique que la variable est systématiquement retenue.

Grille détaillée — 20 variables retenues sur 39 candidates

repairer_avg_invoice_vs_market Qualitative Points : 0 → 108 IV : 0,680 Stabilité : 1,00 Coefficient logistique : 0,997					
MODALITÉ	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
On market (≤ 1,15)	0	Diminue le risque	22 056 (92 %)	8,2 % (1 818)	-0,366
Off market (> 1,15)	108	Augmente le risque	1 944 (8 %)	48,0 % (934)	1,965

insured_claim_amount_history Qualitative Points : 0 → 87 IV : 0,482 Stabilité : 1,00 Coefficient logistique : 0,980					
MODALITÉ	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
≤ 30 000 USD	0	Diminue le risque	21 766 (91 %)	8,6 % (1 881)	-0,314
> 30 000 USD	87	Augmente le risque	2 234 (9 %)	39,0 % (871)	1,596

insured_nb_past_fraud Quantitative Points : 0 → 74 IV : 0,421 Stabilité : 1,00 Coefficient logistique : 0,980					
INTERVALLE	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
< 1	0	Diminue le risque	20 950 (87 %)	8,5 % (1 773)	-0,337
≥ 1	74	Augmente le risque	3 050 (13 %)	32,1 % (979)	1,295

vehicle_market_value Qualitative Points : 0 → 83 IV : 0,312 Stabilité : 1,00 Coefficient logistique : 0,904					
MODALITÉ	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
≤ 5 500 USD	83	Augmente le risque	1 451 (6 %)	22,6 % (328)	0,814
]5 500 ; 28 000] USD	57	Augmente le risque	16 126 (67 %)	13,5 % (2 175)	0,185
> 28 000 USD	0	Diminue le risque	6 423 (27 %)	3,9 % (249)	-1,165

FIGURE 5.3 – Extrait de la grille d'attribution des points du modèle de *scoring* en points

Les résultats du modèle de *scoring* permettent de distinguer 3 catégories d'indicateurs :

- En premier lieu, les signaux forts correspondent aux variables les plus discriminantes, historiquement associées à un sur-risque de fraude et donc fortement pondérées.
 - Le ratio facture/marché du réparateur domine le barème : une facture supérieure de 15 % au prix de marché (« *off market* ») atteint un taux de fraude de 48,0 % (contre 11,5 % en moyenne) et se voit attribuer le maximum de 108 points, pour une IV de 0,680.
 - Viennent ensuite l'historique des montants réclamés par l'assuré (un cumul supérieur à 30 000 USD porte le taux de fraude à 39,0 % et vaut 87 points) ;
 - Les antécédents de fraude de l'assuré (au moins une fraude passée : 32,1 % de fraude, 74 points) ;
 - Et la valeur marchande du véhicule (un véhicule de moins de 5 500 USD atteint 22,6 % de fraude, 83 points).

Ces quatre variables concentrent l'essentiel du pouvoir discriminant du modèle.

- En deuxième lieu, les signaux moyens sont des indicateurs plus diffus, moins déterminants pris isolément, mais dont le cumul affine sensiblement l'évaluation du risque. On y retrouve le nombre d'amendements à la déclaration (jusqu'à 67 points pour au moins trois modifications, 26,3 % de fraude), l'âge du véhicule (49 points au-delà de neuf ans), le nombre de sinistres passés du véhicule comme de l'assuré, le nombre de contrats actifs, le délai depuis le dernier sinistre (64 points en deçà de 800 jours) ou encore les changements récents d'adresse. Chacun pèse modérément, mais leur accumulation sur un même dossier peut faire fortement grimper le score final.
- En troisième lieu, la logique du barème intègre des modalités protectrices, auxquelles zéro ou très peu de points sont attribués afin d'éviter une surévaluation du risque. Ainsi, un dossier où la police a été contactée ne reçoit aucun point, contre 60 points en l'absence de toute autorité ; la présence d'au moins un témoin annule les 38 points attribués à un dossier sans témoin ; de même, un véhicule de plus de 28 000 USD, un contrat de plus de trois ans ou un assuré de plus de 24 ans ne contribuent pas au score. Ces situations, statistiquement associées à un moindre risque de fraude, viennent naturellement contrebalancer les signaux aggravants.
- Enfin, on notera la présence de variables faiblement discriminantes conservées dans le barème mais au poids marginal, comme la profession de l'assuré (IV de 0,022) ou le canal de déclaration : elles n'apportent qu'un ajustement mineur au score et confirment, à l'inverse, la prééminence des signaux liés au réparateur et aux antécédents de l'assuré.

Dans l'ensemble, ce barème repose sur une logique transparente et interprétable, combinant expertise métier et observations empiriques, afin de produire un score global reflétant le niveau de suspicion de fraude associé à chaque dossier.

On peut également s'intéresser à l'importance relative des variables dans le modèle de prédiction de fraude, qui doit intuitivement être liée à l'attribution des points dans le modèle de *scoring* :

Poids des variables dans la grille

Part de l'amplitude totale de points attribuable à chaque variable : plus la barre est longue, plus la variable peut faire varier le score final.




FIGURE 5.4 – Hiérarchie de l'importance globale des variables dans le modèle de *scoring* en points

On remarque que l'importance des variables est ici relativement répartie, mais avec une hiérarchie nette : le pouvoir explicatif s'étale de 2 % à 11 %, sans qu'aucune variable n'écrase les autres, tout en laissant émerger un petit groupe de signaux dominants.

En tête figure le ratio facture/marché du réparateur (11 %), suivi de l'historique des montants réclamés par l'assuré (9 %), de la valeur marchande du véhicule (8 %), du nombre de fraudes passées et du nombre d'amendements à la déclaration (7 % chacun). À l'autre extrémité, des variables comme la profession de l'assuré, le canal de déclaration ou le ratio de surévaluation ne pèsent chacune que 2 %.

Cette hiérarchie relativement douce est cohérente avec la nature même du *scoring* en points : reposant sur une agrégation additive de nombreux critères, le modèle répartit le risque sur un large ensemble de signaux plutôt que de le concentrer sur quelques-uns. C'est là une force autant qu'une caractéristique : le modèle ne dépend pas excessivement d'une seule variable, ce qui le rend robuste et stable (son PSI très faible et l'absence de surapprentissage le confirment) et lui permet de conserver sa pertinence même lorsqu'une variable est absente d'un dossier de sinistre.

On note enfin que les variables présentant les plus fortes importances sont aussi celles susceptibles d'attribuer le plus grand nombre de points dans le barème : le ratio facture/marché, qui domine ce classement, est également la variable la mieux dotée de la grille (jusqu'à 108 points). Cette cohérence entre poids dans la grille et importance dans le score global est logique, puisque l'importance mesure précisément la part de l'amplitude totale de points qu'une variable peut faire varier.

Ces observations sont en accord avec l'étude de fréquence réalisée en amont du lancement du modèle (cf. 4.5.2).

Le modèle est ensuite appliqué à l'ensemble de la base sinistres : pour chaque dossier, les points associés aux caractéristiques observées sont additionnés, produisant un score global de suspicion qui synthétise le niveau de risque du sinistre. Plus ce score est élevé, plus le dossier présente un profil proche de celui des sinistres historiquement identifiés comme frauduleux.

Une fois les scores calculés, il est important de regarder leur distribution par classe (histogrammes superposés) de fraudeurs/non fraudeurs : visuellement, plus les deux distributions sont **séparées**, meilleur est le modèle.

Distribution des scores par classe (jeu de test : 6 000 sinistres)

Pour chaque tranche de score, ce graphique superpose (en transparence) le nombre de sinistres frauduleux et non frauduleux du jeu de test. Plus les deux distributions se chevauchent, plus il est difficile pour le modèle de séparer les deux classes à ce niveau de score.




FIGURE 5.5 – Distribution des scores par classe (fraudeur/non fraudeur)

On observe sur la figure 5.5 que les sinistres frauduleux sont principalement concentrés sur la droite du graphique, correspondant aux scores élevés, à contrario des sinistres non frauduleux qui sont concentrés à gauche.

L'analyse de la sortie du modèle ne se limite pas à la distribution des scores par classe. Il convient également de comparer les niveaux de score observés entre les sinistres frauduleux et les sinistres non frauduleux. Si le modèle est pertinent, les dossiers frauduleux doivent, en moyenne, présenter des scores plus élevés. Cette étape permet d'évaluer la capacité du *scoring* à séparer les deux populations et à hiérarchiser le risque de fraude de manière cohérente.

Taux de fraude avérée par tranche de score (jeu de test : 6 000 sinistres)




FIGURE 5.6 – Taux de fraude avérée par tranche de score de suspicion

À noter que les figures 5.5 et 5.6 mesurent la qualité prédictive sur le jeu de test, c'est-à-dire sur des sinistres dont le modèle n'a pas eu connaissance lors de sa phase d'apprentissage. Les indicateurs reflètent donc sa capacité de généralisation à de nouveaux dossiers, et non une simple performance sur les données d'entraînement.

La figure 5.6 met ici en évidence une relation croissante par paliers entre le score de suspicion et le taux de fraude avérée, ce qui confirme la capacité du modèle à discriminer efficacement les dossiers selon leur niveau de risque : plus le score est élevé, plus la probabilité de fraude augmente.

À partir de la distribution des scores et de la capacité discriminante du modèle, des seuils opérationnels peuvent être définis. Ces seuils permettent de transformer un score continu en règle de gestion. Par exemple, un score faible peut correspondre à une absence de recherche complémentaire, un score intermédiaire à une investigation légère, et un score élevé à une recherche approfondie. Le choix de ces seuils repose sur un arbitrage actuariel et opérationnel entre le coût des contrôles, le nombre de faux positifs acceptables et le gain attendu en matière de fraude détectée.

Dans notre exemple, on observe une première cassure autour de 350 points, à partir de laquelle le taux de fraude avérée augmente légèrement : ce premier changement de régime justifie le déclenchement d'une investigation légère. Une seconde cassure apparaît autour de 450 points, où le taux de fraude avérée croît nettement, seuil à partir duquel une investigation approfondie se justifie.

Autrement dit, les règles d'investigation suivantes peuvent être mises en place :

- Score compris entre 0 et 350 : pas d'investigation
- Score compris entre 350 et 450 : investigation légère
- Score supérieur à 450 : investigation poussée

Enfin, si l'on considère les sinistres classifiés comme nécessitant une investigation poussée comme « frauduleux » (score supérieur à 450), le score étant construit sur une échelle de 0 à 1 000 points, un seuil de 450 points équivaut à 45 % de l'échelle ; c'est cette normalisation qui permet d'exprimer le seuil de décision en pourcentage dans la matrice de confusion. Il convient toutefois de souligner qu'un score normalisé n'est pas, en lui-même, une probabilité de fraude : un score de 45 % signifie que le dossier se situe à 45 % de l'échelle de points, et non qu'il présente 45 % de chances d'être frauduleux (cf. figure 5.6 pour la correspondance entre score et taux de fraude observé). Dans notre choix graphique ci-dessus, on obtient la matrice de confusion suivante :

Matrice de confusion Seuil : 45%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	294	394	688
Réel Non fraude	65	5247	5312
Total	359	5641	6000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.7 – Matrice de confusion du modèle de *scoring* en points pour un seuil de 45 %

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $5\,247/5\,312 = 98,77\%$;
- Le taux de fraudes détectées (prédit fraude / réel fraude) : $294/688 = 42,73\%$;
- Le taux de sinistres signalés frauduleux (prédit fraude / total) : $359/6\,000 = 5,98\%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une **optimisation**

du seuil afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.1.2 Qualité du modèle obtenu

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles présentés en section 3.7.

Pour commencer, un point de vigilance mérite d'être souligné concernant le **choix du seuil de décision**. Le modèle ne restitue pas une classification binaire mais un score continu ; il convient donc de fixer un seuil au-delà duquel un sinistre est considéré comme frauduleux. Le seuil de 45 % (450 points), retenu par méthode graphique, se révèle en réalité trop élevé pour des données fortement déséquilibrées : avec seulement 11,5 % de fraudes, la majorité des scores se concentrent sous ce seuil, si bien que le modèle ne détecte que 42,7 % des fraudes réelles.

Pour corriger ce biais, on recourt à l'**indice de Youden**, défini comme :

$$J = \text{Sensibilité} + \text{Spécificité} - 1 \quad (5.3)$$

Cet indice identifie le seuil qui maximise l'écart entre le taux de vrais positifs (fraudes correctement détectées) et le taux de faux positifs (non-fraudes signalées à tort) ; il correspond graphiquement au point de la courbe ROC le plus éloigné de la diagonale du hasard, c'est-à-dire celui où le modèle sépare le mieux les deux populations.

Appliqué à ce modèle, le seuil optimal est alors de 35 %.

Les résultats du modèle obtenus avec l'utilisation de ce seuil sont présentés ci-dessous :

Matrice de confusion Seuil : 35%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	527	161	688
Réel Non fraude	580	4732	5312
Total	1107	4893	6000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.8 – Matrice de confusion du modèle de *scoring* en points au seuil optimal (35 %)

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $4732/5312 = 89,08\%$;
- Le taux de fraudes détectées (prédit fraude / réel fraude) : $527/688 = 76,60\%$;
- Le taux de sinistres signalés frauduleux (prédit fraude / total) : $1107/6000 = 18,45\%$.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 18,45 % des sinistres, parmi lesquels 47,6 % sont réellement frauduleux, soit une densité de fraude environ 4,1 fois supérieure à celle d'un contrôle aléatoire.

L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :



FIGURE 5.9 – Synthèse des métriques de performance et de stabilité du modèle de *scoring* en points



FIGURE 5.10 – Courbe ROC et AUC correspondant au modèle de *scoring* en points

En retenant le seuil optimal de 35 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,917)** : excellente capacité de discrimination, très au-dessus du seuil de 0,8 considéré comme bon ; le modèle sépare efficacement fraudeurs et non-fraudeurs.

- **Gini (0,835)** : cohérent avec l'AUC, ce niveau traduit un pouvoir discriminant élevé, largement supérieur aux standards habituels en assurance.
- **KS (0,666)** : bien au-delà du seuil de 0,4 jugé satisfaisant (cf. section 3.7), il confirme une nette séparation entre les distributions de scores des deux populations.
- **Précision (47,6 %)** : parmi les dossiers signalés comme frauduleux, un peu moins d'un sur deux l'est réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (76,6 %)** : le modèle détecte près de quatre fraudes sur cinq, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (58,7 %)** : compromis honnête entre précision et rappel, en nette amélioration par rapport au seuil graphique de 45 %.
- **Accuracy (87,6 %)** : taux de bonnes classifications élevé, à interpréter toutefois avec prudence sur données déséquilibrées où cet indicateur est peu informatif à lui seul.
- **Log-loss (0,2015)** : valeur faible, signe d'une bonne calibration des probabilités prédites.

Dans l'ensemble, le modèle présente d'excellents indicateurs de discrimination et de stabilité; le seul point de vigilance concerne la précision modérée, contrepartie assumée d'un rappel volontairement élevé.

Ces résultats sont cohérents avec la nature du modèle : sa simplicité et sa parcimonie le rendent naturellement robuste et peu sujet au surajustement.

Enfin, concernant les indicateurs de robustesse et stabilité du modèle, les résultats suivants sont obtenus :

- **Backtesting (écart AUC *train/test* de 0,003)** : écart quasi nul entre apprentissage et test, confirmant l'absence de surapprentissage et une bonne capacité de généralisation.
- **PSI (0,0026)** : très inférieur à 0,1, il atteste d'une excellente stabilité de la distribution des scores.




FIGURE 5.11 – Indicateurs de robustesse et stabilité du modèle de *scoring* en points

5.1.3 Limites et précautions d'interprétation

Malgré sa simplicité et son interprétabilité, le modèle de *scoring* en points présente plusieurs limites dont il convient de tenir compte.

En premier lieu, le principe d'additivité et l'absence d'interactions. En effet, le score suppose que les contributions des variables s'additionnent dans l'échelle des *log-odds*. Or la fraude se reconnaît souvent à des combinaisons de signaux (contrat récent + sinistre de nuit + absence de tiers identifié + véhicule en fin de vie par exemple). Chaque élément pris isolément est banal, c'est le croisement qui est suspect. Il faut créer les interactions à la main, donc les avoir devinées à l'avance.

De plus, il existe une perte d'information par le *binning*. En effet, le découpage en classes lisse les non-linéarités mais détruit de la granularité et introduit des effets de seuil : deux dossiers quasi identiques de part et d'autre d'une frontière (ex. 31 jours vs 29 jours après souscription par exemple) reçoivent des points différents. Les bornes sont aussi une source de surapprentissage si elles sont optimisées sur les mêmes données que les poids.

Ce type de modèle est également **sensible aux biais présents dans les données historiques**, notamment les biais de sélection liés aux fraudes détectées (toutes les fraudes ne sont pas observées) et les biais d'investigation (certains dossiers étant plus contrôlés que d'autres). Ces biais peuvent affecter la cohérence du score et accentuer les défauts de classement.

Pire encore, il existe **une limite dynamique, liée au contexte *adversarial***, c'est-à-dire le fait que les fraudeurs essaient toujours de « faire mieux » pour ne pas être identifiés. Les fraudeurs s'adaptent. Une grille figée se dégrade plus vite qu'un modèle de risque classique, et si elle fuit en interne ou vers un intermédiaire, elle devient contournable point par point. Il faudrait alors un *backtesting* rapproché et non pas un suivi de dérive ou une simple révision annuelle.

Ainsi, bien que le *scoring* en points constitue un outil robuste et interprétable, il doit être utilisé avec prudence, notamment lorsqu'il s'agit de hiérarchiser finement le risque de fraude ou d'interpréter le score comme une mesure probabiliste. Un suivi régulier de la performance (courbes de gains, *lift*, analyse par déciles) est nécessaire pour s'assurer que le modèle conserve une capacité de discrimination cohérente dans le temps.

5.2 Arbre de décision

Cette section présente l'utilisation de la modélisation via un « arbre de décision » pour estimer la probabilité de fraude.



Arbre de décision



5.2.1 Résultats du modèle

L'arbre construit admet les paramètres suivants :

- Profondeur : 7
- Feuilles : 68
- Nœuds internes : 67

L'arbre construit admet les caractéristiques structurelles suivantes :

- **La profondeur (7)**, qui correspond au nombre maximal de niveaux de décision successifs entre la racine

de l'arbre et ses feuilles. Concrètement, un dossier traverse au plus sept coupures successives (sept questions posées sur ses variables) avant d'aboutir à une prédiction. Cette profondeur a été volontairement limitée à 7 : un arbre trop profond mémoriserait les particularités de l'échantillon d'apprentissage (sur-apprentissage) et généraliserait mal à de nouveaux dossiers, tandis qu'un arbre trop peu profond serait incapable de capter les interactions entre variables. Une profondeur de 7 constitue ainsi un compromis entre pouvoir de discrimination et capacité de généralisation.

- **Les feuilles (68)** sont les nœuds terminaux de l'arbre, c'est-à-dire les points d'aboutissement où une décision finale est rendue (dossier classé frauduleux ou non). Chaque feuille regroupe un ensemble de dossiers partageant le même parcours de décision, et se voit attribuer une probabilité de fraude correspondant à la proportion de fraudes observée parmi les dossiers d'apprentissage qui y aboutissent. L'arbre compte ici 68 feuilles, soit 68 profils de risque distincts.
- **Les nœuds internes (67)** sont les points de décision situés avant les feuilles : à chaque nœud interne, l'arbre applique un test sur une variable (par exemple « le réparateur est-il signalé ? » ou « le montant réclamé dépasse-t-il un certain seuil ? ») qui oriente le dossier vers l'une ou l'autre branche. Le nombre de nœuds internes est directement lié au nombre de feuilles : un arbre binaire comportant 68 feuilles possède nécessairement 67 nœuds internes.




FIGURE 5.12 – Représentation visuelle de l'arbre avec un découpage sur une profondeur de 2 niveaux (7 niveaux au total)

On peut également s'intéresser à l'importance relative des variables dans le modèle de prédiction de fraude, qui doit intuitivement être liée à leur niveau et fréquence d'apparition dans l'arbre retourné :

Importance des variables dans l'arbre

Part des sinistres traités par les nœuds de décision utilisant chaque variable : plus la barre est longue, plus la variable structure l'arbre.




FIGURE 5.13 – Hiérarchie de l'importance globale des variables dans le modèle « arbre de décision »

Le profil d'importance de l'arbre de décision est ici assez réparti, sans variable dominante isolée. Trois critères arrivent en tête à égalité, chacun structurant 14 % des décisions de l'arbre : le ratio facture/marché du réparateur, l'historique des montants réclamés par l'assuré et le nombre de fraudes passées de l'assuré.

Ils sont suivis de près par l'âge du véhicule et la présence d'une blessure déclarée sans preuve médicale (12 % chacun), puis par le nombre d'amendements à la déclaration (10 %) et le nombre de sinistres passés du véhicule (9 %). Viennent ensuite la valeur marchande du véhicule (6 %) et le nombre de sinistres passés de l'assuré (4 %), avant que les dernières variables ne deviennent marginales : 2 % pour le nombre de contrats actifs de l'assuré, et 1 % pour le nombre de jours depuis le dernier sinistre, les autorités contactées et le nombre de véhicules impliqués.

On notera par ailleurs que les variables absentes de ce graphique présentent une importance nulle : elles n'ont tout simplement jamais été retenues comme critère de coupure par l'arbre. Ce phénomène s'explique par la structure même du modèle, dont la profondeur a été limitée à 7 niveaux : **avec seulement 67 nœuds internes disponibles, l'arbre concentre ses coupures sur les variables les plus discriminantes et n'a pas l'occasion de mobiliser les autres, qui restent inexploitées.**

Cette répartition indique que l'arbre construit ses coupures successives sur un ensemble relativement large de variables, plutôt que de faire reposer sa structure sur un ou deux critères dominants. On retrouve néanmoins **en tête les mêmes signaux forts que dans les autres modèles** (ratio facture/marché, historique de l'assuré, antécédents de fraude), ce qui rejoint directement l'analyse de fréquence de fraude où ces variables ressortaient déjà comme les plus discriminantes. La cohérence entre modèles renforce la confiance dans la pertinence de ces résultats.

Il faut toutefois noter que cette mesure d'importance renseigne sur la manière dont l'arbre est structuré (la part des sinistres traités par les nœuds utilisant chaque variable), et non directement sur sa capacité de généralisation. L'arbre de décision demeure en effet le modèle le plus exposé au surapprentissage, comme le montre l'écart un peu plus marqué entre son AUC d'entraînement et son AUC de validation (cf. plus bas) : sa structure s'ajuste finement aux données observées, au risque de manquer de robustesse sur les cas moins typiques.

L'agent retourne une représentation visuelle complète de l'arbre créé mais également d'autres graphiques¹, tels que la distribution des scores par classe (histogrammes superposés) : distribution du score des fraudeurs vs

1. Graphiques réalisés sur la base de l'échantillon test (6 000 lignes) et non sur l'échantillon d'apprentissage du modèle.

distribution du score des non-fraudeurs. Comme pour le modèle de *scoring* en points, visuellement, plus les deux distributions sont **séparées**, meilleur est le modèle.

Distribution des scores par classe (jeu de test : 6 000 sinistres)

Pour chaque tranche de score, ce graphique superpose (en transparence) le nombre de sinistres frauduleux et non frauduleux du jeu de test. Plus les deux distributions se chevauchent, plus il est difficile pour le modèle de séparer les deux classes à ce niveau de score.




FIGURE 5.14 – Distribution des scores par classe avec un arbre de décision (fraudeur/non fraudeur)

On observe sur ce graphique que la proportion de sinistres frauduleux (en rouge) augmente progressivement avec la probabilité estimée : quasi nulle dans les tranches basses, elle devient majoritaire dans les tranches les plus élevées ([90-100 %]). Cette progression témoigne d'un pouvoir de discrimination réel, même si un chevauchement subsiste dans les tranches intermédiaires, et que l'on retrouve certaines fraudes avec des probabilités pourtant faibles, ce qui témoigne d'un défaut du modèle.

Comme pour le modèle de *scoring* en points, le second graphique retourné par l'agent est le taux de fraude avéré par tranche de probabilité en sortie de l'arbre. Si le modèle est pertinent, les dossiers frauduleux doivent, en moyenne, présenter des probabilités plus élevées. Cette étape permet d'évaluer la capacité de l'arbre à séparer les deux populations et à hiérarchiser le risque de fraude de manière cohérente.

Calibration arbre de décision : taux de fraude avérée par tranche de probabilité (jeu de test : 6 000 sinistres)



FIGURE 5.15 – Taux de fraude avérée par tranche de score de suspicion

La sortie issue de l'arbre de décision met en évidence une relation claire et structurée entre la probabilité de

fraude estimée par le modèle et le taux de fraude réellement observé. On observe une **progression à tendance croissante du taux de fraude** à mesure que la probabilité prédite augmente, ce qui traduit une bonne capacité du modèle à ordonner les dossiers selon leur niveau de risque. Les premières tranches de probabilité (faibles scores) présentent des taux de fraude très limités, tandis que les tranches les plus élevées concentrent une proportion significativement plus importante de fraudes, pouvant dépasser 75 %.

Cette montée progressive est particulièrement intéressante d'un point de vue opérationnel, car elle permet de **segmenter efficacement les dossiers** et de prioriser les investigations sur les cas les plus risqués.

Par ailleurs, les caractéristiques du modèle (profondeur maximale de 7) traduisent un compromis maîtrisé entre complexité et capacité de généralisation. Le modèle reste suffisamment lisible tout en capturant des *patterns* discriminants. En synthèse, cette sortie confirme que l'arbre de décision fournit une **hiérarchisation cohérente et exploitable du risque de fraude**, avec une forte concentration des cas frauduleux dans les segments de probabilité élevée.

Si l'on s'appuie sur la distribution observée, l'idée est de définir des seuils qui maximisent la détection tout en restant opérationnellement soutenables (ne pas envoyer trop de dossiers en investigation lourde).

On peut distinguer **trois zones de risque** assez naturelles :

- **Zone faible (<35 %)** : le taux de fraude reste globalement modéré (inférieur à ~10 %). Ces dossiers peuvent être traités en flux standard, éventuellement avec des contrôles légers automatisés.
- **Zone intermédiaire (≈ 35 % à 90 %)** : on observe une tendance progressive du taux de fraude (avec cependant parfois des tranches de probabilité de fraude estimées supérieures, ayant un taux de fraude avérée inférieur, **ce qui témoigne d'un défaut de linéarité du modèle**). À ce niveau, on commence à avoir un enrichissement significatif en fraude, tout en conservant un volume de dossiers encore réalisable manuellement pour des contrôles ciblés (revue documentaire, demandes complémentaires, etc.).
- **Zone élevée (> 90 %)** : le taux de fraude devient nettement plus important avec environ deux sinistres sur trois identifiés comme frauduleux.

Autrement dit, les règles d'investigation suivantes peuvent être mises en place :

- Probabilité < 35 % : pas d'investigation
- Probabilité comprise entre 35 % et 90 % : investigation légère
- Probabilité supérieure à 90 % : investigation poussée

Enfin, si l'on considère les sinistres classifiés comme nécessitant une investigation poussée comme « frauduleux » (score supérieur à 90 dans notre choix graphique ici), on obtient la matrice de confusion suivante :

Matrice de confusion Seuil : 90%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	218	470	688
Réel Non fraude	106	5 206	5 312
Total	324	5 676	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.16 – Matrice de confusion du modèle arbre de décision pour un seuil de 90 %

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $5\,206 / 5\,312 = 98,00\%$;
- Le taux de fraudes détectées (prédit fraude / réel fraude) : $218 / 688 = 31,69\%$;
- Le taux de sinistres signalés frauduleux (prédit fraude / total) : $324 / 6\,000 = 5,40\%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une optimisation du seuil afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.2.2 Qualité du modèle obtenu

L'arbre de décision présente l'intérêt d'intégrer naturellement des interactions entre variables et des effets de seuil, ce qui permet une segmentation lisible du portefeuille : les feuilles les plus risquées de l'arbre concentrent un taux de fraude très élevé, proche de 80 %. Comme le montrent toutefois les indicateurs ci-dessous, ce gain sur les segments extrêmes ne se traduit pas par un meilleur pouvoir discriminant global que celui du *scoring* en points.

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles mis en place présentés en section 3.7.

Pour commencer, on cherche le seuil optimal à partir duquel on peut considérer que les sinistres sont frauduleux à l'aide de l'indicateur de Youden² (présenté en section 5.1.2). Pour le modèle utilisant des arbres de décision, le seuil optimal est de 45 %.

2. Notre agent intègre le calcul du seuil optimal dans son fonctionnement.

Matrice de confusion Seuil : 45%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	517	171	688
Réel Non fraude	1 001	4 311	5 312
Total	1 518	4 482	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.17 – Matrice de confusion du modèle arbre de décision au seuil optimal (45 %)

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $4\,311 / 5\,312 = 81,16\%$;
- Le taux de fraudes détectées (prédit fraude / réel fraude) : $517 / 688 = 75,15\%$;
- Le taux de sinistres signalés frauduleux (prédit fraude / total) : $1\,518 / 6\,000 = 25,30\%$.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 25,30 % des sinistres, parmi lesquels 34,1 % sont réellement frauduleux, soit une densité de fraude environ 3 fois supérieure à celle d'un contrôle aléatoire. L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :




FIGURE 5.18 – Synthèse des métriques de performance et de stabilité du modèle arbre de décision au seuil 45 %



FIGURE 5.19 – Courbe ROC et AUC pour le modèle arbre de décision

En retenant le seuil optimal de 45 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,845)** : capacité de discrimination acceptable, juste au-dessus du seuil de 0,8 considéré comme bon ; le modèle sépare plutôt efficacement fraudeurs et non-fraudeurs.
- **Gini (0,690)** : cohérent avec l'AUC, ce niveau traduit un bon pouvoir discriminant, légèrement supérieur aux standards habituels en assurance.
- **KS (0,564)** : supérieur au seuil de 0,4 jugé satisfaisant, il traduit une séparation réelle mais moins marquée que pour les deux autres modèles entre les distributions de scores des deux populations.
- **PR-AUC (0,518)** : à comparer à la prévalence de la fraude (11,5 %), qui constitue la valeur de référence d'un modèle aléatoire ; l'arbre fait ainsi environ 4,5 fois mieux que le hasard sur la classe d'intérêt.
- **Précision (34,1 %)** : parmi les dossiers signalés comme frauduleux, un peu plus d'un tiers le sont réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (75,1 %)** : le modèle détecte près de trois fraudes sur quatre, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (46,9 %)** : compromis correct entre précision et rappel.
- **Accuracy (80,5 %)** : taux de bonnes classifications élevé, à interpréter toutefois avec prudence sur données déséquilibrées où cet indicateur est peu informatif à lui seul.
- **Log-loss (0,4825)** : valeur modérée, traduisant une calibration des probabilités prédites correcte mais perfectible.

Enfin, concernant les indicateurs de robustesse et stabilité du modèle, les résultats suivants sont obtenus :

- **Backtesting** (écart AUC *train/test* de 0,039) : écart modéré entre apprentissage et test, signalant une tendance au surapprentissage mais restant contenue.
- **PSI** (0,0026) : très inférieur à 0,1, il atteste d'une excellente stabilité de la distribution des scores.

Ces résultats sont satisfaisants, mais restent moins bons que ceux du modèle de *scoring* en points.




FIGURE 5.20 – Indicateurs de robustesse et stabilité du modèle arbre de décision

5.2.3 Limites et précautions d'interprétation

Les arbres de décision se distinguent des modèles de *scoring* en points par leur capacité à modéliser des interactions entre variables et à capturer des effets de seuil. Toutefois, ils présentent également un certain nombre de limites qu'il convient de considérer dans une utilisation opérationnelle.

En premier lieu, les arbres de décision sont **intrinsèquement instables** : de légères variations dans les données d'apprentissage peuvent conduire à des structures d'arbre sensiblement différentes. Cette sensibilité aux données peut impacter la robustesse du modèle et limiter sa capacité de généralisation sur de nouveaux portefeuilles. En d'autres termes, un arbre construit sur un échantillon donné peut ne pas reproduire exactement les mêmes règles de décision sur un autre échantillon pourtant similaire.

Par ailleurs, bien que les arbres permettent de capter des relations non linéaires, ils reposent sur une logique de **partitionnement par seuils successifs**, ce qui introduit des discontinuités dans la modélisation. Deux dossiers très proches peuvent ainsi être classés dans des feuilles différentes et se voir attribuer des probabilités de fraude sensiblement différentes, ce qui peut nuire à la stabilité des prédictions.

En outre, les arbres de décision ont tendance à **sur-apprendre** les données d'entraînement, en particulier lorsque leur profondeur est élevée ou que les contraintes de construction ne sont pas suffisamment strictes. Ce phénomène se traduit par une excellente performance sur les données d'apprentissage, mais une dégradation sur des données nouvelles. Des techniques de régularisation (élagage, limitation de profondeur, nombre minimal d'observations par feuille) sont donc nécessaires pour contrôler cette complexité.

Un autre point de vigilance concerne la **calibration des probabilités**. Les probabilités issues des feuilles de l'arbre (basées sur des proportions observées) peuvent être peu fiables, notamment lorsque les feuilles contiennent un nombre limité d'observations. Cela peut compliquer l'interprétation directe des scores en termes de probabilité de fraude et la définition de seuils décisionnels optimaux.

Enfin, bien que les arbres soient souvent considérés comme interprétables, cette interprétabilité peut rapidement se dégrader dès que la structure devient plus complexe (multiplication des branches et des feuilles). La lecture globale du modèle peut alors devenir difficile, en particulier pour des utilisateurs non techniques.

Ainsi, les arbres de décision offrent un bon compromis entre performance et lisibilité, mais nécessitent un encadrement méthodologique rigoureux pour garantir leur stabilité, leur robustesse et leur capacité de généralisation.

5.3 Un modèle de Machine Learning : le Gradient Boosting

Enfin, le dernier modèle à être testé et dont les résultats sont présentés ci-dessous est un modèle de *machine learning* « Gradient Boosting ».



5.3.1 Résultats du modèle

Les paramètres du modèle de Gradient *Boosting* créé sont les suivants :



FIGURE 5.21 – Paramètres du modèle Gradient *Boosting*

- **Le nombre d'arbres (200)** correspond au nombre de modèles élémentaires construits successivement. Dans le *boosting*, chaque nouvel arbre corrige les erreurs résiduelles des précédents ; l'accumulation de 200 arbres permet d'affiner progressivement la prédiction.
- **La profondeur maximale (3)** limite chaque arbre à trois niveaux de coupures. Des arbres volontairement peu profonds (« arbres faibles ») sont caractéristiques du *boosting* : leur pouvoir prédictif individuel est limité, mais leur combinaison séquentielle produit un modèle performant tout en réduisant le risque de surapprentissage.
- **Le taux d'apprentissage (0,1)** pondère la contribution de chaque arbre au modèle final. Une valeur faible ralentit l'apprentissage mais le rend plus stable et plus robuste, chaque arbre n'apportant qu'une correction mesurée.
- **Le sous-échantillonnage (0,8)** signifie que chaque arbre est entraîné sur 80 % des observations, tirées aléatoirement. Cette introduction de hasard limite le surapprentissage et améliore la capacité de généralisation du modèle.

On peut également s'intéresser à l'importance relative des variables dans le modèle de prédiction de fraude :

Importance des variables

Contribution relative de chaque variable aux arbres du modèle de boosting, telle que rapportée par l'algorithme.




FIGURE 5.22 – Hiérarchie de l'importance globale des variables dans le modèle « Gradient *Boosting* »

Le Gradient *Boosting* présente un profil intermédiaire, plus équilibré que l'arbre mais toujours hiérarchisé. Le ratio facture/marché reste en tête avec 25 %, suivi de l'historique des montants réclamés (16 %) et du nombre de fraudes passées de l'assuré (13 %), mais le pouvoir explicatif est ensuite mieux réparti sur une gamme plus large de variables (valeur du véhicule, amendements, âge du véhicule...), chacune contribuant de façon non négligeable au modèle (entre 5 % et 8 %).

Ce profil illustre bien ce qui fait la performance du Gradient *Boosting* : en combinant de nombreux arbres construits séquentiellement, le modèle conserve la hiérarchie des signaux forts (le ratio facture/marché demeure central) tout en exploitant l'information résiduelle portée par des variables secondaires que l'arbre unique négligeait. Il réalise ainsi un compromis entre la concentration de l'arbre et la dilution du *scoring*. On retrouve par ailleurs les mêmes variables clés que dans les deux autres modèles (ratio facture/marché, historique de l'assuré, antécédents de fraude) ce qui témoigne de la robustesse de ces signaux quel que soit le modèle.

Comme pour les deux autres modèles précédents, l'Agent IA retourne dans un premier temps la distribution du nombre de sinistres par tranche de 5 % de probabilité selon l'état du sinistre (frauduleux ou non).

Distribution des scores par classe (jeu de test : 6000 sinistres)

Pour chaque tranche de score, ce graphique superpose (en transparence) le nombre de sinistres frauduleux et non frauduleux du jeu de test. Plus les deux distributions se chevauchent, plus il est difficile pour le modèle de séparer les deux classes à ce niveau de score.




FIGURE 5.23 – Distribution des scores par classe (fraudeur/non fraudeur)

Le modèle Gradient *Boosting* présente une très bonne séparation des deux classes (sinistres frauduleux / non

frauduleux). La grande majorité des sinistres non frauduleux se concentre dans les tranches de faible probabilité (inférieures à 30 %) tandis que la part de sinistres frauduleux (en rouge) croît fortement dans les tranches élevées, devenant prépondérante autour des scores supérieurs à 85 %.

Ce basculement net, ainsi que le moindre chevauchement des distributions par rapport aux deux modèles précédents confirment la supériorité du Gradient *Boosting* en matière de discrimination entre dossiers frauduleux et sains.

Dans un second temps, l'Agent affiche la performance du modèle au travers de l'indicateur de taux de fraude avéré par tranche de probabilité.

Calibration Gradient Boosting : taux de fraude avérée par tranche de probabilité (jeu de test : 6000 sinistres)




FIGURE 5.24 – Taux de fraude avérée par tranche de score de suspicion

Ces graphiques mesurent la qualité prédictive du modèle sur le jeu de test, c'est-à-dire sur des sinistres qui n'ont pas été utilisés par le modèle lors de l'apprentissage. Les indicateurs reflètent donc sa capacité de généralisation à de nouveaux dossiers, et non une simple performance sur les données d'entraînement.

La sortie du modèle Gradient *Boosting* met en évidence une capacité de discrimination particulièrement élevée entre les dossiers frauduleux et non frauduleux. On observe une augmentation très marquée du taux de fraude avérée à mesure que la probabilité estimée croît, ce qui traduit une excellente cohérence entre les prédictions du modèle et la réalité observée sur les données de test.

Contrairement aux modèles plus simples, la montée du taux de fraude est ici beaucoup plus prononcée. Au-delà de 85 %, on entre dans une zone où plus d'un sinistre sur deux est frauduleux, jusqu'à un taux de 91 % sur la tranche la plus élevée. Cela signifie que le modèle concentre très efficacement les fraudes dans les segments à forte probabilité.

Cette performance s'explique par la capacité du Gradient *Boosting* à capter des relations complexes, non linéaires et des interactions fines entre variables, ce qui lui permet d'identifier des schémas de fraude difficiles à détecter avec des approches plus classiques.

D'où les zones d'investigation suivantes :

- **Zone faible (<45 %)** : le taux de fraude reste globalement modéré (inférieur à ~10 %). Ces dossiers peuvent être traités en flux standard, éventuellement avec des contrôles légers automatisés.

- **Zone intermédiaire** ($\approx 45\%$ à 85%) : on observe une montée progressive du taux de fraude (environ 10% à 45%). À ce niveau, on commence à avoir un enrichissement significatif en fraude, tout en conservant un volume de dossiers encore gérable pour des contrôles ciblés (revue documentaire, demandes complémentaires, etc.).
- **Zone élevée** ($> 85\%$) : le taux de fraude devient nettement plus important (58% à plus de 90% sur les dernières tranches). Un **seuil de vérification poussée autour de 85%** est cohérent. Au-delà de ce seuil, on concentre fortement les fraudes, ce qui justifie des investigations approfondies (enquête terrain, expertise renforcée, gel du dossier, etc.).

Matrice de confusion Seuil : 85%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	390	298	688
Réel Non fraude	99	5213	5312
Total	489	5511	6000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.25 – Matrice de confusion du modèle Gradient *Boosting* pour un seuil de 85%

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $5\,213 / 5\,312 = 98,14\%$;
- Le taux de fraudes détectées (prédit fraude / réel fraude) : $390 / 688 = 56,69\%$;
- Le taux de sinistres signalés frauduleux (prédit fraude / total) : $489 / 6\,000 = 8,15\%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une optimisation du seuil afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.3.2 Qualité du modèle obtenu

Le recours à une méthode ensembliste comme le Gradient *Boosting* marque une rupture en termes de performance. Le modèle parvient à capturer des relations complexes et non linéaires, ce qui se traduit par une courbe de risque nettement plus régulière et globalement monotone.

La concentration des fraudes dans les tranches de probabilité élevées est particulièrement marquée, avec des taux proches de 100% sur les segments les plus extrêmes (sur données de test).

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles mis en place présentés en section 3.7.

Pour commencer, on cherche le seuil optimal à partir duquel on peut considérer que les sinistres sont frauduleux à l'aide de l'indicateur de Youden (présenté en section 5.1.2). Pour le modèle utilisant de Gradient *Boosting*, le seuil optimal est de 45% .

Matrice de confusion Seuil : 45%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	601	87	688
Réel Non fraude	813	4499	5312
Total	1414	4586	6000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.26 – Matrice de confusion du modèle *Gradient Boosting* avec un seuil de 45 %

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $4499/5312 = 84,69\%$;
- Le taux de fraudes détectées (prédit fraude / réel fraude) : $601/688 = 87,35\%$;
- Le taux de sinistres signalés frauduleux (prédit fraude / total) : $1414/6000 = 23,57\%$.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 23,57 % des sinistres, parmi lesquels 42,5 % sont réellement frauduleux, soit une densité de fraude environ 3,7 fois supérieure à celle d'un contrôle aléatoire. L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :

MÉTRIQUES DE DISCRIMINATION ET DE CLASSIFICATION

DISCRIMINATION

AUC-ROC

0.933

GINI

0.867

KS

0.724

PR-AUC

0.744

PERFORMANCE PRÉDICTIVE

PRÉCISION

42.5%

RAPPEL

87.4%

F1-SCORE

57.2%

ACCURACY

85.0%

QUALITÉ DES PROBABILITÉS ET CIBLAGE

LOG-LOSS

0.3131

LIFT @10%

×6.37

COURBE DE GAINS PAR DÉCILE DE RISQUE

Décile	10%	20%	30%	40%	50%	60%	70%	80%	90%	100%
% fraudes	63.7%	83.9%	91.3%	95.1%	96.8%	98.3%	99%	99.6%	100%	100%
Lift	×6.4	×4.2	×3.0	×2.4	×1.9	×1.6	×1.4	×1.2	×1.1	×1.0

FIGURE 5.27 – Synthèse des métriques de performance et de stabilité du modèle *Gradient Boosting* au seuil 45 %



FIGURE 5.28 – Courbe ROC et AUC pour le modèle Gradient *Boosting*

En retenant le seuil optimal de 45 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,933)** : excellente capacité de discrimination, très au-dessus du seuil de 0,8 considéré comme bon ; le modèle sépare efficacement fraudeurs et non-fraudeurs.
- **Gini (0,867)** : cohérent avec l'AUC, ce niveau traduit un pouvoir discriminant élevé, largement supérieur aux standards habituels en assurance.
- **KS (0,724)** : bien au-delà du seuil de 0,4 jugé satisfaisant, il confirme une nette séparation entre les distributions de scores des deux populations.
- **PR-AUC (0,744)** : indicateur à privilégier sur données déséquilibrées (cf. section 3.7), il se lit au regard de la prévalence de la fraude (11,5 %) : le Gradient *Boosting* fait environ 6,5 fois mieux qu'un modèle aléatoire sur la classe d'intérêt, contre 4,5 fois pour l'arbre de décision (PR-AUC de 0,518).
- **Précision (42,5 %)** : parmi les dossiers signalés comme frauduleux, un peu plus de quatre sur dix le sont réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (87,4 %)** : le modèle détecte près de neuf fraudes sur dix, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (57,2 %)** : bon compromis entre précision et rappel.
- **Accuracy (85,0 %)** : taux de bonnes classifications élevé.
- **Log-loss (0,3131)** : valeur faible, signe d'une bonne calibration des probabilités prédites.

Enfin, concernant les indicateurs de robustesse et stabilité du modèle, les résultats suivants sont obtenus :

- **Backtesting** (écart AUC *train/test* de **0,016**) : écart très faible entre apprentissage et test, signalant une excellente capacité de généralisation et l'absence de surapprentissage.
- **PSI** (**0,0023**) : très inférieur à 0,1, il atteste d'une excellente stabilité de la distribution des scores.




FIGURE 5.29 – Indicateurs de robustesse et stabilité du modèle Gradient *Boosting*

5.3.3 Limites et précautions d'interprétation

Le Gradient *Boosting* constitue le modèle le plus performant de cette étude, grâce à sa capacité à combiner un grand nombre d'arbres faibles corrigeant successivement leurs erreurs. Cette puissance s'accompagne toutefois de plusieurs limites qu'il convient de considérer dans une utilisation opérationnelle.

En premier lieu, le Gradient *Boosting* est un modèle nettement moins interprétable que les précédents. Là où un arbre unique ou un *scoring* à point offrent une lecture directe des règles de décision, la combinaison de deux cents arbres rend la logique globale difficile à retracer.

L'interprétation ne peut plus se faire directement sur la structure du modèle et nécessite le recours à des méthodes d'explicabilité complémentaires (importance des variables, valeurs de Shapley), qui restent des approximations et demandent une expertise spécifique.

Par ailleurs, le modèle est particulièrement sensible au réglage de ses hyperparamètres. Le nombre d'arbres, la profondeur, le taux d'apprentissage ou le sous-échantillonnage influencent fortement la performance et la robustesse : un paramétrage mal maîtrisé peut conduire à un surapprentissage, le modèle s'ajustant trop finement aux données d'entraînement au détriment de sa capacité de généralisation. Un encadrement méthodologique rigoureux, via une validation appropriée, est donc indispensable.

En outre, comme tout modèle supervisé, le Gradient *Boosting* reste dépendant de la qualité et de la représentativité des données historiques. Il peut amplifier certains biais présents dans les données (biais de détection ou d'investigation) et reproduire des schémas passés qui ne reflètent pas nécessairement les fraudes futures.

Enfin, la calibration des probabilités mérite attention : les scores produits ne sont pas toujours directement interprétables comme des probabilités exactes, ce qui justifie une étape de calibration et un choix réfléchi du seuil de décision.

Ainsi, le Gradient *Boosting* offre les meilleures performances prédictives de l'étude, mais au prix d'une moindre interprétabilité et d'une plus grande complexité de mise en œuvre, qui imposent un cadre de validation et de suivi rigoureux.

5.4 Comparaison des modèles

Une fois les trois modèles présentés, le passage ci-dessous a pour objet de faire une synthèse et une comparaison des résultats obtenus pour orienter le choix du modèle finalement retenu parmi les trois modèles testés par l'Agent IA.

Ci-dessous, un tableau récapitulatif des différents indicateurs de qualité selon le modèle testé.

Indicateur	<i>Scoring</i> en point	Arbre de décision	Gradient <i>Boosting</i>
AUC-ROC	0,917	0,845	0,933
Gini	0,835	0,690	0,867
KS	0,666	0,564	0,724
PR-AUC	— ³	0,518	0,744
<i>Lift</i> @10 %	—	×4,83	× 6,37
PSI	0,0026	0,0026	0,0023
Écart <i>Backtesting</i>	0,003	0,039	0,016

TABEAU 5.2 – Synthèse des résultats des indicateurs de qualité des différents modèles

Stabilité et robustesse des modèles

Les trois modèles présentent une stabilité remarquable, avec des valeurs de PSI très inférieures au seuil d'alerte de 0,10 (0,0026 pour le *scoring* en points, 0,0026 pour l'arbre de décision et 0,0023 pour le Gradient *Boosting*). Ces valeurs attestent d'une distribution homogène des scores entre les échantillons d'entraînement et de test. Le partitionnement étant aléatoire et non chronologique, ce résultat était toutefois attendu : il ne permet pas de conclure sur la stabilité temporelle des modèles, qui devra être suivie en production via le PSI calculé sur les nouveaux sinistres soumis à l'outil. Par ailleurs, le *backtesting* en *split* 80/20 révèle une bonne capacité de généralisation : les écarts entre AUC d'entraînement et AUC de validation restent contenus (0,003 pour le *scoring* en points, 0,039 pour l'arbre de décision et 0,016 pour le Gradient *Boosting*). Le *scoring* en points affiche l'écart le plus faible, cohérent avec sa simplicité, tandis que le modèle basé sur les arbres de décision présente l'écart le plus marqué, traduisant sa tendance connue au surapprentissage ; celui-ci reste toutefois modéré et n'entame pas significativement la robustesse du modèle.

Analyse du compromis précision / rappel et choix du seuil de décision

Le Gradient *Boosting* s'impose nettement comme le modèle à retenir, car il offre le meilleur pouvoir discriminant parmi les trois approches testées : une AUC de 0,933, un indice de Gini de 0,867 et un *lift* de ×6,37 au premier décile. Il devance nettement le modèle basé sur un arbre de décision (AUC de 0,845, indice de Gini de 0,690, *lift* de ×4,83) et, plus légèrement, le modèle basé sur un *scoring* en points (AUC de 0,917, indice de Gini de 0,835). Sa capacité à concentrer la fraude dans les premiers déciles en fait l'outil le plus efficace pour prioriser les dossiers à investiguer, ce qui correspond précisément à l'objectif opérationnel poursuivi.

Ce choix ne disqualifie pas pour autant le modèle basé sur un *scoring* en points, qui demeure un modèle remarquablement performant au regard de sa simplicité. Avec une AUC de 0,917 et un indice de Gini de 0,835, il se situe très près du Gradient *Boosting* et loin devant l'arbre de décision, tout en conservant une

3. La PR-AUC et le *lift* au premier décile ne sont pas restitués par l'agent pour le modèle de *scoring* en points (cf. figure 5.9) ; la comparaison sur ces deux indicateurs porte donc uniquement sur l'arbre de décision et le Gradient *Boosting*. Une estimation du *lift* peut toutefois être déduite des deux matrices de confusion du modèle (seuils de 45 % et 35 %) : la courbe de gains étant concave, le *lift* au premier décile est compris entre environ ×5,4 et ×7,1, soit un niveau comparable à celui du Gradient *Boosting*.

transparence et une interprétabilité que les méthodes d'ensemble ne permettent pas. Il constitue donc une alternative pleinement crédible lorsque l'explicabilité prime sur le dernier point de performance, par exemple pour une présentation aux gestionnaires ou dans un contexte réglementaire exigeant. Le choix entre ces deux modèles relève ainsi d'un arbitrage entre performance pure (Gradient *Boosting*) et interprétabilité (*scoring* en points), l'arbre de décision étant quant à lui écarté, dominé sur l'ensemble des critères.

Enfin, quel que soit le modèle retenu, la lecture des performances appelle une nuance commune, liée à la tension inhérente entre précision et rappel. Ces deux indicateurs évoluent en sens inverse selon le seuil de décision : abaisser le seuil permet de détecter davantage de fraudes (rappel plus élevé), mais au prix d'un plus grand nombre de dossiers sains signalés à tort (précision plus faible), et inversement. D'un point de vue actuariel, ce ratio doit être piloté explicitement : modifier le seuil de décision permet d'ajuster le rappel au prix d'un volume plus ou moins élevé de dossiers à investiguer. Le choix optimal de ce curseur dépend du coût asymétrique des deux types d'erreurs : un faux négatif (fraude non détectée) engendre une perte indemnisée à tort, tandis qu'un faux positif (investigation inutile) représente un coût opérationnel pour la cellule fraude. C'est précisément pour cette raison que l'outil développé laisse à l'utilisateur le soin de manipuler dynamiquement le curseur des seuils de détection, afin d'adapter le dispositif au contexte et à l'appétence au risque de chaque assureur.

Configuration finale du modèle

La dernière étape de l'Agent IA de création du modèle d'aide à la détection de fraude consiste à l'enregistrement du modèle choisi.

Pour ce faire, l'utilisateur doit confirmer le modèle retenu ainsi que le seuil optimal.

Un seuil d'investigation fixé par défaut à $\pm 10\%$ ⁴ du seuil optimal sera retenu, ainsi, si l'on considère par exemple un seuil optimal de 45 %, trois zones d'investigations seront mises en place :

- Probabilité de fraude < 35 % : pas d'investigation
- Probabilité de fraude entre 35 % et 55 % : investigation légère
- Probabilité de fraude supérieure à 55 % : investigation à lancer


Dans notre cas, on choisit le modèle Gradient *Boosting* avec les seuils 35 % et 55 % .

4. Ces seuils d'investigation peuvent être modifiés par l'utilisateur s'il le souhaite.

CONFIGURATION DU MODULE 2

Confirmer la configuration retenue

Le dernier modèle consulté pendant l'analyse est retenu automatiquement.
Les seuils sont calculés autour de son seuil optimal et ne sont pas modifiables ici.



La confirmation enregistre uniquement cette configuration pour le module 2 ; elle ne lance aucun scoring.

FIGURE 5.30 – Configuration finale du modèle et des seuils d'investigation

Une fois cette dernière étape réalisée, l'outil mis à disposition du service de détection des fraudes est configuré avec ce modèle et ces seuils d'investigation.

Ces derniers ne sont pas modifiables dans le second outil. Seul le premier Agent IA doit être relancé pour modifier le modèle sous-jacent de modélisation de la probabilité de fraude.

Chapitre 6

Outil mis à disposition du service de détection des fraudes

Le présent chapitre traite du second outil créé à l'aide de l'Intelligence Artificielle.

Ce dernier se présente sous forme d'une interface utilisateur proposant trois fonctionnalités :

1. Évaluer un ou plusieurs nouveaux sinistres : l'utilisateur dépose un fichier contenant des informations sinistres pour estimer, pour chaque dossier, sa probabilité de fraude intrinsèque ;
2. Renseigner le résultat de fraude de sinistres testés précédemment : cela permettra d'enrichir la base de données utilisée pour la construction du modèle dans l'outil précédent ;
3. Consulter le bilan annuel de fraude : l'utilisateur peut lire les analyses sur les fraudes de l'année (montant économisé, rapport sur les mécanismes de fraudes récurrents, etc.).

Ces différentes fonctionnalités seront décrites en détail dans les paragraphes suivants.

Scoring — nouveaux sinistres

Que souhaitez-vous faire ?




FIGURE 6.1 – Écran interactif d'accueil du second outil

6.1 Utilisation pratique de l'outil

L'outil mis à disposition du service de détection des fraudes constitue la traduction opérationnelle du modèle de détection des fraudes développé en amont. Il s'inscrit dans une logique d'**aide à la décision fondée sur une**

estimation probabiliste du risque de fraude, permettant d'orienter de manière cohérente et homogène les actions de contrôle sur les sinistres.

En amont de son utilisation, les seuils de décision sont définis par l'actuaire en charge du modèle, puis transmis aux gestionnaires sinistres pour paramétrage dans l'outil. Ces seuils permettent de segmenter l'espace des probabilités en différentes zones de risque.

À ce stade, on retient à titre illustratif le dernier modèle (*Gradient Boosting*) et les seuils suivants :

- $Seuil_{inf} = Seuil_{optimal} - 10 \%$
- $Seuil_{sup} = Seuil_{optimal} + 10 \%$

Ce qui crée naturellement les trois zones :

- Une zone de faible risque (verte) : $[0; Seuil_{inf}[$
- Une zone de risque intermédiaire (orange) : $[Seuil_{inf}; Seuil_{sup}[$
- Une zone de risque élevé (rouge) : $[Seuil_{sup}; 100 \%]$

Ces seuils traduisent un arbitrage actuariel entre le **coût des investigations** (notamment en termes de ressources mobilisées et de délais de gestion) et le **gain attendu lié à la détection de fraude**, en tenant compte des taux de faux positifs et de faux négatifs.

Lorsque l'utilisateur clique sur « tester de nouveaux sinistres », l'outil demande ensuite à l'utilisateur de renseigner les caractéristiques d'un ou plusieurs sinistres pour lancer l'analyse. Cette intégration peut s'effectuer de deux manières : soit de façon industrielle par le dépôt d'un fichier standardisé, soit de manière unitaire via un formulaire de saisie manuelle (cf. illustration ci-dessous).

Fichier CSV à évaluer

Sans la colonne `fraud_reported`



Glissez-déposez votre CSV ici, ou cliquez

Sans `fraud_reported`

Ces flux d'entrée reprennent exactement les mêmes variables explicatives que notre base de modélisation (franchise, âge, profession, type d'incident, montants, etc.), mais sans intégrer la colonne cible de fraude avérée (`fraud_reported`).

Ou saisir les informations sur le sinistre manuellement

Toutes les variables explicatives disponibles pour le scoring, organisées par domaine métier. * Champ obligatoire

Renseignez les informations disponibles

Seul l'identifiant de police est obligatoire. Les champs non renseignés sont traités comme des valeurs manquantes, comme lors d'un import CSV.

Contrat

Informations de souscription et ancienneté de la police. • 5 variables

Assuré

Profil, activité et historique consolidé de l'assuré. • 12 variables

Sinistre

Circonstances, dommages et éléments de preuve du sinistre. • 14 variables

Véhicule

Caractéristiques et historique agrégé du véhicule concerné. • 5 variables

Historique et intervenants

Indicateurs consolidés sur le réparateur et le tiers impliqué. • 5 variables

Indicateurs de déclaration

Délai, canal et signaux complémentaires liés à la déclaration. • 7 variables

FIGURE 6.2 – Saisie manuelle des informations sinistre pour évaluation de la probabilité de fraude

Sur la base des informations sinistre renseignées, le modèle calcule une **probabilité de fraude en appliquant le modèle retenu dans l'outil de modélisation de la fraude**.

Cette probabilité constitue une mesure synthétique du risque, intégrant l'ensemble des signaux de fraude identifiés lors de la phase de modélisation.

La décision opérationnelle repose alors sur la **comparaison de cette probabilité aux seuils définis dans l'outil précédent (enregistrés en paramètres)**. Chaque sinistre est ainsi affecté à une classe de risque, à laquelle est associée une stratégie de gestion différenciée :

- Absence d'investigation pour les niveaux faibles ;
- Contrôles ciblés pour les niveaux intermédiaires ;
- Et investigations approfondies pour les niveaux élevés.

Ce dispositif permet d'optimiser la **fonction de coût globale** du processus de détection, en concentrant les efforts sur les dossiers présentant le meilleur ratio entre probabilité de fraude et coût d'investigation.

À titre d'illustration, sur un échantillon test de 500 sinistres, l'outil réalise un filtrage puissant en isolant immédiatement 474 dossiers en zone verte (ne nécessitant aucune investigation humaine), 21 dossiers en zone orange (à surveiller ou contrôler superficiellement) et seulement 5 dossiers en zone rouge (faisant l'objet d'une alerte prioritaire)¹.

1. Cette illustration a été réalisée avec une configuration antérieure du modèle (seuils d'investigation de 40 % et 60 %), et non

Résultats de l'évaluation

500 sinistres scorés depuis car_insurance_fraud_dataset_500_fraude_inconnue.csv

0-39% 40-59% 60-100%

Ne pas investiguer 474 ↓ CSV			Investiguer un peu 21 ↓ CSV			Investiguer beaucoup 5 ↓ CSV		
Police	Montant	Fraude	Police	Montant	Fraude	Police	Montant	Fraude
POL129644	612	38%	POL129928	24 045	57%	POL129555	22 739	78%
POL129505	22 546	36%	POL129798	22 890	56%	POL129890	784	72%
POL129809	724	35%	POL129586	24 341	55%	POL129600	2 554	64%
POL129872	21 264	35%	POL129712	24 454	54%	POL129607	24 309	63%
POL129962	24 350	34%	POL129542	2 311	49%	POL129742	12 038	60%
POL129923	24 085	34%	POL129725	1 079	49%			
POL129618	9 377	33%	POL129507	6 596	48%			
POL129965	7 093	33%	POL129636	24 645	47%			
POL129548	4 836	33%	POL129511	20 666	46%			
POL129717	15 870	32%	POL129659	15 552	46%			
POL129765	752	32%	POL129973	557	46%			
POL129540	6 441	31%	POL129940	17 042	45%			

FIGURE 6.3 – Probabilité de fraude en sortie de l'outil

Ainsi, l'outil s'inscrit dans une démarche actuarielle classique de **segmentation du risque et de prise de décision sous contrainte**, en transformant une estimation probabiliste issue du modèle en règles de gestion opérationnelles directement exploitables par les équipes métiers.

L'utilisation d'un tel outil présente plusieurs avantages majeurs dans le cadre de la détection de fraude, tant d'un point de vue actuariel qu'opérationnel. En premier lieu, il permet de **standardiser l'évaluation du risque de fraude** en s'appuyant sur un modèle statistique commun, appliqué de manière homogène à l'ensemble des sinistres. Cette standardisation réduit significativement les **variabilités de traitement entre gestionnaires**, liées à l'expérience, à la subjectivité ou à la sensibilité individuelle au risque, et garantit une plus grande cohérence dans les décisions prises.

En outre, l'outil favorise une **objectivation du processus de décision** en reposant sur une estimation probabiliste issue de données historiques. Il limite ainsi les biais cognitifs (sur- ou sous-estimation du risque, effet d'ancrage, etc.) et permet d'inscrire la détection de fraude dans une démarche plus rigoureuse et traçable. Chaque décision d'investigation peut être justifiée par un niveau de risque mesuré, ce qui améliore la **transparence et l'auditabilité** des pratiques.

Par ailleurs, en segmentant les sinistres selon leur niveau de risque, l'outil permet une **allocation optimale des ressources d'investigation**. Les dossiers les plus susceptibles d'être frauduleux sont priorisés, ce qui augmente l'efficacité globale du dispositif tout en maîtrisant les coûts liés aux contrôles. Cette approche s'inscrit dans une logique actuarielle d'optimisation du couple **coût de détection / gain attendu**, en maximisant la rentabilité des actions de lutte contre la fraude.

Enfin, cet outil constitue un levier d'**harmonisation et de pilotage** à l'échelle du portefeuille. Il permet de suivre la performance du dispositif (taux de fraude détectée, taux de transformation des contrôles, etc.), d'ajuster les seuils de décision en fonction des résultats observés, et d'assurer une meilleure comparabilité dans le temps. Il contribue ainsi à structurer la fonction fraude autour d'indicateurs quantitatifs et d'une approche pilotée par la donnée.

avec les seuils de 35 % et 55 % retenus dans la configuration finale. Le faible nombre de dossiers en zone rouge s'explique par le niveau de ce seuil supérieur : seuls les sinistres dont la probabilité de fraude estimée atteint au moins 60 % y sont affectés (zones de 0 à 39 %, de 40 à 59 % et de 60 à 100 %). Par ailleurs, cet échantillon de 500 sinistres, dont le statut de fraude est inconnu, est distinct du jeu de test utilisé au chapitre 5 : la répartition de ses scores n'a donc pas vocation à reproduire celle observée lors de l'évaluation du modèle.

6.2 Un outil permettant l'enrichissement du modèle en continu

Dans une logique d'amélioration continue, l'outil intègre un mécanisme de boucle de retour d'information (*feedback loop*) permettant d'enrichir progressivement la base de données d'apprentissage. Ce mécanisme repose sur une base « historique » (ensemble des sinistres renseignés dans l'outil afin d'obtenir une probabilité de fraude), dans laquelle sont automatiquement archivés l'ensemble des sinistres soumis à l'outil, accompagnés de la probabilité de fraude qui leur a été attribuée.




FIGURE 6.4 – Schéma macro du mécanisme d'enrichissement de la base de données

Comme l'illustre le schéma ci-dessus, lorsque l'utilisateur soumet un nouveau sinistre pour en estimer la probabilité de fraude, le dossier scoré rejoint la base historique. À ce stade, cette base ne contient toutefois pas encore l'information la plus précieuse pour le modèle : l'issue réelle du dossier. Savoir si un sinistre s'est effectivement révélé frauduleux n'est en effet connu qu'à l'issue de son instruction, souvent plusieurs semaines, voire plusieurs mois, après la déclaration. C'est ce constat qui structure la logique d'enrichissement retenue.

Plutôt que de demander au gestionnaire de statuer immédiatement sur une fraude qu'il ne peut encore confirmer, l'outil lui permet de revenir à tout moment dans la base historique pour y renseigner le statut final d'un ou plusieurs sinistres (fraude avérée ou non). **Cette dissociation entre le moment du *scoring* et celui de la qualification reflète fidèlement la réalité opérationnelle de la gestion des sinistres, où le dénouement d'un dossier est par nature différé.**

POL100029
×

Single Vehicle Collision · **97 % de risque** · 17 483 €

Décision à enregistrer
Documentez le statut de fraude et les montants associés à ce sinistre.

Statut fraude *

Fraude
Pas de fraude

Date de décision

14/08/2026

Montant hors fraude (€)
Impact financier (€)

0
0

Part légitime à indemniser.
Fraude évitée ou impact estimé.

Motif

Ex : déclaration incohérente

Commentaire

Observations libres du gestionnaire...

Enregistrer le résultat

FIGURE 6.5 – Fiche de renseignement d'un sinistre à l'issue d'une investigation

Une fois cette issue renseignée, le sinistre concerné dispose d'un couple complet d'informations : ses caractéristiques d'entrée d'une part, et sa variable cible de fraude (*fraud_reported*) d'autre part. Il devient alors une observation exploitable pour l'apprentissage, au même titre que les données ayant servi à la construction initiale du modèle. C'est bien un statut binaire, et non une probabilité, qui alimente ainsi la base : un sinistre confirmé comme frauduleux après investigation est enregistré à 1, tandis qu'un sinistre investigué mais jugé finalement

légitime est enregistré à 0. Le modèle ne se réentraîne donc que sur des cas dont l'issue est avérée, et non sur de simples suspicions, ce qui garantit la fiabilité de son apprentissage au fil du temps.

À noter que **l'enrichissement de la base de données ne modifie pas le modèle de façon instantanée**. En effet le réentraînement s'effectue en repassant par le module de construction (Module 1), qui refait tourner le modèle sur la base augmentée des nouvelles observations qualifiées. En pratique, cette opération est à mener à intervalles de temps réguliers (typiquement une fois par an), afin d'intégrer un volume significatif de nouveaux cas tout en garantissant la stabilité du dispositif entre deux mises à jour.

Cette approche présente plusieurs intérêts sur le plan actuariel. D'abord, elle permet d'augmenter la taille et la représentativité de la base d'apprentissage, en y intégrant des cas récents qui reflètent l'évolution des comportements frauduleux et des méthodes de fraude utilisées. Elle contribue ainsi à réduire le décalage entre les données historiques initiales et la réalité opérationnelle, dans un contexte où les schémas de fraude évoluent rapidement.

Ensuite, ces nouvelles observations permettent un recalibrage et une réestimation réguliers du modèle : actualisation des paramètres, amélioration de la capacité de discrimination et, le cas échéant, réajustement de la pondération des variables. L'objectif est de maintenir dans le temps une performance prédictive stable, mesurée à l'aide d'indicateurs tels que l'AUC, le Gini ou les courbes de gains, et de surveiller l'absence de dérive du modèle (notamment via le *Population Stability Index*).

Enfin, l'intégration systématique des issues réelles permet de mieux appréhender certains biais inhérents aux dispositifs de détection, en particulier le biais de sélection lié aux dossiers investigués. Ce biais ne disparaît toutefois pas entièrement : les dossiers classés en zone verte n'étant pas investigués, leur statut réel reste inconnu, et la base enrichie tend mécaniquement à sur-représenter les dossiers jugés suspects par le modèle. Pour le limiter, il est recommandé d'investiguer périodiquement un échantillon aléatoire de dossiers de la zone verte, afin de disposer d'observations labellisées sur l'ensemble de la distribution des scores.

Ainsi, l'outil ne se limite pas à une utilisation statique du modèle : il s'inscrit dans une démarche dynamique de modélisation itérative, où chaque sinistre qualifié vient affiner la connaissance du risque et améliorer la pertinence du dispositif de détection.

6.3 Rapport annuel de détection de fraude

Au-delà du *scoring* individuel des sinistres, l'outil intègre **une fonctionnalité de pilotage** offrant une vision agrégée de la performance du dispositif sur une période donnée (paramétrable mais dans les faits, mensuelle ou annuelle).

Lancé annuellement, il constitue la synthèse cumulative de l'activité de détection de fraudes : il s'appuie sur l'ensemble des sinistres testés dans l'outil pour obtention de score de fraude et les résultats des investigations renseignés. Ainsi, il permet de ressortir des indicateurs de volume (sur les dossiers traités) mais également économiques (fraude évitée en montant).

Cette vue de synthèse répond à un besoin actuariel essentiel : ne pas se limiter à une utilisation opérationnelle au fil de l'eau, mais disposer d'indicateurs consolidés permettant d'évaluer et de justifier l'utilisation de l'outil et d'ajuster le dispositif mis en place dans le temps.




FIGURE 6.6 – Extrait du rapport annuel de la détection de fraude

Dans notre outil, différents indicateurs ont été mis en place :

1. Les premiers indicateurs portent sur le **volume et la détection** : nombre de sinistres testés, nombre d'alertes générées par le modèle et nombre de fraudes effectivement confirmées après investigation. Leur mise en regard permet d'apprécier la charge de travail générée par l'outil et le taux de concrétisation des alertes.
2. Viennent ensuite les indicateurs **financiers**, au cœur de l'enjeu actuariel. Le montant de fraude évitée agrège les sinistres frauduleux confirmés qui n'ont pas donné lieu à indemnisation grâce à l'outil. Pour compléter cet indicateur, un KPI important est également calculé : l'impact sur le **ratio Sinistres / Primes (S/P)** de la détection de fraude qui traduit directement le gain apporté par la détection sur l'équilibre technique du portefeuille. En effet, en écartant une partie de la charge frauduleuse, l'outil améliore mécaniquement ce ratio. Cet indicateur fait le lien avec l'analyse développée au chapitre 1 : là où nous avons modélisé la surprime supportée par les assurés honnêtes par la relation $\Pi_{\text{chargée}} = \frac{\Pi_{\text{pure}}}{1-\alpha}$, le rapport annuel permet de quantifier *a posteriori* la part de charge frauduleuse α effectivement récupérée, et donc l'effet réel de l'outil sur la tarification.
3. Le rapport suit également la **qualité opérationnelle** du dispositif. La précision de l'outil mesure, parmi

les alertes confirmées, la proportion de véritables fraudes, indicateur clé pour éviter de mobiliser inutilement les équipes d'investigation sur des faux positifs. La répartition des sinistres par zone de risque (verte, orange, rouge) permet quant à elle de visualiser la distribution du portefeuille et d'ajuster les seuils $Seuil_{inf}$ et $Seuil_{sup}$ si nécessaire.

4. Enfin, deux indicateurs relèvent d'une logique d'**intelligence fraude** plus avancée. L'identification des réseaux, en repérant les sinistres impliquant plusieurs véhicules, signale une suspicion de fraude organisée, distincte de la fraude opportuniste. La détection de nouvelles tendances met en évidence l'émergence de schémas de fraude inédits, permettant d'anticiper l'évolution des comportements frauduleux.

L'ensemble se synthétise dans une mesure du **retour sur investissement (ROI) de l'outil**, rapprochant le gain généré (fraude évitée) du coût de mise en œuvre et d'exploitation du dispositif. Cet indicateur répond directement à la problématique de rentabilité posée en introduction : il démontre que l'automatisation de la détection, en abaissant le coût marginal de contrôle, rend rentable l'analyse de l'ensemble des sinistres, y compris ceux de faible montant jusque-là trop coûteux à investiguer manuellement.

Ce rapport peut par ailleurs être exporté au format PDF, offrant un livrable synthétique directement transmissible à la Direction Technique, au service anti-fraude ou aux instances de gouvernance. Cette possibilité d'extraction facilite le *reporting* périodique et la traçabilité des résultats, en cohérence avec les exigences de documentation évoquées dans le cadre de gouvernance de l'outil (cf. section 4.1).

Ainsi, le rapport annuel transforme l'outil de détection en véritable instrument de pilotage actuariel. Il ne se contente pas de traiter les sinistres individuellement, mais fournit une lecture consolidée et chiffrée de la performance du dispositif, permettant de justifier son maintien, d'en ajuster les paramètres et d'en mesurer l'impact réel sur l'équilibre technique du portefeuille.

6.4 Dynamisme de l'outil mis en place

Le modèle développé présente un caractère dynamique et évolutif, essentiel dans un environnement assurantiel en constante mutation. Il ne s'agit pas d'un dispositif figé : la plupart des choix effectués tout au long de ce mémoire constituent des hypothèses de travail, retenues pour les besoins de l'illustration, mais paramétrables et substituables sans refonte de l'outil.

Le tableau ci-dessous récapitule ces principaux choix de conception et les alternatives envisageables pour chacun.

Élément de l'outil	Choix retenu dans ce mémoire	Alternatives / paramétrage possible
Variables d'entrée	53 variables (24 variables source + 29 ajoutées pour enrichissement)	Nombre et nature libres : l'outil s'adapte à tout jeu de variables, avec ou sans enrichissement
Enrichissement de la base	29 variables simulées (historique, réparateur, tiers, véhicule, comportement déclaratif, géo-temporel)	Enrichissement facultatif et extensible ; d'autres axes peuvent être ajoutés selon les données réellement disponibles chez l'assureur
Modèles de détection	3 modèles (<i>scoring</i> en points, arbre de décision, Gradient <i>Boosting</i>)	Architecture agnostique : tout autre modèle de classification (régression logistique, forêt aléatoire, réseau de neurones...) peut être branché
Partitionnement train/test	80 / 20, stratifié sur la cible	Ratio librement modifiable ; validation croisée déjà intégrée sur la partie apprentissage
Seuil de décision	Seuil optimal via l'indice de Youden	Réglable manuellement selon l'arbitrage précision/rappel souhaité
Zones d'investigation	Bande de ± 10 % autour du seuil optimal (3 zones : verte / orange / rouge)	Largeur et nombre de zones paramétrables selon l'appétence au risque et la capacité d'investigation
Gestion des valeurs manquantes	Contrôle bloquant (saisie obligatoire d'une valeur)	Imputation automatique possible (moyenne, médiane, modalité la plus fréquente)
KPI du rapport de suivi	Fraude évitée, taux d'alertes, impact sur le ratio S/P, ROI	Indicateurs ajoutables ou modifiables selon les besoins de pilotage du management
Réentraînement	Boucle continue alimentée par les issues d'investigation	Fréquence de recalibrage paramétrable (au fil de l'eau, périodique...)

TABLEAU 6.1 – Synthèse des choix retenus et des alternatives de paramétrage de l'outil

Cette flexibilité constitue un atout majeur pour accompagner les évolutions réglementaires, tarifaires ou opérationnelles des assureurs. Par exemple, l'introduction de nouvelles modalités dans les classes de véhicules (liée à des changements de classification, à l'émergence de nouveaux types de motorisation ou à des ajustements tarifaires) peut être directement intégrée : le modèle réapprend alors les relations entre ces nouvelles modalités et le risque de fraude, sans nécessiter une refonte complète de l'outil.

Ainsi, le modèle s'inscrit dans une logique **d'amélioration continue**, permettant de maintenir sa pertinence dans le temps. Cette capacité d'adaptation garantit une meilleure prise en compte des évolutions du portefeuille, des comportements frauduleux et du cadre réglementaire, tout en assurant une cohérence avec les pratiques métiers et les politiques de souscription de l'assureur.

Chapitre 7

Réflexions autour de l'IA et limites de l'outil créé

Le développement d'un outil de détection de fraude basé sur un agent IA, en assurance automobile constitue une avancée significative en matière d'aide à la décision. Néanmoins, son utilisation doit être appréhendée avec recul, tant sur le plan opérationnel que méthodologique, et ouvre plusieurs perspectives d'amélioration.

7.1 Un outil d'aide à la décision complémentaire avec l'humain

Il est encore une fois essentiel de souligner que l'agent IA ne se substitue pas au gestionnaire, mais s'inscrit dans une logique de **complémentarité homme-machine**. L'intervention humaine reste centrale à chaque étape du processus.

En amont, l'actuaire ou le *data scientist* intervient dans la **construction et le paramétrage du modèle** : sélection de la base de données, choix du type de modèle (*scoring* en points, arbre de décision, Gradient *Boosting*), validation de sa performance et de sa cohérence métier.

En phase d'utilisation, le gestionnaire reste responsable de la **saisie des informations relatives au sinistre**, de l'interprétation du score fourni et, le cas échéant, de la décision finale d'investigation. Enfin, il contribue à l'amélioration continue du modèle en renseignant le **statut final du dossier (fraude ou non)**, après avoir fait lui-même l'enquête permettant de prouver cette réponse, alimentant ainsi la base d'apprentissage.

Les deux schémas ci-dessous illustrent concrètement les points d'intervention humaine au sein du processus : ils font apparaître, à chaque étape, la frontière entre ce que l'agent automatise et ce qui reste du ressort du gestionnaire.




FIGURE 7.1 – Identification des points d'intervention humaine dans le module de construction du modèle



FIGURE 7.2 – Identification des points d'intervention humaine dans le module opérationnel de détection

Ainsi, l'agent IA agit comme un outil d'aide à la décision structurant et homogénéisant, mais ne remplace en aucun cas l'expertise métier, indispensable pour interpréter les situations complexes et prendre des décisions adaptées.

7.2 Nature de l'IA utilisée : de l'IA générative à l'IA agentique

Il convient également de distinguer les différents types d'intelligence artificielle mobilisables dans ce contexte. L'**IA générative** (comme les modèles de langage) est principalement utilisée pour produire du contenu (texte, code, synthèses) et assister dans des tâches d'analyse ou de documentation. À l'inverse, l'**IA agentique** s'inscrit dans une logique plus opérationnelle : elle est capable d'enchaîner des actions, de prendre des décisions simples et d'interagir avec un environnement en fonction d'objectifs définis.

En pratique, l'outil développé relève d'un **mélange de ces deux approches**, et il serait réducteur de le ranger dans une seule catégorie.

D'un côté, sa conception repose sur une logique largement **dirigée** : le raisonnement de l'agent a été décomposé, via le *prompt*, en une séquence d'étapes précises (ingestion, audit, analyse descriptive, modélisation, évaluation) que l'agent exécute dans l'ordre imposé. Sur ce plan, l'IA agit comme un exécutant guidé pas à pas, sans latitude sur l'enchaînement global de la tâche. Ce cadrage strict est d'ailleurs un choix assumé : il garantit la reproductibilité et l'auditabilité du dispositif, exigences essentielles dans un contexte assurantiel.

De l'autre, l'outil manifeste une véritable dimension **agentique** dans les décisions que l'agent prend de lui-même, sans instruction explicite, en mobilisant une logique métier ou statistique. Plusieurs exemples rencontrés au fil de ce mémoire l'illustrent : l'agent choisit seul la représentation graphique la plus adaptée à chaque variable (camembert pour un faible nombre de modalités, diagramme en barres au-delà) ; il détecte et écarte de lui-même les variables inexploitable, tels les identifiants uniques ou les variables trop granulaires ; il identifie le seuil de décision optimal via l'indice de Youden ; et il sélectionne, parmi les variables candidates, celles à retenir dans le barème de *scoring*. Ces arbitrages, laissés à l'initiative de l'agent, constituent le cœur de son caractère agentique.

C'est cette combinaison qui caractérise l'outil : un cadre procédural dirigé, garant de rigueur et de traçabilité, au sein duquel l'agent conserve une autonomie de décision sur les choix méthodologiques et métiers.

À noter que par défaut, l'outil s'est initialement appuyé sur un **modèle de *scoring* en points**, privilégié pour sa simplicité et son interprétabilité. Des précisions de *prompt* ont ensuite été introduites pour recourir à des modèles plus avancés, tels que les arbres de décision ou des méthodes de *machine learning* (Gradient Boosting).

7.3 Limites liées à la qualité et à la richesse des données

7.3.1 Le couplage à la base portefeuille

La performance et la pertinence d'un modèle de détection de fraude reposent de manière déterminante sur la qualité, la granularité et la richesse des données disponibles.

Dans le cadre de cette étude, le modèle est construit uniquement à partir d'une base sinistre, ce qui constitue une première limite importante. En effet, certaines informations structurantes issues de la base portefeuille ne sont pas accessibles, alors même qu'elles pourraient apporter un pouvoir explicatif significatif.

Parmi ces informations, on peut notamment citer l'ancienneté du contrat, l'historique de sinistralité de l'assuré,

la fréquence de résiliation ou de souscription, ou encore des éléments d'identification permettant de reconstituer des liens entre individus (assurés, conducteurs, tiers).

Pour pallier partiellement cette limite, la base sinistre a été enrichie de vingt-neuf variables reconstituant une partie de cette information (cf. section 4.2.2). Cet enrichissement ne remplace toutefois pas l'accès à une véritable base portefeuille, qui offrirait une profondeur historique et relationnelle hors de portée d'un enrichissement à partir du seul sinistre.

Cet enrichissement appelle en outre une réserve importante dans la lecture des résultats. Les variables les plus contributives des trois modèles (ratio facture/marché du réparateur, historique des montants réclamés, nombre de fraudes passées de l'assuré) sont toutes issues de la simulation, et certaines variables d'enrichissement (taux de fraude du réparateur, taux de fraude de la zone) sont calculées à partir du statut de fraude observé dans la base elle-même. Une partie du pouvoir prédictif mesuré (AUC de 0,933 pour le Gradient *Boosting*) reflète donc vraisemblablement la manière dont ces données ont été générées, plutôt que la seule capacité du modèle à détecter la fraude dans un portefeuille réel. Sur des données d'assureur, ces indicateurs historiques devraient être calculés exclusivement sur des dossiers antérieurs au sinistre évalué, afin d'éviter toute fuite d'information, et les performances obtenues seraient vraisemblablement plus modestes.

L'absence de ces variables limite la capacité du modèle à capter des comportements de fraude plus complexes, notamment ceux reposant sur des logiques de répétition ou d'organisation.

À titre d'exemple, en assurance automobile, l'accès à la base portefeuille permettrait de détecter plus efficacement certains schémas de fraude tels que :

- **Fraudes opportunistes liées à une ancienneté très faible du contrat** : un sinistre survenant peu de temps après la souscription (ex : vol ou incendie dans les premières semaines) constitue un signal faible classique, difficile à exploiter sans information sur la date d'entrée en portefeuille.
- **Récurrence de sinistres sur un même assuré** : un assuré présentant une fréquence de sinistralité anormalement élevée sur une période donnée peut indiquer un comportement suspect (ex : déclarations répétées de bris de glace ou d'accidents matériels). Sans historique consolidé, ces signaux ne peuvent être captés que partiellement.
- **Stratégies de multi-assurance ou de résiliation stratégique** : certains fraudeurs peuvent multiplier les contrats auprès de différents assureurs ou résilier après sinistre pour éviter d'être détectés. L'analyse des trajectoires contractuelles (durée de détention, fréquence de changement d'assureur) constitue alors une variable explicative clé.
- **Fraudes en réseau ou en bande organisée** : l'identification de liens entre individus (même adresse, même véhicule impliqué dans plusieurs sinistres, tiers récurrents dans des accidents) permettrait de détecter des schémas de fraude structurés. Par exemple, des accidents impliquant régulièrement les mêmes personnes ou garages peuvent révéler des montages frauduleux (accidents simulés, complicités avec des réparateurs, etc.).
- **Incohérences entre profil assuré et sinistre déclaré** : certaines variables portefeuille (âge, ancienneté de conduite, historique de comportement) permettent de mieux contextualiser un sinistre. Par exemple, un assuré sans historique de sinistre déclarant soudainement un sinistre grave peut être analysé différemment d'un profil déjà sinistré.

L'intégration de ces données permettrait d'introduire de nouvelles variables explicatives à forte valeur ajoutée actuarielle, telles que :

- Des indicateurs de fréquence individuelle de sinistralité ;
- Des variables de durée en portefeuille ;
- Des scores de comportement client ;
- Des variables de réseaux (*graph analytics*) identifiant des connexions entre dossiers.

Ces enrichissements contribueraient à améliorer significativement la capacité de discrimination du modèle, en captant des dimensions aujourd'hui absentes, notamment les effets temporels et relationnels. En pratique, cela se traduirait par une meilleure séparation entre sinistres frauduleux et non frauduleux, et donc une optimisation des actions de détection.

Au-delà de la richesse des variables, la qualité des données constitue également un enjeu majeur. Les erreurs de saisie, les données manquantes ou encore les délais dans la confirmation des fraudes peuvent introduire des biais dans l'apprentissage du modèle. Par ailleurs, la fraude étant par nature un phénomène partiellement observé, la base d'apprentissage est susceptible de contenir un biais de sous-détection, certaines fraudes n'étant jamais identifiées comme telles.

Ainsi, l'amélioration de la détection de fraude passe non seulement par le choix des modèles, mais aussi (et surtout) par une stratégie d'enrichissement et de fiabilisation des données. Dans cette perspective, l'intégration de données portefeuille, voire de données externes ou mutualisées, constitue un levier essentiel pour renforcer la robustesse et la performance du dispositif.

7.3.2 Ajout de données externes

En complément à l'enrichissement par les données issues de la base portefeuille, le recours à des **sources de données complémentaires** constitue un levier majeur d'amélioration des modèles de détection de fraude. En effet, la fraude étant un phénomène complexe et évolutif, sa détection nécessite une approche multidimensionnelle intégrant des informations variées, parfois extérieures au strict périmètre assurantiel.

En premier lieu, l'exploitation de **données externes ouvertes** (*open data*) peut permettre d'apporter un éclairage contextuel précieux. Par exemple, les données météorologiques peuvent être mobilisées afin de vérifier la cohérence entre les circonstances déclarées d'un sinistre et les conditions climatiques réelles (pluie, grêle, tempête).

De même, les **données géographiques** permettent d'identifier des zones à risque, notamment en matière de vol ou de vandalisme, et d'analyser la fréquence des sinistres dans certaines localisations. Enfin, les données socio-économiques locales peuvent contribuer à affiner la compréhension des comportements, en intégrant des variables de contexte telles que le niveau de revenu ou les caractéristiques du territoire.

Par ailleurs, lorsque cela est possible, **l'intégration de données télématiques** constitue un apport particulièrement structurant. Ces données, issues de capteurs embarqués ou d'applications mobiles, permettent de reconstituer le comportement de conduite (vitesse, accélérations, freinages, horaires d'utilisation) et d'évaluer la cohérence entre l'usage réel du véhicule et le sinistre déclaré. Ainsi, un sinistre survenu dans des conditions incompatibles avec les données de conduite enregistrées peut constituer un signal fort de fraude.

Les données issues des prestataires (réparateurs, experts, avocats) représentent également une source d'information à forte valeur ajoutée. L'analyse de leur historique d'intervention permet d'identifier des acteurs apparaissant de manière récurrente dans des dossiers suspects. Une surreprésentation de certains prestataires dans des sinistres à fort taux de fraude peut révéler des comportements anormaux, voire des complicités, et constitue ainsi un levier de détection des fraudes organisées.

En outre, l'**exploitation des données textuelles non structurées**, telles que les descriptions de sinistres ou les comptes rendus d'expertise, ouvre des perspectives intéressantes grâce aux techniques de traitement automatique du langage (NLP). L'analyse de ces textes permet de détecter des incohérences, des formulations atypiques ou des schémas linguistiques récurrents associés à des comportements frauduleux. Ces informations, difficilement exploitables dans une approche classique, enrichissent considérablement la capacité du modèle à capter des signaux faibles.

Une autre piste d'amélioration repose sur l'**utilisation d'une approche réseau** (*graph analytics*). Cette méthodologie consiste à modéliser les relations entre les différents acteurs d'un sinistre (assurés, tiers, véhicules, adresses, prestataires) afin d'identifier des communautés ou des structures anormales. Elle permet notamment de détecter des schémas de fraude organisée, caractérisés par la répétition de certaines combinaisons d'acteurs ou de situations (typiquement, les mêmes individus impliqués dans plusieurs sinistres, les mêmes véhicules ou les mêmes adresses apparaissant de manière récurrente). Cette approche relationnelle dépasse la simple analyse individuelle des dossiers et offre une vision plus globale des phénomènes de fraude.

Enfin, la **mise en place de dispositifs de mutualisation inter-assureurs** constituerait un levier particulièrement puissant. Le partage d'informations, dans un cadre réglementaire adapté, permettrait de disposer d'un historique multi-compagnies et de détecter des comportements frauduleux dits « nomades », consistant pour un individu à reproduire des schémas de fraude auprès de différents assureurs. Une telle mutualisation renforcerait significativement la capacité de détection, en élargissant le périmètre d'observation et en limitant les angles morts propres à chaque compagnie.




FIGURE 7.3 – Couplage de sources de données pour la création de l'Agent de détection de fraude

Ainsi, l'intégration de ces différentes sources de données permettrait de faire évoluer les modèles vers une approche plus globale, dynamique et contextualisée du risque de fraude, améliorant à la fois leur précision, leur robustesse et leur capacité à détecter des schémas complexes.

7.4 Mutualisation inter-assureurs et extension à une approche multiproduit

Outre l'ajout de données externes, une piste d'amélioration majeure réside dans la **mutualisation des données et des outils entre assureurs**. En effet, les fraudes organisées reposent souvent sur des schémas répétés et peuvent concerner plusieurs compagnies. Un fraudeur détecté chez un assureur est susceptible de reproduire des comportements similaires auprès d'autres acteurs du marché.¹

Le partage d'informations, dans un cadre réglementaire maîtrisé, permettrait d'améliorer les **taux de détection des fraudes en bande organisée**, en identifiant plus rapidement des schémas récurrents et des profils à risque. Un agent IA alimenté par une base mutualisée bénéficierait ainsi d'une **vision élargie**, renforçant significativement son efficacité.

Un cas emblématique de fraude automobile organisée en France concerne le détournement du système d'immatriculation des véhicules (SIV), mis en place en 2009 et dont les démarches ont été entièrement dématérialisées en 2017. Des réseaux ont exploité la possibilité, offerte aux professionnels habilités de réaliser des démarches administratives, en créant des « garages fictifs » servant de sociétés écrans. Ces structures ont permis l'immatriculation massive de véhicules frauduleux, facilitant notamment la réintroduction de véhicules volés dans le circuit légal et la dissimulation de leur traçabilité.²

Selon plusieurs enquêtes de presse et sources sectorielles, cette fraude concernerait jusqu'à un million de véhicules et représenterait plus de 500 millions d'euros de pertes. Certains cas individuels font état de plusieurs milliers de véhicules immatriculés frauduleusement via une seule entité.

Ce type de fraude peut être qualifié de fraude en bande organisée dans la mesure où il repose sur une coordination de plusieurs acteurs aux rôles complémentaires : création de sociétés fictives, obtention d'habilitations administratives, production de documents frauduleux et utilisation répétée du dispositif à grande échelle. La structuration du schéma, son caractère durable dans le temps ainsi que les volumes traités témoignent d'une organisation planifiée et non d'initiatives individuelles isolées.

Bien que cette fraude ne cible pas directement un assureur en particulier, elle entraîne des répercussions significatives sur l'ensemble du secteur de l'assurance automobile, en complexifiant la gestion des sinistres et en facilitant des fraudes secondaires. Ce type de schéma illustre le caractère structuré et organisé des fraudes de grande ampleur dans le domaine automobile.³

Enfin, l'approche développée pourrait être étendue à une analyse transverse des comportements de fraude tous produits confondus. En effet, un individu impliqué dans une fraude en assurance automobile peut présenter un risque accru de fraude sur d'autres lignes de produits, telles que l'assurance habitation (MRH).

Une vision consolidée du client à travers l'ensemble des garanties permettrait de mieux capter ces comportements et d'améliorer la cohérence globale de la détection.

Cette approche multiproduits s'inscrit dans une logique actuarielle de **vision client 360°**, encore peu exploitée mais porteuse de gains significatifs en matière de lutte contre la fraude.

1. <https://www.ccomptes.fr/fr/publications/la-fraude-aux-cartes-grises>

2. <https://www.ccomptes.fr/fr/publications/la-fraude-aux-cartes-grises>

3. Sources : <https://questions.assemblee-nationale.fr/q17/17-4793QE.htm> ; <https://www.senat.fr/questions/base/2025/qSEQ250102893.html>

Conclusion

Ce mémoire a pour objectif de concevoir un outil d'aide à la décision permettant de détecter la fraude en assurance automobile et d'orienter les efforts d'investigation vers les dossiers les plus à risque. Il vise ainsi à répondre à une difficulté structurelle de la lutte anti-fraude : le coût d'une investigation manuelle, qui rend non rentable le contrôle de la fraude de faible montant et laisse échapper une part importante du préjudice. L'enjeu était donc de montrer qu'un agent d'intelligence artificielle pouvait automatiser cette détection à moindre coût et à grande échelle.

Pour y parvenir, il a d'abord fallu constituer une base de travail réaliste. Faute de données réelles suffisamment riches, nous avons enrichi une base publique de sinistres automobiles de vingt-neuf variables simulées, reproduisant l'information dont dispose réellement un assureur au moment d'un sinistre (historique de l'assuré, du réparateur, du véhicule et du tiers, comportement déclaratif, etc.). Ce choix, assumé comme une limite, a permis de rapprocher l'exercice des conditions opérationnelles réelles.

La démarche s'est ensuite structurée autour de la construction d'un agent piloté par un *prompt* décomposé en étapes successives, reproduisant la logique actuarielle : ingestion et audit de la qualité des données, analyse statistique descriptive, puis construction et comparaison des modèles de prédiction de fraude. Trois modèles ont été calibrés puis évalués selon un arbitrage entre interprétabilité et performance : un *scoring* en points, un arbre de décision et un modèle de Gradient *Boosting*.

Ce dernier s'est révélé le plus discriminant, sans toutefois disqualifier le *scoring* en points, qui demeure une alternative crédible lorsque la transparence prime. Nous avons par ailleurs constaté que les trois modèles faisaient converger leur pouvoir explicatif vers les mêmes variables clés, ce qui a renforcé la confiance dans la cohérence des résultats avec l'intuition métier.

Une fois le modèle sélectionné, celui-ci a été intégré au sein d'un outil opérationnel destiné à être utilisé au quotidien par les équipes de gestion des sinistres. L'un des partis pris forts de ce travail a précisément été de décliner l'ensemble en deux modules indépendants, pensés pour deux profils d'utilisateurs distincts. Le premier, destiné aux actuaires, prend en charge la construction et la calibration du modèle ; le second, destiné aux gestionnaires de sinistres, en permet l'exploitation quotidienne sans en exposer la complexité, en restituant pour chaque dossier une probabilité de fraude et une orientation d'investigation. Cette séparation des rôles répond à une réalité de terrain : ceux qui conçoivent le modèle et ceux qui l'utilisent ne font pas partie des mêmes équipes.

Enfin, l'outil a été pensé non comme un modèle figé mais comme un dispositif évolutif : une boucle de rétroaction réintègre dans la base d'apprentissage les dossiers dont l'investigation est close, permettant un recalibrage régulier sur des cas avérés, tandis qu'un rapport de pilotage mesure en continu la valeur ajoutée de l'outil (fraude évitée, impact sur le ratio Sinistres/Primes, retour sur investissement).

Ce travail comporte naturellement des limites. La principale tient au caractère partiellement simulé des données et à la sur-représentation de la fraude dans la base retenue, qui imposeraient de recalibrer le modèle sur une sinistralité réellement représentative avant tout déploiement. Par ailleurs, l'approche supervisée adoptée ne détecte que la fraude de type connu, celle dont on possède des exemples historiques labellisés ; elle reste par construction aveugle aux schémas de fraude organisée ou inédits. Plusieurs prolongements permettraient de dépasser ces limites : le couplage à une base portefeuille, l'intégration de données externes, le recours à des

méthodes non supervisées ou d'analyse de graphes pour la fraude en réseau, la mutualisation inter-assureurs pour repérer les fraudeurs « nomades », ou encore l'extension de l'outil à d'autres branches de l'assurance non-vie.

Au-delà de la seule performance technique, ce mémoire illustre la place croissante de l'actuaire dans la conception d'outils décisionnels concrets, à l'intersection de la modélisation, de la contrainte réglementaire et de l'usage métier. La détection de la fraude est devenue un enjeu stratégique pour les assureurs, et si l'intelligence artificielle en démultiplie aujourd'hui les moyens, elle ne prendra tout son sens qu'articulée à une supervision humaine garante de la maîtrise du risque et du respect des droits des assurés.

Annexes

Annexe A : Méthodes de classification

Le clustering par K-means : regroupement autour de centres mobiles

Principe

Le *clustering* est une méthode statistique de division d'un ensemble de données en groupes homogènes. L'homogénéité n'a pas de sens en elle-même : elle se définit par un critère de proximité, lequel suppose d'avoir introduit au préalable une mesure de distance entre les observations. De nombreux algorithmes conduisent à une partition des données ; celui des K-means est l'un des plus répandus et convient notamment au découpage d'une variable quantitative continue.

Son principe est itératif. On part d'une partition aléatoire de l'ensemble des observations en K classes, puis on reforme pas à pas ces K classes de manière à ce qu'elles contiennent des individus de plus en plus proches les uns des autres. L'algorithme s'arrête lorsque la partition n'évolue plus.

Cadre et notations

Considérons un ensemble fini E de n individus décrits par p caractéristiques quantitatives. Dès que p dépasse 2, la représentation des individus ne tient plus dans un repère simple : on raisonne sur un nuage de n points de $\mathbb{R}^p$, chaque individu étant représenté par un vecteur x_i .

Les variables ne sont pas nécessairement exprimées dans la même unité, ni du même ordre de grandeur. Sans précaution, celles dont l'échelle est la plus large domineraient entièrement le calcul des distances. Elles sont donc centrées et réduites au préalable, chaque variable étant transformée selon :

$$x_i^j \longrightarrow \frac{x_i^j - \bar{x}_j}{\sigma_j} \quad (7.1)$$

Où $\bar{x}_j$ désigne la moyenne de la j -ième variable et σ_j son écart-type. Chaque variable pèse alors le même poids dans la mesure de proximité. L'objectif est de répartir les n individus en K classes homogènes.

La notion de distance

Une distance sur un ensemble E est une application d définie sur le produit $E^2 = E \times E$ et à valeurs dans l'ensemble $\mathbb{R}^+$ des réels positifs, qui vérifie les trois propriétés suivantes :

- **symétrie** : $d(x, y) = d(y, x)$ pour tout couple d'éléments ;
- **séparation** : $d(x, y) = 0$ si et seulement si $x = y$;
- **inégalité triangulaire** : $d(x, z) \leq d(x, y) + d(y, z)$ pour tout triplet d'éléments.

Deux distances sont d'usage courant. La distance euclidienne :

$$d(x, y) = \sqrt{\sum_{j=1}^p (x^j - y^j)^2} \quad (7.2)$$

Et la distance de Manhattan :

$$d(x, y) = \sum_{j=1}^p |x^j - y^j| \quad (7.3)$$

Le choix de la distance n'est pas neutre : la distance euclidienne, qui élève les écarts au carré, accorde plus de poids aux observations éloignées que la distance de Manhattan. Dans le cas particulier d'une variable unique, les deux se confondent avec l'écart absolu entre les valeurs.

Inertie et critère de classification

L'inertie d'un nuage de n points est la moyenne des carrés des distances de ces points à leur centre de gravité, noté g . L'inertie totale s'écrit :

$$I_T = \frac{1}{n} \sum_{i=1}^n d^2(x_i, g) \quad \text{avec} \quad g = \frac{1}{n} \sum_{i=1}^n x_i \quad (7.4)$$

Pour un ensemble de points donné, cette quantité est une constante : elle ne dépend pas de la partition retenue. C'est précisément ce qui en fait une référence pour juger de la qualité d'une classification.

Une classe (ou *cluster*) k est un ensemble non vide d'observations, noté $\pi_k = \{i \mid x_i \text{ appartient à la classe } k\}$. Son effectif est $n_k = \text{Card } \pi_k$, et son centre de gravité :

$$g_k = \frac{1}{n_k} \sum_{i \in \pi_k} x_i \quad (7.5)$$

L'inertie de cette classe mesure sa dispersion interne :

$$I_k = \frac{1}{n_k} \sum_{i \in \pi_k} d^2(x_i, g_k) \quad (7.6)$$

Une classe est d'autant plus homogène que ses éléments sont proches de son centre de gravité, c'est-à-dire que son inertie est faible.

La mesure globale de l'homogénéité des classes est la moyenne des inerties des K classes, chacune pondérée par son poids relatif. On l'appelle inertie intra-classes, d'où le symbole W (pour *within*) :

$$I_W = \sum_{k=1}^K \frac{n_k}{n} I_k = \frac{1}{n} \sum_{k=1}^K \sum_{i \in \pi_k} d^2(x_i, g_k) \quad (7.7)$$

Symétriquement, l'inertie du nuage des K centres de gravité mesure la séparation des classes. On l'appelle inertie inter-classes, d'où le symbole B (pour *between*) :

$$I_B = \sum_{k=1}^K \frac{n_k}{n} d^2(g_k, g) \quad (7.8)$$

Le théorème de Huygens relie ces trois quantités :

$$I_T = I_W + I_B \quad (7.9)$$

L'inertie totale étant constante, minimiser l'inertie intra-classes et maximiser l'inertie inter-classes sont deux formulations du même problème : chercher des classes à la fois homogènes en leur sein et bien séparées les unes des autres. Le critère de classification retenu est donc celui qui rend l'inertie intra-classes minimale. Ce problème n'admet pas de solution analytique et se résout par itérations successives.

L'algorithme

À chaque étape de l'algorithme, chaque individu porte un numéro de classe compris entre 1 et K . Notons $L_t^{(i)}$ le numéro de la classe de l'individu x_i à l'issue de l'étape t , et g_k^t le centre de gravité de la classe k à cette même étape.

Étape 1 : Initialisation. K centres de gravité g_k^0 sont tirés aléatoirement, puis chaque individu est affecté à la classe dont le centre est le plus proche :

$$L_0^{(i)} = n \quad \text{tel que} \quad d(x_i, g_n^0) = \min_{k \in \llbracket 1; K \rrbracket} \{d(x_i, g_k^0)\} \quad (7.10)$$

À l'issue de cette première étape, K groupes sont constitués, mais de façon purement arbitraire : ils contiennent des individus qui ne se ressemblent pas. Les étapes suivantes vont progressivement attirer vers un même centre les individus semblables.

Étape 2 : Réaffectation. Les barycentres des classes obtenues à l'étape précédente sont recalculés, puis chaque observation est réaffectée au barycentre dont elle est la plus proche. De nouvelles classes se forment :

$$L_t^{(i)} = n \quad \text{tel que} \quad d(x_i, g_n^t) = \min_{k \in \llbracket 1; K \rrbracket} \{d(x_i, g_k^t)\} \quad (7.11)$$

Étape 3 : Itération. L'étape 2 est renouvelée jusqu'à l'obtention d'un critère de classification stable, c'est-à-dire jusqu'à ce que plus aucune observation ne change de classe d'une itération à la suivante.

Remarque : dépendance à l'initialisation

Le processus de classification est simple, mais la partition finale dépend de la partition aléatoire initiale : l'algorithme converge vers un minimum local de l'inertie intra-classes, et non nécessairement vers le minimum global. Il convient donc de relancer l'algorithme un nombre suffisant de fois, à partir de tirages initiaux différents, et de retenir la meilleure partition obtenue. C'est à cette condition seulement que la classification choisie peut être jugée robuste.

Le choix du nombre de classes

Le nombre de classes K n'est pas déterminé par l'algorithme : il doit être fixé en entrée. Pour perdre le moins d'information possible, on le choisit de sorte que le rapport de la variance inter-classes à la variance totale atteigne un seuil élevé, fixé par exemple à 95 % :

$$\frac{\text{variance inter-classes}}{\text{variance totale}} > 95 \% \quad (7.12)$$

Ce rapport croît mécaniquement avec K : il vaut 1 lorsque chaque observation forme sa propre classe : de sorte

que le seuil retenu arbitre entre finesse de la partition et parcimonie. En pratique, on retient le plus petit nombre de classes satisfaisant le seuil.

Remarque : exploitabilité de la partition obtenue

Les classes issues de l'algorithme ne sont pas toujours utilisables telles quelles. Le cas le plus fréquent est celui de classes d'effectifs très hétérogènes, certaines étant trop peu peuplées pour qu'un paramètre puisse y être estimé de façon fiable. Il est alors nécessaire de procéder à des regroupements complémentaires, propres à la problématique étudiée, pour rendre la partition exploitable (au prix d'un écart au critère d'inertie initialement optimisé).

La Classification Hiérarchique Ascendante

Principe

Lorsqu'une population décrite par des variables quantitatives doit être partitionnée en sous-populations relativement homogènes, une seconde approche consiste à procéder par agrégations successives. On part des individus pris un à un et l'on regroupe les plus semblables ; une fois les premiers regroupements effectués, l'opération est renouvelée sur les classes ainsi formées, de manière à constituer des classes de classes, jusqu'à obtenir à l'extrême une unique classe réunissant l'ensemble de la population.

La proximité, entre individus comme entre classes déjà formées, est mesurée par une distance. Cette construction ascendante, qui remonte jusqu'à un groupe unique, porte le nom de Classification Hiérarchique Ascendante (CAH). Elle produit non pas une partition, mais une hiérarchie de partitions emboîtées, à l'image d'un système d'appartenances successives : un astre appartient à un système, qui appartient à un amas, lui-même inclus dans une galaxie, et ainsi de suite jusqu'à l'univers entier.

À chaque étape de l'agrégation, de l'information est perdue, puisque des éléments jusque-là distincts deviennent indiscernables ; mais l'on sait en contrepartie que les éléments réunis dans une même classe sont relativement proches les uns des autres.

L'algorithme

Première étape : Préparation des données. Mesurer une distance entre individus suppose des données numériques et comparables entre elles. Deux traitements sont donc appliqués au préalable :

- les variables qualitatives sont rendues quantitatives. La technique usuelle consiste à créer, pour chaque modalité existante, une variable indicatrice valant 1 en cas de présence de la modalité et 0 en cas d'absence ;
- les variables sont centrées et réduites, en retranchant la moyenne de la variable considérée et en divisant par son écart-type, afin que chacune pèse le même poids dans le calcul des distances.

Deuxième étape : Application de l'algorithme.

Initialisation. Les classes initiales sont les n singletons, chaque individu constituant sa propre classe. La matrice des distances deux à deux entre ces n classes est calculée.

Regroupement. Les deux classes les plus proches, au sens de la distance entre groupes retenue, sont réunies. Le tableau des distances est mis à jour : les deux classes fusionnées y sont remplacées par la classe nouvellement formée, dont la distance à chacune des autres classes est recalculée.

Itération. Les deux opérations précédentes sont répétées jusqu'à l'agrégation de l'ensemble des observations en une classe unique.

L'algorithme effectue ainsi $n - 1$ regroupements, chacun correspondant à un niveau de la hiérarchie. Aucun choix de nombre de classes n'intervient pendant son déroulement : contrairement aux K-means, la décision est reportée à la lecture du résultat.

Le choix d'une distance entre classes : la méthode de Ward

La CAH suppose de définir une distance non pas entre individus, mais entre groupes d'individus. Ce choix est appelé stratégie d'agrégation, et il détermine entièrement la forme de la hiérarchie obtenue.

La méthode de Ward est la plus courante. Elle consiste à réunir, à chaque étape, les deux classes dont le regroupement fera le moins baisser l'inertie inter-classes. La distance de Ward entre deux classes A et B est définie comme le carré de la distance entre leurs centres de gravité, pondéré par les effectifs des deux classes :

$$\Delta(A, B) = \frac{n_A \times n_B}{n_A + n_B} \times d^2(g_A, g_B) \quad (7.13)$$

où :

- n_A et n_B désignent les effectifs des classes A et B ;
- g_A et g_B leurs centres de gravité respectifs ;
- d la distance euclidienne, dont l'existence entre observations est ici supposée.

La pondération par les effectifs a une conséquence pratique notable : à distance égale entre centres de gravité, deux petites classes sont réunies avant deux grandes. La méthode de Ward tend donc à regrouper les petites classes entre elles, et produit des hiérarchies relativement équilibrées.

Remarque : lien avec la décomposition de l'inertie

Lorsque deux classes sont remplacées par leur réunion, la diminution de l'inertie inter-classes et donc par le théorème de Huygens, l'augmentation de l'inertie intra-classes est exactement égale à la distance de Ward entre ces deux classes. La méthode de Ward revient ainsi à choisir, à chaque étape, le regroupement qui dégrade le moins l'homogénéité interne des classes. C'est le même critère d'inertie que celui des K-means, appliqué de façon séquentielle et non plus globale.

La représentation : l'arbre de classification

La notion de hiérarchie s'appréhende aisément par une représentation visuelle appelée arbre de classification, ou dendrogramme. Il s'agit d'un arbre binaire représentant les agrégations successives, depuis les individus isolés jusqu'à la réunion de tous en une classe unique.

La hauteur d'une branche y est proportionnelle à la distance entre les deux objets regroupés. Dans le cas du saut de Ward, elle est donc proportionnelle à la perte d'inertie inter-classes occasionnée par le regroupement : une branche haute signale la réunion de deux classes qui se ressemblaient peu.

Le choix du nombre de classes

Le nombre de classes à retenir revient à couper l'arbre à une certaine hauteur. Cette partition doit d'abord être définie en accord avec les objectifs de l'étude ; l'arbre fournit ensuite un critère de lecture.

À chaque agrégation, la distance entre les groupes réunis diminue, et cette décroissance est directement lisible sur le dendrogramme. La meilleure partition est généralement celle qui précède une valeur de la distance inter-classes brutalement plus faible : au-delà de ce point, les regroupements suivants ne réunissent plus que des classes

déjà très semblables et n'apportent donc plus d'information. Une forte perte d'inertie inter-classes observée au passage de k à $k - 1$ classes conduit ainsi à retenir k classes.

Remarque : effectifs et pertinence des classes

Comme pour les K-means, les classes obtenues peuvent présenter des effectifs hétérogènes, voire insuffisants au regard des seuils habituellement retenus. Le réflexe de les regrouper n'est toutefois pas systématique : lorsque la faiblesse d'un effectif traduit un écart réel et durable de comportement (une modalité rare mais nettement plus risquée que les autres, par exemple) la fusionner avec une classe voisine ferait disparaître l'information même que la classification avait mise en évidence. L'arbitrage entre robustesse statistique et finesse de la segmentation relève alors du jugement, non de l'algorithme.

Annexe B : Analyse détaillée des variables - sortie complète de l'agent

Vue complète de la sortie de l'agent IA évoquée au chapitre 4 sur les différentes analyses réalisées

Analyse de la qualité des données de la base


Description de chaque colonne du fichier CSV — types, modalités, taux de remplissage et saisie obligatoire d'une valeur unique pour chaque variable contenant des cases vides avant de lancer les analyses suivantes.

VARIABLES		COMPLÈTEMENT RENSEIGNÉES		AVEC VALEURS MANQUANTES		VALEURS ABRÉVIÉES							
53		53		0		0							
Rechercher une variable...		Tous		Booléen (Vrai/Faux)		Date		Entier		Texte (Alphanumérique)		53 / 53 variables affichées	
VARIABLE	TRADUCTION FR	TYPE ATTENDU	TYPE DÉTECTÉ	MODALITÉS / PLAGE		REMPLEISSAGE	VALEURS MANQUANTES	INCLURE					
policy_id	Identifiant du contrat / de la police	Texte ou Entier (Alphanumérique)	Texte (Alphanumérique)	30000 valeurs distinctes (ex: POL100000 POL100001 POL100002 POL100003 POL100004...)		100%	Non nécessaire	☐ ID					
policy_state	État de souscription du contrat (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX		100%	Non nécessaire	☒					
policy_deductible	Franchise du contrat	Catégorie ordonnée (montant de franchise)	Entier	200 300 400 500 600 700 800 1000		100%	Non nécessaire	☒					
policy_annual_premium	Prime annuelle d'assurance	Catégorie ordonnée (classes)	Texte (Alphanumérique)	600,02 600,04 600,05 600,07 600,13 600,19 600,29 600,31 600,39 600,43 600,47 600,53 600,54 60...		100%	Non nécessaire	☒					
insured_age	Âge de l'assuré	Catégorie ordonnée (classes)	Entier	18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 4...		100%	Non nécessaire	☒					
insured_sex	Sexe de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	FEMALE MALE OTHER		100%	Non nécessaire	☒					
insured_education_level	Niveau d'études de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	College High School Masters PhD		100%	Non nécessaire	☒					
insured_occupation	Profession de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	Clerk Doctor Engineer Lawyer Manager Sales Teacher Technician		100%	Non nécessaire	☒					
insured_hobbies	Loisirs de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	camping chess hiking movies paintball reading yachting		100%	Non nécessaire	☒					
incident_date	Date de l'incident / sinistre	Date	Date	01/01/2024 – 31/12/2024		100%	Non nécessaire	☒					
incident_type	Type d'incident	Texte (Catégorique)	Texte (Alphanumérique)	Multi-vehicle Collision Parked Car Single Vehicle Collision Vehicle Theft		100%	Non nécessaire	☒					
collision_type	Type de collision	Texte (Catégorique)	Texte (Alphanumérique)	Front Rear Side Unknown		100%	Non nécessaire	☒					
incident_severity	Gravité de l'incident	Texte (Catégorique)	Texte (Alphanumérique)	Major Damage Minor Damage Total Loss		100%	Non nécessaire	☒					
authorities_contacted	Autorités contactées (ex: Police, Pompier)	Texte (Catégorique)	Texte (Alphanumérique)	Ambulance Aucun Fire Police		100%	Non nécessaire	☒					
incident_state	État où s'est produit l'incident (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX		100%	Non nécessaire	☒					
incident_city	Ville où s'est produit l'incident	Texte (Catégorique)	Texte (Alphanumérique)	17931 valeurs distinctes (ex: Aaroberg Aaroborough Aaroburgh Aarofort Aarofurt...)		100%	Non nécessaire	☒					
incident_hour_of_the_day	Heure de l'incident (0 à 23)	Catégorie ordonnée (classes)	Entier	0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23		100%	Non nécessaire	☒					
number_of_vehicles_involved	Nombre de véhicules impliqués	Entier	Entier	[1 : 4]		100%	Non nécessaire	☒					
bodily_injuries	Nombre de blessés / Dommages corporels	Entier	Entier	[0 : 4]		100%	Non nécessaire	☒					
witnesses	Nombre de témoins	Entier	Entier	[0 : 5]		100%	Non nécessaire	☒					
police_report_available	Rapport de police disponible (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	No Yes		100%	Non nécessaire	☒					
claim_amount	Montant réclamé pour les dommages	Nombre (Décimal)	Texte (Alphanumérique)	29779 valeurs distinctes (ex: 10000,08 10000,78 10001,09 10001,29 10001,42...)		100%	Non nécessaire	☒					
total_claim_amount	Montant total de la réclamation	Catégorie ordonnée (classes)	Texte (Alphanumérique)	502,18 502,36 504,57 505,28 506,95 507,44 508,13 508,44 508,66 509,77 509,94 510,28 510,78 51...		100%	Non nécessaire	☒					
fraud_reported	Fraude avérée / signalée (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	N Y		100%	Non nécessaire	☒					
insured_id	Identifiant de l'assuré	Texte (Alphanumérique)	Texte (Alphanumérique)	25544 valeurs distinctes (ex: INS0000001 INS0000002 INS0000003 INS0000005 INS0000006...)		100%	Non nécessaire	☒					
insured_nb_past_claims	Nb sinistres passés (assuré)	Entier	Entier	[0 : 5]		100%	Non nécessaire	☒					
insured_nb_past_fraud	Nb fraudes passées (assuré)	Entier	Entier	[0 : 3]		100%	Non nécessaire	☒					
insured_days_since_last_claim	Jours depuis le dernier sinistre	Catégorie ordonnée (classes)	Entier	60 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80 81 82 83 84 85 8...		100%	Non nécessaire	☒					
insured_claim_amount_history	Historique montants réclamés (assuré)	Catégorie ordonnée (classes)	Texte (Alphanumérique)	0,32 1,45 2,69 4,51 5,84 6,37 6,46 8,08 8,6 10,21 10,6 10,74 11,8 12,27 14,13 14,75 16,52 16,58 ...		100%	Non nécessaire	☒					
policy_age_at_incident_days	Antécédent du contrat à l'incident (jours)	Catégorie ordonnée (classes)	Entier	30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 5...		100%	Non nécessaire	☒					


insured_nb_policies_active	Nb de polices actives (assuré)	Entier	Entier	[1 ; 4]	100%	Non nécessaire	✓
insured_address_changes_12m	Changements d'adresse (12 mois)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	✓
repairer_id	Identifiant du réparateur / garage	Texte (Alphanumérique)	Texte (Alphanumérique)	900 valeurs distinctes (ex: GAR0001 GAR0002 GAR0003 GAR0004 GAR0005...)	100%	Non nécessaire	✓
repairer_nb_claims_total	Nb total sinistres (réparateur)	Entier	Entier	[0 ; 197]	100%	Non nécessaire	✓
repairer_nb_fraud_confirmed	Nb fraudes confirmées (réparateur)	Entier	Entier	[0 ; 87]	100%	Non nécessaire	✓
repairer_fraud_rate	Taux de fraude du réparateur	Catégorie ordonnée (classes)	Texte (Alphanumérique)	36 valeurs distinctes (ex: 0 0.01 0.02 0.03 0.04...)	100%	Non nécessaire	✓
repairer_avg_invoice_vs_market	Ratio facture / marché (réparateur)	Catégorie ordonnée (classes)	Texte (Alphanumérique)	0.87 0.871 0.872 0.873 0.874 0.875 0.876 0.877 0.878 0.879 0.88 0.881 0.882 0.883 0.884 0.885 ...	100%	Non nécessaire	✓
repairer_is_flagged	Réparateur signalé (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
third_party_id	Identifiant du tiers impliqué	Texte (Alphanumérique)	Texte (Alphanumérique)	7802 valeurs distinctes (ex: NONE TRS00001 TRS00002 TRS00003 TRS00005...)	100%	Non nécessaire	✓
third_party_nb_past_incidents	Nb incidents passés (tiers)	Entier	Entier	[0 ; 4]	100%	Non nécessaire	✓
witness_id	Identifiant du témoin	Texte (Alphanumérique)	Texte (Alphanumérique)	10514 valeurs distinctes (ex: NONE WIT00001 WIT00004 WIT00005 WIT00007...)	100%	Non nécessaire	✓
insured_third_party_known	Tiers connu de l'assuré (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
vehicle_id	Identifiant du véhicule	Texte (Alphanumérique)	Texte (Alphanumérique)	18069 valeurs distinctes (ex: VEH000005 VEH000010 VEH000011 VEH000018 VEH000019...)	100%	Non nécessaire	✓
vehicle_age_years	Âge du véhicule (années)	Catégorie ordonnée (classes)	Entier	0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20	100%	Non nécessaire	✓
vehicle_market_value	Valeur marchande du véhicule	Catégorie ordonnée (classes)	Texte (Alphanumérique)	2010.22 2014.5 2014.73 2015.87 2016.22 2024.88 2031.11 2038.2 2038.27 2041.25 2042.78 2051.97 ...	100%	Non nécessaire	✓
vehicle_overvalue_ratio	Ratio surévaluation du véhicule	Catégorie ordonnée (classes)	Texte (Alphanumérique)	0.008 0.009 0.01 0.011 0.012 0.013 0.014 0.015 0.016 0.017 0.018 0.019 0.02 0.021 0.022 0.023 ...	100%	Non nécessaire	✓
vehicle_nb_past_claims	Nb sinistres passés (véhicule)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	✓
nb_amendments_declaration	Nb d'amendements à la déclaration	Entier	Entier	[0 ; 4]	100%	Non nécessaire	✓
declaration_channel	Canal de déclaration du sinistre	Texte (Catégorique)	Texte (Alphanumérique)	agence courtier telephone web	100%	Non nécessaire	✓
injury_claimed_without_medical	Blessure déclarée sans preuve médicale	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
incident_rip_fraud_rate	Taux de fraude du code postal de l'incident	Catégorie ordonnée (classes)	Texte (Alphanumérique)	0.1062 0.1092 0.1105 0.1117 0.115 0.1171 0.1176 0.118 0.1191 0.1223	100%	Non nécessaire	✓
incident_is_weekend	Incident en week-end (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
incident_is_holiday	Incident un jour férié (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓

Annexe C : Composition détaillée du portefeuille - sortie complète de l'agent


Tranche d'âge




Nombre de témoins




Blessés corporels




Créneau horaire




Franchise du contrat




Distribution du montant réclamé / dommages (en €)




Distribution du montant total du sinistre (en €)



Sexe de l'assuré



Rapport de police disponible



Autorités contactées




Type d'incident



Sévérité de l'incident




Type de collision



Profession de l'assuré




Loisirs de l'assuré



Niveau d'éducation




Nombre d'amendements à la déclaration



Nombre de véhicules impliqués




Nb sinistres passés (assuré)




Nb fraudes passées (assuré)




Nb de polices actives (assuré)



Changements d'adresse (12 mois)




Réparateur signalé (0/1)




Nb incidents passés (tiers)




Tiers connu de l'assuré (0/1)




Nb sinistres passés (véhicule)




Canal de déclaration du sinistre



Blessure déclarée sans preuve médicale



Taux de fraude du code postal de l'incident



Annexe D : Matrices de corrélations entre variables qualitatives et quantitatives - sortie complète de l'agent

Quantitatives × quantitatives

Variable	insured_address_changes_12m	insured_nb_past_claims	insured_nb_past_fraud	insured_nb_policies_active	nb_amendments_declaration	repairer_nb_claims_total	repairer_nb_fraud_confirmed	third_party_nb_past_incidents	vehicle_nb_past_claims	witnesses
insured_address_changes_12m	1	0,03	0,04	0,03	0,02	0,01	0,02	0,01	0,02	0,00
insured_nb_past_claims	0,03	1	0,03	0,02	0,02	0,01	0,02	0,02	0,02	-0,01
insured_nb_past_fraud	0,04	0,03	1	0,03	0,04	0,02	0,04	0,03	0,03	-0,03
insured_nb_policies_active	0,03	0,02	0,03	1	0,03	0,01	0,01	0,02	0,02	-0,02
nb_amendments_declaration	0,02	0,02	0,04	0,03	1	0,02	0,02	0,02	0,03	-0,02
repairer_nb_claims_total	0,01	0,01	0,02	0,01	0,02	1	0,72	0,13	0,02	0,00
repairer_nb_fraud_confirmed	0,02	0,02	0,04	0,01	0,02	0,72	1	0,09	0,04	0,00
third_party_nb_past_incidents	0,01	0,02	0,03	0,02	0,02	0,13	0,09	1	0,03	0,00
vehicle_nb_past_claims	0,02	0,02	0,03	0,02	0,03	0,02	0,04	0,03	1	-0,03
witnesses	0,00	-0,01	-0,03	-0,02	-0,02	0,00	0,00	0,00	-0,03	1

Qualitatives × quantitatives :

Variable	incident_severity	incident_state	incident_type	incident_zlp_fraud_rate	injury_claimed_without_medical	insured_age	insured_claim_amount_history	insured_days_since_last_claim	insured_education_level	insured_hobbies	insured_occupation	insured_sex	insured_third_party_known	police_report_available	policy_age_at_incident_days	policy_annual_premium	policy_deductible	policy_state	repairer_avg_invoice_vs_market	repairer_fraud_rate	repairer_is_flagged	total_claim_amount	vehicle_age_years	vehicle_market_value	vehicle_overvalue_ratio
bodily_injuries	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
claim_amount	0,00	0,00	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,00	0,00	0,00	0,02	0,00	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,77	0,01	0,00	0,44
insured_address_changes_12m	0,00	0,00	0,00	0,00	0,02	0,01	0,05	0,00	0,00	0,00	0,00	0,00	0,02	0,00	0,00	0,00	0,00	0,00	0,05	0,00	0,04	0,00	0,02	0,00	0,00
insured_nb_past_claims	0,00	0,00	0,00	0,00	0,03	0,01	0,03	0,00	0,00	0,00	0,00	0,00	0,02	0,01	0,00	0,00	0,00	0,00	0,04	0,00	0,03	0,00	0,01	0,00	0,00
insured_nb_past_fraud	0,00	0,00	0,00	0,00	0,05	0,02	0,07	0,00	0,00	0,00	0,00	0,00	0,04	0,00	0,00	0,00	0,00	0,00	0,08	0,01	0,06	0,00	0,04	0,00	0,00
insured_nb_policies_active	0,00	0,00	0,00	0,00	0,04	0,01	0,04	0,00	0,00	0,00	0,00	0,00	0,02	0,00	0,00	0,00	0,00	0,00	0,04	0,00	0,03	0,00	0,01	0,00	0,00
nb_amendments_declaration	0,00	0,00	0,00	0,00	0,04	0,02	0,05	0,00	0,00	0,00	0,00	0,00	0,03	0,00	0,00	0,00	0,00	0,00	0,07	0,00	0,06	0,00	0,02	0,00	0,00
number_of_vehicles_involved	0,00	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,00	0,00
repairer_nb_claims_total	0,00	0,00	0,08	0,00	0,03	0,03	0,05	0,00	0,00	0,00	0,00	0,00	0,04	0,00	0,00	0,00	0,00	0,00	0,60	0,67	0,45	0,00	0,02	0,00	0,00
repairer_nb_fraud_confirmed	0,00	0,00	0,01	0,00	0,06	0,03	0,09	0,00	0,00	0,00	0,00	0,00	0,06	0,00	0,00	0,00	0,00	0,00	0,85	0,70	0,78	0,00	0,04	0,00	0,00
third_party_nb_past_incidents	0,00	0,00	0,08	0,00	0,02	0,01	0,05	0,00	0,00	0,00	0,00	0,00	0,02	0,00	0,00	0,00	0,00	0,00	0,09	0,03	0,07	0,00	0,02	0,00	0,00

Qualitatives × qualitatives :

Variable	authorities_contacted	collision_type	declaration_channel	incident_hour_of_the_day	incident_is_holiday	incident_is_weekend	incident_severity	incident_state	incident_type	incident_zip_fraud_rate	injury_claimed_without_medical	insured_age	insured_claim_amount_history	insured_days_since_last_claim	insured_education_level	insured_hobbies	insured_occupation	insured_sex	insured_third_party_known	policy_report_available	policy_age_at_incident_days	policy_annual_premium	policy_deductible	policy_state	repairer_avg_invoice_vs_market
authorities_contacted	1	0,01	0,01	0,01	0,01	0,01	0,01	0,02	0,01	0,01	0,03	0,01	0,05	0,02	0,01	0,01	0,01	0,01	0,01	0,03	0,02	0,01	0,01	0,01	0,07
collision_type	0,01	1	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,02	0,01	0,01	0,01	0,02	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,00
declaration_channel	0,01	0,01	1	0,01	0,01	0,00	0,01	0,02	0,00	0,01	0,02	0,01	0,03	0,01	0,01	0,01	0,02	0,01	0,01	0,01	0,01	0,02	0,01	0,01	0,03
incident_hour_of_the_day	0,01	0,01	0,01	1	0,00	0,00	0,01	0,02	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,02	0,00
incident_is_holiday	0,01	0,01	0,01	0,00	1	0,05	0,00	0,02	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,01	0,00	0,00	0,00	0,00	0,01	0,01	0,02	0,03	0,00
incident_is_weekend	0,01	0,01	0,00	0,00	0,05	1	0,00	0,02	0,01	0,01	0,00	0,00	0,00	0,01	0,01	0,02	0,02	0,01	0,00	0,01	0,01	0,01	0,02	0,02	0,00
incident_severity	0,01	0,01	0,01	0,01	0,00	0,00	1	0,01	0,01	0,01	0,01	0,00	0,03	0,01	0,01	0,01	0,01	0,01	0,02	0,01	0,01	0,01	0,01	0,02	0,03
incident_state	0,02	0,01	0,02	0,02	0,02	0,02	0,01	1	0,02	1,00	0,02	0,02	0,01	0,02	0,02	0,02	0,02	0,02	0,02	0,02	0,02	0,01	0,02	0,02	0,02
incident_type	0,01	0,01	0,00	0,01	0,00	0,01	0,01	0,02	1	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,02	0,01	0,01	0,01	0,01	0,01	0,01	0,02	0,07
incident_zip_fraud_rate	0,01	0,01	0,01	0,01	0,00	0,01	0,01	1,00	0,01	1	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,00	0,00	0,01	0,01	0,02	0,01
injury_claimed_without_medical	0,03	0,01	0,02	0,01	0,00	0,00	0,01	0,02	0,01	0,01	1	0,01	0,04	0,01	0,00	0,02	0,02	0,02	0,03	0,01	0,01	0,01	0,01	0,02	0,06

Variable	incident_severity	incident_state	incident_type	incident_zip_fraud_rate	injury_claimed_without_medical	insured_age	insured_claim_amount_history	insured_days_since_last_claim	insured_education_level	insured_hobbies	insured_occupation	insured_sex	insured_third_party_known	policy_report_available	policy_age_at_incident_days	policy_annual_premium	policy_deductible	policy_state	repairer_avg_invoice_vs_market	repairer_fraud_rate	repairer_is_flagged	total_claim_amount	vehicle_age_years	vehicle_market_value	vehicle_overvalue_ratio
policy_age_at_incident_days	0,01	0,01	0,01	0,01	0,01	0,02	0,02	0,01	0,01	0,02	0,01	0,01	0,01	0,00	1	0,02	0,02	0,02	0,03	0,03	0,03	0,01	0,03	0,01	0,01
policy_annual_premium	0,01	0,02	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,02	0,00	0,02	1	0,02	0,02	0,01	0,01	0,01	0,01	0,01	0,01	0,01
policy_deductible	0,01	0,02	0,01	0,02	0,01	0,01	0,01	0,02	0,01	0,01	0,01	0,03	0,02	0,02	0,02	0,02	1	0,02	0,01	0,02	0,01	0,01	0,01	0,02	0,02
policy_state	0,02	0,02	0,02	0,02	0,02	0,02	0,01	0,02	0,01	0,02	0,02	0,02	0,02	0,02	0,02	0,02	0,02	1	0,01	0,01	0,01	0,02	0,02	0,01	0,01
repairer_avg_invoice_vs_market	0,03	0,02	0,07	0,01	0,06	0,03	0,10	0,03	0,01	0,01	0,03	0,00	0,07	0,00	0,03	0,01	0,01	0,01	1	0,97	0,62	0,01	0,04	0,05	0,03
repairer_fraud_rate	0,02	0,02	0,29	0,01	0,06	0,03	0,10	0,02	0,01	0,01	0,02	0,01	0,07	0,01	0,03	0,01	0,02	0,01	0,97	1	0,60	0,01	0,04	0,04	0,02
repairer_is_flagged	0,02	0,02	0,05	0,01	0,04	0,02	0,07	0,03	0,01	0,02	0,02	0,01	0,04	0,00	0,03	0,01	0,01	0,01	0,62	0,60	1	0,01	0,04	0,04	0,02
total_claim_amount	0,02	0,02	0,01	0,01	0,01	0,00	0,01	0,01	0,01	0,01	0,02	0,01	0,01	0,01	0,01	0,01	0,01	0,02	0,01	0,01	0,01	1	0,00	0,01	0,35
vehicle_age_years	0,01	0,02	0,01	0,01	0,03	0,01	0,05	0,01	0,01	0,01	0,02	0,01	0,02	0,01	0,03	0,01	0,01	0,02	0,04	0,04	0,04	0,00	1	0,04	0,02
vehicle_market_value	0,01	0,01	0,01	0,01	0,01	0,03	0,04	0,02	0,01	0,02	0,02	0,01	0,02	0,01	0,01	0,01	0,02	0,01	0,05	0,04	0,04	0,01	0,04	1	0,45
vehicle_overvalue_ratio	0,01	0,02	0,01	0,01	0,01	0,01	0,02	0,02	0,01	0,02	0,02	0,01	0,02	0,01	0,01	0,01	0,02	0,01	0,03	0,02	0,02	0,35	0,02	0,45	1

Glossaire

Accuracy (taux de bien classés) : Proportion de dossiers correctement classés (fraude ou non) parmi l'ensemble de la population. Peu informatif seul en présence de classes déséquilibrées, où un modèle prédisant toujours « non-fraude » obtient mécaniquement un score élevé.

ACPR (Autorité de contrôle prudentiel et de résolution) : Superviseur français des secteurs de la banque et de l'assurance, adossé à la Banque de France. Elle publie notamment des attentes sur la gouvernance et l'explicabilité des algorithmes d'intelligence artificielle.

Agent IA : Système d'intelligence artificielle capable d'enchaîner des actions et de prendre des décisions simples pour atteindre un objectif défini, au-delà de la seule production de contenu.

AI Act (règlement (UE) 2024/1689) : Règlement européen encadrant l'intelligence artificielle selon une approche par niveaux de risque. Il classe certains usages en assurance parmi les systèmes à haut risque, soumis à des obligations de documentation, de supervision humaine et d'évaluation continue.

ALFA (Agence de lutte contre la fraude à l'assurance) : Association professionnelle française créée en 1989, chargée d'accompagner les assureurs dans la prévention et la détection des fraudes et de centraliser les informations du secteur.

Anti-sélection : Phénomène par lequel une hausse de prime éloigne les assurés les moins risqués du portefeuille, dégradant progressivement son équilibre technique.

Apprentissage supervisé : Méthode d'apprentissage où le modèle est entraîné sur des données dont la variable cible est connue (ici, le caractère frauduleux ou non de chaque sinistre).

Apprentissage non supervisé : Méthode d'apprentissage sans variable cible, visant à repérer des structures ou des anomalies dans les données à partir des seules variables explicatives.

AUC-ROC (aire sous la courbe ROC) : Indicateur synthétisant le pouvoir discriminant d'un modèle en un nombre compris entre 0,5 (aléatoire) et 1 (parfait). Elle mesure l'aptitude du score à classer les fraudes devant les non-fraudes, indépendamment de tout seuil.

Backtesting : Comparaison des performances d'un modèle entre l'échantillon d'apprentissage et l'échantillon de test, afin de détecter un éventuel surapprentissage.

Bagging (bootstrap aggregating) : Technique consistant à entraîner plusieurs modèles sur des échantillons tirés avec remise, puis à moyenner leurs prédictions pour réduire la variance.

CART (arbre de classification et de régression) : Algorithme construisant un arbre de décision en partitionnant récursivement les données selon des seuils sur les variables explicatives.

CAH (Classification Hiérarchique Ascendante) : Méthode de classification procédant par agrégations successives : partant des individus isolés, elle réunit à chaque étape les deux classes les plus proches (par exemple selon le critère de Ward), jusqu'à obtenir une classe unique. Le nombre de classes est choisi a posteriori, en coupant le dendrogramme obtenu.

Clustering (partitionnement) : Méthode non supervisée regroupant les observations en sous-ensembles homogènes (*clusters*). Les dossiers isolés ou formant de très petits groupes peuvent signaler des comportements atypiques.

Cut-off (seuil de décision) : Valeur de score au-delà de laquelle un dossier est considéré comme frauduleux. Son choix arbitre entre le taux de fraudes détectées et le volume de dossiers à investiguer.

Data profiling : Étape d'audit automatisé des données consistant à contrôler le typage, les plages de valeurs, les modalités et la complétude d'une base avant sa modélisation.

Déchéance de garantie : Sanction privant l'assuré du bénéfice de la garantie pour un sinistre donné, sans remettre en cause l'existence du contrat (à la différence de la nullité).

Elastic net : Méthode de régularisation combinant les pénalités L1 (Lasso) et L2 (Ridge) afin de bénéficier à la fois de la sélection de variables et de la stabilité des coefficients.

F1-score : Moyenne harmonique de la précision et du rappel, évaluant la qualité d'une décision à un seuil fixé. La variante F-bêta permet de pondérer davantage le rappel lorsque le coût d'une fraude non détectée est jugé supérieur à celui d'une enquête inutile.

Feedback loop (boucle de rétroaction) : Mécanisme par lequel les issues réelles des dossiers investigués viennent enrichir la base d'apprentissage, permettant le réentraînement périodique du modèle.

Forêt aléatoire (random forest) : Méthode d'ensemble agrégeant de nombreux arbres de décision décorrélés (par tirage *bootstrap* et sélection aléatoire de variables) pour obtenir un prédicteur plus stable et performant.

Franchise : Part du montant d'un sinistre restant à la charge de l'assuré, prévue au contrat.

FRIA (Fundamental Rights Impact Assessment) : Analyse d'impact sur les droits fondamentaux, imposée par l'AI Act à certains dépoyeurs de systèmes d'IA à haut risque, distincte de l'analyse d'impact relative à la protection des données.

GLM (modèle linéaire généralisé) : Famille de modèles statistiques étendant la régression linéaire, dont fait partie la régression logistique. Largement utilisée en tarification et en modélisation du risque en actuariat.

Gini (coefficient de) : Mesure du pouvoir discriminant d'un score, reliée à l'AUC par la relation $Gini = 2 \times AUC - 1$. Elle varie de 0 (discrimination nulle) à 1 (discrimination parfaite).

Gradient Boosting : Méthode d'ensemble construisant des arbres séquentiellement, chaque nouvel arbre corrigeant les erreurs résiduelles des précédents. Elle atteint généralement le meilleur pouvoir prédictif sur données tabulaires, au prix d'une interprétabilité moindre.

Graph mining (analyse de réseaux) : Modélisation du portefeuille sous forme de graphe (nœuds et arêtes) permettant de détecter des communautés anormalement denses, révélatrices de fraudes organisées.

Hyperparamètre : Paramètre de configuration d'un modèle fixé avant l'apprentissage (par exemple la profondeur d'un arbre, le nombre d'arbres ou le taux d'apprentissage), par opposition aux paramètres appris sur les données.

IA agentique : Intelligence artificielle capable d'enchaîner des actions et de prendre des décisions dans un environnement en fonction d'objectifs définis, par opposition à l'IA générative centrée sur la production de contenu.

IA générative : Intelligence artificielle produisant du contenu (texte, code, images, synthèses), typiquement au moyen de modèles de langage.

IARD (Incendie, Accidents et Risques Divers) : Ensemble des assurances de biens et de responsabilité (dont l'automobile et la multirisque habitation), par opposition aux assurances de personnes.

Impureté (indice de Gini, entropie) : Mesure de l'hétérogénéité d'un nœud d'arbre au regard de la variable cible ; l'algorithme choisit les coupures qui la font le plus décroître.

Indice de Youden : Indicateur ($J = \text{sensibilité} + \text{spécificité} - 1$) identifiant le seuil de décision qui maximise l'écart entre taux de vrais positifs et taux de faux positifs.

Information Value (IV) : Indicateur agrégeant les WOE des classes d'une variable pour quantifier son pouvoir prédictif global et hiérarchiser les variables.

Isolation Forest : Algorithme de détection d'anomalies isolant directement les observations rares et atypiques, qui nécessitent moins de coupures pour être séparées des autres.

K-Means : Algorithme de *clustering* partitionnant les données en k groupes en minimisant la variance intra-classe autour de centres de gravité.

KS (statistique de Kolmogorov-Smirnov) : Écart maximal entre les fonctions de répartition des scores des dossiers frauduleux et licites ; mesure la netteté de la séparation entre les deux populations.

LCB-FT (lutte contre le blanchiment de capitaux et le financement du terrorisme) : Dispositif réglementaire et opérationnel imposé aux acteurs financiers et assurantiels pour prévenir, détecter et signaler ces infractions.

Lift (@10 %) : Rapport entre le taux de fraude observé dans les 10 % de dossiers les mieux notés et le taux de fraude global. Un *lift* de 5 signifie que ce décile concentre cinq fois plus de fraudes qu'une sélection aléatoire.

LLM (modèle de langage) : Modèle d'intelligence artificielle entraîné à produire et comprendre du texte en langage naturel.

Log-loss : Indicateur mesurant la qualité de la calibration des probabilités prédites ; une valeur faible traduit des probabilités bien calibrées.

Matrice de confusion : Tableau croisant les prédictions du modèle et les statuts réels selon quatre cas : vrais positifs (TP), vrais négatifs (TN), faux positifs (FP) et faux négatifs (FN).

Méthode de Louvain : Algorithme de détection de communautés dans un graphe, cherchant à maximiser la modularité (densité des liens internes rapportée aux liens externes).

Multi-colinéarité : Situation où plusieurs variables explicatives sont fortement corrélées, rendant l'estimation des coefficients instable et peu interprétable.

NLP (traitement automatique du langage) : Ensemble de techniques permettant d'analyser des données textuelles non structurées (descriptions de sinistres, comptes rendus d'expertise) pour y détecter des incohérences ou des schémas récurrents.

Nullité du contrat : Sanction rétroactive rendant le contrat réputé n'avoir jamais existé, applicable notamment en cas de fausse déclaration intentionnelle à la souscription (article L.113-8 du Code des assurances).

Odds-ratio : Exponentielle d'un coefficient de régression logistique, indiquant le facteur par lequel la cote de fraude est multipliée quand la variable augmente d'une unité. Supérieur à 1 : variable aggravante ; inférieur à 1 : variable atténuante.

Out-of-bag (erreur) : Estimation de l'erreur de généralisation d'une forêt aléatoire obtenue en prédisant chaque observation à l'aide des seuls arbres ne l'ayant pas vue lors de l'entraînement.

Out-of-bag (échantillon) : Fraction des observations (environ 37 %) absente d'un tirage *bootstrap* donné, utilisable pour l'évaluation interne du modèle.

PDO (Points to Double the Odds) : Nombre de points d'un *scoring* correspondant à un doublement de la cote de fraude ; paramètre de calage de la grille de points.

Précision : Parmi les dossiers signalés comme frauduleux, proportion de ceux qui le sont réellement ($VP / (VP + FP)$).

Prime pure : Espérance du coût des sinistres pour un contrat, modélisée comme le produit de la fréquence moyenne des sinistres et de leur coût moyen.

Principe indemnitaire (règle de non-enrichissement) : Principe selon lequel l'indemnité d'assurance ne peut excéder le montant du préjudice réel : l'assurance répare un dommage sans procurer de profit à l'assuré (article L.121-1 du Code des assurances).

Prompt : Ensemble des instructions, du contexte et des données fournis à un modèle d'IA pour guider son comportement et orienter la nature de ses réponses. Il constitue le point d'entrée de l'interaction avec l'agent.

PR-AUC (aire sous la courbe précision-rappel) : Indicateur de performance particulièrement adapté aux classes déséquilibrées, car centré sur la classe d'intérêt (la fraude) et non flatté par l'abondance des vrais négatifs. Sa référence n'est pas 0,5 mais la prévalence de la fraude.

PSI (Population Stability Index) : Indicateur mesurant la dérive de la distribution des scores entre une population de référence et une population récente. En deçà de 0,1 la population est stable ; au-delà de 0,25 une dérive importante justifie un réentraînement.

Rappel (sensibilité) : Parmi les dossiers réellement frauduleux, proportion de ceux détectés par le modèle ($VP / (VP + FN)$).

Rapport de corrélation (η^2) : Mesure d'association entre une variable quantitative et une variable qualitative, correspondant à la part de variance de la première expliquée par les modalités de la seconde. Compris entre 0 et 1.

Ratio S/P (Sinistres sur Primes) : Rapport entre la charge des sinistres et le montant des primes encaissées, indicateur clé de l'équilibre technique d'un portefeuille.

Red flag (signal d'alerte) : Indice issu de l'expérience métier laissant présumer une fraude (délai anormalement court entre souscription et sinistre, déclaration tardive, antécédents répétés, etc.).

Régression logistique : Modèle linéaire généralisé estimant la probabilité d'un événement binaire (ici la fraude) via la fonction logit. Référence historique de la modélisation du risque, appréciée pour son interprétabilité directe.

Régularisation (L1 / Lasso, L2 / Ridge) : Ajout d'une pénalité sur la taille des coefficients d'un modèle afin de stabiliser l'estimation et de limiter le surapprentissage. La pénalité L1 peut annuler des coefficients (sélection de variables), la L2 les rétrécit sans les annuler.

RGPD (Règlement général sur la protection des données) : Cadre européen encadrant le traitement des données personnelles. Son article 22 restreint les décisions produisant des effets significatifs fondées exclusivement sur un traitement automatisé.

Shrinkage (taux d'apprentissage) : Coefficient pondérant la contribution de chaque arbre dans le gradient *boosting*. Une valeur faible ralentit l'apprentissage mais améliore la généralisation.

Similarité cosinus : Mesure de proximité entre deux dossiers dans l'espace des variables, utilisée en analyse de réseaux pour tracer une arête lorsque deux sinistres se ressemblent anormalement.

SIV (Système d'immatriculation des véhicules) : Dispositif français d'immatriculation mis en place en 2009, dont le détournement par des réseaux organisés a facilité des fraudes automobiles de grande ampleur.

Spécificité : Parmi les dossiers réellement licites, proportion de ceux correctement classés comme non frauduleux ($VN / (VN + FP)$).

Stratification : Technique de partitionnement préservant la proportion de la variable cible (ici 11,5 % de fraudes) dans les jeux d'apprentissage et de test.

Surapprentissage (overfitting) : Situation où un modèle s'ajuste trop finement aux particularités des données d'entraînement, au détriment de sa capacité à généraliser à de nouveaux dossiers.

Télématique : Données issues de capteurs embarqués ou d'applications mobiles reconstituant le comportement de conduite, mobilisables pour vérifier la cohérence d'un sinistre déclaré.

Tracfin : Cellule française de renseignement financier recueillant et analysant les déclarations de soupçon des professionnels assujettis (dont les assureurs) en matière de blanchiment et de financement du terrorisme.

Valeurs de Shapley : Méthode d'explicabilité mesurant la contribution marginale moyenne de chaque variable à une prédiction, en moyennant sur toutes les combinaisons possibles de variables.

Validation croisée (k plis) : Technique d'évaluation divisant les données en k sous-ensembles ; le modèle est entraîné k fois, chaque pli servant tour à tour de jeu de validation, ce qui fournit une estimation robuste de la performance.

V de Cramér : Mesure d'association entre deux variables qualitatives, dérivée de la statistique du khi-deux et comprise entre 0 (indépendance) et 1 (association parfaite). Sa normalisation la rend comparable entre tableaux de dimensions différentes.

WOE (Weight of Evidence) : Poids de la preuve attribué à chaque classe d'une variable, mesurant son pouvoir discriminant en comparant la répartition des dossiers licites et frauduleux. Base de la construction d'un *scoring* à points.

XGBoost / LightGBM / CatBoost : Bibliothèques *open source* d'implémentation du gradient *boosting*, réputées rapides et performantes, principalement utilisées en Python.

Bibliographie

- [1] FRANCE ASSUREURS. *Présentation - Conférence de presse 2026*. (Mars 2026). Consulté sur https://www.franceassureurs.fr/wp-content/uploads/20260325_presentation-conference-de-presse-2.pdf, en mars 2026.
- [2] FRANCE ASSUREURS. *Données clés 2024*. (2024). Consulté sur <https://www.franceassureurs.fr/wp-content/uploads/donnees-cles-2024.pdf>, en mars 2026.
- [3] INSURANCE EUROPE. *The impact of insurance fraud*. Consulté sur <https://www.insuranceeurope.eu/mediaitem/0bf0af82-e7ef-4439-a763-d7862859d421/The+impact+of+insurance+fraud.pdf>, en mars 2026.
- [4] ALFA (Agence de Lutte contre la Fraude à l'Assurance). *Site institutionnel de l'ALFA* (missions, chiffres de la fraude, publications). Consulté sur <https://www.alfa.asso.fr/>, en janvier 2026.
- [5] ALFA (Agence de Lutte contre la Fraude à l'Assurance). *ALFA News n° 48*. (Septembre 2024). Consulté sur <https://www.alfa.asso.fr/alfa-news-48-septembre-2024/>, en janvier 2026.
- [6] ALFA (Agence de Lutte contre la Fraude à l'Assurance). *ALFA News n° 39*. (Juin 2023). Consulté sur <https://www.alfa.asso.fr/alfa-news-39-juin-2023-2/>, en janvier 2026.
- [7] L'ARGUS DE L'ASSURANCE. *Fraude à l'assurance : une facture de 2,5 Md€ en dommages*. Consulté sur <https://www.argusdelassurance.com/institutions/fraude-a-l-assurance-une-facture-de-2-5-md-en-dommages-en-2014-alfa.96060>, en février 2026.
- [8] L'ARGUS DE L'ASSURANCE. *Fraude à l'assurance : un coût de 50 € pour les assurés*. Consulté sur <https://www.argusdelassurance.com/acteurs/fraude-a-l-assurance-un-cout-de-50-pour-les-assures.60931>, en février 2026.
- [9] L'ARGUS DE L'ASSURANCE. *Près d'un milliard d'euros de fraudes à l'assurance détecté en 2025*. Consulté sur <https://www.argusdelassurance.com/assurance-de-personnes/des-filieres-de-larnaue-utilisent-lintelligence-artificielle-pres-dun-milliard-deuros-de-fraudes-a-l-assurance-detecte-en-2025.VRVQHSZDANZGGZL5GXH7FHW3JU4.html>, en février 2026.
- [10] SERVICE-PUBLIC.FR. *Assurance auto : comment se déroule l'expertise ?*. Consulté sur <https://www.service-public.gouv.fr/particuliers/vosdroits/F31268>, en février 2026.
- [11] ITESOFT. *Fraude à l'assurance : les chiffres clés (ALFA)*. Consulté sur <https://www.itesoft.com/fr/blog/fraude-assurance-chiffres-cles-alfa/>, en février 2026.
- [12] ACPR (Autorité de Contrôle Prudentiel et de Résolution). *Gouvernance des algorithmes d'intelligence artificielle dans le secteur financier*. (Juin 2020). Consulté sur https://acpr.banque-france.fr/system/files/2025-02/20200612_gouvernance_evaluation_ia.pdf, en février 2026.
- [13] UNION EUROPÉENNE. *Règlement général sur la protection des données (RGPD), article 22 - Décision individuelle automatisée*. Consulté sur <https://gdpr-text.com/fr/read/article-22/>, en mars 2026.
- [14] UNION EUROPÉENNE. *Règlement (UE) 2024/1689 établissant des règles harmonisées concernant l'intelligence artificielle (AI Act)*. Journal officiel de l'Union européenne, 2024.
- [15] COMMISSION EUROPÉENNE. *L'Omnibus de l'IA entre en vigueur*. (27 juillet 2026). Consulté sur <https://digital-strategy.ec.europa.eu/fr/news/ai-omnibus-enters-force>, en septembre 2026.
- [16] CODE DES ASSURANCES. *Articles L.121-1, L.113-2, L.113-8 et L.113-9*. Legifrance.
- [17] CODE PÉNAL. *Article 313-1 - Escroquerie*. Legifrance.

- [18] COUR DES COMPTES. *La fraude aux cartes grises*. Consulté sur <https://www.ccomptes.fr/fr/publications/la-fraude-aux-cartes-grises>, en février 2026.
- [19] ASSEMBLÉE NATIONALE. *Question écrite n° 4793 - Fraude au système d'immatriculation des véhicules*. Consulté sur <https://questions.assemblee-nationale.fr/q17/17-4793QE.htm>, en février 2026.
- [20] SÉNAT. *Question écrite n° 02893 - Fraude au système d'immatriculation des véhicules*. (2025). Consulté sur <https://www.senat.fr/questions/base/2025/qSEQ250102893.html>, en février 2026.
- [21] BARHOUMI K. (2020). *Modélisation de la fraude en assurance IARD : Application à l'assurance automobile*. Mémoire d'actuariat (Covéa), Institut des actuaires. Consulté sur <https://www.institutdesactuaires.com/se-documenter/memoires/memoires-d-actuariat-4651?id=ba1d51c7d5fe5cef084e612d41bee48f>, en janvier 2026.
- [22] DECOURTIEUX C. (2016). *Modélisation de la fraude sur les contrats Auto du particulier par apprentissage statistique*. Mémoire d'actuariat (Aviva Assurances), Institut des actuaires. Consulté sur <https://www.institutdesactuaires.com/se-documenter/memoires/memoires-d-actuariat-4651?id=9c62b7c3284b2d09e421614b578c9e4a>, en janvier 2026.
- [23] AHLUWALIA SAKSHAM. *Car Insurance Fraud Detection Dataset*. Kaggle. Consulté sur <https://www.kaggle.com/datasets/ahluwaliasaksham/car-insurance-fraud-detection-dataset>, en janvier 2026.
- [24] ANTHROPIC. *Claude - Assistant conversationnel d'intelligence artificielle*. Consulté sur <https://www.anthropic.com>, en février 2026.
- [25] BREIMAN LEO. « Random Forests ». *Machine Learning*, volume 45, n° 1, 2001, p. 5-32.
- [26] FRIEDMAN JEROME H. « Greedy Function Approximation : A Gradient Boosting Machine ». *Annals of Statistics*, volume 29, n° 5, 2001, p. 1189-1232.
- [27] CHEN TIANQI, GUESTRIN CARLOS. « XGBoost : A Scalable Tree Boosting System ». *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, p. 785-794.
- [28] LIU FEI TONY, TING KAI MING, ZHOU ZHI-HUA. « Isolation Forest ». *Proceedings of the 8th IEEE International Conference on Data Mining*, 2008, p. 413-422.
- [29] LUNDBERG SCOTT M., LEE SU-IN. « A Unified Approach to Interpreting Model Predictions ». *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.
- [30] BLONDEL VINCENT D., GUILLAUME JEAN-LOUP, LAMBIOTTE RENAUD, LEFEBVRE ETIENNE. « Fast unfolding of communities in large networks ». *Journal of Statistical Mechanics : Theory and Experiment*, 2008.