

Mémoire présenté le :

**pour l'obtention du Diplôme Universitaire d'actuariat de l'ISFA
et l'admission à l'Institut des Actuaire**

Par : Eliot NEHME

Titre : Détection de fraude en assurance non-vie grâce à l'intelligence artificielle

Confidentialité : ☐ NON ☒ (Durée : ☐ 1 an ☒ 2 ans)

Les signataires s'engagent à respecter la confidentialité indiquée ci-dessus

*Membres présents du jury de Signature
l'Institut des Actuaire*

Entreprise :

Nom :

Signature :

*Directeur de mémoire en entre-
prise :*

Nom :

Signature :

*Membres présents du jury de
l'ISFA*

Invité :

Nom :

Signature :

***Autorisation de publication et
de mise en ligne sur un site de
diffusion de documents actua-
riels (après expiration de l'éventuel
délai de confidentialité)***

Signature du responsable entreprise

Signature du candidat

Table des matières

Résumé	iv
Abstract	v
Remerciements	vi
Synthèse	vii
Synthesis	viii
Introduction	1
1 Introduction	2
1.1 Définition de la fraude à l'assurance	3
1.2 Les stades d'occurrence de la fraude dans le cycle assurantiel en assurance non-vie	4
1.2.1 La fraude à la souscription	5
1.2.2 La fraude à la déclaration de sinistre	5
1.2.3 La fraude liée aux Conditions Générales	7
1.3 Cadre réglementaire des sanctions en cas de fraude avérée	9
1.3.1 Souscription	9
1.3.2 Sinistre	9
1.3.3 Preuve de la fraude et sanctions pénales	10
1.4 Enjeux économiques et actuariels de la fraude	11
1.4.1 L'ampleur du marché de la fraude	11
1.4.2 Impact de la fraude sur la tarification	13
2 La détection de la fraude en assurance : de l'approche manuelle à l'automatisation par l'IA	17
2.1 L'approche traditionnelle : une détection manuelle et ciblée	18
2.1.1 Le rôle des équipes dédiées	18
2.1.2 Une détection fondée sur l'expertise humaine	18
2.1.3 Les limites de cette approche	19
2.2 L'apport de l'intelligence artificielle : de nouvelles solutions de détection	20
2.2.1 Le contexte d'émergence	20

2.2.2	Les nouvelles approches	20
2.2.3	Les bénéfices attendus	21
2.2.4	Les points de vigilance à l'utilisation de l'intelligence artificielle	21
2.3	Comparaison du processus manuel et du processus automatisé	22
2.3.1	Les critères de comparaison	22
2.3.2	Mise en regard des deux processus	23
2.3.3	Vers un modèle hybride	24
3	Cadre théorique : les algorithmes de détection de fraude utilisés en assurance non-vie	25
3.1	La régression logistique (modèle de référence)	27
3.2	La forêt aléatoire	28
3.3	Le gradient boosting	30
3.4	Les modèles de scoring à points	31
3.5	Apprentissage non supervisé : détection d'anomalies et comportements atypiques	32
3.5.1	Les algorithmes d'isolation (exemple : Isolation Forest)	32
3.5.2	Le partitionnement de données (Clustering)	33
3.6	Analyse de réseaux (Graph Mining) pour la détection de la fraude organisée	34
3.6.1	Modélisation mathématique du réseau de fraude	34
3.6.2	Détection de communautés et de clusters suspects	35
3.6.3	Application opérationnelle	35
3.7	Critères de qualité des modèles mis en place	36
4	Mise en place d'un processus de détection de fraude automobile automatisé à l'aide d'un Agent IA	40
4.1	Gouvernance autour de la mise en place de l'Agent IA	41
4.2	Présentation de la base de données	43
4.2.1	Base de données source	43
4.2.2	Enrichissement de la base de données	45
4.3	Descriptif macro de la création du processus de détection de fraude et de sa déclinaison opérationnelle	49
4.3.1	Le prompt : la décomposition du besoin en étapes	50
4.3.2	Présentation macro des différentes étapes	51
4.4	Résultats fournis par l'Agent IA pour la construction du modèle de scoring de fraude — Étapes 1 à 3	54
4.4.1	Étape 1 : Ingestion de la base de données	54
4.4.2	Étape 2 : Audit et contrôles de cohérence	56
4.4.3	Étape 3 : Analyse statistique des données	59
5	Création du modèle de détection de fraude (Étapes 4 et 5)	74
5.1	Scoring en points	76
5.1.1	Résultats du modèle	77
5.1.2	Qualité du modèle obtenu	81
5.1.3	Limites et précautions d'interprétation	85
5.2	Modèle arbre de décision	86

5.2.1	Résultats du modèle	87
5.2.2	Qualité du modèle obtenu	91
5.2.3	Limites et précautions d'interprétation	94
5.3	Machine learning Gradient Boosting	95
5.3.1	Résultats du modèle	95
5.3.2	Qualité du modèle obtenu	99
5.3.3	Limites et précautions d'interprétation	103
5.4	Comparaison des modèles	104
6	Outil mis à disposition du service de détection des fraudes	107
6.1	Utilisation pratique de l'outil	108
6.2	Un outil permettant l'enrichissement du modèle en continu	112
6.3	Un outil de pilotage : le rapport annuel de détection de fraude	114
6.4	Un outil dynamique	116
	Annexes	118
	Bibliographie	119

Résumé

La fraude en assurance non-vie représente un enjeu financier majeur, estimé à environ 2,5 milliards d'euros par an en France, dont une large part échappe encore aux dispositifs de détection traditionnels. Fondés sur l'expertise humaine, ces dispositifs ne contrôlent qu'une fraction des dossiers et peinent à traiter la fraude de masse de faible montant, dont le coût de vérification manuelle excède souvent le gain espéré.

Ce mémoire propose de concevoir et déployer, à l'aide d'un agent d'intelligence artificielle, un processus de détection automatisé de la fraude automobile, de l'ingestion des données jusqu'au pilotage du dispositif. À partir d'une base de sinistres enrichie de variables reproduisant l'information disponible chez un assureur, trois modèles sont construits et comparés selon un arbitrage entre interprétabilité et pouvoir prédictif : un scoring en points, un arbre de décision et un modèle de Gradient Boosting. Ce dernier obtient les meilleures performances (AUC de 0,942, lift de $\times 6,66$ au premier décile) tout en concentrant efficacement les fraudes dans un volume restreint de dossiers à investiguer.

L'outil se décline en deux modules destinés à deux équipes distinctes : la construction du modèle par les actuaires, et son exploitation opérationnelle par les gestionnaires, complétée d'une boucle d'enrichissement continu et d'un rapport de pilotage mesurant le retour sur investissement. L'ensemble s'inscrit dans un cadre de gouvernance conforme au RGPD et à l'AI Act, préservant une supervision humaine à chaque étape.

Les schémas et illustrations de ce mémoire ont été réalisés avec l'aide d'outils d'intelligence artificielle générative. De même, une partie des données d'enrichissement de la base a été simulée à l'aide de tels outils, comme précisé en section 4.2.2.

Abstract

Fraud in non-life insurance is a major financial concern, estimated at around 2.5 billion of euros per year in France, a large share of which still evades traditional detection systems. Relying on human expertise, these systems examine only a fraction of claims and struggle to address low-value mass fraud, where the cost of manual verification often exceeds the expected gain.

This dissertation sets out to design and deploy, using an artificial-intelligence agent, an automated motor-insurance fraud detection process spanning data ingestion through to steering the system. Starting from a claims database enriched with variables reproducing the information available to an insurer, three models are built and compared along an interpretability-versus-predictive-power trade-off : a points-based scorecard, a decision tree and a Gradient Boosting model. The latter achieves the best performance (AUC of 0.942, top-decile lift of $\times 6.66$) while effectively concentrating fraud within a limited volume of claims to investigate.

The tool is organised into two modules aimed at two distinct teams : model construction by actuaries, and operational use by claims handlers, complemented by a continuous-enrichment feedback loop and a monitoring report measuring the return on investment. The whole framework complies with the GDPR and the AI Act, preserving human oversight at every stage.

Keywords : insurance fraud, non-life insurance, automated detection, artificial intelligence, machine learning, scoring, Gradient Boosting, actuarial science.

Remerciements

Je tiens à remercier toute l'équipe Actuariat d'Accenture qui m'a permis de réaliser ce mémoire, et plus particulièrement ma tutrice Rachel Atia pour son implication ainsi que sa capacité à enseigner, qui ont été essentielles tout au long de ce projet.

Synthèse

Reposant sur le principe de mutualisation des risques, l'assurance suppose un climat de confiance entre assureur et assuré que la fraude vient détourner. En assurance non-vie, ce phénomène représente une charge estimée à environ 2,5 milliards d'euros par an en France, dont une partie importante demeure non détectée. La lutte traditionnelle, fondée sur le jugement des gestionnaires et des cellules spécialisées, se heurte à une couverture partielle des dossiers, à une forte dépendance à l'expertise individuelle et à un coût de contrôle rendant non rentable l'investigation de la fraude de faible montant.

Face à ce constat, ce mémoire conçoit un processus de détection automatisé de la fraude automobile s'appuyant sur un agent d'intelligence artificielle. La démarche est volontairement circonscrite à la fraude circonstancielle, décelable à partir de données structurées (caractéristiques du sinistre, antécédents, cohérence déclarative), et s'appuie sur une base publique de 30 000 sinistres enrichie de variables reproduisant l'information réellement disponible chez un assureur.

Trois modèles sont construits et comparés selon un arbitrage entre interprétabilité et performance : un scoring en points, transparent et proche des pratiques actuarielles ; un arbre de décision, capable de capter interactions et effets de seuil ; et un modèle de Gradient Boosting, qui obtient les meilleures performances discriminantes (AUC de 0,942, lift de $\times 6,66$ au premier décile). L'évaluation mobilise une batterie d'indicateurs adaptés au fort déséquilibre des classes (Gini, KS, précision, rappel, PR-AUC, PSI), le choix du seuil de décision relevant d'un arbitrage économique entre coût des faux positifs et coût des fraudes non détectées.

L'outil se structure en deux modules indépendants correspondant à deux profils d'utilisateurs : un premier module de construction et de calibration du modèle, destiné aux actuaires ; un second module opérationnel d'aide à la décision, destiné aux gestionnaires, qui attribue à chaque sinistre une probabilité de fraude et l'oriente vers une zone de risque. Ce dispositif est complété par une boucle d'enrichissement continu, alimentée par les issues réelles des dossiers investigués, et par un rapport de pilotage mesurant la fraude évitée, l'impact sur le ratio Sinistres/Primes et le retour sur investissement.

L'ensemble s'inscrit dans un cadre de gouvernance conforme au RGPD et à l'AI Act, garantissant explicabilité, traçabilité et maintien d'une supervision humaine : l'agent hiérarchise les dossiers sans se substituer à la décision de l'enquêteur. Le mémoire se conclut sur les limites du dispositif et ses perspectives d'extension : couplage à la base portefeuille, intégration de données externes, mutualisation inter-assureurs et approche multi-produits.

Synthesis

Built on the principle of risk pooling, insurance presupposes a relationship of trust between insurer and policyholder that fraud diverts to illegitimate ends. In non-life insurance, this phenomenon represents an estimated burden of around 2.5 billion of euros per year in France, a significant part of which remains undetected. Traditional efforts, based on the judgement of claims handlers and specialised units, face partial coverage of claims, heavy reliance on individual expertise, and a control cost that makes investigating low-value fraud economically unviable.

In response, this dissertation designs an automated motor-insurance fraud detection process based on an artificial-intelligence agent. The approach is deliberately confined to circumstantial fraud, detectable from structured data (claim characteristics, past history, declarative consistency), and draws on a public database of 30 000 claims enriched with variables reproducing the information actually available to an insurer.

Three models are built and compared along an interpretability-versus-performance trade-off : a points-based scorecard, transparent and close to actuarial practice ; a decision tree, able to capture interactions and threshold effects ; and a Gradient Boosting model, which achieves the best discriminating performance (AUC of 0.942, top-decile lift of $\times 6.66$). Evaluation relies on a set of indicators suited to strong class imbalance (Gini, KS, precision, recall, PR-AUC, PSI), the choice of decision threshold being an economic trade-off between the cost of false positives and that of undetected fraud.

The tool is organised into two independent modules matching two user profiles : a first module for model construction and calibration, intended for actuaries ; and a second, operational decision-support module for claims handlers, which assigns each claim a fraud probability and routes it to a risk zone. This is complemented by a continuous-enrichment feedback loop, fed by the actual outcomes of investigated claims, and by a monitoring report measuring avoided fraud, the impact on the loss ratio and the return on investment.

The entire framework complies with the GDPR and the AI Act, ensuring explainability, traceability and the preservation of human oversight : the agent prioritises claims without replacing the investigator's decision. The dissertation concludes on the system's limitations and its avenues for extension : coupling with the policy database, integration of external data, cross-insurer data pooling and a multi-product approach.

Introduction

Ce mémoire est vraiment trop bien

Chapitre 1

Introduction

1.1 Définition de la fraude à l'assurance

Le secteur de l'assurance repose sur un principe fondamental : la mutualisation des risques. En échange du paiement d'une prime, l'assuré bénéficie d'une protection financière en cas de réalisation d'un sinistre prévu au contrat. Ce mécanisme de solidarité économique suppose toutefois un climat de confiance entre l'assureur et l'assuré. Lorsque cette confiance est détournée à des fins illégitimes, on parle alors de fraude en assurance.

La fraude en assurance peut être définie comme **tout acte intentionnel visant à tromper un assureur dans le but d'obtenir un avantage indu, qu'il s'agisse d'une indemnisation injustifiée, majorée ou de la souscription d'un contrat dans des conditions mensongères.**

Elle se distingue de l'erreur ou de l'omission involontaire de par son caractère délibéré et frauduleux.

Cette pratique constitue un enjeu majeur pour les compagnies d'assurance, car elle entraîne des pertes financières importantes, impacte l'équilibre technique des portefeuilles et, indirectement, pèse sur l'ensemble des assurés au travers de l'augmentation des primes afin de compenser ces pertes.

L'objectif de la fraude en assurance est principalement financier : il s'agit d'obtenir un enrichissement personnel ou collectif illégitime. Toutefois, au-delà de la recherche d'un gain immédiat, certaines fraudes répondent à des logiques plus complexes, telles que le blanchiment de capitaux, le financement d'activités criminelles ou la structuration d'organisations délictueuses. Ainsi, la fraude peut prendre des formes variées, allant de la simple exagération d'un dommage à la mise en place de réseaux organisés exploitant systématiquement les failles du système assurantiel.

Il convient, à cet égard, de distinguer deux grandes catégories de fraude, la fraude opportuniste et la fraude organisée :

- **La fraude opportuniste** correspond à un comportement isolé, souvent ponctuel, commis par un assuré qui profite d'une situation donnée (par exemple, majorer le montant d'un sinistre ou déclarer un dommage antérieur comme récent). Elle s'inscrit généralement dans une logique individuelle et circonstancielle.
- À l'inverse, **la fraude organisée** repose sur une démarche structurée et planifiée, impliquant parfois plusieurs acteurs (intermédiaires, professionnels de santé, réparateurs, réseaux criminels). Elle est caractérisée par sa répétition, sa préméditation et son ampleur financière plus importante.

Cette distinction est essentielle, car elle implique des modes de détection, de prévention et de répression différents. Là où la fraude opportuniste peut être combattue par des contrôles renforcés et une sensibilisation accrue, la fraude organisée nécessite des dispositifs d'investigation spécialisés, des outils d'analyse de données avancés et une coopération étroite entre assureurs, autorités judiciaires et organismes de régulation.

À noter que la fraude est contraire à un principe important en assurance : **le principe indemnitaire et la règle de non-enrichissement en assurance non-vie.**

Ce principe est expressément consacré par l'article L.121-1 du Code des assurances, selon lequel :

« L'assurance relative aux biens est un contrat d'indemnité ; l'indemnité due par l'assureur à l'assuré ne peut dépasser le montant de la valeur de la chose assurée au moment du sinistre. »

Ce texte pose clairement la règle de non-enrichissement : l'assurance a pour finalité exclusive la réparation du préjudice subi, et non l'octroi d'un profit à l'assuré. L'indemnité ne peut excéder ni le montant du dommage, ni la somme assurée prévue au contrat.

Ainsi, l'indemnisation vise à replacer l'assuré dans la situation patrimoniale qui aurait été la sienne en l'absence de sinistre (principe de réparation intégrale, sans perte ni profit).

Le principe de non-enrichissement joue également un rôle central dans la lutte contre la fraude en assurance non-vie. En effet, toute déclaration intentionnellement inexacte ayant pour effet d'obtenir une indemnité supérieure au préjudice réel constitue une atteinte directe à ce principe.

Plusieurs dispositions viennent renforcer cette protection :

- **Article L.113-2** : obligation pour l'assuré de répondre exactement aux questions posées lors de la souscription et de déclarer sincèrement le sinistre ;
- **Article L.113-8** : nullité du contrat en cas de réticence ou fausse déclaration intentionnelle ;
- **Article L.113-9** : réduction proportionnelle de l'indemnité en cas de déclaration inexacte non intentionnelle.

Dans le cadre de la fraude opportuniste (exagération du montant des dommages, ajout d'objets inexistants, fausse date du sinistre), la violation du principe indemnitaire se traduit par une tentative d'enrichissement indu.

Dans le cas de la fraude organisée (réseaux de sinistres fictifs, collusion avec des réparateurs ou professionnels de santé, sinistres provoqués), la remise en cause est plus systémique : l'objectif n'est plus seulement d'obtenir une indemnité excessive, mais de détourner de manière structurée le mécanisme même de mutualisation.

1.2 Les stades d'occurrence de la fraude dans le cycle assurantiel en assurance non-vie

En assurance non-vie, la fraude peut intervenir à plusieurs étapes de la relation contractuelle. Deux moments apparaissent particulièrement sensibles :

1. La fraude à la souscription du contrat ;

2. La fraude à la déclaration du sinistre.

Ces deux temporalités répondent à des logiques différentes mais poursuivent un objectif commun : obtenir un avantage économique indu en détournant le mécanisme indemnitaire.

1.2.1 La fraude à la souscription

La fraude à la souscription a lieu lors de la conclusion du contrat, avant tout sinistre. Elle consiste à fournir intentionnellement des informations inexactes ou incomplètes afin d'obtenir des conditions tarifaires plus favorables ou de rendre assurable un risque qui ne le serait pas.

Elle constitue une violation directe de l'obligation de déclaration exacte du risque prévue par l'article L.113-2 du Code des assurances.

L'objectif est ici principalement tarifaire : réduire le montant de la prime ou contourner un refus d'assurance.

La fraude à la souscription peut ainsi priver totalement l'assuré de garantie au moment du sinistre.

	Assurance automobile	Assurance habitation
Fraude à la souscription	— Fausse déclaration du conducteur principal : un parent déclare être le conducteur principal alors que le véhicule est utilisé principalement par un jeune conducteur afin d'éviter une surprime. — Fausse adresse de garage : déclaration d'un stationnement en zone rurale alors que le véhicule est stationné en zone urbaine à forte sinistralité. — Dissimulation d'un usage professionnel : déclarer un usage « privé » alors que le véhicule est utilisé pour des livraisons ou VTC. — Fraude documentaire : faux papiers d'identité.	— Sous-évaluation du capital mobilier pour réduire la prime. — Omission de circonstances aggravantes : logement inoccupé plusieurs mois par an, absence de système de sécurité, activité professionnelle à domicile. — Fausse déclaration de la qualité d'occupant (se déclarer propriétaire occupant plutôt que bailleur).

TABLE 1.1 – Exemples de fraude à la souscription en assurance non-vie

1.2.2 La fraude à la déclaration de sinistre

La fraude la plus courante en assurance non-vie se produit lors de la déclaration d'un sinistre. Cela peut inclure la surestimation des dommages, la déclaration de sinistres fictifs, la falsification de preuves

(comme des photos ou des rapports de police). Ces fraudes visent à obtenir des indemnités plus élevées que celles auxquelles l'assuré aurait pu prétendre, ou bien d'engendrer une indemnité qui n'aurait tout simplement pas dû exister.

À noter que la falsification de documents est de plus en plus accessible et difficile à détecter à l'œil nu suite à l'essor de la *generative IA*.

	Assurance automobile	Assurance habitation
Fraude à la déclaration d'un sinistre	— Exagération des dommages : ajout de dégâts antérieurs sur le constat amiable. — Fausse date de sinistre : déclarer un accident survenu avant la souscription comme postérieur à celle-ci. — Sinistre fictif : déclaration d'un vol de véhicule inexistant ou maquillage d'un incendie volontaire. — Accident provoqué intentionnellement (fraude organisée dans certains cas). — Constats de complaisance entre complices pour imputer la responsabilité à un tiers assuré. — Fraude documentaire : faux devis, fausses factures de réparation, gonflement des temps de main-d'œuvre, faux certificats de cession ou documents d'identité, manipulation de photos (dommages antérieurs).	— Ajout d'objets inexistants lors d'un vol déclaré. — Surestimation de la valeur des biens (factures falsifiées ou modifiées). — Déclaration d'un dégât des eaux ancien comme récent pour le rendre indemnisable. — Incendie volontaire destiné à obtenir une indemnité. — Fraude documentaire : fausses factures d'ameublement après vol, devis travaux surévalués après dégât des eaux, falsification de preuves d'effraction, antidatation de justificatifs.

TABLE 1.2 – Exemples de fraude à la déclaration d'un sinistre en assurance non-vie

En assurance non-vie, la fraude peut ainsi être appréhendée selon différents stades d'occurrence dans le cycle assurantiel. Elle peut naître lors de la souscription du contrat, se révéler au moment de la déclaration du sinistre, mais également prendre la forme d'un détournement des stipulations contractuelles, notamment des conditions générales, afin d'obtenir une prise en charge induue.

1.2.3 La fraude liée aux Conditions Générales

La fraude liée aux conditions générales ne constitue pas, à strictement parler, un moment autonome de la fraude. Elle renvoie plutôt à une logique contractuelle particulière, consistant à manipuler les circonstances du sinistre ou l'interprétation du contrat afin de faire entrer le dommage dans le champ de la garantie. Si cette fraude peut trouver son origine dès la souscription, elle se manifeste le plus souvent lors de la déclaration ou de l'instruction du sinistre.

La fraude aux Conditions Générales en assurance non-vie renvoie à la recherche volontaire d'une indemnisation en contradiction avec les clauses contractuelles (définitions, exclusions, franchises, plafonds, obligations de prévention), sans nécessairement qu'il y ait eu fraude à la souscription.

Elle se matérialise par une manipulation des circonstances du sinistre afin de le faire entrer dans le périmètre de garantie : déclaration d'un vol simple en vol avec effraction, transformation d'un défaut d'entretien en événement accidentel, antériorité dissimulée d'un dommage, ou requalification d'un usage non couvert.

Par exemple, en assurance automobile, dans le cadre d'un sinistre survenu lors d'un usage professionnel alors que le véhicule est déclaré en usage privé, la modification du contexte pour entrer dans le champ contractuel est qualifiée de fraude.

	Assurance automobile	Assurance habitation
Fraude liée aux conditions générales	— Requalification d'un usage exclu : déclarer un sinistre survenu dans un cadre privé alors que le véhicule était utilisé à titre professionnel, afin de bénéficier de la garantie. — Déclaration inexacte des circonstances du vol : affirmer que les clés n'étaient pas laissées dans le véhicule ou à proximité, afin d'éviter l'application d'une exclusion. — Manipulation des circonstances du sinistre : faire passer une panne mécanique ou un défaut d'entretien pour un dommage accidentel couvert par le contrat. — Fausse qualité du conducteur au moment du sinistre : déclarer que le véhicule était conduit par un conducteur autorisé alors qu'il était utilisé par une personne exclue ou non déclarée. — Contournement d'une franchise ou d'un plafond : fractionner artificiellement un dommage ou modifier sa nature pour obtenir une meilleure prise en charge contractuelle.	— Fausse déclaration d'effraction : présenter un vol simple comme un vol avec effraction pour satisfaire à la condition contractuelle de garantie. — Transformation d'un défaut d'entretien en événement accidentel : présenter une infiltration progressive ou un défaut d'étanchéité comme un dégât des eaux soudain et garanti. — Dissimulation de l'inoccupation du logement : omettre que le logement était vacant au-delà de la durée prévue par le contrat au moment du sinistre. — Requalification d'un bien exclu en bien garanti : déclarer comme mobilier assuré un objet relevant d'une exclusion ou nécessitant une garantie spécifique. — Mise en scène d'un dommage garanti : présenter un dommage esthétique, ancien ou non garanti comme consécutif à un événement couvert (incendie, dégât des eaux, vol).

TABLE 1.3 – Exemples de fraude liée aux conditions générales en assurance non-vie

1.3 Cadre réglementaire des sanctions en cas de fraude avérée

La fraude en assurance ne se limite pas à une simple irrégularité contractuelle : elle peut emporter des conséquences à plusieurs niveaux. Selon le moment où elle intervient et sa nature, elle peut produire des effets civils et contractuels, tels que la nullité du contrat, la déchéance de garantie, le refus d'indemnisation ou la restitution des indemnités indûment versées.

Elle peut également, lorsque les manœuvres frauduleuses sont suffisamment caractérisées, relever du droit pénal. Le régime applicable diffère toutefois selon que la fraude intervient au moment de la souscription du contrat ou lors de la déclaration du sinistre, ce qui justifie de distinguer ces deux hypothèses avant d'aborder les questions probatoires et les qualifications pénales susceptibles d'être retenues.

1.3.1 Souscription

En matière de souscription, le régime des sanctions repose principalement sur les articles L.113-8 et L.113-9 du Code des assurances. Il convient toutefois de distinguer selon que l'inexactitude déclarative procède d'une intention frauduleuse ou d'une simple erreur.

L'article L.113-8 prévoit que la réticence ou la fausse déclaration intentionnelle de l'assuré entraîne la nullité du contrat. Cette sanction suppose que l'assureur démontre non seulement l'inexactitude ou l'omission, mais également le caractère intentionnel de cette déclaration, c'est-à-dire la volonté de tromper l'assureur sur l'appréciation du risque. En pratique, cette intention frauduleuse doit porter sur un élément que l'assureur considérerait comme déterminant dans sa décision de contracter ou dans la fixation de la prime.

La nullité du contrat produit un effet rétroactif : le contrat est réputé n'avoir jamais existé, de sorte que l'assureur n'est pas tenu de garantir le sinistre. En outre, les primes déjà versées demeurent acquises à l'assureur, à titre de dommages et intérêts. Cette sanction est particulièrement sévère et reflète l'exigence de bonne foi qui gouverne la formation du contrat d'assurance.

À l'inverse, l'article L.113-9 vise l'hypothèse d'une déclaration inexacte non intentionnelle. Dans ce cas, il n'y a pas fraude à proprement parler, mais le contrat n'est pas pour autant maintenu sans conséquence. Si l'erreur est constatée avant tout sinistre, l'assureur peut soit maintenir le contrat moyennant une augmentation de prime, soit le résilier. Si elle est découverte après sinistre, l'indemnité peut être réduite proportionnellement au rapport entre la prime payée et celle qui aurait été due si le risque avait été exactement déclaré. Cette distinction entre mauvaise foi et simple erreur est essentielle, car toute anomalie déclarative n'a pas vocation à recevoir la qualification de fraude.

1.3.2 Sinistre

Lorsque la fraude intervient au moment du sinistre, les conséquences juridiques diffèrent de celles applicables à la souscription. Il ne s'agit plus de remettre en cause la formation du contrat, mais de sanctionner

une demande de garantie ou d'indemnisation obtenue ou tentée au moyen de déclarations mensongères, d'une dissimulation de circonstances essentielles ou de la production de pièces falsifiées.

La première conséquence est le refus d'indemnisation lorsque la fraude est détectée avant tout paiement. En pratique, l'assureur peut opposer à l'assuré l'absence de droit à garantie dès lors que le sinistre déclaré ne correspond pas à la réalité ou que son montant a été artificiellement majoré. Cette sanction peut également prendre la forme d'une déchéance de garantie lorsque le contrat prévoit qu'une fausse déclaration intentionnelle relative au sinistre prive l'assuré du bénéfice de la garantie. La déchéance se distingue de la nullité en ce qu'elle n'affecte pas l'existence même du contrat, mais uniquement le droit à indemnisation au titre du sinistre concerné.

Si l'indemnité a déjà été versée au moment de la découverte de la fraude, l'assureur peut engager une action en restitution des sommes indûment perçues. Cette répétition de l'indu permet de récupérer le montant versé en l'absence de droit légitime à indemnisation. Dans les cas les plus graves, l'assureur pourra en outre solliciter des dommages et intérêts en réparation du préjudice subi, notamment lorsque la fraude a entraîné des coûts d'expertise, d'enquête ou de gestion supplémentaires.

En pratique, la mise en œuvre de ces sanctions suppose toutefois que la fraude soit effectivement démontrée. Or, la fraude au sinistre ne se présume pas : l'assureur doit être en mesure d'établir le caractère intentionnel des manœuvres invoquées, ce qui renvoie directement à la question de la preuve, mais également, dans certaines hypothèses, à d'éventuelles poursuites pénales.

1.3.3 Preuve de la fraude et sanctions pénales

La mise en œuvre des sanctions contractuelles suppose, en premier lieu, que la fraude soit prouvée. En droit des assurances comme en droit commun, la fraude ne se présume pas. Il appartient donc à l'assureur d'établir l'existence de manœuvres intentionnelles destinées à obtenir un avantage indu. Cette exigence probatoire est particulièrement importante, car une simple incohérence ou une approximation dans les déclarations de l'assuré ne suffit pas, à elle seule, à caractériser une fraude.

La preuve peut être rapportée par tout moyen et résulte souvent, en pratique, d'un faisceau d'indices graves, précis et concordants. Il peut s'agir, par exemple, d'incohérences entre les déclarations successives, d'anomalies documentaires, de contradictions entre les circonstances déclarées et les constatations matérielles, ou encore de rapprochements opérés à partir d'historiques de sinistres et de données comportementales.

Cette dimension probatoire explique le recours croissant, chez les assureurs, à des dispositifs spécialisés d'investigation, à l'analyse de données et à des modèles de scoring destinés à hiérarchiser les dossiers les plus suspects, sans pour autant se substituer à l'appréciation humaine.

Au-delà des conséquences contractuelles, certaines fraudes à l'assurance peuvent également recevoir une qualification pénale. Lorsque l'assuré use de manœuvres frauduleuses afin de tromper l'assureur pour obtenir la remise de fonds, les faits peuvent relever de l'escroquerie au sens de l'article 313-1 du Code pénal.

De même, la production de justificatifs falsifiés, de fausses factures, de faux constats ou de documents

d'identité altérés est susceptible de constituer un faux ou un usage de faux. Le droit pénal vient ainsi compléter le droit des assurances : là où ce dernier organise les conséquences contractuelles de la fraude, le premier sanctionne la manœuvre frauduleuse elle-même lorsqu'elle porte atteinte à l'ordre public économique.

1.4 Enjeux économiques et actuariels de la fraude

1.4.1 L'ampleur du marché de la fraude

Le marché de l'assurance non-vie représente 80,3 Md€ de primes pour 56,3 Md€ de prestations versées en 2025.

Le volume de sinistres étant très important, il n'est pas envisageable de vérifier manuellement la véracité de chaque déclaration sans rogner de manière trop importante sur la marge de l'assureur.

	Cotisations	Prestations
Assurance de biens et de responsabilité	80,3 Md€	56,3 Md€
Dont assurance automobile	30,2 Md€	24,7 Md€
Dont assurance habitation	14,9 Md€	9,9 Md€

TABLE 1.4 – Cotisations et prestations d'assurance de biens et de responsabilité en 2025 (Source : France Assureurs).

Ainsi, la profession s'est structurée autour de l'ALFA (Agence de Lutte contre la Fraude à l'Assurance).

Créée en février 1989, cette association professionnelle a pour mission d'accompagner les assureurs français dans la prévention et la détection des fraudes. Elle agit comme un véritable carrefour d'informations, centralisant les données, formant les gestionnaires et collaborant avec les pouvoirs publics (notamment le ministère de l'Intérieur) pour endiguer ce phénomène.

La fraude à l'assurance est un phénomène complexe à quantifier avec précision, car par nature, une grande partie reste non détectée. Au niveau européen, la fédération Insurance Europe estime que la fraude représente jusqu'à 10 % du coût total des sinistres¹. En France, selon les estimations de la Fédération Française de l'Assurance et de l'ALFA, le coût global de la fraude s'élèverait à environ 2,5 milliards d'euros par an, soit environ 5 % du niveau d'encaissement des primes².

Les montants identifiés sont ainsi passés de 695 millions d'euros en 2023 à 902 millions d'euros en 2024 (+30 %) et 947 millions d'euros en 2025 (+5 %).

0. https://www.franceassureurs.fr/wp-content/uploads/20260325_presentation-conference-de-presse-2.pdf

1. <https://www.insuranceurope.eu/mediaitem/0bf0af82-e7ef-4439-a763-d7862859d421/The+impact+of+insurance+fraud.pdf>

2. <https://www.argusdelassurance.com/institutions/fraude-a-l-assurance-une-facture-de-2-5-md-en-dommages-en-2014-alfa.96060>

Finalement, les acteurs du marché soulignent et rappellent que c'est la collectivité entière qui est pénalisée, la fraude alourdissant la prime annuelle de chaque assuré honnête d'environ 50 euros sur chaque contrat d'assurance automobile³.




FIGURE 1.1 – Évolution de la fraude automobile entre 2020 et 2025 (Source : ALFA Association).

Si ce fléau touche toutes les branches de l'assurance, l'IARD (Incendie, Accidents et Risques Divers) en représente de loin la part la plus importante.

À titre d'exemple, sur les 947 millions d'euros de fraudes détectées en 2025, 627 millions concernent exclusivement l'IARD (notamment l'assurance Automobile et l'assurance Multirisque Habitation), soit près de 66 % du total⁴.

Les assurances de biens, par leur forte fréquence de sinistralité, demeurent le secteur le plus exposé aux déclarations de sinistres fictifs ou à la surestimation des dommages.

Ces segments cumulent plusieurs facteurs d'exposition : une fréquence de sinistres élevée, une forte volumétrie de dossiers de montant unitaire parfois modéré, ainsi qu'une documentation déclarative susceptible d'être manipulée.

En assurance automobile, la multiplicité des intervenants (assuré, tiers, réparateur, expert, dépanneur) accroît les opportunités de fraude. En habitation, la difficulté de vérifier a posteriori la réalité, l'antériorité ou la valeur des biens déclarés favorise également les comportements opportunistes.

Ce phénomène et ses proportions ne sont pas une spécificité française. À l'échelle européenne, la fédération Insurance Europe estime que la fraude représente en moyenne jusqu'à 10 % du coût total des sinistres

3. <https://www.argusdelassurance.com/acteurs/fraude-a-l-assurance-un-cout-de-50-pour-les-assures.60931>

3. Sources : <https://www.alfa.asso.fr/alfa-news-48-septembre-2024/>; <https://www.alfa.asso.fr/alfa-news-39-juin-2023-2/> et <https://www.franceassureurs.fr/wp-content/uploads/donnees-cles-2024.pdf>

4. <https://www.argusdelassurance.com/assurance-de-personnes/des-filieres-de-larnaque-utilisent-lintelligence-artificielle.VRVQHSNDANZGGZL5GXH7FHW3JU4.html>

dans les pays voisins (comme au Royaume-Uni ou en Allemagne). La France se situe donc dans cette moyenne continentale. Toutefois, l'écart observé au niveau européen entre la fraude détectée (environ 2,5 milliards d'euros) et la fraude réelle non détectée (estimée à plus de 13 milliards d'euros) souligne qu'une immense partie des préjudices passe encore « à travers les mailles du filet ». Cette « fraude invisible » représente un défi majeur pour la rentabilité des compagnies d'assurance.

1.4.2 Impact de la fraude sur la tarification

L'enjeu de la fraude ne se résume pas à une perte ponctuelle pour les assureurs : il affecte plus largement l'équilibre technique du marché, la qualité des données historiques et, en définitive, la construction même des primes. C'est ce lien direct entre fraude, sinistralité observée et tarification qu'il convient désormais d'examiner.

1.4.2.1 Modèle tarifaire usuel en assurance non-vie et biais statistiques

En assurance non-vie, la tarification repose usuellement sur des Modèles Linéaires Généralisés (GLM).

La Prime Pure (PP) est modélisée par le produit de l'espérance de la fréquence des sinistres (N) et de l'espérance de leur coût moyen (C) :

$$PP = \mathbb{E}[N] \times \mathbb{E}[C] \quad (1.1)$$

L'absence de détection de la fraude introduit un biais systématique dans les bases de données utilisées pour calibrer ces modèles tarifaires (que ce soit via des GLM traditionnels ou des algorithmes de Machine Learning comme XGBoost) :

- **Impact sur la fréquence (N)** : la fraude opportuniste ou préméditée (déclaration de sinistres imaginaires) augmente artificiellement le nombre de sinistres dans le portefeuille.
- **Impact sur le coût moyen (C)** : la majoration de dommages (ajout d'éléments fictifs sur une facture réelle) gonfle la sévérité moyenne des sinistres.

Si l'actuaire calibre ses modèles sur ces données polluées, il surestime le risque réel du portefeuille sain. La prime demandée aux assurés honnêtes augmente, ce qui dégrade la compétitivité de l'assureur sur le marché.

1.4.2.2 Conséquence de la fraude sur la prime pure

Dans l'équation de la prime pure, une surestimation de la fréquence ou du coût moyen conduit mécaniquement à une prime plus élevée pour l'ensemble du portefeuille.

Dans le cas de la fraude par majoration (sinistre réel mais montant surévalué), l'impact est directement porté sur l'espérance du coût moyen $\mathbb{E}[C]$:

$$\mathbb{E}[C]_{\text{fraude}} = \mathbb{E}[C]_{\text{réel}} + \mathbb{E}[C]_{\text{majoration}} \quad (1.2)$$

Dans le cas de la fraude par invention (sinistre totalement fictif), l'impact est porté sur la fréquence $\mathbb{E}[N]$:

$$\mathbb{E}[N]_{\text{fraude}} = \mathbb{E}[N]_{\text{réel}} + \mathbb{E}[N]_{\text{fictif}} \quad (1.3)$$

Ainsi, si l'on note α la part de la charge sinistre imputable à la fraude, la prime d'équilibre technique observée ($\Pi_{\text{chargée}}$) se déduit de la prime pure théorique (Π_{pure}) par la relation :

$$\Pi_{\text{chargée}} = \frac{\Pi_{\text{pure}}}{1 - \alpha} \quad (1.4)$$

où α est estimé entre 5 % et 10 % du volume des prestations selon les branches (Source : ALFA).

Part de la fraude dans la charge (α)	Surcoût sur la prime pure (%)
5,0 %	+ 5,26 %
7,5 %	+ 8,11 %
10,0 %	+ 11,11 %

TABLE 1.5 – Impact du levier de la fraude sur la prime des assurés honnêtes

Il faut souligner que l'effet de la fraude sur la tarification ne se limite pas à une hausse mécanique de la prime pure. Il se propage également aux chargements de gestion, dans la mesure où la lutte contre la fraude mobilise des ressources d'expertise, de contrôle et de contentieux.

En outre, une répercussion trop importante de ces coûts dans les primes commerciales peut nuire à la compétitivité de l'assureur et accentuer les phénomènes d'anti-sélection, en éloignant les assurés les moins risqués du portefeuille.

De plus, un enjeu central réside dans le fait que la fraude peut fausser la segmentation elle-même.

En effet, certaines variables explicatives peuvent apparaître comme fortement corrélées à la sinistralité observée non pas en raison d'un risque assurantiel intrinsèque plus élevé, mais parce qu'elles sont associées à une fréquence accrue de comportements frauduleux ou à des modalités de détection différenciées. L'actuaire court alors le risque d'intégrer dans la tarification des effets qui relèvent moins du risque pur que de distorsions comportementales ou informationnelles.

Inversement, l'amélioration des dispositifs de détection permet d'assainir les bases historiques servant à la modélisation actuarielle. À terme, une meilleure identification des dossiers frauduleux contribue à restaurer une mesure plus fidèle du risque technique, à améliorer la segmentation tarifaire et à limiter le transfert de charge vers les assurés honnêtes. La lutte contre la fraude devient ainsi non seulement un levier de réduction des pertes, mais également un instrument de qualité tarifaire.

1.4.2.3 L'analyse coût-bénéfice : le seuil de rentabilité du contrôle

Pour corriger ce biais tarifaire, l'assureur doit identifier et rejeter les sinistres frauduleux. Cependant, le processus de détection n'est pas gratuit : il engage des frais de gestion supplémentaires (expertise contradictoire, enquête administrative, recours à un détective privé).

L'assureur fait donc face à un problème d'optimisation économique simple : l'espérance d'économie (le non-paiement du sinistre) doit être supérieure au coût du contrôle.

Soit C_{invest} le coût moyen d'une investigation et M_{sinistre} le montant du sinistre réclamé. Le contrôle n'est rationnel que si :

$$M_{\text{sinistre}} \times P(\text{Fraude} \mid \text{Alerte}) > C_{\text{invest}} \quad (1.5)$$

où $P(\text{Fraude} \mid \text{Alerte})$ représente la précision du modèle de détection (la probabilité que l'alerte soit réellement fondée).

Sur le marché IARD français, une expertise automobile classique coûte entre 70 € et 400 € par dossier⁵, tandis qu'une investigation spécialisée (enquêteur certifié ALFA) peut rapidement dépasser les 1 000 €, les honoraires étant libres et dépendant fortement du type de sinistre.

Ainsi, pour un sinistre matériel de 1 200 €, engager une expertise à 250 € est rentable. En revanche, pour de « petits sinistres » (par exemple un bris de glace à 400 €), le coût administratif et d'expertise rend la détection humaine irrationnelle d'un point de vue économique.

1.4.2.4 L'automatisation de la détection de la fraude comme levier de rentabilité

C'est sur cette « fraude de masse », de faible montant, que le modèle traditionnel atteint ses limites, et que l'implémentation de nouvelles technologies devient indispensable.

En effet, à date, avec la digitalisation, on observe une hausse des tentatives de fraude, notamment au travers de falsifications numériques et de retouches d'image⁶.

En parallèle, l'amélioration des outils tels que la Data analytics, la détection d'anomalies, l'analyse d'image ou le Cross-checking de bases externes permet d'améliorer le taux de détection des fraudes.

Néanmoins, malgré l'amélioration des méthodes de détection de fraude, la fraude documentaire reste un poste matériel dans le coût technique global. En mettant en place des méthodes de détection de fraude automatiques (algorithmes de scoring, IA etc.), l'assureur réduit drastiquement le coût de traitement et de ciblage des fraudes.

Le coût marginal de vérification s'approchant de zéro, il devient alors rentable d'investiguer des sinistres de plus faible montant, assainissant ainsi la base de sinistralité et protégeant l'équilibre de la prime.

C'est précisément dans la réponse à ce défi opérationnel et financier que s'inscrit l'objectif central de ce

5. Source : Service public.

6. La fraude documentaire (faux certificats, fausses factures, photos retouchées) est en explosion et représente désormais 39 % des cas de fraude détectés en IARD (source : <https://www.itesoft.com/fr/blog/fraude-assurance-chiffres-cles-alfa/>).

mémoire. En effet, les ambitions des travaux de ce mémoire sont de concevoir et déployer un processus de détection automatisé des fraudes de bout en bout.

Il convient toutefois de circonscrire d'emblée le périmètre de cette détection. Notre démarche ne porte pas sur la fraude documentaire (falsification de factures, de devis ou d'attestations) ni sur la fraude relevant de l'analyse d'images (clichés retouchés ou détournés), faute de disposer des bases de données documentaires et photographiques nécessaires à l'entraînement de tels modèles.

L'approche retenue se concentre au contraire sur la fraude circonstancielle, c'est-à-dire celle qui se révèle à travers les caractéristiques mêmes du sinistre et de l'assuré : nature et chronologie de la déclaration, antécédents et historique du contrat, profil du déclarant, cohérence entre les circonstances rapportées et les paramètres du sinistre, ou encore récurrence de signaux faibles susceptibles de trahir une intention frauduleuse.

Cette orientation présente l'avantage de s'appuyer exclusivement sur des données structurées déjà disponibles dans les systèmes de gestion de l'assureur, ce qui en fait un levier à la fois exploitable, reproductible et directement intégrable au processus d'instruction des sinistres.

Pour y parvenir, l'étude s'appuie sur une base de données publique de sinistres automobiles issue de Kaggle, contenant des dossiers étiquetés comme frauduleux ou non. À défaut de données réelles d'assureur, difficilement accessibles pour des raisons de confidentialité, cette base offre un support représentatif et reproductible pour développer et tester la démarche, même si sa transposition à un portefeuille réel nécessiterait une phase de recalibrage.

Pour pallier en partie à ce recalibrage inexistant, cette base a été enrichie avec des données qui auraient été disponibles chez un assureur de manière à enrichir le modèle de détection de fraude créé.

Les chapitres suivants détailleront cette démarche : après un état des lieux des processus de détection existants et de l'apport de l'intelligence artificielle (Chapitre 2), en opposition à ce qui se fait déjà en matière de détection de fraude (Chapitre 3), nous présenterons la construction et la comparaison des trois modèles de détection retenus (scoring en points, arbre de décision et Gradient Boosting) ainsi que l'évaluation de leurs performances respectives (Chapitre 4). Le Chapitre 5 décrira l'outil opérationnel développé à destination des services de gestion des sinistres, suivi du Chapitre 6 qui expliquera la logique d'enrichissement continu du modèle. Enfin, le Chapitre 7 ouvrira sur les limites de l'outil et les perspectives d'évolution, notamment autour de la qualité des données, de la mutualisation inter-assureurs et de l'extension à une approche multi-produits.

Chapitre 2

La détection de la fraude en assurance :
de l'approche manuelle à l'automatisa-
tion par l'IA

2.1 L'approche traditionnelle : une détection manuelle et ciblée

2.1.1 Le rôle des équipes dédiées

Historiquement, la lutte contre la fraude en assurance non-vie repose sur une organisation humaine structurée, intégrée à la chaîne de gestion des sinistres.

Le premier maillon en est le gestionnaire de sinistres : chargé d'instruire les déclarations et de procéder à l'indemnisation, il constitue le point de contact initial avec le dossier et, à ce titre, la première ligne de détection.

Lorsqu'un dossier éveille un doute, il peut être orienté vers une instance spécialisée (service ou cellule anti-fraude) composée d'enquêteurs et d'analystes dont c'est le métier exclusif. Ces cellules regroupent souvent des enquêteurs spécialisés, des data analysts (pour la détection algorithmique), des juristes et parfois d'anciens policiers ou gendarmes.

Ces enquêteurs disposent de prérogatives et de moyens d'investigation plus poussés : demande de pièces complémentaires, vérification des déclarations, recoupement avec des bases sectorielles, recours éventuel à des expertises ou à des enquêtes de terrain.

Cette organisation s'insère à un point précis de la chaîne d'indemnisation : entre la déclaration du sinistre et le versement de l'indemnité. La détection intervient ainsi comme un filtre, destiné à suspendre ou approfondir l'instruction des dossiers suspects avant que l'indemnisation ne soit prononcée.

Sa position est donc stratégique, puisqu'une fraude non détectée à ce stade se traduit directement par un versement indu, tandis qu'un contrôle trop systématique alourdit les délais de gestion et dégrade la qualité de service pour les assurés de bonne foi. L'équilibre entre maîtrise du risque de fraude et fluidité du règlement constitue l'arbitrage permanent de ces équipes.

2.1.2 Une détection fondée sur l'expertise humaine

Dans ce dispositif traditionnel, la détection repose essentiellement sur le jugement et l'expérience des intervenants. Elle s'opère largement « au fil de l'eau » : c'est au moment de l'instruction d'un dossier que le gestionnaire, par sa connaissance des cas habituels, perçoit une anomalie ou une incohérence. Cette vigilance s'appuie sur un ensemble de signaux d'alerte ou *red flags* issus de l'expérience accumulée : délai anormalement court entre la souscription et le sinistre, déclaration tardive, circonstances peu cohérentes, antécédents répétés, montant de dommages disproportionnés, ou encore concordances suspectes entre plusieurs dossiers.

Une fois le soupçon né, la confirmation passe par un travail de recoupement manuel : rapprochement des informations déclarées, comparaison avec l'historique du contrat et de l'assuré, vérification de la cohérence d'ensemble. Ce processus mobilise fortement l'intuition métier, c'est-à-dire la capacité, forgée par la pratique, à identifier des configurations atypiques que ne traduit aucune règle écrite. Cette

expertise humaine constitue une force réelle : elle est fine, contextuelle et capable d'appréhender des situations inédites. Mais elle est aussi, par nature, difficilement formalisable et transmissible, ce qui en fait simultanément la principale limite de l'approche.

2.1.3 Les limites de cette approche

Si l'expertise humaine demeure précieuse, l'organisation traditionnelle se heurte à plusieurs limites structurelles. La première tient à sa couverture partielle : le contrôle manuel étant coûteux en temps, seule une fraction des dossiers peut être examinée en profondeur, la grande majorité étant traitée sans analyse anti-fraude approfondie. Il en résulte un risque non négligeable de non-détection : de nombreuses fraudes échappent au dispositif, non parce qu'elles seraient indétectables, mais faute de ressources pour les examiner, passant inaperçues sous la forme de faux négatifs lorsque les indices ne sont pas suffisamment manifestes.

S'y ajoute une forte dépendance à l'expertise individuelle. La qualité de la détection varie selon l'expérience, la charge de travail et la vigilance de chaque gestionnaire, chacun appliquant ses propres critères et son propre niveau de rigueur. Il en découle une hétérogénéité des décisions (un même dossier pourra être contrôlé par l'un et laissé passer par l'autre) qui nuit à la reproductibilité du processus et à son auditabilité. Le caractère manuel des vérifications induit par ailleurs une lenteur de traitement et un coût humain élevé, puisque chaque dossier suspect doit être examiné de façon approfondie et que l'augmentation du nombre de contrôles suppose un accroissement proportionnel des effectifs, ce qui ralentit le règlement global des sinistres.

L'approche montre enfin ses limites dans l'exploitation des données disponibles. Les volumes d'informations accumulés au fil du temps sont difficiles à analyser de manière exhaustive sans outils automatisés, ce qui empêche d'identifier les schémas récurrents ou les comportements suspects à grande échelle. Cette difficulté favorise en outre des biais d'attention : à force de concentrer les contrôles sur certains profils ou types de sinistres réputés à risque, on délaisse les schémas de fraude moins familiers et l'on reproduit des a priori non fondés.

L'ensemble de ces limites converge vers un même enjeu de rentabilité. Le volume de fraudes effectivement détecté reste faible au regard du coût que représente le dispositif humain, et surtout au regard de la fraude réellement présente dans le portefeuille. Le rapport entre les montants recouvrés et les ressources mobilisées plafonne, sans qu'il soit possible de l'améliorer significativement par les seuls moyens manuels. C'est précisément cette inefficience (un coût élevé pour une couverture limitée) qui motive le recours à une détection automatisée fondée sur l'intelligence artificielle, capable d'analyser l'intégralité des dossiers à un coût marginal réduit et de dépasser ainsi un grand nombre des limites associées aux méthodes manuelles.

2.2 L'apport de l'intelligence artificielle : de nouvelles solutions de détection

2.2.1 Le contexte d'émergence

L'essor des solutions de détection automatisée n'est pas le fruit d'une rupture isolée, mais la convergence de plusieurs évolutions.

La première est l'explosion du volume de données structurées disponibles : la dématérialisation de la gestion des sinistres, la standardisation des systèmes d'information, la conservation systématique de l'historique des contrats et des déclarations ont constitué des bases de données riches, exploitables et homogènes, là où l'information était auparavant éparse et largement non numérisée.

La deuxième tient à la maturité des méthodes d'apprentissage : les algorithmes de machine learning, et en particulier les méthodes d'ensemble sur données tabulaires présentées précédemment, sont désormais éprouvés, accessibles via des bibliothèques robustes et applicables à coût raisonnable.

La troisième relève du contexte économique : la pression croissante sur les coûts et sur les délais de gestion pousse les assureurs à rechercher des gains d'efficacité, tandis que la fraude, par son impact direct sur la sinistralité et donc sur la prime, demeure un enjeu financier majeur. La conjonction de ces facteurs (données disponibles, outils matures et nécessité économique) a rendu possible et souhaitable le passage à des dispositifs automatisés.

2.2.2 Les nouvelles approches

Ce passage s'est opéré par étapes. Les premiers dispositifs automatisés reposaient sur des moteurs de règles : des conditions explicites, traduisant les signaux d'alerte connus des experts (un délai inférieur à tel seuil, un cumul de sinistres supérieur à tel nombre), déclenchaient une alerte. Reproduisant la connaissance métier, ces systèmes en héritaient aussi les limites : rigides, ils ne détectaient que la fraude déjà identifiée et se révélaient incapables d'appréhender des schémas nouveaux ou la conjonction subtile de plusieurs facteurs.

Les modèles prédictifs ont marqué l'évolution suivante. Plutôt que d'appliquer des règles figées, ils apprennent à partir de l'historique des dossiers à attribuer à chaque sinistre un score de risque de fraude, c'est-à-dire une probabilité estimée à partir de l'ensemble de ses caractéristiques. Cette approche autorise une détection circonstancielle, fondée sur les caractéristiques du sinistre et de l'assuré (chronologie, antécédents, cohérence des circonstances déclarées, profil du dossier) et capable de capter automatiquement des interactions que nul ne formaliserait sous forme de règle. Surtout, elle modifie en profondeur la logique de couverture : alors que le contrôle manuel ne portait que sur un échantillon de dossiers, le modèle procède à un traitement systématique de l'ensemble des dossiers, chacun se voyant attribuer un score, sans tri préalable.

2.2.3 Les bénéfices attendus

Il découle de ces approches plusieurs bénéfices :

- **Une augmentation du volume de fraudes détectées** : en analysant l'intégralité du portefeuille plutôt qu'une fraction, le dispositif fait remonter des dossiers suspects qui auraient échappé à un contrôle manuel nécessairement sélectif. Cette couverture exhaustive s'accompagne d'une capacité analytique accrue : en exploitant aussi bien les données courantes que les historiques, le modèle détecte des schémas complexes et des corrélations difficilement identifiables par l'humain, améliorant ainsi la détection des fraudes les plus élaborées, souvent caractérisées par des signaux faibles ou dispersés.
- **Une réduction du coût unitaire de détection** : une fois le modèle développé, le scoring d'un dossier supplémentaire présente un coût marginal quasi nul, ce qui améliore directement le rapport entre les fraudes détectées et les ressources mobilisées.
- **Une réduction des délais de traitement** : grâce au tri automatique, de grands volumes de sinistres peuvent être analysés quasi instantanément, accélérant ainsi le règlement des dossiers sains tout en orientant sans délai les cas suspects vers l'investigation.
- **Une priorisation objective, homogène et reproductible** : le score fournit un critère unique de hiérarchisation des dossiers, appliqué de manière identique à tous. En substituant des règles et des algorithmes standardisés à l'appréciation individuelle, cette homogénéisation des pratiques garantit une cohérence d'évaluation indépendante des intervenants et réduit le risque de biais subjectifs ou discriminatoires.
- **Une forte capacité de passage à l'échelle** : ces dispositifs absorbent des volumes croissants de données sans accroissement proportionnel des effectifs ni dégradation des performances. L'intervention humaine est ainsi recentrée sur les seuls dossiers présentant le niveau de risque le plus élevé, un atout précieux dans un contexte de croissance et de diversification des flux.

Cette logique constitue le fondement de l'outil développé dans ce mémoire. À chaque nouveau sinistre, l'agent attribue une probabilité de fraude permettant de hiérarchiser les dossiers selon leur niveau de risque. Les équipes d'investigation peuvent ainsi concentrer leurs efforts sur les cas les plus suspects, sans mobiliser inutilement des ressources sur les dossiers présentant une faible probabilité de fraude. Le score ne se substitue pas à la décision humaine : il l'éclaire en transformant un ensemble de déclarations en une file de traitement priorisée.

2.2.4 Les points de vigilance à l'utilisation de l'intelligence artificielle

Ces bénéfices ne sont toutefois pas acquis sans contrepartie, et l'automatisation appelle plusieurs précautions, déjà évoquées dans le cadre de la gouvernance :

- **La qualité des données** : un modèle n'a de valeur que celle des données sur lesquelles il est entraîné. Des données incomplètes, erronées ou biaisées se traduisent mécaniquement par des prédictions de moindre qualité.
- **L'explicabilité des résultats** : un score de fraude ne saurait être opposé à un assuré sans que les facteurs ayant conduit à son attribution puissent être compris et justifiés. Cette exigence répond à des impératifs à la fois opérationnels, réglementaires et éthiques.
- **Le maintien d'une supervision humaine** : l'agent identifie les dossiers susceptibles de présenter un risque de fraude, mais ne prend pas la décision finale. L'investigation et la décision demeurent du ressort des équipes, ce qui permet d'éviter toute décision défavorable fondée exclusivement sur un traitement automatisé.
- **La surveillance de la performance du modèle** : les comportements frauduleux et les caractéristiques du portefeuille évoluant au fil du temps, les performances d'un modèle peuvent se dégrader en l'absence d'un suivi continu et d'un réentraînement périodique.

Loin de constituer une solution autosuffisante, l'intelligence artificielle apparaît ainsi comme un outil puissant dont l'efficacité demeure étroitement conditionnée à la qualité des données, à la robustesse de sa gouvernance et au maintien d'un cadre de contrôle rigoureux.

2.3 Comparaison du processus manuel et du processus automatisé

2.3.1 Les critères de comparaison

Comparer l'approche traditionnelle et l'approche automatisée suppose de fixer au préalable les dimensions sur lesquelles porte l'évaluation, afin d'éviter un jugement global et impressionniste. Sept critères apparaissent particulièrement structurants :

1. Le volume de dossiers analysés mesure la part du portefeuille effectivement soumise à un examen anti-fraude.
2. Le taux de détection rapporte les fraudes identifiées à la fraude réellement présente, et traduit l'efficacité du dispositif.
3. Le coût par dossier rend compte des ressources consommées pour analyser une déclaration.
4. Le délai de traitement conditionne la fluidité du règlement et la qualité de service.
5. L'homogénéité et la traçabilité des décisions renvoient à la reproductibilité du processus et à sa capacité à être audité.
6. La scalabilité désigne l'aptitude du dispositif à absorber une hausse du volume sans dégradation.

7. Enfin, la dépendance à l'expertise caractérise la vulnérabilité du processus à la disponibilité et au niveau de compétence des intervenants.

Ces critères couvrent ainsi les trois enjeux essentiels : l'efficacité de la détection, son coût, et sa robustesse.

2.3.2 Mise en regard des deux processus

La confrontation des deux approches selon ces critères peut être synthétisée comme suit :

Critère	Processus manuel	Processus automatisé (IA)
Volume de dossiers analysés	Partiel : seule une fraction des dossiers est examinée	Exhaustif : l'ensemble des dossiers est scoré
Taux de détection	Limité par la capacité humaine de contrôle	Plus élevé, y compris sur des schémas peu visibles
Coût par dossier	Élevé et croissant avec le volume	Faible coût marginal après développement du modèle
Délai de traitement	Long, tributaire de la charge des équipes	Quasi instantané (scoring automatique)
Homogénéité et traçabilité	Variable, subjective, peu reproductible	Critère unique, appliqué identiquement et traçable
Scalabilité	Faible : suppose d'accroître les effectifs	Élevée : montée en charge à coût quasi constant
Dépendance à l'expertise	Forte : qualité tributaire de chaque intervenant	Réduite à l'usage, déportée vers la conception du modèle

TABLE 2.1 – Comparaison du processus manuel et du processus automatisé de détection de la fraude

Cette mise en regard fait clairement ressortir l'avantage de l'automatisation sur les dimensions de volume, de coût, de délai et d'homogénéité. Elle ne doit cependant pas être lue comme la disqualification de l'intervention humaine.

D'une part, l'expertise reste indispensable en amont, pour concevoir, entraîner et valider le modèle, et en aval, pour instruire les dossiers signalés. D'autre part, le modèle ne produit qu'une probabilité de fraude, c'est-à-dire un soupçon hiérarchisé, et non une preuve : seule l'investigation humaine permet d'établir la réalité de la fraude et d'en tirer les conséquences.

L'automatisation ne supprime donc pas le travail humain, elle le réoriente : libérée du tri d'une masse indifférenciée de dossiers, l'expertise se concentre sur les cas à plus forte valeur ajoutée, ceux que le modèle a identifiés comme les plus à risque.

2.3.3 Vers un modèle hybride

De cette comparaison se dégage non pas une opposition, mais une complémentarité. Les forces de chaque approche répondent précisément aux faiblesses de l'autre : l'IA excelle dans le traitement exhaustif, rapide et homogène de gros volumes, là où l'humain excelle dans l'analyse fine, contextuelle et le jugement sur les cas complexes.

La configuration la plus efficace est dès lors un modèle hybride, dans lequel chaque acteur intervient là où il est le plus pertinent. L'IA assure le filtrage et la priorisation : elle analyse l'ensemble des dossiers et les classe par niveau de risque. L'humain assure l'investigation et la décision finale : il examine les dossiers prioritaires, confirme ou écarte la suspicion, et prononce les suites à donner. Cette articulation préserve la maîtrise humaine du processus tout en démultipliant sa portée.

C'est exactement cette logique hybride que met en œuvre l'Agent développé dans ce mémoire, dont nous présenterons la conception et le fonctionnement après un rapide rappel du cadre théorique sur les algorithmes de détection de fraude utilisés en assurance non-vie.

Chapitre 3

Cadre théorique : les algorithmes de détection de fraude utilisés en assurance non-vie

La détection de la fraude circonstancielle se formule naturellement comme un problème d'apprentissage supervisé binaire. Cette formulation suppose de disposer d'un historique de sinistres dont l'issue (frauduleuse ou licite) a été établie, par exemple à l'issue d'enquêtes passées. On note l'échantillon d'apprentissage :

$$\mathcal{D}_n = \{(x_i, y_i)\}, \quad i = 1, \dots, n, \quad (3.1)$$

où le vecteur $x_i \in \mathbb{R}^p$ rassemble les p caractéristiques décrivant le sinistre et l'assuré (montant déclaré, ancienneté du contrat, délai entre la souscription et la survenance, antécédents, nature de la garantie, canal de déclaration, etc.), et où la variable cible $y_i \in \{0, 1\}$ vaut 1 lorsque le sinistre est frauduleux. Cette classe d'intérêt est par nature minoritaire, ce qui constitue l'une des principales difficultés statistiques du problème et conditionne tant le choix des modèles que celui des métriques d'évaluation. L'objectif commun à toutes les méthodes présentées ci-dessous est d'estimer une fonction de score exprimant la probabilité de fraude conditionnelle aux caractéristiques observées :

$$\hat{p}(x) = \hat{P}(Y = 1 \mid X = x) \in [0, 1]. \quad (3.2)$$

Le recours à une sortie continue plutôt qu'à une décision binaire immédiate est un choix structurant. Il permet de hiérarchiser les dossiers selon leur niveau de risque et de ne déclencher une investigation (coûteuse) que sur les cas les plus suspects, le seuil de décision étant calibré séparément selon une logique économique (rapport entre le coût d'une enquête et le gain espéré d'une fraude évitée). Cette logique de score partagée explique également pourquoi l'évaluation des modèles ne peut reposer sur le simple taux de bonnes classifications, trompeur en présence de classes déséquilibrées, mais s'appuie sur des indicateurs tels que la précision, le rappel et l'aire sous la courbe précision-rappel.

Les quatre familles de modèles retenues dans ce mémoire sont présentées selon un fil conducteur unique : l'arbitrage entre interprétabilité et pouvoir prédictif.

On progresse ainsi de la régression logistique, modèle paramétrique parfaitement transparent, vers la forêt aléatoire puis le gradient boosting, dont la capacité à capturer des relations complexes se paie d'une opacité croissante, avant de revenir avec les modèles de scoring à points à une représentation directement lisible par les équipes métier.

À noter que dans un secteur soumis à de fortes exigences d'explicabilité et de gouvernance (notamment de la part de l'ACPR¹), cet arbitrage n'est pas un simple détail technique mais un critère de sélection à part entière.

1. ACPR : Autorité de Contrôle Prudentiel et de Résolution.

3.1 La régression logistique (modèle de référence)

La régression logistique constitue la référence historique de la modélisation du risque en actuariat. Il s'agit d'un modèle linéaire généralisé (GLM) appartenant à la famille binomiale et doté de la fonction de lien logit. Plutôt que de modéliser directement la probabilité, dont le domaine est borné à l'intervalle $[0, 1]$, le modèle agit sur le logarithme de la cote de fraude (le « log-odds »), dont le domaine couvre l'ensemble des réels, et le relie linéairement aux variables explicatives. Ainsi, la probabilité de fraude $p(x)$ s'écrit :

$$\ln \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \sum_{j=1}^p \beta_j x_j \quad (3.3)$$

En inversant cette relation, on retrouve la fonction logistique (ou sigmoïde) qui garantit une probabilité comprise entre 0 et 1. En notant $\eta = \beta_0 + \beta^\top x$ le prédicteur linéaire, la probabilité de fraude s'écrit :

$$p(x) = \frac{1}{1 + e^{-\eta}} \quad (3.4)$$

La forme sigmoïdale a une conséquence importante pour l'interprétation : la relation est linéaire sur l'échelle du logit, mais l'effet d'une variable sur la probabilité n'est pas constant : il est maximal autour de $p = 0,5$ et s'atténue aux extrêmes. Les coefficients β sont estimés par maximum de vraisemblance. Contrairement à la régression linéaire, il n'existe pas de solution analytique : la log-vraisemblance, dont l'expression est donnée ci-dessous, est concave et maximisée numériquement par des algorithmes itératifs de type Newton-Raphson (moindres carrés repondérés itérativement) :

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln p(x_i) + (1 - y_i) \ln(1 - p(x_i))] \quad (3.5)$$

L'atout déterminant du modèle réside dans son interprétabilité directe. L'exponentielle d'un coefficient fournit un odds-ratio, c'est-à-dire le facteur par lequel la cote de fraude est multipliée lorsque la variable correspondante augmente d'une unité, toutes choses égales par ailleurs :

$$OR_j = e^{\beta_j} \quad (3.6)$$

Un odds-ratio supérieur à 1 traduit une variable aggravante, un odds-ratio inférieur à 1 une variable atténuante ; cette lecture immédiate facilite la justification des décisions et le dialogue avec les équipes de gestion et les autorités de contrôle.

Lorsque le nombre de variables est élevé ou que celles-ci sont fortement corrélées, on recourt à la régularisation, qui ajoute à l'objectif une pénalité sur la norme des coefficients afin de stabiliser l'estimation et de limiter le surapprentissage.

Ainsi on cherche à minimiser :

$$J(\beta) = -\ell(\beta) + \lambda \cdot \text{Pénalité}(\beta) \quad (3.7)$$

avec $\text{Pénalité}(\beta)$ qui admet différentes variantes :

- La pénalité L1² (Lasso) définie par $\text{Pénalité}(\beta) = \lambda \sum_{j=1}^p |\beta_j|$, qui a la propriété d'annuler certains coefficients, réalisant ainsi une sélection automatique de variables. En effet, si $\beta_j = 0$, la variable j est complètement exclue du modèle ;
- La pénalité L2³ (Ridge) définie par $\text{Pénalité}(\beta) = \lambda \sum_{j=1}^p \beta_j^2$, qui rétrécit les coefficients sans les annuler. Ainsi, toutes les variables restent dans le modèle mais leurs coefficients sont tassés. Ceci est particulièrement utile lorsque les variables sont fortement corrélées entre elles.
- L'elastic net, définie par $\text{Pénalité}(\beta) = \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right]$, avec $\alpha \in [0, 1]$, qui combine les deux termes avec un paramètre qui dose le mélange, pour bénéficier à la fois de la sélection et de la stabilité.

La principale limite du modèle tient à son hypothèse d'additivité et de linéarité sur l'échelle du logit : les interactions entre variables et les effets non linéaires ne sont pas captés automatiquement et doivent être spécifiés à la main (termes croisés, discrétisations, transformations). Face à des schémas de fraude où la suspicion naît précisément de la conjonction de plusieurs facteurs, cette contrainte motive le recours à des méthodes plus flexibles.

3.2 La forêt aléatoire

La forêt aléatoire (random forest, Breiman, 2001) appartient à la famille des méthodes d'agrégation (ou méthodes ensemblistes), dont le principe est de combiner de nombreux modèles élémentaires pour obtenir un prédicteur plus performant et plus stable qu'aucun d'entre eux pris isolément. L'unité de base est l'arbre de décision (CART), qui partitionne récursivement l'espace des variables en régions de plus en plus homogènes au regard de la cible. À chaque nœud, l'algorithme évalue toutes les coupures possibles (une variable et un seuil) et retient celle qui maximise la décroissance d'une mesure d'impureté. Les deux mesures les plus courantes en classification sont l'indice de Gini $G(t)$ et l'entropie de Shannon $H(t)$, calculés sur un nœud t comportant une proportion $\hat{p}_{t,1}$ de sinistres frauduleux :

$$G(t) = 2\hat{p}_{t,1}(1 - \hat{p}_{t,1}) \quad (3.8)$$

$$H(t) = - \sum_k \hat{p}_{t,k} \log_2 \hat{p}_{t,k} \quad (3.9)$$

2. La pénalité L1 ajoute la somme des valeurs absolues des coefficients à l'objectif à minimiser.

3. La pénalité L2 ajoute la somme des carrés des coefficients.

La construction se poursuit jusqu'à un critère d'arrêt (profondeur maximale, effectif minimal par feuille), et la prédiction associée à une feuille est la fréquence empirique de fraude qu'elle contient. Pris isolément, un arbre profond présente un biais faible mais une variance élevée : il s'adapte finement aux données mais une légère perturbation de l'échantillon peut bouleverser sa structure et donc ses prédictions. C'est cette instabilité que la forêt aléatoire vient corriger, au moyen de deux mécanismes complémentaires.

Le premier est le bagging (bootstrap aggregating) : on construit B arbres sur autant d'échantillons obtenus par tirage avec remise dans les données d'origine, puis on moyenne leurs prédictions. La moyenne de prédictors de même loi réduit la variance sans augmenter le biais, d'autant plus efficacement que ces prédictors sont peu corrélés (la décomposition formelle de cette réduction est reportée en annexe).

Le second mécanisme vise précisément à décorréliser les arbres : à chaque nœud, l'algorithme ne considère qu'un sous-ensemble aléatoire de $m \leq p$ variables candidates (typiquement $m = \sqrt{p}$ en classification), renouvelé à chaque division. Cette restriction empêche les quelques variables les plus prédictives de structurer tous les arbres de façon identique, ce qui diversifie l'ensemble et amplifie la réduction de variance. Le score final est la moyenne des B arbres T_b :

$$\hat{p}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_{T_b}(x) \quad (3.10)$$

avec $\hat{p}_{T_b}(x)$ la prédiction de l'arbre numéro b pour un individu x .

Le tirage bootstrap offre en outre un mécanisme d'évaluation interne quasiment gratuit : chaque observation étant en moyenne absente d'environ 37 % des échantillons, elle peut être prédite par les seuls arbres qui ne l'ont pas vue, fournissant une estimation peu biaisée de l'erreur de généralisation (erreur out-of-bag). Cet avantage est précieux en détection de fraude, où les cas étiquetés sont rares et où l'on souhaite préserver un maximum d'observations pour l'apprentissage. Bien que moins transparente que la régression logistique, la forêt n'est pas une pure boîte noire : elle fournit des mesures d'importance des variables (décroissance moyenne d'impureté, importance par permutation) qui restituent une part d'interprétabilité utile à la gouvernance du dispositif.

Les propriétés de la forêt aléatoire en font un candidat particulièrement adapté à notre problème : elle capture automatiquement non-linéarités et interactions, tolère des variables hétérogènes, corrélées ou aberrantes, ne requiert qu'un prétraitement limité, et gère le déséquilibre des classes via une pondération ou un rééquilibrage des tirages (balanced random forest). Elle se règle au moyen de quelques hyperparamètres principaux, notamment le nombre d'arbres, le nombre de variables candidates par nœud et la complexité des arbres, et échange une part de l'interprétabilité paramétrique du GLM contre un gain substantiel de pouvoir prédictif.

3.3 Le gradient boosting

Le gradient boosting est, comme la forêt aléatoire, une méthode ensembliste fondée sur des arbres, mais il en diffère radicalement par sa logique de construction. Là où le bagging assemble des arbres en parallèle pour réduire la variance, le boosting les construit séquentiellement, chaque nouvel arbre s'attachant à corriger les erreurs résiduelles de l'ensemble déjà constitué ; il vise donc avant tout à réduire le biais. Le modèle final est une somme pondérée de M arbres h_m :

$$F_M(x) = \sum_{m=1}^M \nu h_m(x) \quad (3.11)$$

Cette somme se construit de façon récursive : partant d'un modèle initial constant, on enrichit à chaque étape le modèle courant d'un nouvel arbre pondéré par le taux d'apprentissage $\nu \in (0, 1]$:

$$F_m(x) = F_{m-1}(x) + \nu h_m(x) \quad (3.12)$$

La clé de la méthode est l'interprétation de cette correction comme une descente de gradient dans l'espace des fonctions. À chaque étape, on calcule les pseudo-résidus r_{im} , définis comme l'opposé du gradient de la fonction de perte L évalué aux prédictions courantes, puis on ajuste un arbre pour les approcher :

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}} \quad (3.13)$$

Le taux d'apprentissage ν joue un rôle de régularisation essentiel : une valeur faible ralentit l'apprentissage et améliore la généralisation, au prix d'un plus grand nombre d'arbres. On combine fréquemment ce « shrinkage » avec un sous-échantillonnage aléatoire des observations et des variables à chaque étape (stochastic gradient boosting), ce qui réduit encore le surapprentissage. Les implémentations modernes ajoutent par ailleurs à la fonction de perte un terme de régularisation Ω pénalisant explicitement la complexité des arbres (nombre de feuilles, norme des poids), de sorte que l'objectif minimisé s'écrit :

$$L(F) = \sum_{i=1}^n L(y_i, F(x_i)) + \sum_{m=1}^M \Omega(h_m) \quad (3.14)$$

Les bibliothèques de référence (XGBoost, LightGBM, CatBoost ⁴) mettent en œuvre ces principes avec des optimisations algorithmiques (construction par histogrammes, croissance des arbres par feuille, traitement natif des variables catégorielles) qui les rendent rapides et très performantes.

Le gradient boosting atteint généralement le meilleur pouvoir prédictif parmi les modèles considérés sur des données tabulaires telles que celles de la détection de fraude. En contrepartie, il est plus sensible au réglage des hyperparamètres et au surapprentissage : le nombre d'arbres doit être contrôlé par un arrêt précoce sur un jeu de validation, et son interprétabilité est moindre que celle de la forêt, ce qui conduit

4. XGBoost, LightGBM et CatBoost sont des bibliothèques open source d'implémentation du gradient boosting, principalement utilisées en Python.

à s'appuyer sur des outils d'explication post-hoc (importance des variables, valeurs de Shapley⁵) pour en restituer la logique.

3.4 Les modèles de scoring à points

Hérités de la pratique du credit scoring, les modèles de scoring à points (ou scorecards) ne constituent pas tant une nouvelle famille d'algorithmes qu'une méthode de mise en forme d'un modèle statistique (le plus souvent une régression logistique) en une grille de points additive, lisible et directement exploitable par un gestionnaire, sans recours à un outil informatique. Leur intérêt est avant tout opérationnel et réglementaire : dans un contexte assurantiel soumis à un devoir d'explication, pouvoir justifier un score par la simple addition de points attachés aux caractéristiques d'un dossier constitue un atout majeur.

La construction débute par une discrétisation de chaque variable en classes, définies de manière à être suffisamment peuplées et, idéalement, à présenter un risque monotone. Cette étape capture les non-linéarités propres à chaque variable et réduit la sensibilité aux valeurs extrêmes. Chaque classe se voit ensuite attribuer un poids de la preuve (Weight of Evidence, WOE), qui mesure son pouvoir discriminant en comparant la répartition des dossiers licites et frauduleux :

$$WOE_i = \ln \left(\frac{\% \text{ non-fraude}_i}{\% \text{ fraude}_i} \right) \quad (3.15)$$

Le pouvoir prédictif global d'une variable peut alors être quantifié par sa valeur informative (Information Value, IV), qui agrège les WOE de ses classes pondérés par l'écart de répartition, et sert à sélectionner et hiérarchiser les variables :

$$IV = \sum_i (\% \text{ non-fraude}_i - \% \text{ fraude}_i) \times WOE_i \quad (3.16)$$

Une régression logistique est ensuite ajustée sur les variables transformées en WOE. Ses coefficients sont enfin convertis en points entiers au moyen d'une transformation affine, calée par deux paramètres : le facteur et l'offset, déterminés à partir d'un score de référence, d'une cote de référence et du nombre de points doublant la cote (PDO, Points to Double the Odds) :

$$\text{facteur} = \frac{PDO}{\ln 2}, \quad \text{offset} = \text{Score}_0 - \text{facteur} \times \ln(\text{Odds}_0) \quad (3.17)$$

Les points attribués à une classe de la variable j combinent le coefficient estimé, le WOE de la classe, l'ordonnée à l'origine α répartie sur les p variables, et les paramètres de calage :

$$\text{Points}_j = \left(\beta_j \times WOE_j + \frac{\alpha}{p} \right) \times \text{facteur} + \frac{\text{offset}}{p} \quad (3.18)$$

5. La valeur de Shapley de la variable j pour un individu x mesure sa contribution marginale moyenne à la prédiction en moyennant sur toutes les coalitions possibles de variables.

Le score d'un dossier est alors la simple somme des points de chacune de ses caractéristiques :

$$\text{Score} = \sum_{j=1}^p \text{Points}_j \quad (3.19)$$

Ce dispositif présente une transparence et une auditableté maximales : chaque point du score est traçable jusqu'à une caractéristique précise du dossier, ce qui satisfait directement les exigences d'explicabilité et facilite le suivi de la stabilité du modèle dans le temps (via des indicateurs de dérive des populations).

En contrepartie, la discrétisation et la dépendance à une structure logistique entraînent une perte de finesse prédictive par rapport au gradient boosting, et la définition des classes demande un travail manuel non négligeable. Le scoring à points occupe ainsi une position singulière dans notre panorama : il referme la boucle ouverte par la régression logistique en réconciliant la performance statistique avec une lisibilité opérationnelle.

On peut d'ailleurs envisager une articulation des deux logiques : un modèle puissant de type gradient boosting pour la détection, doublé d'une grille de points pour l'explication et la communication des décisions aux gestionnaires et aux assurés.

3.5 Apprentissage non supervisé : détection d'anomalies et comportements atypiques

Si l'apprentissage supervisé excelle dans l'identification de schémas de fraude historiquement connus, il présente une limite structurelle majeure : il est vulnérable aux techniques de fraude émergentes (zero-day frauds). En effet, un algorithme supervisé ne peut prédire que ce qu'il a déjà vu.

Pour pallier cette faille, les assureurs déploient en complément des algorithmes d'apprentissage non supervisé (Unsupervised Learning). Dans ce paradigme, la variable cible Y (le label « fraude » ou « non-fraude ») est ignorée ou indisponible. L'algorithme explore uniquement l'espace des variables explicatives X pour identifier des structures sous-jacentes ou des déviations statistiques. La fraude est alors assimilée à une anomalie, c'est-à-dire une observation qui dévie si significativement des autres qu'elle éveille le soupçon d'avoir été générée par un mécanisme différent.

Deux grandes familles de méthodes se distinguent pour ce type d'analyse : les algorithmes d'isolation et le partitionnement des données.

3.5.1 Les algorithmes d'isolation (exemple : Isolation Forest)

Contrairement aux approches statistiques classiques qui cherchent d'abord à modéliser le comportement « normal » pour ensuite en déduire les anomalies, l'Isolation Forest cherche directement à isoler les anomalies. Ce modèle repose sur un postulat simple : les anomalies sont des données « peu nombreuses

et différentes » (few and different).

L'algorithme construit une forêt d'arbres (les Isolation Trees). Pour chaque arbre, il sélectionne aléatoirement une variable et un seuil de coupure aléatoire (compris entre le minimum et le maximum de cette variable) pour partitionner l'espace récursivement.

Mathématiquement, la métrique clé est la longueur du chemin $h(x)$, c'est-à-dire le nombre d'arêtes qu'une observation x doit parcourir depuis la racine de l'arbre jusqu'à atteindre une feuille terminale où elle est isolée. Parce qu'elles sont situées dans des zones clairsemées de l'espace vectoriel, les anomalies nécessitent beaucoup moins de coupures pour être isolées que les observations normales.

Le score d'anomalie $s(x, n)$ pour un jeu de n données est défini par :

$$s(x, n) = 2^{-\frac{\mathbb{E}(h(x))}{c(n)}} \quad (3.20)$$

où $\mathbb{E}(h(x))$ est l'espérance de la longueur du chemin sur l'ensemble des arbres, et $c(n)$ est une constante de normalisation représentant la longueur moyenne non réussie d'une recherche dans un arbre binaire.

Si $s(x, n)$ tend vers 1, le sinistre est fortement suspect et justifie une levée de doute par un expert. Si le score tend vers 0,5, le sinistre est considéré comme non frauduleux.

3.5.2 Le partitionnement de données (Clustering)

Les algorithmes de Clustering (tels que les K-Means) visent à regrouper les sinistres en sous-ensembles (les clusters) de telle sorte que les dossiers d'un même groupe soient les plus similaires possibles, tout en étant distincts des autres groupes.

Dans le cas de l'algorithme K-Means, l'objectif est de minimiser la variance intra-classe (la distance au carré entre chaque sinistre x_i et le centre de gravité μ_j de son cluster de rattachement) :

$$\arg \min_S \sum_{j=1}^k \sum_{x_i \in S_j} \|x_i - \mu_j\|^2 \quad (3.21)$$

Appliqué à la lutte anti-fraude, le clustering permet d'identifier des sinistres qui ne s'intègrent dans aucun des clusters principaux (les dossiers de masse), ou qui forment de très petits groupes (micro-clusters) très éloignés des autres. Ces poches de données marginales signalent souvent des comportements atypiques, comme des réseaux organisés déclarant des sinistres aux caractéristiques étrangement similaires.

3.6 Analyse de réseaux (Graph Mining) pour la détection de la fraude organisée

Contrairement à la fraude opportuniste (un assuré isolé qui majore ponctuellement un devis), la fraude en bande organisée implique une complicité entre plusieurs acteurs coordonnés dans le but de soutirer des capitaux importants à la compagnie d'assurance de manière répétée.

Ce type de criminalité financière s'appuie sur des réseaux structurés incluant de faux assurés, des prête-noms, et bien souvent des professionnels complices (garagistes, sociétés de dépannage, professionnels de santé ou experts automobiles marrons). Leurs modes opératoires sont quasi industriels : accidents de la circulation mis en scène, carambolages fictifs en chaîne, ou recyclage de véhicules gravement endommagés.

La dangerosité extrême de ces réseaux réside dans leur capacité à « lisser » le risque : pris isolément, chaque sinistre déclaré par le réseau est conçu pour paraître parfaitement vraisemblable et passer sous les radars des règles de gestion classiques. Les algorithmes de Machine Learning vus précédemment montrent ici leurs limites, car ils analysent chaque dossier de manière individuelle. C'est précisément pour contourner ce camouflage qu'il devient impératif de ne plus regarder les sinistres, mais les liens cachés qui les unissent, grâce à la théorie des graphes (Graph Mining).

3.6.1 Modélisation mathématique du réseau de fraude

Dans cette approche, le portefeuille de sinistres n'est plus vu comme un simple tableau (lignes/colonnes), mais est modélisé sous la forme d'un graphe mathématique $G = (V, E)$.

- **Les Nœuds (Vertices — V)** : ils représentent les entités du système. Il peut s'agir d'un dossier de sinistre, d'un assuré, d'un numéro de téléphone, d'une adresse IP ou d'un professionnel de l'automobile.
- **Les arêtes (Edges — E)** : elles matérialisent une relation entre deux nœuds. Une arête est créée si deux sinistres partagent un attribut commun (ex : même garagiste, même compte bancaire pour l'indemnisation) ou s'ils présentent une similarité vectorielle anormalement élevée (ce qui trahit souvent la réutilisation d'un même scénario de fraude).

On peut mesurer la similarité entre deux dossiers A et B dans l'espace des variables via la similarité cosinus :

$$\text{sim}(A, B) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^p A_i B_i}{\sqrt{\sum_{i=1}^p A_i^2} \sqrt{\sum_{i=1}^p B_i^2}} \quad (3.22)$$

Si cette similarité dépasse un seuil critique défini par l'actuaire, une arête est tracée entre les deux dossiers.

3.6.2 Détection de communautés et de clusters suspects

Une fois le graphe construit, l'objectif n'est plus d'évaluer la probabilité de fraude d'un nœud individuel, mais d'identifier des sous-graphes anormalement denses. En théorie des graphes, on appelle cela la détection de communautés ou de composantes connexes.

Des algorithmes comme la méthode de Louvain ou la propagation de labels (Label Propagation) sont utilisés pour partitionner le graphe. Ils cherchent à maximiser la modularité Q , c'est-à-dire la densité des liens à l'intérieur d'un cluster par rapport à la densité des liens à l'extérieur :

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j) \quad (3.23)$$

où A_{ij} est la matrice d'adjacence, k_i est le degré du nœud i , m le nombre total d'arêtes, et $\delta(c_i, c_j)$ indique si les nœuds appartiennent à la même communauté c .

3.6.3 Application opérationnelle

Sur le plan opérationnel, lorsqu'un algorithme de Graph Mining isole un cluster suspect, il fournit une alerte d'une valeur ajoutée qualitativement différente de celle produite par les modèles de scoring individuels classiques. L'investigation ne porte plus sur un sinistre isolé de 2 000 €, mais sur un réseau organisé dont le préjudice global potentiel se chiffre en plusieurs dizaines, voire centaines de milliers d'euros. Cette bascule d'échelle transforme profondément la logique d'allocation des ressources au sein des cellules anti-fraude.

Concrètement, le cluster fourni par l'algorithme se matérialise sous la forme d'un graphe annoté restituant l'ensemble des entités impliquées (assurés, prestataires, intermédiaires) ainsi que la nature et la fréquence de leurs interactions. L'enquêteur dispose ainsi d'une cartographie complète du réseau présumé, lui permettant d'identifier le nœud central (souvent le coordinateur du schéma frauduleux) et de hiérarchiser ses investigations en remontant des ramifications périphériques vers le cœur du dispositif. Cette approche contraste avec l'instruction traditionnelle dossier par dossier, où les connexions entre sinistres restent invisibles faute d'une vision transversale.

Du point de vue du pilotage, le démantèlement d'un tel réseau offre un retour sur investissement massif pour la compagnie d'assurance. Là où l'instruction d'un dossier individuel mobilise plusieurs heures d'analyse pour un enjeu financier limité, une seule investigation réseau peut aboutir à la neutralisation simultanée de plusieurs dizaines de dossiers frauduleux, à des résiliations en cascade et, le cas échéant, à des dépôts de plainte groupés susceptibles d'aboutir à des condamnations pénales. Ces dernières constituent un signal dissuasif fort, dont l'effet préventif sur les comportements frauduleux dépasse largement le périmètre du réseau démantelé.

Enfin, les sorties du Graph Mining s'intègrent naturellement aux processus de reporting réglementaire. Les clusters détectés, documentés et tracés, alimentent les déclarations de soupçon transmises à Tracfin ⁶

6. Tracfin (Traitement du renseignement et action contre les circuits financiers clandestins) est une cellule de renseignement financier placée sous la tutelle du ministère de l'Économie et des Finances. Créée en 1990, elle est chargée de recueillir,

et renforcent la robustesse du dispositif LCB-FT⁷ de la compagnie, démontrant aux autorités de contrôle, notamment à l'ACPR, que la lutte contre la fraude organisée repose sur des méthodes quantitatives structurées et auditable.

3.7 Critères de qualité des modèles mis en place

La première mesure naturelle de la qualité d'un modèle de détection de fraude est le taux de bien classés (ou accuracy), défini comme la proportion d'individus correctement classés parmi l'ensemble de la population soumise au modèle. Il se calcule directement à partir de la matrice de confusion, qui croise les prédictions du modèle avec les statuts réels observés selon quatre configurations possibles.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.24)$$

Un dossier est dit :

- vrai positif (TP) lorsque le modèle prédit une fraude et que le dossier est effectivement frauduleux ;
- vrai négatif (TN) lorsque le modèle prédit un dossier sain et que celui-ci l'est bien ;
- faux positif (FP) lorsqu'un dossier sain est incorrectement signalé comme frauduleux (génération d'un coût opérationnel inutile et une dégradation de l'expérience client) ;
- faux négatif (FN) lorsqu'un dossier frauduleux n'est pas détecté, constituant la perte financière directe pour la compagnie.

analyser et transmettre aux autorités judiciaires les déclarations de soupçon émises par les professionnels assujettis (dont les organismes d'assurance).

7. La LCB-FT (Lutte contre le blanchiment de capitaux et le financement du terrorisme) désigne l'ensemble du dispositif réglementaire et opérationnel imposé aux acteurs du secteur financier et assurantiel pour prévenir, détecter et signaler ces infractions. En France, ce dispositif est principalement encadré par le Code monétaire et financier (articles L. 561-1 et suivants), transposant les directives européennes.

		Statut réel	
		Fraude réelle	Non-fraude réelle
Prédiction du modèle	Fraude prédite	Vrai Positif (TP) Fraude détectée ✓	Faux Positif (FP) Fausse alerte ✗
	Non-fraude prédite	Faux Négatif (FN) Fraude non détectée ✗	Vrai Négatif (TN) Sain classé sain ✓

FIGURE 3.1 – Matrice de confusion

Toutefois, si le taux de bien classés présente l'avantage d'une lecture immédiate, il s'avère trompeur dans le contexte de la détection de fraude, où les classes sont structurellement déséquilibrées : la fraude ne représente généralement que 1 à 3 % des dossiers.

Un modèle naïf prédisant systématiquement « non-fraude » atteindrait mécaniquement un taux de bien classés supérieur à 97 %, sans détecter la moindre fraude.

Cette limite justifie le recours à des critères complémentaires mieux adaptés aux distributions asymétriques, notamment des indicateurs capables de mesurer la capacité du modèle à ordonner les dossiers par risque (indépendamment de tout seuil), et d'autres la qualité d'une décision prise à un seuil déterminé.

Ainsi, on distingue les indicateurs suivants, présentés dans le tableau ci-dessous :

Indicateur	Description
Coefficient de Gini et courbe ROC ⁸	Mesure le pouvoir discriminant global du score, c'est-à-dire son aptitude à classer les sinistres frauduleux devant les sinistres licites, sur l'ensemble de la plage de seuils, en s'appuyant sur la courbe ROC (Receiver Operating Characteristic). Le coefficient de Gini est relié à l'AUC par la relation $Gini = 2 \times AUC - 1$ et varie de 0 (discrimination nulle) à 1 (discrimination parfaite).
Statistique de Kolmogorov-Smirnov (KS) ⁹	Mesure l'écart maximal entre les fonctions de répartition cumulées des scores des deux populations (frauduleux et licites). De façon équivalente, elle correspond au plus grand écart entre le taux de vrais positifs et le taux de faux positifs le long de la courbe ROC : $KS = \max_s (TVP(s) - TFP(s))$. Comprise entre 0 et 1, elle indique en outre le seuil de score où la séparation entre les deux classes est la plus nette.
Aire sous la courbe précision-rappel (PR-AUC)	Particulièrement adaptée aux classes déséquilibrées, car elle se concentre sur la classe d'intérêt (la fraude) sans être flattée par l'abondance des vrais négatifs, contrairement à l'AUC-ROC qui peut donner une image trop optimiste. Son interprétation est relative : la valeur de référence (modèle aléatoire) n'est pas 0,5 mais la prévalence de la fraude π , de sorte qu'une PR-AUC doit toujours être appréciée au regard de ce taux de base.
F1-score ¹⁰	Évalue une décision à un seuil fixé. Il s'agit de la moyenne harmonique de la précision $P = \frac{VP}{VP + FP}$ et du rappel $R = \frac{VP}{VP + FN}$, soit $F_1 = \frac{2PR}{P + R}$. Il offre un compromis entre les faux positifs (investigations menées à tort) et les faux négatifs (fraudes manquées).
Lift au décile supérieur (lift@10 %)	Indicateur opérationnel directement aligné sur la logique de priorisation de l'outil. Après avoir classé tous les dossiers par score décroissant, il rapporte le taux de fraude observé dans les 10 % les plus suspects au taux de fraude global : $lift@10\% = \frac{\text{taux de fraude dans le décile supérieur}}{\text{taux de fraude global}}$. Un lift de 5 signifie que le décile ciblé concentre cinq fois plus de fraudes qu'une sélection aléatoire.

TABLE 3.1 – Principaux critères d'évaluation d'un modèle de détection de fraude

De plus, on s'intéressera également à l'indice de stabilité des populations (PSI, Population Stability Index). Ce dernier ne mesure pas le pouvoir prédictif du modèle mais la stabilité de la population dans le temps. Il quantifie l'écart entre la distribution des scores observée sur une population de référence (typiquement l'échantillon d'apprentissage) et celle observée sur une population récente, afin de détecter une dérive susceptible de dégrader la pertinence du modèle. Après avoir réparti les scores en classes (souvent les déciles de la population de référence), il se calcule comme la somme sur les classes des écarts de proportions pondérés par le logarithme de leur rapport :

$$PSI = \sum_i (a_i - r_i) \ln \left(\frac{a_i}{r_i} \right), \quad (3.25)$$

où r_i et a_i désignent respectivement la proportion d'observations de la classe i dans la population de

référence et dans la population actuelle. Par convention, un PSI inférieur à 0,1 traduit une population stable, une valeur comprise entre 0,1 et 0,25 signale une dérive modérée appelant une surveillance, et une valeur supérieure à 0,25 indique une dérive importante justifiant une investigation, voire un réentraînement du modèle. Le PSI peut s'appliquer à la distribution du score global comme à celle de chaque variable explicative, ce qui permet d'identifier l'origine d'une dérive. Il constitue ainsi un outil clé du suivi opérationnel de l'agent une fois déployé.

En synthèse, l'évaluation d'un modèle actuariel de détection de fraude articule six dimensions complémentaires : le pouvoir discriminant (Gini, KS, PR-AUC), la qualité d'une décision seuillée (F1, matrice de confusion), la valeur économique (coût espéré, ROI, lift financier), la calibration probabiliste (Brier, ECE), la stabilité temporelle (PSI) et l'équité entre segments. Aucun de ces indicateurs pris isolément n'épuise le jugement à porter sur l'agent ; c'est leur lecture conjointe, adossée à une matrice de coûts explicite et à un cadre de gouvernance clair, qui fonde la légitimité actuarielle du dispositif.

ANCRAGE RÉGLEMENTAIRE

Le dispositif d'évaluation retenu s'inscrit dans les attentes de la recommandation ACPR 2020-R-01 sur la gouvernance des algorithmes en assurance, laquelle exige l'existence d'un cadre de suivi de performance, de stabilité et d'explicabilité tout au long du cycle de vie du modèle. Le règlement européen sur l'intelligence artificielle classe par ailleurs les dispositifs de détection de fraude en assurance vie et santé comme systèmes à haut risque, imposant une documentation technique détaillée, une surveillance humaine et une évaluation continue, exigences que la batterie d'indicateurs présentée ci-dessus contribue à satisfaire (cf. §4.1 pour plus de détails).

Chapitre 4

Mise en place d'un processus de détection de fraude automobile automatisé à l'aide d'un Agent IA

4.1 Gouvernance autour de la mise en place de l'Agent IA

Avant même d'aborder la conception technique de l'outil, la mise en place d'un agent de détection de fraude doit être encadrée par une gouvernance explicite. Un tel dispositif traite en effet des données personnelles d'assurés, alimente des décisions susceptibles d'affecter individuellement ces derniers (orientation d'un dossier vers une enquête, suspicion portée sur une déclaration), et s'inscrit dans un secteur étroitement supervisé.

La gouvernance n'est donc pas un complément formel postérieur au modèle, mais un préalable structurant qui en définit le cahier des charges. On peut l'articuler autour de trois niveaux complémentaires :

- un cadre réglementaire et de conformité,
- une organisation interne et une répartition des responsabilités,
- et enfin une maîtrise opérationnelle du cycle de vie du modèle assortie d'une supervision humaine.

Sur le plan réglementaire, le dispositif s'inscrit d'abord dans le cadre du Règlement général sur la protection des données (RGPD).

Les principes de finalité, de minimisation et de légalité du traitement encadrent la collecte et l'usage des données du sinistre et de l'assuré, tandis que l'article 22¹, relatif aux décisions individuelles fondées exclusivement sur un traitement automatisé, impose une vigilance particulière : un assuré ne saurait voir sa déclaration rejetée sur la seule base d'un score algorithmique, sans intervention humaine ni possibilité de contestation.

À ce socle s'ajoute désormais le règlement européen sur l'intelligence artificielle (« AI Act »). Le règlement (UE) 2024/1689 est entré en vigueur le 1^{er} août 2024 selon une application échelonnée, les pratiques interdites étant effectives depuis le 2 février 2025. Son annexe III classe parmi les systèmes à haut risque ceux relevant de l'accès aux services essentiels, dont l'assurance. À la suite de l'accord politique dit « Digital Omnibus » du printemps 2026, l'application des obligations relatives aux systèmes à haut risque de l'annexe III a toutefois été reportée au 2 décembre 2027.

La qualification précise d'un agent de détection de fraude automobile reste à apprécier au cas par cas : la catégorie à haut risque vise surtout l'évaluation du risque et la tarification, de sorte qu'un outil qui se borne à signaler des dossiers à des enquêteurs humains se situe vraisemblablement à un niveau de risque inférieur.

La prudence conduit néanmoins à anticiper les exigences applicables aux systèmes sensibles : un système de gestion des risques documenté, une gouvernance des données garantissant leur qualité et l'absence de biais discriminatoires, une documentation technique complète, la journalisation des activités assurant la

1. « La personne concernée a le droit de ne pas faire l'objet d'une décision fondée exclusivement sur un traitement automatisé, y compris le profilage, produisant des effets juridiques la concernant ou l'affectant de manière significative de façon similaire. » (§1, <https://gdpr-text.com/fr/read/article-22/>).

traçabilité, des obligations de transparence, une supervision humaine et un niveau adéquat de précision, de robustesse et de cybersécurité.

Pour certains déployeurs de services essentiels privés, une analyse d'impact sur les droits fondamentaux (FRIA², Fundamental Rights Impact Assessment) peut par ailleurs être requise, distincte de l'analyse d'impact relative à la protection des données. Enfin, l'agent évolue dans l'environnement particulier de la lutte contre la fraude à l'assurance, qui mobilise des dispositifs sectoriels propres (échanges de place, conventions professionnelles) et impose le respect du secret et des droits de la personne concernée.

Au-delà du cadre légal, la gouvernance doit intégrer les attentes du superviseur national.

Dès juin 2020, l'ACPR a publié un document de réflexion sur la gouvernance des algorithmes d'intelligence artificielle dans le secteur financier, fruit de travaux exploratoires menés depuis 2018 avec des acteurs du secteur, et portant notamment sur l'explicabilité et la gouvernance du machine learning³.

Ces travaux ont dégagé quatre critères interdépendants d'évaluation des algorithmes : la gestion appropriée des données, la performance, la stabilité et l'explicabilité. Un arbitrage est nécessaire entre ces quatre critères, ainsi qu'un principe de validation continue. L'explicabilité y est érigée en pilier et déclinée selon plusieurs niveaux, selon que l'on s'adresse à la clientèle, à des experts métier ou à des auditeurs.

Ces orientations fixent un horizon clair : l'agent devra être non seulement performant, mais aussi auditable et explicable à différents publics, ce qui justifie a posteriori l'attention portée à l'interprétabilité des modèles dans la partie théorique.

Ce cadre externe se traduit en interne par une organisation et une répartition des rôles formalisées. La conduite du projet gagne à être pilotée par une instance de gouvernance réunissant les parties prenantes : les équipes métier de la gestion des sinistres et de la lutte anti-fraude, qui portent le besoin et la connaissance du terrain ; les data scientistes et actuaires, responsables de la conception et de la validation statistique ; la fonction conformité et juridique ainsi que le délégué à la protection des données, garants du respect du cadre réglementaire ; et le contrôle interne ou l'audit, chargés d'une revue indépendante.

Cette organisation s'inscrit naturellement dans une politique de gestion du risque de modèle, qui définit les responsabilités, les exigences de documentation et les seuils de validation tout au long de la vie de l'agent.

La maîtrise opérationnelle porte enfin sur l'ensemble du cycle de vie du modèle : chaque étape (cadrage des données, entraînement, validation indépendante, recette, déploiement puis surveillance) doit être documentée et tracée, de manière à pouvoir reconstituer a posteriori les choix effectués. Une attention spécifique est accordée à la détection et à la remédiation des biais, afin que le modèle ne reproduise pas de discriminations, directes ou indirectes via des variables corrélées à des caractéristiques protégées.

Mais surtout, le principe de supervision humaine structure l'ensemble du dispositif : l'agent produit un score ou une alerte, mais ne prononce aucune décision défavorable de façon automatique ; l'investigation et la décision finale demeurent du ressort d'un gestionnaire ou d'un enquêteur.

Ce maintien d'un « humain dans la boucle » répond à l'exigence de l'article 22 du RGPD, préserve les

2. Évaluation structurée, réalisée avant le déploiement, imposée par l'article 27 de l'AI Act à certains déployeurs de systèmes d'IA à haut risque.

3. https://acpr.banque-france.fr/system/files/2025-02/20200612_gouvernance_evaluation_ia.pdf

droits de l'assuré et circonscrit le risque réglementaire, tout en organisant une boucle de rétroaction : les retours des enquêteurs alimentant le suivi de la performance, la détection de la dérive du modèle dans le temps et son réentraînement encadré.

Posée en amont, cette gouvernance conditionne la confiance, la conformité et la pérennité du dispositif. Elle constitue le cadre dans lequel s'inscrit la conception de l'outil, présentée dans les sections suivantes.




FIGURE 4.1 – Les trois niveaux de gouvernance encadrant la mise en place de l'agent IA de détection de fraude

4.2 Présentation de la base de données

4.2.1 Base de données source

L'illustration de la mise en place du processus de détection de fraude automobile réalisée dans ce mémoire se fera à l'aide d'une base de données récupérée en open source sous : <https://www.kaggle.com/datasets/ahluwaliasaksham/car-insurance-fraud-detection-dataset>

Cette base de données concerne des sinistres automobiles, et contient le flag « frauduleux » sur lequel repose notre modélisation.

Elle contient 30 000 sinistres, dont 11,5 % sont des sinistres frauduleux. Ce pourcentage est sensiblement supérieur aux estimations communément admises en France, qui situent la fraude réelle autour de 5 % des sinistres automobile. Cet écart s'explique vraisemblablement par le mode de constitution de la base : les dossiers qui la composent ont en grande partie fait l'objet d'une instruction approfondie ou d'une suspicion préalable, ce qui tend mécaniquement à sur-représenter les cas frauduleux par rapport à un portefeuille

de sinistres bruts. Conscient de ce biais, nous avons néanmoins choisi de travailler sur cette base, dans la mesure où elle offre un volume suffisant de cas labellisés pour entraîner et évaluer les modèles de détection. Les résultats obtenus devront donc être interprétés avec cette réserve méthodologique à l'esprit, et toute généralisation à l'ensemble du portefeuille automobile français nécessiterait une recalibration du modèle sur des données plus représentatives de la sinistralité réelle.

Usuellement dans les mémoires, une présentation de la base de données est réalisée en amont de la mise en place d'un modèle sur les données. On se propose ici de revisiter cette présentation, qui sera introduite dans les résultats de l'agent IA afin de mettre en avant le fait que ces travaux ont été automatisés via l'agent et non réalisés manuellement ou via un Code R, Python ou encore SAS, comme c'est le cas usuellement.

Néanmoins, les variables présentes dans la base de données sinistre sont listées ci-dessous :

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
policy_id	Identifiant contrat	Identifiant	Texte	Identifiant unique du contrat d'assurance	POL100000 ... POL129999
policy_state	État de souscription	Contrat	Catégoriel	État américain de souscription du contrat	GA, PA, MI, CA, OH, NC, SC, WA, TX, NY...
policy_deductible	Franchise	Contrat	Numérique	Montant de la franchise (USD)	300 / 400 / 600 / 1000
policy_annual_premium	Prime annuelle	Contrat	Numérique	Prime annuelle payée par l'assuré (USD)	Float > 0
insured_age	Âge de l'assuré	Assuré	Entier	Âge de l'assuré en années	18 – 75
insured_sex	Sexe de l'assuré	Assuré	Catégoriel	Sexe déclaré de l'assuré	MALE, FEMALE, OTHER
insured_education_level	Niveau d'études	Assuré	Catégoriel	Niveau d'études de l'assuré	High School, College, Master, PhD, JD, MD
insured_occupation	Profession	Assuré	Catégoriel	Profession de l'assuré	Manager, Lawyer, Doctor, Teacher, Sales, Clerk, Technician, Engineer
insured_hobbies	Loisirs	Assuré	Catégoriel	Loisirs déclarés de l'assuré	reading, chess, yachting, golf, hiking...
incident_date	Date du sinistre	Sinistre	Date	Date du sinistre déclaré	YYYY-MM-DD
incident_type	Type de sinistre	Sinistre	Catégoriel	Nature du sinistre	Parked Car, Vehicle Theft, Single Vehicle Collision, Multi-vehicle Collision
collision_type	Zone d'impact	Sinistre	Catégoriel	Zone d'impact lors de la collision	Front, Rear, Side, Unknown

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
incident_severity	Gravité du sinistre	Sinistre	Catégoriel	Gravité des dégâts matériels	Minor Damage, Major Damage, Total Loss
authorities_contacted	Autorités contactées	Sinistre	Catégoriel	Autorités contactées suite au sinistre	Police, Fire, Ambulance, None (NaN)
incident_state	État du sinistre	Sinistre	Catégoriel	État américain où le sinistre a eu lieu	GA, PA, MI, CA, OH, NC...
incident_city	Ville du sinistre	Sinistre	Texte	Ville où le sinistre a eu lieu	Texte libre
incident_hour_of_the_day	Heure du sinistre	Sinistre	Entier	Heure du sinistre (format 24h)	0 – 23
number_of_vehicles_involved	Nb de véhicules impliqués	Sinistre	Entier	Nombre de véhicules impliqués dans le sinistre	1 – 4
bodily_injuries	Nb blessés déclarés	Sinistre	Entier	Nombre de blessés corporels déclarés	0 – 4
witnesses	Nb témoins	Sinistre	Entier	Nombre de témoins déclarés	0 – 5
police_report_available	Rapport police disponible	Sinistre	Booléen	Rapport de police disponible	Yes, No
claim_amount	Montant réclamé	Réclamation	Numérique	Montant réclamé par l'assuré pour ce sinistre (USD)	Float > 0
total_claim_amount	Indemnisation totale	Réclamation	Numérique	Montant total de l'indemnisation versée (USD)	Float > 0
fraud_reported	Fraude confirmée (cible)	Cible ML	Catégoriel	Variable cible : fraude confirmée ou non. Variable à prédire par le modèle. 11,5 % de Y dans la base.	Y (fraude) / N (légitime)

TABLE 4.1: Variables de la base de données source

Au total 24 variables, avec la variable « fraud_reported » correspondant au flag dossier frauduleux ou non et « total_claim_amount » le montant du sinistre.

4.2.2 Enrichissement de la base de données

Afin de rendre ce mémoire proche de la réalité des assureurs, le choix d'enrichir la base de données disponible a été réalisé.

En effet, certaines informations incluses dans la base telles que le niveau d'éducation (insured_education_level) ou encore les passions de l'assuré (insured_hobbies) ne font pas partie des questionnaires usuels de sous-

cription en assurance automobile sur le marché français.

De plus, l'assureur, lors de la déclaration d'un sinistre, a accès à bien plus d'informations que celles reportées dans cette base : ces dernières ont été recréées par simulation à l'aide de Claude⁴ avec pour consigne d'être explicatives dans notre recherche d'identification de fraude sans pour autant être en lien direct avec la variable à expliquer (fraud_reported).

Ainsi, la base a été enrichie avec 6 types de données, toutes les données pouvant être rendues disponibles en pratique chez un assureur lors de la survenance d'un sinistre automobile :

1. L'historique de l'assuré, notamment ses sinistres passés, l'historique du contrat etc. ;
2. Des informations sur le réseau de garagistes et les prestataires impliqués dans la réparation du sinistre ;
3. Des informations sur le tiers et les témoins, de manière à identifier d'éventuels témoins récurrents ou des liens entre le tiers et l'assuré/les témoins ;
4. Des informations sur le véhicule, notamment son âge et sa valeur ;
5. Des informations sur le comportement déclaratif, notamment le délai entre la date de sinistre et de déclaration, le nombre de fois où l'assuré a modifié sa déclaration, le canal de déclaration etc. ;
6. Des informations géographiques et temporelles, notamment le jour de l'accident (férié/week-end) ou son lieu de survenance.

Au total, trente variables ont été générées et sont décrites ci-dessous :

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
insured_id	Identifiant assuré	Historique assuré	Texte	Identifiant stable de l'assuré, indépendant du numéro de contrat. Permet de relier les dossiers d'un même assuré.	INS000001 ... INS0XXXXXX
insured_nb_past_claims	Nb sinistres passés	Historique assuré	Entier	Nombre total de sinistres déclarés par cet assuré sur les 5 dernières années. Distributions chevauchantes, signal modéré.	0 – 5
insured_nb_past_frauds	Nb fraudes passées confirmées	Historique assuré	Entier	Nombre de fraudes confirmées antérieures pour cet assuré.	0 – 3
insured_days_since_last_claim	Jours depuis dernier sinistre	Historique assuré	Entier	Jours depuis le dernier sinistre de cet assuré.	60 – 2500
insured_claim_amount_history	Montant réclamé cumulé (3 ans)	Historique assuré	Numérique	Montant cumulé (USD) de toutes les réclamations de cet assuré sur 3 ans.	0 – 55 000

4. Assistant conversationnel développé par Anthropic, société américaine spécialisée en intelligence artificielle.

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
policy_age_at_incident	Ancienneté contrat (jours)	Contrat enrichi	Entier	Ancienneté du contrat en jours au moment du sinistre.	30 – 3600
insured_nb_policies	Nombre de contrats actifs	Contrat enrichi	Entier	Nombre de contrats d'assurance actifs simultanément (multi-assurance).	1 – 4
insured_address_changes	Nombre de changements d'adresse (12 mois)	Historique assuré	Entier	Nombre de changements d'adresse dans les 12 derniers mois.	0 – 3
repairer_id	Identifiant réparateur	Réseau garagiste	Texte	Identifiant unique du réparateur mandaté. NONE = pas de réparateur.	GAR0001...GAR0899, NONE
repairer_nb_claims	Nombre de dossiers traités (réparateur)	Réseau garagiste	Entier	Nombre total de dossiers sinistres traités par ce réparateur dans la base.	0 – 200
repairer_nb_fraud	Nombre de fraudes (réparateur)	Réseau garagiste	Entier	Nombre de fois où ce réparateur apparaît dans un dossier clôturé fraude.	0 – ~100
repairer_avg_invoice_ratio	Ratio facture / marché	Réseau garagiste	Numérique	Ratio facture réparateur / prix marché. >1 = surfacturation.	0,85 – 1,55
repairer_is_flagged	Réparateur signalé	Réseau garagiste	Booléen 0/1	Réparateur inscrit en liste de vigilance.	0 = non signalé / 1 = signalé
third_party_id	Identifiant tiers	Réseau tiers	Texte	Identifiant du tiers impliqué. NONE si sinistre sans tiers.	TRS00001...TRS09999, NONE
third_party_nb_past_incidents	Nombre d'incidents passés (tiers)	Réseau tiers	Entier	Nombre de fois où ce tiers est apparu dans des dossiers passés.	0 – 5
witness_id	Identifiant témoin	Réseau tiers	Texte	Identifiant du témoin principal. NONE si pas de témoin.	WIT00001...WIT11999, NONE
insured_third_party_known	Tiers connu de l'assuré	Réseau tiers	Booléen 0/1	Assuré et tiers se connaissent (même adresse, téléphone ou lien familial).	0 = inconnus / 1 = connus
vehicle_id	Identifiant véhicule	Véhicule	Texte	Immatriculation anonymisée.	VEH000001...VEH027999
vehicle_age_years	Âge du véhicule (années)	Véhicule	Entier	Âge du véhicule en années.	1 – 22

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
vehicle_market_value	Valeur marché du véhicule	Véhicule	Numérique	Valeur argus estimée du véhicule (USD). Distributions très chevauchantes.	2 000 – 40 000
vehicle_overvalue_ratio	Ratio surévaluation réclamation	Véhicule	Numérique	claim_amount / vehicle_market_value. >1 = réclamation dépasse la valeur du véhicule.	0,10 – 5,00
vehicle_nb_past_claims	Nb sinistres passés (véhicule)	Véhicule	Entier	Sinistres antérieurs sur ce véhicule, tous propriétaires confondus.	0 – 4
vehicle_ownership_duration_days	Duration possession (jours)	Véhicule	Entier	Jours de possession avant le sinistre.	20 – 3500
time_to_report_days	Délai de déclaration (jours)	Comportement déclaratif	Entier	Délai entre sinistre et déclaration.	0 – 75
nb_amendments_declaration	Nombre modifications déclaration	Comportement déclaratif	Entier	Nombre de modifications de la déclaration initiale.	0 – 4
declaration_channel	Canal de déclaration	Comportement déclaratif	Catégoriel	Canal utilisé pour déclarer le sinistre.	web, telephone, agence, courtier
injury_claimed_with_medical_justificatif	Blessures corporelles déclarées sans justificatif médical.	Comportement déclaratif	Booléen 0/1	Blessures corporelles déclarées sans justificatif médical.	0 = justificatif présent / 1 = absent
incident_zip_fraud_rate	Taux fraude de la zone	Géographique	Numérique	Taux historique de fraude dans l'État du sinistre, calculé sur la base.	0,00 – 0,30
incident_is_weekend	Sinistre en weekend	Temporel	Booléen 0/1	Sinistre un vendredi soir, samedi ou dimanche.	0 = semaine / 1 = weekend
incident_is_holiday	Sinistre jour férié	Temporel	Booléen 0/1	Sinistre un jour férié américain (1er jan, 4 juillet, Thanksgiving, Noël).	0 = jour normal / 1 = jour férié

TABLE 4.2: Variables d'enrichissement de la base de données

La base de données finale rassemble ainsi 24 variables issues de la base source et 30 variables d'enrichissement, soit 54 variables explicatives, auxquelles s'ajoute la variable cible binaire fraud_reported (Y/N). C'est sur cet ensemble que reposera l'apprentissage des modèles de détection.

4.3 Descriptif macro de la création du processus de détection de fraude et de sa déclinaison opérationnelle

Afin de répondre aux enjeux de rentabilité évoqués précédemment, un processus de détection automatisé à l'aide d'un Agent IA a été construit. L'objectif est de fournir aux équipes d'investigation un outil d'aide à la décision opérationnelle « clé en main ».

Cet outil repose sur une logique en deux temps, articulée autour de deux profils d'utilisateurs distincts :

- Dans un premier temps, une équipe d'actuaire se charge de modéliser, construire et entraîner le modèle de détection. À partir d'une base de données sinistres au format standardisé, l'outil réalise automatiquement des contrôles qualité sur les données, produit une étude statistique descriptive mettant en avant les indicateurs clés (fréquence de fraude, coût moyen, segmentation par critères prédéfinis), puis entraîne un modèle de détection de fraude. Le résultat est un modèle calibré, sauvegardé et prêt à être déployé.
- Dans un second temps, une équipe opérationnelle (gestionnaires sinistres ou service de détection des fraudes) utilise ce modèle au quotidien sans avoir à en comprendre la construction. Pour chaque nouveau sinistre soumis, l'outil restitue une probabilité de fraude associée, permettant d'identifier les dossiers suspects et de les prioriser. Ainsi, les équipes d'investigation peuvent concentrer leurs efforts sur les cas les plus à risque, sans perdre de temps sur les dossiers à faible probabilité de fraude.




FIGURE 4.2 – Schéma macroscopique du fonctionnement de l'outil

L'architecture complète de ce processus est détaillée dans les chapitres suivants, de l'alimentation de la base de données à la boucle d'enrichissement continu, en passant par la modélisation de la probabilité de fraude.

Le plus de l'agent : un suivi du ROI disponible

Enfin, l'outil produit automatiquement un rapport annuel de détection de fraude, enrichi à chaque fois qu'un sinistre testé est renseigné comme frauduleux par un expert. Ce rapport est accessible à tout moment et fournit une synthèse consolidée des performances : nombre de sinistres analysés, taux d'alertes générées, fraudes confirmées et montant de fraude évitée. Il calcule notamment l'impact direct sur le ratio Sinistres/Primes (S/P), indicateur clé de rentabilité en assurance, en rapportant le montant de fraude évitée à la masse de primes du portefeuille. Cette restitution permet au management de suivre en continu le retour sur investissement de l'outil (ROI) et d'objectiver la valeur ajoutée de la détection automatisée année après année.

4.3.1 Le prompt : la décomposition du besoin en étapes

Dans le contexte de l'intelligence artificielle, et plus particulièrement des modèles de langage, un prompt désigne l'ensemble des instructions, du contexte et des données fournis au modèle afin de guider son comportement et d'orienter la nature des réponses ou des actions qu'il produit. Il constitue le point d'entrée de l'interaction entre l'utilisateur (ou un système) et l'agent. Un prompt ne se réduit pas à une simple question : il peut comporter des consignes précises, des contraintes, des exemples et une structuration attendue du résultat. De façon générale, plus il est clair, détaillé et contextualisé, plus le

modèle est en mesure de produire une réponse pertinente et alignée sur l'objectif visé.

D'un point de vue méthodologique, le prompt peut être assimilé à la spécification fonctionnelle de la tâche confiée à l'agent : il joue, vis-à-vis du modèle, un rôle comparable à celui d'un cahier des charges vis-à-vis d'un modèle actuariel. Sa qualité conditionne directement celle du résultat, au même titre que la rigueur d'une note technique conditionne la fiabilité d'un calcul. Cette exigence rejoint les principes de gouvernance évoqués précédemment : un prompt explicite, documenté et reproductible contribue à la traçabilité et à l'auditabilité du dispositif, en rendant intelligibles les consignes sur lesquelles repose le comportement de l'agent.

Concrètement, un prompt bien construit remplit trois fonctions :

- Il définit la cible : il ne s'agit pas ici d'affirmer qu'un dossier est frauduleux (l'agent ne se substitue pas à l'enquêteur) mais d'identifier, à partir des données disponibles, les dossiers présentant un risque de fraude élevé.
- Il précise le cadre d'intervention : le rôle de l'agent, le contexte métier, les critères à prendre en compte et les limites de son action.
- Il encadre enfin la forme de la réponse attendue, par exemple un score, un tableau ou une synthèse exploitable par les équipes opérationnelles.

Pour obtenir un résultat précis, contrôlable et reproductible, il ne suffit toutefois pas de formuler une consigne unique et globale, qui laisserait à l'agent une marge d'interprétation trop large et nuirait à la stabilité des réponses. Nous avons donc adopté une approche de construction du prompt par étapes : plutôt que de soumettre l'intégralité de la tâche en un seul bloc, le raisonnement attendu de l'agent a été décomposé en une séquence d'étapes successives, chacune assortie d'un objectif clair et d'un résultat intermédiaire vérifiable.

Cette décomposition présente un double intérêt. Elle reproduit la logique même de la démarche actuarielle (du contrôle de la qualité des données à la production d'un score, en passant par l'analyse descriptive et la modélisation) et elle permet de valider chaque maillon de la chaîne indépendamment, limitant ainsi le risque d'erreur ou de dérive et renforçant l'explicabilité de l'ensemble.

Ainsi, le prompt constitue un élément central du système : il transforme une demande générale en une tâche claire, structurée et exploitable, et montre que l'efficacité de l'outil ne repose pas uniquement sur les données ou sur le modèle, mais aussi sur la qualité des instructions fournies à l'agent. Le raisonnement confié à ce dernier a en conséquence été structuré selon les étapes successives présentées ci-après.

4.3.2 Présentation macro des différentes étapes

Les étapes menant à la création du modèle sont ainsi décomposées :

1. Ingestion standardisée des données ;
2. Audit et contrôles de cohérence ;

52

Une fois le modèle de détection mis en place, il est intégré dans un outil d'aide à la décision destiné aux gestionnaires et au service fraude. Contrairement aux modules précédents, ce second module ne fonctionne pas selon une séquence figée : il se comporte comme un véritable logiciel au sein duquel l'utilisateur navigue librement. S'il existe un enchaînement logique naturel, l'utilisateur peut à tout moment revenir en arrière, répéter une opération ou accéder directement à une fonctionnalité selon ses besoins.

L'outil met à disposition les fonctionnalités suivantes :

- La saisie d'un sinistre : l'utilisateur renseigne les informations d'un dossier à évaluer.
- L'obtention d'un score de fraude : le modèle restitue une probabilité de fraude associée au sinistre soumis.
- Le renseignement du statut du dossier : lorsque l'issue de l'investigation est connue, l'utilisateur peut indiquer si le sinistre s'est avéré frauduleux ou non.

De plus, l'outil reste lié de manière cyclique au modèle puisque le renseignement du statut du dossier permet :

- l'alimentation de la base de données sinistre ayant servi à faire tourner le modèle ;
- l'affinage du modèle créé à l'aide des nouveaux sinistres renseignés.




FIGURE 4.4 – Agent d'aide à la détection de fraude

À noter que la logique de création des deux agents respecte l'objectif d'utilisation de ces derniers : deux

équipes distinctes seront en charge de leur utilisation, d'où le besoin de rendre totalement indépendants les deux agents créés.

4.4 Résultats fournis par l'Agent IA pour la construction du modèle de scoring de fraude — Étapes 1 à 3

Dans cette section, nous présentons la restitution concrète produite par notre outil sur le portefeuille de sinistres simulé (construit à partir des données Kaggle enrichies).

Cette phase de conception du modèle constitue une étape amont essentielle, mais elle n'a pas vocation à être maîtrisée par les équipes opérationnelles en charge de la détection de la fraude. En effet, l'outil final qui leur est destiné repose sur un modèle déjà entraîné et optimisé, qu'ils pourront exploiter sans avoir à intervenir sur ses mécanismes internes. Ainsi, la complexité technique est volontairement « encapsulée » afin de proposer une solution simple d'utilisation, centrée sur l'aide à la décision aux gestionnaires.

Dans la pratique, la responsabilité de la construction, de l'ajustement et de l'amélioration continue du modèle incombe généralement à des profils spécialisés, tels que les actuaires ou les data scientists. Ces experts interviennent pour affiner les performances du modèle, intégrer de nouvelles données, ajuster les paramètres et garantir la robustesse des résultats dans le temps. Cette séparation des rôles permet d'assurer à la fois un haut niveau de performance analytique et une appropriation efficace de l'outil par les équipes métiers.

4.4.1 Étape 1 : Ingestion de la base de données

La première étape correspond au chargement des données.

Sur la page d'accueil de l'outil, intitulée « Aide à la détection de fraude », nous invitons l'utilisateur à déposer son fichier de sinistres, qui constitue la donnée d'entrée de l'ensemble du processus.

Le dépôt peut se faire de deux manières :

- soit par glisser-déposer directement dans la zone prévue à cet effet,
- soit en cliquant sur le bouton « Parcourir vos fichiers » afin de sélectionner le document depuis l'explorateur.

Les formats acceptés sont les plus courants pour ce type de données, à savoir CSV, Excel (.xlsx et .xls) et ODS, de manière à s'adapter aux différents systèmes de gestion des professionnels de l'assurance.




FIGURE 4.5 – Extrait du prompt pour la création de l'étape 1

À ce stade, aucun choix de modèle n'est demandé : celui-ci n'interviendra qu'ultérieurement, une fois les analyses descriptives consultées, ce qui permet à l'utilisateur de sélectionner en connaissance de cause le modèle de détection le plus adapté à la structure de son portefeuille.

Enfin, nous signalons à l'utilisateur que les données importées sont traitées de manière sécurisée et confidentielle, l'outil étant réservé aux professionnels de l'assurance.

L'utilisateur clique ensuite sur le bouton « submit » pour passer à l'étape suivante.




FIGURE 4.6 – Page d’accueil de l’outil d’aide à la détection de fraude

4.4.2 Étape 2 : Audit et contrôles de cohérence

Dès l’importation du fichier brut de sinistres, l’outil procède à un audit automatisé, étape fondamentale de Data Profiling. L’objectif de cette interface n’est pas de réaliser un simple inventaire, mais de garantir l’intégrité et la qualité des données avant qu’elles ne soient intégrées dans un modèle de prédiction de la fraude.

Concrètement, comme illustré dans le tableau de restitution ci-dessous, le moteur cartographie le portefeuille en réalisant plusieurs contrôles croisés pour chaque variable :

- **La vérification du type** : l’outil confronte le type de donnée attendu par le système au type réellement détecté. Cela permet de bloquer instantanément les erreurs de formatage.
- **L’analyse des plages et modalités** : le système extrait automatiquement les bornes pour les variables numériques, et liste les différentes catégories pour les variables textuelles, facilitant la détection immédiate de valeurs aberrantes (outliers).
- **Le contrôle de complétude** : il calcule le taux de remplissage exact pour mettre en évidence

les données manquantes. En cas de donnée(s) manquante(s), l'Agent demande à l'utilisateur de les remplacer par une valeur par défaut à renseigner. À noter qu'il aurait également été possible de proposer des options de remplissage par défaut, par exemple, pour une variable quantitative, la moyenne ou encore la médiane ou la valeur la plus représentée.

Dans notre outil, un contrôle bloquant a été mis en place sur la complétude des données : l'agent ne permet pas la poursuite des tâches si la base de données n'est pas complète.

À titre illustratif, voici une sortie de l'outil lorsque la base admet une valeur manquante :

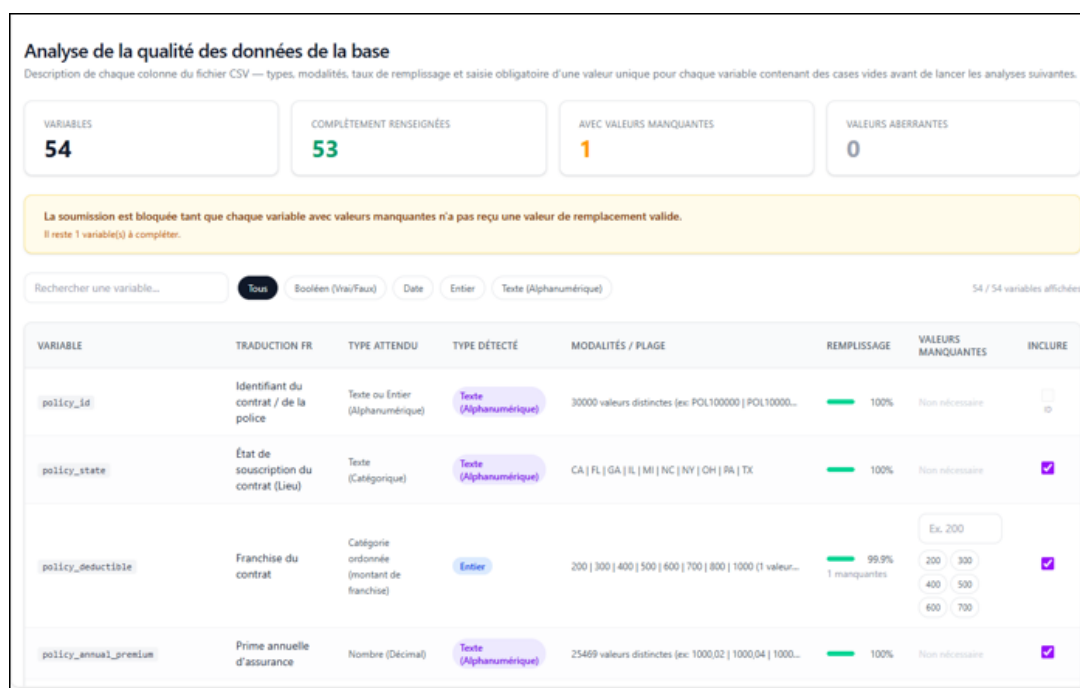


FIGURE 4.7 – Sortie de l'outil « Analyse de la qualité des données de la base » avec une valeur manquante

Ici, la variable « policy_deductible » qui correspond à la franchise du contrat admet une valeur manquante. L'utilisateur est invité à choisir une des valeurs qui s'affiche pour compléter la ligne manquante (les valeurs affichées correspondent aux modalités observées dans la base d'entrée), ou à entrer manuellement une valeur dans un champ dédié.

Une fois l'information complétée, l'affichage se met à jour automatiquement ⁵ :

5. L'affichage intégral de la sortie de l'agent à cette étape est disponible en Annexe (Cf. XXXX).

Analyse de la qualité des données de la base
Description de chaque colonne du fichier CSV — types, modalités, taux de remplissage et saisie obligatoire d'une valeur unique pour chaque variable contenant des cases vides avant de lancer les analyses suivantes.

VARIABLES
54

COMPLÈTEMENT RENSEIGNÉES
54

AVEC VALEURS MANQUANTES
0

VALEURS ABERRANTES
0

Rechercher une variable... Tous Booléen (Vrai/Faux) Date Entier Texte (Alphanumérique) 54 / 54 variables affichées

VARIABLE	TRADUCTION FR	TYPE ATTENDU	TYPE DÉTECTÉ	MODALITÉS / PLAGE	REPLISSAGE	VALEURS MANQUANTES	INCLURE
policy_id	Identifiant du contrat / de la police	Texte ou Entier (Alphanumérique)	Texte (Alphanumérique)	30000 valeurs distinctes (ex: POL100000 POL10000...	100%	Non nécessaire	☐
policy_state	État de souscription du contrat (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX	100%	Non nécessaire	☒
policy_deductible	Franchise du contrat	Catégorie ordonnée (montant de franchise)	Entier	200 300 400 500 600 700 800 1000	100%	Non nécessaire	☒
policy_annual_premium	Prime annuelle d'assurance	Nombre (Décimal)	Texte (Alphanumérique)	25469 valeurs distinctes (ex: 1000.02 1000.04 1000...	100%	Non nécessaire	☒
insured_age	Âge de l'assuré	Entier	Entier	[18 ; 75]	100%	Non nécessaire	☒
insured_sex	Sexe de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	FEMALE MALE OTHER	100%	Non nécessaire	☒

FIGURE 4.8 – Sortie de l'outil « Analyse de la qualité des données de la base » sans valeur manquante

L'examen du tableau de contrôle permet de formuler deux observations métier majeures sur notre jeu de données :

- D'une part, le contrôle des bornes (colonne « Modalités / Plage ») valide la cohérence globale de notre portefeuille. À titre d'exemple, l'outil confirme immédiatement que la variable `insured_age` est strictement comprise entre 18 et 75 ans. L'absence de valeurs irréalistes confirme que les règles de gestion ont été respectées lors de la saisie.
- De plus, la variable cible de notre étude, `fraud_reported`, est correctement identifiée et renseignée à 100 %, condition sine qua non pour l'entraînement d'un modèle supervisé.

De plus, l'agent a la capacité de détecter les variables susceptibles d'être utilisées dans le modèle et celles qui ne le sont pas (cf. dernière colonne « Inclure ») : la variable « `policy_id` » correspondant à l'identifiant du contrat a été reconnue comme une variable d'incrément et est exclue de la modélisation. L'utilisateur peut également en exclure d'autres, pour des raisons réglementaires ou techniques à ce niveau.

Enfin, en bas de page, l'utilisateur doit préciser à l'agent quelle variable désigne la variable à expliquer.

Pour cela il suffit de sélectionner la variable cible dans la liste déroulante proposée :

Variable cible
La colonne que le modèle cherche à prédire.

Colonne du CSV Nom affiché dans l'outil

Les variables décochées dans le tableau ne seront pas utilisées dans les graphiques ni les modèles.

Variable cible
La colonne que le modèle cherche à prédire.

Colonne du CSV Nom affiché dans l'outil

Les variables décochées dans le tableau ne seront pas utilisées dans les graphiques ni les modèles.

Ici, c'est la variable `fraud_reported` qui est la variable à modéliser, et elle sera appelée « fraude » dans la suite des analyses.

4.4.3 Étape 3 : Analyse statistique des données

Une fois la qualité des données validée, l'agent bascule dans une phase d'analyse exploratoire :

- **Univariée** : il s'agit d'analyser la composition de notre portefeuille par variable ;
- **Bivariée** : il s'agit ici d'analyser la fréquence et le coût moyen de la fraude, au même titre que les analyses qui seraient réalisées dans le cadre d'une tarification produit.

4.4.3.1 Analyse de la composition du portefeuille

Avant d'engager toute modélisation ou détection de comportements atypiques, il est essentiel de dresser un portrait détaillé de la base de données sinistres automobiles étudiée.

Cette analyse préliminaire vise à caractériser la structure des sinistres déclarés selon plusieurs axes : la nature des sinistres (accidents corporels, dommages, etc.), ainsi que les caractéristiques des conducteurs impliqués (âge, sexe, profession, adresse, etc.) et les paramètres du contrat (franchise, prime annuelle, etc.)

Elle permet également d'examiner la distribution temporelle et géographique des déclarations, deux dimensions particulièrement révélatrices en matière de fraude automobile. Une telle exploration permet d'identifier d'éventuels déséquilibres ou concentrations atypiques dans les données (comme une surreprésentation de sinistres déclarés en fin de contrat ou dans certaines zones géographiques) et d'en tenir compte dans les étapes ultérieures de l'analyse. La connaissance fine de la structure de cette base constitue un prérequis indispensable à toute démarche actuarielle rigoureuse, en posant les fondements empiriques

sur lesquels reposera l'ensemble de la modélisation de la fraude développée dans ce mémoire.

Le prompt adressé à l'agent concernant l'analyse de composition de portefeuille renvoie la sortie suivante :




FIGURE 4.9 – Composition du portefeuille

La base de données étudiée comprend 30 000 sinistres automobiles, offrant ainsi un volume suffisant pour mener une analyse statistique robuste et entraîner des modèles de détection de la fraude performants.

La répartition par tranche d'âge (par pas de cinq ans) est relativement homogène, à l'exception de la tranche des 18-20 ans, nettement moins représentée (1 556 sinistres), ce qui s'explique par sa moindre amplitude et la faible part des très jeunes conducteurs. La répartition par sexe est quant à elle quasi équilibrée, avec une part similaire d'hommes (33,5 %), de femmes (32,9 %) et de personnes morales (33,6 %).

Les sinistres surviennent majoritairement la nuit, entre 0h et 6h (8 715 cas, soit environ 29 %), devant l'après-midi et le matin, ce qui constitue un premier signal d'attention dans une optique anti-fraude, la nuit étant une période propice aux déclarations difficiles à contredire faute de témoins. À cet égard, on note que 66,8 % des sinistres impliquent au moins deux témoins, tandis que 16,4 % n'en comptent aucun. Par ailleurs, 60,1 % des sinistres font état d'au moins deux blessés corporels, un chiffre élevé qui mérite d'être mis en perspective avec le taux de fraude observé.

La franchise du contrat est répartie de manière très uniforme entre les différents niveaux (de 200 à

1 000 €), avec des effectifs oscillant entre 3 674 et 3 794 sinistres par modalité, suggérant une bonne diversité des profils de contrats. Concernant les démarches déclaratives, un rapport de police est disponible dans 49,7 % des cas, et les autorités les plus fréquemment contactées sont les pompiers (7 569) et la police (7 498), tandis que près de 25 % des sinistres n'impliquent aucune autorité, ce qui peut constituer un indicateur de risque supplémentaire dans la modélisation.

Au-delà de ces caractéristiques générales, la base intègre également plusieurs variables directement pensées pour la détection de la fraude, dont la distribution mérite d'être soulignée. Ainsi, 3,2 % des sinistres font intervenir un réparateur préalablement signalé et 10,4 % font état d'une blessure déclarée sans preuve médicale, deux signaux classiques d'alerte. De même, 9 % des dossiers concernent un tiers déjà connu de l'assuré, configuration propice aux sinistres arrangés. Enfin, la grande majorité des assurés ne présente aucun antécédent de fraude (26 222 dossiers), les cas répétés restant marginaux, ce qui reflète le caractère rare et déséquilibré du phénomène étudié.

Cette analyse descriptive de la base sinistres permet d'établir une vision globale de la structure des données, sans distinction entre sinistres frauduleux et non frauduleux. La section suivante propose d'affiner cette exploration en adoptant une lecture bivariable, c'est-à-dire en comparant systématiquement la distribution de chaque variable selon le statut de fraude, afin d'identifier les premières variables discriminantes qui pourront guider la construction des modèles prédictifs.

À noter que, de manière autonome, l'agent détecte automatiquement la représentation la plus adaptée à la variable à étudier, notamment des camemberts pour les variables qui admettent un faible nombre de modalités et des diagrammes en barres pour les variables admettant un nombre plus important de modalités.

Enfin, l'agent permet l'export de la sortie graphique de composition du portefeuille, à des fins de traçabilité ou d'études intermédiaires par exemple.

4.4.3.2 Analyse des corrélations entre les variables

L'agent renvoie également une table de corrélation entre variables après l'analyse de composition du portefeuille, qui faisait partie de notre demande dans le prompt adressé.

En effet, avant d'engager la phase de modélisation, il est important d'examiner les relations existantes entre les différentes variables explicatives de la base sinistres. Cette analyse permet de détecter d'éventuelles redondances entre variables, susceptibles d'introduire des problèmes de multicollinéarité dans les modèles ultérieurs, et de mieux comprendre la structure sous-jacente des données.

La nature mixte des variables retenues (à la fois quantitatives et qualitatives) nécessite de recourir à plusieurs mesures d'association adaptées à chaque configuration.

Corrélation entre deux variables quantitatives

Les corrélations entre variables quantitatives sont mesurées via le coefficient de Pearson. Pour deux variables X et Y , il est défini par :

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y} \quad (4.1)$$

Son estimateur empirique sur un échantillon de taille n s'écrit :

$$r_{X,Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (4.2)$$

Ce coefficient, borné dans $[-1, 1]$, mesure exclusivement l'intensité et le sens d'une relation linéaire. Une valeur proche de 1 traduit une relation positive forte (les deux variables évoluent dans le même sens), une valeur proche de -1 une relation négative forte (l'une croît lorsque l'autre décroît), et une valeur proche de 0 l'absence de relation linéaire.

Attention, une valeur nulle n'exclut pas l'existence d'une dépendance non linéaire, ce qui justifie de compléter l'analyse par une inspection graphique lorsque cela est pertinent.

Association entre deux variables qualitatives

Les associations entre variables qualitatives sont quant à elles évaluées à l'aide du V de Cramér (dérivé de la statistique du χ^2 de Pearson). Pour deux variables qualitatives comportant respectivement k et l modalités, croisées dans un tableau de contingence de n observations, il est défini par :

$$V = \sqrt{\frac{\chi^2/n}{\min(k-1, l-1)}} \quad (4.3)$$

où la statistique du χ^2 est donnée par :

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*} \quad (4.4)$$

Les termes n_{ij} désignent les effectifs observés dans la cellule (i, j) et n_{ij}^* les effectifs théoriques sous l'hypothèse d'indépendance des deux variables. Le V de Cramér prend ses valeurs dans $[0, 1]$, une valeur nulle traduisant l'indépendance et une valeur unitaire une association parfaite.

Sa normalisation par $\min(k-1, l-1)$ le rend comparable entre tableaux de dimensions différentes, ce qui constitue un avantage déterminant dans un contexte où les variables catégorielles présentent des cardinalités hétérogènes.

Contrairement au coefficient de Pearson, le V de Cramér ne renseigne pas sur le sens de la relation, mais uniquement sur son intensité, puisqu'il s'applique à des variables non ordonnées.

Association entre une variable quantitative et une variable qualitative

Les relations entre une variable quantitative et une variable qualitative sont appréhendées par le rapport de corrélation (η^2).

Soit Y une variable quantitative et X une variable qualitative à k modalités partitionnant l'échantillon en k classes d'effectifs $n_1, \dots, n_k$. En notant $\bar{y}_j$ la moyenne de Y dans la classe j et $\bar{y}$ la moyenne globale, la décomposition de la variance totale s'écrit :

$$\underbrace{\sum_{j=1}^k \sum_{i=1}^{n_j} (y_{ij} - \bar{y})^2}_{SC_{\text{totale}}} = \underbrace{\sum_{j=1}^k n_j (\bar{y}_j - \bar{y})^2}_{SC_{\text{inter}}} + \underbrace{\sum_{j=1}^k \sum_{i=1}^{n_j} (y_{ij} - \bar{y}_j)^2}_{SC_{\text{intra}}} \quad (4.5)$$

avec SC la somme des carrés. Le rapport de corrélation est alors défini par :

$$\eta^2 = \frac{SC_{\text{inter}}}{SC_{\text{totale}}} \quad (4.6)$$

Il s'interprète comme la part de la variance de Y expliquée par l'appartenance aux modalités de X . Une valeur proche de zéro indique une absence de discrimination des modalités de X sur les niveaux moyens de Y , tandis qu'une valeur proche de 1 traduit une segmentation forte.

Par convention, un coefficient supérieur à 0,7 est généralement considéré comme révélateur d'une association forte, pouvant justifier l'exclusion ou la transformation de l'une des variables concernées.

Corrélation entre les variables de la base étudiée

Les tableaux ci-dessous synthétisent l'ensemble de ces mesures et constituent ainsi un prérequis méthodologique essentiel à la construction de modèles robustes et interprétables, en garantissant la qualité et l'indépendance de l'information apportée par chaque variable retenue dans l'analyse.



FIGURE 4.10 – Matrice de corrélations — variables quantitatives (coefficient de Pearson)



FIGURE 4.11 – Matrice de corrélations — variables qualitatives (V de Cramér)




FIGURE 4.12 – Matrice de corrélations — variables mixtes (rapport de corrélation η^2)

Chaque matrice d'association mobilise une mesure selon la nature des variables croisées : le coefficient de Pearson pour les couples de variables quantitatives, le V de Cramér pour les couples de variables

qualitatives, et le rapport de corrélation η^2 pour les couples de variables mixtes.

S'agissant des variables quantitatives, la grande majorité des corrélations de Pearson sont très faibles (proches de 0), traduisant une quasi-indépendance linéaire entre la plupart des grandeurs continues (prime, franchise, âge, délais, etc.). Deux exceptions se distinguent toutefois nettement. D'une part, le montant réclamé et le montant total de l'indemnisation présentent une corrélation très élevée (0,90), ce qui est logique puisque ces deux variables mesurent des quantités monétaires étroitement liées. D'autre part, le ratio de surévaluation de la réclamation est corrélé de façon marquée à ces mêmes montants (0,76 et 0,70). Ces redondances signalent un risque de multicolinéarité qu'il conviendra de traiter lors de la modélisation, par exemple en ne conservant qu'une seule de ces variables ou en construisant un indicateur synthétique, afin de préserver la stabilité et l'interprétabilité des modèles.

Parmi les variables qualitatives, mesurées par le V de Cramér, l'association la plus marquée avec la fraude concerne le statut de réparateur signalé ($V = 0,26$), suivi des autorités contactées ($V = 0,18$), de la présence d'une blessure déclarée sans preuve médicale ($V = 0,17$) et du fait que le tiers soit déjà connu de l'assuré ($V = 0,17$). Les autres variables qualitatives (gravité de l'incident, canal de déclaration, profession, etc.) présentent des associations nettement plus faibles.

Parmi les variables quantitatives, mesurées par le rapport de corrélation η^2 , les intensités les plus fortes s'observent pour le passé du réparateur, avec le nombre de fraudes qu'il a déjà confirmées ($\eta^2 = 0,32$) et son nombre total de sinistres traités ($\eta^2 = 0,19$), ainsi que pour le ratio entre la facture et le prix de marché ($\eta^2 = 0,28$) et les antécédents de fraude de l'assuré ($\eta^2 = 0,24$). Viennent ensuite l'historique des montants réclamés (0,19), le nombre de modifications apportées à la déclaration (0,18) et le nombre d'incidents passés du tiers (0,17).

Concernant les corrélations linéaires entre variables quantitatives, seul le couple montant réclamé / montant total dépasse le seuil de 0,7 retenu comme signal de redondance excessive (0,90). Cette forte corrélation justifie de ne conserver qu'une seule de ces deux variables lors de la modélisation. Pour l'ensemble des autres variables explicatives, aucune association n'atteint ce seuil : elles apportent une information suffisamment distincte pour être toutes conservées dans la phase de modélisation.

4.4.3.3 Élimination des variables corrélées

À l'issue de l'analyse des matrices d'association, l'outil offre à l'utilisateur la possibilité d'écarter les variables jugées redondantes. Cette étape de sélection vise à ne conserver, parmi les variables candidates, que celles qui apportent une information « propre » et non déjà captée par d'autres, afin de ne pas dégrader la qualité des modèles construits par la suite.

Sur les 54 variables explicatives disponibles à ce stade (24 issues de la base source et 30 issues de l'enrichissement), 45 ont été retenues pour la modélisation. Les 9 variables restantes ont été écartées automatiquement par l'outil, qui les a identifiées comme non pertinentes pour la prédiction : la variable cible `fraud_reported`, qui constitue précisément la grandeur à prédire et ne peut donc servir d'entrée ; les identifiants uniques ou quasi uniques, dépourvus de tout pouvoir prédictif généralisable (`policy_id`, `insured_id`, `repairer_id`, `third_party_id`, `witness_id`, `vehicle_id`) ; et deux variables trop granulaires pour une analyse statistique robuste, à savoir la date exacte du sinistre (`incident_date`) et la ville du sinistre (`incident_city`), dont le très grand nombre de modalités rendrait les effectifs par catégorie

trop faibles. Ce filtrage, réalisé en amont par l'agent sans intervention manuelle, garantit que seules les variables réellement porteuses d'information alimentent les modèles.




FIGURE 4.13 – Interface de sélection permettant de conserver ou de retirer des variables

Le retrait des variables fortement corrélées répond à un enjeu méthodologique important. Lorsque deux variables explicatives sont redondantes, elles introduisent un phénomène de multicolinéarité qui peut fragiliser le modèle de plusieurs manières.

Sur les modèles de type régression ou scoring, la multicolinéarité rend l'estimation des coefficients instable : de faibles variations dans les données peuvent entraîner des changements importants dans les pondérations attribuées à chaque variable, rendant leur interprétation peu fiable, voire trompeuse. Sur l'ensemble des modèles, elle nuit également à la parcimonie et à la lisibilité du dispositif, sans améliorer le pouvoir prédictif puisque l'information est déjà présente. Éliminer ces redondances en amont permet donc de gagner en robustesse, en stabilité et en interprétabilité, sans perte d'information significative.

4.4.3.4 Analyse de la fréquence de fraude

Le système ne se contente plus de décrire chaque variable isolément, il croise systématiquement chaque caractéristique avec la variable cible (fraud_reported) préalablement identifiée par l'utilisateur.

L'objectif de cette interface est de réaliser un « profilage » automatisé. En comparant visuellement la distribution des modalités au sein de la population saine (« Non-fraudeurs ») avec celle des fraudeurs avérés (« Fraudeurs »), l'outil calcule un indicateur de déviation statistique appelé le « Delta » :

- un delta positif important révèle une sur-représentation anormale d'une caractéristique dans les dossiers de fraude historiques ;
- à l'inverse, un delta négatif met en avant la sous-représentation de certaines caractéristiques dans les dossiers de fraude.

L'agent va ensuite réaliser deux actions de manière autonome :

- afficher le top 3 des variables jugées comme les plus discriminantes au vu de la variable cible (affichage on Top) ;
- choisir la représentation la plus adaptée à la variable à étudier, notamment des camemberts pour les variables qui admettent un faible nombre de modalités et des diagrammes en barres pour les

variables admettant un nombre plus important de modalités.




FIGURE 4.14 – Extrait de la sortie de l'analyse statistique des fraudes/non fraudes par variables sur la base de données de sinistres automobile

Afin de permettre à l'utilisateur de visualiser l'ensemble des variables, un choix d'affichage est disponible à droite sur simple clic.




FIGURE 4.15 – Extrait de la sortie de l'analyse statistique des fraudes/non fraudes pour les variables des autorités contactées et nombre de fraudes passées sur la base de données de sinistres automobile

À noter que l'agent comprend également seul qu'il est inutile de réaliser l'analyse de la fraude par police_id par exemple, dans la mesure où cet indicateur sert de compteur (ou incrément) et n'a pas

d'apport dans la modélisation. Pour rappel cette variable avait été décochée dès le début.

Pour les variables dont les modalités ont été regroupées en classes, une loupe située en haut à droite permet d'afficher une version plus détaillée, où les tranches sont segmentées à la maille la plus fine disponible.




FIGURE 4.16 – Analyse de la variable tranche d'âge selon le statut fraude du sinistre

À titre d'exemple, la variable tranche d'âge peut être affichée dans sa version détaillée :

Tranche d'âge (détaillé) — vue détaillée

Intervallés affinés. Cliquez en dehors pour fermer.

Non fraudeurs



Fraudeurs




FIGURE 4.17 – Vue détaillée de la variable tranche d'âge

Cette vue détaillée par âge fait apparaître une surreprésentation des assurés de 18 à 24 ans parmi les sinistres frauduleux : alors que la distribution des non-fraudeurs reste relativement uniforme sur l'ensemble des tranches d'âge, celle des fraudeurs présente un pic sur les premiers âges avant de se stabiliser au-delà de 24 ans. Cet effet reste toutefois localisé sur les jeunes conducteurs : au-delà de cette tranche, l'âge ne discrimine plus la fraude. L'âge n'est donc pas une variable fortement discriminante en soi, mais la classe des 18-24 ans mérite une attention particulière.

L'analyse de ces graphiques et diagrammes permet de dégager des enseignements métiers déterminants pour orienter les règles de gestion et alimenter les algorithmes prédictifs :

1. Les antécédents de fraude et l'environnement du sinistre : des signaux prioritaires.

L'analyse met en évidence une forte association entre la fraude et les informations relatives au réparateur ainsi qu'aux antécédents de l'assuré. Le nombre de fraudes déjà confirmées pour le réparateur constitue le signal le plus marqué ($\eta^2 = 0,32$), devant le ratio facture/marché ($\eta^2 = 0,28$) et le nombre de fraudes passées de l'assuré ($\eta^2 = 0,24$). S'y ajoute, parmi les variables qualitatives, le statut de réparateur signalé ($V = 0,26$). Ainsi, les assurés ayant déjà connu au moins une fraude représentent 35,6 % des dossiers frauduleux, contre 9,6 % des dossiers non frauduleux. Ces éléments justifient une vigilance renforcée lorsque l'historique de l'assuré et celui des intervenants convergent vers un profil à risque.

2. La cohérence de la déclaration : un levier essentiel de détection.

Les modalités de déclaration du sinistre apportent des indicateurs particulièrement discriminants. L'absence d'autorités contactées apparaît dans 46,5 % des dossiers frauduleux, contre 22,5 % des dossiers non frauduleux, soit un écart de 24 points. Le nombre d'amendements apportés à la déclaration constitue

également un signal important : les dossiers comprenant au moins deux modifications représentent 31,9 % des fraudes, contre 13,5 % des dossiers non frauduleux. Enfin, une blessure déclarée sans preuve médicale concerne 24,6 % des dossiers frauduleux, contre 8,6 % des dossiers non frauduleux. Ces incohérences ou ajustements successifs doivent donc alimenter les règles de contrôle et les mécanismes de priorisation des dossiers.

3. **Les historiques de sinistres : une lecture complémentaire du risque.** L'accumulation de sinistres antérieurs est davantage observée parmi les dossiers frauduleux. Les assurés ayant déclaré au moins deux sinistres par le passé représentent 47,6 % des cas de fraude, contre 30,4 % des dossiers non frauduleux. Les antécédents d'incidents du tiers impliqué suivent une logique similaire : 18,5 % des dossiers frauduleux concernent un tiers ayant déjà connu au moins un incident, contre 8,2 % des dossiers non frauduleux. Ces résultats confirment l'intérêt d'une analyse croisée entre l'historique de l'assuré, celui du tiers et les caractéristiques du réparateur, plutôt que d'une lecture fondée sur une seule variable.
4. **Les variables descriptives : utiles pour segmenter, moins déterminantes pour alerter.** Les caractéristiques socio-démographiques et contractuelles (le sexe, la prime annuelle, la franchise, l'heure de l'incident ou le nombre de véhicules impliqués) présentent des associations faibles avec la fraude. L'âge relève également de cette catégorie : hormis la surreprésentation ciblée des 18-24 ans évoquée plus haut, il ne constitue pas un facteur de priorisation. Ces variables contribuent à la description et à la segmentation du portefeuille, sans figurer parmi les principaux signaux d'alerte. La sévérité de l'incident conserve toutefois un intérêt descriptif : la modalité « perte totale » est présente dans 43,5 % des fraudes, contre 32,4 % des dossiers non frauduleux. L'évaluation globale du risque doit donc privilégier les éléments d'historique et de cohérence déclarative, tout en conservant les variables descriptives pour enrichir l'analyse des profils.

4.4.3.5 Analyse du coût moyen de la fraude

Après avoir analysé la fréquence de fraude, une étude est réalisée sur le coût moyen des dossiers frauduleux (variable `total_claim_amount`).

Analyse du coût moyen

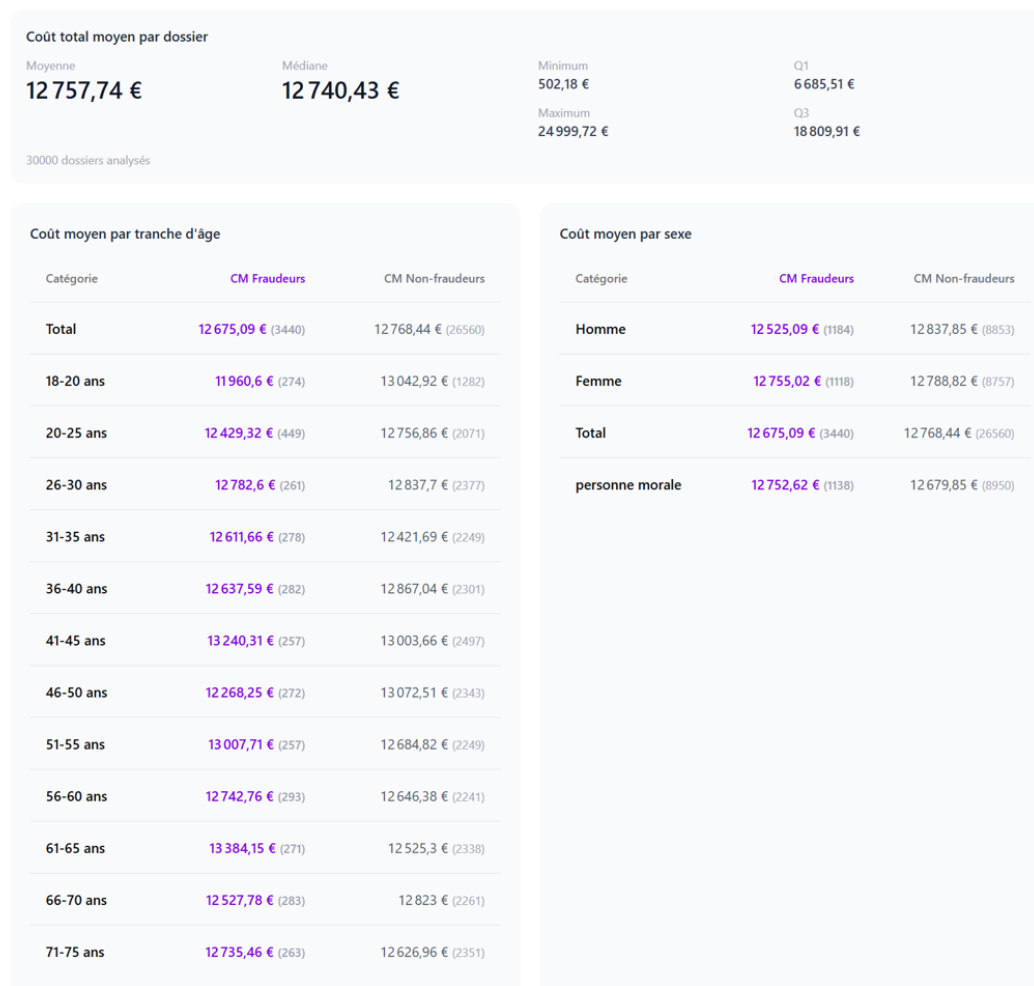


FIGURE 4.18 – Analyse du coût moyen des sinistres frauduleux et non frauduleux

Ces indicateurs nous permettent de faire un constat contre-intuitif : la fraude ne concerne pas les sinistres les plus coûteux. Le coût moyen des 3 440 dossiers frauduleux s'élève à 12 675,09 €, soit un montant quasiment identique, et même légèrement inférieur, au coût moyen global (12 757,74 €). Autrement dit, les dossiers frauduleux ne se distinguent pas par des montants réclamés plus élevés que les dossiers sains.

Ce résultat, à première vue surprenant, a une implication importante : le montant du sinistre n'est pas, à lui seul, un signal permettant d'orienter la détection vers les fraudeurs. Une stratégie de contrôle qui se concentrerait uniquement sur les sinistres les plus coûteux passerait donc à côté d'une large part de la fraude. C'est précisément ce qui justifie le recours à une approche multivariée : la fraude se révèle non pas par le montant réclamé, mais par la combinaison de signaux comportementaux et déclaratifs identifiés précédemment (antécédents, cohérence de la déclaration, environnement du sinistre).

L'objectif du mémoire étant de modéliser une probabilité de fraude (variable cible binaire), l'étude du

coût moyen n'entre a priori pas directement dans la spécification du modèle. Néanmoins, elle conserve une justification importante dans un mémoire actuariel : la justification de l'enjeu économique du modèle. En effet, modéliser une probabilité de fraude n'a de valeur opérationnelle que si la fraude représente un enjeu financier significatif.

Ainsi, le gain unitaire espéré d'une fraude correctement détectée correspond au coût moyen d'un sinistre frauduleux $\tilde{C}_F$:

$$\text{Gain unitaire espéré} \approx \tilde{C}_F \quad (4.7)$$

Ce gain correspond au montant que l'assureur évite de verser indûment en écartant le dossier. On fait ici l'hypothèse qu'un sinistre identifié comme frauduleux est intégralement rejeté ; dans le cas d'une simple exagération, seul le surcoût frauduleux serait effectivement récupéré. Cela pose le cadre économique qui légitime la démarche de modélisation.

Chapitre 5

Création du modèle de détection de fraude (Étapes 4 et 5)

Dans la suite de l'analyse, l'étude se concentre sur trois approches de modélisation couramment utilisées en détection de fraude :

- un **modèle de scoring en points** (interprétable et proche des pratiques actuarielles traditionnelles) ;
- un **arbre de décision** (permettant de capturer des effets non linéaires et des interactions) ;
- un **modèle de type Gradient Boosting** (plus performant en général grâce aux méthodes d'ensemble).

L'objectif est d'évaluer et de comparer leur **qualité de prédiction** à partir de métriques adaptées, tout en tenant compte des enjeux d'interprétabilité et d'implémentation opérationnelle.

Dans ce cadre, l'outil développé propose dans un premier temps de sélectionner un partitionnement de la base globale de manière à définir deux jeux de données :

- un jeu qui servira de base d'apprentissage ;
- un jeu qui servira de base de test du modèle créé.

Le choix du partitionnement est laissé à l'utilisateur, avec une valeur par défaut de départ à 80/20 (base d'apprentissage/base de test) correspondant aux proportions généralement utilisées lors de la mise en place de modèles sur ce type de volumétrie de données.



Répartition entraînement / test

Le fichier contient **30 000 lignes** — taux de fraude observé : **11.5%**. Comment voulez-vous répartir le jeu d'entraînement et le jeu de test ?

Méthode de répartition

Le split est stratifié sur la variable cible : le taux de fraude est préservé dans les deux jeux.

80% 20%

Glissez la barre, ou modifiez directement le nombre de lignes ci-dessous.

● Entraînement 24000 lignes

→

● Test 6000 lignes

FIGURE 5.1 – Choix du partitionnement de la base

Pour notre exemple, une partition **80 / 20** est retenue : 80 % des observations (24 000 lignes) constituent le jeu d'apprentissage-validation, et les 20 % restants (6 000 lignes) forment le jeu de test final, mis de côté dès le départ et jamais utilisé pendant la phase de construction.

Ce partitionnement est **stratifié sur la variable cible**, ce qui signifie que le taux de fraude observé (11,5 %) est préservé à l'identique dans les deux jeux. Cette précaution est essentielle sur des données déséquilibrées : un tirage purement aléatoire pourrait sur- ou sous-représenter les cas de fraude dans l'un des jeux, faussant l'apprentissage comme l'évaluation.

Sur la portion d'apprentissage-validation (80 %), une **validation croisée à 5 plis** est appliquée pour la sélection des hyperparamètres. Le principe consiste à diviser ces données en cinq sous-ensembles : le modèle est entraîné à cinq reprises, chaque fois sur quatre plis et évalué sur le cinquième, de sorte que chaque observation serve tour à tour à l'entraînement et à la validation. Cette approche fournit une estimation plus robuste de la performance et limite le risque de sur-ajustement (*overfitting*) au moment du choix des paramètres.

Enfin, le jeu de test (20 %), resté totalement isolé, permet une **évaluation finale en conditions réelles** : les métriques de performance (AUC, Gini, KS, rappel, précision etc.) sont calculées sur des données que le modèle n'a jamais vues, garantissant une mesure honnête de sa capacité de généralisation.

Une fois le partitionnement entraînement/test choisi, les trois modélisations sont lancées et le résultat de chacune d'elles s'affiche sur simple clic, permettant ainsi une comparaison entre modèles.

Résultats des 3 modèles

Les trois modèles ont été entraînés sur vos données. Consultez leurs résultats avant de retenir une configuration.

CHOISISSEZ LE MODÈLE À VISUALISER

 Scoring en points 

 Arbre de décision

 Gradient Boosting

FIGURE 5.2 – Affichage de l'Agent IA pour le choix de modélisation (à renseigner par l'utilisateur)

Une présentation et analyse des résultats de chaque modèle est proposée ci-dessous.

5.1 Scoring en points

Sur la base de sinistre transmise, l'Agent IA va à présent appliquer un *modèle de scoring en points*.



FIGURE 5.3 – Sélection du modèle de scoring en points

5.1.1 Résultats du modèle

La construction d'un modèle de *scoring* performant repose en amont sur une sélection rigoureuse des variables explicatives. Cette étape poursuit un double objectif : d'une part, retenir uniquement les variables porteuses d'un pouvoir discriminant réel vis-à-vis de la variable cible (l'occurrence de fraude), afin de maximiser la performance prédictive du modèle ; d'autre part, garantir la parcimonie du barème, condition essentielle à sa lisibilité, à son appropriation par les gestionnaires sinistres et à sa maintenabilité dans le temps.

Un barème surchargé de critères, même statistiquement significatifs, perd en effet en opérationnalité et devient difficilement auditable.

Une fois la phase de sélection des variables terminée, un nombre de points est affecté à chaque modalité ou situation à risque. Plus une modalité est associée historiquement à un niveau élevé de fraude, plus le nombre de points attribué est important. À l'inverse, les situations jugées peu suspectes reçoivent peu de points, voire aucun.

Le *scoring* en points repose donc sur une logique additive : chaque dossier cumule des points selon les caractéristiques qu'il présente. Le barème reflète ainsi la contribution relative de chaque critère au risque de fraude.

Grille détaillée — 20 variables retenues sur 38 candidates

Nb fraudes confirmées (réparateur) Quantitative repaier_nb_fraud_confirmed
Points : 0 → 89 IV : 0,585 Stabilité : 0,97 Coefficient logistique : 0,775

INTERVALLE	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
< 1	8	Diminue le risque	14 253 (59 %)	8,7 % (1 243)	-0,305
[1 ; 3[	0	Diminue le risque	6 083 (25 %)	7,2 % (436)	-0,517
[3 ; 4[	11	Diminue le risque	1 203 (5 %)	9,4 % (113)	-0,219
[4 ; 29[	60	Augmente le risque	1 251 (5 %)	29,6 % (370)	1,176
≥ 29	89	Augmente le risque	1 210 (5 %)	48,8 % (590)	1,994

Nb total sinistres (réparateur) Quantitative repaier_nb_claims_total Points : 0 → 32 IV : 0,455 Stabilité : 0,92 Coefficient logistique : 0,267

INTERVALLE	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
< 9	6	Diminue le risque	5 989 (25 %)	10,6 % (634)	-0,090
[9 ; 27[	0	Diminue le risque	3 597 (15 %)	6,8 % (245)	-0,571
[27 ; 72[	3	Diminue le risque	9 607 (40 %)	8,8 % (849)	-0,290
[72 ; 117[	7	Augmente le risque	3 604 (15 %)	11,8 % (426)	0,035
≥ 117	32	Augmente le risque	1 203 (5 %)	49,7 % (598)	2,031

Nb fraudes passées (assuré) Quantitative insured_nb_past_fraud Points : 0 → 77 IV : 0,434 Stabilité : 1,00 Coefficient logistique : 1,007

INTERVALLE	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
< 1	0	Diminue le risque	20 974 (87 %)	8,4 % (1 767)	-0,342
≥ 1	77	Augmente le risque	3 026 (13 %)	32,6 % (985)	1,315

FIGURE 5.4 – Extrait de la grille d'attribution des points du modèle de scoring en points

Les résultats du modèle de scoring permettent de distinguer 3 catégories d'indicateurs :

- Tout d'abord, les **signaux forts (individuels)** correspondent à des indicateurs particulièrement discriminants, historiquement associés à un sur-risque de fraude. Ils sont donc fortement pondérés en points. Les plus marquants concernent l'environnement du réparateur et les antécédents de l'assuré. Ainsi, un réparateur présentant au moins 28 fraudes déjà confirmées atteint un taux de fraude de 51,1 % (contre 11,5 % en moyenne) et se voit attribuer 91 points; un assuré ayant déjà connu une fraude par le passé (taux de 32,1 %) reçoit 76 points; un délai de déclaration très court, inférieur à deux jours (24,9 % de fraude), rapporte 61 points. Le nombre d'amendements apportés à la déclaration constitue également un signal fort, un dossier comportant au moins trois modifications (27,2 % de fraude) recevant 71 points.
- Le deuxième type correspond aux **signaux moyens**, qui sont des indicateurs plus diffus ou moins discriminants pris individuellement, mais qui contribuent néanmoins à affiner l'évaluation du risque

lorsqu'ils s'accumulent. Il peut s'agir de l'ancienneté ou de la durée de possession du véhicule (un véhicule possédé depuis moins de 237 jours reçoit 81 points), de l'âge du véhicule, du nombre de sinistres passés (de l'assuré comme du véhicule), du nombre de polices actives ou encore des changements récents d'adresse. Ces signaux ont une pondération plus modérée, mais leur cumul peut significativement influencer le score final.

- Enfin, des **pénalités (signaux négatifs)** (points nuls ou faibles) sont attribuées aux situations jugées rassurantes, afin d'éviter une surévaluation du risque. Ainsi, un dossier où les autorités ont été contactées (Police, Pompiers, Ambulance) reçoit très peu de points, contre 59 points en leur absence ; de même, la présence d'au moins un témoin, un délai de déclaration long ou un véhicule ancien dans le portefeuille se traduisent par une contribution nulle ou négligeable au score. Ces ajustements permettent de rééquilibrer l'analyse.

Dans l'ensemble, ce barème repose sur une logique transparente et interprétable, combinant expertise métier et observations empiriques, afin de produire un score global reflétant le niveau de suspicion de fraude associé à chaque dossier.

Le modèle est ensuite appliqué à l'ensemble de la base sinistres. Pour chaque dossier, on additionne les points associés aux différentes caractéristiques observées. On obtient alors un **score global de suspicion**, qui synthétise le niveau de risque du sinistre au regard des signaux de fraude intégrés dans le modèle. Plus le score est élevé, plus le dossier présente un profil proche de celui des sinistres historiquement identifiés comme frauduleux.

Une fois les scores calculés, il est important de regarder leur distribution par classe (histogrammes superposés) de fraudeurs/non fraudeurs : visuellement, plus les deux distributions sont **séparées**, meilleur est le modèle.




FIGURE 5.5 – Distribution des scores par classe (fraudeur/non fraudeur)

On observe sur la figure 5.5 que les sinistres frauduleux sont principalement concentrés sur la droite du graphique, correspondant aux scores élevés, à l'inverse des sinistres non frauduleux qui sont concentrés à gauche.

L'analyse de la sortie du modèle ne se limite pas à la distribution des scores par classe. Il convient également de comparer les niveaux de score observés entre les sinistres frauduleux et les sinistres non frauduleux. Si le modèle est pertinent, les dossiers frauduleux doivent, en moyenne, présenter des scores plus élevés. Cette étape permet d'évaluer la capacité du scoring à séparer les deux populations et à hiérarchiser le risque de fraude de manière cohérente.




FIGURE 5.6 – Taux de fraude avérée par tranche de score de suspicion

À noter que les figures 5.5 et 5.6 mesurent la qualité prédictive sur le jeu de test, c'est-à-dire sur des sinistres que le modèle n'a pas vus lors de la phase d'apprentissage. Les indicateurs reflètent donc sa capacité de généralisation à de nouveaux dossiers, et non une simple performance sur les données d'entraînement.

La figure 5.6 met ici en évidence une relation croissante par paliers entre le score de suspicion et le taux de fraude avérée, ce qui confirme la capacité du modèle à discriminer efficacement les dossiers selon leur niveau de risque : plus le score est élevé, plus la probabilité de fraude augmente.

À partir de la distribution des scores et de la capacité discriminante du modèle, des seuils opérationnels peuvent être définis. Ces seuils permettent de transformer un score continu en règle de gestion. Par exemple, un score faible peut correspondre à une absence de recherche complémentaire, un score intermédiaire à une investigation légère, et un score élevé à une recherche approfondie. Le choix de ces seuils repose sur un arbitrage actuariel et opérationnel entre le coût des contrôles, le nombre de faux positifs acceptables et le gain attendu en matière de fraude détectée.

Dans notre exemple, on observe une première cassure autour de 350 points, à partir de laquelle le taux de fraude avérée augmente légèrement : ce premier changement de régime justifie le déclenchement d'une investigation légère. Une seconde cassure apparaît autour de 500 points, où le taux de fraude avérée croît nettement, seuil à partir duquel une investigation approfondie se justifie.

Autrement dit, les règles d'investigation suivantes peuvent être mises en place :

- score compris entre 0 et 350 : pas d'investigation ;
- score compris entre 350 et 500 : investigation légère ;
- score supérieur à 500 : investigation poussée.

Enfin, si l'on considère les sinistres classifiés comme nécessitant une investigation poussée comme « frauduleux » (score supérieur à 500), le score étant construit sur une échelle de 0 à 1 000 points, un seuil de 500 points équivaut à la moitié de l'échelle, soit 50 % ; c'est cette normalisation qui permet d'exprimer le seuil de décision en pourcentage dans la matrice de confusion. Dans notre choix graphique ci-dessus, on obtient la matrice de confusion suivante :

Matrice de confusion Seuil : 50%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	169	519	688
Réel Non fraude	16	5 296	5 312
Total	185	5 815	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.7 – Matrice de confusion du modèle de scoring en points pour un seuil de 50 %

Cette matrice permet de calculer :

- le taux de bien classés (prédit non-fraude / réel non-fraude) : $5\,296/5\,312 = 99,70\%$;
- le taux de fraude détectée (prédit fraude / réel fraude) : $169/688 = 24,56\%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une **optimisation du seuil** afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.1.2 Qualité du modèle obtenu

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles présentés en section ??.

Pour commencer, un point de vigilance mérite d'être souligné concernant le **choix du seuil de décision**. Le modèle ne restitue pas une classification binaire mais une probabilité de fraude ; il convient donc de fixer un seuil (*cut-off*) au-delà duquel un sinistre est considéré comme frauduleux. Le seuil de 0,5, retenu par convention, se révèle en réalité inadapté aux données fortement déséquilibrées : avec seulement 11,5 % de fraudes, la majorité des scores se concentrent sous 0,5, si bien que le modèle ne détecte qu'une fraction infime des fraudes réelles, d'où un rappel de seulement 24,6 % à ce seuil.

Pour corriger ce biais, on recourt à l'**indice de Youden**, défini comme :

$$J = \text{Sensibilité} + \text{Spécificité} - 1 \quad (5.1)$$

Cet indice identifie le seuil qui maximise l'écart entre le taux de vrais positifs (fraudes correctement détectées) et le taux de faux positifs (non-fraudes signalées à tort) ; il correspond graphiquement au point de la courbe ROC le plus éloigné de la diagonale du hasard, c'est-à-dire celui où le modèle sépare le mieux les deux populations.

Appliqué à ce modèle, le seuil optimal ressort à 35 %.

Les résultats du modèle obtenus avec l'utilisation de ce seuil sont présentés ci-dessous :

Matrice de confusion Seuil : 35%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	548	140	688
Réel Non fraude	746	4566	5312
Total	1294	4706	6000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.8 – Matrice de confusion au seuil optimal du modèle de scoring en points

Pour commencer, cette matrice permet de calculer :

- le taux de bien classés (réel non-fraude / prédit non-fraude) : $4566/5312 = 85,96 \%$;
- le taux de fraude détectée (prédit fraude / réel fraude) : $548/688 = 79,65 \%$;
- le taux de sinistres signalés frauduleux : $1294/6000 = 21,57 \%$.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 21,57 % des sinistres, parmi lesquels

42,35 % sont réellement frauduleux, soit une densité de fraude environ 3,7 fois supérieure à celle d'un contrôle aléatoire. L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :



FIGURE 5.9 – Synthèse des métriques de performance et de stabilité du modèle de scoring en points




FIGURE 5.10 – Courbe ROC-AUC correspondant au modèle de scoring en points

En retenant le seuil optimal de 35 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,910)** : excellente capacité de discrimination, très au-dessus du seuil de 0,8 considéré comme bon ; le modèle sépare efficacement fraudeurs et non-fraudeurs.
- **Gini (0,820)** : cohérent avec l'AUC, ce niveau traduit un pouvoir discriminant élevé, largement supérieur aux standards habituels en assurance.
- **KS (0,668)** : bien au-delà du seuil de 0,5, il confirme une nette séparation entre les distributions de scores des deux populations.
- **Précision (42,4 %)** : parmi les dossiers signalés comme frauduleux, un peu plus de quatre sur dix le sont réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (79,7 %)** : le modèle détecte près de quatre fraudes sur cinq, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (55,3 %)** : compromis honnête entre précision et rappel, en nette amélioration par rapport au seuil de 0,5.
- **Accuracy (85,2 %)** : taux de bonnes classifications élevé, à interpréter toutefois avec prudence sur données déséquilibrées où cet indicateur est peu informatif à lui seul.
- **Log-loss (0,2079)** : valeur faible, signe d'une bonne calibration des probabilités prédites.
- **Backtesting (écart AUC train/test de 0,002)** : écart quasi nul entre apprentissage et test, confirmant l'absence de surapprentissage et une bonne capacité de généralisation.
- **PSI (0,0014)** : très inférieur à 0,1, il atteste d'une parfaite stabilité de la distribution des scores.

Dans l'ensemble, le modèle présente d'excellents indicateurs de discrimination et de stabilité ; le seul point de vigilance concerne la précision modérée, contrepartie assumée d'un rappel volontairement élevé.

À ce seuil, le rappel passe de 24,6 % à 79,7 %, au prix d'une précision plus faible (42,4 % contre 91,3 %). Ce résultat est rassurant : il indique que le modèle est correctement calibré et que l'abaissement du seuil améliore nettement la détection.

Ces valeurs illustrent surtout un arbitrage fondamental propre à la détection de fraude sur données déséquilibrées : le modèle privilégie un rappel élevé (près de 80 % des fraudes détectées) au prix d'une précision plus modérée (environ quatre dossiers signalés sur dix sont réellement frauduleux). Ce compromis est cohérent avec l'enjeu métier : dans un contexte où le coût d'un faux négatif (une fraude non détectée, donc indemnisée à tort) est généralement bien supérieur à celui d'un faux positif (une investigation inutile mobilisant les équipes), il est préférable de maximiser la détection quitte à générer davantage de dossiers à contrôler. Le choix final du seuil ne relève donc pas d'une logique purement statistique mais

d'un arbitrage économique, qui rejoint directement l'analyse coût-bénéfice développée au chapitre ??.

Enfin, concernant les indicateurs de robustesse et de stabilité du modèle, les résultats suivants sont obtenus :




FIGURE 5.11 – Indicateurs de robustesse et de stabilité du modèle de scoring en points

Le modèle de *scoring* présente un écart quasi nul entre l'AUC d'entraînement (0,933) et l'AUC de validation (0,923), de l'ordre de 0,009. Cette proximité témoigne de l'absence de surapprentissage et d'une excellente capacité de généralisation à de nouvelles données. Le PSI¹, égal à 0,0008, très inférieur au seuil de 0,1, confirme par ailleurs une parfaite stabilité de la distribution des scores.

Ces résultats sont cohérents avec la nature du modèle : sa simplicité et sa parcimonie le rendent naturellement robuste et peu sujet au surajustement.

5.1.3 Limites et précautions d'interprétation

Il convient de rappeler qu'un *scoring* en points reste une modélisation simplifiée du risque de fraude. Sa performance dépend fortement de la qualité des données disponibles, de la pertinence des critères retenus et de la représentativité des fraudes observées historiquement. Il doit donc être régulièrement recalibré et suivi dans le temps afin de garantir sa robustesse et son adéquation aux évolutions des comportements frauduleux.

Malgré sa simplicité et son interprétabilité, le modèle de *scoring* en points présente plusieurs limites qu'il convient de prendre en compte dans l'analyse et l'utilisation opérationnelle de ce dernier. En particulier, il est important de noter que le score obtenu ne garantit pas une relation strictement croissante avec la probabilité réelle de fraude, ce qui peut limiter la qualité de la classification.

En théorie, un score de fraude devrait être monotone : plus le score est élevé, plus la probabilité qu'un

1. Population Stability Index : indicateur mesurant la dérive de la distribution des scores entre deux périodes. En deçà de 0,1, la population est considérée comme stable ; au-delà de 0,25, la dérive est importante.

sinistre soit frauduleux devrait augmenter. Or, dans un modèle de scoring en points, cette propriété n'est pas toujours vérifiée. Cela s'explique par la nature même de la construction du score, qui repose sur une agrégation additive de critères discrétisés, sans modélisation explicite des interactions complexes entre variables. Ainsi, deux dossiers ayant des combinaisons de caractéristiques différentes peuvent aboutir à un score identique, tout en présentant des niveaux de risque de fraude sensiblement différents.

Par ailleurs, la transformation de variables continues en classes (via des tranches ou des modalités) entraîne une perte d'information et peut introduire des effets de seuil artificiels. Cela peut conduire à des situations où une légère variation d'un critère modifie fortement le score, sans que le risque réel évolue de manière proportionnelle. Inversement, des différences significatives de profil peuvent être insuffisamment reflétées dans le score final.

Cette absence de stricte monotonie peut se traduire empiriquement par une instabilité des taux de fraude observés par tranche de score. Autrement dit, il est possible que certaines classes de score intermédiaires présentent un taux de fraude plus élevé que des classes de score supérieures, ce qui va à l'encontre de l'intuition attendue d'un bon modèle de *ranking*. Cela limite la capacité du score à ordonner parfaitement les dossiers selon leur risque.

En outre, le *scoring* en points ne fournit généralement pas une probabilité calibrée de fraude, mais plutôt un indicateur ordinal. L'interprétation du score en termes de probabilité nécessite des étapes supplémentaires de calibration, qui ne sont pas toujours mises en œuvre. Cela peut compliquer la définition optimale des seuils de décision et l'évaluation économique du modèle (coût des faux positifs vs gains liés à la fraude détectée).


Enfin, ce type de modèle est sensible aux biais présents dans les données historiques, notamment les biais de sélection liés aux fraudes détectées (toutes les fraudes ne sont pas observées) et les biais d'investigation (certains dossiers étant plus contrôlés que d'autres). Ces biais peuvent affecter la cohérence du score et accentuer les défauts de classement.

Ainsi, bien que le *scoring* en points constitue un outil robuste et interprétable, il doit être utilisé avec prudence, notamment lorsqu'il s'agit de hiérarchiser finement le risque de fraude ou d'interpréter le score comme une mesure probabiliste. Un suivi régulier de la performance (courbes de gains, lift, analyse par déciles) est nécessaire pour s'assurer que le modèle conserve une capacité de discrimination cohérente dans le temps.

5.2 Modèle arbre de décision

Cette section présente l'utilisation de la méthode « arbre de décision » pour estimer la probabilité de fraude.

5.2.1 Résultats du modèle



L'arbre construit admet les paramètres suivants :

- Profondeur : 5
- Feuilles : 67
- Nœuds internes : 66




FIGURE 5.12 – Paramètres du modèle arbre de décision

L'arbre construit admet les caractéristiques structurelles suivantes :

- **La profondeur (5)**, qui correspond au nombre maximal de niveaux de décision successifs entre la racine de l'arbre et ses feuilles. Concrètement, un dossier traverse au plus cinq coupures successives (cinq questions posées sur ses variables) avant d'aboutir à une prédiction. Cette profondeur a été volontairement limitée à 5 : un arbre trop profond mémoriserait les particularités de l'échantillon d'apprentissage (sur-apprentissage) et généraliserait mal à de nouveaux dossiers, tandis qu'un arbre trop peu profond serait incapable de capter les interactions entre variables. Une profondeur de 5 constitue ainsi un compromis entre pouvoir de discrimination et capacité de généralisation.
- **Les feuilles (67)** sont les nœuds terminaux de l'arbre, c'est-à-dire les points d'aboutissement où une décision finale est rendue (dossier classé frauduleux ou non). Chaque feuille regroupe un ensemble de dossiers partageant le même parcours de décision, et se voit attribuer une probabilité de fraude correspondant à la proportion de fraudes observée parmi les dossiers d'apprentissage qui y aboutissent. L'arbre compte ici 67 feuilles, soit 67 profils de risque distincts.
- **Les nœuds internes (66)** sont les points de décision situés avant les feuilles : à chaque nœud interne, l'arbre applique un test sur une variable (par exemple « le réparateur est-il signalé ? » ou « le montant réclamé dépasse-t-il un certain seuil ? ») qui oriente le dossier vers l'une ou l'autre branche. Le nombre de nœuds internes est directement lié au nombre de feuilles : un arbre binaire comportant 67 feuilles possède nécessairement 66 nœuds internes.




FIGURE 5.13 – Représentation visuelle de l’arbre avec un découpage sur une profondeur de 2 branches (5 branches au total)

L’agent retourne une représentation visuelle complète de l’arbre créé mais également d’autres graphiques², tels que la distribution des scores par classe (histogrammes superposés) : distribution du score des fraudeurs vs distribution du score des non-fraudeurs. Comme pour le modèle de *scoring* en points, visuellement, plus les deux distributions sont **séparées**, meilleur est le modèle.




FIGURE 5.14 – Distribution des scores par classe avec un arbre de décision (fraudeur/non fraudeur)

On observe sur ce graphique que la proportion de sinistres frauduleux (en rouge) augmente progressivement avec la probabilité estimée : quasi nulle dans les tranches basses, elle devient majoritaire dans les tranches les plus élevées ([90-100 %]). Cette progression témoigne d’un pouvoir de discrimination

2. Graphiques réalisés sur la base de l’échantillon test (6000 lignes) et non sur l’échantillon d’apprentissage du modèle.

réel, même si un chevauchement subsiste dans les tranches intermédiaires, et que l'on retrouve certaines fraudes avec des probabilités pourtant faibles, ce qui témoigne d'un défaut du modèle.

Comme pour le modèle de *scoring* en points, le second graphique retourné par l'agent est le taux de fraude avéré par tranche de probabilité en sortie de l'arbre. Si le modèle est pertinent, les dossiers frauduleux doivent, en moyenne, présenter des probabilités plus élevées. Cette étape permet d'évaluer la capacité de l'arbre à séparer les deux populations et à hiérarchiser le risque de fraude de manière cohérente.



FIGURE 5.15 – Taux de fraude avérée par tranche de score de suspicion

La sortie issue de l'arbre de décision met en évidence une relation claire et structurée entre la probabilité de fraude estimée par le modèle et le taux de fraude réellement observé. On observe une **progression à tendance croissante du taux de fraude** à mesure que la probabilité prédite augmente, ce qui traduit une bonne capacité du modèle à ordonner les dossiers selon leur niveau de risque. Les premières tranches de probabilité (faibles scores) présentent des taux de fraude très limités, tandis que les tranches les plus élevées concentrent une proportion significativement plus importante de fraudes, pouvant dépasser 75 %.

Cette montée progressive est particulièrement intéressante d'un point de vue opérationnel, car elle permet de **segmenter efficacement les dossiers** et de prioriser les investigations sur les cas les plus risqués.

Par ailleurs, les caractéristiques du modèle (profondeur maximale de 5) traduisent un compromis maîtrisé entre complexité et capacité de généralisation. Le modèle reste suffisamment lisible tout en capturant des patterns discriminants. En synthèse, cette sortie confirme que l'arbre de décision fournit une **hiérarchisation cohérente et exploitable du risque de fraude**, avec une forte concentration des cas frauduleux dans les segments de probabilité élevée.

Si l'on s'appuie sur la distribution observée, l'idée est de définir des seuils qui maximisent la détection tout en restant opérationnellement soutenables (ne pas envoyer trop de dossiers en investigation lourde).

On peut distinguer **trois zones de risque** assez naturelles :

- **Zone faible (<45 %)** : le taux de fraude reste globalement modéré (inférieur à ~10 %, sauf un pic isolé à 14 %). Ces dossiers peuvent être traités en flux standard, éventuellement avec des contrôles

légers automatisés.

- **Zone intermédiaire ($\approx 45\%$ à 85%)** : on observe une montée progressive du taux de fraude (environ 20% à $30\%+$) : un **seuil de vérification intermédiaire autour de $65\text{--}70\%$** paraît pertinent. À ce niveau, on commence à avoir un enrichissement significatif en fraude, tout en conservant un volume de dossiers encore gérable pour des contrôles ciblés (revue documentaire, demandes complémentaires, etc.).
- **Zone élevée ($> 85\%$)** : le taux de fraude devient nettement plus important (60% à plus de 70% sur les dernières tranches). Un **seuil de vérification poussée autour de 85%** est cohérent. Au-delà de ce seuil, on concentre fortement les fraudes, ce qui justifie des investigations approfondies (enquête terrain, expertise renforcée, gel du dossier, etc.).

Autrement dit, les règles d'investigation suivantes peuvent être mises en place :

- probabilité $< 45\%$: pas d'investigation ;
- probabilité comprise entre 45% et 85% : investigation légère ;
- probabilité supérieure à 85% : investigation poussée.

Enfin, si l'on considère les sinistres classifiés comme nécessitant une investigation poussée comme « frauduleux » (score supérieur à 80 dans notre choix graphique ici), on obtient la matrice de confusion suivante :

Matrice de confusion				Seuil : 85%
	Prédit Fraude	Prédit Non fraude	Total	
Réel Fraude	269	399	668	
Réel Non fraude	142	5 167	5 309	
Total	411	5 566	5 977	
Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)				

FIGURE 5.16 – Matrice de confusion du modèle arbre de décision pour un seuil de 85%

Cette matrice permet de calculer :

- le taux de bien classés (non-fraude prédite / non-fraude) : $5\,167/5\,309 = 97,33\%$;

- le taux de fraude détectée (prédit fraude / réel fraude) : $269/688 = 39,10 \%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une optimisation du seuil afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.2.2 Qualité du modèle obtenu

L'introduction d'un arbre de décision permet de franchir un cap significatif. En intégrant des interactions entre variables et des effets de seuil, le modèle améliore la structuration du risque et offre une segmentation plus nette du portefeuille. La hiérarchisation des dossiers est plus cohérente : les feuilles les plus risquées de l'arbre concentrent un taux de fraude très élevé, proche de 79 %, bien au-delà de ce que permettait le scoring en points. Le modèle gagne ainsi en pouvoir discriminant sur les segments extrêmes, tout en conservant une certaine lisibilité grâce à sa structure arborescente.

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles mis en place présentés en section ??.

Pour commencer, on cherche le seuil optimal à partir duquel on peut considérer que les sinistres sont frauduleux à l'aide de l'indicateur de Youden³ (présenté en section ??). Pour le modèle utilisant des arbres de décision, le seuil optimal est de 45 %.

Matrice de confusion Seuil : 45%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	512	156	668
Réel Non fraude	1 098	4 211	5 309
Total	1 610	4 367	5 977

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.17 – Matrice de confusion du modèle arbre de décision au seuil optimal (45 %)

Cette matrice permet de calculer :

- le taux de bien classés (non-fraude prédite / non-fraude) : $4\,211/5\,309 = 79,31 \%$;
- le taux de fraude détectée (prédit fraude / réel fraude) : $512/688 = 74,41 \%$;
- le taux de sinistres signalés : $1\,610/5\,977 = 26,94 \%$.

3. Notre agent intègre le calcul du seuil optimal dans son fonctionnement.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 26,94 % des sinistres, parmi lesquels 31,80 % sont réellement frauduleux, soit une densité de fraude environ 2,8 fois supérieure à celle d'un contrôle aléatoire. L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :




FIGURE 5.18 – Synthèse des métriques de performance et de stabilité du modèle arbre de décision au seuil 45 %



FIGURE 5.19 – Courbe ROC et AUC pour le modèle arbre de décision

En retenant le seuil optimal de 45 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,852)** : excellente capacité de discrimination, très au-dessus du seuil de 0,8 considéré comme bon ; le modèle sépare efficacement fraudeurs et non-fraudeurs.
- **Gini (0,704)** : cohérent avec l'AUC, ce niveau traduit un pouvoir discriminant élevé, largement supérieur aux standards habituels en assurance.
- **KS (0,568)** : bien au-delà du seuil de 0,5, il confirme une nette séparation entre les distributions de scores des deux populations.
- **Précision (31,8 %)** : parmi les dossiers signalés comme frauduleux, un peu plus de trois sur dix le sont réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (76,6 %)** : le modèle détecte près de trois fraudes sur quatre, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (45,0 %)** : compromis correct entre précision et rappel.

- **Accuracy (79,0 %)** : taux de bonnes classifications élevé, à interpréter toutefois avec prudence sur données déséquilibrées où cet indicateur est peu informatif à lui seul.
- **Log-loss (0,4724)** : valeur modérée, traduisant une calibration des probabilités prédites correcte mais perfectible.

Enfin, concernant les indicateurs de robustesse et stabilité du modèle, les résultats suivants sont obtenus :




FIGURE 5.20 – Indicateurs de robustesse et stabilité du modèle arbre de décision

L'arbre de décision affiche un écart un peu plus marqué entre l'AUC d'entraînement (0,877) et l'AUC de validation (0,838), soit 0,039. Ce léger écart, signalé comme point de vigilance, traduit une tendance modérée au surapprentissage, caractéristique des arbres de décision dont la structure s'ajuste finement aux données d'entraînement. Il reste toutefois contenu et n'entame pas significativement la capacité de généralisation. Le PSI, à 0,0026, demeure très faible et atteste d'une bonne stabilité de la distribution des scores dans le temps.

5.2.3 Limites et précautions d'interprétation

Les arbres de décision constituent une avancée significative par rapport aux modèles de *scoring* en points, notamment par leur capacité à modéliser des interactions entre variables et à capturer des effets de seuil. Toutefois, ils présentent également un certain nombre de limites qu'il convient de considérer dans une utilisation opérationnelle.

En premier lieu, les arbres de décision sont **intrinsèquement instables** : de légères variations dans les données d'apprentissage peuvent conduire à des structures d'arbre sensiblement différentes. Cette sensibilité aux données peut impacter la robustesse du modèle et limiter sa capacité de généralisation sur de nouveaux portefeuilles. En d'autres termes, un arbre construit sur un échantillon donné peut ne pas reproduire exactement les mêmes règles de décision sur un autre échantillon pourtant similaire.

Par ailleurs, bien que les arbres permettent de capter des relations non linéaires, ils reposent sur une logique de **partitionnement par seuils successifs**, ce qui introduit des discontinuités dans la modélisation. Deux dossiers très proches peuvent ainsi être classés dans des feuilles différentes et se voir attribuer des probabilités de fraude sensiblement différentes, ce qui peut nuire à la stabilité des prédictions.

En outre, les arbres de décision ont tendance à **sur-apprendre** les données d'entraînement, en particulier lorsque leur profondeur est élevée ou que les contraintes de construction ne sont pas suffisamment strictes. Ce phénomène se traduit par une excellente performance sur les données d'apprentissage, mais une dégradation sur des données nouvelles. Des techniques de régularisation (élagage, limitation de profondeur, nombre minimal d'observations par feuille) sont donc nécessaires pour contrôler cette complexité.

Un autre point de vigilance concerne la **calibration des probabilités**. Les probabilités issues des feuilles de l'arbre (basées sur des proportions observées) peuvent être peu fiables, notamment lorsque les feuilles contiennent un nombre limité d'observations. Cela peut compliquer l'interprétation directe des scores en termes de probabilité de fraude et la définition de seuils décisionnels optimaux.

Enfin, bien que les arbres soient souvent considérés comme interprétables, cette interprétabilité peut rapidement se dégrader dès que la structure devient plus complexe (multiplication des branches et des feuilles). La lecture globale du modèle peut alors devenir difficile, en particulier pour des utilisateurs non techniques.

Ainsi, les arbres de décision offrent un bon compromis entre performance et lisibilité, mais nécessitent un encadrement méthodologique rigoureux pour garantir leur stabilité, leur robustesse et leur capacité de généralisation.

5.3 Machine learning Gradient Boosting

Enfin, le dernier modèle à être testé et dont les résultats sont présentés ci-dessous est un modèle de Machine Learning « Gradient Boosting ».



5.3.1 Résultats du modèle

Les paramètres du modèle de gradient boosting créé sont les suivants :




FIGURE 5.21 – Paramètres du modèle Gradient Boosting

- **Le nombre d'arbres (200)** correspond au nombre de modèles élémentaires construits successivement. Dans le *boosting*, chaque nouvel arbre corrige les erreurs résiduelles des précédents ; l'accumulation de 200 arbres permet d'affiner progressivement la prédiction.
- **La profondeur maximale (3)** limite chaque arbre à trois niveaux de coupures. Des arbres volontairement peu profonds (« arbres faibles ») sont caractéristiques du *boosting* : leur pouvoir prédictif individuel est limité, mais leur combinaison séquentielle produit un modèle performant tout en réduisant le risque de surapprentissage.
- **Le taux d'apprentissage (0,1)** pondère la contribution de chaque arbre au modèle final. Une valeur faible ralentit l'apprentissage mais le rend plus stable et plus robuste, chaque arbre n'apportant qu'une correction mesurée.
- **Le sous-échantillonnage (0,8)** signifie que chaque arbre est entraîné sur 80 % des observations, tirées aléatoirement. Cette introduction de hasard limite le surapprentissage et améliore la capacité de généralisation du modèle.

Comme pour les deux autres modèles précédents, l'Agent IA retourne dans un premier temps la distribution du nombre de sinistres par tranche de 5 % de probabilité selon l'état du sinistre (frauduleux ou non).




FIGURE 5.22 – Distribution des scores par classe (fraudeur/non fraudeur)

Le modèle *Gradient Boosting* présente une très bonne séparation des deux classes. La grande majorité des sinistres non frauduleux se concentre dans les tranches de faible probabilité (inférieures à 20 %) tandis que la part de sinistres frauduleux (en rouge) croît fortement dans les tranches élevées, devenant prépondérante autour des scores supérieurs à 80 %.

Ce basculement net, ainsi que le moindre chevauchement des distributions par rapport aux deux modèles précédents confirment la supériorité du *Gradient Boosting* en matière de discrimination entre dossiers frauduleux et sains.

Dans un second temps, l'Agent affiche la performance du modèle au travers de l'indicateur de taux de fraude avéré par tranche de probabilité.




FIGURE 5.23 – Taux de fraude avérée par tranche de score de suspicion

Ces graphiques mesurent la qualité prédictive du modèle sur le jeu de test, c'est-à-dire sur des sinistres qui n'ont pas été utilisés par le modèle lors de l'apprentissage. Les indicateurs reflètent donc sa capacité de généralisation à de nouveaux dossiers, et non une simple performance sur les données d'entraînement.

La sortie du modèle *Gradient Boosting* met en évidence une capacité de discrimination particulièrement élevée entre les dossiers frauduleux et non frauduleux. On observe une augmentation très marquée du taux de fraude avérée à mesure que la probabilité estimée croît, ce qui traduit une excellente cohérence entre les prédictions du modèle et la réalité observée sur les données d'apprentissage.

Contrairement aux modèles plus simples, la montée du taux de fraude est ici beaucoup plus rapide et plus prononcée. Au-delà de 80 %, on entre dans une zone où plus d'un sinistre sur deux est frauduleux, jusqu'à des taux proches de 100 % sur la tranche la plus élevée. Cela signifie que le modèle concentre très efficacement les fraudes dans les segments à forte probabilité.

Cette performance s'explique par la capacité du *Gradient Boosting* à capter des relations complexes, non linéaires et des interactions fines entre variables, ce qui lui permet d'identifier des schémas de fraude difficiles à détecter avec des approches plus classiques.

D'où les zones d'investigation suivantes :

- **Zone faible (<60 %)** : le taux de fraude reste globalement modéré (inférieur à ~15 %). Ces dossiers peuvent être traités en flux standard, éventuellement avec des contrôles légers automatisés.
- **Zone intermédiaire (≈ 60 % à 80 %)** : on observe une montée progressive du taux de fraude (environ 25 % à 40 %). À ce niveau, on commence à avoir un enrichissement significatif en fraude, tout en conservant un volume de dossiers encore gérable pour des contrôles ciblés (revue documentaire, demandes complémentaires, etc.).
- **Zone élevée (> 80 %)** : le taux de fraude devient nettement plus important (50 % à plus de 90 % sur les dernières tranches). Un **seuil de vérification poussée autour de 80 %** est cohérent. Au-delà de ce seuil, on concentre fortement les fraudes, ce qui justifie des investigations approfondies (enquête terrain, expertise renforcée, gel du dossier, etc.).

Matrice de confusion Seuil : 80%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	445	243	688
Réel Non fraude	117	5 195	5 312
Total	562	5 438	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.24 – Matrice de confusion du modèle Gradient Boosting pour un seuil de 80 %

Cette matrice permet de calculer :

- le taux de bien classés (non-fraude prédite / non-fraude) : $5\,195/5\,312 = 97,80\%$;
- le taux de fraude détectée (prédit fraude / réel fraude) : $445/688 = 64,68\%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une optimisation du seuil afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.3.2 Qualité du modèle obtenu

Le recours à une méthode ensembliste comme le *Gradient Boosting* marque une rupture en termes de performance. Le modèle parvient à capturer des relations complexes et non linéaires, ce qui se traduit par une courbe de risque nettement plus régulière et globalement monotone.

La concentration des fraudes dans les tranches de probabilité élevées est particulièrement marquée, avec des taux atteignant jusqu'à 100 % sur les segments les plus extrêmes (sur données d'apprentissage).

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles mis en place présentés en section ??.

Pour commencer, on cherche le seuil optimal à partir duquel on peut considérer que les sinistres sont frauduleux à l'aide de l'indicateur de Youden (présenté en section ??). Pour le modèle utilisant de *Gradient Boosting*, le seuil optimal est de 50 %.

Matrice de confusion Seuil : 50%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	576	112	688
Réel Non fraude	532	4780	5312
Total	1108	4892	6000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.25 – Matrice de confusion du modèle Gradient Boosting avec un seuil de 50 %

Cette matrice permet de calculer :

- le taux de bien classés (non-fraude prédite / non-fraude) : $4780/5312 = 89,98 \%$;
- le taux de fraude détectée (prédit fraude / réel fraude) : $576/688 = 82,41 \%$;
- le taux de sinistres signalés : $1108/6000 = 18,47 \%$.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 18,47 % des sinistres, parmi lesquels 51,99 % sont réellement frauduleux, soit une densité de fraude environ 4,5 fois supérieure à celle d'un contrôle aléatoire. L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :




FIGURE 5.26 – Synthèse des métriques de discrimination et classification du modèle Gradient Boosting au seuil 50 %



FIGURE 5.27 – Courbe ROC et AUC pour le modèle Gradient Boosting

En retenant le seuil optimal de 50 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,942)** : excellente capacité de discrimination, très au-dessus du seuil de 0,8 considéré comme bon ; le modèle sépare efficacement fraudeurs et non-fraudeurs.
- **Gini (0,885)** : cohérent avec l'AUC, ce niveau traduit un pouvoir discriminant élevé, largement supérieur aux standards habituels en assurance.
- **KS (0,740)** : bien au-delà du seuil de 0,5, il confirme une nette séparation entre les distributions de scores des deux populations.
- **Précision (52,0 %)** : parmi les dossiers signalés comme frauduleux, environ un sur deux l'est réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (83,7 %)** : le modèle détecte plus de quatre fraudes sur cinq, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (64,1 %)** : bon compromis entre précision et rappel.

- **Accuracy (89,3 %)** : taux de bonnes classifications élevé.
- **Log-loss (0,2724)** : valeur faible, signe d'une bonne calibration des probabilités prédites.

Enfin, concernant les indicateurs de robustesse et stabilité du modèle, les résultats suivants sont obtenus :




FIGURE 5.28 – Indicateurs de robustesse et stabilité du modèle Gradient Boosting

Le gradient boosting atteint les meilleures performances de discrimination, avec une AUC de validation de 0,942, tout en conservant un écart maîtrisé avec l'AUC d'entraînement (0,968), soit 0,026. Cet écart, jugé stable, confirme l'absence de surapprentissage malgré la puissance du modèle, ce qui témoigne de l'efficacité de sa régularisation (arbres peu profonds, sous-échantillonnage, taux d'apprentissage modéré). Le PSI, égal à 0,0023, très inférieur au seuil d'alerte, garantit enfin une excellente stabilité de la distribution des scores.

5.3.3 Limites et précautions d'interprétation

Le *gradient boosting* constitue le modèle le plus performant de cette étude, grâce à sa capacité à combiner un grand nombre d'arbres faibles corrigeant successivement leurs erreurs. Cette puissance s'accompagne toutefois de plusieurs limites qu'il convient de considérer dans une utilisation opérationnelle.

En premier lieu, le *gradient boosting* est un modèle nettement moins interprétable que les précédents. Là où un arbre unique ou un *scoring à point* offrent une lecture directe des règles de décision, la combinaison de deux cents arbres rend la logique globale difficile à retracer.

L'interprétation ne peut plus se faire directement sur la structure du modèle et nécessite le recours à des méthodes d'explicabilité complémentaires (importance des variables, valeurs de Shapley), qui restent des approximations et demandent une expertise spécifique.

Par ailleurs, le modèle est particulièrement sensible au réglage de ses hyperparamètres. Le nombre

d'arbres, la profondeur, le taux d'apprentissage ou le sous-échantillonnage influencent fortement la performance et la robustesse : un paramétrage mal maîtrisé peut conduire à un surapprentissage, le modèle s'ajustant trop finement aux données d'entraînement au détriment de sa capacité de généralisation. Un encadrement méthodologique rigoureux, via une validation appropriée, est donc indispensable.

En outre, comme tout modèle supervisé, le *gradient boosting* reste dépendant de la qualité et de la représentativité des données historiques. Il peut amplifier certains biais présents dans les données (biais de détection ou d'investigation) et reproduire des schémas passés qui ne reflètent pas nécessairement les fraudes futures.

Enfin, la calibration des probabilités mérite attention : les scores produits ne sont pas toujours directement interprétables comme des probabilités exactes, ce qui justifie une étape de calibration et un choix réfléchi du seuil de décision.

Ainsi, le *gradient boosting* offre les meilleures performances prédictives de l'étude, mais au prix d'une moindre interprétabilité et d'une plus grande complexité de mise en œuvre, qui imposent un cadre de validation et de suivi rigoureux.

5.4 Comparaison des modèles

Une fois les trois modèles présentés, le passage ci-dessous permet de faire une synthèse et comparaison des résultats obtenus pour orienter le choix du modèle finalement retenu parmi les trois modèles testés par l'Agent IA.

Ci-dessous, un tableau récapitulatif des différents indicateurs de qualité selon le modèle testé.

Indicateur	Scoring en point	Arbre de décision	Gradient Boosting
AUC-ROC	0,923	0,838	0,942
Gini	0,846	0,676	0,885
KS	0,688	0,565	0,74
Lift @10 %	—	×4,61	×6,66
PSI	0,0008	0,0026	0,0023
Écart Backtesting	0,009	0,039	0,026

TABLE 5.1 – Synthèse des résultats des indicateurs de qualité des différents modèles

Stabilité et robustesse des modèles

Les trois modèles présentent une stabilité temporelle remarquable, avec des valeurs de PSI très inférieures au seuil d'alerte de 0,10 (0,0008 pour le *scoring en points*, 0,0026 pour l'arbre de décision et 0,0023 pour le gradient boosting). Ces valeurs attestent d'une distribution homogène des scores entre les échantillons

d'entraînement et de validation, et confirment que les modèles ne sont pas sensibles à des dérives temporelles sur la période considérée. Par ailleurs, le backtesting en split 80/20 révèle une bonne capacité de généralisation : les écarts entre AUC d'entraînement et AUC de validation restent contenus (0,009 pour le scoring en points, 0,039 pour l'arbre de décision et 0,026 pour le gradient boosting). Le *scoring en points* affiche l'écart le plus faible, cohérent avec sa simplicité, tandis que l'arbre de décision présente l'écart le plus marqué, traduisant sa tendance connue au surapprentissage ; celui-ci reste toutefois modéré et n'entame pas significativement la robustesse du modèle.

Analyse du compromis précision / rappel et choix du seuil de décision

Au terme de cette comparaison, le **Gradient Boosting s'impose comme le modèle retenu**, car il offre le meilleur pouvoir discriminant des trois approches testées : une AUC de 0,942, un Gini de 0,885 et un lift de $\times 6,66$ au premier décile. Il devance nettement l'arbre de décision (AUC de 0,838, Gini de 0,676, lift de $\times 4,61$) et, plus légèrement, le scoring en points (AUC de 0,923, Gini de 0,846). Sa capacité à concentrer la fraude dans les premiers déciles en fait l'outil le plus efficace pour prioriser les dossiers à investiguer, ce qui correspond précisément à l'objectif opérationnel poursuivi.

Ce choix ne disqualifie pas pour autant le **scoring en points, qui demeure un modèle remarquablement performant au regard de sa simplicité**. Avec une AUC de 0,923 et un Gini de 0,846, il se situe très près du Gradient Boosting et loin devant l'arbre de décision, tout en conservant une transparence et une interprétabilité que les méthodes d'ensemble ne permettent pas. Il constitue donc une alternative pleinement crédible lorsque l'explicabilité prime sur le dernier point de performance, par exemple pour une présentation aux gestionnaires ou dans un contexte réglementaire exigeant. Le choix entre ces deux modèles relève ainsi d'un arbitrage entre performance pure (Gradient Boosting) et interprétabilité (scoring en points), l'arbre de décision étant quant à lui écarté, dominé sur l'ensemble des critères.

Enfin, quel que soit le modèle retenu, la lecture des performances appelle une nuance commune. Le compromis entre précision et rappel est la conséquence directe du fort déséquilibre des classes dans les données de sinistres. D'un point de vue actuariel, ce ratio doit être piloté explicitement : modifier le seuil de décision permet d'ajuster le rappel au prix d'un volume plus ou moins élevé de dossiers à investiguer. Le choix optimal de ce curseur dépend du coût asymétrique des deux types d'erreurs : un faux négatif (fraude non détectée) engendre une perte indemnisée à tort, tandis qu'un faux positif (investigation inutile) représente un coût opérationnel pour la cellule fraude. C'est précisément pour cette raison que l'outil développé laisse à l'utilisateur le soin de manipuler dynamiquement le curseur des seuils de détection (*cut-off*), afin d'adapter le dispositif au contexte et à l'appétence au risque de chaque assureur.

Configuration finale du modèle

La dernière étape de l'Agent IA de création du modèle d'aide à la détection de fraude consiste à l'enregistrement du modèle choisi.

Pour ce faire, l'utilisateur doit confirmer le modèle retenu ainsi que le seuil optimal.

Un seuil d'investigation fixé par défaut à $\pm 10\%$ ⁴ du seuil optimal sera retenu, par exemple ici, pour un seuil optimal de 50 %, trois zones d'investigations seront mises en place :

- probabilité de fraude $< 40\%$: pas d'investigation ;
- probabilité de fraude entre 40 % et 60 % : investigation légère ;
- probabilité de fraude supérieure à 60 % : investigation à lancer.




FIGURE 5.29 – Configuration finale du modèle et des seuils d'investigation

Une fois cette dernière étape réalisée, l'outil mis à disposition du service de détection des fraudes est configuré avec ce modèle et ces seuils d'investigation.

Ces derniers ne sont pas modifiables dans le second outil. Seul le premier Agent IA doit être relancé pour modifier le modèle sous-jacent de modélisation de la probabilité de fraude.

4. Ces seuils d'investigation peuvent être modifiés par l'utilisateur s'il le souhaite.

Chapitre 6

Outil mis à disposition du service de détection des fraudes

Le présent chapitre traite à présent du second outil créé à l'aide de l'Intelligence Artificielle.

Ce dernier se présente sous forme d'une interface utilisateur proposant trois fonctionnalités :

1. Évaluer un ou plusieurs nouveaux sinistres : l'utilisateur dépose un fichier contenant des informations sinistres pour estimer, pour chaque dossier, sa probabilité de fraude intrinsèque ;
2. Renseigner le résultat de fraude de sinistres testés précédemment : cela permettra d'enrichir la base de données utilisée pour la construction du modèle dans l'outil précédent ;
3. Consulter le bilan annuel de fraude : l'utilisateur peut lire les analyses sur les fraudes de l'année (montant économisé, rapport sur les mécanismes de fraudes récurrents, etc.).

Ces différentes fonctionnalités seront décrites en détail dans les paragraphes suivants.

Scoring — nouveaux sinistres

Que souhaitez-vous faire ?




FIGURE 6.1 – Écran interactif d'accueil du second outil

6.1 Utilisation pratique de l'outil

L'outil mis à disposition du service de détection des fraudes constitue la traduction opérationnelle du modèle de détection des fraudes développé en amont. Il s'inscrit dans une logique d'**aide à la décision fondée sur une estimation probabiliste du risque de fraude**, permettant d'orienter de manière cohérente et homogène les actions de contrôle sur les sinistres.

En amont de son utilisation, les seuils de décision sont définis par l'actuaire en charge du modèle, puis transmis aux gestionnaires sinistres pour paramétrage dans l'outil. Ces seuils permettent de segmenter l'espace des probabilités en différentes zones de risque.

À ce stade, on retient à titre illustratif le dernier modèle (*Gradient Boosting*) et les seuils suivants :

$$Seuil_{inf} = Seuil_{optimal} - 10 \%$$

$$Seuil_{sup} = Seuil_{optimal} + 10 \%$$

Ce qui crée naturellement les trois zones :

- une zone de faible risque (verte) : $[0 ; Seuil_{inf}[$;
- une zone de risque intermédiaire (orange) : $[Seuil_{inf} ; Seuil_{sup}[$;
- une zone de risque élevé (rouge) : $[Seuil_{sup} ; 100 \%)$.

Ces seuils traduisent un arbitrage actuariel entre le **coût des investigations** (notamment en termes de ressources mobilisées et de délais de gestion) et le **gain attendu lié à la détection de fraude**, en tenant compte des taux de faux positifs et de faux négatifs.

Lorsque l'utilisateur clique sur « tester de nouveaux sinistres », l'outil demande ensuite à l'utilisateur de renseigner les caractéristiques d'un ou plusieurs sinistres pour lancer l'analyse. Cette intégration peut s'effectuer de deux manières : soit de façon industrielle par le dépôt d'un fichier standardisé, soit de manière unitaire via un formulaire de saisie manuelle (cf. illustration ci-dessous).

Fichier CSV à évaluer

Sans la colonne `fraud_reported`



Glissez-déposez votre CSV ici, ou cliquez

Sans `fraud_reported`

Ces flux d'entrée reprennent exactement les mêmes variables explicatives que notre base de modélisation (franchise, âge, profession, type d'incident, montants, etc.), mais sans intégrer la colonne cible de fraude avérée (`fraud_reported`).

Ou saisir un sinistre à la main

Renseignez les champs du sinistre à évaluer

N° de police ex: POL-2024-00123	État du contrat ex: OH
Franchise (€) ex: 500	Prime annuelle (€) ex: 1200
Âge assuré ex: 42	Sexe assuré MALE ou FEMALE
Niveau d'études ex: Bachelor	Profession ex: exec-managerial
Loisirs ex: chess	Date incident ex: 2024-01-15
Type d'incident ex: Vehicle Theft	Type de collision ex: Rear Collision
Gravité ex: Major Damage	Autorités contactées ex: Police
État incident ex: OH	Ville incident ex: Columbus
Heure incident (0-23) ex: 14	Nb véhicules impliqués ex: 2
Blessures corporelles ex: 1	Témoins ex: 1
Rapport police YES ou NO	Montant réclamé (€) ex: 8500
Montant total réclamé (€) ex: 12500	

FIGURE 6.2 – Saisie manuelle des informations sinistre pour évaluation de la probabilité de fraude

Sur la base des informations sinistre renseignés, le modèle calcule une **probabilité de fraude en appliquant le modèle retenu dans l'outil de modélisation de la fraude**.

Cette probabilité constitue une mesure synthétique du risque, intégrant l'ensemble des signaux de fraude identifiés lors de la phase de modélisation.

La décision opérationnelle repose alors sur la **comparaison de cette probabilité aux seuils définis dans l'outil précédent (enregistrés en paramètres)**. Chaque sinistre est ainsi affecté à une classe de risque, à laquelle est associée une stratégie de gestion différenciée :

- absence d'investigation pour les niveaux faibles ;
- contrôles ciblés pour les niveaux intermédiaires ;

— et investigations approfondies pour les niveaux élevés.

Ce dispositif permet d'optimiser la **fonction de coût globale** du processus de détection, en concentrant les efforts sur les dossiers présentant le meilleur ratio entre probabilité de fraude et coût d'investigation.




FIGURE 6.3 – Probabilité en sortie de l'outil et action à mener en fonction des seuils renseignés

À titre d'illustration, sur un échantillon test de 500 sinistres, l'outil réalise un filtrage puissant en isolant immédiatement 474 dossiers en zone verte (ne nécessitant aucune investigation humaine), 21 dossiers en zone orange (à surveiller ou contrôler superficiellement) et seulement 5 dossiers en zone rouge (faisant l'objet d'une alerte prioritaire).

Ainsi, l'outil s'inscrit dans une démarche actuarielle classique de **segmentation du risque et de prise de décision sous contrainte**, en transformant une estimation probabiliste issue du modèle en règles de gestion opérationnelles directement exploitables par les équipes métiers.

L'utilisation d'un tel outil présente plusieurs avantages majeurs dans le cadre de la détection de fraude, tant d'un point de vue actuariel qu'opérationnel. En premier lieu, il permet de **standardiser l'évaluation du risque de fraude** en s'appuyant sur un modèle statistique commun, appliqué de manière homogène à l'ensemble des sinistres. Cette standardisation réduit significativement les **variabilités de traitement entre gestionnaires**, liées à l'expérience, à la subjectivité ou à la sensibilité individuelle au risque, et garantit une plus grande cohérence dans les décisions prises.

En outre, l'outil favorise une **objectivation du processus de décision** en reposant sur une estimation probabiliste issue de données historiques. Il limite ainsi les biais cognitifs (sur- ou sous-estimation du risque, effet d'ancrage, etc.) et permet d'inscrire la détection de fraude dans une démarche plus rigoureuse et traçable. Chaque décision d'investigation peut être justifiée par un niveau de risque mesuré, ce qui améliore la **transparence et l'auditabilité** des pratiques.

Par ailleurs, en segmentant les sinistres selon leur niveau de risque, l'outil permet une **allocation optimale des ressources d'investigation**. Les dossiers les plus susceptibles d'être frauduleux sont priorisés,

ce qui augmente l'efficacité globale du dispositif tout en maîtrisant les coûts liés aux contrôles. Cette approche s'inscrit dans une logique actuarielle d'optimisation du couple **coût de détection / gain attendu**, en maximisant la rentabilité des actions de lutte contre la fraude.

Enfin, cet outil constitue un levier d'**harmonisation et de pilotage** à l'échelle du portefeuille. Il permet de suivre la performance du dispositif (taux de fraude détectée, taux de transformation des contrôles, etc.), d'ajuster les seuils de décision en fonction des résultats observés, et d'assurer une meilleure comparabilité dans le temps. Il contribue ainsi à structurer la fonction fraude autour d'indicateurs quantitatifs et d'une approche pilotée par la donnée.

6.2 Un outil permettant l'enrichissement du modèle en continu

Dans une logique d'amélioration continue, l'outil intègre un mécanisme de boucle de retour d'information (feedback loop) permettant d'enrichir progressivement la base de données d'apprentissage. Ce mécanisme repose sur une base historique, dans laquelle sont automatiquement archivés l'ensemble des sinistres soumis à l'outil, accompagnés de la probabilité de fraude qui leur a été attribuée.

Lorsque l'utilisateur soumet un nouveau sinistre pour estimer sa probabilité de fraude, le dossier scodé rejoint la base historique.

Au moment du calcul de la probabilité de fraude, la base historique ne contient toutefois pas encore l'information la plus précieuse pour le modèle : l'issue réelle du dossier. En effet, savoir si un sinistre s'est effectivement révélé frauduleux n'est connu qu'à l'issue de son instruction, souvent plusieurs semaines ou mois après la déclaration. C'est ce constat qui structure la logique d'enrichissement retenue.

Plutôt que de demander au gestionnaire de statuer immédiatement sur une fraude qu'il ne peut encore confirmer, l'outil lui permet de revenir à tout moment dans la base historique pour y renseigner le statut final d'un ou plusieurs sinistres (fraude avérée ou non). Cette dissociation entre le moment du scoring et le moment de la qualification reflète fidèlement la réalité opérationnelle de la gestion des sinistres, où le dénouement d'un dossier est par nature différé.

POL100029
×

Single Vehicle Collision · 97 % de risque · 17483 €

Décision à enregistrer
 Documentez le statut de fraude et les montants associés à ce sinistre.

Statut fraude *

Fraude
 Pas de fraude

Date de décision

14/08/2026
 

Montant hors fraude (€)

0

 Part légitime à indemniser.

Impact financier (€)

0

 Fraude évitée ou impact estimé.

Motif

Ex : déclaration incohérente

Commentaire

Observations libres du gestionnaire...

Enregistrer le résultat

FIGURE 6.4 – Feuille de renseignement d'un sinistre

Une fois cette issue renseignée, le sinistre concerné dispose désormais d'un couple complet : ses caractéristiques d'entrée d'une part, et sa variable cible de fraude (*fraud_reported*) d'autre part. Il devient alors une observation exploitable pour l'apprentissage, au même titre que les données ayant servi à la construction initiale du modèle.

L'enrichissement de la base de données ne modifie pas le modèle de façon instantanée. Le réentraînement s'effectue en repassant par le module de construction (Module 1), qui réapprend le modèle sur la base augmentée des nouvelles observations qualifiées. En pratique, cette opération est menée à intervalle régulier, typiquement une fois par an, afin d'intégrer un volume significatif de nouveaux cas tout en garantissant la stabilité du dispositif entre deux mises à jour.

Cette approche présente plusieurs intérêts sur le plan actuariel. D'abord, elle permet d'augmenter la taille

et la représentativité de la base d'apprentissage, en y intégrant des cas récents qui reflètent l'évolution des comportements frauduleux. Elle contribue ainsi à réduire le décalage entre les données historiques initiales et la réalité opérationnelle, dans un contexte où les schémas de fraude évoluent rapidement.

Ensuite, ces nouvelles observations permettent un recalibrage et une réestimation réguliers du modèle : actualisation des paramètres, amélioration de la capacité de discrimination et, le cas échéant, réajustement de la pondération des variables. L'objectif est de maintenir dans le temps une performance prédictive stable, mesurée à l'aide d'indicateurs tels que l'AUC, le Gini ou les courbes de gains, et de surveiller l'absence de dérive du modèle (via le PSI notamment).

Enfin, l'intégration systématique des issues réelles permet de mieux maîtriser certains biais inhérents aux dispositifs de détection, en particulier le biais de sélection lié aux dossiers investigués. En alimentant la base avec les décisions finales issues de l'ensemble des sinistres traités (et non des seuls dossiers ayant fait l'objet d'une alerte) le modèle gagne en robustesse et en cohérence.

Ainsi, l'outil ne se limite pas à une utilisation statique du modèle : il s'inscrit dans une démarche dynamique de modélisation itérative, où chaque sinistre qualifié vient affiner la connaissance du risque et améliorer la pertinence du dispositif de détection.

6.3 Un outil de pilotage : le rapport annuel de détection de fraude

Au-delà du scoring individuel des sinistres, l'outil intègre une fonctionnalité de pilotage offrant une vision agrégée de la performance du dispositif sur une période donnée. Ce rapport annuel constitue la synthèse cumulative de l'activité de détection : il s'appuie sur la base historique H , une fois les issues réelles des sinistres renseignées, pour mesurer l'efficacité effective de l'outil et son apport économique.

Cette vue de synthèse répond à un besoin actuariel essentiel : ne pas se limiter à une utilisation opérationnelle au fil de l'eau, mais disposer d'indicateurs consolidés permettant d'évaluer, de justifier et d'ajuster le dispositif dans le temps.




FIGURE 6.5 – Exemple de rapport annuel de la détection de fraude

Les premiers indicateurs portent sur le **volume et la détection** : nombre de sinistres testés, nombre d'alertes générées par le modèle et nombre de fraudes effectivement confirmées après investigation. Leur mise en regard permet d'apprécier la charge de travail générée par l'outil et le taux de concrétisation des alertes.

Viennent ensuite les indicateurs **financiers**, au cœur de l'enjeu actuariel. Le montant de fraude évitée agrège les sinistres frauduleux confirmés qui n'ont pas donné lieu à indemnisation grâce à l'outil. Surtout, l'impact sur le **ratio Sinistres / Primes (S/P)** traduit directement le gain apporté par la détection sur l'équilibre technique du portefeuille : en écartant une partie de la charge frauduleuse, l'outil améliore mécaniquement ce ratio. Cet indicateur fait le lien avec l'analyse développée au chapitre 1 : là où nous avons modélisé la surprime supportée par les assurés honnêtes par la relation $\Pi_{\text{chargée}} = \frac{\Pi_{\text{pure}}}{1-\alpha}$, le rapport annuel permet de quantifier *a posteriori* la part de charge frauduleuse α effectivement récupérée, et donc l'effet réel de l'outil sur la tarification.

Le rapport suit également la **qualité opérationnelle** du dispositif. La précision de l'outil mesure, parmi les alertes confirmées, la proportion de véritables fraudes, indicateur clé pour éviter de mobiliser

inutilement les équipes d'investigation sur des faux positifs. La répartition des sinistres par zone de risque (verte, orange, rouge) permet quant à elle de visualiser la distribution du portefeuille et d'ajuster les seuils $Seuil_{inf}$ et $Seuil_{sup}$ si nécessaire.

Enfin, deux indicateurs relèvent d'une logique d'**intelligence fraude** plus avancée. L'identification des réseaux, en repérant les sinistres impliquant plusieurs véhicules, signale une suspicion de fraude organisée, distincte de la fraude opportuniste. La détection de nouvelles tendances met en évidence l'émergence de schémas de fraude inédits, permettant d'anticiper l'évolution des comportements frauduleux.

L'ensemble se synthétise dans une mesure du **retour sur investissement (ROI) de l'outil**, rapprochant le gain généré (fraude évitée) du coût de mise en œuvre et d'exploitation du dispositif. Cet indicateur répond directement à la problématique de rentabilité posée en introduction : il démontre que l'automatisation de la détection, en abaissant le coût marginal de contrôle, rend rentable l'analyse de l'ensemble des sinistres, y compris ceux de faible montant jusque-là trop coûteux à investiguer manuellement.

Ce rapport peut par ailleurs être exporté au format PDF, offrant un livrable synthétique directement transmissible à la direction technique, au service anti-fraude ou aux instances de gouvernance. Cette possibilité d'extraction facilite le reporting périodique et la traçabilité des résultats, en cohérence avec les exigences de documentation évoquées dans le cadre de gouvernance de l'outil (cf. section ??).

Ainsi, le rapport annuel transforme l'outil de détection en véritable instrument de pilotage actuariel. Il ne se contente pas de traiter les sinistres individuellement, mais fournit une lecture consolidée et chiffrée de la performance du dispositif, permettant de justifier son maintien, d'en ajuster les paramètres et d'en mesurer l'impact réel sur l'équilibre technique du portefeuille.

6.4 Un outil dynamique

Le modèle développé présente un caractère **dynamique et évolutif**, essentiel dans un environnement assurantiel en constante mutation. Concrètement, il ne s'agit pas d'un modèle figé : sa structure permet de **modifier le format des données d'entrée**, qu'il s'agisse des variables utilisées, de leurs modalités ou encore des règles de segmentation associées. Il est ainsi possible d'intégrer de nouvelles caractéristiques, d'adapter les découpages existants ou de faire évoluer les référentiels, puis de **relancer le processus d'apprentissage** afin de recalibrer automatiquement le modèle.

Cette flexibilité constitue un atout majeur pour accompagner les évolutions réglementaires, tarifaires ou opérationnelles des assureurs. Par exemple, l'introduction de nouvelles modalités dans les classes de véhicules — liée à des changements de classification, à l'émergence de nouveaux types de motorisation ou à des ajustements tarifaires — peut être directement intégrée dans le modèle. Celui-ci est alors en mesure de réapprendre les relations entre ces nouvelles modalités et le risque de fraude, sans nécessiter une refonte complète de l'outil.

Ainsi, le modèle s'inscrit dans une logique d'**amélioration continue**, permettant de maintenir sa pertinence dans le temps. Cette capacité d'adaptation garantit une meilleure prise en compte des évolutions

du portefeuille, des comportements frauduleux et du cadre réglementaire, tout en assurant une cohérence avec les pratiques métiers et les politiques de souscription de l'assureur.

Annexes

Chapitre 3

Bibliographie

- [1] FRANCE ASSUREURS. *L'assurance vie en 2024*. (23 septembre 2025). Consulté le 28 Octobre 2025, sur <https://www.franceassureurs.fr/nos-chiffres-cles/assurance-vie/lassurance-vie-en-2024/>
- [2] DORNAIKA Fadi, HAMAD Denis, CONSTANTIN Joseph, TRONG HOANG Vinh. *Advances in Data Clustering*. Lieu d'édition : Springer, 2024.
- [3] GOFFARD Pierre-Olivier, GUERRAULT Xavier. « Is it optimal to group policyholders by age, gender, and seniority for BEL computations based on model points ? ». *European Actuariel Journal*, volume 5, 17 Avril 2015, p. 165-180.
- [4] BEN FADHEL Amine. « Accélération de l'évaluation de la solvabilité prospective d'un assureur épargne ». *Mémoire pour l'Institut des Actuaire*s , 2022.
- [5] INSEE. *Taux de détention des produits de patrimoine selon l'âge de la personne de référence du ménage en 2021*. (2021). Consulté le 18 Septembre 2025, sur https://www.insee.fr/fr/outil-interactif/5367857/details/30_RPC/34_PAT/34A_Figure1
- [6] INSEE. *Pyramide des âges de la population française en 2024*. (2024). Consulté le 1er Septembre 2025, sur <https://www.insee.fr/fr/outil-interactif/5014911/pyramide.htm>
- [7] INSEE. *Enquête Histoire de vie et Patrimoine 2020-2021*. 2021.
- [8] IFOP. *Enquête sur les 60 ans de l'indépendance financière des femmes : chiffres clés sur la répartition hommes-femmes en assurance vie*. (16 Juillet 2025). Consulté le 16 Novembre 2025, sur <https://www.ifop.com/article/enquete-sur-les-60-ans-de-lindependance-financiere-des-femmes/>
- [9] IFOP. *Baromètre - les femmes et l'argent : chiffres clés sur la répartition hommes-femmes sur les fonds EURO et UC en assurance vie*. (Janvier 2024). Consulté le 16 Novembre 2025, sur <https://www.ifop.com/wp-content/uploads/2024/03/barometre-vives-2024ok-1.pdf>