

Mémoire présenté le :
pour l'obtention du Diplôme Universitaire d'actuariat de l'ISFA
et l'admission à l'Institut des Actuaires

Par : Eliot NEHME

Titre : Détection de fraude en assurance non-vie grâce à l'intelligence artificielle

Confidentialité : ☐ NON ☒ (Durée : ☐ 1 an ☒ 2 ans)

Les signataires s'engagent à respecter la confidentialité indiquée ci-dessus

*Membres présents du jury de Signature
l'Institut des Actuaires*

Entreprise :

Nom :

Signature :

*Directeur de mémoire en entre-
prise :*

Nom :

Signature :

*Membres présents du jury de
l'ISFA*

Invité :

Nom :

Signature :

***Autorisation de publication et
de mise en ligne sur un site de
diffusion de documents actua-
riels (après expiration de l'éventuel
délai de confidentialité)***

Signature du responsable entreprise

Signature du candidat

Table des matières

Résumé	iv
Abstract	v
Remerciements	vi
Synthèse	vii
Synthesis	xi
1 Introduction et contexte	1
1.1 Définition de la fraude à l'assurance	1
1.2 Les stades d'occurrence de la fraude dans le cycle assurantiel en assurance non-vie	3
1.2.1 La fraude à la souscription	3
1.2.2 La fraude à la déclaration de sinistre	4
1.2.3 La fraude liée aux Conditions Générales	5
1.3 Cadre réglementaire des sanctions en cas de fraude avérée	6
1.3.1 Souscription	7
1.3.2 Sinistre	7
1.3.3 Preuve de la fraude et sanctions pénales	8
1.4 Enjeux économiques et actuariels de la fraude	9
1.4.1 L'ampleur du marché de la fraude	9
1.4.2 Impact de la fraude sur la tarification	11
2 La détection de la fraude en assurance : de l'approche manuelle à l'automatisation par l'IA	16
2.1 L'approche traditionnelle : une détection manuelle et ciblée	16
2.1.1 Le rôle des équipes dédiées	16
2.1.2 Une détection fondée sur l'expertise humaine	17
2.1.3 Les limites de cette approche	17
2.2 L'apport de l'intelligence artificielle : de nouvelles solutions de détection	18
2.2.1 Le contexte d'émergence	18
2.2.2 Les nouvelles approches	19

2.2.3	Les bénéfices attendus	19
2.2.4	Les points de vigilance à l'utilisation de l'intelligence artificielle	20
2.3	Comparaison du processus manuel et du processus automatisé	21
2.3.1	Les critères de comparaison	21
2.3.2	Mise en regard des deux processus	21
2.3.3	Vers un modèle hybride	22
3	Cadre théorique : les algorithmes de détection de fraude utilisés en assurance non-vie	24
3.1	La régression logistique (modèle de référence)	25
3.2	La forêt aléatoire	27
3.3	Le gradient boosting	28
3.4	Les modèles de scoring à points	29
3.5	Apprentissage non supervisé : détection d'anomalies et comportements atypiques	31
3.5.1	Les algorithmes d'isolation (exemple : Isolation Forest)	31
3.5.2	Le partitionnement de données (Clustering)	32
3.6	Analyse de réseaux (Graph Mining) pour la détection de la fraude organisée	32
3.6.1	Modélisation mathématique du réseau de fraude	32
3.6.2	Détection de communautés et de clusters suspects	33
3.6.3	Application opérationnelle	33
3.7	Critères de qualité des modèles mis en place	34
4	Mise en place d'un processus de détection de fraude automobile automatisé à l'aide d'un Agent IA	38
4.1	Gouvernance autour de la mise en place de l'Agent IA	38
4.2	Présentation de la base de données	41
4.2.1	Base de données source	41
4.2.2	Enrichissement de la base de données	43
4.3	Descriptif macro de la création du processus de détection de fraude et de sa déclinaison opérationnelle	46
4.3.1	Le prompt : la décomposition du besoin en étapes	47
4.3.2	Présentation macro des différentes étapes	48
4.4	Étapes 1 & 2 : Ingestion de la base de données et Audit de contrôles de cohérence	51
4.4.1	Étape 1 : Ingestion de la base de données	51
4.4.2	Étape 2 : Audit et contrôles de cohérence	53
4.5	Étape 3 : Analyse statistique des données	55
4.5.1	Analyse de la composition du portefeuille	56
4.5.2	Analyse de la fréquence de la fraude	58
4.5.3	Création de classes de variables	58
4.5.4	Analyse des corrélations entre les variables	64
5	Création du modèle de détection de fraude : Étapes 4 et 5	76
5.1	Scoring en points	78
5.1.1	Résultats du modèle	78
5.1.2	Qualité du modèle obtenu	86

5.1.3	Limites et précautions d'interprétation	90
5.2	Arbre de décision	90
5.2.1	Résultats du modèle	90
5.2.2	Qualité du modèle obtenu	96
5.2.3	Limites et précautions d'interprétation	99
5.3	Un modèle de Machine learning : le Gradient Boosting	100
5.3.1	Résultats du modèle	100
5.3.2	Qualité du modèle obtenu	104
5.3.3	Limites et précautions d'interprétation	108
5.4	Comparaison des modèles	109
6	Outil mis à disposition du service de détection des fraudes	112
6.1	Utilisation pratique de l'outil	113
6.2	Un outil permettant l'enrichissement du modèle en continu	117
6.3	Rapport annuel de détection de fraude	120
6.4	Dynamisme de l'outil mis en place	122
7	7 Réflexions autour de l'IA et limites de l'outil créé	124
7.1	Un outil d'aide à la décision complémentaire avec l'humain	124
7.2	Nature de l'IA utilisée : de l'IA générative à l'IA agentique	126
7.3	Limites liées à la qualité et à la richesse des données	127
7.3.1	Le couplage à la base portefeuille	127
7.3.2	Ajout de données externes	129
7.4	Mutualisation inter-assureurs et détection des fraudes organisées	130
7.5	Extension à une approche multi-produits	131
	Annexes	133
	Méthodes de classification	133

Résumé

La fraude en assurance non-vie représente un enjeu financier majeur, estimé à environ 2,5 milliards d'euros par an en France, dont une large part échappe encore aux dispositifs de détection traditionnels. Fondés sur l'expertise humaine, ces dispositifs ne contrôlent qu'une fraction des dossiers et peinent à traiter la fraude de masse de faible montant, dont le coût de vérification manuelle excède souvent le gain espéré.

Ce mémoire propose de concevoir et déployer, à l'aide d'un agent d'intelligence artificielle, un processus de détection automatisé de la fraude automobile, de l'ingestion des données jusqu'au pilotage du dispositif. À partir d'une base de sinistres enrichie de variables reproduisant l'information disponible chez un assureur, trois modèles d'estimation de probabilité de fraude seront construits et comparés selon un arbitrage entre interprétabilité et pouvoir prédictif : un scoring en points, un arbre de décision et un modèle de Gradient Boosting.

In fine, c'est ce dernier qui obtiendrait les meilleures performances (AUC de 0,942, lift de $\times 6,66$ au premier décile) tout en concentrant efficacement les fraudes dans un volume restreint de dossiers à investiguer.

L'outil se décline en deux modules destinés à deux équipes distinctes : d'une part la construction du modèle par les actuaires, et d'autre part son exploitation opérationnelle par les gestionnaires, complétée d'une boucle d'enrichissement continu et d'un rapport de pilotage mesurant le retour sur investissement de l'outil. L'ensemble de ces développements s'inscrit dans un cadre de gouvernance conforme au RGPD et à l'AI Act, préservant une supervision humaine à chaque étape du processus de détection de fraude.

Note : Les schémas et illustrations de ce mémoire ont été réalisés avec l'aide d'outils d'intelligence artificielle générative. De même, une partie des données d'enrichissement de la base a été simulée à l'aide de tels outils, comme précisé en section 4.2.2.

Mots-clés : fraude à l'assurance, assurance non-vie, détection automatisée, intelligence artificielle, machine learning, scoring à points, Gradient Boosting, arbre décision, processus, actuariat.

Abstract

Fraud in non-life insurance represents a major financial challenge in France, with annual losses estimated at approximately €2.5 billion, a substantial share of which remains undetected by traditional detection systems. As these systems rely primarily on human expertise, they examine only a fraction of claims and struggle to address high-volume, low-value fraud, for which the cost of manual verification often exceeds the expected financial benefit.

This thesis proposes the design and deployment of an AI-agent-supported process for the automated detection of motor insurance fraud, covering the entire workflow from data ingestion to system monitoring. Using a claims dataset enriched with variables designed to replicate the information available to an insurer, three fraud-probability estimation models are developed and compared in terms of the trade-off between interpretability and predictive performance : a points-based scorecard, a decision tree, and a Gradient Boosting model.

Ultimately, the Gradient Boosting model achieves the strongest performance, with an AUC of 0.942 and a lift of $\times 6.66$ in the first decile, while effectively concentrating fraudulent claims within a limited volume of cases requiring investigation.

The tool comprises two modules designed for two distinct teams : a model-development module for actuaries and an operational-use module for claims handlers, complemented by a continuous data-enrichment loop and a monitoring report that assesses the tool's return on investment. The overall framework is governed in accordance with the GDPR and the AI Act and maintains human oversight at every stage of the fraud-detection process.

Note : The diagrams and illustrations included in this thesis were produced with the assistance of generative artificial intelligence tools. Likewise, part of the data used to enrich the dataset was simulated using such tools, as specified in Section 4.2.2.

Keywords : insurance fraud, non-life insurance, automated detection, artificial intelligence, *machine learning*, points-based scoring, Gradient Boosting, decision tree, process, actuarial science.

Remerciements

Je tiens à remercier toute l'équipe Actuariat d'Accenture qui m'a permis de réaliser ce mémoire, et plus particulièrement ma tutrice Rachel Atia pour son implication ainsi que sa capacité à enseigner, qui ont été essentielles tout au long de ce projet.

Synthèse

Le principe de mutualisation des risques est un principe pilier de l'assurance qui suppose un climat de confiance entre assureur et assuré que la fraude vient détourner.

En assurance non-vie, ce phénomène représente une charge estimée à environ 2,5 milliards d'euros par an en France, soit près de 5 % du niveau d'encaissement des primes, dont une partie importante demeure non détectée. Au-delà de son coût direct, la fraude alourdit la prime de chaque assuré honnête d'une cinquantaine d'euros par contrat automobile et fragilise à terme la solidarité même de la mutualité.

La lutte traditionnelle contre ce phénomène, fondée sur le jugement des gestionnaires de sinistres et l'intervention de cellules spécialisées, atteint aujourd'hui ses limites. Elle ne permet de contrôler qu'une fraction des dossiers, dépend fortement de l'expertise individuelle des enquêteurs, et se heurte à une contrainte économique difficilement surmontable : le coût d'une investigation manuelle rend non rentable le contrôle de la fraude de faible montant, pourtant la plus répandue. C'est de ce constat qu'est né le présent mémoire, dont l'objet est de présenter la conception et la mise en œuvre pas à pas d'un processus de détection automatisé de la fraude automobile, reposant sur un agent d'intelligence artificielle et couvrant l'intégralité de la chaîne, de l'ingestion des données jusqu'au pilotage du dispositif, des outils similaires ayant déjà fait leur émergence sur le marché ces dernières années.

Enjeux et positionnement : Le mémoire s'ouvre sur une caractérisation de la fraude à l'assurance, de ses typologies (opportuniste ou organisée, à la souscription ou au sinistre) et de son cadre juridique, avant d'en établir l'enjeu économique. La valeur d'un dispositif de détection ne se mesure pas à sa seule performance statistique, mais à la charge de sinistres qu'il permet d'éviter : cet ancrage économique, formalisé par la notion de gain unitaire espéré, constitue le fil conducteur du travail et justifie que le choix des paramètres du modèle relève in fine d'un arbitrage coût-bénéfice. Le mémoire dresse ensuite un panorama des méthodes de détection, opposant les approches manuelles traditionnelles aux apports de l'intelligence artificielle, pour aboutir à une conviction qui oriente toute la suite : loin de remplacer l'expertise humaine, l'IA doit s'articuler avec elle selon une logique de complémentarité, où l'algorithme filtre et hiérarchise tandis que l'humain investigue et décide.

Cadre théorique : La partie méthodologique présente les modèles supervisés retenus (du scoring en points à la régression logistique, en passant par les arbres de décision et les méthodes d'ensemble comme le Gradient Boosting), ainsi que les approches non supervisées mobilisables pour la fraude organisée (détection d'anomalies, clustering, analyse de graphes). Une attention particulière est portée aux critères

d'évaluation adaptés au fort déséquilibre des classes : dans une population où la fraude est rare, les indicateurs usuels comme le taux de bonne classification deviennent trompeurs, et l'on doit leur préférer l'AUC-ROC, le coefficient de Gini, la statistique de Kolmogorov-Smirnov, la précision, le rappel ou la PR-AUC. Cette partie insiste enfin sur les exigences de gouvernance, d'interprétabilité et de conformité réglementaire (RGPD, AI Act) encadrant le déploiement de tels modèles.

Conception de l'outil : Le cœur du mémoire est consacré à la mise en œuvre concrète l'outil d'aide à la détection de fraude en assurance automobile. La démarche est volontairement circonscrite à la fraude circonstancielle, décelable à partir de données structurées : caractéristiques du sinistre, antécédents de l'assuré et des intervenants, cohérence de la déclaration. Elle s'appuie sur une base publique de 30 000 sinistres automobiles et 24 variables, présentant un taux de fraude de 11,5 %. La base est ensuite enrichie de trente variables supplémentaires, simulées par l'intelligence artificielle, de manière à reproduire l'information réellement disponible chez un assureur (notamment l'historique du réparateur, du tiers et du véhicule, comportement déclaratif, dimension géographique et temporelle).

L'outil se structure en deux modules, correspondant à deux profils d'utilisateurs bien distincts ainsi qu'à deux temporalités d'utilisation. Le premier outil, destiné aux actuaires, prend en charge la construction du modèle : ingestion standardisée des données, audit automatisé de la qualité de ces dernières, analyses statistiques descriptives, construction des modèles de prédiction de fraude et sélection du modèle le plus performant au regard des critères de qualité définis. Le second outil, cette fois-ci destiné aux gestionnaires de sinistres, exploite le modèle précédemment calibré sans en exposer la complexité, ni même le fonctionnement : pour chaque nouveau dossier de sinistre renseigné, il restitue une probabilité de fraude et oriente le gestionnaire vers une zone de risque conditionnant le niveau d'investigation.

La logique de construction de l'agent est pilotée par un prompt décomposé en étapes successives, qui reproduit la démarche actuarielle et garantit la traçabilité de chaque maillon de la chaîne.

Résultats : L'analyse descriptive fait ressortir les déterminants majeurs de la fraude : le rôle central de l'environnement du réparateur, les antécédents de fraude de l'assuré, la cohérence de la déclaration et le ratio entre la facture de réparation et le prix de marché. Un constat contre-intuitif s'en dégage : la fraude ne concerne pas les sinistres les plus coûteux, ce qui justifie pleinement le recours à une approche multivariée. Trois modèles sont alors construits et comparés selon un arbitrage entre interprétabilité et performance, dont les résultats sont synthétisés ci-dessous.

Indicateur	Scoring en points	Arbre de décision	Gradient Boosting
AUC-ROC	0,923	0,838	0,942
Gini	0,846	0,676	0,885
KS	0,688	0,565	0,740
Lift @10 %	–	×4,61	×6,66
PSI	0,0008	0,0026	0,0023
Écart backtesting	0,009	0,039	0,026

TABLE 1 – Synthèse des indicateurs de qualité des trois modèles testés

Le Gradient Boosting s'impose comme le modèle le plus discriminant (AUC de 0,942, Gini de 0,885, lift de $\times 6,66$ au premier décile) et est retenu à ce titre. Le modèle de *scoring* en points demeure toutefois une alternative pleinement crédible : avec une AUC de 0,923, il se situe très près du Gradient Boosting tout en offrant une transparence que les méthodes d'ensemble ne permettent pas, ce qui en fait le choix privilégié lorsque l'explicabilité prime. L'arbre de décision, dominé sur l'ensemble des critères, est écarté. Les trois modèles présentent par ailleurs une excellente stabilité (PSI très inférieur au seuil d'alerte de 0,10) et une bonne capacité de généralisation.

Un enseignement transversal mérite d'être souligné : les trois modèles, pourtant construits sur des principes différents, font converger leur pouvoir explicatif vers les mêmes variables clés, comme l'illustre le profil du modèle retenu.




FIGURE 1 – Importance relative des variables dans le modèle retenu (Gradient Boosting)

Exploitation et gouvernance : Une fois le modèle retenu et intégré, l'outil est mis à la disposition du service de détection des fraudes. Au quotidien, le gestionnaire y soumet un ou plusieurs sinistre(s), et l'outil lui restitue pour chacun des sinistres soumis une probabilité de fraude assortie d'une orientation sur l'effort d'investigation à engager. Les dossiers sont ainsi répartis en trois zones de risque : une zone verte (probabilité faible, aucune investigation), une zone orange (probabilité intermédiaire, investigation légère) et une zone rouge (probabilité élevée, investigation approfondie). Le gestionnaire concentre dès lors ses efforts sur les dossiers les plus à risque, sans perdre de temps sur les dossiers à faible probabilité de fraude.

Résultats de l'évaluation

500 sinistres scorés depuis car_insurance_fraud_dataset_500_fraude_inconnue.csv

● 0-39% ● 40-59% ● 60-100%

Ne pas investiguer 474 CSV			Investiguer un peu 21 CSV			Investiguer beaucoup 5 CSV		
Police	Montant	Fraude	Police	Montant	Fraude	Police	Montant	Fraude
POL129644	612	38%	POL129928	24045	57%	POL129555	22739	78%
POL129585	22546	36%	POL129798	22890	56%	POL129898	784	72%
POL129889	724	35%	POL129586	24341	55%	POL129688	2554	64%
POL129872	21264	35%	POL129712	24454	54%	POL129687	24309	63%
POL129962	24350	34%	POL129542	2311	49%	POL129742	12038	60%
POL129923	24085	34%	POL129725	1079	49%			
POL129618	9377	33%	POL129587	6596	48%			
POL129965	7093	33%	POL129636	24645	47%			
POL129548	4836	33%	POL129511	20666	46%			
POL129717	15870	32%	POL129659	15552	46%			
POL129765	752	32%	POL129973	557	46%			
POL129548	6441	31%	POL129948	17042	45%			

FIGURE 2 – Résultats de l'évaluation restitués au gestionnaire : répartition des sinistres scorés en trois zones d'investigation (vert / orange / rouge)

Le dispositif est ensuite complété par une boucle d'enrichissement continu : une fois l'investigation d'un dossier close, son issue réelle (fraude avérée ou non) est renseignée sous forme binaire, et seuls les dossiers ainsi qualifiés viennent s'ajouter à la base d'apprentissage, permettant au modèle de se recalibrer sur des cas avérés et de suivre l'évolution des comportements frauduleux. Un rapport de pilotage restitué en continu la valeur ajoutée de l'outil avec la mise en avant de KPI clés : le montant de fraude évitée grâce à l'outil, l'impact sur le ratio Sinistres/Primes et le retour sur investissement (ROI). L'ensemble demeure placé sous supervision humaine : l'agent hiérarchise et oriente les dossiers, mais ne prononce aucune décision défavorable de façon automatique, l'investigation et la décision finale relevant toujours de l'enquêteur, conformément à l'article 22 du RGPD et à l'AI Act.

Limites et perspectives : Le mémoire se conclut sur une réflexion critique. Parmi les limites figurent le caractère partiellement simulé des données d'enrichissement, la sur-représentation probable de la fraude dans la base retenue (11,5 % contre environ 5 % en réalité), et la nécessité de recalibrer le modèle sur une sinistralité représentative avant tout déploiement. L'outil ouvre néanmoins de nombreuses voies d'amélioration : le couplage à une base portefeuille offrant une profondeur historique et relationnelle inaccessible au seul niveau du sinistre, l'intégration de données externes, la mutualisation inter-assureurs pour détecter les fraudeurs « nomades », ou encore l'extension à d'autres branches de l'assurance non-vie. À mesure que les capacités de l'intelligence artificielle progressent, la question n'est sans doute plus de savoir si ces outils transformeront la lutte anti-fraude, mais comment les assureurs sauront en faire un usage à la fois performant, maîtrisé et respectueux des droits des assurés.

Synthesis

The principle of risk pooling is a cornerstone of insurance : it presupposes a relationship of trust between insurer and policyholder, which fraud diverts to illegitimate ends.

In non-life insurance, this phenomenon represents an estimated burden of around €2.5 billion per year in France, close to 5 % of premium income, a significant part of which remains undetected. Beyond its direct cost, fraud adds around fifty euros to the premium of every honest policyholder on each motor contract and, over time, undermines the very solidarity of the mutualised pool.

The traditional fight against this phenomenon, based on the judgement of claims handlers and the intervention of specialised units, is now reaching its limits. It allows only a fraction of claims to be reviewed, depends heavily on the individual expertise of investigators, and comes up against an economic constraint that is difficult to overcome : the cost of a manual investigation makes it unprofitable to control low-value fraud, which is nonetheless the most widespread. It is from this observation that the present dissertation arose, its purpose being to present the step-by-step design and implementation of an automated motor-insurance fraud detection process, based on an artificial-intelligence agent and covering the entire chain, from data ingestion through to steering the system, such tools having already emerged on the market in recent years.

Context and positioning : The dissertation opens with a characterisation of insurance fraud, its typologies (opportunistic or organised, at underwriting or at the claim stage) and its legal framework, before establishing its economic stakes. The value of a detection system is not measured by its statistical performance alone, but by the claims burden it helps to avoid : this economic grounding, formalised through the notion of expected unit gain, constitutes the guiding thread of the work and justifies the fact that the choice of the model's parameters ultimately stems from a cost-benefit trade-off. The dissertation then provides an overview of detection methods, contrasting traditional manual approaches with the contributions of artificial intelligence, leading to a conviction that shapes the rest of the work : far from replacing human expertise, AI must be combined with it in a logic of complementarity, where the algorithm filters and prioritises while the human investigates and decides.

Theoretical framework : The methodological section presents the supervised models retained (from points-based scoring to logistic regression, through decision trees and ensemble methods such as Gradient Boosting), as well as the unsupervised approaches available for organised fraud (anomaly detection, clustering, graph analysis). Particular attention is paid to evaluation criteria suited to strong class imba-

lance : in a population where fraud is rare, standard indicators such as the overall accuracy rate become misleading, and should be replaced by the AUC-ROC, the Gini coefficient, the Kolmogorov-Smirnov statistic, precision, recall or the PR-AUC. This section finally stresses the requirements of governance, interpretability and regulatory compliance (GDPR, AI Act) framing the deployment of such models.

Tool design : The core of the dissertation is devoted to the concrete implementation of the motor-insurance fraud detection tool. The approach is deliberately confined to circumstantial fraud, detectable from structured data : claim characteristics, history of the policyholder and other parties involved, and consistency of the declaration. It draws on a public database of 30,000 motor claims and 24 variables, with a fraud rate of 11.5 %. The database is then enriched with thirty additional variables, simulated by artificial intelligence, so as to reproduce the information actually available to an insurer (in particular the history of the repairer, the third party and the vehicle, declarative behaviour, and the geographical and temporal dimensions).

The tool is structured into two modules, corresponding to two clearly distinct user profiles as well as two usage timeframes. The first tool, intended for actuaries, handles the construction of the model : standardised data ingestion, automated auditing of data quality, descriptive statistical analyses, construction of the fraud prediction models and selection of the most performant model with respect to the defined quality criteria. The second tool, this time intended for claims handlers, exploits the previously calibrated model without exposing its complexity, nor even its inner workings : for each new claim entered, it returns a fraud probability and directs the handler towards a risk zone determining the level of investigation.

The logic used to build the agent is driven by a prompt broken down into successive steps, which reproduces the actuarial approach and guarantees the traceability of every link in the chain.

Results : The descriptive analysis brings out the major drivers of fraud : the central role of the repairer's environment, the policyholder's history of fraud, the consistency of the declaration, and the ratio between the repair invoice and the market price. A counter-intuitive finding emerges : fraud does not concern the most costly claims, which fully justifies the use of a multivariate approach. Three models are then built and compared along an interpretability-versus-performance trade-off, the results of which are summarised below.

Indicator	Points-based scoring	Decision tree	Gradient Boosting
AUC-ROC	0.923	0.838	0.942
Gini	0.846	0.676	0.885
KS	0.688	0.565	0.740
Lift @10 %	–	×4.61	× 6.66
PSI	0.0008	0.0026	0.0023
Backtesting gap	0.009	0.039	0.026

TABLE 2 – Summary of the quality indicators of the three models tested

Gradient Boosting stands out as the most discriminating model (AUC of 0.942, Gini of 0.885, top-decile

lift of $\times 6.66$) and is retained on that basis. The points-based *scoring* model nevertheless remains a fully credible alternative : with an AUC of 0.923, it lies very close to Gradient Boosting while offering a transparency that ensemble methods do not allow, which makes it the preferred choice when explainability takes precedence. The decision tree, dominated on all criteria, is set aside. The three models moreover display excellent stability (PSI well below the alert threshold of 0.10) and good generalisation capacity.

One cross-cutting insight deserves to be highlighted : the three models, although built on different principles, converge in directing their explanatory power towards the same key variables, as illustrated by the profile of the retained model.




FIGURE 3 – Relative importance of variables in the retained model (Gradient Boosting)

Deployment and governance : Once the model has been selected and integrated, the tool is made available to the fraud detection department. On a day-to-day basis, the claims handler submits a claim, individually or in batches, and the tool returns for each one a fraud probability together with guidance on the investigation effort to undertake. Claims are thus sorted into three risk zones : a green zone (low probability, no investigation), an orange zone (intermediate probability, light investigation) and a red zone (high probability, in-depth investigation). The handler can therefore focus efforts on the highest-risk claims, without wasting time on those with a low probability of fraud.

Résultats de l'évaluation

500 sinistres scorés depuis car_insurance_fraud_dataset_500_fraude_inconnue.csv

● 0-39% ● 40-59% ● 60-100%

Ne pas investiguer 474 CSV			Investiguer un peu 21 CSV			Investiguer beaucoup 5 CSV		
Police	Montant	Fraude	Police	Montant	Fraude	Police	Montant	Fraude
POL129644	612	38%	POL129928	24045	57%	POL129555	22739	78%
POL129585	22546	36%	POL129798	22890	56%	POL129898	784	72%
POL129889	724	35%	POL129586	24341	55%	POL129688	2554	64%
POL129872	21264	35%	POL129712	24454	54%	POL129687	24309	63%
POL129962	24350	34%	POL129542	2311	49%	POL129742	12038	60%
POL129923	24085	34%	POL129725	1079	49%			
POL129618	9377	33%	POL129587	6596	48%			
POL129965	7093	33%	POL129636	24645	47%			
POL129548	4836	33%	POL129511	20666	46%			
POL129717	15870	32%	POL129659	15552	46%			
POL129765	752	32%	POL129973	557	46%			
POL129548	6441	31%	POL129948	17042	45%			

FIGURE 4 – Evaluation results returned to the claims handler : scored claims sorted into three investigation zones (green / orange / red)

The system is then completed by a continuous-enrichment feedback loop : once a claim's investigation is closed, its actual outcome (fraud confirmed or not) is recorded in binary form, and only claims thus qualified are added to the training database, allowing the model to recalibrate on established cases and to track the evolution of fraudulent behaviour over time. A monitoring report continuously restitutes the tool's added value through key indicators : the amount of fraud avoided thanks to the tool, the impact on the loss ratio (claims-to-premiums) and the return on investment (ROI). The whole framework remains under human oversight : the agent prioritises and directs claims, but issues no adverse decision automatically, the investigation and the final decision always resting with the investigator, in accordance with Article 22 of the GDPR and with the AI Act.

Limitations and outlook : The dissertation concludes with a critical reflection. Among the limitations are the partially simulated nature of the enrichment data, the likely over-representation of fraud in the database used (11.5 % against around 5 % in reality), and the need to recalibrate the model on a representative claims experience before any deployment. The tool nevertheless opens up many avenues for improvement : coupling with a policy database offering a historical and relational depth inaccessible at the level of the claim alone, the integration of external data, cross-insurer data pooling to detect "nomadic" fraudsters, or the extension to other non-life insurance lines. As the capabilities of artificial intelligence advance, the question is probably no longer whether these tools will transform the fight against fraud, but how insurers will manage to make use of them in a way that is at once performant, controlled and respectful of policyholders' rights.

Chapitre 1

Introduction et contexte

1.1 Définition de la fraude à l'assurance

Le secteur de l'assurance repose sur un principe fondamental : la mutualisation des risques. En échange du paiement d'une prime, l'assuré bénéficie d'une protection financière en cas de réalisation d'un sinistre prévu au contrat. Ce mécanisme de solidarité économique suppose toutefois un climat de confiance entre l'assureur et l'assuré. Lorsque cette confiance est détournée à des fins illégitimes, on parle alors de fraude en assurance.

La fraude en assurance peut être définie comme **tout acte intentionnel visant à tromper un assureur dans le but d'obtenir un avantage indu, qu'il s'agisse d'une indemnisation injustifiée, majorée ou de la souscription d'un contrat dans des conditions mensongères.**

Elle se distingue de l'erreur ou de l'omission involontaire de par son caractère délibéré et frauduleux.

Cette pratique constitue un enjeu majeur pour les compagnies d'assurance, car elle entraîne des pertes financières importantes, impacte l'équilibre technique des portefeuilles et, indirectement, pèse sur l'ensemble des assurés au travers de l'augmentation des primes afin de compenser ces pertes.

L'objectif de la fraude en assurance est principalement financier : il s'agit d'obtenir un enrichissement personnel ou collectif illégitime. Toutefois, au-delà de la recherche d'un gain immédiat, certaines fraudes répondent à des logiques plus complexes, telles que le blanchiment de capitaux, le financement d'activités criminelles ou la structuration d'organisations délictueuses. Ainsi, la fraude peut prendre des formes variées, allant de la simple exagération d'un dommage à la mise en place de réseaux organisés exploitant systématiquement les failles du système assurantiel.

Il convient, à cet égard, de distinguer deux grandes catégories de fraude, la fraude opportuniste et la fraude organisée :

- **La fraude opportuniste** correspond à un comportement isolé, souvent ponctuel, commis par un assuré qui profite d'une situation donnée (par exemple, majorer le montant d'un sinistre ou déclarer un dommage antérieur comme récent). Elle s'inscrit généralement dans une logique individuelle et circonstancielle.
- À l'inverse, **la fraude organisée** repose sur une démarche structurée et planifiée, impliquant parfois plusieurs acteurs (intermédiaires, professionnels de santé, réparateurs, réseaux criminels). Elle est caractérisée par sa répétition, sa préméditation et son ampleur financière plus importante.

Cette distinction est essentielle, car elle implique des modes de détection, de prévention et de répression différents. Là où la fraude opportuniste peut être combattue par des contrôles renforcés et une sensibilisation accrue, la fraude organisée nécessite des dispositifs d'investigation spécialisés, des outils d'analyse de données avancés et une coopération étroite entre assureurs, autorités judiciaires et organismes de régulation.

À noter que la fraude est contraire à un principe important en assurance : **le principe indemnitaire et la règle de non-enrichissement en assurance non-vie.**

Ce principe est expressément consacré par l'article L.121-1 du Code des assurances, selon lequel :

« L'assurance relative aux biens est un contrat d'indemnité ; l'indemnité due par l'assureur à l'assuré ne peut dépasser le montant de la valeur de la chose assurée au moment du sinistre. »

Ce texte pose clairement la règle de non-enrichissement : l'assurance a pour finalité exclusive la réparation du préjudice subi, et non l'octroi d'un profit à l'assuré. L'indemnité ne peut excéder ni le montant du dommage, ni la somme assurée prévue au contrat.

Ainsi, l'indemnisation vise à replacer l'assuré dans la situation patrimoniale qui aurait été la sienne en l'absence de sinistre (principe de réparation intégrale, sans perte ni profit).

Le principe de non-enrichissement joue également un rôle central dans la lutte contre la fraude en assurance non-vie. En effet, toute déclaration intentionnellement inexacte ayant pour effet d'obtenir une indemnité supérieure au préjudice réel constitue une atteinte directe à ce principe.

Plusieurs dispositions viennent renforcer cette protection :

- **Article L.113-2** : obligation pour l'assuré de répondre exactement aux questions posées lors de la souscription et de déclarer sincèrement le sinistre ;
- **Article L.113-8** : nullité du contrat en cas de réticence ou fausse déclaration intentionnelle ;
- **Article L.113-9** : réduction proportionnelle de l'indemnité en cas de déclaration inexacte non intentionnelle.

Dans le cadre de la fraude opportuniste (exagération du montant des dommages, ajout d'objets inexistants, fausse date du sinistre), la violation du principe indemnitaire se traduit par une tentative

d'enrichissement indu.

Dans le cas de la fraude organisée (réseaux de sinistres fictifs, collusion avec des réparateurs ou professionnels de santé, sinistres provoqués), la remise en cause est plus systémique : l'objectif n'est plus seulement d'obtenir une indemnité excessive, mais de détourner de manière structurée le mécanisme même de mutualisation.

1.2 Les stades d'occurrence de la fraude dans le cycle assurantiel en assurance non-vie

En assurance non-vie, la fraude peut intervenir à plusieurs étapes de la relation contractuelle. Deux moments apparaissent particulièrement sensibles :

1. La fraude à la souscription du contrat ;
2. La fraude à la déclaration du sinistre.

Ces deux temporalités répondent à des logiques différentes mais poursuivent un objectif commun : obtenir un avantage économique indu en détournant le mécanisme indemnitaire.

1.2.1 La fraude à la souscription

La fraude à la souscription a lieu lors de la conclusion du contrat, avant tout sinistre. Elle consiste à fournir intentionnellement des informations inexactes ou incomplètes afin d'obtenir des conditions tarifaires plus favorables ou de rendre assurable un risque qui ne le serait pas.

Elle constitue une violation directe de l'obligation de déclaration exacte du risque prévue par l'article L.113-2 du Code des assurances.

L'objectif est ici principalement tarifaire : réduire le montant de la prime ou contourner un refus d'assurance.

La fraude à la souscription peut ainsi priver totalement l'assuré de garantie au moment du sinistre.

	Assurance automobile	Assurance habitation
Fraude à la souscription	• Fausse déclaration du conducteur principal : un parent déclare être le conducteur principal alors que le véhicule est utilisé principalement par un jeune conducteur afin d'éviter une surprime. • Fausse adresse de garage : déclaration d'un stationnement en zone rurale alors que le véhicule est stationné en zone urbaine à forte sinistralité. • Dissimulation d'un usage professionnel : déclarer un usage « privé » alors que le véhicule est utilisé pour des livraisons ou VTC. • Fraude documentaire : faux papiers d'identité.	• Sous-évaluation du capital mobilier pour réduire la prime. • Omission de circonstances aggravantes : logement inoccupé plusieurs mois par an, absence de système de sécurité, activité professionnelle à domicile. • Fausse déclaration de la qualité d'occupant (se déclarer propriétaire occupant plutôt que bailleur).

TABLE 1.1 – Exemples de fraude à la souscription en assurance non-vie

1.2.2 La fraude à la déclaration de sinistre

La fraude la plus courante en assurance non-vie se produit lors de la déclaration d'un sinistre. Cela peut inclure la surestimation des dommages, la déclaration de sinistres fictifs, la falsification de preuves (comme des photos ou des rapports de police). Ces fraudes visent à obtenir des indemnités plus élevées que celles auxquelles l'assuré aurait pu prétendre, ou bien d'engendrer une indemnité qui n'aurait tout simplement pas dû exister.

À noter que la falsification de documents est de plus en plus accessible et difficile à détecter à l'œil nu suite à l'essor de la *generative IA*.

	Assurance automobile	Assurance habitation
Fraude à la déclaration d'un sinistre	• Exagération des dommages : ajout de dégâts antérieurs sur le constat amiable. • Fausse date de sinistre : déclarer un accident survenu avant la souscription comme postérieur à celle-ci. • Sinistre fictif : déclaration d'un vol de véhicule inexistant ou maquillage d'un incendie volontaire. • Accident provoqué intentionnellement (fraude organisée dans certains cas). • Constats de complaisance entre complices pour imputer la responsabilité à un tiers assuré. • Fraude documentaire : faux devis, fausses factures de réparation, gonflement des temps de main-d'œuvre, faux certificats de cession ou documents d'identité, manipulation de photos (dommages antérieurs).	• Ajout d'objets inexistants lors d'un vol déclaré. • Surestimation de la valeur des biens (factures falsifiées ou modifiées). • Déclaration d'un dégât des eaux ancien comme récent pour le rendre indemnisable. • Incendie volontaire destiné à obtenir une indemnité. • Fraude documentaire : fausses factures d'ameublement après vol, devis travaux surévalués après dégât des eaux, falsification de preuves d'effraction, antidatation de justificatifs.

TABLE 1.2 – Exemples de fraude à la déclaration d'un sinistre en assurance non-vie

En assurance non-vie, la fraude peut ainsi être appréhendée selon différents stades d'occurrence dans le cycle assurantiel. Elle peut naître lors de la souscription du contrat, se révéler au moment de la déclaration du sinistre, mais également prendre la forme d'un détournement des stipulations contractuelles, notamment des conditions générales, afin d'obtenir une prise en charge induue.

1.2.3 La fraude liée aux Conditions Générales

La fraude liée aux conditions générales ne constitue pas, à strictement parler, un moment autonome de la fraude. Elle renvoie plutôt à une logique contractuelle particulière, consistant à manipuler les circonstances du sinistre ou l'interprétation du contrat afin de faire entrer le dommage dans le champ de la garantie. Si cette fraude peut trouver son origine dès la souscription, elle se manifeste le plus souvent lors de la déclaration ou de l'instruction du sinistre.

La fraude aux Conditions Générales en assurance non-vie renvoie à la recherche volontaire d'une indemnisation en contradiction avec les clauses contractuelles (définitions, exclusions, franchises, plafonds, obligations de prévention), sans nécessairement qu'il y ait eu fraude à la souscription.

Elle se matérialise par une manipulation des circonstances du sinistre afin de le faire entrer dans le périmètre de garantie : déclaration d'un vol simple en vol avec effraction, transformation d'un défaut d'entretien en événement accidentel, antériorité dissimulée d'un dommage, ou requalification d'un usage

non couvert.

Par exemple, en assurance automobile, dans le cadre d'un sinistre survenu lors d'un usage professionnel alors que le véhicule est déclaré en usage privé, la modification du contexte pour entrer dans le champ contractuel est qualifiée de fraude.

	Assurance automobile	Assurance habitation
Fraude liée aux conditions générales	• Requalification d'un usage exclu : déclarer un sinistre survenu dans un cadre privé alors que le véhicule était utilisé à titre professionnel, afin de bénéficier de la garantie. • Déclaration inexacte des circonstances du vol : affirmer que les clés n'étaient pas laissées dans le véhicule ou à proximité, afin d'éviter l'application d'une exclusion. • Manipulation des circonstances du sinistre : faire passer une panne mécanique ou un défaut d'entretien pour un dommage accidentel couvert par le contrat. • Fausse qualité du conducteur au moment du sinistre : déclarer que le véhicule était conduit par un conducteur autorisé alors qu'il était utilisé par une personne exclue ou non déclarée. • Contournement d'une franchise ou d'un plafond : fractionner artificiellement un dommage ou modifier sa nature pour obtenir une meilleure prise en charge contractuelle.	• Fausse déclaration d'effraction : présenter un vol simple comme un vol avec effraction pour satisfaire à la condition contractuelle de garantie. • Transformation d'un défaut d'entretien en événement accidentel : présenter une infiltration progressive ou un défaut d'étanchéité comme un dégât des eaux soudain et garanti. • Dissimulation de l'inoccupation du logement : omettre que le logement était vacant au-delà de la durée prévue par le contrat au moment du sinistre. • Requalification d'un bien exclu en bien garanti : déclarer comme mobilier assuré un objet relevant d'une exclusion ou nécessitant une garantie spécifique. • Mise en scène d'un dommage garanti : présenter un dommage esthétique, ancien ou non garanti comme consécutif à un événement couvert (incendie, dégât des eaux, vol).

TABLE 1.3 – Exemples de fraude liée aux conditions générales en assurance non-vie

1.3 Cadre réglementaire des sanctions en cas de fraude avérée

La fraude en assurance ne se limite pas à une simple irrégularité contractuelle : elle peut emporter des conséquences à plusieurs niveaux. Selon le moment où elle intervient et sa nature, elle peut produire des effets civils et contractuels, tels que la nullité du contrat, la déchéance de garantie, le refus d'indemnisation ou la restitution des indemnités indûment versées.

Elle peut également, lorsque les manœuvres frauduleuses sont suffisamment caractérisées, relever du droit pénal. Le régime applicable diffère toutefois selon que la fraude intervient au moment de la souscription du contrat ou lors de la déclaration du sinistre, ce qui justifie de distinguer ces deux hypothèses avant d'aborder les questions probatoires et les qualifications pénales susceptibles d'être retenues.

1.3.1 Souscription

En matière de souscription, le régime des sanctions repose principalement sur les articles L.113-8 et L.113-9 du Code des assurances. Il convient toutefois de distinguer selon que l'inexactitude déclarative procède d'une intention frauduleuse ou d'une simple erreur.

L'article L.113-8 prévoit que la réticence ou la fausse déclaration intentionnelle de l'assuré entraîne la nullité du contrat. Cette sanction suppose que l'assureur démontre non seulement l'inexactitude ou l'omission, mais également le caractère intentionnel de cette déclaration, c'est-à-dire la volonté de tromper l'assureur sur l'appréciation du risque. En pratique, cette intention frauduleuse doit porter sur un élément que l'assureur considérerait comme déterminant dans sa décision de contracter ou dans la fixation de la prime.

La nullité du contrat produit un effet rétroactif : le contrat est réputé n'avoir jamais existé, de sorte que l'assureur n'est pas tenu de garantir le sinistre. En outre, les primes déjà versées demeurent acquises à l'assureur, à titre de dommages et intérêts. Cette sanction est particulièrement sévère et reflète l'exigence de bonne foi qui gouverne la formation du contrat d'assurance.

À l'inverse, l'article L.113-9 vise l'hypothèse d'une déclaration inexacte non intentionnelle. Dans ce cas, il n'y a pas fraude à proprement parler, mais le contrat n'est pas pour autant maintenu sans conséquence. Si l'erreur est constatée avant tout sinistre, l'assureur peut soit maintenir le contrat moyennant une augmentation de prime, soit le résilier. Si elle est découverte après sinistre, l'indemnité peut être réduite proportionnellement au rapport entre la prime payée et celle qui aurait été due si le risque avait été exactement déclaré. Cette distinction entre mauvaise foi et simple erreur est essentielle, car toute anomalie déclarative n'a pas vocation à recevoir la qualification de fraude.

1.3.2 Sinistre

Lorsque la fraude intervient au moment du sinistre, les conséquences juridiques diffèrent de celles applicables à la souscription. Il ne s'agit plus de remettre en cause la formation du contrat, mais de sanctionner une demande de garantie ou d'indemnisation obtenue ou tentée au moyen de déclarations mensongères, d'une dissimulation de circonstances essentielles ou de la production de pièces falsifiées.

La première conséquence est le refus d'indemnisation lorsque la fraude est détectée avant tout paiement. En pratique, l'assureur peut opposer à l'assuré l'absence de droit à garantie dès lors que le sinistre déclaré ne correspond pas à la réalité ou que son montant a été artificiellement majoré. Cette sanction peut également prendre la forme d'une déchéance de garantie lorsque le contrat prévoit qu'une fausse déclaration intentionnelle relative au sinistre prive l'assuré du bénéfice de la garantie. La déchéance se distingue de la nullité en ce qu'elle n'affecte pas l'existence même du contrat, mais uniquement le droit

à indemnisation au titre du sinistre concerné.

Si l'indemnité a déjà été versée au moment de la découverte de la fraude, l'assureur peut engager une action en restitution des sommes indûment perçues. Cette répétition de l'indu permet de récupérer le montant versé en l'absence de droit légitime à indemnisation. Dans les cas les plus graves, l'assureur pourra en outre solliciter des dommages et intérêts en réparation du préjudice subi, notamment lorsque la fraude a entraîné des coûts d'expertise, d'enquête ou de gestion supplémentaires.

En pratique, la mise en œuvre de ces sanctions suppose toutefois que la fraude soit effectivement démontrée. Or, la fraude au sinistre ne se présume pas : l'assureur doit être en mesure d'établir le caractère intentionnel des manœuvres invoquées, ce qui renvoie directement à la question de la preuve, mais également, dans certaines hypothèses, à d'éventuelles poursuites pénales.

1.3.3 Preuve de la fraude et sanctions pénales

La mise en œuvre des sanctions contractuelles suppose, en premier lieu, que la fraude soit prouvée. En droit des assurances comme en droit commun, la fraude ne se présume pas. Il appartient donc à l'assureur d'établir l'existence de manœuvres intentionnelles destinées à obtenir un avantage indu. Cette exigence probatoire est particulièrement importante, car une simple incohérence ou une approximation dans les déclarations de l'assuré ne suffit pas, à elle seule, à caractériser une fraude.

La preuve peut être rapportée par tout moyen et résulte souvent, en pratique, d'un faisceau d'indices graves, précis et concordants. Il peut s'agir, par exemple, d'incohérences entre les déclarations successives, d'anomalies documentaires, de contradictions entre les circonstances déclarées et les constatations matérielles, ou encore de rapprochements opérés à partir d'historiques de sinistres et de données comportementales.

Cette dimension probatoire explique le recours croissant, chez les assureurs, à des dispositifs spécialisés d'investigation, à l'analyse de données et à des modèles de scoring destinés à hiérarchiser les dossiers les plus suspects, sans pour autant se substituer à l'appréciation humaine.

Au-delà des conséquences contractuelles, certaines fraudes à l'assurance peuvent également recevoir une qualification pénale. Lorsque l'assuré use de manœuvres frauduleuses afin de tromper l'assureur pour obtenir la remise de fonds, les faits peuvent relever de l'escroquerie au sens de l'article 313-1 du Code pénal.

De même, la production de justificatifs falsifiés, de fausses factures, de faux constats ou de documents d'identité altérés est susceptible de constituer un faux ou un usage de faux. Le droit pénal vient ainsi compléter le droit des assurances : là où ce dernier organise les conséquences contractuelles de la fraude, le premier sanctionne la manœuvre frauduleuse elle-même lorsqu'elle porte atteinte à l'ordre public économique.

1.4 Enjeux économiques et actuariels de la fraude

1.4.1 L'ampleur du marché de la fraude

Le marché de l'assurance non-vie représente 80,3 Md€ de primes pour 56,3 Md€ de prestations versées en 2025.

Le volume de sinistres étant très important, il n'est pas envisageable de vérifier manuellement la véracité de chaque déclaration sans rogner de manière trop importante sur la marge de l'assureur.

	Cotisations	Prestations
Assurance de biens et de responsabilité	80,3 Md€	56,3 Md€
Dont assurance automobile	30,2 Md€	24,7 Md€
Dont assurance habitation	14,9 Md€	9,9 Md€

TABLE 1.4 – Cotisations et prestations d'assurance de biens et de responsabilité en 2025 (Source : France Assureurs).

Ainsi, la profession s'est structurée autour de l'ALFA (Agence de Lutte contre la Fraude à l'Assurance).

Créée en février 1989, cette association professionnelle a pour mission d'accompagner les assureurs français dans la prévention et la détection des fraudes. Elle agit comme un véritable carrefour d'informations, centralisant les données, formant les gestionnaires et collaborant avec les pouvoirs publics (notamment le ministère de l'Intérieur) pour endiguer ce phénomène.

La fraude à l'assurance est un phénomène complexe à quantifier avec précision, car par nature, une grande partie reste non détectée. Au niveau européen, la fédération Insurance Europe estime que la fraude représente jusqu'à 10 % du coût total des sinistres¹. En France, selon les estimations de la Fédération Française de l'Assurance et de l'ALFA, le coût global de la fraude s'élèverait à environ 2,5 milliards d'euros par an, soit environ 5 % du niveau d'encaissement des primes².

Les montants identifiés sont ainsi passés de 695 millions d'euros en 2023 à 902 millions d'euros en 2024 (+30 %) et 947 millions d'euros en 2025 (+5 %).

Finalement, les acteurs du marché soulignent et rappellent que c'est la collectivité entière qui est pénalisée, la fraude alourdissant la prime annuelle de chaque assuré honnête d'environ 50 euros sur chaque contrat d'assurance automobile³.

0. https://www.franceassureurs.fr/wp-content/uploads/20260325_presentation-conference-de-presse-2.pdf

1. <https://www.insuranceeurope.eu/mediaitem/0bf0af82-e7ef-4439-a763-d7862859d421/The+impact+of+insurance+fraud.pdf>

2. <https://www.argusdelassurance.com/institutions/fraude-a-l-assurance-une-facture-de-2-5-md-en-dommages-en-2014-alfa.96060>

3. <https://www.argusdelassurance.com/acteurs/fraude-a-l-assurance-un-cout-de-50-pour-les-assures.60931>




FIGURE 1.1 – Évolution de la fraude automobile entre 2020 et 2025 (Source : ALFA Association).

Si ce fléau touche toutes les branches de l'assurance, l'IARD (Incendie, Accidents et Risques Divers) en représente de loin la part la plus importante.

À titre d'exemple, sur les 947 millions d'euros de fraudes détectées en 2025, 627 millions concernent exclusivement l'IARD (notamment l'assurance Automobile et l'assurance Multirisque Habitation), soit près de 66 % du total⁴.

Les assurances de biens, par leur forte fréquence de sinistralité, demeurent le secteur le plus exposé aux déclarations de sinistres fictifs ou à la surestimation des dommages.

Ces segments cumulent plusieurs facteurs d'exposition : une fréquence de sinistres élevée, une forte volumétrie de dossiers de montant unitaire parfois modéré, ainsi qu'une documentation déclarative susceptible d'être manipulée.

En assurance automobile, la multiplicité des intervenants (assuré, tiers, réparateur, expert, dépanneur) accroît les opportunités de fraude. En habitation, la difficulté de vérifier a posteriori la réalité, l'antériorité ou la valeur des biens déclarés favorise également les comportements opportunistes.

Ce phénomène et ses proportions ne sont pas une spécificité française. À l'échelle européenne, la fédération Insurance Europe estime que la fraude représente en moyenne jusqu'à 10 % du coût total des sinistres dans les pays voisins (comme au Royaume-Uni ou en Allemagne). La France se situe donc dans cette moyenne continentale. Toutefois, l'écart observé au niveau européen entre la fraude détectée (environ 2,5 milliards d'euros) et la fraude réelle non détectée (estimée à plus de 13 milliards d'euros) souligne qu'une immense partie des préjudices passe encore « à travers les mailles du filet ». Cette « fraude invisible » représente un défi majeur pour la rentabilité des compagnies d'assurance.

3. Sources : <https://www.alfa.asso.fr/alfa-news-48-septembre-2024/> ; <https://www.alfa.asso.fr/alfa-news-39-juin-2023-2/> et <https://www.franceassureurs.fr/wp-content/uploads/donnees-cles-2024.pdf>

4. <https://www.argusdelassurance.com/assurance-de-personnes/des-filieres-de-larnaque-utilisent-lintelligence-artificielle>
VRVQHS DANZGGZL5GXH7FW3JU4.html

1.4.2 Impact de la fraude sur la tarification

L'enjeu de la fraude ne se résume pas à une perte ponctuelle pour les assureurs : il affecte plus largement l'équilibre technique du marché, la qualité des données historiques et, en définitive, la construction même des primes. C'est ce lien direct entre fraude, sinistralité observée et tarification qu'il convient désormais d'examiner.

1.4.2.1 Modèle tarifaire usuel en assurance non-vie et biais statistiques

En assurance non-vie, la tarification repose usuellement sur des Modèles Linéaires Généralisés (GLM).

La Prime Pure (PP) est modélisée par le produit de l'espérance de la fréquence des sinistres (N) et de l'espérance de leur coût moyen (C) :

$$PP = \mathbb{E}[N] \times \mathbb{E}[C] \quad (1.1)$$

L'absence de détection de la fraude introduit un biais systématique dans les bases de données utilisées pour calibrer ces modèles tarifaires (que ce soit via des GLM traditionnels ou des algorithmes de Machine Learning comme XGBoost) :

	Assurance automobile	Assurance habitation
Fraude liée aux conditions générales	• Requalification d'un usage exclu : déclarer un sinistre survenu dans un cadre privé alors que le véhicule était utilisé à titre professionnel, afin de bénéficier de la garantie. • Déclaration inexacte des circonstances du vol : affirmer que les clés n'étaient pas laissées dans le véhicule ou à proximité, afin d'éviter l'application d'une exclusion. • Manipulation des circonstances du sinistre : faire passer une panne mécanique ou un défaut d'entretien pour un dommage accidentel couvert par le contrat. • Fausse qualité du conducteur au moment du sinistre : déclarer que le véhicule était conduit par un conducteur autorisé alors qu'il était utilisé par une personne exclue ou non déclarée. • Contournement d'une franchise ou d'un plafond : fractionner artificiellement un dommage ou modifier sa nature pour obtenir une meilleure prise en charge contractuelle.	• Fausse déclaration d'effraction : présenter un vol simple comme un vol avec effraction pour satisfaire à la condition contractuelle de garantie. • Transformation d'un défaut d'entretien en événement accidentel : présenter une infiltration progressive ou un défaut d'étanchéité comme un dégât des eaux soudain et garanti. • Dissimulation de l'inoccupation du logement : omettre que le logement était vacant au-delà de la durée prévue par le contrat au moment du sinistre. • Requalification d'un bien exclu en bien garanti : déclarer comme mobilier assuré un objet relevant d'une exclusion ou nécessitant une garantie spécifique. • Mise en scène d'un dommage garanti : présenter un dommage esthétique, ancien ou non garanti comme consécutif à un événement couvert (incendie, dégât des eaux, vol).

TABLE 1.5 – Exemples de fraude liée aux conditions générales en assurance non-vie

Si l'actuaire calibre ses modèles sur ces données polluées, il surestime le risque réel du portefeuille sain. La prime demandée aux assurés honnêtes augmente, ce qui dégrade la compétitivité de l'assureur sur le marché.

1.4.2.2 Conséquence de la fraude sur la prime pure

Dans l'équation de la prime pure, une surestimation de la fréquence ou du coût moyen conduit mécaniquement à une prime plus élevée pour l'ensemble du portefeuille.

Dans le cas de la fraude par majoration (sinistre réel mais montant surévalué), l'impact est directement porté sur l'espérance du coût moyen $\mathbb{E}[C]$:

$$\mathbb{E}[C]_{\text{fraude}} = \mathbb{E}[C]_{\text{réel}} + \mathbb{E}[C]_{\text{majoration}} \quad (1.2)$$

Dans le cas de la fraude par invention (sinistre totalement fictif), l'impact est porté sur la fréquence $\mathbb{E}[N]$:

$$\mathbb{E}[N]_{\text{fraude}} = \mathbb{E}[N]_{\text{réel}} + \mathbb{E}[N]_{\text{fictif}} \quad (1.3)$$

Ainsi, si l'on note α la part de la charge sinistre imputable à la fraude, la prime d'équilibre technique observée ($\Pi_{\text{chargée}}$) se déduit de la prime pure théorique (Π_{pure}) par la relation :

$$\Pi_{\text{chargée}} = \frac{\Pi_{\text{pure}}}{1 - \alpha} \quad (1.4)$$

où α est estimé entre 5 % et 10 % du volume des prestations selon les branches (Source : ALFA).

Part de la fraude dans la charge (α)	Surcoût sur la prime pure (%)
5,0 %	+ 5,26 %
7,5 %	+ 8,11 %
10,0 %	+ 11,11 %

TABLE 1.6 – Impact du levier de la fraude sur la prime des assurés honnêtes

Il faut souligner que l'effet de la fraude sur la tarification ne se limite pas à une hausse mécanique de la prime pure. Il se propage également aux chargements de gestion, dans la mesure où la lutte contre la fraude mobilise des ressources d'expertise, de contrôle et de contentieux.

En outre, une répercussion trop importante de ces coûts dans les primes commerciales peut nuire à la compétitivité de l'assureur et accentuer les phénomènes d'anti-sélection, en éloignant les assurés les moins risqués du portefeuille.

De plus, un enjeu central réside dans le fait que la fraude peut fausser la segmentation elle-même.

En effet, certaines variables explicatives peuvent apparaître comme fortement corrélées à la sinistralité observée non pas en raison d'un risque assurantiel intrinsèque plus élevé, mais parce qu'elles sont associées à une fréquence accrue de comportements frauduleux ou à des modalités de détection différenciées. L'actuaire court alors le risque d'intégrer dans la tarification des effets qui relèvent moins du risque pur que de distorsions comportementales ou informationnelles.

Inversement, l'amélioration des dispositifs de détection permet d'assainir les bases historiques servant à la modélisation actuarielle. À terme, une meilleure identification des dossiers frauduleux contribue à restaurer une mesure plus fidèle du risque technique, à améliorer la segmentation tarifaire et à limiter le transfert de charge vers les assurés honnêtes. La lutte contre la fraude devient ainsi non seulement un levier de réduction des pertes, mais également un instrument de qualité tarifaire.

1.4.2.3 L'analyse coût-bénéfice : le seuil de rentabilité du contrôle

Pour corriger ce biais tarifaire, l'assureur doit identifier et rejeter les sinistres frauduleux. Cependant, le processus de détection n'est pas gratuit : il engage des frais de gestion supplémentaires (expertise contradictoire, enquête administrative, recours à un détective privé).

L'assureur fait donc face à un problème d'optimisation économique simple : l'espérance d'économie (le non-paiement du sinistre) doit être supérieure au coût du contrôle.

Soit C_{invest} le coût moyen d'une investigation et M_{sinistre} le montant du sinistre réclamé. Le contrôle n'est rationnel que si :

$$M_{\text{sinistre}} \times P(\text{Fraude} \mid \text{Alerte}) > C_{\text{invest}} \quad (1.5)$$

où $P(\text{Fraude} \mid \text{Alerte})$ représente la précision du modèle de détection (la probabilité que l'alerte soit réellement fondée).

Sur le marché IARD français, une expertise automobile classique coûte entre 70 € et 400 € par dossier⁵, tandis qu'une investigation spécialisée (enquêteur certifié ALFA) peut rapidement dépasser les 1 000 €, les honoraires étant libres et dépendant fortement du type de sinistre.

Ainsi, pour un sinistre matériel de 1 200 €, engager une expertise à 250 € est rentable. En revanche, pour de « petits sinistres » (par exemple un bris de glace à 400 €), le coût administratif et d'expertise rend la détection humaine irrationnelle d'un point de vue économique.

1.4.2.4 L'automatisation de la détection de la fraude comme levier de rentabilité

C'est sur cette « fraude de masse », de faible montant, que le modèle traditionnel atteint ses limites, et que l'implémentation de nouvelles technologies devient indispensable.

En effet, à date, avec la digitalisation, on observe une hausse des tentatives de fraude, notamment au travers de falsifications numériques et de retouches d'image⁶.

En parallèle, l'amélioration des outils tels que la Data analytics, la détection d'anomalies, l'analyse d'image ou le Cross-checking de bases externes permet d'améliorer le taux de détection des fraudes.

Néanmoins, malgré l'amélioration des méthodes de détection de fraude, la fraude documentaire reste un poste matériel dans le coût technique global. En mettant en place des méthodes de détection de fraude automatiques (algorithmes de scoring, IA etc.), l'assureur réduit drastiquement le coût de traitement et de ciblage des fraudes.

Le coût marginal de vérification s'approchant de zéro, il devient alors rentable d'investiguer des sinistres de plus faible montant, assainissant ainsi la base de sinistralité et protégeant l'équilibre de la prime.

C'est précisément dans la réponse à ce défi opérationnel et financier que s'inscrit l'objectif central de ce

5. Source : Service public.

6. La fraude documentaire (faux certificats, fausses factures, photos retouchées) est en explosion et représente désormais 39 % des cas de fraude détectés en IARD (source : <https://www.itesoft.com/fr/blog/fraude-assurance-chiffres-cles-alfa/>).

mémoire. En effet, les ambitions des travaux de ce mémoire sont de concevoir et déployer un processus de détection automatisé des fraudes de bout en bout.

Il convient toutefois de circonscrire d'emblée le périmètre de cette détection. Notre démarche ne porte pas sur la fraude documentaire (falsification de factures, de devis ou d'attestations) ni sur la fraude relevant de l'analyse d'images (clichés retouchés ou détournés), faute de disposer des bases de données documentaires et photographiques nécessaires à l'entraînement de tels modèles.

L'approche retenue se concentre au contraire sur la fraude circonstancielle, c'est-à-dire celle qui se révèle à travers les caractéristiques mêmes du sinistre et de l'assuré : nature et chronologie de la déclaration, antécédents et historique du contrat, profil du déclarant, cohérence entre les circonstances rapportées et les paramètres du sinistre, ou encore récurrence de signaux faibles susceptibles de trahir une intention frauduleuse.

Cette orientation présente l'avantage de s'appuyer exclusivement sur des données structurées déjà disponibles dans les systèmes de gestion de l'assureur, ce qui en fait un levier à la fois exploitable, reproductible et directement intégrable au processus d'instruction des sinistres.

Pour y parvenir, l'étude s'appuie sur une base de données publique de sinistres automobiles issue de Kaggle, contenant des dossiers étiquetés comme frauduleux ou non. À défaut de données réelles d'assureur, difficilement accessibles pour des raisons de confidentialité, cette base offre un support représentatif et reproductible pour développer et tester la démarche, même si sa transposition à un portefeuille réel nécessiterait une phase de recalibrage.

Pour pallier en partie à ce recalibrage inexistant, cette base a été enrichie avec des données qui auraient été disponibles chez un assureur de manière à enrichir le modèle de détection de fraude créé.

Les chapitres suivants détailleront la démarche de mise en oeuvre d'un tel outil pas à pas : après un état des lieux des processus de détection existants et de l'apport de l'intelligence artificielle (Chapitre 2), en opposition à ce qui se fait déjà en matière de détection de fraude (Chapitre 3), nous présenterons la construction et la comparaison des trois modèles de détection retenus (scoring en points, arbre de décision et Gradient Boosting) ainsi que l'évaluation de leurs performances respectives (Chapitre 4). Le Chapitre 5 décrira l'outil opérationnel développé à destination des services de gestion des sinistres, suivi du Chapitre 6 qui détaillera son utilisation pratique et sa logique d'enrichissement continu. Enfin, le Chapitre 7 ouvrira sur les limites de l'outil et les perspectives d'évolution, notamment autour de la qualité des données, de la mutualisation inter-assureurs et de l'extension de l'outil à une approche multi-produits.

Chapitre 2

La détection de la fraude en assurance : de l'approche manuelle à l'automatisation par l'IA

2.1 L'approche traditionnelle : une détection manuelle et ciblée

2.1.1 Le rôle des équipes dédiées

Historiquement, la lutte contre la fraude en assurance non-vie repose sur une organisation humaine structurée, intégrée à la chaîne de gestion des sinistres.

Le premier maillon en est le gestionnaire de sinistres : chargé d'instruire les déclarations et de procéder à l'indemnisation, il constitue le point de contact initial avec le dossier et, à ce titre, la première ligne de détection.

Lorsqu'un dossier éveille un doute, il peut être orienté vers une instance spécialisée (service ou cellule anti-fraude) composée d'enquêteurs et d'analystes dont c'est le métier exclusif. Ces cellules regroupent souvent des enquêteurs spécialisés, des data analystes (pour la détection algorithmique), des juristes et parfois d'anciens policiers ou gendarmes.

Ces enquêteurs disposent de prérogatives et de moyens d'investigation plus poussés : demande de pièces complémentaires, vérification des déclarations, recoupement avec des bases sectorielles, recours éventuel à des expertises ou à des enquêtes de terrain.

Cette organisation s'insère à un point précis de la chaîne d'indemnisation : entre la déclaration du

sinistre et le versement de l'indemnité. La détection intervient ainsi comme un filtre, destiné à suspendre ou approfondir l'instruction des dossiers suspects avant que l'indemnisation ne soit prononcée.

Sa position est donc stratégique, puisqu'une fraude non détectée à ce stade se traduit directement par un versement indu, tandis qu'un contrôle trop systématique alourdit les délais de gestion et dégrade la qualité de service pour les assurés de bonne foi. L'équilibre entre maîtrise du risque de fraude et fluidité du règlement constitue l'arbitrage permanent de ces équipes.

2.1.2 Une détection fondée sur l'expertise humaine

Dans ce **dispositif traditionnel**, la détection repose essentiellement sur **le jugement et l'expérience des intervenants**. Elle s'opère largement « au fil de l'eau » : c'est au moment de l'instruction d'un dossier que le gestionnaire, par sa connaissance des cas habituels, perçoit une anomalie ou une incohérence. Cette vigilance s'appuie sur un ensemble de signaux d'alerte ou *red flags* issus de l'expérience accumulée : délai anormalement court entre la souscription et le sinistre, déclaration tardive, circonstances peu cohérentes, antécédents répétés, montant de dommages disproportionnés, ou encore concordances suspectes entre plusieurs dossiers.

Une fois le soupçon né, la confirmation passe par un travail de recoupement manuel : rapprochement des informations déclarées, comparaison avec l'historique du contrat et de l'assuré, vérification de la cohérence d'ensemble. Ce processus mobilise fortement l'intuition métier, c'est-à-dire la capacité, forgée par la pratique, à identifier des configurations atypiques que ne traduit aucune règle écrite. Cette expertise humaine constitue une force réelle : elle est fine, contextuelle et capable d'appréhender des situations inédites. Mais elle est aussi, par nature, **difficilement formalisable et transmissible**, ce qui en fait simultanément la principale limite de l'approche.

2.1.3 Les limites de cette approche

Si l'expertise humaine demeure précieuse, l'organisation traditionnelle se heurte à plusieurs limites structurelles. La première tient à sa couverture partielle : **le contrôle manuel étant coûteux** en temps, seule une fraction des dossiers peut être examinée en profondeur, la grande majorité étant traitée sans analyse anti-fraude approfondie. Il en résulte un risque non négligeable de non-détection : de nombreuses fraudes échappent au dispositif, non parce qu'elles seraient indétectables, mais faute de ressources pour les examiner, passant inaperçues sous la forme de faux négatifs lorsque les indices ne sont pas suffisamment manifestes.

S'y ajoute une **forte dépendance à l'expertise individuelle**. La qualité de la détection varie selon l'expérience, la charge de travail et la vigilance de chaque gestionnaire, chacun appliquant ses propres critères et son propre niveau de rigueur. Il en découle une **hétérogénéité des décisions** (un même dossier pourra être contrôlé par l'un et laissé passer par l'autre) qui nuit à la reproductibilité du processus et à son auditabilité. Le caractère manuel des vérifications induit par ailleurs une lenteur de traitement et un coût humain élevé, puisque chaque dossier suspect doit être examiné de façon approfondie et que l'augmentation du nombre de contrôles suppose un accroissement proportionnel des effectifs, ce qui

ralentit le règlement global des sinistres.

L'approche montre enfin ses limites dans l'**exploitation des données disponibles**. Les volumes d'informations accumulés au fil du temps sont difficiles à analyser de manière exhaustive sans outils automatisés, ce qui empêche d'identifier les schémas récurrents ou les comportements suspects à grande échelle. Cette difficulté favorise en outre des **biais d'attention** : à force de concentrer les contrôles sur certains profils ou types de sinistres réputés à risque, on délaisse les schémas de fraude moins familiers et l'on reproduit des a priori non fondés.

L'ensemble de ces limites converge vers un même **enjeu de rentabilité**. Le volume de fraudes effectivement détecté reste faible au regard du coût que représente le dispositif humain, et surtout au regard de la fraude réellement présente dans le portefeuille. Le rapport entre les montants recouvrés et les ressources mobilisées plafonne, sans qu'il soit possible de l'améliorer significativement par les seuls moyens manuels. C'est précisément cette inefficience (un coût élevé pour une couverture limitée) qui motive le recours à une détection automatisée fondée sur l'intelligence artificielle, capable d'analyser l'intégralité des dossiers à un coût marginal réduit et de dépasser ainsi un grand nombre des limites associées aux méthodes manuelles.

2.2 L'apport de l'intelligence artificielle : de nouvelles solutions de détection

2.2.1 Le contexte d'émergence

L'essor des solutions de détection automatisée n'est pas le fruit d'une rupture isolée, mais la convergence de plusieurs évolutions.

La première est l'**explosion du volume de données structurées** disponibles : la dématérialisation de la gestion des sinistres, la standardisation des systèmes d'information, la conservation systématique de l'historique des contrats et des déclarations ont constitué des bases de données riches, exploitables et homogènes, là où l'information était auparavant éparse et largement non numérisée.

La deuxième tient à la **maturité des méthodes d'apprentissage** : les algorithmes de machine learning, et en particulier les méthodes d'ensemble sur données tabulaires présentées précédemment, sont désormais éprouvés, accessibles via des bibliothèques robustes et applicables à coût raisonnable.

La troisième relève du contexte économique : la **pression croissante sur les coûts et sur les délais de gestion** pousse les assureurs à rechercher des gains d'efficacité, tandis que la fraude, par son impact direct sur la sinistralité et donc sur la prime, demeure un enjeu financier majeur. La conjonction de ces facteurs (données disponibles, outils matures et nécessité économique) a rendu possible et souhaitable le passage à des dispositifs automatisés.

2.2.2 Les nouvelles approches

Ce passage s'est opéré par étapes. Les premiers dispositifs automatisés reposaient sur des **moteurs de règles** : des conditions explicites, traduisant les signaux d'alerte connus des experts (un délai inférieur à tel seuil, un cumul de sinistres supérieur à tel nombre), déclenchaient une alerte. Reproduisant la connaissance métier, ces systèmes en héritaient aussi les limites : rigides, ils ne détectaient que la fraude déjà identifiée et se révélaient incapables d'appréhender des schémas nouveaux ou la conjonction subtile de plusieurs facteurs.

Les **modèles prédictifs** ont marqué l'évolution suivante. Plutôt que d'appliquer des règles figées, ils apprennent à partir de l'historique des dossiers à attribuer à chaque sinistre un **score de risque de fraude**, c'est-à-dire une probabilité estimée à partir de l'ensemble de ses caractéristiques. Cette approche autorise une **détection circonstancielle**, fondée sur les caractéristiques du sinistre et de l'assuré (chronologie, antécédents, cohérence des circonstances déclarées, profil du dossier) et capable de capter automatiquement des interactions que nul ne formaliserait sous forme de règle. Surtout, elle modifie en profondeur la logique de couverture : alors que le contrôle manuel ne portait que sur un échantillon de dossiers, le modèle procède à un **traitement systématique de l'ensemble des dossiers**, chacun se voyant attribuer un score, sans tri préalable.

2.2.3 Les bénéfices attendus

Il découle de ces approches plusieurs bénéfices :

- **Une augmentation du volume de fraudes détectées** : en analysant l'intégralité du portefeuille plutôt qu'une fraction, le dispositif fait remonter des dossiers suspects qui auraient échappé à un contrôle manuel nécessairement sélectif. Cette couverture exhaustive s'accompagne d'une capacité analytique accrue : en exploitant aussi bien les données courantes que les historiques, le modèle détecte des schémas complexes et des corrélations difficilement identifiables par l'humain, améliorant ainsi la détection des fraudes les plus élaborées, souvent caractérisées par des signaux faibles ou dispersés.
- **Une réduction du coût unitaire de détection** : une fois le modèle développé, le *scoring* d'un dossier supplémentaire présente un coût marginal quasi nul, ce qui améliore directement le rapport entre les fraudes détectées et les ressources mobilisées.
- **Une réduction des délais de traitement** : grâce au tri automatique, de grands volumes de sinistres peuvent être analysés quasi instantanément, accélérant ainsi le règlement des dossiers sains tout en orientant sans délai les cas suspects vers l'investigation.
- **Une priorisation objective, homogène et reproductible** : le score fournit un critère unique de hiérarchisation des dossiers, appliqué de manière identique à tous. En substituant des règles et des algorithmes standardisés à l'appréciation individuelle, cette homogénéisation des pratiques garantit une cohérence d'évaluation indépendante des intervenants et réduit le risque de biais subjectifs ou

discriminatoires.

- **Une forte capacité de passage à l'échelle** : ces dispositifs absorbent des volumes croissants de données sans accroissement proportionnel des effectifs ni dégradation des performances. L'intervention humaine est ainsi recentrée sur les seuls dossiers présentant le niveau de risque le plus élevé, un atout précieux dans un contexte de croissance et de diversification des flux.

Cette logique constitue le fondement de l'outil développé dans ce mémoire. À chaque nouveau sinistre, l'agent attribue une probabilité de fraude permettant de hiérarchiser les dossiers selon leur niveau de risque. Les équipes d'investigation peuvent ainsi concentrer leurs efforts sur les cas les plus suspects, sans mobiliser inutilement des ressources sur les dossiers présentant une faible probabilité de fraude. Le score ne se substitue pas à la décision humaine : il l'éclaire en transformant un ensemble de déclarations en une file de traitement priorisée.

2.2.4 Les points de vigilance à l'utilisation de l'intelligence artificielle

Ces bénéfices ne sont toutefois pas acquis sans contrepartie, et l'automatisation appelle plusieurs précautions, déjà évoquées dans le cadre de la gouvernance :

- **La qualité des données** : un modèle n'a de valeur que celle des données sur lesquelles il est entraîné. Des données incomplètes, erronées ou biaisées se traduisent mécaniquement par des prédictions de moindre qualité.
- **L'explicabilité des résultats** : un score de fraude ne saurait être opposé à un assuré sans que les facteurs ayant conduit à son attribution puissent être compris et justifiés. Cette exigence répond à des impératifs à la fois opérationnels, réglementaires et éthiques.
- **Le maintien d'une supervision humaine** : l'agent identifie les dossiers susceptibles de présenter un risque de fraude, mais ne prend pas la décision finale. L'investigation et la décision demeurent du ressort des équipes, ce qui permet d'éviter toute décision défavorable fondée exclusivement sur un traitement automatisé.
- **La surveillance de la performance du modèle** : les comportements frauduleux et les caractéristiques du portefeuille évoluant au fil du temps, les performances d'un modèle peuvent se dégrader en l'absence d'un suivi continu et d'un réentraînement périodique.

Loin de constituer une solution autosuffisante, l'intelligence artificielle apparaît ainsi comme un outil puissant dont l'efficacité demeure étroitement conditionnée à la qualité des données, à la robustesse de sa gouvernance et au maintien d'un cadre de contrôle rigoureux.

2.3 Comparaison du processus manuel et du processus automatisé

2.3.1 Les critères de comparaison

Comparer l'approche traditionnelle et l'approche automatisée suppose de fixer au préalable les dimensions sur lesquelles porte l'évaluation, afin d'éviter un jugement global et impressionniste. Sept critères apparaissent particulièrement structurants :

1. Le **volume de dossiers analysés** mesure la part du portefeuille effectivement soumise à un examen anti-fraude.
2. Le **taux de détection** rapporte les fraudes identifiées à la fraude réellement présente, et traduit l'efficacité du dispositif.
3. Le **coût par dossier** rend compte des ressources consommées pour analyser une déclaration.
4. Le **délai de traitement** conditionne la fluidité du règlement et la qualité de service.
5. L'**homogénéité et la traçabilité des décisions** renvoient à la reproductibilité du processus et à sa capacité à être audité.
6. La **scalabilité** désigne l'aptitude du dispositif à absorber une hausse du volume sans dégradation.
7. Enfin, la **dépendance à l'expertise** caractérise la vulnérabilité du processus à la disponibilité et au niveau de compétence des intervenants.

Ces critères couvrent ainsi les trois enjeux essentiels : l'efficacité de la détection, son coût, et sa robustesse.

2.3.2 Mise en regard des deux processus

La confrontation des deux approches selon ces critères peut être synthétisée comme suit :

Critère	Processus manuel	Processus automatisé (IA)
Volume de dossiers analysés	Partiel : seule une fraction des dossiers est examinée	Exhaustif : l'ensemble des dossiers est scoré
Taux de détection	Limité par la capacité humaine de contrôle	Plus élevé, y compris sur des schémas peu visibles
Coût par dossier	Élevé et croissant avec le volume	Faible coût marginal après développement du modèle
Délai de traitement	Long, tributaire de la charge des équipes	Quasi instantané (<i>scoring</i> automatique)
Homogénéité et traçabilité	Variable, subjective, peu reproductible	Critère unique, appliqué identiquement et traçable
Scalabilité	Faible : suppose d'accroître les effectifs	Élevée : montée en charge à coût quasi constant
Dépendance à l'expertise	Forte : qualité tributaire de chaque intervenant	Réduite à l'usage, déportée vers la conception du modèle

TABLE 2.1 – Comparaison du processus manuel et du processus automatisé de détection de la fraude

Cette mise en regard fait clairement ressortir l'avantage de l'automatisation sur les dimensions de volume, de coût, de délai et d'homogénéité. Elle ne doit cependant pas être lue comme la disqualification de l'intervention humaine.

D'une part, l'expertise reste indispensable en amont, pour concevoir, entraîner et valider le modèle, et en aval, pour instruire les dossiers signalés. D'autre part, **le modèle ne produit qu'une probabilité de fraude, c'est-à-dire un soupçon hiérarchisé, et non une preuve : seule l'investigation humaine permet d'établir la réalité de la fraude et d'en tirer les conséquences.**

L'automatisation ne supprime donc pas le travail humain, elle le **réoriente** : libérée du tri d'une masse indifférenciée de dossiers, l'expertise se concentre sur les cas à plus forte valeur ajoutée, ceux que le modèle a identifiés comme les plus à risque.

2.3.3 Vers un modèle hybride

De cette comparaison se dégage non pas une opposition, mais une complémentarité. Les forces de chaque approche répondent précisément aux faiblesses de l'autre : l'IA excelle dans le traitement exhaustif, rapide et homogène de gros volumes, là où l'humain excelle dans l'analyse fine, contextuelle et le jugement sur les cas complexes.

La configuration la plus efficace est dès lors un **modèle hybride**, dans lequel chaque acteur intervient là où il est le plus pertinent. L'IA assure le **filtrage et la priorisation** : elle analyse l'ensemble des dossiers et les classe par niveau de risque. L'humain assure **l'investigation et la décision finale** : il examine les dossiers prioritaires, confirme ou écarte la suspicion, et prononce les suites à donner. Cette articulation préserve la maîtrise humaine du processus tout en démultipliant sa portée.

C'est exactement cette logique hybride que met en œuvre l'Agent développé dans ce mémoire, dont nous présenterons la conception et le fonctionnement après un rapide rappel du cadre théorique sur les algorithmes de détection de fraude utilisés en assurance non-vie.

Chapitre 3

Cadre théorique : les algorithmes de détection de fraude utilisés en assurance non-vie

La détection de la fraude circonstancielle se formule naturellement comme un problème d'apprentissage supervisé binaire. Cette formulation suppose de disposer d'un historique de sinistres dont l'issue (frauduleuse ou licite) a été établie, par exemple à l'issue d'enquêtes passées. On note l'échantillon d'apprentissage :

$$\mathcal{D}_n = \{(x_i, y_i)\}, \quad i = 1, \dots, n, \quad (3.1)$$

Où le vecteur $x_i \in \mathbb{R}^p$ rassemble les p caractéristiques décrivant le sinistre et l'assuré (montant déclaré, ancienneté du contrat, délai entre la souscription et la survenance, antécédents, nature de la garantie, canal de déclaration, etc.), et où la variable cible $y_i \in \{0, 1\}$ vaut 1 lorsque le sinistre est frauduleux. Cette classe d'intérêt est par nature **minoritaire**, ce qui constitue l'une des principales difficultés statistiques du problème et conditionne tant le choix des modèles que celui des métriques d'évaluation. L'objectif commun à toutes les méthodes présentées ci-dessous est d'estimer une **fonction de score** exprimant la probabilité de fraude conditionnelle aux caractéristiques observées :

$$\hat{p}(x) = \hat{P}(Y = 1 \mid X = x) \in [0, 1]. \quad (3.2)$$

Le recours à une sortie continue plutôt qu'à une décision binaire immédiate est un choix structurant. Il permet de hiérarchiser les dossiers selon leur niveau de risque et de ne déclencher une investigation (coûteuse) que sur les cas les plus suspects, le seuil de décision étant calibré séparément selon une logique

économique (rapport entre le coût d'une enquête et le gain espéré d'une fraude évitée). Cette logique de score partagée explique également pourquoi l'évaluation des modèles ne peut reposer sur le simple taux de bonnes classifications, trompeur en présence de classes déséquilibrées, mais s'appuie sur des indicateurs tels que la précision, le rappel et l'aire sous la courbe précision-rappel.

Les quatre familles de modèles retenues dans ce mémoire sont présentées selon un fil conducteur unique : l'arbitrage entre **interprétabilité** et **pouvoir prédictif**.

On progresse ainsi de la régression logistique, **modèle paramétrique** parfaitement transparent, vers la **forêt aléatoire** puis le **gradient boosting**, dont la capacité à capturer des relations complexes se paie d'une opacité croissante, avant de revenir avec les **modèles de scoring à points** à une représentation directement lisible par les équipes métier.

À noter que dans un secteur soumis à de fortes exigences d'explicabilité et de gouvernance (notamment de la part de l'ACPR¹), cet arbitrage n'est pas un simple détail technique mais un critère de sélection à part entière.

3.1 La régression logistique (modèle de référence)

La régression logistique constitue la référence historique de la modélisation du risque en actuariat. Il s'agit d'un **modèle linéaire généralisé** (GLM) appartenant à la famille binomiale et doté de la fonction de lien logit. Plutôt que de modéliser directement la probabilité, dont le domaine est borné à l'intervalle $[0, 1]$, le modèle agit sur le logarithme de la cote de fraude (le « log-odds »), dont le domaine couvre l'ensemble des réels, et le relie linéairement aux variables explicatives. Ainsi, la probabilité de fraude $p(x)$ s'écrit :

$$\ln \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \sum_{j=1}^p \beta_j x_j \quad (3.3)$$

En inversant cette relation, on retrouve la fonction logistique (ou sigmoïde) qui garantit une probabilité comprise entre 0 et 1. En notant $\eta = \beta_0 + \beta^\top x$ le prédicteur linéaire, la probabilité de fraude s'écrit :

$$p(x) = \frac{1}{1 + e^{-\eta}} \quad (3.4)$$

La forme sigmoïdale a une conséquence importante pour l'interprétation : la relation est linéaire sur l'échelle du logit, mais l'effet d'une variable sur la probabilité n'est pas constant : il est maximal autour de $p = 0,5$ et s'atténue aux extrêmes. Les coefficients β sont estimés par **maximum de vraisemblance**. Contrairement à la régression linéaire, il n'existe pas de solution analytique : la log-vraisemblance, dont l'expression est donnée ci-dessous, est concave et maximisée numériquement par des algorithmes itératifs de type Newton-Raphson (moindres carrés repondérés itérativement) :

1. ACPR : Autorité de Contrôle Prudentiel et de Résolution.

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln p(x_i) + (1 - y_i) \ln(1 - p(x_i))] \quad (3.5)$$

L'atout déterminant du modèle réside dans son interprétabilité directe. L'exponentielle d'un coefficient fournit un odds-ratio, c'est-à-dire le facteur par lequel la cote de fraude est multipliée lorsque la variable correspondante augmente d'une unité, toutes choses égales par ailleurs :

$$OR_j = e^{\beta_j} \quad (3.6)$$

Un odds-ratio supérieur à 1 traduit une variable aggravante, un odds-ratio inférieur à 1 une variable atténuante ; cette lecture immédiate facilite la justification des décisions et le dialogue avec les équipes de gestion et les autorités de contrôle.

Lorsque le nombre de variables est élevé ou que celles-ci sont fortement corrélées, on recourt à la **régularisation**, qui ajoute à l'objectif une pénalité sur la norme des coefficients afin de stabiliser l'estimation et de limiter le surapprentissage.

Ainsi on cherche à minimiser :

$$J(\beta) = -\ell(\beta) + \lambda \cdot \text{Pénalité}(\beta) \quad (3.7)$$

avec $\text{Pénalité}(\beta)$ qui admet différentes variantes :

- La pénalité L1 ² (Lasso) définie par $\text{Pénalité}(\beta) = \lambda \sum_{j=1}^p |\beta_j|$, qui a la propriété d'annuler certains coefficients, réalisant ainsi une sélection automatique de variables. En effet, si $\beta_j = 0$, la variable j est complètement exclue du modèle ;
- La pénalité L2 ³ (Ridge) définie par $\text{Pénalité}(\beta) = \lambda \sum_{j=1}^p \beta_j^2$, qui rétrécit les coefficients sans les annuler. Ainsi, toutes les variables restent dans le modèle mais leurs coefficients sont tassés. Ceci est particulièrement utile lorsque les variables sont fortement corrélées entre elles.
- L'elastic net, définie par $\text{Pénalité}(\beta) = \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right]$, avec $\alpha \in [0, 1]$, qui combine les deux termes avec un paramètre qui dose le mélange, pour bénéficier à la fois de la sélection et de la stabilité.

La principale limite du modèle tient à son hypothèse d'**additivité et de linéarité** sur l'échelle du logit : les interactions entre variables et les effets non linéaires ne sont pas captés automatiquement et doivent être spécifiés à la main (termes croisés, discrétisations, transformations). Face à des schémas de fraude où la suspicion naît précisément de la conjonction de plusieurs facteurs, cette contrainte motive le recours à des méthodes plus flexibles.

2. La pénalité L1 ajoute la somme des valeurs absolues des coefficients à l'objectif à minimiser.

3. La pénalité L2 ajoute la somme des carrés des coefficients.

3.2 La forêt aléatoire

La forêt aléatoire (random forest, Breiman, 2001) appartient à la famille des méthodes d'**agrégation** (ou méthodes ensemblistes), dont le principe est de combiner de nombreux modèles élémentaires pour obtenir un prédicteur plus performant et plus stable qu'aucun d'entre eux pris isolément. L'unité de base est l'**arbre de décision** (CART), qui partitionne récursivement l'espace des variables en régions de plus en plus homogènes au regard de la cible. À chaque nœud, l'algorithme évalue toutes les coupures possibles (une variable et un seuil) et retient celle qui maximise la décroissance d'une mesure d'impureté. Les deux mesures les plus courantes en classification sont l'indice de Gini $G(t)$ et l'entropie de Shannon $H(t)$, calculés sur un nœud t comportant une proportion $\hat{p}_{t,1}$ de sinistres frauduleux :

$$G(t) = 2\hat{p}_{t,1}(1 - \hat{p}_{t,1}) \quad (3.8)$$

$$H(t) = - \sum_k \hat{p}_{t,k} \log_2 \hat{p}_{t,k} \quad (3.9)$$

La construction se poursuit jusqu'à un critère d'arrêt (profondeur maximale, effectif minimal par feuille), et la prédiction associée à une feuille est la fréquence empirique de fraude qu'elle contient. Pris isolément, un arbre profond présente un **biais faible mais une variance élevée** : il s'adapte finement aux données mais une légère perturbation de l'échantillon peut bouleverser sa structure et donc ses prédictions. C'est cette instabilité que la forêt aléatoire vient corriger, au moyen de deux mécanismes complémentaires.

Le premier est le **bagging** (*bootstrap aggregating*) : on construit B arbres sur autant d'échantillons obtenus par tirage avec remise dans les données d'origine, puis on moyenne leurs prédictions. La moyenne de prédicteurs de même loi réduit la variance sans augmenter le biais, d'autant plus efficacement que ces prédicteurs sont peu corrélés (la décomposition formelle de cette réduction est reportée en annexe).

Le second mécanisme vise précisément à **décorréliser** les arbres : à chaque nœud, l'algorithme ne considère qu'un sous-ensemble aléatoire de $m \leq p$ variables candidates (typiquement $m = \sqrt{p}$ en classification), renouvelé à chaque division. Cette restriction empêche les quelques variables les plus prédictives de structurer tous les arbres de façon identique, ce qui diversifie l'ensemble et amplifie la réduction de variance. Le score final est la moyenne des B arbres T_b :

$$\hat{p}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_{T_b}(x) \quad (3.10)$$

Avec $\hat{p}_{T_b}(x)$ la prédiction de l'arbre numéro b pour un individu x .

Le tirage *bootstrap* offre en outre un mécanisme d'évaluation interne quasiment gratuit : chaque observation étant en moyenne absente d'environ 37 % des échantillons, elle peut être prédite par les seuls arbres qui ne l'ont pas vue, fournissant une estimation peu biaisée de l'erreur de généralisation (erreur *out-of-bag*). Cet avantage est précieux en détection de fraude, où les cas étiquetés sont rares et où l'on souhaite préserver un maximum d'observations pour l'apprentissage. Bien que moins transparente que

la régression logistique, la forêt n'est pas une pure boîte noire : elle fournit des **mesures d'importance des variables** (décroissance moyenne d'impureté, importance par permutation) qui restituent une part d'interprétabilité utile à la gouvernance du dispositif.

Les propriétés de la forêt aléatoire en font un candidat particulièrement adapté à notre problème : elle capture automatiquement non-linéarités et interactions, tolère des variables hétérogènes, corrélées ou aberrantes, ne requiert qu'un prétraitement limité, et gère le déséquilibre des classes via une pondération ou un rééquilibrage des tirages (*balanced random forest*). Elle se règle au moyen de quelques hyperparamètres principaux, notamment le nombre d'arbres, le nombre de variables candidates par nœud et la complexité des arbres, et échange une part de l'interprétabilité paramétrique du GLM contre un gain substantiel de pouvoir prédictif.

3.3 Le gradient boosting

Le **gradient boosting** est, comme la forêt aléatoire, une méthode ensembliste fondée sur des arbres, mais il en diffère radicalement par sa logique de construction. Là où le bagging assemble des arbres **en parallèle** pour réduire la variance, le boosting les construit **séquentiellement**, chaque nouvel arbre s'attachant à corriger les erreurs résiduelles de l'ensemble déjà constitué ; il vise donc avant tout à réduire le biais. Le modèle final est une somme pondérée de M arbres h_m :

$$F_M(x) = \sum_{m=1}^M \nu h_m(x) \quad (3.11)$$

Cette somme se construit de façon récursive : partant d'un modèle initial constant, on enrichit à chaque étape le modèle courant d'un nouvel arbre pondéré par le taux d'apprentissage $\nu \in (0, 1]$:

$$F_m(x) = F_{m-1}(x) + \nu h_m(x) \quad (3.12)$$

La clé de la méthode est l'interprétation de cette correction comme une **descente de gradient dans l'espace des fonctions**. À chaque étape, on calcule les **pseudo-résidus** r_{im} , définis comme l'opposé du gradient de la fonction de perte L évalué aux prédictions courantes, puis on ajuste un arbre pour les approcher :

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}} \quad (3.13)$$

Le taux d'apprentissage ν joue un rôle de régularisation essentiel : une valeur faible ralentit l'apprentissage et améliore la généralisation, au prix d'un plus grand nombre d'arbres. On combine fréquemment ce « shrinkage » avec un sous-échantillonnage aléatoire des observations et des variables à chaque étape (*stochastic gradient boosting*), ce qui réduit encore le surapprentissage. Les implémentations modernes ajoutent par ailleurs à la fonction de perte un terme de régularisation Ω pénalisant explicitement la

complexité des arbres (nombre de feuilles, norme des poids), de sorte que l'objectif minimisé s'écrit :

$$L(F) = \sum_{i=1}^n L(y_i, F(x_i)) + \sum_{m=1}^M \Omega(h_m) \quad (3.14)$$

Les bibliothèques de référence (XGBoost, LightGBM, CatBoost ⁴) mettent en œuvre ces principes avec des optimisations algorithmiques (construction par histogrammes, croissance des arbres par feuille, traitement natif des variables catégorielles) qui les rendent rapides et très performantes.

Le gradient boosting atteint généralement le meilleur pouvoir prédictif parmi les modèles considérés sur des données tabulaires telles que celles de la détection de fraude. En contrepartie, il est plus sensible au réglage des hyperparamètres et au surapprentissage : le nombre d'arbres doit être contrôlé par un arrêt précoce sur un jeu de validation, et son interprétabilité est moindre que celle de la forêt, ce qui conduit à s'appuyer sur des outils d'explication post-hoc (importance des variables, valeurs de Shapley ⁵) pour en restituer la logique.

3.4 Les modèles de scoring à points

Hérités de la pratique du credit scoring, les modèles de scoring à points (ou scorecards) ne constituent pas tant une nouvelle famille d'algorithmes qu'une méthode de mise en forme d'un modèle statistique (le plus souvent une régression logistique) en une grille de points additive, lisible et directement exploitable par un gestionnaire, sans recours à un outil informatique. Leur intérêt est avant tout opérationnel et réglementaire : dans un contexte assurantiel soumis à un devoir d'explication, pouvoir justifier un score par la simple addition de points attachés aux caractéristiques d'un dossier constitue un atout majeur.

La construction débute par une discrétisation de chaque variable en classes, définies de manière à être suffisamment peuplées et, idéalement, à présenter un risque monotone. Cette étape capture les non-linéarités propres à chaque variable et réduit la sensibilité aux valeurs extrêmes. Chaque classe se voit ensuite attribuer un poids de la preuve (Weight of Evidence, WOE), qui mesure son pouvoir discriminant en comparant la répartition des dossiers licites et frauduleux :

$$WOE_i = \ln \left(\frac{\% \text{ non-fraude}_i}{\% \text{ fraude}_i} \right) \quad (3.15)$$

Le pouvoir prédictif global d'une variable peut alors être quantifié par sa valeur informative (Information Value, IV), qui agrège les WOE de ses classes pondérées par l'écart de répartition, et sert à sélectionner et hiérarchiser les variables :

4. XGBoost, LightGBM et CatBoost sont des bibliothèques open source d'implémentation du gradient boosting, principalement utilisées en Python.

5. La valeur de Shapley de la variable j pour un individu x mesure sa contribution marginale moyenne à la prédiction en moyennant sur toutes les coalitions possibles de variables.

$$IV = \sum_i (\% \text{ non-fraude}_i - \% \text{ fraude}_i) \times \text{WOE}_i \quad (3.16)$$

Une régression logistique est ensuite ajustée sur les variables transformées en WOE. Ses coefficients sont enfin convertis en points entiers au moyen d'une transformation affine, calée par deux paramètres : le facteur et l'offset, déterminés à partir d'un score de référence, d'une cote de référence et du nombre de points doublant la cote (PDO, Points to Double the Odds) :

$$\text{facteur} = \frac{PDO}{\ln 2} \quad (3.17)$$

$$\text{offset} = \text{Score}_0 - \text{facteur} \times \ln(\text{Odds}_0) \quad (3.18)$$

Les points attribués à une classe de la variable j combinent le coefficient estimé, le WOE de la classe, l'ordonnée à l'origine α répartie sur les p variables, et les paramètres de calage :

$$\text{Points}_j = \left(\beta_j \times \text{WOE}_j + \frac{\alpha}{p} \right) \times \text{facteur} + \frac{\text{offset}}{p} \quad (3.19)$$

Le score d'un dossier est alors la simple somme des points de chacune de ses caractéristiques :

$$\text{Score} = \sum_{j=1}^p \text{Points}_j \quad (3.20)$$

Ce dispositif présente une transparence et une auditabilité maximales : chaque point du score est traçable jusqu'à une caractéristique précise du dossier, ce qui satisfait directement les exigences d'explicabilité et facilite le suivi de la stabilité du modèle dans le temps (via des indicateurs de dérive des populations).

En contrepartie, la discrétisation et la dépendance à une structure logistique entraînent une **perte de finesse prédictive** par rapport au *gradient boosting*, et la définition des classes demande un travail manuel non négligeable. Le *scoring* à points occupe ainsi une position singulière dans notre panorama : il referme la boucle ouverte par la régression logistique en réconciliant la performance statistique avec une lisibilité opérationnelle.

On peut d'ailleurs envisager une articulation des deux logiques : un modèle puissant de type gradient boosting pour la détection, doublé d'une grille de points pour l'explication et la communication des décisions aux gestionnaires et aux assurés.

3.5 Apprentissage non supervisé : détection d'anomalies et comportements atypiques

Si l'apprentissage supervisé excelle dans l'identification de schémas de fraude historiquement connus, il présente une limite structurelle majeure : **il est vulnérable aux techniques de fraude émergentes** (*zero-day frauds*). En effet, un algorithme supervisé ne peut prédire que ce qu'il a déjà vu.

Pour pallier cette faille, les assureurs déploient en complément des algorithmes d'apprentissage non supervisé (*Unsupervised Learning*). Dans ce paradigme, la variable cible Y (le label « fraude » ou « non-fraude ») est ignorée ou indisponible. L'algorithme explore uniquement l'espace des variables explicatives X pour identifier des structures sous-jacentes ou des déviations statistiques. La fraude est alors assimilée à une anomalie, c'est-à-dire une observation qui dévie si significativement des autres qu'elle éveille le soupçon d'avoir été générée par un mécanisme différent.

Deux grandes familles de méthodes se distinguent pour ce type d'analyse : les algorithmes d'isolation et le partitionnement des données.

3.5.1 Les algorithmes d'isolation (exemple : Isolation Forest)

Contrairement aux approches statistiques classiques qui cherchent d'abord à modéliser le comportement « normal » pour ensuite en déduire les anomalies, l'*Isolation Forest* cherche directement à isoler les anomalies. Ce modèle repose sur un postulat simple : les anomalies sont des données « peu nombreuses et différentes » (*few and different*).

L'algorithme construit une forêt d'arbres (les *Isolation Trees*). Pour chaque arbre, il sélectionne aléatoirement une variable et un seuil de coupure aléatoire (compris entre le minimum et le maximum de cette variable) pour partitionner l'espace récursivement.

Mathématiquement, la métrique clé est la longueur du chemin $h(x)$, c'est-à-dire le nombre d'arêtes qu'une observation x doit parcourir depuis la racine de l'arbre jusqu'à atteindre une feuille terminale où elle est isolée. Parce qu'elles sont situées dans des zones clairsemées de l'espace vectoriel, les anomalies nécessitent beaucoup moins de coupures pour être isolées que les observations normales.

Le score d'anomalie $s(x, n)$ pour un jeu de n données est défini par :

$$s(x, n) = 2^{-\frac{\mathbb{E}(h(x))}{c(n)}} \quad (3.21)$$

Où $\mathbb{E}(h(x))$ est l'espérance de la longueur du chemin sur l'ensemble des arbres, et $c(n)$ est une constante de normalisation représentant la longueur moyenne non réussie d'une recherche dans un arbre binaire.

Si $s(x, n)$ tend vers 1, le sinistre est fortement suspect et justifie une levée de doute par un expert. Si le score tend vers 0,5, le sinistre est considéré comme non frauduleux.

3.5.2 Le partitionnement de données (Clustering)

Les algorithmes de Clustering (tels que les K-Means) visent à regrouper les sinistres en sous-ensembles (les clusters) de telle sorte que les dossiers d'un même groupe soient les plus similaires possibles, tout en étant distincts des autres groupes.

Dans le cas de l'algorithme K-Means, l'objectif est de minimiser la variance intra-classe (la distance au carré entre chaque sinistre x_i et le centre de gravité μ_j de son cluster de rattachement) :

$$J = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - \mu_j\|^2 \quad (3.22)$$

Appliqué à la lutte anti-fraude, le clustering permet d'identifier des sinistres qui ne s'intègrent dans aucun des clusters principaux (les dossiers de masse), ou qui forment de très petits groupes (micro-clusters) très éloignés des autres. Ces poches de données marginales signalent souvent des comportements atypiques, comme des réseaux organisés déclarant des sinistres aux caractéristiques étrangement similaires.

3.6 Analyse de réseaux (Graph Mining) pour la détection de la fraude organisée

Contrairement à la fraude opportuniste (un assuré isolé qui majore ponctuellement un devis), la fraude en bande organisée implique une complicité entre plusieurs acteurs coordonnés dans le but de soutirer des capitaux importants à la compagnie d'assurance de manière répétée.

Ce type de criminalité financière s'appuie sur des réseaux structurés incluant de faux assurés, des prête-noms, et bien souvent des professionnels complices (garagistes, sociétés de dépannage, professionnels de santé ou experts automobiles marrons). Leurs modes opératoires sont quasi industriels : accidents de la circulation mis en scène, carambolages fictifs en chaîne, ou recyclage de véhicules gravement endommagés.

La dangerosité extrême de ces réseaux réside dans leur capacité à « lisser » le risque : pris isolément, chaque sinistre déclaré par le réseau est conçu pour paraître parfaitement vraisemblable et passer sous les radars des règles de gestion classiques. Les algorithmes de Machine Learning vus précédemment montrent ici leurs limites, car ils analysent chaque dossier de manière individuelle. C'est précisément pour contourner ce camouflage qu'il devient impératif de ne plus regarder les sinistres, mais les liens cachés qui les unissent, grâce à la théorie des graphes (Graph Mining).

3.6.1 Modélisation mathématique du réseau de fraude

Dans cette approche, le portefeuille de sinistres n'est plus vu comme un simple tableau (lignes/colonnes), mais est modélisé sous la forme d'un graphe mathématique $G = (V, E)$.

- **Les Nœuds (Vertices : V)** : ils représentent les entités du système. Il peut s'agir d'un dossier de sinistre, d'un assuré, d'un numéro de téléphone, d'une adresse IP ou d'un professionnel de l'automobile.
- **Les arêtes (Edges : E)** : elles matérialisent une relation entre deux nœuds. Une arête est créée si deux sinistres partagent un attribut commun (ex : même garagiste, même compte bancaire pour l'indemnisation) ou s'ils présentent une similarité vectorielle anormalement élevée (ce qui trahit souvent la réutilisation d'un même scénario de fraude).

On peut mesurer la similarité entre deux dossiers A et B dans l'espace des variables via la similarité cosinus :

$$\text{Similarité}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} \quad (3.23)$$

Si cette similarité dépasse un seuil critique défini par l'actuaire, une arête est tracée entre les deux dossiers.

3.6.2 Détection de communautés et de clusters suspects

Une fois le graphe construit, l'objectif n'est plus d'évaluer la probabilité de fraude d'un nœud individuel, mais d'identifier des sous-graphes anormalement denses. En théorie des graphes, on appelle cela la détection de communautés ou de composantes connexes.

Des algorithmes comme la méthode de Louvain ou la propagation de labels (Label Propagation) sont utilisés pour partitionner le graphe. Ils cherchent à maximiser la modularité Q , c'est-à-dire la densité des liens à l'intérieur d'un cluster par rapport à la densité des liens à l'extérieur :

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j) \quad (3.24)$$

Où A_{ij} est la matrice d'adjacence, k_i est le degré du nœud i , m le nombre total d'arêtes, et $\delta(c_i, c_j)$ indique si les nœuds appartiennent à la même communauté c .

3.6.3 Application opérationnelle

Sur le plan opérationnel, lorsqu'un algorithme de Graph Mining isole un cluster suspect, il fournit une alerte d'une valeur ajoutée qualitativement différente de celle produite par les modèles de scoring individuels classiques. L'investigation ne porte plus sur un sinistre isolé de 2 000 €, mais sur un réseau organisé dont le préjudice global potentiel se chiffre en plusieurs dizaines, voire centaines de milliers d'euros. Cette bascule d'échelle transforme profondément la logique d'allocation des ressources au sein des cellules anti-fraude.

Concrètement, le cluster fourni par l'algorithme se matérialise sous la forme d'un graphe annoté restituant

l'ensemble des entités impliquées (assurés, prestataires, intermédiaires) ainsi que la nature et la fréquence de leurs interactions. L'enquêteur dispose ainsi d'une cartographie complète du réseau présumé, lui permettant d'identifier le nœud central (souvent le coordinateur du schéma frauduleux) et de hiérarchiser ses investigations en remontant des ramifications périphériques vers le cœur du dispositif. Cette approche contraste avec l'instruction traditionnelle dossier par dossier, où les connexions entre sinistres restent invisibles faute d'une vision transversale.

Du point de vue du pilotage, le démantèlement d'un tel réseau offre un retour sur investissement massif pour la compagnie d'assurance. Là où l'instruction d'un dossier individuel mobilise plusieurs heures d'analyse pour un enjeu financier limité, une seule investigation réseau peut aboutir à la neutralisation simultanée de plusieurs dizaines de dossiers frauduleux, à des résiliations en cascade et, le cas échéant, à des dépôts de plainte groupés susceptibles d'aboutir à des condamnations pénales. Ces dernières constituent un signal dissuasif fort, dont l'effet préventif sur les comportements frauduleux dépasse largement le périmètre du réseau démantelé.

Enfin, les sorties du Graph Mining s'intègrent naturellement aux processus de reporting réglementaire. Les clusters détectés, documentés et tracés, alimentent les déclarations de soupçon transmises à Tracfin⁶ et renforcent la robustesse du dispositif LCB-FT⁷ de la compagnie, démontrant aux autorités de contrôle, notamment à l'ACPR, que la lutte contre la fraude organisée repose sur des méthodes quantitatives structurées et auditable.

3.7 Critères de qualité des modèles mis en place

La première mesure naturelle de la qualité d'un modèle de détection de fraude est le **taux de bien classés** (ou *accuracy*), défini comme la proportion d'individus correctement classés parmi l'ensemble de la population soumise au modèle. Il se calcule directement à partir de la matrice de confusion, qui croise les prédictions du modèle avec les statuts réels observés selon quatre configurations possibles.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.25)$$

Un dossier est dit :

- **Vrai positif (TP)** lorsque le modèle prédit une fraude et que le dossier est effectivement frauduleux ;
- **Vrai négatif (TN)** lorsque le modèle prédit un dossier sain et que celui-ci l'est bien ;

6. Tracfin (Traitement du renseignement et action contre les circuits financiers clandestins) est une cellule de renseignement financier placée sous la tutelle du ministère de l'Économie et des Finances. Créée en 1990, elle est chargée de recueillir, analyser et transmettre aux autorités judiciaires les déclarations de soupçon émises par les professionnels assujettis (dont les organismes d'assurance).

7. La LCB-FT (Lutte contre le blanchiment de capitaux et le financement du terrorisme) désigne l'ensemble du dispositif réglementaire et opérationnel imposé aux acteurs du secteur financier et assurantiel pour prévenir, détecter et signaler ces infractions. En France, ce dispositif est principalement encadré par le Code monétaire et financier (articles L. 561-1 et suivants), transposant les directives européennes.

- **Faux positif (FP)** lorsqu'un dossier sain est incorrectement signalé comme frauduleux (génération d'un coût opérationnel inutile et une dégradation de l'expérience client) ;
- **Faux négatif (FN)** lorsqu'un dossier frauduleux n'est pas détecté, constituant la perte financière directe pour la compagnie.




FIGURE 3.1 – Matrice de confusion

Toutefois, si le taux de bien classés présente l'avantage d'une lecture immédiate, il s'avère trompeur dans le contexte de la détection de fraude, où les classes sont structurellement déséquilibrées : la fraude ne représente généralement que 1 à 3 % des dossiers.

Un modèle naïf prédisant systématiquement « non-fraude » atteindrait mécaniquement un taux de bien classés supérieur à 97 %, sans détecter la moindre fraude.

Cette limite justifie le recours à des critères complémentaires mieux adaptés aux distributions asymétriques, notamment des indicateurs capables de mesurer la capacité du modèle à ordonner les dossiers par risque (indépendamment de tout seuil), et d'autres la qualité d'une décision prise à un seuil déterminé.

Ainsi, on distingue :

- **Le coefficient de Gini et la courbe ROC** : ce coefficient mesure le pouvoir discriminant global du score, c'est-à-dire son aptitude à classer les sinistres frauduleux devant les sinistres licites. Cette capacité est mesurée sur l'ensemble de la plage de seuil possible, en s'appuyant sur la courbe ROC (*Receiver Operating Characteristic*). Cette courbe est construite en faisant varier le seuil de décision de 0 à 1 en reportant pour chaque valeur, le taux de vrais positifs (TVP, ou rappel) en ordonnée contre le taux de faux positifs (TFP) en abscisse :

$$\text{TVP} = \frac{TP}{TP + FN}, \quad \text{TFP} = \frac{FP}{FP + TN} \quad (3.26)$$

Un modèle parfait atteint le point $(0, 1)$ (aucun faux positif, tous les fraudeurs détectés) tandis qu'un modèle aléatoire suit la diagonale principale. L'aire sous la courbe ROC, notée AUC (*Area Under the Curve*), synthétise cette performance en un scalaire entre 0,5 (aléatoire) et 1 (parfait). Le coefficient de Gini est directement relié à l'AUC par la relation : $Gini = 2 \times AUC - 1$ et varie de 0 (discrimination nulle, équivalente au hasard) à 1 (discrimination parfaite).

À titre indicatif, un Gini inférieur à 0,3 traduit un pouvoir discriminant faible, une valeur de 0,3 à 0,5 est acceptable, au-delà de 0,5 le modèle est jugé bon et au-delà de 0,6 très performant : ces bornes restant des conventions de *scoring* à adapter au contexte. Dans notre exemple d'application, un Gini supérieur à 0,5 est généralement considéré comme satisfaisant, compte tenu du fort déséquilibre des classes et de la rareté du signal frauduleux.

- **La statistique de Kolmogorov-Smirnov (KS)** : elle mesure l'écart maximal entre les fonctions de répartition cumulées des scores des deux populations (frauduleux et licites). De façon équivalente, elle correspond au plus grand écart entre le taux de vrais positifs et le taux de faux positifs le long de la courbe ROC : $KS = \max_s (TVP(s) - TFP(s))$. Comprise entre 0 et 1, elle indique en outre le seuil de score où la séparation entre les deux classes est la plus nette. En pratique, une valeur supérieure à 0,3 est généralement considérée comme acceptable et au-delà de 0,4 comme satisfaisante.
- **L'aire sous la courbe précision-rappel (PR-AUC)** : elle est particulièrement adaptée aux classes déséquilibrées, car elle se concentre sur la classe d'intérêt (la fraude) sans être flattée par l'abondance des vrais négatifs, contrairement à l'AUC-ROC qui peut donner une image trop optimiste. Son interprétation est relative : la valeur de référence (modèle aléatoire) n'est pas 0,5 mais la prévalence de la fraude π , de sorte qu'une PR-AUC doit toujours être appréciée au regard de ce taux de base.
- **Le F1-score** : il évalue une décision à un seuil fixé. Il s'agit de la moyenne harmonique de la précision $P = \frac{VP}{VP + FP}$ et du rappel $R = \frac{VP}{VP + FN}$, soit $F_1 = \frac{2PR}{P + R}$. Il offre un compromis entre les faux positifs (investigations menées à tort) et les faux négatifs (fraudes manquées). Comme il dépend du seuil retenu, on peut lui préférer une variante F_β pondérant davantage le rappel lorsque le coût d'une fraude non détectée est jugé supérieur à celui d'une enquête inutile.
- **Le lift au décile supérieur (lift@10 %)** : il s'agit d'un indicateur opérationnel directement aligné sur la logique de priorisation de l'outil. Après avoir classé tous les dossiers par score décroissant, il rapporte le taux de fraude observé dans les 10 % les plus suspects au taux de fraude global : $lift@10\% = \frac{\text{taux de fraude dans le décile supérieur}}{\text{taux de fraude global}}$. Un lift de 5 signifie que le décile ciblé concentre cinq fois plus de fraudes qu'une sélection aléatoire. Cet indicateur traduit concrètement le gain d'efficacité offert aux équipes d'investigation et se relie naturellement à l'arbitrage coût-bénéfice du dispositif.

De plus, on s'intéressera également à l'indice de stabilité des populations (PSI, Population Stability Index). Ce dernier ne mesure pas le pouvoir prédictif du modèle mais la stabilité de la population dans

le temps. Il quantifie l'écart entre la distribution des scores observée sur une population de référence (typiquement l'échantillon d'apprentissage) et celle observée sur une population récente, afin de détecter une dérive susceptible de dégrader la pertinence du modèle. Après avoir réparti les scores en classes (souvent les déciles de la population de référence), il se calcule comme la somme sur les classes des écarts de proportions pondérés par le logarithme de leur rapport :

$$\text{PSI} = \sum_i (a_i - r_i) \ln \left(\frac{a_i}{r_i} \right), \quad (3.27)$$

Où r_i et a_i désignent respectivement la proportion d'observations de la classe i dans la population de référence et dans la population actuelle. Par convention, un PSI inférieur à 0,1 traduit une population stable, une valeur comprise entre 0,1 et 0,25 signale une dérive modérée appelant une surveillance, et une valeur supérieure à 0,25 indique une dérive importante justifiant une investigation, voire un réentraînement du modèle. Le PSI peut s'appliquer à la distribution du score global comme à celle de chaque variable explicative, ce qui permet d'identifier l'origine d'une dérive. Il constitue ainsi un outil clé du suivi opérationnel de l'agent une fois déployé.

En synthèse, l'évaluation d'un modèle actuariel de détection de fraude articule six dimensions complémentaires : le pouvoir discriminant (Gini, KS, PR-AUC), la **qualité d'une décision seuillée** (F1, matrice de confusion), la **valeur économique** (coût espéré, ROI, lift financier), la **stabilité temporelle** (PSI) et l'**équité entre segments**. Aucun de ces indicateurs pris isolément n'épuise le jugement à porter sur l'agent ; c'est leur lecture conjointe, adossée à une matrice de coûts explicite et à un cadre de gouvernance clair, qui fonde la légitimité actuarielle du dispositif.

ANCRAGE RÉGLEMENTAIRE

Le dispositif d'évaluation retenu s'inscrit dans les attentes de la recommandation ACPR 2020-R-01⁸ sur la gouvernance des algorithmes en assurance, laquelle exige l'existence d'un cadre de suivi de performance, de stabilité et d'explicabilité tout au long du cycle de vie du modèle. Le règlement européen sur l'intelligence artificielle classe par ailleurs les dispositifs de détection de fraude en assurance vie et santé comme systèmes à haut risque, imposant une documentation technique détaillée, une surveillance humaine et une évaluation continue, exigences que la batterie d'indicateurs présentée ci-dessus contribue à satisfaire (cf. 4.1).

Chapitre 4

Mise en place d'un processus de détection de fraude automobile automatisé à l'aide d'un Agent IA

4.1 Gouvernance autour de la mise en place de l'Agent IA

Avant même d'aborder la conception technique de l'outil, la mise en place d'un agent de détection de fraude doit être encadrée par une gouvernance explicite. Un tel dispositif traite en effet des données personnelles d'assurés, alimente des décisions susceptibles d'affecter individuellement ces derniers (orientation d'un dossier vers une enquête, suspicion portée sur une déclaration), et s'inscrit dans un secteur étroitement supervisé.

La gouvernance n'est donc pas un complément formel postérieur au modèle, mais un préalable structurant qui en définit le cahier des charges. On peut l'articuler autour de trois niveaux complémentaires :

- Un cadre réglementaire et de conformité,
- Une organisation interne et une répartition des responsabilités,
- Et enfin une maîtrise opérationnelle du cycle de vie du modèle assortie d'une supervision humaine.

Sur le plan réglementaire, le dispositif s'inscrit d'abord dans le cadre du Règlement général sur la protection des données (RGPD).

Les principes de finalité, de minimisation et de légalité du traitement encadrent la collecte et l'usage des données du sinistre et de l'assuré, tandis que l'article 22¹, relatif aux décisions individuelles fondées exclusivement sur un traitement automatisé, impose une vigilance particulière : un assuré ne saurait voir sa déclaration rejetée sur la seule base d'un score algorithmique, sans intervention humaine ni possibilité de contestation.

À ce socle s'ajoute désormais le **règlement européen sur l'intelligence artificielle (« AI Act »)**. Le règlement (UE) 2024/1689 est entré en vigueur le 1^{er} août 2024 selon une application échelonnée, les pratiques interdites étant effectives depuis le 2 février 2025. Son annexe III classe parmi les **systèmes à haut risque** ceux relevant de l'accès aux services essentiels, dont l'assurance. À la suite de l'accord politique dit « Digital Omnibus » du printemps 2026, l'application des obligations relatives aux systèmes à haut risque de l'annexe III a toutefois été reportée au 2 décembre 2027.

La qualification précise d'un agent de détection de fraude automobile reste à apprécier au cas par cas : la catégorie à haut risque vise surtout l'évaluation du risque et la tarification, de sorte qu'un outil qui se borne à signaler des dossiers à des enquêteurs humains se situe vraisemblablement à un niveau de risque inférieur.

La prudence conduit néanmoins à anticiper les exigences applicables aux systèmes sensibles : un système de gestion des risques documenté, une gouvernance des données garantissant leur qualité et l'absence de biais discriminatoires, une documentation technique complète, la journalisation des activités assurant la traçabilité, des obligations de transparence, une supervision humaine et un niveau adéquat de précision, de robustesse et de cybersécurité.

Pour certains déployeurs de services essentiels privés, une analyse d'impact sur les droits fondamentaux (FRIA², *Fundamental Rights Impact Assessment*) peut par ailleurs être requise, distincte de l'analyse d'impact relative à la protection des données. Enfin, l'agent évolue dans l'environnement particulier de la lutte contre la fraude à l'assurance, qui mobilise des dispositifs sectoriels propres (échanges de place, conventions professionnelles) et impose le respect du secret et des droits de la personne concernée.

Au-delà du cadre légal, la gouvernance doit intégrer les attentes du superviseur national.

Dès juin 2020, l'ACPR a publié un document de réflexion sur la gouvernance des algorithmes d'intelligence artificielle dans le secteur financier, fruit de travaux exploratoires menés depuis 2018 avec des acteurs du secteur, et portant notamment sur l'explicabilité et la gouvernance du *machine learning*.

Ces travaux ont dégagé quatre critères interdépendants d'évaluation des algorithmes : la gestion appropriée des données, la performance, la stabilité et l'explicabilité. Un arbitrage est nécessaire entre ces quatre critères, ainsi qu'un principe de validation continue. L'explicabilité y est érigée en pilier et déclinée selon plusieurs niveaux, selon que l'on s'adresse à la clientèle, à des experts métier ou à des auditeurs.

Ces orientations fixent un horizon clair : **l'agent devra être non seulement performant, mais aussi auditable et explicable à différents publics, ce qui justifie a posteriori l'attention portée à**

1. « La personne concernée a le droit de ne pas faire l'objet d'une décision fondée exclusivement sur un traitement automatisé, y compris le profilage, produisant des effets juridiques la concernant ou l'affectant de manière significative de façon similaire. » (§1, <https://gdpr-text.com/fr/read/article-22/>).

2. Évaluation structurée, réalisée avant le déploiement, imposée par l'article 27 de l'AI Act à certains déployeurs de systèmes d'IA à haut risque.

l'interprétabilité des modèles dans la partie théorique³.

Ce cadre externe se traduit en interne par une organisation et une répartition des rôles formalisées. La conduite du projet gagne à être pilotée par une instance de gouvernance réunissant les parties prenantes : les équipes métier de la gestion des sinistres et de la lutte anti-fraude, qui portent le besoin et la connaissance du terrain ; les data scientifiques et actuaires, responsables de la conception et de la validation statistique ; la fonction conformité et juridique ainsi que le délégué à la protection des données, garants du respect du cadre réglementaire ; et le contrôle interne ou l'audit, chargés d'une revue indépendante.

Cette organisation s'inscrit naturellement dans une politique de gestion du risque de modèle, qui définit les responsabilités, les exigences de documentation et les seuils de validation tout au long de la vie de l'agent.

La maîtrise opérationnelle porte enfin sur l'ensemble du cycle de vie du modèle : chaque étape (cadre des données, entraînement, validation indépendante, recette, déploiement puis surveillance) doit être documentée et tracée, de manière à pouvoir reconstituer a posteriori les choix effectués. Une attention spécifique est accordée à la détection et à la remédiation des biais, afin que le modèle ne reproduise pas de discriminations, directes ou indirectes via des variables corrélées à des caractéristiques protégées.

Mais surtout, le principe de supervision humaine structure l'ensemble du dispositif : l'agent produit un score ou une alerte, mais ne prononce aucune décision défavorable de façon automatique ; l'investigation et la décision finale demeurent du ressort d'un gestionnaire ou d'un enquêteur.

Ce maintien d'un « humain dans la boucle » répond à l'exigence de l'article 22 du RGPD, préserve les droits de l'assuré et circonscrit le risque réglementaire, tout en organisant une boucle de rétroaction : les retours des enquêteurs alimentant le suivi de la performance, la détection de la dérive du modèle dans le temps et son réentraînement encadré.

Posée en amont, cette gouvernance conditionne la confiance, la conformité et la pérennité du dispositif. Elle constitue le cadre dans lequel s'inscrit la conception de l'outil, présentée dans les sections suivantes.

3. https://acpr.banque-france.fr/system/files/2025-02/20200612_gouvernance_evaluation_ia.pdf




FIGURE 4.1 – Les trois niveaux de gouvernance encadrant la mise en place de l'agent IA de détection de fraude

4.2 Présentation de la base de données

4.2.1 Base de données source

L'illustration de la mise en place du processus de détection de fraude automobile réalisée dans ce mémoire se fera à l'aide d'une base de données récupérée en open source sous :

<https://www.kaggle.com/datasets/ahluwaliasaksham/car-insurance-fraud-detection-dataset>

Cette base de données concerne des sinistres automobiles, et contient le flag « frauduleux » sur lequel repose notre modélisation.

Elle contient 30 000 sinistres, dont 11,5 % sont des sinistres frauduleux. Ce pourcentage est sensiblement supérieur aux estimations communément admises en France, qui situent la fraude réelle autour de 5 % des sinistres automobile. Cet écart s'explique vraisemblablement par le mode de constitution de la base : les dossiers qui la composent ont en grande partie fait l'objet d'une instruction approfondie ou d'une suspicion préalable, ce qui tend mécaniquement à sur-représenter les cas frauduleux par rapport à un portefeuille de sinistres bruts. Conscient de ce biais, nous avons néanmoins choisi de travailler sur cette base, dans la mesure où elle offre un volume suffisant de cas labellisés pour entraîner et évaluer les modèles de détection. Les résultats obtenus devront donc être interprétés avec cette réserve méthodologique à l'esprit, et toute généralisation à l'ensemble du portefeuille automobile français nécessiterait une recalibration du modèle sur des données plus représentatives de la sinistralité réelle.

Usuellement dans les mémoires, une présentation de la base de données est réalisée en amont de la mise

en place d'un modèle sur les données. **On se propose ici de revisiter cette présentation, qui sera introduite dans les résultats de l'agent IA afin de mettre en avant le fait que ces travaux ont été automatisés via l'agent et non réalisés manuellement ou via un Code R, Python ou encore SAS, comme c'est le cas usuellement.**

Néanmoins, les variables présentes dans la base de données sinistre sont listées ci-dessous :

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
policy_id	Identifiant contrat	Identifiant	Texte	Identifiant unique du contrat d'assurance	POL100000 ... POL129999
policy_state	<i>État de souscription</i>	Contrat	Catégoriel	État américain de souscription du contrat	GA, PA, MI, CA, OH, NC, SC, WA, TX, NY...
policy_deductible	<i>Franchise</i>	Contrat	Numérique	Montant de la franchise (USD)	300 / 400 / 600 / 1000
policy_annual_premium	<i>Prime annuelle</i>	Contrat	Numérique	Prime annuelle payée par l'assuré (USD)	Float > 0
insured_age	<i>Âge de l'assuré</i>	Assuré	Entier	Âge de l'assuré en années	18 – 75
insured_sex	<i>Sexe de l'assuré</i>	Assuré	Catégoriel (3)	Sexe déclaré de l'assuré	MALE, FEMALE, OTHER
insured_education_level	<i>Niveau d'études</i>	Assuré	Catégoriel (4)	Niveau d'études de l'assuré	High School, College, Master, PhD
insured_occupation	<i>Profession</i>	Assuré	Catégoriel (8)	Profession de l'assuré	Manager, Lawyer, Doctor, Teacher, Sales, Clerk, Technician, Engineer
insured_hobbies	<i>Loisirs</i>	Assuré	Catégoriel (7)	Loisirs déclarés de l'assuré	reading, chess, yachting, hiking, camping, movies, paintball
incident_date	<i>Date du sinistre</i>	Sinistre	Date	Date du sinistre déclaré	YYYY-MM-DD
incident_type	<i>Type de sinistre</i>	Sinistre	Catégoriel (4)	Nature du sinistre	Parked Car, Vehicle Theft, Single Vehicle Collision, Multi-vehicle Collision
collision_type	<i>Zone d'impact</i>	Sinistre	Catégoriel (4)	Zone d'impact lors de la collision	Front, Rear, Side, Unknown
incident_severity	<i>Gravité du sinistre</i>	Sinistre	Catégoriel (3)	Gravité des dégâts matériels	Minor Damage, Major Damage, Total Loss
authorities_contacted	<i>Autorités contactées</i>	Sinistre	Catégoriel (4)	Autorités contactées suite au sinistre	Police, Fire, Ambulance, None (NaN)
incident_state	<i>État du sinistre</i>	Sinistre	Catégoriel (10)	État américain où le sinistre a eu lieu	GA, PA, MI, CA, OH, NC...
incident_city	<i>Ville du sinistre</i>	Sinistre	Texte	Ville où le sinistre a eu lieu	Texte libre
incident_hour_of_the_day	<i>Heure du sinistre</i>	Sinistre	Entier	Heure du sinistre (format 24h)	0 – 23
number_of_vehicles_involved	<i>Nb véhicules impliqués</i>	Sinistre	Entier	Nombre de véhicules impliqués dans le sinistre	1 – 4
bodily_injuries	<i>Nb blessés déclarés</i>	Sinistre	Entier	Nombre de blessés corporels déclarés	0 – 4

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
witnesses	<i>Nb témoins</i>	Sinistre	Entier	Nombre de témoins déclarés	0 – 5
police_report_available	<i>Rapport police disponible</i>	Sinistre	Booléen	Rapport de police disponible	Yes, No
claim_amount	<i>Montant réclamé</i>	Réclamation	Numérique	Montant réclamé par l'assuré pour ce sinistre (USD)	Float > 0
total_claim_amount	<i>Indemnisation totale</i>	Réclamation	Numérique	Montant total de l'indemnisation versée (USD)	Float > 0
fraud_reported	<i>Fraude confirmée (cible)</i>	Cible ML	Catégoriel	Variable cible : fraude confirmée ou non. Variable à prédire par le modèle. 11,5 % de Y dans la base.	Y (fraude) / N (légitime)

TABLE 4.1: Variables de la base de données source

Au total 24 variables, avec la variable « fraud_reported » correspondant au flag dossier frauduleux ou non et « total_claim_amount » le montant du sinistre.

4.2.2 Enrichissement de la base de données

Afin de rendre ce mémoire proche de la réalité des assureurs, le choix d'enrichir la base de données disponible a été réalisé.

En effet, certaines informations incluses dans la base telles que le niveau d'éducation (*insured_education_level*) ou encore les passions de l'assuré (*insured_hobbies*) ne font pas partie des questionnaires usuels de souscription en assurance automobile sur le marché français.

De plus, l'assureur, lors de la déclaration d'un sinistre, a accès à bien plus d'informations que celles reportées dans cette base : ces dernières ont été recréées par simulation à l'aide de Claude⁴ avec pour consigne d'être explicatives dans notre recherche d'identification de fraude **sans pour autant être en lien direct avec la variable à expliquer** (*fraud_reported*).

Ainsi, la base a été enrichie avec 6 types de données, toutes les données pouvant être rendues disponibles en pratique chez un assureur lors de la survenance d'un sinistre automobile :

1. **L'historique de l'assuré**, notamment ses sinistres passés, l'historique du contrat etc. ;
2. **Des informations sur le réseau de garagistes et les prestataires** impliqués dans la réparation du sinistre ;
3. **Des informations sur le tiers et les témoins**, de manière à identifier d'éventuels témoins récurrents ou des liens entre le tiers et l'assuré/les témoins ;
4. **Des informations sur le véhicule**, notamment son âge et sa valeur ;
5. **Des informations sur le comportement déclaratif**, notamment le délai entre la date de sinistre et de déclaration, le nombre de fois où l'assuré a modifié sa déclaration, le canal de déclaration

4. Assistant conversationnel développé par Anthropic, société américaine spécialisée en intelligence artificielle.

etc.;

6. Des informations géographiques et temporelles, notamment le jour de l'accident (férié/week-end) ou son lieu de survenance.

Au total, trente variables ont été générées et sont décrites ci-dessous :

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
insured_id	Identifiant assuré	Historique assuré	Texte	Identifiant stable de l'assuré, indépendant du numéro de contrat. Permet de relier les dossiers d'un même assuré.	INS000001 ... INS0XXXXXX
insured_nb_past_claims	Nb sinistres passés	Historique assuré	Entier	Nombre total de sinistres déclarés par cet assuré sur les 5 dernières années. Distributions chevauchantes, signal modéré.	0 – 5
insured_nb_past_fraud	Nb fraudes passées confirmées	Historique assuré	Entier	Nombre de fraudes confirmées antérieures pour cet assuré.	0 – 3
insured_days_since_last_claim	Jours depuis dernier sinistre	Historique assuré	Entier	Jours depuis le dernier sinistre de cet assuré.	60 – 2500
insured_claim_amount_history	Montant réclamé cumulé (3 ans)	Historique assuré	Numérique	Montant cumulé (USD) de toutes les réclamations de cet assuré sur 3 ans.	0 – 55 000
policy_age_at_incident_days	Ancienneté contrat (jours)	Contrat enrichi	Entier	Ancienneté du contrat en jours au moment du sinistre.	30 – 3600
insured_nb_policies_active	Nb contrats actifs	Contrat enrichi	Entier	Nombre de contrats d'assurance actifs simultanément (multi-assurance).	1 – 4
insured_address_changes_12m	Changements d'adresse (12 mois)	Historique assuré	Entier	Nombre de changements d'adresse dans les 12 derniers mois.	0 – 3
repairer_id	Identifiant réparateur	Réseau garagiste	Texte	Identifiant unique du réparateur mandaté. NONE = pas de réparateur.	GAR0001... GAR0899,NONE
repairer_nb_claims_total	Nb dossiers traités (réparateur)	Réseau garagiste	Entier	Nombre total de dossiers sinistres traités par ce réparateur dans la base.	0 – 200
repairer_nb_fraud_confirmed	Nb fraudes (réparateur)	Réseau garagiste	Entier	Nombre de fois où ce réparateur apparaît dans un dossier clôturé fraude.	0 – ~100

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
repairer_fraud_rate	Taux de fraude (réparateur)	Réseau garagiste	Numérique	Taux de fraudes du réparateur mandaté calculé comme $\frac{\text{repairer_nb_fraud_confirmed}}{\text{repairer_nb_claims_total}}$.	0 – 0,48
repairer_avg_invoice_vs_market	Ratio facture / marché	Réseau garagiste	Numérique	Ratio facture réparateur / prix marché. >1 = surfacturation.	0,85 – 1,55
repairer_is_flagged	Réparateur signalé	Réseau garagiste	Booléen 0/1	Réparateur inscrit en liste de vigilance.	0 = non signalé / 1 = signalé
third_party_id	Identifiant tiers	Réseau tiers	Texte	Identifiant du tiers impliqué. NONE si sinistre sans tiers.	TRS00001... TRS09999,NONE
third_party_nb_past_incidents	Nb incidents passés (tiers)	Réseau tiers	Entier	Nombre de fois où ce tiers est apparu dans des dossiers passés.	0 – 5
witness_id	Identifiant témoin	Réseau tiers	Texte	Identifiant du témoin principal. NONE si pas de témoin.	WIT00001... WIT11999,NONE
insured_third_party_known	Tiers connu de l'assuré	Réseau tiers	Booléen 0/1	Assuré et tiers se connaissent (même adresse, téléphone ou lien familial).	0 = inconnus / 1 = connus
vehicle_id	Identifiant véhicule	Véhicule	Texte	Immatriculation anonymisée.	VEH000001... VEH027999
vehicle_age_years	Âge du véhicule (années)	Véhicule	Entier	Âge du véhicule en années.	0 – 20
vehicle_market_value	Valeur marché du véhicule	Véhicule	Numérique	Valeur argus estimée du véhicule (USD). Distributions très chevauchantes.	2 000 – 40 000
vehicle_overvalue_ratio	Ratio surévaluation réclamation	Véhicule	Numérique	$\frac{\text{claim_amount}}{\text{vehicle_market_value}}$. >1 = réclamation dépasse la valeur du véhicule.	0,10 – 5,00
vehicle_nb_past_claims	Nb sinistres passés (véhicule)	Véhicule	Entier	Sinistres antérieurs sur ce véhicule, tous propriétaires confondus.	0 – 4
nb_amendments_declaration	Nb modifications déclaration	Comportement déclaratif	Entier	Nombre de modifications de la déclaration initiale.	0 – 4
declaration_channel	Canal de déclaration	Comportement déclaratif	Catégoriel (4)	Canal utilisé pour déclarer le sinistre.	web, telephone, agence, courtier
injury_claimed_without_medical	Blessure sans justificatif	Comportement déclaratif	Booléen 0/1	Blessures corporelles déclarées sans justificatif médical.	0 = justificatif présent / 1 = absent
incident_zip_fraud_rate	Taux fraude de la zone	Géographique	Numérique	Taux historique de fraude dans l'État du sinistre, calculé sur la base.	0,00 – 0,30

Champ (EN)	Nom (FR)	Axe	Type	Description	Modalités / Plage
incident_is_weekend	Sinistre en weekend	Temporel	Booléen 0/1	Sinistre un vendredi soir, samedi ou dimanche.	0 = semaine / 1 = weekend
incident_is_holiday	Sinistre jour férié	Temporel	Booléen 0/1	Sinistre un jour férié américain (1er jan, 4 juillet, Thanksgiving, Noël).	0 = jour normal / 1 = jour férié

TABLE 4.2: Variables d'enrichissement de la base de données

La base de données finale rassemble ainsi 24 variables issues de la base source et 30 variables d'enrichissement, soit 54 variables explicatives, auxquelles s'ajoute la variable cible binaire fraud_reported (Y/N). C'est sur cet ensemble que reposera l'apprentissage des modèles de détection.

4.3 Descriptif macro de la création du processus de détection de fraude et de sa déclinaison opérationnelle

Afin de répondre aux enjeux de rentabilité évoqués précédemment, un processus de détection automatisé à l'aide d'un Agent IA a été construit. L'objectif est de fournir aux équipes d'investigation un outil d'aide à la décision opérationnelle « clé en main ».

Cet outil repose sur une **logique en deux temps**, articulée autour de **deux profils d'utilisateurs distincts** :

- Dans un premier temps, une équipe d'actuaire se charge de modéliser, construire et entraîner le modèle de détection. À partir d'une base de données sinistres au format standardisé, l'outil réalise automatiquement des contrôles qualité sur les données, produit une étude statistique descriptive mettant en avant les indicateurs clés (fréquence de fraude, coût moyen, segmentation par critères prédéfinis), puis entraîne un modèle de détection de fraude. Le résultat est un modèle calibré, sauvegardé et prêt à être déployé.
- Dans un second temps, une équipe opérationnelle (gestionnaires sinistres ou service de détection des fraudes) utilise ce modèle au quotidien sans avoir à en comprendre la construction. Pour chaque nouveau sinistre soumis, l'outil restitue une probabilité de fraude associée, permettant d'identifier les dossiers suspects et de les prioriser. Ainsi, les équipes d'investigation peuvent concentrer leurs efforts sur les cas les plus à risque, sans perdre de temps sur les dossiers à faible probabilité de fraude.




FIGURE 4.2 – Vision macro du fonctionnement de l'outil

L'architecture complète de ce processus est détaillée dans les chapitres suivants, de l'alimentation de la base de données à la boucle d'enrichissement continu, en passant par la modélisation de la probabilité de fraude.

Le plus de l'agent : un suivi du ROI disponible

Enfin, l'outil produit automatiquement un **rapport annuel de détection de fraude**, enrichi à chaque fois qu'un sinistre testé est renseigné comme frauduleux par un expert. Ce rapport est accessible à tout moment et fournit une **synthèse consolidée des performances** : nombre de sinistres analysés, taux d'alertes générées, fraudes confirmées et montant de fraude évitée. Il calcule notamment l'impact direct sur le ratio Sinistres/Primes (S/P), indicateur clé de rentabilité en assurance, en rapportant le montant de fraude évitée à la masse de primes du portefeuille. Cette restitution permet au management de suivre en continu le retour sur investissement de l'outil (ROI) et d'objectiver la valeur ajoutée de la détection automatisée année après année.

4.3.1 Le prompt : la décomposition du besoin en étapes

Dans le contexte de l'intelligence artificielle, et plus particulièrement des modèles de langage, un prompt désigne l'ensemble des instructions, du contexte et des données fournis au modèle afin de guider son comportement et d'orienter la nature des réponses ou des actions qu'il produit. Il constitue le point d'entrée de l'interaction entre l'utilisateur (ou un système) et l'agent. Un prompt ne se réduit pas à une simple question : il peut comporter des consignes précises, des contraintes, des exemples et une structuration attendue du résultat. De façon générale, plus il est clair, détaillé et contextualisé, plus le

modèle est en mesure de produire une réponse pertinente et alignée sur l'objectif visé.

D'un point de vue méthodologique, le prompt peut être assimilé à la **spécification fonctionnelle** de la tâche confiée à l'agent : il joue, vis-à-vis du modèle, un rôle comparable à celui d'un cahier des charges vis-à-vis d'un modèle actuariel. Sa qualité conditionne directement celle du résultat, au même titre que la rigueur d'une note technique conditionne la fiabilité d'un calcul. Cette exigence rejoint les principes de gouvernance évoqués précédemment : un prompt explicite, documenté et reproductible contribue à la traçabilité et à l'auditabilité du dispositif, en rendant intelligibles les consignes sur lesquelles repose le comportement de l'agent.

Concrètement, un prompt bien construit remplit trois fonctions :

- Il **définit la cible** : il ne s'agit pas ici d'affirmer qu'un dossier est frauduleux (l'agent ne se substitue pas à l'enquêteur) mais d'identifier, à partir des données disponibles, les dossiers présentant un risque de fraude élevé.
- Il **précise le cadre d'intervention** : le rôle de l'agent, le contexte métier, les critères à prendre en compte et les limites de son action.
- Il **encadre enfin la forme de la réponse** attendue, par exemple un score, un tableau ou une synthèse exploitable par les équipes opérationnelles.

Pour obtenir un résultat précis, contrôlable et reproductible, il ne suffit toutefois pas de formuler une consigne unique et globale, qui laisserait à l'agent une marge d'interprétation trop large et nuirait à la stabilité des réponses. Nous avons donc adopté une approche de **construction du prompt par étapes** : plutôt que de soumettre l'intégralité de la tâche en un seul bloc, le raisonnement attendu de l'agent a été décomposé en une séquence d'étapes successives, chacune assortie d'un objectif clair et d'un résultat intermédiaire vérifiable.

Cette décomposition présente un double intérêt. Elle reproduit la logique même de la démarche actuarielle (du contrôle de la qualité des données à la production d'un score, en passant par l'analyse descriptive et la modélisation) et elle permet de valider chaque maillon de la chaîne indépendamment, limitant ainsi le risque d'erreur ou de dérive et renforçant l'explicabilité de l'ensemble.

Ainsi, le prompt constitue un élément central du système : il transforme une demande générale en une tâche claire, structurée et exploitable, et montre que l'efficacité de l'outil ne repose pas uniquement sur les données ou sur le modèle, mais aussi sur la qualité des instructions fournies à l'agent. Le raisonnement confié à ce dernier a en conséquence été structuré selon les étapes successives présentées ci-après.

4.3.2 Présentation macro des différentes étapes

Les étapes menant à la création du modèle sont ainsi décomposées :

1. Ingestion standardisée des données
2. Audit et contrôles de cohérence

3. Analyse statistique descriptive
4. Construction des modèles de prédiction de fraude
5. Critères de qualité du modèle et choix du modèle parmi les modèles construits

FIGURE 4.3 – Création et calibration du modèle de détection de fraude

Une fois le modèle de détection mis en place, il est intégré dans un outil d'aide à la décision destiné aux gestionnaires et au service fraude. Contrairement aux modules précédents, ce second module ne fonctionne pas selon une séquence figée : il se comporte comme un véritable logiciel au sein duquel l'utilisateur navigue librement. S'il existe un enchaînement logique naturel, l'utilisateur peut à tout moment revenir en arrière, répéter une opération ou accéder directement à une fonctionnalité selon ses besoins.

L'outil met à disposition les fonctionnalités suivantes :

- **La saisie d'un sinistre** : l'utilisateur renseigne les informations d'un dossier à évaluer.
- **L'obtention d'un score de fraude** : le modèle restitue une probabilité de fraude associée au sinistre soumis.
- **Le renseignement du statut du dossier** : lorsque l'issue de l'investigation est connue, l'utilisateur peut indiquer si le sinistre s'est avéré frauduleux ou non.

De plus, l'outil reste lié de manière cyclique au modèle puisque le renseignement du statut du dossier permet :

- l'alimentation de la base de données sinistre ayant servi à faire tourner le modèle ;
- l'affinage du modèle créé à l'aide des nouveaux sinistres renseignés.




FIGURE 4.4 – Représentation des différents blocs de l'agent d'aide à la détection de fraude

À noter que la logique de création des deux agents respecte l'objectif d'utilisation de ces derniers : **deux**

équipes distinctes seront en charge de leur utilisation, d'où le besoin de rendre totalement indépendants les deux agents créés.

Dans les paragraphes suivants, nous présenterons la restitution concrète produite par notre outil sur le portefeuille de sinistres simulé (construit à partir des données *Kaggle* enrichies).

Cette phase de conception du modèle constitue une étape amont essentielle, mais elle **n'a pas vocation à être maîtrisée par les équipes opérationnelles en charge de la détection de la fraude**. En effet, l'outil final qui leur est destiné repose sur un modèle déjà entraîné et optimisé, qu'ils pourront exploiter sans avoir à intervenir sur ses mécanismes internes. Ainsi, la complexité technique est volontairement « encapsulée » afin de **proposer une solution simple d'utilisation, centrée sur l'aide à la décision** aux gestionnaires.

Dans la pratique, la responsabilité de la construction, de l'ajustement et de l'amélioration continue du modèle incombe généralement à des profils spécialisés, tels que les actuaires ou les data scientists. Ces experts interviennent pour affiner les performances du modèle, intégrer de nouvelles données, ajuster les paramètres et garantir la robustesse des résultats dans le temps. Cette séparation des rôles permet d'assurer à la fois un haut niveau de performance analytique et une appropriation efficace de l'outil par les équipes métiers.

4.4 Étapes 1 & 2 : Ingestion de la base de données et Audit de contrôles de cohérence

4.4.1 Étape 1 : Ingestion de la base de données

La première étape correspond au chargement des données.

Sur la page d'accueil de l'outil, intitulée « Aide à la détection de fraude », nous invitons l'utilisateur à déposer son fichier de sinistres, qui constitue la donnée d'entrée de l'ensemble du processus.

Le dépôt peut se faire de deux manières :

- Soit par glisser-déposer directement dans la zone prévue à cet effet,
- Soit en cliquant sur le bouton « Parcourir vos fichiers » afin de sélectionner le document depuis l'explorateur.

Les formats acceptés sont les plus courants pour ce type de données, à savoir CSV, Excel (.xlsx et .xls) et ODS, de manière à s'adapter aux différents systèmes de gestion des professionnels de l'assurance.




FIGURE 4.5 – Extrait du prompt pour la création de l'étape 1

À ce stade, aucun choix de modèle n'est demandé : celui-ci n'interviendra qu'ultérieurement, une fois les analyses descriptives consultées, ce qui permet à l'utilisateur de sélectionner en connaissance de cause le modèle de détection le plus adapté à la structure de son portefeuille.

Enfin, nous signalons à l'utilisateur que les données importées sont traitées de manière sécurisée et confidentielle, l'outil étant réservé aux professionnels de l'assurance.

L'utilisateur clique ensuite sur le bouton « *submit* » pour passer à l'étape suivante.




FIGURE 4.6 – Page d’accueil de l’outil d’aide à la détection de fraude

4.4.2 Étape 2 : Audit et contrôles de cohérence

Dès l’importation du fichier brut de sinistres, l’outil procède à un audit automatisé, étape fondamentale de Data Profiling. L’objectif de cette interface n’est pas de réaliser un simple inventaire, mais de garantir l’intégrité et la qualité des données avant qu’elles ne soient intégrées dans un modèle de prédiction de la fraude.

Concrètement, comme illustré dans le tableau de restitution ci-dessous, le moteur cartographie le portefeuille en réalisant plusieurs contrôles croisés pour chaque variable :

- **La vérification du type** : l’outil confronte le type de donnée attendu par le système au type réellement détecté. Cela permet de bloquer instantanément les erreurs de formatage.
- **L’analyse des plages et modalités** : le système extrait automatiquement les bornes pour les variables numériques, et liste les différentes catégories pour les variables textuelles, facilitant la détection immédiate de valeurs aberrantes (*outliers*).
- **Le contrôle de complétude** : il calcule le taux de remplissage exact pour mettre en évidence

les données manquantes. En cas de donnée(s) manquante(s), l'Agent demande à l'utilisateur de les remplacer par une valeur par défaut à renseigner. À noter qu'il aurait également été possible de proposer des options de remplissage par défaut, par exemple, pour une variable quantitative, la moyenne ou encore la médiane ou la valeur la plus représentée.

Dans notre outil, un contrôle bloquant a été mis en place sur la complétude des données : l'agent ne permet pas la poursuite des tâches si la base de données n'est pas complète.

À titre illustratif, voici une sortie de l'outil lorsque la base admet une valeur manquante :




FIGURE 4.7 – Sortie de l'outil « Analyse de la qualité des données de la base » avec une valeur manquante

Ici, la variable « *policy_deductible* » qui correspond à la franchise du contrat admet une valeur manquante. L'utilisateur est invité à choisir une des valeurs qui s'affiche pour compléter la ligne manquante (les valeurs affichées correspondent aux modalités observées dans la base d'entrée), ou à entrer manuellement une valeur dans un champ dédié.

Une fois l'information complétée, l'affichage se met à jour automatiquement ⁵ :

5. L'affichage intégral de la sortie de l'agent à cette étape est disponible en Annexe (Cf. XXXX).

Analyse de la qualité des données de la base

Description de chaque colonne du fichier CSV — types, modalités, taux de remplissage et saisie obligatoire d'une valeur unique pour chaque variable contenant des cases vides avant de lancer les analyses suivantes.




FIGURE 4.8 – Sortie de l'outil « Analyse de la qualité des données de la base » sans valeur manquante

L'examen du tableau de contrôle permet de formuler deux observations métier majeures sur notre jeu de données :

- D'une part, le contrôle des bornes (colonne « Modalités / Plage ») valide la cohérence globale de notre portefeuille. À titre d'exemple, l'outil confirme immédiatement que la variable *insured_age* est strictement comprise entre 18 et 75 ans. L'absence de valeurs irréalistes confirme que les règles de gestion ont été respectées lors de la saisie.
- De plus, la variable cible de notre étude, *fraud_reported*, est correctement identifiée et renseignée à 100 %, condition sine qua non pour l'entraînement d'un modèle supervisé.

De plus, l'agent a la capacité de détecter les variables susceptibles d'être utilisées dans le modèle et celles qui ne le sont pas (cf. dernière colonne « Inclure ») : la variable « *policy_id* » correspondant à l'identifiant du contrat a été reconnue comme une variable d'incrément et est exclue de la modélisation. L'utilisateur peut également en exclure d'autres, pour des raisons réglementaires ou techniques à ce niveau.

Enfin, en bas de page, l'utilisateur doit préciser à l'agent quelle variable désigne la variable à expliquer.

Pour cela il suffit de sélectionner la variable cible dans la liste déroulante proposée :

Ici, c'est la variable *fraud_reported* qui est la variable à modéliser, et elle sera appelée « fraude » dans la suite des analyses.

4.5 Étape 3 : Analyse statistique des données

Une fois la qualité des données validée, l'agent bascule dans une phase d'analyse exploratoire :

- Univariée : il s'agit d'analyser la composition de notre portefeuille par variable ;
- Bivariée : il s'agit ici d'analyser la fréquence et le coût moyen de la fraude, au même titre que les analyses qui seraient réalisées dans le cadre d'une tarification produit.

4.5.1 Analyse de la composition du portefeuille

Avant d'engager toute modélisation ou détection de comportements atypiques, il est essentiel de dresser un portrait détaillé de la base de données sinistres automobiles étudiée.

Cette analyse préliminaire vise à caractériser la structure des sinistres déclarés selon plusieurs axes : la nature des sinistres (accidents corporels, dommages, etc.), ainsi que les caractéristiques des conducteurs impliqués (âge, sexe, profession, adresse, etc.) et les paramètres du contrat (franchise, prime annuelle, etc.)

Elle permet également d'examiner la distribution temporelle et géographique des déclarations, deux dimensions particulièrement révélatrices en matière de fraude automobile. Une telle exploration permet d'identifier d'éventuels déséquilibres ou concentrations atypiques dans les données (comme une surreprésentation de sinistres déclarés en fin de contrat ou dans certaines zones géographiques) et d'en tenir compte dans les étapes ultérieures de l'analyse. La connaissance fine de la structure de cette base constitue un prérequis indispensable à toute démarche actuarielle rigoureuse, en posant les fondements empiriques sur lesquels reposera l'ensemble de la modélisation de la fraude développée dans ce mémoire.

Le prompt adressé à l'agent concernant l'analyse de composition de portefeuille renvoie la sortie suivante :




FIGURE 4.9 – Composition du portefeuille

La base de données étudiée comprend 30 000 sinistres automobiles, offrant ainsi un volume suffisant pour mener une analyse statistique robuste et entraîner des modèles de détection de la fraude performants.

Les classifications de certaines variables proposées ici en sortie (comme *insured_age* et *incident_hour_of_the_day*) ont été définies par l'agent. Ces dernières seront modifiées par la suite et recrées via les méthodes classiques de création de classes telles que l'algorithme K-means ou encore la méthode de classification hiérarchique ascendante (cf. paragraphe 4.5.2).

Cette analyse descriptive de la base sinistres permet d'établir une vision globale de la structure des données, sans distinction entre sinistres frauduleux et non frauduleux. La section suivante propose d'affiner cette exploration en adoptant une lecture bivariable, c'est-à-dire en comparant systématiquement la distribution de chaque variable selon le statut de fraude, afin d'identifier les premières variables discriminantes qui pourront guider la construction des modèles prédictifs.

À noter que, de manière autonome, l'agent détecte automatiquement la représentation la plus adaptée à la variable à étudier, notamment des camemberts pour les variables qui admettent un faible nombre de modalités et des diagrammes en barres pour les variables admettant un nombre plus important de modalités.

Enfin, l'agent permet l'export de la sortie graphique de composition du portefeuille, à des fins de traçabilité ou d'études intermédiaires par exemple.

4.5.2 Analyse de la fréquence de la fraude

Suite à l'analyse de composition du portefeuille, une analyse de la fréquence de fraude selon les variables explicatives potentielles va être réalisée. Cette analyse permet d'avoir un premier aperçu des variables ayant un impact significatif sur le niveau de fraude observé et de valider par la suite la cohérence des modèles obtenus. Cette analyse permet également d'alimenter le choix de création de classes au sein d'une variables admettant des modalités ayant un comportement similaire en termes de taux de fraude.

L'agent va ensuite réaliser deux actions de manière autonome :

- Afficher le top3 des variables jugées comme les plus discriminantes au vu de la variable cible (affichage *on Top*)
- Choisir la représentation la plus adaptée à la variable à étudier, notamment des camemberts pour les variables qui admettent un faible nombre de modalités et des diagrammes en barre pour les variables admettant un nombre plus important de modalités.

ICI METTRE CAPTURE D'ECRAN

L'affichage a volontairement été limité à 4 variables à la fois pour offrir une meilleure clarté à l'utilisateur. Afin de permettre à l'utilisateur de visualiser l'ensemble des variables, un choix d'affichage est disponible à droite sur simple clic.

À noter que l'agent comprend également seul qu'il est inutile de réaliser l'analyse de la fraude par "police_id" par exemple, dans la mesure où cet indicateur sert de compteur (ou incrément) et n'a pas d'apport dans la modélisation. Pour rappel cette variable avait été décochée dès le début.

L'analyse de ces graphiques et diagrammes permet de dégager des enseignements métiers déterminants pour l'identification des sinistres frauduleux :

-

4.5.3 Création de classes de variables

La création de classes constitue une étape préalable importante à la mise en œuvre de certains modèles prédictifs, notamment lorsque les variables explicatives sont continues ou présentent un grand nombre de modalités.

Cette discrétisation permet de regrouper des observations présentant des caractéristiques similaires, afin de réduire la complexité des données, de limiter la sensibilité du modèle aux fluctuations locales et de faciliter l'interprétation des effets associés aux différentes variables.

En actuariat, elle contribue également à obtenir des groupes suffisamment homogènes et robustes d'un point de vue statistique.

Plusieurs approches peuvent être utilisées pour construire ces classes, parmi lesquelles les méthodes

fondées sur des quantiles ou des intervalles de largeur constante, les méthodes de classification via l'algorithme des K-means ou encore une classification hiérarchique ascendante.

Une présentation plus détaillée des principes théoriques et des principales méthodes de discrétisation est proposée en Annexe 7.5

Pour la suite des traitements, les variables suivantes ont été classifiées selon le découpage suivant :

Variable	Nombre de classes créées	Méthode de classification	Descriptif des classes
policy_annual_premium (prime annuelle)	5	Découpage de l'intervalle de valeur [600; 1 500] en amplitudes égales. Contrôle de l'effectif par classe créée ($\geq 5\%$)	[600; 780]]780; 960]]960; 1 140]]1 140; 1 320]]1 320; 1 500]
insured_age (âge de l'assuré)	2	Arbre de décision CART univarié	18 – 24 ans 25 – 75 ans
incident_hour_of_the_day (heure du sinistre)	3	Découpage métier (créneaux horaires)	Nuit : 22h – 6h Matin : 6h – 12h Après-midi / soir : 12h – 22h
total_claim_amount (montant total du sinistre)	5	Quantiles arrondis à des bornes métier de 5 000 €	$\leq 5\,000$]5 000; 10 000]]10 000; 15 000]]15 000; 20 000] > 20 000
insured_days_since_last_claim (jours depuis le dernier sinistre)	3	Arbre CART univarié	≤ 800 jours (≈ 2 ans)]800; 2 500] jours > 2 500 jours (≈ 7 ans)
insured_claim_amount_history (historique des montants indemnisés)	2	Arbre CART univarié	$\leq 30\,000$ > 30 000
policy_age_at_incident_days (ancienneté du contrat)	3	Découpage métier	Moins de 1 an (< 365 jours) Entre 1 an et 3 ans Plus de 3 ans
repairer_fraud_rate (taux de fraude du réparateur)	4	Découpage métier + arbre CART univarié	Pas de réparateur identifié 0 % (réparateur avec historique, aucune fraude)]0 %; 5 %] > 5 %
repairer_avg_invoice_vs_market (facture moyenne / prix du marché)	2	Arbre CART univarié	On market : $\leq 1,15$ Off market (surfacturation) : > 1,15
vehicle_age_years (âge du véhicule)	2	Arbre CART univarié	0 – 8 ans 9 ans et plus
vehicle_market_value (valeur de marché du véhicule)	3	Arbre CART univarié	$\leq 5\,500$]5 500; 28 000] > 28 000

Variable	Nombre de classes créées	Méthode de classification	Descriptif des classes
vehicle_overvalue_ratio (ratio de survalorisation)	4	Quantiles + validation par CART	$\leq 0,50$]0,50; 0,95]]0,95; 2,20] > 2,20
incident_zip_fraud_rate (taux de fraude du code postal)	3	Terciles des 10 modalités observées	Faible : $\leq 11,05\%$ Moyen :]11,05 %; 11,71 %] Élevé : > 11,71 %

TABLE 4.3: Méthodes de discrétisation retenues pour chaque variable

Le détail du découpage de chaque variable est présenté ci-dessous.

- La variable « **policy_annual_premium** » est quantitative et admet des valeurs comprises entre 600 et 1 500 USD. Le choix de découpage pour la création de classes a été de créer cinq classes de valeur d'amplitudes égales, tout en s'assurant que chacune des classes créées admettait assez de volume (à minima 5 % de la base de sinistres testée).

policy_annual_premium	Nombre de sinistres associés	% de la base sinistre
[600; 780]	5 970	19,90 %
]780; 960]	6 031	20,10 %
]960; 1 140]	5 933	19,78 %
]1 140; 1 320]	5 992	19,97 %
]1 320; 1 500]	6 074	20,25 %
Total	30 000	100 %

- La variable « **insured_age** », correspondant à l'âge de l'assuré, prend ses valeurs entre 18 et 75 ans. Usuellement, ce sont des classes d'âge d'amplitude 5 ou 10 ans qui sont créées en tarification automobile ou en suivi du risque en portefeuille. Pour ce mémoire, l'objectif étant de créer un modèle prédictif de fraude automobile, c'est avant tout l'impact de l'âge sur le taux de fraude qui a été utilisé pour orienter le choix de création de classes sur cette variable. Ce découpage a été établi à l'aide d'un arbre de décision CART univarié, avec en paramétrage un minimum de 5 % des lignes de la base sinistre par feuille. Ainsi, un seuil unique à 24,5 ans a été établi, suivi d'une fusion des classes à taux homogènes. Seules 2 classes ont donc été créées : les moins de 24 ans et les plus de 24 ans.

insured_age	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
18 – 24 ans	3 539	11,80 %	18,71 %
25 – 75 ans	26 461	88,20 %	10,50 %
Total	30 000	100 %	11,5 %

- La variable « **incident_hour_of_the_day** », correspondant à l'heure du sinistre, a été découpée selon une logique métier, afin de représenter les différents moments de la journée. Ainsi, 3 classes ont été créées : Nuit (22h – 6h), Matin (6h – 12h) et Après-midi – soir (12h – 22h).

incident_hour_of_the_day	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
Nuit : 22h – 6h	9 932	33,11 %	11,38 %
Matin : 6h – 12h	7 535	25,12 %	11,12 %
Après-midi – soir : 12h – 22h	12 533	41,78 %	11,74 %
Total	30 000	100 %	11,5 %

- La variable « **total_claim_amount** », correspondant au montant total du sinistre, a été découpée en quintiles (5 classes) avec un arrondi par tranche de 5 000 USD.

total_claim_amount	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
≤ 5 000	5 410	18,03 %	12,13 %
]5 000; 10 000]	6 168	20,56 %	10,96 %
]10 000; 15 000]	6 199	20,66 %	11,60 %
]15 000; 20 000]	6 151	20,50 %	11,46 %
> 20 000	6 072	20,24 %	11,26 %
Total	30 000	100 %	11,5 %

- La variable « **insured_days_since_last_claim** », correspondant au nombre de jours depuis le dernier sinistre, a été découpée en 3 classes. Ce découpage a été établi à l'aide d'un arbre de décision CART univarié, avec en paramétrage un minimum de 5 % des lignes de la base sinistre par feuille. Ainsi, deux seuils ont été établis, 798,5 et 2 504,5 jours, arrondis respectivement à 800 et 2 500 jours.

insured_days_since_last_claim	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
≤ 800 jours (≈ 2 ans)	9 910	33,03 %	17,28 %
]800; 2 500] jours	17 415	58,05 %	9,21 %
> 2 500 jours (≈ 7 ans)	2 675	8,92 %	4,64 %
Total	30 000	100 %	11,5 %

- La variable « **insured_claim_amount_history** », correspondant à l'historique des montants indemnisés, a été découpée en 2 classes. Ce découpage a été établi à l'aide d'un arbre de décision CART univarié, avec en paramétrage un minimum de 5 % des lignes de la base sinistre par feuille. Ainsi, le seuil de 29 997 USD a été établi, arrondi à 30 000 USD.

insured_claim_amount_history	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
≤ 30 000	27 206	90,69 %	8,63 %
> 30 000	2 794	9,31 %	39,08 %
Total	30 000	100 %	11,5 %

- La variable « **policy_age_at_incident_days** », correspondant à l'ancienneté du contrat, a été découpée selon une logique métier de manière à isoler les polices récentes des polices plus anciennes, tout en assurant un volume suffisant d'information par classe créée. Ainsi 3 classes ont été créées : moins de 1 an, 1–3 ans et plus de 3 ans.

policy_age_at_incident_days	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
< 1 an	4 439	14,80 %	16,63 %
1–3 ans	8 502	28,34 %	13,46 %
> 3 ans	17 059	56,86 %	9,13 %
Total	30 000	100 %	11,5 %

- La variable « **repairer_fraud_rate** », correspondant au taux de fraude du réparateur, a été découpée selon un découpage métier de manière à isoler la modalité structurelle « pas de réparateur ». Ce découpage a été réalisé à l'aide d'un arbre CART donnant un intervalle de [0; 10 %], ramené à [0; 5 %] pour respecter la contrainte d'effectif par classe créée (> 5 %).

repairer_fraud_rate	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
Pas de réparateur identifié	6 074	20,25 %	11,31 %
0 % (réparateur avec historique, aucune fraude)	11 680	38,93 %	7,31 %
]0 %; 5 %]	9 696	32,32 %	7,52 %
> 5 %	2 550	8,50 %	45,88 %
Total	30 000	100 %	11,5 %

- La variable « **repairer_avg_invoice_vs_market** », correspondant au ratio facture moyenne / prix du marché, a été découpée en 2 classes à l'aide d'un arbre CART. Le seuil obtenu est de 1,15.

repairer_avg_invoice_vs_market	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
On market : $\leq 1,15$	27 589	91,96 %	8,26 %
Off market (surfacturation) : $> 1,15$	2 411	8,04 %	48,15 %
Total	30 000	100 %	11,5 %

- La variable « **vehicle_age_years** », correspondant à l'âge du véhicule, a été découpée en 2 classes de manière à mettre en évidence les écarts relatifs au taux de fraude observé. Un arbre de décision CART univarié a été utilisé, le seuil de 8,5 ans a été mis en évidence.

vehicle_age_years	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
0 – 8 ans	22 480	74,93 %	8,50 %
9 ans et plus	7 520	25,07 %	20,33 %
Total	30 000	100 %	11,5 %

- La variable « **vehicle_market_value** », correspondant à la valeur de marché du véhicule, a été découpée à l'aide d'un arbre de décision CART univarié, avec en paramétrage un minimum de 5 % des lignes de la base sinistre par feuille. Ainsi, deux seuils de 5 140 et 27 970 ont été établis, arrondis à 5 500 et 28 000 USD respectivement pour garantir un volume ≥ 5 % par classe.

vehicle _ market _ value	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
$\leq 5\,500$	1 825	6,08 %	22,19 %
]5 500; 28 000]	20 204	67,35 %	13,47 %
> 28 000	7 971	26,57 %	3,94 %
Total	30 000	100 %	11,5 %

- La variable « **vehicle _ overvalue _ ratio** », correspondant au ratio de survalorisation, a été découpée à l'aide de la méthode des quantiles, associée à une validation par CART.

vehicle _ overvalue _ ratio	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
$\leq 0,50$	14 829	49,43 %	8,54 %
]0,50; 0,95]	7 721	25,74 %	12,47 %
]0,95; 2,20]	5 553	18,51 %	14,96 %
> 2,20	1 897	6,32 %	20,03 %
Total	30 000	100 %	11,5 %

- La variable « **incident _ zip _ fraud _ rate** », correspondant au taux de fraude du code postal, a été regroupée en 3 classes selon les terciles des valeurs (10 valeurs uniquement).

incident _ zip _ fraud _ rate	Nombre de sinistres associés	% de la base sinistre	Taux de fraude en base
Faible : $\leq 11,05\%$	9 011	30,04 %	10,86 %
Moyen :]11,05 %; 11,71 %]	8 995	29,98 %	11,46 %
Élevé : $> 11,71\%$	11 994	39,98 %	11,92 %
Total	30 000	100 %	11,5 %

4.5.4 Analyse des corrélations entre les variables

L'agent renvoie également une table de corrélation entre variables après l'analyse de composition du portefeuille, qui faisait partie de notre demande dans le prompt adressé.

En effet, avant d'engager la phase de modélisation, il est important d'examiner les relations existantes entre les différentes variables explicatives de la base sinistres. Cette analyse permet de détecter d'éventuelles redondances entre variables, susceptibles d'introduire des problèmes de multicollinéarité dans les modèles ultérieurs, et de mieux comprendre la structure sous-jacente des données.

La nature mixte des variables retenues (à la fois quantitatives et qualitatives) nécessite de recourir à plusieurs mesures d'association adaptées à chaque configuration.

a) Corrélation entre deux variables quantitatives

Les corrélations entre variables quantitatives sont mesurées via le coefficient de Pearson. Pour deux variables X et Y , il est défini par :

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y} = \frac{\mathbb{E}[(X - \mu_X)(Y - \mu_Y)]}{\sqrt{\mathbb{E}[(X - \mu_X)^2] \mathbb{E}[(Y - \mu_Y)^2]}} \quad (4.1)$$

Son estimateur empirique sur un échantillon de taille n s'écrit :

$$\hat{\rho}_{X,Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (4.2)$$

Ce coefficient, borné dans $[-1, 1]$, mesure exclusivement l'intensité et le sens d'une relation *linéaire*. Une valeur proche de 1 traduit une relation positive forte (les deux variables évoluent dans le même sens), une valeur proche de -1 une relation négative forte (l'une croît lorsque l'autre décroît), et une valeur proche de 0 l'absence de relation linéaire.

Attention, une valeur nulle n'exclut pas l'existence d'une dépendance non linéaire, ce qui justifie de compléter l'analyse par une inspection graphique lorsque cela est pertinent.

b) Association entre deux variables qualitatives

Les associations entre variables qualitatives sont quant à elles évaluées à l'aide du V de Cramér (dérivé de la statistique du χ^2 de Pearson). Pour deux variables qualitatives comportant respectivement k et l modalités, croisées dans un tableau de contingence de n observations, il est défini par :

$$V = \sqrt{\frac{\chi^2}{n * \min(k-1, l-1)}} \quad (4.3)$$

où la statistique du χ^2 est donnée par :

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*}, \quad \text{avec} \quad n_{ij}^* = \frac{n_{i.} n_{.j}}{n} \quad (4.4)$$

Les termes n_{ij} désignent les effectifs observés dans la cellule (i, j) et n_{ij}^* les effectifs théoriques sous l'hypothèse d'indépendance des deux variables. Le V de Cramér prend ses valeurs dans $[0, 1]$, une valeur nulle traduisant l'indépendance et une valeur unitaire une association parfaite.

Sa normalisation par $\min(k-1, l-1)$ le rend comparable entre tableaux de dimensions différentes, ce qui constitue un avantage déterminant dans un contexte où les variables catégorielles présentent des cardinalités hétérogènes.

Contrairement au coefficient de Pearson, le V de Cramér ne renseigne pas sur le sens de la relation, mais uniquement sur son intensité, puisqu'il s'applique à des variables non ordonnées.

c) Association entre une variable quantitative et une variable qualitative

Les relations entre une variable quantitative et une variable qualitative sont appréhendées par le **rapport de corrélation** (η^2).

Soit Y une variable quantitative et X une variable qualitative à k modalités partitionnant l'échantillon en k classes d'effectifs $n_1, \dots, n_k$. En notant $\bar{y}_j$ la moyenne de Y dans la classe j et $\bar{y}$ la moyenne globale, la décomposition de la variance totale s'écrit :

$$\underbrace{\sum_{j=1}^k \sum_{i=1}^{n_j} (y_{ij} - \bar{y})^2}_{SC_{\text{totale}}} = \underbrace{\sum_{j=1}^k n_j (\bar{y}_j - \bar{y})^2}_{SC_{\text{inter}}} + \underbrace{\sum_{j=1}^k \sum_{i=1}^{n_j} (y_{ij} - \bar{y}_j)^2}_{SC_{\text{intra}}} \quad (4.5)$$

Avec SC la somme des carrés. Le rapport de corrélation est alors défini par :

$$\eta^2 = \frac{SC_{\text{inter}}}{SC_{\text{totale}}} \in [0, 1] \quad (4.6)$$

Il s'interprète comme la part de la variance de Y expliquée par l'appartenance aux modalités de X . Une valeur proche de zéro indique une absence de discrimination des modalités de X sur les niveaux moyens de Y , tandis qu'une valeur proche de 1 traduit une segmentation forte.

Par convention, un coefficient supérieur à **0,7** est généralement considéré comme révélateur d'une association forte, pouvant justifier l'exclusion ou la transformation de l'une des variables concernées.

d) Corrélation entre les variables de la base étudiée

Les tableaux ci-dessous synthétisent l'ensemble de ces mesures et constituent ainsi un prérequis méthodologique essentiel à la construction de modèles robustes et interprétables, en garantissant la qualité et l'indépendance de l'information apportée par chaque variable retenue dans l'analyse.

Pour chaque paire de variables par type, le coefficient de corrélation est calculé. La variable de fraude avérée (fraud_reported), qui est notre variable à expliquer, ne fait pas partie des corrélations testées. L'objet ici est uniquement de relever les corrélations entre les variables explicatives.

Variable	insured_address_changes_12m	insured_nb_past_claims	insured_nb_past_fraud	insured_nb_policies_active	nb_amendments_declaration	repairer_nb_claims_total	repairer_nb_fraud_confirmed	third_party_nb_past_incidents	vehicle_nb_past_claims	witnesses
insured_address_changes_12m	1	0,03 _s	0,04 _s	0,03 _s	0,02 _s	0,01 _s	0,02 _s	0,01 _s	0,02 _s	0,00 _s
insured_nb_past_claims	0,03 _s	1	0,03 _s	0,02 _s	0,02 _s	0,01 _s	0,02 _s	0,02 _s	0,02 _s	-0,01 _s
insured_nb_past_fraud	0,04 _s	0,03 _s	1	0,03 _s	0,04 _s	0,02 _s	0,04 _s	0,03 _s	0,03 _s	-0,03 _s
insured_nb_policies_active	0,03 _s	0,02 _s	0,03 _s	1	0,03 _s	0,01 _s	0,01 _s	0,02 _s	0,02 _s	-0,02 _s
nb_amendments_declaration	0,02 _s	0,02 _s	0,04 _s	0,03 _s	1	0,02 _s	0,02 _s	0,02 _s	0,03 _s	-0,02 _s
repairer_nb_claims_total	0,01 _s	0,01 _s	0,02 _s	0,01 _s	0,02 _s	1	0,72 _s	0,13 _s	0,02 _s	0,00 _s
repairer_nb_fraud_confirmed	0,02 _s	0,02 _s	0,04 _s	0,01 _s	0,02 _s	0,72 _s	1	0,09 _s	0,04 _s	0,00 _s
third_party_nb_past_incidents	0,01 _s	0,02 _s	0,03 _s	0,02 _s	0,02 _s	0,13 _s	0,09 _s	1	0,03 _s	0,00 _s
vehicle_nb_past_claims	0,02 _s	0,02 _s	0,03 _s	0,02 _s	0,03 _s	0,02 _s	0,04 _s	0,03 _s	1	-0,03 _s
witnesses	0,00 _s	-0,01 _s	-0,03 _s	-0,02 _s	-0,02 _s	0,00 _s	0,00 _s	0,00 _s	-0,03 _s	1

	incident_zip_fraud_rate	repairer_fraud_rate	repairer_is_flagged
incident_state	1	0,02	0,02
repairer_avg_invoice_vs_market	0,01	0,97	0,62

TABLE 4.4 – V de Cramér — Extrait de la matrice qualitative × qualitative

	repairer_fraud_rate	repairer_avg_invoice_vs_market	repairer_is_flagged	total_claim_amount
repairer_nb_claims_total	0,67	0,6	0,45	0
repairer_nb_fraud_confirmed	0,7	0,85	0,78	0
claim_total	0	0,01	0	0,77

TABLE 4.5 – Intensité d'association entre variables quantitatives × qualitatives

Chaque matrice d'association mobilise une mesure selon la nature des variables croisées : le coefficient de Pearson pour les couples de variables quantitatives, le V de Cramér pour les couples de variables qualitatives, et le rapport de corrélation η^2 pour les couples de variables mixtes.

S'agissant des variables quantitatives, la grande majorité des corrélations de Pearson sont très faibles (proches de 0), traduisant une quasi-indépendance linéaire entre la plupart des grandeurs continues (prime, franchise, âge, délais, etc.). Deux exceptions se distinguent toutefois nettement.

D'une part, le montant réclamé et le montant total de l'indemnisation présentent une corrélation très élevée (0,90), ce qui est logique puisque ces deux variables mesurent des quantités monétaires étroitement liées. D'autre part, le ratio de surévaluation de la réclamation est corrélé de façon marquée à ces mêmes montants (0,76 et 0,70). Ces redondances signalent un risque de multicollinéarité qu'il conviendra de traiter lors de la modélisation, par exemple en ne conservant qu'une seule de ces variables ou en construisant un indicateur synthétique, afin de préserver la stabilité et l'interprétabilité des modèles.

Parmi les variables qualitatives, les corrélations les plus fortes mesurées par le V de Cramér sont :

ICI ON VA LISTER

Les autres variables qualitatives (gravité de l'incident, canal de déclaration, profession, etc.) présentent des associations nettement plus faibles entre elles.

Parmi les variables quantitatives, mesurées par le rapport de corrélation η^2 , les intensités les plus fortes s'observent pour le passé du réparateur, avec le nombre de fraudes qu'il a déjà confirmées ($\eta^2 = 0,32$) et son nombre total de sinistres traités ($\eta^2 = 0,19$), ainsi que pour le ratio entre la facture et le prix de marché ($\eta^2 = 0,28$) et les antécédents de fraude de l'assuré ($\eta^2 = 0,24$). Viennent ensuite l'historique des montants réclamés (0,19), le nombre de modifications apportées à la déclaration (0,18) et le nombre d'incidents passés du tiers (0,17).

Concernant les corrélations linéaires entre variables quantitatives, seul le couple montant réclamé / montant total dépasse le seuil de 0,7 retenu comme signal de redondance excessive (0,90). Cette forte corrélation justifie de ne conserver qu'une seule de ces deux variables lors de la modélisation. Pour l'ensemble des autres variables explicatives, aucune association n'atteint ce seuil : elles apportent une information suffisamment distincte pour être toutes conservées dans la phase de modélisation.

Élimination des variables corrélées


À l'issue de l'analyse des matrices d'association, l'outil offre à l'utilisateur la possibilité d'écarter les variables jugées redondantes. Cette étape de sélection vise à ne conserver, parmi les variables candidates, que celles qui apportent une information « propre » et non déjà captée par d'autres variables par ailleurs, afin de ne pas dégrader la qualité des modèles construits par la suite.



Sur les 53 variables explicatives disponibles à ce stade (24 issues de la base source et 29 issues de l'enrichissement), 44 ont été retenues pour la modélisation.

En effet, 9 variables ont été écartées **automatiquement** par l'outil, qui les a identifiées comme non pertinentes pour la prédiction :

la variable cible `fraud_reported`, qui constitue précisément la grandeur à prédire et ne peut donc servir d'entrée; les identifiants uniques ou quasi uniques, dépourvus de tout pouvoir prédictif généralisable (`policy_id`, `insured_id`, `repairer_id`, `third_party_id`, `witness_id`, `vehicle_id`); et deux variables trop granulaires pour une analyse statistique robuste, à savoir la date exacte du sinistre (`incident_date`) et la ville du sinistre (`incident_city`), dont le très grand nombre de modalités rendrait les effectifs par catégorie trop faibles. Ce filtrage, réalisé en amont par l'agent sans intervention manuelle, garantit que seules les variables réellement porteuses d'information alimentent les modèles.



Cochez les variables à retirer de la modélisation

3 variables sélectionnées · 41 variables conservées sur 44.

☐ <code>authorities_contacted</code> Quantitative	☐ <code>bodily_injuries</code> Quantitative
☒ <code>claim_amount</code> Quantitative	☐ <code>collision_type</code> Qualitative
☐ <code>declaration_channel</code> Qualitative	☐ <code>incident_hour_of_the_day</code> Qualitative
☐ <code>incident_is_holiday</code> Qualitative	☐ <code>incident_is_weekend</code> Qualitative
☐ <code>incident_severity</code> Qualitative	☒ <code>incident_state</code> Qualitative
☐ <code>incident_type</code> Qualitative	☐ <code>incident_zip_fraud_rate</code> Qualitative

Valider la sélection Revenir à la question

FIGURE 4.10 – Interface de sélection permettant de conserver ou de retirer des variables

Le retrait des variables fortement corrélées répond à un enjeu méthodologique important. Lorsque deux variables explicatives sont redondantes, elles introduisent un phénomène de multicollinéarité qui peut fragiliser le modèle de plusieurs manières.

Sur les modèles de type régression ou *scoring*, la multicollinéarité rend l'estimation des coefficients instable : de faibles variations dans les données peuvent entraîner des changements importants dans les pondérations attribuées à chaque variable, rendant leur interprétation peu fiable, voire trompeuse. Sur l'ensemble des modèles, elle nuit également à la parcimonie et à la lisibilité du dispositif, sans améliorer le pouvoir prédictif puisque l'information est déjà présente. Éliminer ces redondances en amont permet donc de gagner en robustesse, en stabilité et en interprétabilité, sans perte d'information significative.

Analyse de la fréquence de fraude

Le système ne se contente plus de décrire chaque variable isolément, il croise systématiquement chaque caractéristique avec la variable cible (`fraud_reported`) préalablement identifiée par l'utilisateur.

L'objectif de cette interface est de réaliser un « profilage » automatisé. En comparant visuellement la distribution des modalités au sein de la population saine (« Non-fraudeurs ») avec celle des fraudeurs

avérés (« Fraudeurs »), l'outil calcule un indicateur de déviation statistique appelé le « Delta » :

- un **delta positif** important révèle une **sur-représentation** anormale d'une caractéristique dans les dossiers de fraude historiques ;
- à l'inverse, un **delta négatif** met en avant la **sous-représentation** de certaines caractéristiques dans les dossiers de fraude.

L'agent va ensuite réaliser deux actions de manière autonome :

- afficher le top 3 des variables jugées comme les plus discriminantes au vu de la variable cible (affichage *on Top*) ;
- choisir la représentation la plus adaptée à la variable à étudier, notamment des camemberts pour les variables qui admettent un faible nombre de modalités et des diagrammes en barres pour les variables admettant un nombre plus important de modalités.




FIGURE 4.11 – Extrait de la sortie de l'analyse statistique des fraudes/non fraudes pour variables sur la base de données de sinistres automobile

Afin de permettre à l'utilisateur de visualiser l'ensemble des variables, un choix d'affichage est disponible à droite sur simple clic.





FIGURE 4.12 – Extrait de la sortie de l'analyse statistique des fraudes/non fraudes sur la base de données de sinistres automobile

À noter que l'agent comprend également seul qu'il est inutile de réaliser l'analyse de la fraude par police_id par exemple, dans la mesure où cet indicateur sert de compteur (ou incrément) et n'a pas d'apport dans la modélisation. Pour rappel cette variable avait été décochée dès le début.

Pour les variables dont les modalités ont été regroupées en classes, une loupe située en haut à droite permet d'afficher une version plus détaillée, où les tranches sont segmentées à la maille la plus fine disponible.

Exemple avec la variable tranche d'âge :



Tranche d'âge (détaillé) — vue détaillée

Intervallés affinés. Cliquez en dehors pour fermer.

Non fraudeurs



Fraudeurs




FIGURE 4.13 – Vue détaillée de la variable tranche d'âge

Cette vue détaillée par âge fait apparaître une surreprésentation des assurés de 18 à 24 ans parmi les sinistres frauduleux : alors que la distribution des non-fraudeurs reste relativement uniforme sur l'ensemble des tranches d'âge, celle des fraudeurs présente un pic sur les premiers âges avant de se stabiliser au-delà de 24 ans. Cet effet reste toutefois localisé sur les jeunes conducteurs : au-delà de cette tranche, l'âge ne discrimine plus la fraude. L'âge n'est donc pas une variable fortement discriminante en soi, mais la classe des 18-24 ans mérite une attention particulière.

L'analyse de ces graphiques et diagrammes permet de dégager des enseignements métiers déterminants pour orienter les règles de gestion et alimenter les algorithmes prédictifs :

1. Les antécédents de fraude et l'environnement du sinistre : des signaux prioritaires.

L'analyse met en évidence une forte association entre la fraude et les informations relatives au réparateur ainsi qu'aux antécédents de l'assuré. Le nombre de fraudes déjà confirmées pour le réparateur constitue le signal le plus marqué ($\eta^2 = 0,32$), devant le ratio facture/marché ($\eta^2 = 0,28$) et le nombre de fraudes passées de l'assuré ($\eta^2 = 0,24$). S'y ajoute, parmi les variables qualitatives, le statut de réparateur signalé ($V = 0,26$). Ainsi, les assurés ayant déjà connu au moins une fraude représentent 35,6 % des dossiers frauduleux, contre 9,6 % des dossiers non frauduleux. Ces éléments justifient une vigilance renforcée lorsque l'historique de l'assuré et celui des intervenants convergent vers un profil à risque.

2. La cohérence de la déclaration : un levier essentiel de détection.

Les modalités de déclaration du sinistre apportent des indicateurs particulièrement discriminants. L'absence d'autorités contactées apparaît dans 46,5 % des dossiers frauduleux, contre 22,5 % des dossiers non frauduleux, soit un écart de 24 points. Le nombre d'amendements apportés à la déclaration constitue

également un signal important : les dossiers comprenant au moins deux modifications représentent 31,9 % des fraudes, contre 13,5 % des dossiers non frauduleux. Enfin, une blessure déclarée sans preuve médicale concerne 24,6 % des dossiers frauduleux, contre 8,6 % des dossiers non frauduleux. Ces incohérences ou ajustements successifs doivent donc alimenter les règles de contrôle et les mécanismes de priorisation des dossiers.

3. **Les historiques de sinistres : une lecture complémentaire du risque.** L'accumulation de sinistres antérieurs est davantage observée parmi les dossiers frauduleux. Les assurés ayant déclaré au moins deux sinistres par le passé représentent 47,6 % des cas de fraude, contre 30,4 % des dossiers non frauduleux. Les antécédents d'incidents du tiers impliqué suivent une logique similaire : 18,5 % des dossiers frauduleux concernent un tiers ayant déjà connu au moins un incident, contre 8,2 % des dossiers non frauduleux. Ces résultats confirment l'intérêt d'une analyse croisée entre l'historique de l'assuré, celui du tiers et les caractéristiques du réparateur, plutôt que d'une lecture fondée sur une seule variable.
4. **Les variables descriptives : utiles pour segmenter, moins déterminantes pour alerter.** Les caractéristiques socio-démographiques et contractuelles (le sexe, la prime annuelle, la franchise, l'heure de l'incident ou le nombre de véhicules impliqués) présentent des associations faibles avec la fraude. L'âge relève également de cette catégorie : hormis la surreprésentation ciblée des 18-24 ans évoquée plus haut, il ne constitue pas un facteur de priorisation. Ces variables contribuent à la description et à la segmentation du portefeuille, sans figurer parmi les principaux signaux d'alerte. La sévérité de l'incident conserve toutefois un intérêt descriptif : la modalité « perte totale » est présente dans 43,5 % des fraudes, contre 32,4 % des dossiers non frauduleux. L'évaluation globale du risque doit donc privilégier les éléments d'historique et de cohérence déclarative, tout en conservant les variables descriptives pour enrichir l'analyse des profils.

Analyse du coût moyen de la fraude

Après avoir analysé la fréquence de fraude, une étude est réalisée sur le coût moyen des dossiers frauduleux (variable *total_claim_amount*).

Analyse du coût moyen




FIGURE 4.14 – Analyse du coût moyen des sinistres frauduleux et non frauduleux

Ces indicateurs nous permettent de faire un constat contre-intuitif : la fraude ne concerne pas les sinistres les plus coûteux. Le coût moyen des 3 440 dossiers frauduleux s'élève à 12 675,09 €, soit un montant quasiment identique, et même légèrement inférieur, au coût moyen global (12 757,74 €). Autrement dit, les dossiers frauduleux ne se distinguent pas par des montants réclamés plus élevés que les dossiers sains.

Ce résultat, à première vue surprenant, a une implication importante : **le montant du sinistre n'est pas, à lui seul, un signal permettant d'orienter la détection vers les fraudeurs**. Une stratégie de contrôle qui se concentrerait uniquement sur les sinistres les plus coûteux passerait donc à côté d'une large part de la fraude. C'est précisément ce qui justifie le recours à une approche multivariée : la fraude se révèle non pas par le montant réclamé, mais par la combinaison de signaux comportementaux et déclaratifs identifiés précédemment (antécédents, cohérence de la déclaration, environnement du sinistre). L'objectif du mémoire étant de modéliser une **probabilité de fraude** (variable cible binaire), l'étude du coût moyen n'entre a priori pas directement dans la spécification du modèle. Néanmoins, elle conserve une justification importante dans un mémoire actuariel : la justification de l'enjeu économique du modèle. En effet, modéliser une probabilité de fraude n'a de valeur opérationnelle que si la fraude représente un enjeu financier significatif.

Le gain unitaire espéré d'une fraude détectée correspond au coût moyen d'un sinistre frauduleux ($\bar{C}_F$), c'est-à-dire au montant que l'assureur évite de verser indûment en écartant le dossier. On fait ici l'hypothèse qu'un sinistre identifié comme frauduleux est intégralement rejeté ; dans le cas d'une simple exagération, seul le surcoût frauduleux serait récupéré. Cela pose le cadre économique qui légitime la démarche de modélisation.

Chapitre 5

Création du modèle de détection de fraude : Étapes 4 et 5

Dans la suite de l'analyse, l'étude se concentre sur trois approches de modélisation couramment utilisées en détection de fraude :

- Un **modèle de *Scoring* en points** (interprétable et proche des pratiques actuarielles traditionnelles) ;
- Un **arbre de décision** (permettant de capturer des effets non linéaires et des interactions) ;
- Un **modèle de type Gradient Boosting** (plus performant en général grâce aux méthodes d'ensemble).

L'objectif est d'évaluer et de comparer leur **qualité de prédiction** à partir de métriques adaptées, tout en tenant compte des enjeux d'interprétabilité et d'implémentation opérationnelle.

Dans ce cadre, l'outil développé propose dans un premier temps de sélectionner un partitionnement de la base globale de manière à définir deux jeux de données :

- Un jeu qui servira de base d'apprentissage ;
- Un jeu qui servira de base de test du modèle créé.

Le choix du partitionnement est laissé à l'utilisateur, avec une valeur par défaut de départ à 80/20 (base d'apprentissage/base de test) correspondant aux proportions généralement utilisées lors de la mise en place de modèles sur ce type de volumétrie de données.

Répartition entraînement / test

Le fichier contient **30000 lignes** — taux de fraude observé : **11.5%**. Comment voulez-vous répartir le jeu d'entraînement et le jeu de test ?

Méthode de répartition

Le split est stratifié sur la variable cible : le taux de fraude est préservé dans les deux jeux.

80%

20%

Glissez la barre, ou modifiez directement le nombre de lignes ci-dessous.

● Entraînement

24000

lignes

→

● Test

6000

lignes

FIGURE 5.1 – Choix du partitionnement de la base

Pour notre exemple, une partition **80 / 20** est retenue : 80 % des observations (24 000 lignes) constituent le jeu d'apprentissage-validation, et les 20 % restants (6 000 lignes) forment le jeu de test final, mis de côté dès le départ et jamais utilisé pendant la phase de construction.

Ce partitionnement est **stratifié sur la variable cible**, ce qui signifie que le taux de fraude observé (11,5 %) est préservé à l'identique dans les deux jeux. Cette précaution est essentielle sur des données déséquilibrées : un tirage purement aléatoire pourrait sur- ou sous-représenter les cas de fraude dans l'un des jeux, faussant l'apprentissage comme l'évaluation.

Sur la portion d'apprentissage-validation (80 %), une **validation croisée à 5 plis** est appliquée pour la sélection des hyperparamètres. Le principe consiste à diviser ces données en cinq sous-ensembles : le modèle est entraîné à cinq reprises, chaque fois sur quatre plis et évalué sur le cinquième, de sorte que chaque observation serve tour à tour à l'entraînement et à la validation. Cette approche fournit une estimation plus robuste de la performance et limite le risque de sur-ajustement (*overfitting*) au moment du choix des paramètres.

Enfin, le jeu de test (20 %), resté totalement isolé, permet une **évaluation finale en conditions réelles** : les métriques de performance (AUC, Gini, KS, rappel, précision etc.) sont calculées sur des données que le modèle n'a jamais vues, garantissant une mesure honnête de sa capacité de généralisation.

Une fois le partitionnement entraînement/test choisi, les trois modélisations sont lancées et le résultat de chacune d'elles s'affiche sur simple clic, permettant ainsi une comparaison entre modèles.

Résultats des 3 modèles

Les trois modèles ont été entraînés sur vos données. Consultez leurs résultats avant de retenir une configuration.

CHOISISSEZ LE MODÈLE À VISUALISER

 Scoring en points 

 Arbre de décision

 Gradient Boosting

FIGURE 5.2 – Affichage de l'Agent IA pour le choix de modélisation (à renseigner par l'utilisateur)

Une présentation et analyse des résultats de chaque modèle est proposée ci-dessous.

5.1 Scoring en points

Sur la base de sinistre transmise, l'Agent IA va à présent appliquer un *modèle de Scoring en points*.

 Scoring en points 

A noter que pour faciliter l'interprétation des scores obtenus et leur passage en probabilité de fraude, nous avons demandé à l'agent de normaliser le barème de score de manière à ce que l'ensemble des combinaisons possibles soient comprises entre 0 et 1000 points.

5.1.1 Résultats du modèle

La construction d'un modèle de *scoring* performant repose en amont sur une sélection rigoureuse des variables explicatives. Cette étape poursuit un double objectif : d'une part, retenir uniquement les variables porteuses d'un pouvoir discriminant réel vis-à-vis de la variable cible (l'occurrence de fraude), afin de maximiser la performance prédictive du modèle ; d'autre part, garantir la parcimonie du barème, condition essentielle à sa lisibilité, à son appropriation par les gestionnaires sinistres et à sa maintenabilité dans le temps.

Un barème surchargé de critères, même statistiquement significatifs, perd en effet en opérationnalité et devient difficilement auditable.

Une fois la phase de sélection des variables terminée, un nombre de points est affecté à chaque modalité

ou situation à risque. Plus une modalité est associée historiquement à un niveau élevé de fraude, plus le nombre de points attribué est important. À l'inverse, les situations jugées peu suspectes reçoivent peu de points, voire aucun.

Le *scoring* en points repose donc sur une logique additive : chaque dossier cumule des points selon les caractéristiques qu'il présente. Le barème reflète ainsi la contribution relative de chaque critère au risque de fraude.

En sortie du modèle, on obtient les indicateurs suivants :

- Le nombre de variables retenues dans le modèle de *Scoring* (20) ;
- Pour chaque variable, le nombre de points associé à chaque modalité ;
- « Effectif train » correspondant au nombre de lignes de chaque modalité au sein de la base d'apprentissage ;
- « Taux de fraude train », le taux de fraude observé sur la base d'apprentissage ;
- Le WOE (Weight of Evidence), qui correspond au log-odds de la modalité, recentré sur le log-odds global :

$$\text{WOE} = \ln(\text{odds}_{\text{modalité}}) - \ln(\text{odds}_{\text{global}}) \quad (5.1)$$

Par exemple, pour la variable « *repaired_avg_invoice_vs_market* », sur la modalité « Off market », le taux global de fraude est de $2752/24000 \approx 11,5\%$, donc $\ln(0,48/0,52) - \ln(0,115/0,885) = 1,96$. Un WOE positif signifie donc « plus risqué que la moyenne du portefeuille », négatif « moins risqué », et 0 correspond exactement au risque moyen. C'est la variable explicative réellement injectée dans la régression : chaque modalité est remplacée par son WOE.

- L'Information Value (IV) : c'est une mesure de pouvoir discriminant univarié, indépendante du modèle final, donnée par :

$$\text{IV} = \sum_{\text{modalités}} (\% \text{ fraudes} - \% \text{ non-fraudes}) \times \text{WOE} \quad (5.2)$$

Par exemple, sur la variable « *repaired_avg_invoice_vs_market* » : $(0,661 - 0,953) \times (-0,366) + (0,339 - 0,048) \times 1,965 = 0,680$.

Valeur de l'IV	Interprétation
$< 0,02$	Inutile
$0,02 - 0,1$	Faible
$0,1 - 0,3$	Moyen
$0,3 - 0,5$	Fort
$> 0,5$	À examiner

TABLE 5.1 – Grille d'interprétation de l'IV

- Le coefficient logistique : c'est le coefficient de la variable WOE-isée dans la régression multivariée. Sa référence naturelle est 1 : si une variable était seule dans le modèle, son coefficient vaudrait mécaniquement 1 puisque le WOE est déjà exprimé en log-odds. Les valeurs retournées par le modèle (ici 0,997 / 0,980 / 0,980 / 0,904) sont donc à lire comme un facteur d'atténuation. S'il est proche de 1, cela signifie que la variable apporte une information peu redondante avec les autres. À noter que le 0,904 de « *vehicle_market_value* » indique un léger recouvrement avec d'autres variables du modèle. Les signaux d'alerte seraient un coefficient très inférieur à 1 (redondance forte), supérieur à 1,3–1,5, ou négatif, ce dernier cas traduisant une inversion de sens due à de la colinéarité.
- La stabilité de la variable : elle représente la fréquence de sélection de la variable sur des rééchantillonnages (*bootstrap* ou validation croisée). La valeur 1 indique que la variable est systématiquement retenue.

Grille détaillée — 20 variables retenues sur 39 candidates

reparer_avg_invoice_vs_market Qualitative Points : 0 → 108 IV : 0,680 Stabilité : 1,00 Coefficient logistique : 0,997					
MODALITÉ	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
On market ($\leq 1,15$)	0	Diminue le risque	22 056 (92 %)	8,2 % (1 818)	-0,366
Off market ($> 1,15$)	108	Augmente le risque	1 944 (8 %)	48,0 % (934)	1,965

insured_claim_amount_history Qualitative Points : 0 → 87 IV : 0,482 Stabilité : 1,00 Coefficient logistique : 0,980					
MODALITÉ	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
$\leq 30\,000\,€$	0	Diminue le risque	21 766 (91 %)	8,6 % (1 881)	-0,314
$> 30\,000\,€$	87	Augmente le risque	2 234 (9 %)	39,0 % (871)	1,596

insured_nb_past_fraud Quantitative Points : 0 → 74 IV : 0,421 Stabilité : 1,00 Coefficient logistique : 0,980					
INTERVALLE	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
< 1	0	Diminue le risque	20 950 (87 %)	8,5 % (1 773)	-0,337
≥ 1	74	Augmente le risque	3 050 (13 %)	32,1 % (979)	1,295

vehicle_market_value Qualitative Points : 0 → 83 IV : 0,312 Stabilité : 1,00 Coefficient logistique : 0,904					
MODALITÉ	POINTS	EFFET SUR LE RISQUE	EFFECTIF TRAIN	TAUX DE FRAUDE TRAIN	WOE
$\leq 5\,500\,€$	83	Augmente le risque	1 451 (6 %)	22,6 % (328)	0,814
$]5\,500 ; 28\,000]\,€$	57	Augmente le risque	16 126 (67 %)	13,5 % (2 175)	0,185
$> 28\,000\,€$	0	Diminue le risque	6 423 (27 %)	3,9 % (249)	-1,165

FIGURE 5.3 – Extrait de la grille d'attribution des points du modèle de *Scoring* en points

Les résultats du modèle de *Scoring* permettent de distinguer 3 catégories d'indicateurs :

- En premier lieu, les signaux forts correspondent aux variables les plus discriminantes, historiquement associées à un sur-risque de fraude et donc fortement pondérées.
 - Le ratio facture/marché du réparateur domine le barème : une facture supérieure de 15 % au prix de marché (« off market ») atteint un taux de fraude de 48,0 % (contre 11,5 % en moyenne) et se voit attribuer le maximum de 108 points, pour une IV de 0,680.
 - Viennent ensuite l'historique des montants réclamés par l'assuré (un cumul supérieur à 30 000 USD porte le taux de fraude à 39,0 % et vaut 87 points) ;
 - Les antécédents de fraude de l'assuré (au moins une fraude passée : 32,1 % de fraude, 74 points) ;

- Et la valeur marchande du véhicule (un véhicule de moins de 5 500 € atteint 22,6 % de fraude, 83 points).

Ces quatre variables concentrent l'essentiel du pouvoir discriminant du modèle.

- En deuxième lieu, les signaux moyens sont des indicateurs plus diffus, moins déterminants pris isolément, mais dont le cumul affine sensiblement l'évaluation du risque. On y retrouve le nombre d'amendements à la déclaration (jusqu'à 67 points pour au moins trois modifications, 26,3 % de fraude), l'âge du véhicule (49 points au-delà de neuf ans), le nombre de sinistres passés du véhicule comme de l'assuré, le nombre de contrats actifs, le délai depuis le dernier sinistre (64 points en deçà de 800 jours) ou encore les changements récents d'adresse. Chacun pèse modérément, mais leur accumulation sur un même dossier peut faire fortement grimper le score final.
- En troisième lieu, la logique du barème intègre des modalités protectrices, auxquelles zéro ou très peu de points sont attribués afin d'éviter une surévaluation du risque. Ainsi, un dossier où la police a été contactée ne reçoit aucun point, contre 60 points en l'absence de toute autorité ; la présence d'au moins un témoin annule les 38 points attribués à un dossier sans témoin ; de même, un véhicule de plus de 28 000 USD, un contrat de plus de trois ans ou un assuré de plus de 24 ans ne contribuent pas au score. Ces situations, statistiquement associées à un moindre risque de fraude, viennent naturellement contrebalancer les signaux aggravants.
- Enfin, on notera la présence de variables faiblement discriminantes conservées dans le barème mais au poids marginal, comme la profession de l'assuré (IV de 0,022) ou le canal de déclaration : elles n'apportent qu'un ajustement mineur au score et confirment, à l'inverse, la prééminence des signaux liés au réparateur et aux antécédents de l'assuré.

Dans l'ensemble, ce barème repose sur une logique transparente et interprétable, combinant expertise métier et observations empiriques, afin de produire un score global reflétant le niveau de suspicion de fraude associé à chaque dossier.

On peut également s'intéresser à l'importance relative des variables dans le modèle de prédiction de fraude, qui doit intuitivement être liée à l'attribution des points dans le modèle de *scoring* :

Poids des variables dans la grille

Part de l'amplitude totale de points attribuable à chaque variable : plus la barre est longue, plus la variable peut faire varier le score final.



FIGURE 5.4 – Hiérarchie de l'importance globale des variables dans le modèle de *scoring* en points

On remarque que l'importance des variables est ici relativement répartie, mais avec une hiérarchie nette : le pouvoir explicatif s'étale de 2 % à 11 %, sans qu'aucune variable n'écrase les autres, tout en laissant émerger un petit groupe de signaux dominants.

En tête figure le ratio facture/marché du réparateur (11 %), suivi de l'historique des montants réclamés par l'assuré (9 %), de la valeur marchande du véhicule (8 %), du nombre de fraudes passées et du nombre d'amendements à la déclaration (7 % chacun). À l'autre extrémité, des variables comme la profession de l'assuré, le canal de déclaration ou le ratio de surévaluation ne pèsent chacune que 2 %.

Cette hiérarchie relativement douce est cohérente avec la nature même du *Scoring* en points : reposant sur une agrégation additive de nombreux critères, le modèle répartit le risque sur un large ensemble de signaux plutôt que de le concentrer sur quelques-uns. C'est là une force autant qu'une caractéristique : le modèle ne dépend pas excessivement d'une seule variable, ce qui le rend robuste et stable (son PSI très faible et l'absence de surapprentissage le confirment) et lui permet de conserver sa pertinence même lorsqu'une variable est absente d'un dossier de sinistre.

On note enfin que les variables présentant les plus fortes importances sont aussi celles susceptibles d'attribuer le plus grand nombre de points dans le barème : le ratio facture/marché, qui domine ce classement, est également la variable la mieux dotée de la grille (jusqu'à 108 points). Cette cohérence entre poids dans la grille et importance dans le score global est logique, puisque l'importance mesure précisément la part de l'amplitude totale de points qu'une variable peut faire varier.

Ces observations sont en accord avec l'étude de fréquence réalisée en amont du lancement du modèle (cf. 4.5.2).

Le modèle est ensuite appliqué à l'ensemble de la base sinistres : pour chaque dossier, les points associés aux caractéristiques observées sont additionnés, produisant un score global de suspicion qui synthétise le niveau de risque du sinistre. Plus ce score est élevé, plus le dossier présente un profil proche de celui des sinistres historiquement identifiés comme frauduleux.

Une fois les scores calculés, il est important de regarder leur distribution par classe (histogrammes superposés) de fraudeurs/non fraudeurs : visuellement, plus les deux distributions sont **séparées**, meilleur est le modèle.

Distribution des scores par classe (jeu de test : 6000 sinistres)

Pour chaque tranche de score, ce graphique superpose (en transparence) le nombre de sinistres frauduleux et non frauduleux du jeu de test. Plus les deux distributions se chevauchent, plus il est difficile pour le modèle de séparer les deux classes à ce niveau de score.




FIGURE 5.5 – Distribution des scores par classe (fraudeur/non fraudeur)

On observe sur la figure 5.5 que les sinistres frauduleux sont principalement concentrés sur la droite du graphique, correspondant aux scores élevés, à l'inverse des sinistres non frauduleux qui sont concentrés à gauche.

L'analyse de la sortie du modèle ne se limite pas à la distribution des scores par classe. Il convient également de comparer les niveaux de score observés entre les sinistres frauduleux et les sinistres non frauduleux. Si le modèle est pertinent, les dossiers frauduleux doivent, en moyenne, présenter des scores plus élevés. Cette étape permet d'évaluer la capacité du *scoring* à séparer les deux populations et à hiérarchiser le risque de fraude de manière cohérente.

Taux de fraude avérée par tranche de score (jeu de test : 6 000 sinistres)




FIGURE 5.6 – Taux de fraude avérée par tranche de score de suspicion

À noter que les figures 5.5 et 5.6 mesurent la qualité prédictive sur le jeu de test, c'est-à-dire sur des sinistres dont le modèle n'a pas eu connaissance lors de sa phase d'apprentissage. Les indicateurs reflètent donc sa capacité de généralisation à de nouveaux dossiers, et non une simple performance sur les données d'entraînement.

La figure 5.6 met ici en évidence une relation croissante par paliers entre le score de suspicion et le taux de fraude avérée, ce qui confirme la capacité du modèle à discriminer efficacement les dossiers selon leur niveau de risque : plus le score est élevé, plus la probabilité de fraude augmente.

À partir de la distribution des scores et de la capacité discriminante du modèle, des seuils opérationnels peuvent être définis. Ces seuils permettent de transformer un score continu en règle de gestion. Par exemple, un score faible peut correspondre à une absence de recherche complémentaire, un score intermédiaire à une investigation légère, et un score élevé à une recherche approfondie. Le choix de ces seuils repose sur un arbitrage actuariel et opérationnel entre le coût des contrôles, le nombre de faux positifs acceptables et le gain attendu en matière de fraude détectée.

Dans notre exemple, on observe une première cassure autour de 350 points, à partir de laquelle le taux de fraude avérée augmente légèrement : ce premier changement de régime justifie le déclenchement d'une investigation légère. Une seconde cassure apparaît autour de 450 points, où le taux de fraude avérée croît nettement, seuil à partir duquel une investigation approfondie se justifie.

Autrement dit, les règles d'investigation suivantes peuvent être mises en place :

- Score compris entre 0 et 350 : pas d'investigation
- Score compris entre 350 et 450 : investigation légère
- Score supérieur à 450 : investigation poussée

Enfin, si l'on considère les sinistres classifiés comme nécessitant une investigation poussée comme « frauduleux » (score supérieur à 450), le score étant construit sur une échelle de 0 à 1 000 points, un seuil

de 450 points équivaut à 45 % de l'échelle ; c'est cette normalisation qui permet d'exprimer le seuil de décision en pourcentage dans la matrice de confusion. Dans notre choix graphique ci-dessus, on obtient la matrice de confusion suivante :

Matrice de confusion Seuil : 45%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	294	394	688
Réel Non fraude	65	5 247	5 312
Total	359	5 641	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.7 – Matrice de confusion du modèle de *Scoring* en points pour un seuil de 45 %

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $5\,247 / 5\,312 = 98,77\%$;
- Le taux de fraude détectées (prédit fraude / réel fraude) : $294 / 688 = 42,73\%$.
- Le taux de sinistres signalés frauduleux : $\text{prédit fraude} / \text{total} = 359 / 6\,000 = 5,98\%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une **optimisation du seuil** afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.1.2 Qualité du modèle obtenu

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles présentés en section 3.7.

Pour commencer, un point de vigilance mérite d'être souligné concernant le **choix du seuil de décision**. Le modèle ne restitue pas une classification binaire mais une probabilité de fraude ; il convient donc de fixer un seuil au-delà duquel un sinistre est considéré comme frauduleux. Le seuil de 0,5, retenu par méthode graphique, se révèle en réalité inadapté aux données fortement déséquilibrées : avec seulement 11,5 % de fraudes, la majorité des scores se concentrent sous 0,45, si bien que le modèle ne détecte qu'une fraction infime des fraudes réelles.

Pour corriger ce biais, on recourt à l'**indice de Youden**, défini comme :

$$J = \text{Sensibilité} + \text{Spécificité} - 1 \quad (5.3)$$

Cet indice identifie le seuil qui maximise l'écart entre le taux de vrais positifs (fraudes correctement détectées) et le taux de faux positifs (non-fraudes signalées à tort) ; il correspond graphiquement au point de la courbe ROC le plus éloigné de la diagonale du hasard, c'est-à-dire celui où le modèle sépare le mieux les deux populations.

Appliqué à ce modèle, le seuil optimal est alors de 35 %.

Les résultats du modèle obtenus avec l'utilisation de ce seuil sont présentés ci-dessous :

Matrice de confusion Seuil : 35%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	527	161	688
Réel Non fraude	580	4732	5312
Total	1107	4893	6000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.8 – Matrice de confusion au seuil optimal du modèle de *Scoring* en points (35 %)

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $4732/5312 = 89,08 \%$;
- Le taux de fraude détectées (prédit fraude / réel fraude) : $527/688 = 76,60 \%$;
- Le taux de sinistres signalés frauduleux : $\text{prédit fraude} / \text{total} = 1107/6000 = 18,45 \%$.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 18,45 % des sinistres, parmi lesquels 76,42 % sont réellement frauduleux, soit une densité de fraude environ 6,6 fois supérieure à celle d'un contrôle aléatoire. L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :



FIGURE 5.9 – Synthèse des métriques de performance et de stabilité du modèle de *scoring* en points



FIGURE 5.10 – Courbe ROC et AUC correspondant au modèle de *scoring* en points

En retenant le seuil optimal de 35 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,917)** : excellente capacité de discrimination, très au-dessus du seuil de 0,8 considéré

comme bon ; le modèle sépare efficacement fraudeurs et non-fraudeurs.

- **Gini (0,835)** : cohérent avec l'AUC, ce niveau traduit un pouvoir discriminant élevé, largement supérieur aux standards habituels en assurance.
- **KS (0,666)** : bien au-delà du seuil de 0,5, il confirme une nette séparation entre les distributions de scores des deux populations.
- **Précision (47,6 %)** : parmi les dossiers signalés comme frauduleux, un peu plus de quatre sur dix le sont réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (76,6 %)** : le modèle détecte près de quatre fraudes sur cinq, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (58,7 %)** : compromis honnête entre précision et rappel, en nette amélioration par rapport au seuil de 0,5.
- **Accuracy (87,6 %)** : taux de bonnes classifications élevé, à interpréter toutefois avec prudence sur données déséquilibrées où cet indicateur est peu informatif à lui seul.
- **Log-loss (0,2015)** : valeur faible, signe d'une bonne calibration des probabilités prédites.

Dans l'ensemble, le modèle présente d'excellents indicateurs de discrimination et de stabilité ; le seul point de vigilance concerne la précision modérée, contrepartie assumée d'un rappel volontairement élevé.

Ces résultats sont cohérents avec la nature du modèle : sa simplicité et sa parcimonie le rendent naturellement robuste et peu sujet au surajustement.

Enfin, concernant les indicateurs de robustesse et stabilité du modèle, les résultats suivants sont obtenus :

- **Backtesting (écart AUC train/test de 0,003)** : écart quasi nul entre apprentissage et test, confirmant l'absence de surapprentissage et une bonne capacité de généralisation.
- **PSI (0,0026)** : très inférieur à 0,1, il atteste d'une parfaite stabilité de la distribution des scores.





FIGURE 5.11 – Indicateurs de robustesse et de stabilité du modèle de *scoring* en points

5.1.3 Limites et précautions d'interprétation

5.2 Arbre de décision

Cette section présente l'utilisation de la modélisation via un « arbre de décision » pour estimer la probabilité de fraude.



5.2.1 Résultats du modèle

TROUVER UNE LIMITE

L'arbre construit admet les paramètres suivants :

- Profondeur : 5
- Feuilles : 68
- Nœuds internes : 67

L'arbre construit admet les caractéristiques structurelles suivantes :

- **La profondeur (5)**, qui correspond au nombre maximal de niveaux de décision successifs entre la racine de l'arbre et ses feuilles. Concrètement, un dossier traverse au plus cinq coupures successives

(cinq questions posées sur ses variables) avant d'aboutir à une prédiction. Cette profondeur a été volontairement limitée à 5 : un arbre trop profond mémoriserait les particularités de l'échantillon d'apprentissage (sur-apprentissage) et généraliserait mal à de nouveaux dossiers, tandis qu'un arbre trop peu profond serait incapable de capter les interactions entre variables. Une profondeur de 5 constitue ainsi un compromis entre pouvoir de discrimination et capacité de généralisation.

- **Les feuilles (68)** sont les nœuds terminaux de l'arbre, c'est-à-dire les points d'aboutissement où une décision finale est rendue (dossier classé frauduleux ou non). Chaque feuille regroupe un ensemble de dossiers partageant le même parcours de décision, et se voit attribuer une probabilité de fraude correspondant à la proportion de fraudes observée parmi les dossiers d'apprentissage qui y aboutissent. L'arbre compte ici 68 feuilles, soit 68 profils de risque distincts.
- **Les nœuds internes (67)** sont les points de décision situés avant les feuilles : à chaque nœud interne, l'arbre applique un test sur une variable (par exemple « le réparateur est-il signalé ? » ou « le montant réclamé dépasse-t-il un certain seuil ? ») qui oriente le dossier vers l'une ou l'autre branche. Le nombre de nœuds internes est directement lié au nombre de feuilles : un arbre binaire comportant 68 feuilles possède nécessairement 67 nœuds internes.




FIGURE 5.12 – Représentation visuelle de l'arbre avec un découpage sur une profondeur de 2 branches (5 branches au total)

On peut également s'intéresser à l'importance relative des variables dans le modèle de prédiction de fraude, qui doit intuitivement être liée à leur niveau et fréquence d'apparition dans l'arbre retourné :

Importance des variables dans l'arbre

Part des sinistres traités par les nœuds de décision utilisant chaque variable : plus la barre est longue, plus la variable structure l'arbre.



FIGURE 5.13 – Hiérarchie de l'importance globale des variables dans le modèle "arbre de décision"

Le profil d'importance de l'arbre de décision est ici assez réparti, sans variable dominante isolée. Trois critères arrivent en tête à égalité, chacun structurant 14 % des décisions de l'arbre : le ratio facture/marché du réparateur, l'historique des montants réclamés par l'assuré et le nombre de fraudes passées de l'assuré.

Ils sont suivis de près par l'âge du véhicule et la présence d'une blessure déclarée sans preuve médicale (12 % chacun), puis par le nombre d'amendements à la déclaration (10 %) et le nombre de sinistres passés du véhicule (9 %). Ce n'est qu'ensuite que les autres variables voient leur poids décroître nettement, jusqu'à devenir marginales (2 % ou moins pour l'ancienneté du contrat, les autorités contactées ou le nombre de véhicules impliqués).

On notera par ailleurs que les variables absentes de ce graphique présentent une importance nulle : elles n'ont tout simplement jamais été retenues comme critère de coupure par l'arbre. Ce phénomène s'explique par la structure même du modèle, dont la profondeur a été limitée à 5 niveaux : **avec seulement 67 nœuds internes disponibles, l'arbre concentre ses coupures sur les variables les plus discriminantes et n'a pas l'occasion de mobiliser les autres, qui restent inexploitées.**

Cette répartition indique que l'arbre construit ses coupures successives sur un ensemble relativement large de variables, plutôt que de faire reposer sa structure sur un ou deux critères dominants. On retrouve néanmoins **en tête les mêmes signaux forts que dans les autres modèles** (ratio facture/marché, historique de l'assuré, antécédents de fraude), ce qui rejoint directement l'analyse de fréquence de fraude où ces variables ressortaient déjà comme les plus discriminantes. La cohérence entre modèles renforce la confiance dans la pertinence de ces résultats.

Il faut toutefois noter que cette mesure d'importance renseigne sur la manière dont l'arbre est structuré (la part des sinistres traités par les nœuds utilisant chaque variable), et non directement sur sa capacité de généralisation. L'arbre de décision demeure en effet le modèle le plus exposé au surapprentissage, comme le montre l'écart un peu plus marqué entre son AUC d'entraînement et son AUC de validation (cf. plus bas) : sa structure s'ajuste finement aux données observées, au risque de manquer de robustesse sur les cas moins typiques.

L'agent retourne une représentation visuelle complète de l'arbre créé mais également d'autres graphiques¹, tels que la distribution des scores par classe (histogrammes superposés) : distribution du score des fraudeurs vs distribution du score des non-fraudeurs. Comme pour le modèle de *scoring* en points, visuellement, plus les deux distributions sont **séparées**, meilleur est le modèle.

Distribution des scores par classe (jeu de test : 6000 sinistres)

Pour chaque tranche de score, ce graphique superpose (en transparence) le nombre de sinistres frauduleux et non frauduleux du jeu de test. Plus les deux distributions se chevauchent, plus il est difficile pour le modèle de séparer les deux classes à ce niveau de score.




FIGURE 5.14 – Distribution des scores par classe avec un arbre de décision (fraudeur/non fraudeur)

On observe sur ce graphique que la proportion de sinistres frauduleux (en rouge) augmente progressivement avec la probabilité estimée : quasi nulle dans les tranches basses, elle devient majoritaire dans les tranches les plus élevées ([90-100 %]). Cette progression témoigne d'un pouvoir de discrimination réel, même si un chevauchement subsiste dans les tranches intermédiaires, et que l'on retrouve certaines fraudes avec des probabilités pourtant faibles, ce qui témoigne d'un défaut du modèle.

Comme pour le modèle de *scoring* en points, le second graphique retourné par l'agent est le taux de fraude avéré par tranche de probabilité en sortie de l'arbre. Si le modèle est pertinent, les dossiers frauduleux doivent, en moyenne, présenter des probabilités plus élevées. Cette étape permet d'évaluer la capacité de l'arbre à séparer les deux populations et à hiérarchiser le risque de fraude de manière cohérente.

1. Graphiques réalisés sur la base de l'échantillon test (6000 lignes) et non sur l'échantillon d'apprentissage du modèle.

Calibration arbre de décision : taux de fraude avérée par tranche de probabilité (jeu de test : 6000 sinistres)




FIGURE 5.15 – Taux de fraude avérée par tranche de score de suspicion

La sortie issue de l'arbre de décision met en évidence une relation claire et structurée entre la probabilité de fraude estimée par le modèle et le taux de fraude réellement observé. On observe une **progression à tendance croissante du taux de fraude** à mesure que la probabilité prédite augmente, ce qui traduit une bonne capacité du modèle à ordonner les dossiers selon leur niveau de risque. Les premières tranches de probabilité (faibles scores) présentent des taux de fraude très limités, tandis que les tranches les plus élevées concentrent une proportion significativement plus importante de fraudes, pouvant dépasser 75 %.

Cette montée progressive est particulièrement intéressante d'un point de vue opérationnel, car elle permet de **segmenter efficacement les dossiers** et de prioriser les investigations sur les cas les plus risqués.

Par ailleurs, les caractéristiques du modèle (profondeur maximale de 5) traduisent un compromis maîtrisé entre complexité et capacité de généralisation. Le modèle reste suffisamment lisible tout en capturant des patterns discriminants. En synthèse, cette sortie confirme que l'arbre de décision fournit une **hiérarchisation cohérente et exploitable du risque de fraude**, avec une forte concentration des cas frauduleux dans les segments de probabilité élevée.

Si l'on s'appuie sur la distribution observée, l'idée est de définir des seuils qui maximisent la détection tout en restant opérationnellement soutenables (ne pas envoyer trop de dossiers en investigation lourde).

On peut distinguer **trois zones de risque** assez naturelles :

- **Zone faible (<35 %)** : le taux de fraude reste globalement modéré (inférieur à ~10 %). Ces dossiers peuvent être traités en flux standard, éventuellement avec des contrôles légers automatisés.
- **Zone intermédiaire (≈ 35 % à 90 %)** : on observe une montée progressive du taux de fraude (environ 20 % à 30 %+). un **seuil de vérification intermédiaire autour de 65–70 %** paraît pertinent. À ce niveau, on commence à avoir un enrichissement significatif en fraude, tout en conservant un volume de dossiers encore gérable pour des contrôles ciblés (revue documentaire, demandes complémentaires, etc.).
- **Zone élevée (> 90 %)** : le taux de fraude devient nettement plus important (60 % à plus de 70 %).

sur les dernières tranches). Un **seuil de vérification poussée autour de 90 %** est cohérent. Au-delà de ce seuil, on concentre fortement les fraudes, ce qui justifie des investigations approfondies (enquête terrain, expertise renforcée, gel du dossier, etc.).

Autrement dit, les règles d'investigation suivantes peuvent être mises en place :

- Probabilité < 35 % : pas d'investigation
- Probabilité comprise entre 35 % et 90 % : investigation légère
- Probabilité supérieure à 90 % : investigation poussée

Enfin, si l'on considère les sinistres classifiés comme nécessitant une investigation poussée comme « frauduleux » (score supérieur à 90 dans notre choix graphique ici), on obtient la matrice de confusion suivante :

Matrice de confusion Seuil : 90%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	218	470	688
Réel Non fraude	106	5 206	5 312
Total	324	5 676	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.16 – Matrice de confusion du modèle arbre de décision pour un seuil de 90 %

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $5\,206 / 5\,312 = 98,00 \%$;
- Le taux de fraude détectées (prédit fraude / réel fraude) : $218 / 688 = 31,69 \%$.
- Le taux de sinistres signalés frauduleux : $\text{prédit fraude} / \text{total} = 324 / 6\,000 = 5,40 \%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une optimisation du seuil afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.2.2 Qualité du modèle obtenu

L'introduction d'un arbre de décision permet de franchir un cap significatif. En intégrant des interactions entre variables et des effets de seuil, le modèle améliore la structuration du risque et offre une segmentation plus nette du portefeuille. La hiérarchisation des dossiers est plus cohérente : les feuilles les plus risquées de l'arbre concentrent un taux de fraude très élevé, proche de 79 %, bien au-delà de ce que permettait le *scoring* en points. Le modèle gagne ainsi en pouvoir discriminant sur les segments extrêmes, tout en conservant une certaine lisibilité grâce à sa structure arborescente.

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles mis en place présentés en section 3.7.

Pour commencer, on cherche le seuil optimal à partir duquel on peut considérer que les sinistres sont frauduleux à l'aide de l'indicateur de Youden² (présenté en section 5.1.2). Pour le modèle utilisant des arbres de décision, le seuil optimal est de 45 %.

Matrice de confusion Seuil : 45%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	517	171	688
Réel Non fraude	1 001	4 311	5 312
Total	1 518	4 482	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.17 – Matrice de confusion du modèle arbre de décision au seuil optimal (45 %)

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $4\,311 / 5\,312 = 81,16 \%$;
- Le taux de fraude détectées (prédit fraude / réel fraude) : $517 / 688 = 75,15 \%$;
- Le taux de sinistres signalés frauduleux : $\text{prédit fraude} / \text{total} = 1\,518 / 6\,000 = 25,30 \%$.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 25,30 % des sinistres, parmi lesquels 75,15 % sont réellement frauduleux, soit une densité de fraude environ 6,5 fois supérieure à celle d'un

2. Notre agent intègre le calcul du seuil optimal dans son fonctionnement.

contrôle aléatoire. L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :



FIGURE 5.18 – Synthèse des métriques de performance et de stabilité du modèle arbre de décision au seuil 45 %



FIGURE 5.19 – Courbe ROC et AUC pour le modèle arbre de décision

En retenant le seuil optimal de 45 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,845)** : excellente capacité de discrimination, très au-dessus du seuil de 0,8 considéré comme bon ; le modèle sépare efficacement fraudeurs et non-fraudeurs.
- **Gini (0,690)** : cohérent avec l'AUC, ce niveau traduit un pouvoir discriminant élevé, largement supérieur aux standards habituels en assurance.
- **KS (0,564)** : bien au-delà du seuil de 0,5, il confirme une nette séparation entre les distributions de scores des deux populations.
- **Précision (34,1 %)** : parmi les dossiers signalés comme frauduleux, un peu d'un tiers le sont réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (75,1 %)** : le modèle détecte près de trois fraudes sur quatre, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (46,9 %)** : compromis correct entre précision et rappel.
- **Accuracy (80,5 %)** : taux de bonnes classifications élevé, à interpréter toutefois avec prudence

sur données déséquilibrées où cet indicateur est peu informatif à lui seul.

- **Log-loss (0,4825)** : valeur modérée, traduisant une calibration des probabilités prédites correcte mais perfectible.

Enfin, concernant les indicateurs de robustesse et stabilité du modèle, les résultats suivants sont obtenus :

- **Backtesting (écart AUC train/test de 0,039)** : écart modéré entre apprentissage et test, signalant une tendance au surapprentissage mais restant contenue.
- **PSI (0,0026)** : très inférieur à 0,1, il atteste d'une bonne stabilité de la distribution des scores.

Ces résultats sont satisfaisants, mais restent moins bons que ceux du modèle de *scoring* en points.




FIGURE 5.20 – Indicateurs de robustesse et stabilité du modèle arbre de décision

5.2.3 Limites et précautions d'interprétation

Les arbres de décision constituent une avancée significative par rapport aux modèles de *scoring* en points, notamment par leur capacité à modéliser des interactions entre variables et à capturer des effets de seuil. Toutefois, ils présentent également un certain nombre de limites qu'il convient de considérer dans une utilisation opérationnelle.

En premier lieu, les arbres de décision sont **intrinsèquement instables** : de légères variations dans les données d'apprentissage peuvent conduire à des structures d'arbre sensiblement différentes. Cette sensibilité aux données peut impacter la robustesse du modèle et limiter sa capacité de généralisation sur de nouveaux portefeuilles. En d'autres termes, un arbre construit sur un échantillon donné peut ne pas reproduire exactement les mêmes règles de décision sur un autre échantillon pourtant similaire.

Par ailleurs, bien que les arbres permettent de capter des relations non linéaires, ils reposent sur une logique de **partitionnement par seuils successifs**, ce qui introduit des discontinuités dans la modélisa-

tion. Deux dossiers très proches peuvent ainsi être classés dans des feuilles différentes et se voir attribuer des probabilités de fraude sensiblement différentes, ce qui peut nuire à la stabilité des prédictions.

En outre, les arbres de décision ont tendance à **sur-apprendre** les données d'entraînement, en particulier lorsque leur profondeur est élevée ou que les contraintes de construction ne sont pas suffisamment strictes. Ce phénomène se traduit par une excellente performance sur les données d'apprentissage, mais une dégradation sur des données nouvelles. Des techniques de régularisation (élagage, limitation de profondeur, nombre minimal d'observations par feuille) sont donc nécessaires pour contrôler cette complexité.

Un autre point de vigilance concerne la **calibration des probabilités**. Les probabilités issues des feuilles de l'arbre (basées sur des proportions observées) peuvent être peu fiables, notamment lorsque les feuilles contiennent un nombre limité d'observations. Cela peut compliquer l'interprétation directe des scores en termes de probabilité de fraude et la définition de seuils décisionnels optimaux.

Enfin, bien que les arbres soient souvent considérés comme interprétables, cette interprétabilité peut rapidement se dégrader dès que la structure devient plus complexe (multiplication des branches et des feuilles). La lecture globale du modèle peut alors devenir difficile, en particulier pour des utilisateurs non techniques.

Ainsi, les arbres de décision offrent un bon compromis entre performance et lisibilité, mais nécessitent un encadrement méthodologique rigoureux pour garantir leur stabilité, leur robustesse et leur capacité de généralisation.

5.3 Un modèle de Machine learning : le Gradient Boosting

Enfin, le dernier modèle à être testé et dont les résultats sont présentés ci-dessous est un modèle de Machine Learning « Gradient *Boosting* ».



5.3.1 Résultats du modèle

Les paramètres du modèle de Gradient *Boosting* créé sont les suivants :

- **Le nombre d'arbres (200)** correspond au nombre de modèles élémentaires construits successivement. Dans le *boosting*, chaque nouvel arbre corrige les erreurs résiduelles des précédents ; l'accumulation de 200 arbres permet d'affiner progressivement la prédiction.
- **La profondeur maximale (3)** limite chaque arbre à trois niveaux de coupures. Des arbres vo-

lontainement peu profonds (« arbres faibles ») sont caractéristiques du *boosting* : leur pouvoir prédictif individuel est limité, mais leur combinaison séquentielle produit un modèle performant tout en réduisant le risque de surapprentissage.

- **Le taux d'apprentissage (0,1)** pondère la contribution de chaque arbre au modèle final. Une valeur faible ralentit l'apprentissage mais le rend plus stable et plus robuste, chaque arbre n'apportant qu'une correction mesurée.
- **Le sous-échantillonnage (0,8)** signifie que chaque arbre est entraîné sur 80 % des observations, tirées aléatoirement. Cette introduction de hasard limite le surapprentissage et améliore la capacité de généralisation du modèle.

On peut également s'intéresser à l'importance relative des variables dans le modèle de prédiction de fraude :

Importance des variables

Contribution relative de chaque variable aux arbres du modèle de boosting, telle que rapportée par l'algorithme.



FIGURE 5.21 – Hiérarchie de l'importance globale des variables dans le modèle "Gradient Boosting"

Le Gradient *Boosting* présente un profil intermédiaire, plus équilibré que l'arbre mais toujours hiérarchisé. Le ratio facture/marché reste en tête avec 25 %, suivi de l'historique des montants réclamés (16 %) et du nombre de fraudes passées de l'assuré (13 %), mais le pouvoir explicatif est ensuite mieux réparti sur une gamme plus large de variables (valeur du véhicule, amendements, durée de possession, âge du véhicule...), chacune contribuant de façon non négligeable au modèle (entre 5 % et 8 %).

Ce profil illustre bien ce qui fait la performance du Gradient *Boosting* : en combinant de nombreux arbres construits séquentiellement, le modèle conserve la hiérarchie des signaux forts (le ratio facture/marché demeure central) tout en exploitant l'information résiduelle portée par des variables secondaires que l'arbre unique négligeait. Il réalise ainsi un compromis entre la concentration de l'arbre et la dilution du *scoring*. On retrouve par ailleurs les mêmes variables clés que dans les deux autres modèles (ratio facture/marché, historique de l'assuré, antécédents de fraude) ce qui témoigne de la robustesse de ces signaux quel que soit le modèle.

Comme pour les deux autres modèles précédents, l'Agent IA retourne dans un premier temps la distribution du nombre de sinistres par tranche de 5 % de probabilité selon l'état du sinistre (frauduleux ou non).

Distribution des scores par classe (jeu de test : 6 000 sinistres)

Pour chaque tranche de score, ce graphique superpose (en transparence) le nombre de sinistres frauduleux et non frauduleux du jeu de test. Plus les deux distributions se chevauchent, plus il est difficile pour le modèle de séparer les deux classes à ce niveau de score.




FIGURE 5.22 – Distribution des scores par classe (fraudeur/non fraudeur)

Le modèle Gradient *Boosting* présente une très bonne séparation des deux classes (sinistres frauduleux / non frauduleux). La grande majorité des sinistres non frauduleux se concentre dans les tranches de faible probabilité (inférieures à 30 %) tandis que la part de sinistres frauduleux (en rouge) croît fortement dans les tranches élevées, devenant prépondérante autour des scores supérieurs à 85 %.

Ce basculement net, ainsi que le moindre chevauchement des distributions par rapport aux deux modèles précédents confirment la supériorité du Gradient *Boosting* en matière de discrimination entre dossiers frauduleux et sains.

Dans un second temps, l'Agent affiche la performance du modèle au travers de l'indicateur de taux de fraude avéré par tranche de probabilité.

Calibration Gradient Boosting : taux de fraude avérée par tranche de probabilité (jeu de test : 6000 sinistres)




FIGURE 5.23 – Taux de fraude avérée par tranche de score de suspicion

Ces graphiques mesurent la qualité prédictive du modèle sur le jeu de test, c'est-à-dire sur des sinistres qui n'ont pas été utilisés par le modèle lors de l'apprentissage. Les indicateurs reflètent donc sa capacité de généralisation à de nouveaux dossiers, et non une simple performance sur les données d'entraînement.

La sortie du modèle *Gradient Boosting* met en évidence une capacité de discrimination particulièrement élevée entre les dossiers frauduleux et non frauduleux. On observe une augmentation très marquée du taux de fraude avérée à mesure que la probabilité estimée croît, ce qui traduit une excellente cohérence entre les prédictions du modèle et la réalité observée sur les données d'apprentissage.

Contrairement aux modèles plus simples, la montée du taux de fraude est ici beaucoup plus prononcée. Au-delà de 85 %, on entre dans une zone où plus d'un sinistre sur deux est frauduleux, jusqu'à un taux de 91 % sur la tranche la plus élevée. Cela signifie que le modèle concentre très efficacement les fraudes dans les segments à forte probabilité.

Cette performance s'explique par la capacité du *Gradient Boosting* à capter des relations complexes, non linéaires et des interactions fines entre variables, ce qui lui permet d'identifier des schémas de fraude difficiles à détecter avec des approches plus classiques.

D'où les zones d'investigation suivantes :

- **Zone faible (<45 %)** : le taux de fraude reste globalement modéré (inférieur à ~10 %). Ces dossiers peuvent être traités en flux standard, éventuellement avec des contrôles légers automatisés.
- **Zone intermédiaire (≈ 45 % à 85 %)** : on observe une montée progressive du taux de fraude (environ 10 % à 45 %). À ce niveau, on commence à avoir un enrichissement significatif en fraude, tout en conservant un volume de dossiers encore gérable pour des contrôles ciblés (revue documentaire, demandes complémentaires, etc.).
- **Zone élevée (> 85 %)** : le taux de fraude devient nettement plus important (58 % à plus de 90 % sur les dernières tranches). Un **seuil de vérification poussée autour de 85 %** est cohérent. Au-

delà de ce seuil, on concentre fortement les fraudes, ce qui justifie des investigations approfondies (enquête terrain, expertise renforcée, gel du dossier, etc.).

Matrice de confusion Seuil : 85%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	390	298	688
Réel Non fraude	99	5 213	5 312
Total	489	5 511	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.24 – Matrice de confusion du modèle Gradient Boosting pour un seuil de 85 %

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $5\,213/5\,312 = 98,14\%$;
- Le taux de fraude détectées (prédit fraude / réel fraude) : $390/688 = 56,69\%$.
- Le taux de sinistres signalés frauduleux : $\text{prédit fraude} / \text{total} = 489/6\,000 = 8,15\%$.

Néanmoins, la méthode graphique de détermination du seuil n'est pas toujours la meilleure et une optimisation du seuil afin d'obtenir la meilleure qualité de modèle est proposée dans le passage suivant.

5.3.2 Qualité du modèle obtenu

Le recours à une méthode ensembliste comme le Gradient *Boosting* marque une rupture en termes de performance. Le modèle parvient à capturer des relations complexes et non linéaires, ce qui se traduit par une courbe de risque nettement plus régulière et globalement monotone.

La concentration des fraudes dans les tranches de probabilité élevées est particulièrement marquée, avec des taux proches de 100 % sur les segments les plus extrêmes (sur données d'apprentissage).

Les indicateurs présentés dans cette partie sont l'application pratique des critères de qualité des modèles mis en place présentés en section 3.7.

Pour commencer, on cherche le seuil optimal à partir duquel on peut considérer que les sinistres sont frauduleux à l'aide de l'indicateur de Youden (présenté en section 5.1.2). Pour le modèle utilisant de

Gradient *Boosting*, le seuil optimal est de 50 %.

Matrice de confusion Seuil : 45%

	Prédit Fraude	Prédit Non fraude	Total
Réel Fraude	601	87	688
Réel Non fraude	813	4 499	5 312
Total	1 414	4 586	6 000

Vert = correct Rouge = erreur Haut-gauche : vraies fraudes détectées (VP) Bas-droite : vrais non-fraudes (VN)

FIGURE 5.25 – Matrice de confusion du modèle Gradient Boosting avec un seuil de 45 %

Cette matrice permet de calculer :

- Le taux de non-fraudes bien classées (prédit non-fraudes / réel non-fraude total) : $4\,499 / 5\,312 = 84,69\%$;
- Le taux de fraude détectées (prédit fraude / réel fraude) : $601 / 688 = 87,35\%$;
- Le taux de sinistres signalés frauduleux : $\text{prédit fraude} / \text{total} = 1\,414 / 6\,000 = 23,57\%$.

L'efficacité opérationnelle de l'outil se mesure aussi à sa capacité à concentrer la fraude dans un volume restreint de dossiers à investiguer. Au seuil retenu, le modèle signale 23,57 % des sinistres, parmi lesquels 87,35 % sont réellement frauduleux, soit une densité de fraude environ 7,6 fois supérieure à celle d'un contrôle aléatoire. L'outil permet ainsi aux gestionnaires de concentrer leurs efforts sur un sous-ensemble à forte valeur, plutôt que de traiter l'ensemble du portefeuille.

À présent, observons les autres indicateurs de qualité du modèle :




FIGURE 5.26 – Synthèse des métriques de discrimination et classification du modèle Gradient Boosting au seuil 45 %



FIGURE 5.27 – Courbe ROC et AUC pour le modèle Gradient Boosting

En retenant le seuil optimal de 45 %, les indicateurs obtenus s'interprètent de la façon suivante :

- **AUC-ROC (0,933)** : excellente capacité de discrimination, très au-dessus du seuil de 0,8 considéré comme bon ; le modèle sépare efficacement fraudeurs et non-fraudeurs.
- **Gini (0,867)** : cohérent avec l'AUC, ce niveau traduit un pouvoir discriminant élevé, largement supérieur aux standards habituels en assurance.
- **KS (0,724)** : bien au-delà du seuil de 0,5, il confirme une nette séparation entre les distributions de scores des deux populations.
- **Précision (42,5 %)** : parmi les dossiers signalés comme frauduleux, un peu moins d'un sur deux l'est réellement. Valeur modérée, mais attendue à ce seuil abaissé et acceptable au vu de l'objectif de détection.
- **Rappel (87,4 %)** : le modèle détecte plus de quatre fraudes sur cinq, ce qui est le point fort de ce seuil et l'objectif prioritaire en détection de fraude.
- **F1-score (57,2 %)** : bon compromis entre précision et rappel.
- **Accuracy (85,0 %)** : taux de bonnes classifications élevé.

- **Log-loss (0,3131)** : valeur faible, signe d'une bonne calibration des probabilités prédites.

Enfin, concernant les indicateurs de robustesse et stabilité du modèle, les résultats suivants sont obtenus :

- **Backtesting** (écart AUC train/test de 0,016) : écart très faible entre apprentissage et test, signalant une excellente capacité de généralisation et l'absence de surapprentissage.
- **PSI (0,0023)** : très inférieur à 0,1, il atteste d'une bonne stabilité de la distribution des scores.




FIGURE 5.28 – Indicateurs de robustesse et stabilité du modèle Gradient Boosting

5.3.3 Limites et précautions d'interprétation

Le Gradient *Boosting* constitue le modèle le plus performant de cette étude, grâce à sa capacité à combiner un grand nombre d'arbres faibles corrigeant successivement leurs erreurs. Cette puissance s'accompagne toutefois de plusieurs limites qu'il convient de considérer dans une utilisation opérationnelle.

En premier lieu, le Gradient *Boosting* est un modèle nettement moins interprétable que les précédents. Là où un arbre unique ou un *scoring à point* offrent une lecture directe des règles de décision, la combinaison de deux cents arbres rend la logique globale difficile à retracer.

L'interprétation ne peut plus se faire directement sur la structure du modèle et nécessite le recours à des méthodes d'explicabilité complémentaires (importance des variables, valeurs de Shapley), qui restent des approximations et demandent une expertise spécifique.

Par ailleurs, le modèle est particulièrement sensible au réglage de ses hyperparamètres. Le nombre d'arbres, la profondeur, le taux d'apprentissage ou le sous-échantillonnage influencent fortement la performance et la robustesse : un paramétrage mal maîtrisé peut conduire à un surapprentissage, le modèle s'ajustant trop finement aux données d'entraînement au détriment de sa capacité de généralisation. Un encadrement méthodologique rigoureux, via une validation appropriée, est donc indispensable.

En outre, comme tout modèle supervisé, le *Gradient Boosting* reste dépendant de la qualité et de la représentativité des données historiques. Il peut amplifier certains biais présents dans les données (biais de détection ou d'investigation) et reproduire des schémas passés qui ne reflètent pas nécessairement les fraudes futures.

Enfin, la calibration des probabilités mérite attention : les scores produits ne sont pas toujours directement interprétables comme des probabilités exactes, ce qui justifie une étape de calibration et un choix réfléchi du seuil de décision.

Ainsi, le *Gradient Boosting* offre les meilleures performances prédictives de l'étude, mais au prix d'une moindre interprétabilité et d'une plus grande complexité de mise en œuvre, qui imposent un cadre de validation et de suivi rigoureux.

5.4 Comparaison des modèles

Une fois les trois modèles présentés, le passage ci-dessous a pour objet de faire une synthèse et comparaison des résultats obtenus pour orienter le choix du modèle finalement retenu parmi les trois modèles testés par l'Agent IA.

Ci-dessous, un tableau récapitulatif des différents indicateurs de qualité selon le modèle testé.

Indicateur	Scoring en point	Arbre de décision	Gradient Boosting
AUC-ROC	0,917	0,845	0,933
Gini	0,835	0,690	0,867
KS	0,666	0,564	0,724
Lift @10 %	—	×4,83	× 6,37
PSI	0,0026	0,0026	0,0023
Écart Backtesting	0,003	0,039	0,016

TABLE 5.2 – Synthèse des résultats des indicateurs de qualité des différents modèles

Stabilité et robustesse des modèles

Les trois modèles présentent une stabilité temporelle remarquable, avec des valeurs de PSI très inférieures au seuil d'alerte de 0,10 (0,003 pour le *scoring en points*, 0,0026 pour l'arbre de décision et 0,0023 pour le gradient boosting). Ces valeurs attestent d'une distribution homogène des scores entre les échantillons d'entraînement et de validation, et confirment que les modèles ne sont pas sensibles à des dérives temporelles sur la période considérée. Par ailleurs, le *backtesting* en split 80/20 révèle une bonne capacité de généralisation : les écarts entre AUC d'entraînement et AUC de validation restent contenus (0,009 pour le *Scoring en points*, 0,039 pour l'arbre de décision et 0,016 pour le *Gradient Boosting*). Le *scoring en points* affiche l'écart le plus faible, cohérent avec sa simplicité, tandis que le modèle basé sur les arbres

de décision présente l'écart le plus marqué, traduisant sa tendance connue au surapprentissage ; celui-ci reste toutefois modéré et n'entame pas significativement la robustesse du modèle.

Analyse du compromis précision / rappel et choix du seuil de décision

Le Gradient *Boosting* s'impose comme le modèle retenu à retenir, car il offre le meilleur pouvoir discriminant parmi les trois approches testées : une AUC de 0,942, un indice de Gini de 0,885 et un lift de $\times 6,66$ au premier décile. Il devance nettement le modèle basé sur un arbre de décision (AUC de 0,838, indice de Gini de 0,676, lift de $\times 4,61$) et, plus légèrement, le modèle basé sur un *scoring* en points (AUC de 0,923, indice de Gini de 0,846). Sa capacité à concentrer la fraude dans les premiers déciles en fait l'outil le plus efficace pour prioriser les dossiers à investiguer, ce qui correspond précisément à l'objectif opérationnel poursuivi.

Ce choix ne disqualifie pas pour autant le modèle basé sur un ***scoring* en points, qui demeure un modèle remarquablement performant au regard de sa simplicité**. Avec une AUC de 0,923 et un indice de Gini de 0,846, il se situe très près du Gradient Boosting et loin devant l'arbre de décision, tout en conservant une transparence et une interprétabilité que les méthodes d'ensemble ne permettent pas. Il constitue donc une alternative pleinement crédible lorsque l'explicabilité prime sur le dernier point de performance, par exemple pour une présentation aux gestionnaires ou dans un contexte réglementaire exigeant. Le choix entre ces deux modèles relève ainsi d'un arbitrage entre performance pure (Gradient *Boosting*) et interprétabilité (*scoring* en points), l'arbre de décision étant quant à lui écarté, dominé sur l'ensemble des critères.

Enfin, quel que soit le modèle retenu, la lecture des performances appelle une nuance commune. Le compromis entre précision et rappel est la conséquence directe du fort déséquilibre des classes dans les données de sinistres. D'un point de vue actuariel, ce ratio doit être piloté explicitement : modifier le seuil de décision permet d'ajuster le rappel au prix d'un volume plus ou moins élevé de dossiers à investiguer.

Enfin, quel que soit le modèle retenu, la lecture des performances appelle une nuance commune, liée à la tension inhérente entre précision et rappel. Ces deux indicateurs évoluent en sens inverse selon le seuil de décision : abaisser le seuil permet de détecter davantage de fraudes (rappel plus élevé), mais au prix d'un plus grand nombre de dossiers sains signalés à tort (précision plus faible), et inversement.. D'un point de vue actuariel, ce ratio doit être piloté explicitement : modifier le seuil de décision permet d'ajuster le rappel au prix d'un volume plus ou moins élevé de dossiers à investiguer. Le choix optimal de ce curseur dépend du coût asymétrique des deux types d'erreurs : un faux négatif (fraude non détectée) engendre une perte indemnisée à tort, tandis qu'un faux positif (investigation inutile) représente un coût opérationnel pour la cellule fraude. C'est précisément pour cette raison que l'outil développé laisse à l'utilisateur le soin de manipuler dynamiquement le curseur des seuils de détection, afin d'adapter le dispositif au contexte et à l'appétence au risque de chaque assureur.

Configuration finale du modèle

La dernière étape de l'Agent IA de création du modèle d'aide à la détection de fraude consiste à l'enregistrement du modèle choisi.

Pour ce faire, l'utilisateur doit confirmer le modèle retenu ainsi que le seuil optimal.

Un seuil d'investigation fixé par défaut à $\pm 10\%$ ³ du seuil optimal sera retenu, ainsi, si l'on considère par exemple un seuil optimal de 45 %, trois zones d'investigations seront mises en place :

- Probabilité de fraude < 35 % : pas d'investigation
- Probabilité de fraude entre 35 % et 55 % : investigation légère
- Probabilité de fraude supérieure à 55 % : investigation à lancer

Dans notre cas, on choisit le modèle *Gradient Boosting* avec les seuils 35 % et 55 % .

CONFIGURATION DU MODULE 2

Confirmer la configuration retenue

Le dernier modèle consulté pendant l'analyse est retenu automatiquement.
Les seuils sont calculés autour de son seuil optimal et ne sont pas modifiables ici.



La confirmation enregistre uniquement cette configuration pour le module 2 ; elle ne lance aucun scoring.

FIGURE 5.29 – Configuration finale du modèle et des seuils d'investigation

Une fois cette dernière étape réalisée, l'outil mis à disposition du service de détection des fraudes est configuré avec ce modèle et ces seuils d'investigation.

Ces derniers ne sont pas modifiables dans le second outil. Seul le premier Agent IA doit être relancé pour modifier le modèle sous-jacent de modélisation de la probabilité de fraude.

3. Ces seuils d'investigation peuvent être modifiés par l'utilisateur s'il le souhaite.

Chapitre 6

Outil mis à disposition du service de détection des fraudes

Le présent chapitre traite à présent du second outil créé à l'aide de l'Intelligence Artificielle.

Ce dernier se présente sous forme d'une interface utilisateur proposant trois fonctionnalités :

1. Évaluer un ou plusieurs nouveaux sinistres : l'utilisateur dépose un fichier contenant des informations sinistres pour estimer, pour chaque dossier, sa probabilité de fraude intrinsèque ;
2. Renseigner le résultat de fraude de sinistres testés précédemment : cela permettra d'enrichir la base de données utilisée pour la construction du modèle dans l'outil précédent ;
3. Consulter le bilan annuel de fraude : l'utilisateur peut lire les analyses sur les fraudes de l'année (montant économisé, rapport sur les mécanismes de fraudes récurrents, etc.).

Ces différentes fonctionnalités seront décrites en détail dans les paragraphes suivants.

Scoring — nouveaux sinistres

Que souhaitez-vous faire ?




FIGURE 6.1 – Écran interactif d'accueil du second outil

6.1 Utilisation pratique de l'outil

L'outil mis à disposition du service de détection des fraudes constitue la traduction opérationnelle du modèle de détection des fraudes développé en amont. Il s'inscrit dans une logique d'**aide à la décision fondée sur une estimation probabiliste du risque de fraude**, permettant d'orienter de manière cohérente et homogène les actions de contrôle sur les sinistres.

En amont de son utilisation, les seuils de décision sont définis par l'actuaire en charge du modèle, puis transmis aux gestionnaires sinistres pour paramétrage dans l'outil. Ces seuils permettent de segmenter l'espace des probabilités en différentes zones de risque.

À ce stade, on retient à titre illustratif le dernier modèle (*Gradient Boosting*) et les seuils suivants :

- $Seuil_{inf} = Seuil_{optimal} - 10 \%$
- $Seuil_{sup} = Seuil_{optimal} + 10 \%$

Ce qui crée naturellement les trois zones :

- Une zone de faible risque (verte) : $[0; Seuil_{inf}[$;
- Une zone de risque intermédiaire (orange) : $[Seuil_{inf}; Seuil_{sup}[$;
- Une zone de risque élevé (rouge) : $[Seuil_{sup}; 100 \%]$.

Ces seuils traduisent un arbitrage actuariel entre le **coût des investigations** (notamment en termes de ressources mobilisées et de délais de gestion) et le **gain attendu lié à la détection de fraude**, en tenant compte des taux de faux positifs et de faux négatifs.

Lorsque l'utilisateur clique sur « tester de nouveaux sinistres », l'outil demande ensuite à l'utilisateur de renseigner les caractéristiques d'un ou plusieurs sinistres pour lancer l'analyse. Cette intégration peut s'effectuer de deux manières : soit de façon industrielle par le dépôt d'un fichier standardisé, soit de manière unitaire via un formulaire de saisie manuelle (cf. illustration ci-dessous).

Fichier CSV à évaluer

Sans la colonne `fraud_reported`



Glissez-déposez votre CSV ici, ou cliquez

Sans `fraud_reported`

Ces flux d'entrée reprennent exactement les mêmes variables explicatives que notre base de modélisation (franchise, âge, profession, type d'incident, montants, etc.), mais sans intégrer la colonne cible de fraude avérée (`fraud_reported`).

Ou saisir les informations sur le sinistre manuellement

Toutes les variables explicatives disponibles pour le scoring, organisées par domaine métier. * Champ obligatoire

Renseignez les informations disponibles

Seul l'identifiant de police est obligatoire. Les champs non renseignés sont traités comme des valeurs manquantes, comme lors d'un import CSV.

Contrat

Informations de souscription et ancienneté de la police. • 5 variables

Assuré

Profil, activité et historique consolidé de l'assuré. • 12 variables

Sinistre

Circonstances, dommages et éléments de preuve du sinistre. • 14 variables

Véhicule

Caractéristiques et historique agrégé du véhicule concerné. • 5 variables

Historique et intervenants

Indicateurs consolidés sur le réparateur et le tiers impliqué. • 5 variables

Indicateurs de déclaration

Délai, canal et signaux complémentaires liés à la déclaration. • 7 variables

FIGURE 6.2 – Saisie manuelle des informations sinistre pour évaluation de la probabilité de fraude

Sur la base des informations sinistre renseignés, le modèle calcule une **probabilité de fraude en appliquant le modèle retenu dans l'outil de modélisation de la fraude**.

Cette probabilité constitue une mesure synthétique du risque, intégrant l'ensemble des signaux de fraude identifiés lors de la phase de modélisation.

La décision opérationnelle repose alors sur la **comparaison de cette probabilité aux seuils définis dans l'outil précédent (enregistrés en paramètres)**. Chaque sinistre est ainsi affecté à une classe de risque, à laquelle est associée une stratégie de gestion différenciée :

- Absence d'investigation pour les niveaux faibles ;
- Contrôles ciblés pour les niveaux intermédiaires ;
- Et investigations approfondies pour les niveaux élevés.

Ce dispositif permet d'optimiser la **fonction de coût globale** du processus de détection, en concentrant les efforts sur les dossiers présentant le meilleur ratio entre probabilité de fraude et coût d'investigation.

À titre d'illustration, sur un échantillon test de 500 sinistres, l'outil réalise un filtrage puissant en isolant immédiatement 474 dossiers en zone verte (ne nécessitant aucune investigation humaine), 21 dossiers en

zone orange (à surveiller ou contrôler superficiellement) et seulement 5 dossiers en zone rouge (faisant l'objet d'une alerte prioritaire).




FIGURE 6.3 – Probabilité en sortie de l'outil

Ainsi, l'outil s'inscrit dans une démarche actuarielle classique de **segmentation du risque et de prise de décision sous contrainte**, en transformant une estimation probabiliste issue du modèle en règles de gestion opérationnelles directement exploitables par les équipes métiers.

L'utilisation d'un tel outil présente plusieurs avantages majeurs dans le cadre de la détection de fraude, tant d'un point de vue actuariel qu'opérationnel. En premier lieu, il permet de **standardiser l'évaluation du risque de fraude** en s'appuyant sur un modèle statistique commun, appliqué de manière homogène à l'ensemble des sinistres. Cette standardisation réduit significativement les **variabilités de traitement entre gestionnaires**, liées à l'expérience, à la subjectivité ou à la sensibilité individuelle au risque, et garantit une plus grande cohérence dans les décisions prises.

En outre, l'outil favorise une **objectivation du processus de décision** en reposant sur une estimation probabiliste issue de données historiques. Il limite ainsi les biais cognitifs (sur- ou sous-estimation du risque, effet d'ancrage, etc.) et permet d'inscrire la détection de fraude dans une démarche plus rigoureuse et traçable. Chaque décision d'investigation peut être justifiée par un niveau de risque mesuré, ce qui améliore la **transparence et l'auditabilité** des pratiques.

Par ailleurs, en segmentant les sinistres selon leur niveau de risque, l'outil permet une **allocation optimale des ressources d'investigation**. Les dossiers les plus susceptibles d'être frauduleux sont priorisés, ce qui augmente l'efficacité globale du dispositif tout en maîtrisant les coûts liés aux contrôles. Cette approche s'inscrit dans une logique actuarielle d'optimisation du couple **coût de détection / gain attendu**, en maximisant la rentabilité des actions de lutte contre la fraude.

Enfin, cet outil constitue un levier d'**harmonisation et de pilotage** à l'échelle du portefeuille. Il permet de suivre la performance du dispositif (taux de fraude détectée, taux de transformation des contrôles, etc.), d'ajuster les seuils de décision en fonction des résultats observés, et d'assurer une meilleure compa-

rabilité dans le temps. Il contribue ainsi à structurer la fonction fraude autour d'indicateurs quantitatifs et d'une approche pilotée par la donnée.

6.2 Un outil permettant l'enrichissement du modèle en continu

Dans une logique d'amélioration continue, l'outil intègre un mécanisme de boucle de retour d'information (*feedback loop*) permettant d'enrichir progressivement la base de données d'apprentissage. Ce mécanisme repose sur une base "historique" (ensemble des sinistres renseignés dans l'outil afin d'obtenir une probabilité de fraude), dans laquelle sont automatiquement archivés l'ensemble des sinistres soumis à l'outil, accompagnés de la probabilité de fraude qui leur a été attribuée.




FIGURE 6.4 – Schéma macro du mécanisme d'enrichissement de la base de données

Comme l'illustre le schéma ci-dessus, lorsque l'utilisateur soumet un nouveau sinistre pour en estimer la probabilité de fraude, le dossier scoré rejoint la base historique. À ce stade, cette base ne contient toutefois pas encore l'information la plus précieuse pour le modèle : l'issue réelle du dossier. Savoir si un sinistre s'est effectivement révélé frauduleux n'est en effet connu qu'à l'issue de son instruction, souvent plusieurs semaines, voire plusieurs mois, après la déclaration. C'est ce constat qui structure la logique d'enrichissement retenue.

Plutôt que de demander au gestionnaire de statuer immédiatement sur une fraude qu'il ne peut encore confirmer, l'outil lui permet de revenir à tout moment dans la base historique pour y renseigner le statut final d'un ou plusieurs sinistres (fraude avérée ou non). Cette dissociation entre le moment du *scoring* et celui de la qualification reflète fidèlement la réalité opérationnelle de la gestion des sinistres, où le dénouement d'un dossier est par nature différé.

POL100029

×

Single Vehicle Collision · 97 % de risque · 17483 €

Décision à enregistrer
Documentez le statut de fraude et les montants associés à ce sinistre.

Statut fraude *

Fraude
Pas de fraude

Date de décision

14/08/2026

📅

Montant hors fraude (€)
Impact financier (€)

0

0

Part légitime à indemniser.
Fraude évitée ou impact estimé.

Motif

Ex : déclaration incohérente

Commentaire

Observations libres du gestionnaire...

Enregistrer le résultat

FIGURE 6.5 – Feuille de renseignement d'un sinistre à l'issue d'une investigation

Une fois cette issue renseignée, le sinistre concerné dispose d'un couple complet d'informations : ses caractéristiques d'entrée d'une part, et sa variable cible de fraude (*fraud_reported*) d'autre part. Il devient alors une observation exploitable pour l'apprentissage, au même titre que les données ayant servi à la construction initiale du modèle. C'est bien un statut binaire, et non une probabilité, qui alimente ainsi la base : un sinistre confirmé comme frauduleux après investigation est enregistré à 1, tandis qu'un sinistre investigué mais jugé finalement légitime est enregistré à 0. Le modèle ne se réentraîne donc que sur des cas dont l'issue est avérée, et non sur de simples suspicions, ce qui garantit la fiabilité de son apprentissage au fil du temps.

A noter que **l'enrichissement de la base de données ne modifie pas le modèle de façon instantanée**. En effet le réentraînement s'effectue en repassant par le module de construction (Module 1), qui

refait tourner le modèle sur la base augmentée des nouvelles observations qualifiées. En pratique, cette opération est menée à intervalles de temps réguliers (, typiquement une fois par an), afin d'intégrer un volume significatif de nouveaux cas tout en garantissant la stabilité du dispositif entre deux mises à jour.

Cette approche présente plusieurs intérêts sur le plan actuariel. D'abord, elle permet d'augmenter la taille et la représentativité de la base d'apprentissage, en y intégrant des cas récents qui reflètent l'évolution des comportements frauduleux et des méthodes de fraude utilisées. Elle contribue ainsi à réduire le décalage entre les données historiques initiales et la réalité opérationnelle, dans un contexte où les schémas de fraude évoluent rapidement.

Ensuite, ces nouvelles observations permettent un recalibrage et une réestimation réguliers du modèle : actualisation des paramètres, amélioration de la capacité de discrimination et, le cas échéant, réajustement de la pondération des variables. L'objectif est de maintenir dans le temps une performance prédictive stable, mesurée à l'aide d'indicateurs tels que l'AUC, le Gini ou les courbes de gains, et de surveiller l'absence de dérive du modèle (via le PSI notamment).

Enfin, l'intégration systématique des issues réelles permet de mieux maîtriser certains biais inhérents aux dispositifs de détection, en particulier le biais de sélection lié aux dossiers investigués. En alimentant la base avec les décisions finales issues de l'ensemble des sinistres traités (et non des seuls dossiers ayant fait l'objet d'une alerte) le modèle gagne en robustesse et en cohérence.

Ainsi, l'outil ne se limite pas à une utilisation statique du modèle : il s'inscrit dans une démarche dynamique de modélisation itérative, où chaque sinistre qualifié vient affiner la connaissance du risque et améliorer la pertinence du dispositif de détection.

6.3 Rapport annuel de détection de fraude

Au-delà du *scoring* individuel des sinistres, l'outil **intègre une fonctionnalité de pilotage** offrant une vision agrégée de la performance du dispositif sur une période donnée (paramétrable mais dans les faits, mensuelle ou annuelle). Lancé annuellement, il constitue la synthèse cumulative de l'activité de détection de fraudes : il s'appuie sur l'ensemble des sinistres testés dans l'outil pour obtention de score de fraude et les résultats des investigations renseignés. Ainsi, il permet de ressortir des indicateurs de volume (sur les dossiers traités) mais également économiques (fraude évitée en montant).

Cette vue de synthèse répond à un besoin actuariel essentiel : ne pas se limiter à une utilisation opérationnelle au fil de l'eau, mais disposer d'indicateurs consolidés permettant d'évaluer et de justifier l'utilisation de l'outil et d'ajuster le dispositif mis en place dans le temps.




FIGURE 6.6 – Exemple de rapport annuel de la détection de fraude

Dans notre outil, différents indicateurs ont été mis en place :

- Les premiers indicateurs portent sur le **volume et la détection** : nombre de sinistres testés, nombre d'alertes générées par le modèle et nombre de fraudes effectivement confirmées après investigation. Leur mise en regard permet d'apprécier la charge de travail générée par l'outil et le taux de concrétisation des alertes.
- Viennent ensuite les indicateurs **financiers**, au cœur de l'enjeu actuariel. Le montant de fraude évitée agrège les sinistres frauduleux confirmés qui n'ont pas donné lieu à indemnisation grâce à l'outil. Pour compléter cet indicateur, un KPI important est également calculé : l'impact sur le **ratio Sinistres / Primes (S/P)** de la détection de fraude qui traduit directement le gain apporté par la détection sur l'équilibre technique du portefeuille. En effet, en écartant une partie de la charge frauduleuse, l'outil améliore mécaniquement ce ratio. Cet indicateur fait le lien avec l'analyse développée au chapitre 1 : là où nous avons modélisé la surprime supportée par les assurés honnêtes par la relation $\Pi_{\text{chargée}} = \frac{\Pi_{\text{pure}}}{1-\alpha}$, le rapport annuel permet de quantifier *a posteriori* la part de charge frauduleuse α effectivement récupérée, et donc l'effet réel de l'outil sur la tarification.

- Le rapport suit également la **qualité opérationnelle** du dispositif. La précision de l'outil mesure, parmi les alertes confirmées, la proportion de véritables fraudes, indicateur clé pour éviter de mobiliser inutilement les équipes d'investigation sur des faux positifs. La répartition des sinistres par zone de risque (verte, orange, rouge) permet quant à elle de visualiser la distribution du portefeuille et d'ajuster les seuils $Seuil_{inf}$ et $Seuil_{sup}$ si nécessaire.
- Enfin, deux indicateurs relèvent d'une logique d'**intelligence fraude** plus avancée. L'identification des réseaux, en repérant les sinistres impliquant plusieurs véhicules, signale une suspicion de fraude organisée, distincte de la fraude opportuniste. La détection de nouvelles tendances met en évidence l'émergence de schémas de fraude inédits, permettant d'anticiper l'évolution des comportements frauduleux.

L'ensemble se synthétise dans une mesure du **retour sur investissement (ROI) de l'outil**, rapprochant le gain généré (fraude évitée) du coût de mise en œuvre et d'exploitation du dispositif. Cet indicateur répond directement à la problématique de rentabilité posée en introduction : il démontre que l'automatisation de la détection, en abaissant le coût marginal de contrôle, rend rentable l'analyse de l'ensemble des sinistres, y compris ceux de faible montant jusque-là trop coûteux à investiguer manuellement.

Ce rapport peut par ailleurs être exporté au format PDF, offrant un livrable synthétique directement transmissible à la Direction Technique, au service anti-fraude ou aux instances de gouvernance. Cette possibilité d'extraction facilite le reporting périodique et la traçabilité des résultats, en cohérence avec les exigences de documentation évoquées dans le cadre de gouvernance de l'outil (cf. section 4.1).

Ainsi, le rapport annuel transforme l'outil de détection en véritable instrument de pilotage actuariel. Il ne se contente pas de traiter les sinistres individuellement, mais fournit une lecture consolidée et chiffrée de la performance du dispositif, permettant de justifier son maintien, d'en ajuster les paramètres et d'en mesurer l'impact réel sur l'équilibre technique du portefeuille.

6.4 Dynamisme de l'outil mis en place

Le modèle développé présente un caractère **dynamique et évolutif**, essentiel dans un environnement assurantiel en constante mutation. Concrètement, il ne s'agit pas d'un modèle figé : sa structure permet de **modifier le format des données d'entrée**, qu'il s'agisse des variables utilisées, de leurs modalités ou encore des règles de segmentation associées. Il est ainsi possible d'intégrer de nouvelles caractéristiques, d'adapter les découpages existants ou de faire évoluer les référentiels, puis de **relancer le processus d'apprentissage** afin de recalibrer automatiquement le modèle.

Cette flexibilité constitue un atout majeur pour accompagner les évolutions réglementaires, tarifaires ou opérationnelles des assureurs. Par exemple, l'introduction de nouvelles modalités dans les classes de véhicules — liée à des changements de classification, à l'émergence de nouveaux types de motorisation ou à des ajustements tarifaires — peut être directement intégrée dans le modèle. Celui-ci est alors en mesure de réapprendre les relations entre ces nouvelles modalités et le risque de fraude, sans nécessiter

une refonte complète de l'outil.

Ainsi, le modèle s'inscrit dans une logique d'**amélioration continue**, permettant de maintenir sa pertinence dans le temps. Cette capacité d'adaptation garantit une meilleure prise en compte des évolutions du portefeuille, des comportements frauduleux et du cadre réglementaire, tout en assurant une cohérence avec les pratiques métiers et les politiques de souscription de l'assureur.

Chapitre 7

7 Réflexions autour de l'IA et limites de l'outil créé

Le développement d'un outil de détection de fraude basé sur un agent IA, en assurance automobile constitue une avancée significative en matière d'aide à la décision. Néanmoins, son utilisation doit être appréhendée avec recul, tant sur le plan opérationnel que méthodologique, et ouvre plusieurs perspectives d'amélioration.

7.1 Un outil d'aide à la décision complémentaire avec l'humain

Il est encore une fois essentiel de souligner que l'agent IA ne se substitue pas au gestionnaire, mais s'inscrit dans une logique de **complémentarité homme-machine**. L'intervention humaine reste centrale à chaque étape du processus.

En amont, l'actuaire ou le *data scientist* intervient dans la **construction et le paramétrage du modèle** : sélection de la base de données, choix du type de modèle (scoring en points, arbre de décision, Gradient Boosting), validation de sa performance et de sa cohérence métier.

En phase d'utilisation, le gestionnaire reste responsable de la **saisie des informations relatives au sinistre**, de l'interprétation du score fourni et, le cas échéant, de la décision finale d'investigation. Enfin, il contribue à l'amélioration continue du modèle en renseignant le **statut final du dossier (fraude ou non)**, après avoir fait lui-même l'enquête permettant de prouver cette réponse, alimentant ainsi la base d'apprentissage.

Les deux schémas ci-dessous illustrent concrètement les points d'intervention humaine au sein du processus : ils font apparaître, à chaque étape, la frontière entre ce que l'agent automatise et ce qui reste du ressort du gestionnaire.




FIGURE 7.1 – Points d'intervention humaine dans le module de construction du modèle




FIGURE 7.2 – Points d'intervention humaine dans le module opérationnel de détection

Ainsi, l'agent IA agit comme un outil d'aide à la décision structurant et homogénéisant, mais ne remplace en aucun cas l'expertise métier, indispensable pour interpréter les situations complexes et prendre des décisions adaptées.

7.2 Nature de l'IA utilisée : de l'IA générative à l'IA agentique

Il convient également de distinguer les différents types d'intelligence artificielle mobilisables dans ce contexte.

L'**IA générative** (comme les modèles de langage) est principalement utilisée pour produire du contenu (texte, code, synthèses) et assister dans des tâches d'analyse ou de documentation. À l'inverse, l'**IA agentique** s'inscrit dans une logique plus opérationnelle : elle est capable d'enchaîner des actions, de prendre des décisions simples et d'interagir avec un environnement en fonction d'objectifs définis.

Dans le cadre de cet outil, l'agent IA relève davantage d'une approche **agentique**, en ce sens qu'il guide l'utilisateur dans le choix du modèle, applique le modèle défini, et restitue une probabilité de fraude accompagnée d'une recommandation d'action.

À noter que par défaut, l'outil s'est initialement appuyé sur un **modèle de scoring en points**, privilégié pour sa simplicité et son interprétabilité. Toutefois, afin d'améliorer la performance prédictive, des extensions ont ensuite été introduites permettant de recourir à des modèles plus avancés tels que les **arbres de décision**, ou des méthodes de **machine learning** (Gradient Boosting). Cette ouverture permet d'arbitrer entre **interprétabilité et performance**, en fonction des besoins métiers.

7.3 Limites liées à la qualité et à la richesse des données

7.3.1 Le couplage à la base portefeuille

La performance et la pertinence d'un modèle de détection de fraude reposent de manière déterminante sur la qualité, la granularité et la richesse des données disponibles.

Dans le cadre de cette étude, le modèle est construit uniquement à partir d'une base sinistre, ce qui constitue une première limite importante. En effet, certaines informations structurantes issues de la base portefeuille ne sont pas accessibles, alors même qu'elles pourraient apporter un pouvoir explicatif significatif.

Parmi ces informations, on peut notamment citer l'ancienneté du contrat, l'historique de sinistralité de l'assuré, la fréquence de résiliation ou de souscription, ou encore des éléments d'identification permettant de reconstituer des liens entre individus (assurés, conducteurs, tiers).

Pour pallier partiellement cette limite, la base sinistre a été enrichie de trente variables reconstituant une partie de cette information (cf. section 4.2.2). Cet enrichissement ne remplace toutefois pas l'accès à une véritable base portefeuille, qui offrirait une profondeur historique et relationnelle hors de portée d'un enrichissement à partir du seul sinistre.

L'absence de ces variables limite la capacité du modèle à capter des comportements de fraude plus complexes, notamment ceux reposant sur des logiques de répétition ou d'organisation.

À titre d'exemple, en assurance automobile, l'accès à la base portefeuille permettrait de détecter plus efficacement certains schémas de fraude tels que :

- **Fraudes opportunistes liées à une ancienneté très faible du contrat** : un sinistre survenant peu de temps après la souscription (ex : vol ou incendie dans les premières semaines) constitue un signal faible classique, difficile à exploiter sans information sur la date d'entrée en portefeuille.
- **Récurrence de sinistres sur un même assuré** : un assuré présentant une fréquence de sinistralité anormalement élevée sur une période donnée peut indiquer un comportement suspect (ex : déclarations répétées de bris de glace ou d'accidents matériels). Sans historique consolidé, ces

signaux ne peuvent être captés que partiellement.

- **Stratégies de multi-assurance ou de résiliation stratégique** : certains fraudeurs peuvent multiplier les contrats auprès de différents assureurs ou résilier après sinistre pour éviter d'être détectés. L'analyse des trajectoires contractuelles (durée de détention, fréquence de changement d'assureur) constitue alors une variable explicative clé.
- **Fraudes en réseau ou en bande organisée** : l'identification de liens entre individus (même adresse, même véhicule impliqué dans plusieurs sinistres, tiers récurrents dans des accidents) permettrait de détecter des schémas de fraude structurés. Par exemple, des accidents impliquant régulièrement les mêmes personnes ou garages peuvent révéler des montages frauduleux (accidents simulés, complicités avec des réparateurs, etc.).
- **Incohérences entre profil assuré et sinistre déclaré** : certaines variables portefeuille (âge, ancienneté de conduite, historique de comportement) permettent de mieux contextualiser un sinistre. Par exemple, un assuré sans historique de sinistre déclarant soudainement un sinistre grave peut être analysé différemment d'un profil déjà sinistré.

L'intégration de ces données permettrait d'introduire de nouvelles variables explicatives à forte valeur ajoutée actuarielle, telles que :

- des indicateurs de fréquence individuelle de sinistralité ;
- des variables de durée en portefeuille ;
- des scores de comportement client ;
- des variables de réseaux (graph analytics) identifiant des connexions entre dossiers.

Ces enrichissements contribueraient à améliorer significativement la capacité de discrimination du modèle, en captant des dimensions aujourd'hui absentes, notamment les effets temporels et relationnels. En pratique, cela se traduirait par une meilleure séparation entre sinistres frauduleux et non frauduleux, et donc une optimisation des actions de détection.

Au-delà de la richesse des variables, la qualité des données constitue également un enjeu majeur. Les erreurs de saisie, les données manquantes ou encore les délais dans la confirmation des fraudes peuvent introduire des biais dans l'apprentissage du modèle. Par ailleurs, la fraude étant par nature un phénomène partiellement observé, la base d'apprentissage est susceptible de contenir un biais de sous-détection, certaines fraudes n'étant jamais identifiées comme telles.

Ainsi, l'amélioration de la détection de fraude passe non seulement par le choix des modèles, mais aussi (et surtout) par une stratégie d'enrichissement et de fiabilisation des données. Dans cette perspective, l'intégration de données portefeuille, voire de données externes ou mutualisées, constitue un levier essentiel pour renforcer la robustesse et la performance du dispositif.

7.3.2 Ajout de données externes

En complément à l'enrichissement par les données issues de la base portefeuille, le recours à des **sources de données complémentaires** constitue un levier majeur d'amélioration des modèles de détection de fraude. En effet, la fraude étant un phénomène complexe et évolutif, sa détection nécessite une approche multidimensionnelle intégrant des informations variées, parfois extérieures au strict périmètre assurantiel.

En premier lieu, l'exploitation de données externes ouvertes (*open data*) peut permettre d'apporter un éclairage contextuel précieux. Par exemple, les données météorologiques peuvent être mobilisées afin de vérifier la cohérence entre les circonstances déclarées d'un sinistre et les conditions climatiques réelles (pluie, grêle, tempête).

De même, les données géographiques permettent d'identifier des zones à risque, notamment en matière de vol ou de vandalisme, et d'analyser la fréquence des sinistres dans certaines localisations. Enfin, les données socio-économiques locales peuvent contribuer à affiner la compréhension des comportements, en intégrant des variables de contexte telles que le niveau de revenu ou les caractéristiques du territoire.

Par ailleurs, lorsque cela est possible, l'intégration de données télématiques constitue un apport particulièrement structurant. Ces données, issues de capteurs embarqués ou d'applications mobiles, permettent de reconstituer le comportement de conduite (vitesse, accélérations, freinages, horaires d'utilisation) et d'évaluer la cohérence entre l'usage réel du véhicule et le sinistre déclaré. Ainsi, un sinistre survenu dans des conditions incompatibles avec les données de conduite enregistrées peut constituer un signal fort de fraude.

Les données issues des prestataires (réparateurs, experts, avocats) représentent également une source d'information à forte valeur ajoutée. L'analyse de leur historique d'intervention permet d'identifier des acteurs apparaissant de manière récurrente dans des dossiers suspects. Une surreprésentation de certains prestataires dans des sinistres à fort taux de fraude peut révéler des comportements anormaux, voire des complicités, et constitue ainsi un levier de détection des fraudes organisées.

En outre, l'exploitation des données textuelles non structurées, telles que les descriptions de sinistres ou les comptes rendus d'expertise, ouvre des perspectives intéressantes grâce aux techniques de traitement automatique du langage (NLP). L'analyse de ces textes permet de détecter des incohérences, des formulations atypiques ou des schémas linguistiques récurrents associés à des comportements frauduleux. Ces informations, difficilement exploitables dans une approche classique, enrichissent considérablement la capacité du modèle à capter des signaux faibles.

Une autre piste d'amélioration repose sur l'utilisation d'une approche réseau (*graph analytics*). Cette méthodologie consiste à modéliser les relations entre les différents acteurs d'un sinistre (assurés, tiers, véhicules, adresses, prestataires) afin d'identifier des communautés ou des structures anormales. Elle permet notamment de détecter des schémas de fraude organisée, caractérisés par la répétition de certaines combinaisons d'acteurs ou de situations (typiquement, les mêmes individus impliqués dans plusieurs sinistres, les mêmes véhicules ou les mêmes adresses apparaissant de manière récurrente). Cette approche relationnelle dépasse la simple analyse individuelle des dossiers et offre une vision plus globale des phénomènes de fraude.

Enfin, la mise en place de dispositifs de mutualisation inter-assureurs constituerait un levier particu-

lièrement puissant. Le partage d'informations, dans un cadre réglementaire adapté, permettrait de disposer d'un historique multi-compagnies et de détecter des comportements frauduleux dits « nomades », consistant pour un individu à reproduire des schémas de fraude auprès de différents assureurs. Une telle mutualisation renforcerait significativement la capacité de détection, en élargissant le périmètre d'observation et en limitant les angles morts propres à chaque compagnie.




FIGURE 7.3 – Couplage de sources de données pour la création de l'Agent de détection de fraude

Ainsi, l'intégration de ces différentes sources de données permettrait de faire évoluer les modèles vers une approche plus globale, dynamique et contextualisée du risque de fraude, améliorant à la fois leur précision, leur robustesse et leur capacité à détecter des schémas complexes.

7.4 Mutualisation inter-assureurs et détection des fraudes organisées

Outre l'ajout de données externes, une piste d'amélioration majeure réside dans la **mutualisation des données et des outils entre assureurs**. En effet, les fraudes organisées reposent souvent sur des schémas répétés et peuvent concerner plusieurs compagnies. Un fraudeur détecté chez un assureur est susceptible de reproduire des comportements similaires auprès d'autres acteurs du marché.¹

1. <https://www.ccomptes.fr/fr/publications/la-fraude-aux-cartes-grises>

Le partage d'informations, dans un cadre réglementaire maîtrisé, permettrait d'améliorer les **taux de détection des fraudes en bande organisée**, en identifiant plus rapidement des schémas récurrents et des profils à risque. Un agent IA alimenté par une base mutualisée bénéficierait ainsi d'une **vision élargie**, renforçant significativement son efficacité.

Un cas emblématique de fraude automobile organisée en France concerne le détournement du système d'immatriculation des véhicules (SIV), mis en place en 2017. Des réseaux ont exploité la possibilité, offerte aux professionnels habilités de réaliser des démarches administratives, en créant des « garages fictifs » servant de sociétés écrans. Ces structures ont permis l'immatriculation massive de véhicules frauduleux, facilitant notamment la réintroduction de véhicules volés dans le circuit légal et la dissimulation de leur traçabilité.

Selon plusieurs enquêtes de presse et sources sectorielles, cette fraude concernerait jusqu'à un million de véhicules et représenterait plus de 500 millions d'euros de pertes. Certains cas individuels font état de plusieurs milliers de véhicules immatriculés frauduleusement via une seule entité.

Ce type de fraude peut être qualifié de fraude en bande organisée dans la mesure où il repose sur une coordination de plusieurs acteurs aux rôles complémentaires : création de sociétés fictives, obtention d'habilitations administratives, production de documents frauduleux et utilisation répétée du dispositif à grande échelle. La structuration du schéma, son caractère durable dans le temps ainsi que les volumes traités témoignent d'une organisation planifiée et non d'initiatives individuelles isolées.

Bien que cette fraude ne cible pas directement un assureur en particulier, elle a des répercussions significatives sur l'ensemble du secteur de l'assurance automobile, en complexifiant la gestion des sinistres et en facilitant des fraudes secondaires. Ce type de schéma illustre le caractère structuré et organisé des fraudes de grande ampleur dans le domaine automobile.²

7.5 Extension à une approche multi-produits

Enfin, l'approche développée pourrait être étendue à une analyse transverse des comportements de fraude tous produits confondus. En effet, un individu impliqué dans une fraude en assurance automobile peut présenter un risque accru de fraude sur d'autres lignes de produits, telles que l'assurance habitation (MRH).

Une vision consolidée du client à travers l'ensemble des garanties permettrait de mieux capter ces comportements et d'améliorer la cohérence globale de la détection.

Cette approche multi-produits s'inscrit dans une logique actuarielle de **vision client 360°**, encore peu exploitée mais porteuse de gains significatifs en matière de lutte contre la fraude.

2. Sources : <https://questions.assemblee-nationale.fr/q17/17-4793QE.htm>; <https://www.senat.fr/questions/base/2025/qSEQ250102893.html>



Conclusion

Annexes

Méthodes de classification

Le clustering par K-means : regroupement autour de centres mobiles

Principe

Le clustering est une méthode statistique de division d'un ensemble de données en groupes homogènes. L'homogénéité n'a pas de sens en elle-même : elle se définit par un critère de proximité, lequel suppose d'avoir introduit au préalable une mesure de distance entre les observations. De nombreux algorithmes conduisent à une partition des données ; celui des K-means est l'un des plus répandus et convient notamment au découpage d'une variable quantitative continue.

Son principe est itératif. On part d'une partition aléatoire de l'ensemble des observations en K classes, puis on reforme pas à pas ces K classes de manière à ce qu'elles contiennent des individus de plus en plus proches les uns des autres. L'algorithme s'arrête lorsque la partition n'évolue plus.

Cadre et notations

Considérons un ensemble fini E de n individus décrits par p caractéristiques quantitatives. Dès que p dépasse 2, la représentation des individus ne tient plus dans un repère simple : on raisonne sur un nuage de n points de $\mathbb{R}^p$, chaque individu étant représenté par un vecteur x_i .

Les variables ne sont pas nécessairement exprimées dans la même unité, ni du même ordre de grandeur. Sans précaution, celles dont l'échelle est la plus large domineraient entièrement le calcul des distances. Elles sont donc centrées et réduites au préalable, chaque variable étant transformée selon :

$$x_i^j \longrightarrow \frac{x_i^j - \bar{x}_j}{\sigma_j} \quad (7.1)$$

Où $\bar{x}_j$ désigne la moyenne de la j -ième variable et σ_j son écart-type. Chaque variable pèse alors le même poids dans la mesure de proximité. L'objectif est de répartir les n individus en K classes homogènes.

La notion de distance

Une distance sur un ensemble E est une application d définie sur le produit $E^2 = E \times E$ et à valeurs dans l'ensemble $\mathbb{R}^+$ des réels positifs, qui vérifie les trois propriétés suivantes :

- **symétrie** : $d(x, y) = d(y, x)$ pour tout couple d'éléments ;
- **séparation** : $d(x, y) = 0$ si et seulement si $x = y$;
- **inégalité triangulaire** : $d(x, z) \leq d(x, y) + d(y, z)$ pour tout triplet d'éléments.

Deux distances sont d'usage courant. La distance euclidienne :

$$d(x, y) = \sqrt{\sum_{j=1}^p (x^j - y^j)^2} \quad (7.2)$$

Et la distance de Manhattan :

$$d(x, y) = \sum_{j=1}^p |x^j - y^j| \quad (7.3)$$

Le choix de la distance n'est pas neutre : la distance euclidienne, qui élève les écarts au carré, accorde plus de poids aux observations éloignées que la distance de Manhattan. Dans le cas particulier d'une variable unique, les deux se confondent avec l'écart absolu entre les valeurs.

Inertie et critère de classification

L'inertie d'un nuage de n points est la moyenne des carrés des distances de ces points à leur centre de gravité, noté g . L'inertie totale s'écrit :

$$I_T = \frac{1}{n} \sum_{i=1}^n d^2(x_i, g) \quad \text{avec} \quad g = \frac{1}{n} \sum_{i=1}^n x_i \quad (7.4)$$

Pour un ensemble de points donné, cette quantité est une constante : elle ne dépend pas de la partition retenue. C'est précisément ce qui en fait une référence pour juger de la qualité d'une classification.

Une classe (ou cluster) k est un ensemble non vide d'observations, noté $\pi_k = \{i \mid x_i \text{ appartient à la classe } k\}$. Son effectif est $n_k = \text{Card } \pi_k$, et son centre de gravité :

$$g_k = \frac{1}{n_k} \sum_{i \in \pi_k} x_i \quad (7.5)$$

L'inertie de cette classe mesure sa dispersion interne :

$$I_k = \frac{1}{n_k} \sum_{i \in \pi_k} d^2(x_i, g_k) \quad (7.6)$$

Une classe est d'autant plus homogène que ses éléments sont proches de son centre de gravité, c'est-à-dire que son inertie est faible.

La mesure globale de l'homogénéité des classes est la moyenne des inerties des K classes, chacune pondérée par son poids relatif. On l'appelle inertie intra-classes, d'où le symbole W (pour *within*) :

$$I_W = \sum_{k=1}^K \frac{n_k}{n} I_k = \frac{1}{n} \sum_{k=1}^K \sum_{i \in \pi_k} d^2(x_i, g_k) \quad (7.7)$$

Symétriquement, l'inertie du nuage des K centres de gravité mesure la séparation des classes. On l'appelle inertie inter-classes, d'où le symbole B (pour *between*) :

$$I_B = \sum_{k=1}^K \frac{n_k}{n} d^2(g_k, g) \quad (7.8)$$

Le théorème de Huygens relie ces trois quantités :

$$I_T = I_W + I_B \quad (7.9)$$

L'inertie totale étant constante, minimiser l'inertie intra-classes et maximiser l'inertie inter-classes sont deux formulations du même problème : chercher des classes à la fois homogènes en leur sein et bien séparées les unes des autres. Le critère de classification retenu est donc celui qui rend l'inertie intra-classes minimale. Ce problème n'admet pas de solution analytique et se résout par itérations successives.

L'algorithme

À chaque étape de l'algorithme, chaque individu porte un numéro de classe compris entre 1 et K . Notons $L_t^{(i)}$ le numéro de la classe de l'individu x_i à l'issue de l'étape t , et g_k^t le centre de gravité de la classe k à cette même étape.

Étape 1 — Initialisation. K centres de gravité g_k^0 sont tirés aléatoirement, puis chaque individu est affecté à la classe dont le centre est le plus proche :

$$L_0^{(i)} = n \quad \text{tel que} \quad d(x_i, g_n^0) = \min_{k \in \llbracket 1; K \rrbracket} \{d(x_i, g_k^0)\} \quad (7.10)$$

À l'issue de cette première étape, K groupes sont constitués, mais de façon purement arbitraire : ils contiennent des individus qui ne se ressemblent pas. Les étapes suivantes vont progressivement attirer vers un même centre les individus semblables.

Étape 2 — Réaffectation. Les barycentres des classes obtenues à l'étape précédente sont recalculés,

puis chaque observation est réaffectée au barycentre dont elle est la plus proche. De nouvelles classes se forment :

$$L_t^{(i)} = n \quad \text{tel que} \quad d(x_i, g_n^t) = \min_{k \in \llbracket 1; K \rrbracket} \{d(x_i, g_k^t)\} \quad (7.11)$$

Étape 3 — Itération. L'étape 2 est renouvelée jusqu'à l'obtention d'un critère de classification stable, c'est-à-dire jusqu'à ce que plus aucune observation ne change de classe d'une itération à la suivante.

Remarque — dépendance à l'initialisation

Le processus de classification est simple, mais la partition finale dépend de la partition aléatoire initiale : l'algorithme converge vers un minimum local de l'inertie intra-classes, et non nécessairement vers le minimum global. Il convient donc de relancer l'algorithme un nombre suffisant de fois, à partir de tirages initiaux différents, et de retenir la meilleure partition obtenue. C'est à cette condition seulement que la classification choisie peut être jugée robuste.

Le choix du nombre de classes

Le nombre de classes K n'est pas déterminé par l'algorithme : il doit être fixé en entrée. Pour perdre le moins d'information possible, on le choisit de sorte que le rapport de la variance inter-classes à la variance totale atteigne un seuil élevé, fixé par exemple à 95 % :

$$\frac{\text{variance inter-classes}}{\text{variance totale}} > 95 \% \quad (7.12)$$

Ce rapport croît mécaniquement avec K — il vaut 1 lorsque chaque observation forme sa propre classe — de sorte que le seuil retenu arbitre entre finesse de la partition et parcimonie. En pratique, on retient le plus petit nombre de classes satisfaisant le seuil.

Remarque — exploitabilité de la partition obtenue

Les classes issues de l'algorithme ne sont pas toujours utilisables telles quelles. Le cas le plus fréquent est celui de classes d'effectifs très hétérogènes, certaines étant trop peu peuplées pour qu'un paramètre puisse y être estimé de façon fiable. Il est alors nécessaire de procéder à des regroupements complémentaires, propres à la problématique étudiée, pour rendre la partition exploitable — au prix d'un écart au critère d'inertie initialement optimisé.

La Classification Hiérarchique Ascendante

Principe

Lorsqu'une population décrite par des variables quantitatives doit être partitionnée en sous-populations relativement homogènes, une seconde approche consiste à procéder par agrégations successives. On part des individus pris un à un et l'on regroupe les plus semblables ; une fois les premiers regroupements

effectués, l'opération est renouvelée sur les classes ainsi formées, de manière à constituer des classes de classes, jusqu'à obtenir à l'extrême une unique classe réunissant l'ensemble de la population.

La proximité, entre individus comme entre classes déjà formées, est mesurée par une distance. Cette construction ascendante, qui remonte jusqu'à un groupe unique, porte le nom de Classification Hiérarchique Ascendante (CAH). Elle produit non pas une partition, mais une hiérarchie de partitions emboîtées, à l'image d'un système d'appartenances successives : un astre appartient à un système, qui appartient à un amas, lui-même inclus dans une galaxie, et ainsi de suite jusqu'à l'univers entier.

À chaque étape de l'agrégation, de l'information est perdue, puisque des éléments jusque-là distincts deviennent indiscernables ; mais l'on sait en contrepartie que les éléments réunis dans une même classe sont relativement proches les uns des autres.

L'algorithme

Première étape — Préparation des données. Mesurer une distance entre individus suppose des données numériques et comparables entre elles. Deux traitements sont donc appliqués au préalable :

- les variables qualitatives sont rendues quantitatives. La technique usuelle consiste à créer, pour chaque modalité existante, une variable indicatrice valant 1 en cas de présence de la modalité et 0 en cas d'absence ;
- les variables sont centrées et réduites, en retranchant la moyenne de la variable considérée et en divisant par son écart-type, afin que chacune pèse le même poids dans le calcul des distances.

Deuxième étape — Application de l'algorithme.

Initialisation. Les classes initiales sont les n singletons, chaque individu constituant sa propre classe. La matrice des distances deux à deux entre ces n classes est calculée.

Regroupement. Les deux classes les plus proches, au sens de la distance entre groupes retenue, sont réunies. Le tableau des distances est mis à jour : les deux classes fusionnées y sont remplacées par la classe nouvellement formée, dont la distance à chacune des autres classes est recalculée.

Itération. Les deux opérations précédentes sont répétées jusqu'à l'agrégation de l'ensemble des observations en une classe unique.

L'algorithme effectue ainsi $n - 1$ regroupements, chacun correspondant à un niveau de la hiérarchie. Aucun choix de nombre de classes n'intervient pendant son déroulement : contrairement aux K-means, la décision est reportée à la lecture du résultat.

Le choix d'une distance entre classes : la méthode de Ward

La CAH suppose de définir une distance non pas entre individus, mais entre groupes d'individus. Ce choix est appelé stratégie d'agrégation, et il détermine entièrement la forme de la hiérarchie obtenue.

La méthode de Ward est la plus courante. Elle consiste à réunir, à chaque étape, les deux classes dont le

regroupement fera le moins baisser l'inertie inter-classes. La distance de Ward entre deux classes A et B est définie comme le carré de la distance entre leurs centres de gravité, pondéré par les effectifs des deux classes :

$$\Delta(A, B) = \frac{n_A \times n_B}{n_A + n_B} \times d^2(g_A, g_B) \quad (7.13)$$

où :

- n_A et n_B désignent les effectifs des classes A et B ;
- g_A et g_B leurs centres de gravité respectifs ;
- d la distance euclidienne, dont l'existence entre observations est ici supposée.

La pondération par les effectifs a une conséquence pratique notable : à distance égale entre centres de gravité, deux petites classes sont réunies avant deux grandes. La méthode de Ward tend donc à regrouper les petites classes entre elles, et produit des hiérarchies relativement équilibrées.

Remarque — lien avec la décomposition de l'inertie

Lorsque deux classes sont remplacées par leur réunion, la diminution de l'inertie inter-classes — et donc, par le théorème de Huygens, l'augmentation de l'inertie intra-classes — est exactement égale à la distance de Ward entre ces deux classes. La méthode de Ward revient ainsi à choisir, à chaque étape, le regroupement qui dégrade le moins l'homogénéité interne des classes. C'est le même critère d'inertie que celui des K-means, appliqué de façon séquentielle et non plus globale.

La représentation : l'arbre de classification

La notion de hiérarchie s'appréhende aisément par une représentation visuelle appelée arbre de classification, ou dendrogramme. Il s'agit d'un arbre binaire représentant les agrégations successives, depuis les individus isolés jusqu'à la réunion de tous en une classe unique.

La hauteur d'une branche y est proportionnelle à la distance entre les deux objets regroupés. Dans le cas du saut de Ward, elle est donc proportionnelle à la perte d'inertie inter-classes occasionnée par le regroupement : une branche haute signale la réunion de deux classes qui se ressemblaient peu.

Le choix du nombre de classes

Le nombre de classes à retenir revient à couper l'arbre à une certaine hauteur. Cette partition doit d'abord être définie en accord avec les objectifs de l'étude ; l'arbre fournit ensuite un critère de lecture.

À chaque agrégation, la distance entre les groupes réunis diminue, et cette décroissance est directement lisible sur le dendrogramme. La meilleure partition est généralement celle qui précède une valeur de la distance inter-classes brutalement plus faible : au-delà de ce point, les regroupements suivants ne

réunissent plus que des classes déjà très semblables et n'apportent donc plus d'information. Une forte perte d'inertie inter-classes observée au passage de k à $k - 1$ classes conduit ainsi à retenir k classes.

Remarque — effectifs et pertinence des classes

Comme pour les K-means, les classes obtenues peuvent présenter des effectifs hétérogènes, voire insuffisants au regard des seuils habituellement retenus. Le réflexe de les regrouper n'est toutefois pas systématique : lorsque la faiblesse d'un effectif traduit un écart réel et durable de comportement — une modalité rare mais nettement plus risquée que les autres, par exemple — la fusionner avec une classe voisine ferait disparaître l'information même que la classification avait mise en évidence. L'arbitrage entre robustesse statistique et finesse de la segmentation relève alors du jugement, non de l'algorithme.

Chapitre 4



Analyse détaillée des variables (sortie complète de l’agent)

Analyse de la qualité des données de la base

Description de chaque colonne du fichier CSV — types, modalités, taux de remplissage et saisie obligatoire d’une valeur unique pour chaque variable contenant des cases vides avant de lancer les analyses suivantes.

VARIABLES
54

COMPLÈTEMENT RENSEIGNÉES
54

AVEC VALEURS MANQUANTES
0

VALEURS ABERRANTES
0

Rechercher une variable...

TousBoolean (Vrai/Faux)DateEntierTexte (Alphanumérique)

54 / 54 variables affichées

VARIABLE	TRADUCTION FR	TYPE ATTENDU	TYPE DÉTECTÉ	MODALITÉS / PLAGE	REMPLISSAGE	VALEURS MANQUANTES	INCLURE
policy_id	Identifiant du contrat / de la police	Texte ou Entier (Alphanumérique)	Texte (Alphanumérique)	30000 valeurs distinctes (ex: POL100000 POL100001 POL100002 POL100003 POL100004...)	100%	Non nécessaire	☐
policy_state	État de souscription du contrat (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX	100%	Non nécessaire	☒
policy_deductible	Franchise du contrat	Catégorie ordonnée (montant de franchise)	Entier	200 300 400 500 600 700 800 1000	100%	Non nécessaire	☒
policy_annual_premium	Prime annuelle d'assurance	Nombre (Décimal)	Texte (Alphanumérique)	25489 valeurs distinctes (ex: 1000.02 1000.04 1000.05 1000.13 1000.15...)	100%	Non nécessaire	☒
insured_age	Âge de l'assuré	Entier	Entier	[18 ; 75]	100%	Non nécessaire	☒
insured_sex	Sexe de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	FEMALE MALE OTHER	100%	Non nécessaire	☒
insured_education_level	Niveau d'études de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	College High School Masters PhD	100%	Non nécessaire	☒
insured_occupation	Profession de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	Clerk Doctor Engineer Lawyer Manager Sales Teacher Technician	100%	Non nécessaire	☒
insured_hobbies	Loisirs de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	camping chess hiking movies paintball reading yachting	100%	Non nécessaire	☒
incident_date	Date de l'incident / sinistre	Date	Date	01/01/2024 – 31/12/2024	100%	Non nécessaire	☒
incident_type	Type d'incident	Texte (Catégorique)	Texte (Alphanumérique)	Multi-vehicle Collision Parked Car Single Vehicle Collision Vehicle Theft	100%	Non nécessaire	☒
collision_type	Type de collision	Texte (Catégorique)	Texte (Alphanumérique)	Front Rear Side Unknown	100%	Non nécessaire	☒
incident_severity	Gravité de l'incident	Texte (Catégorique)	Texte (Alphanumérique)	Major Damage Minor Damage Total Loss	100%	Non nécessaire	☒
authorities_contacted	Autorités contactées (ex: Police, Pompier)	Texte (Catégorique)	Texte (Alphanumérique)	Ambulance Aucun Fire Police	100%	Non nécessaire	☒
incident_state	État où s'est produit l'incident (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX	100%	Non nécessaire	☒
incident_city	Ville où s'est produit l'incident	Texte (Catégorique)	Texte (Alphanumérique)	17931 valeurs distinctes (ex: Aaronberg Aaronborough Aaronburgh Aaronfort Aaronfurt...)	100%	Non nécessaire	☒
incident_hour_of_the_day	Heure de l'incident (0 à 23)	Entier	Entier	[0 ; 23]	100%	Non nécessaire	☒
number_of_vehicles_involved	Nombre de véhicules impliqués	Entier	Entier	[1 ; 4]	100%	Non nécessaire	☒
bodily_injuries	Nombre de blessés / Dommages corporels	Entier	Entier	[0 ; 4]	100%	Non nécessaire	☒
witnesses	Nombre de témoins	Entier	Entier	[0 ; 5]	100%	Non nécessaire	☒
police_report_available	Rapport de police disponible (Oui/Non)	Texte ou Boolean (Vrai/Faux)	Boolean (Vrai/Faux)	No Yes	100%	Non nécessaire	☒
claim_amount	Montant réclamé pour les dommages	Nombre (Décimal)	Texte (Alphanumérique)	29779 valeurs distinctes (ex: 10000.08 10000.78 10001.09 10001.29 10001.42...)	100%	Non nécessaire	☒
total_claim_amount	Montant total de la réclamation	Nombre (Décimal)	Texte (Alphanumérique)	29824 valeurs distinctes (ex: 1000.82 10000.12 10001.04 10001.44 10001.61...)	100%	Non nécessaire	☒
fraud_reported	Fraude avérée / signalée (Oui/Non)	Texte ou Boolean (Vrai/Faux)	Boolean (Vrai/Faux)	N Y	100%	Non nécessaire	☒
insured_id	Identifiant de l'assuré	Texte (Alphanumérique)	Texte (Alphanumérique)	25544 valeurs distinctes (ex: INS000001 INS000002 INS000003 INS000005 INS000006...)	100%	Non nécessaire	☒
insured_nb_past_claims	Nb sinistres passés (assuré)	Entier	Entier	[0 ; 5]	100%	Non nécessaire	☒
insured_nb_past_fraud	Nb fraudes passées (assuré)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	☒
insured_days_since_last_claim	Jours depuis le dernier sinistre	Entier	Entier	[0 ; 2799]	100%	Non nécessaire	☒
insured_claim_amount_history	Historique montants réclamés (assuré)	Nombre (Décimal)	Texte (Alphanumérique)	29886 valeurs distinctes (ex: 0.32 1.45 10.21 10.6 10.74...)	100%	Non nécessaire	☒
policy_age_at_incident_days	Ancienneté du contrat à l'incident (jours)	Entier	Entier	[0 ; 3599]	100%	Non nécessaire	☒
insured_nb_policies_active	Nb de polices actives (assuré)	Entier	Entier	[1 ; 4]	100%	Non nécessaire	☒
insured_address_changes_12m	Changements d'adresse (12 mois)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	☒
repairer_id	Identifiant du réparateur / garage	Texte (Alphanumérique)	Texte (Alphanumérique)	900 valeurs distinctes (ex: GAR0001 GAR0002 GAR0003 GAR0004 GAR0005...)	100%	Non nécessaire	☒
repairer_nb_claims_total	Nb total sinistres (réparateur)	Entier	Entier	[0 ; 197]	100%	Non nécessaire	☒
repairer_nb_fraud_confirmed	Nb fraudes confirmées (réparateur)	Entier	Entier	[0 ; 87]	100%	Non nécessaire	☒
repairer_avg_invoice_vs_market	Ratio facture / marché (réparateur)	Nombre (Décimal)	Texte (Alphanumérique)	300 valeurs distinctes (ex: 0.87 0.871 0.872 0.873 0.874...)	100%	Non nécessaire	☒



VARIABLE	TRADUCTION FR	TYPE ATTENDU	TYPE DÉTECTÉ	MODALITÉS / PLAGE	REMPLISSAGE	VALEURS MANQUANTES	INCLURE
policy_id	Identifiant du contrat / de la police	Texte ou Entier (Alphanumérique)	Texte (Alphanumérique)	30000 valeurs distinctes (ex: POL100000 POL100001 POL100002 POL100003 POL100004...)	100%	Non nécessaire	☐
policy_state	État de souscription du contrat (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX	100%	Non nécessaire	☒
policy_deductible	Franchise du contrat	Catégorie ordonnée (montant de franchise)	Entier	200 300 400 500 600 700 800 1000	100%	Non nécessaire	☒
policy_annual_premium	Prime annuelle d'assurance	Nombre (Décimal)	Texte (Alphanumérique)	25469 valeurs distinctes (ex: 1000.02 1000.04 1000.05 1000.13 1000.15...)	100%	Non nécessaire	☒
insured_age	Âge de l'assuré	Entier	Entier	[18 ; 75]	100%	Non nécessaire	☒
insured_sex	Sexe de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	FEMALE MALE OTHER	100%	Non nécessaire	☒
insured_education_level	Niveau d'études de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	College High School Masters PhD	100%	Non nécessaire	☒
insured_occupation	Profession de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	Clerk Doctor Engineer Lawyer Manager Sales Teacher Technician	100%	Non nécessaire	☒
insured_hobbies	Loisirs de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	camping chess hiking movies paintball reading yachting	100%	Non nécessaire	☒
incident_date	Date de l'incident / sinistre	Date	Date	01/01/2024 – 31/12/2024	100%	Non nécessaire	☒
incident_type	Type d'incident	Texte (Catégorique)	Texte (Alphanumérique)	Multi-vehicle Collision Parked Car Single Vehicle Collision Vehicle Theft	100%	Non nécessaire	☒
collision_type	Type de collision	Texte (Catégorique)	Texte (Alphanumérique)	Front Rear Side Unknown	100%	Non nécessaire	☒
incident_severity	Gravité de l'incident	Texte (Catégorique)	Texte (Alphanumérique)	Major Damage Minor Damage Total Loss	100%	Non nécessaire	☒
authorities_contacted	Autorités contactées (ex: Police, Pompier)	Texte (Catégorique)	Texte (Alphanumérique)	Ambulance Aucion Fire Police	100%	Non nécessaire	☒
incident_state	État où s'est produit l'incident (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX	100%	Non nécessaire	☒
incident_city	Ville où s'est produit l'incident	Texte (Catégorique)	Texte (Alphanumérique)	17931 valeurs distinctes (ex: Aaronberg Aaronborough Aaronburgh Aaronfort Aaronfurt...)	100%	Non nécessaire	☒
incident_hour_of_the_day	Heure de l'incident (0 à 23)	Entier	Entier	[0 ; 23]	100%	Non nécessaire	☒
number_of_vehicles_involved	Nombre de véhicules impliqués	Entier	Entier	[1 ; 4]	100%	Non nécessaire	☒
bodily_injuries	Nombre de blessés / Dommages corporels	Entier	Entier	[0 ; 4]	100%	Non nécessaire	☒
witnesses	Nombre de témoins	Entier	Entier	[0 ; 5]	100%	Non nécessaire	☒
police_report_available	Rapport de police disponible (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	No Yes	100%	Non nécessaire	☒
claim_amount	Montant réclamé pour les dommages	Nombre (Décimal)	Texte (Alphanumérique)	29779 valeurs distinctes (ex: 10000.08 10000.78 10001.09 10001.29 10001.42...)	100%	Non nécessaire	☒
total_claim_amount	Montant total de la réclamation	Nombre (Décimal)	Texte (Alphanumérique)	29824 valeurs distinctes (ex: 1000.82 1000.12 10001.04 10001.44 10001.61...)	100%	Non nécessaire	☒
fraud_reported	Fraude avérée / signalée (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	N Y	100%	Non nécessaire	☒
insured_id	Identifiant de l'assuré	Texte (Alphanumérique)	Texte (Alphanumérique)	25544 valeurs distinctes (ex: INS000001 INS000002 INS000003 INS000005 INS000006...)	100%	Non nécessaire	☒
insured_nb_past_claims	Nb sinistres passés (assuré)	Entier	Entier	[0 ; 5]	100%	Non nécessaire	☒
insured_nb_past_fraud	Nb fraudes passées (assuré)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	☒
insured_days_since_last_claim	Jours depuis le dernier sinistre	Entier	Entier	[60 ; 2799]	100%	Non nécessaire	☒
insured_claim_amount_history	Historique montants réclamés (assuré)	Nombre (Décimal)	Texte (Alphanumérique)	29886 valeurs distinctes (ex: 0.32 1.45 10.21 10.6 10.74...)	100%	Non nécessaire	☒
policy_age_at_incident_days	Ancienneté du contrat à l'incident (jours)	Entier	Entier	[30 ; 3599]	100%	Non nécessaire	☒
insured_nb_policies_active	Nb de polices actives (assuré)	Entier	Entier	[1 ; 4]	100%	Non nécessaire	☒
insured_address_changes_12m	Changements d'adresse (12 mois)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	☒
repairer_id	Identifiant du réparateur / garage	Texte (Alphanumérique)	Texte (Alphanumérique)	900 valeurs distinctes (ex: GAR0001 GAR0002 GAR0003 GAR0004 GAR0005...)	100%	Non nécessaire	☒
repairer_nb_claims_total	Nb total sinistres (réparateur)	Entier	Entier	[0 ; 197]	100%	Non nécessaire	☒
repairer_nb_fraud_confirmed	Nb fraudes confirmées (réparateur)	Entier	Entier	[0 ; 87]	100%	Non nécessaire	☒
repairer_avg_invoice_vs_market	Ratio facture / marché (réparateur)	Nombre (Décimal)	Texte (Alphanumérique)	300 valeurs distinctes (ex: 0.87 0.871 0.872 0.873 0.874...)	100%	Non nécessaire	☒
repairer_is_flagged	Réparateur signalé (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	☒
third_party_id	Identifiant du tiers impliqué	Texte (Alphanumérique)	Texte (Alphanumérique)	7802 valeurs distinctes (ex: NONE TRS00001 TRS00002 TRS00003 TRS00005...)	100%	Non nécessaire	☒
third_party_nb_past_incidents	Nb incidents passés (tiers)	Entier	Entier	[0 ; 4]	100%	Non nécessaire	☒
witness_id	Identifiant du témoin	Texte (Alphanumérique)	Texte (Alphanumérique)	10514 valeurs distinctes (ex: NONE WIT00001 WIT00004 WIT00005 WIT00007...)	100%	Non nécessaire	☒
insured_third_party_known	Tiers connu de l'assuré (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	☒
vehicle_id	Identifiant du véhicule	Texte (Alphanumérique)	Texte (Alphanumérique)	18069 valeurs distinctes (ex: VEH000005 VEH000010 VEH000011 VEH000018 VEH000019...)	100%	Non nécessaire	☒




franchise							
policy_annual_premium	Prime annuelle d'assurance	Nombre (Décimal)	Texte (Alphanumérique)	25489 valeurs distinctes (ex: 1000,02 1000,04 1000,05 1000,13 1000,15...)	100%	Non nécessaire	✓
insured_age	Âge de l'assuré	Entier	Entier	[18 ; 75]	100%	Non nécessaire	✓
insured_sex	Sexe de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	FEMALE MALE OTHER	100%	Non nécessaire	✓
insured_education_level	Niveau d'études de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	College High School Masters PhD	100%	Non nécessaire	✓
insured_occupation	Profession de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	Clerk Doctor Engineer Lawyer Manager Sales Teacher Technician	100%	Non nécessaire	✓
insured_hobbies	Loisirs de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	camping chess hiking movies paintball reading yachting	100%	Non nécessaire	✓
incident_date	Date de l'incident / sinistre	Date	Date	01/01/2024 – 31/12/2024	100%	Non nécessaire	✓
incident_type	Type d'incident	Texte (Catégorique)	Texte (Alphanumérique)	Multi-vehicle Collision Parked Car Single Vehicle Collision Vehicle Theft	100%	Non nécessaire	✓
collision_type	Type de collision	Texte (Catégorique)	Texte (Alphanumérique)	Front Rear Side Unknown	100%	Non nécessaire	✓
incident_severity	Gravité de l'incident	Texte (Catégorique)	Texte (Alphanumérique)	Major Damage Minor Damage Total Loss	100%	Non nécessaire	✓
authorities_contacted	Autorités contactées (ex: Police, Pompier)	Texte (Catégorique)	Texte (Alphanumérique)	Ambulance Aucion Fire Police	100%	Non nécessaire	✓
incident_state	État où s'est produit l'incident (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX	100%	Non nécessaire	✓
incident_city	Ville où s'est produit l'incident	Texte (Catégorique)	Texte (Alphanumérique)	17931 valeurs distinctes (ex: Aaronberg Aaronborough Aaronburgh Aaronfort Aaronfurt...)	100%	Non nécessaire	✓
incident_hour_of_the_day	Heure de l'incident (0 à 23)	Entier	Entier	[0 ; 23]	100%	Non nécessaire	✓
number_of_vehicles_involved	Nombre de véhicules impliqués	Entier	Entier	[1 ; 4]	100%	Non nécessaire	✓
bodily_injuries	Nombre de blessés / Dommages corporels	Entier	Entier	[0 ; 4]	100%	Non nécessaire	✓
witnesses	Nombre de témoins	Entier	Entier	[0 ; 5]	100%	Non nécessaire	✓
police_report_available	Rapport de police disponible (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	No Yes	100%	Non nécessaire	✓
claim_amount	Montant réclamé pour les dommages	Nombre (Décimal)	Texte (Alphanumérique)	29779 valeurs distinctes (ex: 10000,08 10000,78 10001,09 10001,29 10001,42...)	100%	Non nécessaire	✓
total_claim_amount	Montant total de la réclamation	Nombre (Décimal)	Texte (Alphanumérique)	29824 valeurs distinctes (ex: 1000,82 10000,12 10001,04 10001,44 10001,61...)	100%	Non nécessaire	✓
fraud_reported	Fraude avérée / signalée (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	N Y	100%	Non nécessaire	✓
insured_id	Identifiant de l'assuré	Texte (Alphanumérique)	Texte (Alphanumérique)	25544 valeurs distinctes (ex: INS000001 INS000002 INS000003 INS000005 INS000006...)	100%	Non nécessaire	✓
insured_nb_past_claims	Nb sinistres passés (assuré)	Entier	Entier	[0 ; 5]	100%	Non nécessaire	✓
insured_nb_past_fraud	Nb fraudes passées (assuré)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	✓
insured_days_since_last_claim	Jours depuis le dernier sinistre	Entier	Entier	[60 ; 2799]	100%	Non nécessaire	✓
insured_claim_amount_history	Historique montants réclamés (assuré)	Nombre (Décimal)	Texte (Alphanumérique)	29886 valeurs distinctes (ex: 0,32 1,45 10,21 10,6 10,74...)	100%	Non nécessaire	✓
policy_age_at_incident_days	Ancienneté du contrat à l'incident (jours)	Entier	Entier	[30 ; 3599]	100%	Non nécessaire	✓
insured_nb_policies_active	Nb de polices actives (assuré)	Entier	Entier	[1 ; 4]	100%	Non nécessaire	✓
insured_address_changes_12m	Changements d'adresse (12 mois)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	✓
repairer_id	Identifiant du réparateur / garage	Texte (Alphanumérique)	Texte (Alphanumérique)	900 valeurs distinctes (ex: GAR0001 GAR0002 GAR0003 GAR0004 GAR0005...)	100%	Non nécessaire	✓
repairer_nb_claims_total	Nb total sinistres (réparateur)	Entier	Entier	[0 ; 197]	100%	Non nécessaire	✓
repairer_nb_fraud_confirmed	Nb fraudes confirmées (réparateur)	Entier	Entier	[0 ; 87]	100%	Non nécessaire	✓
repairer_avg_invoice_vs_market	Ratio facture / marché (réparateur)	Nombre (Décimal)	Texte (Alphanumérique)	300 valeurs distinctes (ex: 0,87 0,871 0,872 0,873 0,874...)	100%	Non nécessaire	✓
repairer_is_flagged	Réparateur signalé (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
third_party_id	Identifiant du tiers impliqué	Texte (Alphanumérique)	Texte (Alphanumérique)	7802 valeurs distinctes (ex: NONE TRS00001 TRS00002 TRS00003 TRS00005...)	100%	Non nécessaire	✓
third_party_nb_past_incidents	Nb incidents passés (tiers)	Entier	Entier	[0 ; 4]	100%	Non nécessaire	✓
witness_id	Identifiant du témoin	Texte (Alphanumérique)	Texte (Alphanumérique)	10514 valeurs distinctes (ex: NONE WIT00001 WIT00004 WIT00005 WIT00007...)	100%	Non nécessaire	✓
insured_third_party_known	Tiers connu de l'assuré (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
vehicle_id	Identifiant du véhicule	Texte (Alphanumérique)	Texte (Alphanumérique)	18069 valeurs distinctes (ex: VEH000005 VEH000010 VEH000011 VEH000018 VEH000019...)	100%	Non nécessaire	✓
vehicle_age_years	Âge du véhicule (années)	Entier	Entier	[1 ; 21]	100%	Non nécessaire	✓
vehicle_market_value	Valeur marchande du véhicule	Nombre (Décimal)	Texte (Alphanumérique)	29671 valeurs distinctes (ex: 10000,94 10001,36 10001,45 10001,53 10003,82...)	100%	Non nécessaire	✓
vehicle_overvalue_ratio	Ratio surévaluation du véhicule	Nombre (Décimal)	Texte (Alphanumérique)	3479 valeurs distinctes (ex: 0,008 0,009 0,01 0,011 0,012...)	100%	Non nécessaire	✓
vehicle_nb_past_claims	Nb sinistres passés (véhicule)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	✓




insured_occupation	Profession de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	Clerk Doctor Engineer Lawyer Manager Sales Teacher Technician	100%	Non nécessaire	✓
insured_hobbies	Loisirs de l'assuré	Texte (Catégorique)	Texte (Alphanumérique)	camping chess hiking movies paintball reading yachting	100%	Non nécessaire	✓
incident_date	Date de l'incident / sinistre	Date	Date	01/01/2024 – 31/12/2024	100%	Non nécessaire	✓
incident_type	Type d'incident	Texte (Catégorique)	Texte (Alphanumérique)	Multi-vehicle Collision Parked Car Single Vehicle Collision Vehicle Theft	100%	Non nécessaire	✓
collision_type	Type de collision	Texte (Catégorique)	Texte (Alphanumérique)	Front Rear Side Unknown	100%	Non nécessaire	✓
incident_severity	Gravité de l'incident	Texte (Catégorique)	Texte (Alphanumérique)	Major Damage Minor Damage Total Loss	100%	Non nécessaire	✓
authorities_contacted	Autorités contactées (ex: Police, Pompier)	Texte (Catégorique)	Texte (Alphanumérique)	Ambulance Aucun Fire Police	100%	Non nécessaire	✓
incident_state	État où s'est produit l'incident (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX	100%	Non nécessaire	✓
incident_city	Ville où s'est produit l'incident	Texte (Catégorique)	Texte (Alphanumérique)	17931 valeurs distinctes (ex: Aaronberg Aaronborough Aaronburgh Aaronfort Aaronfurt...)	100%	Non nécessaire	✓
incident_hour_of_the_day	Heure de l'incident (0 à 23)	Entier	Entier	[0 : 23]	100%	Non nécessaire	✓
number_of_vehicles_involved	Nombre de véhicules impliqués	Entier	Entier	[1 : 4]	100%	Non nécessaire	✓
bodily_injuries	Nombre de blessés / Dommages corporels	Entier	Entier	[0 : 4]	100%	Non nécessaire	✓
witnesses	Nombre de témoins	Entier	Entier	[0 : 5]	100%	Non nécessaire	✓
police_report_available	Rapport de police disponible (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	No Yes	100%	Non nécessaire	✓
claim_amount	Montant réclamé pour les dommages	Nombre (Décimal)	Texte (Alphanumérique)	29779 valeurs distinctes (ex: 10000.08 10000.78 10001.09 10001.29 10001.42...)	100%	Non nécessaire	✓
total_claim_amount	Montant total de la réclamation	Nombre (Décimal)	Texte (Alphanumérique)	29824 valeurs distinctes (ex: 1000.82 10000.12 10001.04 10001.44 10001.61...)	100%	Non nécessaire	✓
fraud_reported	Fraude avérée / signalée (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	N Y	100%	Non nécessaire	✓
insured_id	Identifiant de l'assuré	Texte (Alphanumérique)	Texte (Alphanumérique)	25544 valeurs distinctes (ex: INS000001 INS000002 INS000003 INS000005 INS000006...)	100%	Non nécessaire	✓
insured_nb_past_claims	Nb sinistres passés (assuré)	Entier	Entier	[0 : 5]	100%	Non nécessaire	✓
insured_nb_past_fraud	Nb fraudes passées (assuré)	Entier	Entier	[0 : 3]	100%	Non nécessaire	✓
insured_days_since_last_claim	Jours depuis le dernier sinistre	Entier	Entier	[60 : 2799]	100%	Non nécessaire	✓
insured_claim_amount_history	Historique montants réclamés (assuré)	Nombre (Décimal)	Texte (Alphanumérique)	29886 valeurs distinctes (ex: 0.32 1.45 10.21 10.6 10.74...)	100%	Non nécessaire	✓
policy_age_at_incident_days	Ancienneté du contrat à l'incident (jours)	Entier	Entier	[30 : 3599]	100%	Non nécessaire	✓
insured_nb_policies_active	Nb de polices actives (assuré)	Entier	Entier	[1 : 4]	100%	Non nécessaire	✓
insured_address_changes_12m	Changements d'adresse (12 mois)	Entier	Entier	[0 : 3]	100%	Non nécessaire	✓
repairer_id	Identifiant du réparateur / garage	Texte (Alphanumérique)	Texte (Alphanumérique)	900 valeurs distinctes (ex: GAR0001 GAR0002 GAR0003 GAR0004 GAR0005...)	100%	Non nécessaire	✓
repairer_nb_claims_total	Nb total sinistres (réparateur)	Entier	Entier	[0 : 197]	100%	Non nécessaire	✓
repairer_nb_fraud_confirmed	Nb fraudes confirmées (réparateur)	Entier	Entier	[0 : 87]	100%	Non nécessaire	✓
repairer_avg_invoice_vs_market	Ratio facture / marché (réparateur)	Nombre (Décimal)	Texte (Alphanumérique)	300 valeurs distinctes (ex: 0.87 0.871 0.872 0.873 0.874...)	100%	Non nécessaire	✓
repairer_is_flagged	Réparateur signalé (0/1)	Booléen (Vrai/Faux)	Entier	[0 : 1]	100%	Non nécessaire	✓
third_party_id	Identifiant du tiers impliqué	Texte (Alphanumérique)	Texte (Alphanumérique)	7802 valeurs distinctes (ex: NONE TRS00001 TRS00002 TRS00003 TRS00005...)	100%	Non nécessaire	✓
third_party_nb_past_incidents	Nb incidents passés (tiers)	Entier	Entier	[0 : 4]	100%	Non nécessaire	✓
witness_id	Identifiant du témoin	Texte (Alphanumérique)	Texte (Alphanumérique)	10514 valeurs distinctes (ex: NONE WIT00001 WIT00004 WIT00005 WIT00007...)	100%	Non nécessaire	✓
insured_third_party_known	Tiers connu de l'assuré (0/1)	Booléen (Vrai/Faux)	Entier	[0 : 1]	100%	Non nécessaire	✓
vehicle_id	Identifiant du véhicule	Texte (Alphanumérique)	Texte (Alphanumérique)	18069 valeurs distinctes (ex: VEH000005 VEH000010 VEH000011 VEH000018 VEH000019...)	100%	Non nécessaire	✓
vehicle_age_years	Âge du véhicule (années)	Entier	Entier	[1 : 21]	100%	Non nécessaire	✓
vehicle_market_value	Valeur marchande du véhicule	Nombre (Décimal)	Texte (Alphanumérique)	29871 valeurs distinctes (ex: 10000.94 10001.36 10001.45 10001.53 10003.82...)	100%	Non nécessaire	✓
vehicle_overvalue_ratio	Ratio surévaluation du véhicule	Nombre (Décimal)	Texte (Alphanumérique)	3479 valeurs distinctes (ex: 0.008 0.009 0.01 0.011 0.012...)	100%	Non nécessaire	✓
vehicle_nb_past_claims	Nb sinistres passés (véhicule)	Entier	Entier	[0 : 3]	100%	Non nécessaire	✓
vehicle_ownership_duration_days	Durée de possession du véhicule (jours)	Entier	Entier	[20 : 3499]	100%	Non nécessaire	✓
time_to_report_days	Délai de déclaration (jours)	Entier	Entier	[0 : 74]	100%	Non nécessaire	✓
nb_amendments_declaration	Nb d'amendements à la déclaration	Entier	Entier	[0 : 4]	100%	Non nécessaire	✓
declaration_channel	Canal de déclaration du sinistre	Texte (Catégorique)	Texte (Alphanumérique)	agence courtier telephone web	100%	Non nécessaire	✓

collision_type	Type de collision	Texte (Catégorique)	Texte (Alphanumérique)	Front Rear Side Unknown	100%	Non nécessaire	✓
incident_severity	Gravité de l'incident	Texte (Catégorique)	Texte (Alphanumérique)	Major Damage Minor Damage Total Loss	100%	Non nécessaire	✓
authorities_contacted	Autorités contactées (ex: Police, Pompier)	Texte (Catégorique)	Texte (Alphanumérique)	Ambulance Aucun Fire Police	100%	Non nécessaire	✓
incident_state	État où s'est produit l'incident (Lieu)	Texte (Catégorique)	Texte (Alphanumérique)	CA FL GA IL MI NC NY OH PA TX	100%	Non nécessaire	✓
incident_city	Ville où s'est produit l'incident	Texte (Catégorique)	Texte (Alphanumérique)	17931 valeurs distinctes (ex: Aaronberg Aaronborough Aaronburgh Aaronfort Aaronfurt...)	100%	Non nécessaire	✓
incident_hour_of_the_day	Heure de l'incident (0 à 23)	Entier	Entier	[0 ; 23]	100%	Non nécessaire	✓
number_of_vehicles_involved	Nombre de véhicules impliqués	Entier	Entier	[1 ; 4]	100%	Non nécessaire	✓
bodily_injuries	Nombre de blessés / Dommages corporels	Entier	Entier	[0 ; 4]	100%	Non nécessaire	✓
witnesses	Nombre de témoins	Entier	Entier	[0 ; 5]	100%	Non nécessaire	✓
police_report_available	Rapport de police disponible (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	No Yes	100%	Non nécessaire	✓
claim_amount	Montant réclamé pour les dommages	Nombre (Décimal)	Texte (Alphanumérique)	29779 valeurs distinctes (ex: 10000,08 10000,78 10001,09 10001,29 10001,42...)	100%	Non nécessaire	✓
total_claim_amount	Montant total de la réclamation	Nombre (Décimal)	Texte (Alphanumérique)	29824 valeurs distinctes (ex: 1000,82 10000,12 10001,04 10001,44 10001,61...)	100%	Non nécessaire	✓
fraud_reported	Fraude avérée / signalée (Oui/Non)	Texte ou Booléen (Vrai/Faux)	Booléen (Vrai/Faux)	N Y	100%	Non nécessaire	✓
insured_id	Identifiant de l'assuré	Texte (Alphanumérique)	Texte (Alphanumérique)	25544 valeurs distinctes (ex: INS000001 INS000002 INS000003 INS000005 INS000006...)	100%	Non nécessaire	✓
insured_nb_past_claims	Nb sinistres passés (assuré)	Entier	Entier	[0 ; 5]	100%	Non nécessaire	✓
insured_nb_past_fraud	Nb fraudes passées (assuré)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	✓
insured_days_since_last_claim	Jours depuis le dernier sinistre	Entier	Entier	[60 ; 2799]	100%	Non nécessaire	✓
insured_claim_amount_history	Historique montants réclamés (assuré)	Nombre (Décimal)	Texte (Alphanumérique)	29886 valeurs distinctes (ex: 0,32 1,45 10,21 10,6 10,74...)	100%	Non nécessaire	✓
policy_age_at_incident_days	Ancienneté du contrat à l'incident (jours)	Entier	Entier	[30 ; 3599]	100%	Non nécessaire	✓
insured_nb_policies_active	Nb de polices actives (assuré)	Entier	Entier	[1 ; 4]	100%	Non nécessaire	✓
insured_address_changes_12m	Changements d'adresse (12 mois)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	✓
repairer_id	Identifiant du réparateur / garage	Texte (Alphanumérique)	Texte (Alphanumérique)	900 valeurs distinctes (ex: GAR0001 GAR0002 GAR0003 GAR0004 GAR0005...)	100%	Non nécessaire	✓
repairer_nb_claims_total	Nb total sinistres (réparateur)	Entier	Entier	[0 ; 197]	100%	Non nécessaire	✓
repairer_nb_fraud_confirmed	Nb fraudes confirmées (réparateur)	Entier	Entier	[0 ; 87]	100%	Non nécessaire	✓
repairer_avg_invoice_vs_market	Ratio facture / marché (réparateur)	Nombre (Décimal)	Texte (Alphanumérique)	300 valeurs distinctes (ex: 0,87 0,871 0,872 0,873 0,874...)	100%	Non nécessaire	✓
repairer_is_flagged	Réparateur signalé (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
third_party_id	Identifiant du tiers impliqué	Texte (Alphanumérique)	Texte (Alphanumérique)	7802 valeurs distinctes (ex: NONE TRS00001 TRS00002 TRS00003 TRS00005...)	100%	Non nécessaire	✓
third_party_nb_past_incidents	Nb incidents passés (tiers)	Entier	Entier	[0 ; 4]	100%	Non nécessaire	✓
witness_id	Identifiant du témoin	Texte (Alphanumérique)	Texte (Alphanumérique)	10514 valeurs distinctes (ex: NONE WIT00001 WIT00004 WIT00005 WIT00007...)	100%	Non nécessaire	✓
insured_third_party_known	Tiers connu de l'assuré (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
vehicle_id	Identifiant du véhicule	Texte (Alphanumérique)	Texte (Alphanumérique)	18069 valeurs distinctes (ex: VEH000005 VEH000010 VEH000011 VEH000018 VEH000019...)	100%	Non nécessaire	✓
vehicle_age_years	Âge du véhicule (années)	Entier	Entier	[1 ; 21]	100%	Non nécessaire	✓
vehicle_market_value	Valeur marchande du véhicule	Nombre (Décimal)	Texte (Alphanumérique)	29871 valeurs distinctes (ex: 10000,94 10001,36 10001,45 10001,53 10003,82...)	100%	Non nécessaire	✓
vehicle_overture_ratio	Ratio surévaluation du véhicule	Nombre (Décimal)	Texte (Alphanumérique)	3479 valeurs distinctes (ex: 0,008 0,009 0,01 0,011 0,012...)	100%	Non nécessaire	✓
vehicle_nb_past_claims	Nb sinistres passés (véhicule)	Entier	Entier	[0 ; 3]	100%	Non nécessaire	✓
vehicle_ownership_duration_days	Durée de possession du véhicule (jours)	Entier	Entier	[20 ; 3499]	100%	Non nécessaire	✓
time_to_report_days	Délai de déclaration (jours)	Entier	Entier	[0 ; 74]	100%	Non nécessaire	✓
nb_amendments_declaration	Nb d'amendements à la déclaration	Entier	Entier	[0 ; 4]	100%	Non nécessaire	✓
declaration_channel	Canal de déclaration du sinistre	Texte (Catégorique)	Texte (Alphanumérique)	agence courtier telephone web	100%	Non nécessaire	✓
injury_claimed_without_medical	Blessure déclarée sans preuve médicale	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
incident_is_fraud_rate	Taux de fraude du code postal de l'incident	Nombre (Décimal)	Texte (Alphanumérique)	0,1062 0,1092 0,1124 0,1144 0,115 0,1171 0,1176 0,118 0,1191 0,1223	100%	Non nécessaire	✓
incident_is_weekend	Incident en week-end (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓
incident_is_holiday	Incident un jour férié (0/1)	Booléen (Vrai/Faux)	Entier	[0 ; 1]	100%	Non nécessaire	✓

Analyse des variables selon le statut de fraude (sortie complète de l'agent)



Composition détaillée du portefeuille (sortie complète de l'agent)



Bibliographie

- [1] FRANCE ASSUREURS. *Présentation — Conférence de presse 2026*. (Mars 2026). Consulté sur https://www.franceassureurs.fr/wp-content/uploads/20260325_presentation-conference-de-presse-2.pdf
- [2] FRANCE ASSUREURS. *Données clés 2024*. (2024). Consulté sur <https://www.franceassureurs.fr/wp-content/uploads/donnees-cles-2024.pdf>
- [3] INSURANCE EUROPE. *The impact of insurance fraud*. Consulté sur <https://www.insuranceeurope.eu/mediaitem/0bf0af82-e7ef-4439-a763-d7862859d421/The+impact+of+insurance+fraud.pdf>
- [4] ALFA (Agence de Lutte contre la Fraude à l'Assurance). *ALFA News n° 48*. (Septembre 2024). Consulté sur <https://www.alfa.asso.fr/alfa-news-48-septembre-2024/>
- [5] ALFA (Agence de Lutte contre la Fraude à l'Assurance). *ALFA News n° 39*. (Juin 2023). Consulté sur <https://www.alfa.asso.fr/alfa-news-39-juin-2023-2/>
- [6] L'ARGUS DE L'ASSURANCE. *Fraude à l'assurance : une facture de 2,5 Md€ en dommages*. Consulté sur <https://www.argusdelassurance.com/institutions/fraude-a-l-assurance-une-facture-de-2-5-md-en-dommages-en-2014-alfa.96060>
- [7] L'ARGUS DE L'ASSURANCE. *Fraude à l'assurance : un coût de 50 € pour les assurés*. Consulté sur <https://www.argusdelassurance.com/acteurs/fraude-a-l-assurance-un-cout-de-50-pour-les-assures.60931>
- [8] L'ARGUS DE L'ASSURANCE. *Près d'un milliard d'euros de fraudes à l'assurance détecté en 2025*. Consulté sur <https://www.argusdelassurance.com/assurance-de-personnes/des-filieres-de-larnaque-utilisent-lintelligence-artificielle-pres-dun-milliard-deuros-de-fraudVRVQHSDANZGGZL5GXH7FHW3JU4.html>
- [9] ITESOFT. *Fraude à l'assurance : les chiffres clés (ALFA)*. Consulté sur <https://www.itesoft.com/fr/blog/fraude-assurance-chiffres-cles-alfa/>
- [10] ACPR (Autorité de Contrôle Prudentiel et de Résolution). *Gouvernance des algorithmes d'intelligence artificielle dans le secteur financier*. (Juin 2020). Consulté sur https://acpr.banque-france.fr/system/files/2025-02/20200612_gouvernance_evaluation_ia.pdf
- [11] UNION EUROPÉENNE. *Règlement général sur la protection des données (RGPD), article 22 — Décision individuelle automatisée*. Consulté sur <https://gdpr-text.com/fr/read/article-22/>
- [12] UNION EUROPÉENNE. *Règlement (UE) 2024/1689 établissant des règles harmonisées concernant l'intelligence artificielle (AI Act)*. Journal officiel de l'Union européenne, 2024.

- [13] CODE DES ASSURANCES. *Articles L.121-1, L.113-2, L.113-8 et L.113-9*. Legifrance.
- [14] CODE PÉNAL. *Article 313-1 — Escroquerie*. Legifrance.
- [15] ASSEMBLÉE NATIONALE. *Question écrite n° 4793 — Fraude au système d'immatriculation des véhicules*. Consulté sur <https://questions.assemblee-nationale.fr/q17/17-4793QE.htm>
- [16] SÉNAT. *Question écrite n° 02893 — Fraude au système d'immatriculation des véhicules*. (2025). Consulté sur <https://www.senat.fr/questions/base/2025/qSEQ250102893.html>
- [17] AHLUWALIA Saksham. *Car Insurance Fraud Detection Dataset*. Kaggle. Consulté sur <https://www.kaggle.com/datasets/ahluwaliasaksham/car-insurance-fraud-detection-dataset>
- [18] ANTHROPIC. *Claude — Assistant conversationnel d'intelligence artificielle*. Consulté sur <https://www.anthropic.com>
- [19] BREIMAN Leo. « Random Forests ». *Machine Learning*, volume 45, n° 1, 2001, p. 5-32.
- [20] FRIEDMAN Jerome H. « Greedy Function Approximation : A Gradient Boosting Machine ». *Annals of Statistics*, volume 29, n° 5, 2001, p. 1189-1232.
- [21] CHEN Tianqi, GUESTRIN Carlos. « XGBoost : A Scalable Tree Boosting System ». *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, p. 785-794.
- [22] LIU Fei Tony, TING Kai Ming, ZHOU Zhi-Hua. « Isolation Forest ». *Proceedings of the 8th IEEE International Conference on Data Mining*, 2008, p. 413-422.
- [23] LUNDBERG Scott M., LEE Su-In. « A Unified Approach to Interpreting Model Predictions ». *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.
- [24] BLONDEL Vincent D., GUILLAUME Jean-Loup, LAMBIOTTE Renaud, LEFEBVRE Etienne. « Fast unfolding of communities in large networks ». *Journal of Statistical Mechanics : Theory and Experiment*, 2008.